

Notes de cours sur l'ACP

Paul Minchella

Avril 2026

Plan principal de l'Analyse en Composantes Principales (dimension 2)




Table des matières

Motivation : ACP	2
1 Préambule algébrique	3
1.1 Matrices orthonormées	3
1.2 Théorème spectral	3
1.3 Matrice définie positive	4
1.4 Interprétation géométrique en dimension 2	4
2 Construction de la matrice de covariance	6
2.1 Définition formelle probabiliste	6
2.2 Centrage des données	7
2.3 Matrice de covariance empirique	7
2.4 Principe fondamental de l'ACP	8
2.5 Interprétation statistique des composantes principales	9
2.6 Deuxième objectif fondamental de l'ACP : la réduction de dimension	11
2.6.1 Projection optimale dans un sous-espace de dimension réduite	11
2.6.2 Solution du problème d'optimisation	11
2.6.3 Proportion de variance expliquée	12
Synthèse : ACP	13

Motivation conceptuelle de l'Analyse en Composantes Principales

Considérons un jeu de données constitué de n individus décrits par p variables quantitatives :

$$(X_i^1, \dots, X_i^p), \quad i = 1, \dots, n.$$

Chaque observation peut être vue comme un point de $\mathbb{R}^p$. Lorsque p est grand, il devient difficile de visualiser les données, de comprendre quelles variables expliquent réellement leur structure et d'identifier les directions principales de variation. C'est ce qui motive l'étude par *composantes principales* de la variabilité.

Motivation

L'analyse en composantes principales (ACP) est une méthode fondamentale d'exploration des données multidimensionnelles. Son objectif est de construire une nouvelle représentation des données permettant d'identifier les directions principales selon lesquelles les observations varient le plus.

L'idée centrale est donc la suivante :

Construire un nouveau repère orthonormé adapté aux données.

C'est-à-dire que l'on cherche une nouvelle base de $\mathbb{R}^p$ dans laquelle :

- ✓ les axes sont orthogonaux entre eux,
- ✓ chaque axe capture un maximum de variance possible,
- ✓ la variance totale des données est conservée.

Une question naturelle apparaît alors :

Comment mesurer la quantité totale d'information contenue dans les données ?

Une réponse naturelle est donnée par la matrice de variance-covariance. En effet, si l'on note V cette matrice, alors

$$\text{tr}(V) = \sum_{j=1}^p \text{Var}(\tilde{X}^j)$$

mesure la dispersion totale du nuage de points. Cette quantité joue un rôle fondamental puisqu'elle correspond à la variance totale du jeu de données et peut être interprétée comme une **mesure de la quantité globale d'information** contenue dans les variables.

Un résultat essentiel est alors le suivant ¹ :

$$\text{tr}(V) = \text{tr}(P\Lambda P^\top) = \text{tr}(\underbrace{P^\top P}_{I_p} \Lambda) = \text{tr}(\Lambda) = \sum_{j=1}^p \lambda_j$$

où $\lambda_1, \dots, \lambda_p$ sont les valeurs propres de V , ce qui implique une conservation de la quantité d'information par changement de base :

$$\sum_{j=1}^p \text{Var}(\tilde{X}^j) = \sum_{j=1}^p \lambda_j,$$

ou dit autrement : la variance totale des données est égale à la somme des valeurs propres de la matrice de covariance. Ce résultat sera au cœur de la construction de l'ACP.

On se donne alors comme objectif d'identifier les directions principales de variance du nuage de points, directions qui correspondront précisément aux vecteurs propres de la matrice de covariance. Avant d'introduire formellement l'ACP, nous avons besoin de quelques outils fondamentaux d'algèbre linéaire.

1. On montrera dans la suite de ce cours qu'une telle matrice est nécessairement diagonalisable, et de valeurs propres positives, qui plus est.

1 Préambule algébrique

1.1 Matrices orthonormées

Les matrices orthonormées jouent un rôle central en ACP car elles permettent de représenter des changements de base conservant la géométrie de l'espace.

Définition 1.1. Une matrice carrée $M \in \mathbb{R}^{p \times p}$ est dite orthonormée si

$$M^\top M = I_p \iff M^{-1} = M^\top.$$

Propriété 1.1. Une matrice est orthonormée si et seulement si ses colonnes forment une base orthonormée de $\mathbb{R}^p$.

Preuve.

Notons $C_1, \dots, C_p$ les colonnes de M . Alors

$$M^\top M = \begin{pmatrix} \langle C_1, C_1 \rangle & \cdots & \langle C_1, C_p \rangle \\ \vdots & \ddots & \vdots \\ \langle C_p, C_1 \rangle & \cdots & \langle C_p, C_p \rangle \end{pmatrix}.$$

Rappelons nous que M vérifie

$$M^\top M = I_p,$$

ce qui équivaut **terme à terme** à :

$$\langle C_i, C_j \rangle = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{sinon.} \end{cases}$$

Cela signifie exactement que les colonnes forment une base orthonormée. □

1.2 Théorème spectral

Le résultat fondamental permettant la construction de l'ACP est le théorème spectral.

Théorème 1.1 (Théorème spectral). *Toute matrice symétrique réelle $V \in \mathbb{R}^{p \times p}$ est diagonalisable dans une base orthonormée.*

Autrement dit, il existe une matrice orthonormée P telle que

$$V = P \Lambda P^\top$$

où Λ est une matrice diagonale contenant les valeurs propres de V .

Ce résultat (un des plus importants de l'algèbre, aux très nombreuses applications dans plein de différents domaines en mathématiques) garantit l'existence d'un repère orthonormé adapté à la structure de la matrice de covariance.²

2. L'orthogonalité induit de belles propriétés en *machine learning*. Elle garantit notamment que les nouvelles variables construites sont décorréliées entre elles, ce qui simplifie leur interprétation statistique. Elle stabilise également les calculs numériques : une transformation orthogonale conserve les distances, les angles et la norme des vecteurs (isométrie), ce qui évite les effets d'amplification d'erreurs d'arrondi. Enfin, elle permet de répartir la variance totale des données comme une somme de contributions indépendantes portées par chaque axe, ce qui rend possible la quantification du pourcentage de variance expliqué par chaque composante principale.

1.3 Matrice définie positive

Propriété 1.2 (Signe des valeurs propres d'une matrice définie positive). Soit $V \in \mathbb{R}^{p \times p}$ une matrice symétrique définie positive, c'est-à-dire telle que

$$\forall u \in \mathbb{R}^p, \quad u^\top V u \geq 0.$$

Alors toutes les valeurs propres de V sont positives ou nulles.

Preuve.

Soit λ une valeur propre de V , et soit $u \in \mathbb{R}^p$ un vecteur propre associé, non nul, tel que

$$Vu = \lambda u.$$

Comme $u \neq 0$ et que V est définie positive, on a

$$u^\top V u \geq 0.$$

Or, en utilisant la relation $Vu = \lambda u$, on obtient

$$u^\top V u = u^\top (\lambda u) = \lambda u^\top u.$$

Donc

$$\lambda u^\top u \geq 0.$$

Maintenant, comme u est non nul, on a

$$u^\top u = \|u\|^2 > 0.$$

On peut donc diviser par $u^\top u$, ce qui donne

$$\lambda \geq 0.$$

Ainsi, toute valeur propre de V est positive ou nulle.

□

1.4 Interprétation géométrique en dimension 2

En dimension 2, une matrice symétrique possède une interprétation géométrique particulièrement simple.

Propriété 1.3. Toute matrice symétrique définie positive

$$V = \begin{pmatrix} a & b \\ b & c \end{pmatrix}$$

définit une ellipse via la forme quadratique

$$\mathbf{x}^\top V^{-1} \mathbf{x} = 1.$$

où $\mathbf{x} = (x^1, x^2) \in \mathbb{R}^2$.

Les axes principaux de cette ellipse correspondent exactement aux vecteurs propres de V , et les longueurs de ces axes sont liées aux valeurs propres. Ainsi :

diagonaliser une matrice symétrique revient à identifier les axes principaux d'une ellipse.

Cette interprétation géométrique est exactement celle utilisée en ACP ! Le nuage de points est approximé par une ellipse multidimensionnelle dont les axes principaux correspondent aux composantes principales.

Prenons le cas de la dimension 2, comme illustré en figure 1. La matrice de variance–covariance admet une interprétation géométrique particulièrement instructive. Intuitivement, la moyenne μ indique la position centrale du nuage de points, tandis que Σ – dont le rôle est d’illustrer la dispersion autour de la moyenne μ – décrit sa forme et son orientation. Considérons l’ensemble défini par

$$\mathcal{E}_c = \{x \in \mathbb{R}^2 : (x - \mu)^\top \Sigma^{-1} (x - \mu) \leq c^2\},$$

où $c > 0$ est une constante et où l’on suppose Σ inversible. Cet ensemble est une ellipse centrée en μ . Les axes principaux de l’ellipse sont orientés selon les vecteurs propres de Σ , et leurs longueurs sont proportionnelles aux racines carrées des valeurs propres de Σ . Autrement dit :

- la moyenne μ joue le rôle de *centre* (opérateur de position) ;
- les variances déterminent la dispersion selon les directions principales ;
- la covariance oriente l’ellipse : si $\text{Cov}(X^1, X^2) \neq 0$, l’ellipse est inclinée par rapport aux axes.

Cette représentation est particulièrement utile en statistique multivariée et en apprentissage automatique : elle permet de visualiser en un coup d’œil la dispersion d’un groupe d’observations, la présence de corrélations entre variables, et la structure géométrique induite par la matrice de covariance. Elle constitue également le point de départ naturel de méthodes de réduction de dimension (telles que l’ACP), qui cherchent précisément à identifier les directions de plus grande variance.




FIGURE 1 – Illustration géométrique de la moyenne et de la matrice de variance–covariance pour un vecteur aléatoire bidimensionnel $X = (X^1, X^2)$. Les points représentent des réalisations de X , la croix indique la moyenne empirique, qui joue le rôle d’opérateur de position du nuage de points dans le plan. L’ellipse en pointillé correspond à une courbe d’iso-dispersion associée à la matrice de variance–covariance : sa taille traduit l’intensité de la dispersion, tandis que son orientation reflète la présence d’une covariance non nulle entre X^1 et X^2 .

2 Construction de la matrice de covariance

On revient à notre jeu de données initial, comprenant n observations décrites par p variables :

$$(X_i^1, \dots, X_i^p).$$

2.1 Définition formelle probabiliste

Les notions de variance et de covariance se généralisent naturellement lorsque l'on considère non plus une variable aléatoire réelle, mais un vecteur aléatoire

$$X = (X^1, \dots, X^p)^\top \in \mathbb{R}^p.$$

Dans ce cadre, la moyenne $\mu = \mathbb{E}[X] \in \mathbb{R}^p$ joue le même rôle que dans le cas unidimensionnel : elle représente un opérateur de position, c'est-à-dire le *centre* du nuage de points associé aux réalisations de X dans l'espace $\mathbb{R}^p$. La dispersion et les dépendances linéaires entre coordonnées sont quant à elles décrites par une matrice, appelée matrice de variance-covariance.

Définition 2.1 (Matrice de variance-covariance). Soit $X = (X^1, \dots, X^p)^\top$ un vecteur aléatoire de moyenne $\mu = \mathbb{E}[X]$. On appelle *matrice de variance-covariance* de X la matrice $\Sigma \in \mathbb{R}^{p \times p}$ définie par

$$\Sigma = \text{Var}(X) = \mathbb{E}[(X - \mu)(X - \mu)^\top].$$

Ses coefficients sont donnés par

$$\Sigma_{jk} = \text{Cov}(X^j, X^k), \quad 1 \leq j, k \leq p.$$

En particulier, les termes diagonaux vérifient $\Sigma_{jj} = \text{Var}(X^j)$.

Par construction, la matrice Σ est symétrique et positive semi-définie, ce qui reflète le fait qu'elle encode une dispersion quadratique.

Exemple 2.1 (Illustration en dimension 2.). Considérons $X = (X^1, X^2)^\top$ et notons

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} = \begin{pmatrix} \mathbb{E}[X^1] \\ \mathbb{E}[X^2] \end{pmatrix}.$$

Alors,

$$\begin{aligned} \Sigma &= \mathbb{E} \left[\begin{pmatrix} X^1 - \mu_1 \\ X^2 - \mu_2 \end{pmatrix} \begin{pmatrix} X^1 - \mu_1 & X^2 - \mu_2 \end{pmatrix} \right] \\ &= \begin{pmatrix} \mathbb{E}[(X^1 - \mu_1)^2] & \mathbb{E}[(X^1 - \mu_1)(X^2 - \mu_2)] \\ \mathbb{E}[(X^2 - \mu_2)(X^1 - \mu_1)] & \mathbb{E}[(X^2 - \mu_2)^2] \end{pmatrix}. \end{aligned}$$

On retrouve donc explicitement

$$\Sigma = \begin{pmatrix} \text{Var}(X^1) & \text{Cov}(X^1, X^2) \\ \text{Cov}(X^1, X^2) & \text{Var}(X^2) \end{pmatrix}.$$

Comme éayé en section précédente, le terme $\text{Cov}(X^1, X^2)$ mesure la dépendance linéaire entre les deux coordonnées : son signe indique si les variations de X^1 et X^2 tendent à aller dans le même sens (covariance positive) ou en sens opposé (covariance négative), et sa valeur absolue quantifie l'intensité de cette relation en unités quadratiques.

2.2 Centrage des données

Définition 2.2. On définit les variables centrées par

$$\tilde{X}_i^j = X_i^j - \bar{X}^j$$

avec

$$\bar{X}^j = \frac{1}{n} \sum_{i=1}^n X_i^j.$$

Le centrage garantit que l'analyse porte uniquement sur la dispersion des données et non sur leur position moyenne. Les algorithmes recentrent par défaut les variables par rapport à leur moyenne. Il n'y a donc ici aucune perte de généralité.

2.3 Matrice de covariance empirique

Définition 2.3. La matrice de covariance empirique est définie par

$$V = \frac{1}{n} \sum_{i=1}^n \tilde{X}_i \tilde{X}_i^\top$$

où

$$\tilde{X}_i = (\tilde{X}_i^1, \dots, \tilde{X}_i^p)^\top.$$

On notera les coefficients de V par $V_{jk} = \text{Cov}(\tilde{X}^j, \tilde{X}^k)$. Les termes diagonaux correspondent aux variances des variables.

Propriété 2.1 (Propriété fondamentale de la matrice de covariance empirique). *Soit*

$$V = \frac{1}{n} \sum_{i=1}^n \tilde{X}_i \tilde{X}_i^\top$$

la matrice de covariance empirique associée aux données centrées

$$\tilde{X}_i = (\tilde{X}_i^1, \dots, \tilde{X}_i^p)^\top \in \mathbb{R}^p.$$

Alors :

- (★)₁ V est symétrique,
- (★)₂ V est définie positive,
- (★)₃ toutes ses valeurs propres sont positives ou nulles :

$$\lambda_1, \dots, \lambda_p \geq 0.$$

Preuve.

- (★)₁ **Symétrie.** Pour toute observation i , la matrice $\tilde{X}_i \tilde{X}_i^\top$ est naturellement symétrique car

$$(\tilde{X}_i \tilde{X}_i^\top)^\top = \tilde{X}_i \tilde{X}_i^\top.$$

Comme une somme de matrices symétriques est symétrique (linéarité de la transposée), on en déduit que

$$V^\top = V.$$

(★)₂ **Positivité de la forme quadratique associée.** Montrons maintenant que V est définie positive, i.e.,

$$\forall u \in \mathbb{R}^p, \quad u^\top V u \geq 0.$$

Soit alors un vecteur arbitraire

$$u = (u_1, \dots, u_p)^\top \in \mathbb{R}^p.$$

Calculons la forme quadratique associée à V :

$$\begin{aligned} u^\top V u &= u^\top \left(\frac{1}{n} \sum_{i=1}^n \tilde{X}_i \tilde{X}_i^\top \right) u \\ &= \frac{1}{n} \sum_{i=1}^n u^\top (\tilde{X}_i \tilde{X}_i^\top) u \\ &= \frac{1}{n} \sum_{i=1}^n \left(u^\top \tilde{X}_i \right)^2. \end{aligned}$$

Or chaque terme $\left(u^\top \tilde{X}_i \right)^2$ étant un carré réel, il est nécessairement positif ou nul. Par conséquent :

$$u^\top V u \geq 0.$$

Cela montre que V est définie positive.

(*)₃ **Conséquence sur les valeurs propres.** Par Propriété 1.2, on en déduit donc que

$$\lambda_1, \dots, \lambda_p \geq 0.$$

□

2.4 Principe fondamental de l'ACP

Récapitulons la situation. Nous avons construit la matrice de variance-covariance empirique des données centrées :

$$V = \frac{1}{n} \sum_{i=1}^n \tilde{X}_i \tilde{X}_i^\top,$$

qui a le bon goût de contenir toute l'information sur la dispersion du nuage de points. Deux propriétés fondamentales ont été de surcroît établies.

(P1) La matrice V est symétrique réelle. Par le Théorème Spectral 1.1, il existe une matrice diagonale

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$$

et une matrice orthonormée P (i.e., $PP^\top = I_p$) telle que

$$V = P\Lambda P^\top.$$

(P2) La matrice V est définie positive. Ainsi toutes ses valeurs propres sont positives ou nulles :

$$\lambda_1, \lambda_2, \dots, \lambda_p \geq 0.$$

Quitte à tout ré-ordonner, on peut choisir de construire la nouvelle base de vecteurs propres selon l'ordre décroissant des valeurs propres :

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0.$$

Ces deux résultats permettent de comprendre le principe même de l'ACP.

Principe de l'ACP

L'analyse en composantes principales consiste à construire un nouveau repère orthonormé adapté à la structure de dispersion des données, dont les axes sont donnés par les vecteurs propres de la matrice de covariance.

Chaque axe principal correspond à une direction de variance maximale, et la variance expliquée par cet axe est exactement égale à la valeur propre associée.

Les **composantes principales** sont donc les **directions principales de variabilité** du dataset.

Ce changement de repère présente une propriété remarquable (déjà énoncée plus tôt) : la variance totale des données est conservée. En effet,

$$\sum_{j=1}^p \text{Var}(\tilde{X}^j) = \sum_{j=1}^p \lambda_j.$$

Ainsi, l'ACP ne modifie pas la quantité totale d'information contenue dans les données : elle la redistribue simplement selon de nouveaux axes orthogonaux mieux adaptés à leur structure.

2.5 Interprétation statistique des composantes principales

Notations : On note le vecteur de covariables par

$$\widetilde{\mathbf{X}} = (X^1 \ X^2 \ \dots \ X^p).$$

Étant donnée P la matrice de passage (*aux valeurs propres ordonnées de la plus grande à la plus petite*) orthogonales, on explicite son écriture en vecteurs colonnes concaténés :

$$P = [P_1 \mid P_2 \mid \dots \mid P_p].$$

Chaque vecteur propre P_k définit une nouvelle variable :

$$Z^k = P_k^\top \widetilde{\mathbf{X}}.$$

Cette variable est **appelée la k -ième composante principale** et possède une propriété fondamentale.

Propriété 2.2. Soit P_k un vecteur propre unitaire de la matrice de covariance V associé à la valeur propre λ_k . Alors la composante principale

$$Z^k = P_k^\top \widetilde{\mathbf{X}}$$

vérifie

$$\text{Var}(Z^k) = \lambda_k.$$

Preuve.

Par définition,

$$Z^k = P_k^\top \widetilde{\mathbf{X}}.$$

Calculons la variance de cette nouvelle variable. Comme les données sont centrées, on a

$$\mathbb{E}(\widetilde{\mathbf{X}}) = 0.$$

De plus, le vecteur $P_k^\top$ n'étant pas aléatoire,

$$\mathbb{E}(Z^k) = \mathbb{E}(P_k^\top \widetilde{\mathbf{X}}) = P_k^\top \mathbb{E}(\widetilde{\mathbf{X}}) = 0.$$

Ainsi,

$$\begin{aligned}
\text{Var}(Z^k) &= \mathbb{E} \left[(Z^k - \underbrace{\mathbb{E}[Z^k]}_{=0})^2 \right] \\
&= \mathbb{E} [(Z^k)^2] \\
&= \mathbb{E} [(P_k^\top \widetilde{\mathbf{X}})^2] \\
&= \mathbb{E} (P_k^\top \widetilde{\mathbf{X}} \widetilde{\mathbf{X}}^\top P_k) \\
&= P_k^\top \mathbb{E} (\widetilde{\mathbf{X}} \widetilde{\mathbf{X}}^\top) P_k
\end{aligned}$$

Mais, par définition de la matrice de covariance,

$$\mathbb{E} (\widetilde{\mathbf{X}} \widetilde{\mathbf{X}}^\top) = V.$$

Ainsi,

$$\text{Var}(Z^k) = P_k^\top V P_k.$$

Puisque P_k est vecteur propre de V associé à la valeur propre λ_k , on a que $V P_k = \lambda_k P_k$. Par conséquent,

$$P_k^\top V P_k = P_k^\top (\lambda_k P_k) = \lambda_k P_k^\top P_k.$$

Comme P_k est un vecteur unitaire,

$$P_k^\top P_k = 1.$$

Finalement,

$$\text{Var}(Z^k) = \lambda_k.$$

□

Conséquence

Dés lors, les valeurs propres mesurent exactement la variance expliquée par chaque composante principale. Comme les vecteurs propres sont orthogonaux entre eux, les composantes principales sont décorrélées :

$$\text{Cov}(Z^i, Z^j) = 0 \quad (i \neq j).$$

Cela signifie que l'information initialement répartie entre variables corrélées est **réorganisée sous forme de contributions indépendantes**.

Remarque 1 (Interprétation de la matrice P comme matrice de passage). La matrice $P = [P_1 \cdots P_p]$ est la matrice dont les colonnes sont les vecteurs propres de la matrice de covariance V , exprimés dans la base initiale (canonique). Ses colonnes définissent donc les axes principaux du nouveau repère associé à l'ACP. Si l'on note

$$Z = \begin{pmatrix} z_1 \\ \vdots \\ z_p \end{pmatrix}$$

les coordonnées d'un vecteur dans cette nouvelle base principale, alors le vecteur correspondant dans la base initiale s'écrit

$$X = z_1 P_1 + \cdots + z_p P_p = P Z.$$

Ainsi, la matrice P permet de reconstruire un vecteur exprimé dans la base principale à partir de ses coordonnées : elle réalise donc le passage de la nouvelle base vers l'ancienne. Comme les vecteurs propres forment une base orthonormée, on a

$$P^{-1} = P^\top,$$

et les coordonnées d'un vecteur $\widetilde{\mathbf{X}}$ dans la base principale s'obtiennent par projection orthogonale sur les axes principaux :

$$Z = P^\top \widetilde{\mathbf{X}}.$$

2.6 Deuxième objectif fondamental de l'ACP : la réduction de dimension

Un intérêt majeur de l'ACP apparaît lorsque le nombre de variables est grand. Supposons que les premières valeurs propres expliquent la majorité de la variance totale. Alors il devient possible de projeter les données sur un sous-espace de dimension plus faible tout en conservant l'essentiel de l'information.

Exemple 2.2. Supposons que nous disposons de $p = 500$ variables.

L'ACP révèle qu'une première composante principale explique 70% de la variance totale, une deuxième 20%, et une troisième encore 5%.

Ainsi,

$$\lambda_1 + \lambda_2 + \lambda_3 = 0.95 \sum_{j=1}^{500} \text{Var}(\tilde{X}_j).$$

Autrement dit, trois directions seulement permettent de restituer 95% de la variabilité initiale des données.

On peut alors remplacer les 500 variables initiales par seulement trois variables synthétiques sans perte significative d'information.

Et ça, en pratique, c'est ultra puissant. Détaillons un peu cet aspect là.

2.6.1 Projection optimale dans un sous-espace de dimension réduite

On va maintenant formaliser ce principe. Soit

$$R \in \mathbb{R}^{p \times d}, \quad d < p,$$

une matrice dont les colonnes forment une base orthonormée : $R^\top R = I_d$. On définit les variables projetées :

$$Z = R^\top \tilde{X}.$$

On l'a vu précédemment, la variance totale des données projetées peut se calculer grâce à la trace (invariante par changement de base) : $\text{tr}(R^\top V R)$. Cette quantité représente la dispersion totale du nuage de points après projection sur le sous-espace engendré par les colonnes de R . Le problème s'écrit alors comme :

$$\max_{R^\top R = I_d} \text{tr}(R^\top V R).$$

C'est-à-dire que l'on cherche les directions orthogonales conservant le maximum de variabilité possible.

2.6.2 Solution du problème d'optimisation

Ce problème possède une solution remarquable.

Théorème 2.1. *La matrice R maximisant*

$$\text{tr}(R^\top V R)$$

sous la contrainte $R^\top R = I_d$ est obtenue en choisissant les d vecteurs propres associés aux d plus grandes valeurs propres de V .

Plus explicitement :

$$R = [P_1 \mid P_2 \mid \cdots \mid P_d].$$

Dans ce cas,

$$R^\top V R = \text{diag}(\lambda_1, \dots, \lambda_d).$$

La variance expliquée devient alors

$$\lambda_1 + \cdots + \lambda_d.$$

2.6.3 Proportion de variance expliquée

Une fois les vecteurs propres triés, une question naturelle qu'on se pose : *combien de composantes principales faut-il conserver ?* La proportion de variance expliquée par les d premières composantes principales est donnée par le rapport :

$$\frac{\lambda_1 + \dots + \lambda_d}{\lambda_1 + \dots + \lambda_d + \dots + \lambda_p} = \frac{\sum_{i=1}^d \lambda_i}{\sum_{i=1}^p \lambda_i}. \quad (\text{PVE})$$

Cette expression représente exactement la **proportion de variabilité expliquée** par le sous-espace de dimension d engendré par les d premiers vecteurs propres. Ce rapport est bien sûr compris entre 0 et 100%.

Dans l'expression (PVE), le dénominateur est la variance totale des données, tandis que le numérateur mesure la variance des données projetées sur le sous-espace de dimension d . Ce rapport mesure donc exactement la quantité d'information préservée lors de la réduction de dimension.

En pratique, on choisit souvent la dimension d de manière à conserver entre 90% et 95% de la variance totale. Ce choix correspond à un compromis entre la réduction de dimension – qui simplifie l'analyse et stabilise les modèles statistiques – et la conservation d'une partie suffisamment importante de la variabilité initiale des données. On obtient ainsi une représentation plus compacte du jeu de données tout en conservant l'essentiel de l'information utile.

Une remarque sur les variables projetées qu vivent dans un cercle (plan factoriel). Dans le plan formé par deux composantes principales, les variables projetées apparaissent toujours à l'intérieur du cercle unité. Cette propriété provient du fait que les composantes principales sont obtenues par projection orthogonale sur une base orthonormée.

Comme P_k est un vecteur propre unitaire (c'est une colonne d'une matrice orthogonale), alors $\|P_k\| = 1$. Ainsi,

$$\sum_{j=1}^p (P_k^j)^2 = 1.$$

Cela signifie que les coordonnées des variables sur un plan principal sont contraintes par une relation de normalisation. Géométriquement, les variables projetées vivent nécessairement dans le cercle de rayon 1, appelé **cercle des corrélations**.

Synthèse : ce qu'il faut retenir sur l'Analyse en Composantes Principales

Cette section propose une synthèse des idées essentielles de l'ACP. Elle distingue deux niveaux de lecture complémentaires :

- (✓)₁ une lecture **conceptuelle et mathématique**,
- (✓)₂ une lecture **opérationnelle en statistique et en *machine learning***.

Synthèse conceptuelle

L'analyse en composantes principales repose sur l'étude de la matrice de variance-covariance des données centrées :

$$V = \frac{1}{n} \sum_{i=1}^n \widetilde{\mathbf{X}}_i \widetilde{\mathbf{X}}_i^\top.$$

Cette matrice contient toute l'information sur la dispersion du nuage de points dans l'espace des variables. Ses propriétés fondamentales sont les suivantes :

- (★)₁ La matrice V est **symétrique réelle**.

Par le théorème spectral, elle est diagonalisable dans une base orthonormée :

$$V = P \Lambda P^\top.$$

- (★)₂ La matrice V est **définie positive**.

Ses valeurs propres vérifient donc :

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0.$$

- (★)₃ Les vecteurs propres de V définissent une **nouvelle base orthonormée adaptée aux données**. Chaque direction propre correspond à une direction principale de dispersion du nuage de points.
- (★)₄ Chaque valeur propre λ_k représente exactement la **variance expliquée** par la composante principale associée : $\text{Var}(Z^k) = \lambda_k$, ce qui conduit au fait que la variance totale des données

$$\sum_{j=1}^p \text{Var}(\widetilde{X}^j)$$

est redistribuée le long des axes principaux :

$$\sum_{k=1}^p \lambda_k.$$

Synthèse *machine learning*

Du point de vue du *machine learning*, l'ACP fournit une nouvelle représentation des données :

$$Z^k = P_k^\top \widetilde{\mathbf{X}}.$$

Les variables $Z^1, \dots, Z^p$ sont appelées **composantes principales** et présentent les propriétés suivantes :

- ✓ elles sont **décorrélées entre elles**, ce qui simplifie leur interprétation statistique ;
- ✓ elles conservent la **variabilité totale** du jeu de données initial ;
- ✓ elles sont **ordonnées selon leur importance**, chaque composante expliquant une part décroissante de la variance ;
- ✓ elles permettent d'**explorer la structure géométrique du nuage de points** en projetant les observations sur des **plans principaux** de dimension faible (souvent 2 ou 3), facilitant ainsi la visualisation et l'interprétation des données.

Lecture des sorties de l'ACP. Dans R, les résultats de l'ACP sont souvent présentés à travers trois colonnes principales :

□ **coord**

Coordonnées des variables sur les axes principaux. Elles correspondent aux corrélations entre les variables initiales et les composantes principales. Une valeur élevée indique qu'une variable contribue fortement à l'axe considéré.

□ **cos2**

Qualité de représentation d'une variable sur un axe principal. Il s'agit du carré du cosinus de l'angle entre la variable et l'axe. Un **cos2** proche de 1 signifie que la variable est bien représentée dans le plan factoriel.

□ **contrib**

Contribution relative d'une variable à la construction d'un axe principal. Elle permet d'identifier les variables structurant réellement la direction principale.

L'interprétation conjointe de **coord**, **cos2** et **contrib** permet d'analyser précisément le rôle de chaque variable dans la structure du dataset.

Réduction de dimension

L'un des objectifs majeurs de l'ACP consiste à remplacer un grand nombre de variables initiales par un petit nombre de composantes principales conservant l'essentiel de l'information. On choisit alors une dimension réduite $d < p$ telle que

$$\frac{\sum_{k=1}^d \lambda_k}{\sum_{k=1}^p \lambda_k}$$

soit suffisamment proche de 1. En pratique, on retient souvent une valeur de d permettant de conserver entre 90% et 95% de la variance totale. Cela permet entre-autre :

- de simplifier l'analyse des données,
- de réduire le bruit statistique,
- de stabiliser les modèles d'apprentissage,
- de faciliter la visualisation des observations.

Outil visuel : le scree plot

Un outil graphique très utilisé pour choisir la dimension de projection d en ACP est le *scree plot*. Il s'agit d'un graphique représentant les valeurs propres

$$\lambda_1, \dots, \lambda_p$$

en fonction de leur rang. Comme les valeurs propres sont ordonnées par ordre décroissant,

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p,$$

le graphe présente généralement une décroissance rapide suivie d'un palier.

Ce graphique permet d'identifier visuellement le nombre de composantes principales pertinentes à conserver. On cherche en particulier un changement de pente marqué, appelé **coude** (*elbow*), qui sépare :

- les premières composantes principales, qui contiennent l'essentiel de la variabilité des données ;
- les suivantes, qui correspondent le plus souvent à du bruit ou à de la variabilité résiduelle.

On complète généralement cette analyse par l'étude de la **variance expliquée cumulée**. Celle-ci correspond à la quantité

$$\frac{\lambda_1 + \dots + \lambda_d}{\lambda_1 + \dots + \lambda_p},$$

qui mesure la proportion totale de variabilité conservée lorsqu'on projette les données sur les d premières composantes principales. En pratique, on choisit souvent d de manière à conserver entre **90% et 95%** de la variance totale.




FIGURE 2 – Exemple de scree plot normalisé. La courbe bleue représente la proportion de variance expliquée par chaque composante principale. La courbe rouge représente la variance expliquée cumulée. Le coude observé après les premières composantes indique le nombre de directions principales pertinentes à conserver.

Dans l'exemple illustré à la Figure 2, on observe que les 2 ou 3 premières composantes principales expliquent l'essentiel de la variabilité totale des données, tandis que les suivantes apportent une contribution minime. Il est donc naturel de restreindre l'analyse à ces premières directions principales.