

TP Statistiques – ACP

EPITA PBS2

Avril 2026

TP — ACP sur un jeu de données œnologiques

Dans ce TP, on s'intéresse à un jeu de données décrivant un ensemble de vins français évalués par des experts en œnologie. Chaque vin est caractérisé par un ensemble de variables quantitatives correspondant à des notes sensorielles (intensité olfactive, qualité aromatique, équilibre, harmonie, etc.), ainsi que par quelques variables qualitatives décrivant son contexte de production. L'objectif de ce travail est double :

- (★)₁ Comprendre la structure statistique du jeu de données ;
- (★)₂ Mettre en œuvre une **analyse en composantes principales (ACP)** afin de résumer l'information contenue dans les nombreuses variables quantitatives.

L'ACP est une méthode qui consiste à construire une nouvelle base orthonormée centrée en la moyenne des données. Cette nouvelle base est choisie de manière à capturer au mieux la variabilité du nuage de points. Elle permet ainsi de réaliser une **réduction de dimension** en construisant de nouvelles variables synthétiques, appelées **composantes principales**, qui résument l'essentiel de l'information contenue dans les variables initiales.

Dans le contexte présent, elle permettra notamment de répondre à des questions naturelles : quelles sont les grandes dimensions sensorielles structurant les vins ? Certaines variables apportent-elles une information redondante ? Peut-on représenter fidèlement les vins dans un espace de dimension plus faible ? Comment certains vins se distinguent-ils des autres ? Etc.

Dans tout le TP, on utilisera le fichier `vins.csv`. On veillera à distinguer clairement les variables qualitatives, utiles pour l'interprétation, des variables quantitatives, seules mobilisées pour la construction de l'ACP.

Partie I – Analyse exploratoire du jeu de données

1) Lecture des données

- a) Importer le fichier `vins.csv` dans R, en prenant en compte le fait que la première colonne correspond à un identifiant et non à une variable statistique.
- b) Donner le nombre d'observations et le nombre de variables.
- c) Examiner la structure générale du tableau de données à l'aide de commandes adaptées (`head`, `dim`, ...).

2) Identification des variables qualitatives et quantitatives

- a) Repérer les variables qualitatives et les variables quantitatives. Expliquer pourquoi cette distinction est essentielle avant de réaliser une ACP.
- b) Isoler dans un objet dédié les variables numériques qui serviront à construire l'analyse. Produire un résumé descriptif pour ces variables quantitatives : minimum, maximum, médiane, moyenne et **écart-type**. (`summary`, `str`, ...).
- c) Commenter brièvement les dispersions observées et discuter la pertinence d'une standardisation.

3) Première exploration du jeu de données

- a) Vérifier s'il existe des valeurs manquantes ou des observations paraissant atypiques.
- b) Indiquer, à ce stade, si le jeu de données semble adapté à une analyse multivariée.

4) Description des variables disponibles

Expliquer en quelques lignes en quoi ces variables sont susceptibles d'être corrélées, et pourquoi cela motive l'usage de l'ACP.

5) Matrice de corrélation des variables quantitatives

- a) Afficher la matrice de corrélation des variables quantitatives (package `corrplot` recommandé).
- b) Identifier d'éventuelles variables présentant des corrélations faibles ou négatives avec les autres.
- c) Expliquer en quoi la présence de corrélations fortes justifie le recours à une ACP.

Partie II – Analyse en composantes principales

1) Mise en œuvre de l'ACP

Réaliser une ACP sur les variables quantitatives. construction des axes principaux.

2) Cercle des corrélations

- a) Afficher le cercle des corrélations associé au plan principal. Expliquer précisément ce que représente ce graphique.
- b) Rappeler comment sont obtenues les coordonnées d'une variable sur ce graphe.
- c) Interpréter la proximité, l'opposition et l'orthogonalité de deux flèches.
- d) Identifier les variables structurant principalement les deux premiers axes.
- e) Proposer une interprétation qualitative des axes 1 et 2.

3) Coordonnées factorielles des variables

- a) Extraire les coordonnées des variables sur les axes principaux. Expliquer ce que représentent ces coordonnées.
- b) Préciser le lien entre ces coordonnées et les corrélations des variables avec les composantes principales. Indiquer comment ces informations permettent d'interpréter le sens statistique des axes.

4) Plan principal des individus

- a) Afficher la projection des individus sur le premier plan principal (P^1, P^2).
- b) Justifier sur le plan mathématique le fait que les nouvelles coordonnées des individus sont obtenues par projection sur les axes principaux.
- c) Indiquer ce que signifie la proximité de deux individus dans le plan principal.
- d) Commenter librement la structure du nuage d'individus. Repérer d'éventuels individus paraissant extrêmes ou isolés.

5) Coordonnées factorielles des individus

- a) Extraire les coordonnées factorielles des individus.
- b) Donner l'interprétation mathématique de ces coordonnées.
- c) Expliquer à quoi elles servent dans l'étude géométrique du nuage de points.
- d) Extraire les coordonnées sur les cinq premiers axes.

6) Valeurs propres et variance expliquée

- a) Extraire les valeurs propres de l'ACP.
- b) Rappeler leur interprétation statistique.
- c) Donner le pourcentage de variance expliqué par les deux premiers axes.
- d) Calculer la variance expliquée cumulée par le plan principal.
- e) Discuter si ce plan fournit une représentation satisfaisante des données.

7) Scree plot

- a) Construire un *scree plot* représentant :
 - la variance expliquée par chaque composante principale ;
 - la variance expliquée cumulée.
- b) Expliquer comment interpréter ce graphique. Repérer un éventuel *coude* et discuter son intérêt.
- c) Relier ce graphique à la question du choix du nombre de composantes principales à conserver.

8) Lecture détaillée de la commande `summary(Vins.PCA)`

- a) Afficher la commande `summary(Vins.PCA)` et expliquer pourquoi elle est centrale pour l'interprétation d'une ACP.
- b) Dans la partie `Individuals`, expliquer la signification des colonnes : `Dist`, `Dim.k`, `ctr`, et `cos2`.
- c) Dans la partie `Variables`, expliquer les quantités `coord`, `ctr` et `cos2`.

9) Individus et variables structurant le premier axe principal

- a) Identifier les cinq individus les plus contributifs à l'axe 1.
- b) Identifier les cinq variables les plus contributives à l'axe 1.
- c) Commenter la position des individus les plus contributifs dans le plan principal, puis interpréter la signification sensorielle du premier axe principal à partir des variables les plus contributives.

Partie III – Réduction de dimension

1) Choix d'un nombre de composantes principales

- a) Déterminer le nombre minimal de composantes principales à conserver pour expliquer au moins 95% de la variabilité totale.
- b) Vérifier la cohérence de ce choix avec le scree plot.
- c) Commenter le compromis entre fidélité à l'information initiale et compacité de la représentation.

2) Intérêt pour un pipeline de machine learning

- a) Expliquer pourquoi l'ACP peut être utilisée comme étape de prétraitement dans un pipeline usuel de modélisation.
- b) Donner au moins quatre avantages de la réduction de dimension par ACP dans un cadre de *machine learning*.
- c) Discuter l'intérêt de conserver 95% de la variance plutôt que 100%.