

Arbres de décision pour la classification

Les arbres de décision constituent une famille de modèles très utilisés en apprentissage supervisé. Leur principe consiste à **partitionner** récursivement l'espace des variables explicatives afin de construire des régions dans lesquelles la prédiction est **la plus homogène possible**. On va illustrer ce principe sur un petit exemple.

Un exemple introductif

Supposons que l'on observe des clients entrant dans une boutique et que l'on souhaite prédire s'ils vont effectuer un achat. Pour chaque client, on observe deux variables explicatives :

- $X^{(1)}$: présence d'une promotion (0 = non, 1 = oui),
- $X^{(2)}$: moment de la journée (A = après-midi, B = matin).

La variable cible est

$$Y = \begin{cases} V & \text{si le client achète ("Vrai"),} \\ F & \text{sinon ("Faux").} \end{cases}$$

Les données observées sont les suivantes :

i	$X^{(1)}$	$X^{(2)}$	Y
1	0	B	V
2	0	A	F
3	0	A	F
4	1	B	V
5	1	A	V
6	1	B	V
7	1	A	V

TABLE 1 – Jeu de données.

Notre objectif est donc de construire une fonction de prédiction

$$f(x^{(1)}, x^{(2)})$$

qui permette de prédire la classe Y d'un nouveau client.

1 Rappels de cours

Principe de prédiction dans une région

Un arbre de décision partitionne l'espace des variables explicatives en plusieurs régions

$$\mathcal{R}_1, \dots, \mathcal{R}_M.$$

Dans chaque région, la prédiction se fait par **vote majoritaire**. Si l'on note

$$p_k(\mathcal{R}_m) = \frac{1}{|\mathcal{R}_m|} \sum_{i \in \mathcal{R}_m} \mathbb{1}_{\{Y_i=k\}},$$

la proportion d'observations de classe k dans la région $\mathcal{R}_m$, alors la classe prédite est

$$c_m = \arg \max_k p_k(\mathcal{R}_m).$$

Autrement dit, on prédit simplement la classe la plus fréquente parmi les observations présentes dans la région.

Comment choisir les découpages ?

L'idée est de construire des régions aussi **pures** que possible, c'est-à-dire contenant des observations majoritairement de la même classe. Pour quantifier cette notion de pureté, on introduit la notion d'**entropie**.

Entropie d'une région

Soit une région $\mathcal{R}$. Supposons que l'observation a pour label $y_i \in \mathcal{Y}$ avec $\mathcal{Y} = \{1, 2, \dots, K\}$. Si l'on note p_k la proportion d'observations appartenant à la classe k , l'entropie de cette région est définie par

$$H(\mathcal{R}) = - \sum_{k=1}^K p_k \log p_k.$$

Cette quantité mesure l'incertitude associée à la distribution des classes.

- Si toutes les observations sont dans la même classe, l'entropie est nulle.
- Si les classes sont mélangées, l'entropie est élevée.

On cherche donc à choisir les *splits* qui **réduisent le plus possible l'entropie**.

Entropie après découpage d'une région

Dans un arbre de décision, on ne cherche pas seulement à mesurer l'incertitude d'une région $\mathcal{R}$ donnée : on cherche surtout à savoir si une variable explicative X permet de **réduire cette incertitude** en partitionnant cette région en sous-régions plus homogènes.

Pour cela, on étudie l'entropie des régions obtenues après découpage selon la variable X .

Cas d'une variable explicative binaire. Supposons que la variable X prenne deux modalités :

$$X = 0 \quad \text{ou} \quad X = 1.$$

Un découpage selon X partitionne alors la région $\mathcal{R}$ en deux sous-régions :

$$\mathcal{R}_0 = \{X = 0\}, \quad \mathcal{R}_1 = \{X = 1\}.$$

Dans chacune de ces régions, on peut calculer l'entropie comme précédemment. Si l'on note

$$p_{k|X=0} \quad \text{et} \quad p_{k|X=1}$$

les proportions (*jouant le rôle de probabilités estimées*) d'observations appartenant à la classe k dans chacune des deux régions, on obtient :

$$H(\mathcal{R}_0) = - \sum_{k=1}^K p_{k|X=0} \log p_{k|X=0},$$
$$H(\mathcal{R}_1) = - \sum_{k=1}^K p_{k|X=1} \log p_{k|X=1}.$$

Entropie moyenne après découpage. Après le découpage selon X , l'incertitude globale n'est plus décrite par l'entropie initiale $H(\mathcal{R})$, mais par la **moyenne pondérée** des entropies des deux sous-régions :

$$H(Y | X) = \mathbb{P}(X = 0) H(\mathcal{R}_0) + \mathbb{P}(X = 1) H(\mathcal{R}_1).$$

Dans un jeu de données de taille n , cette quantité s'écrit simplement

$$H(Y | X) = \frac{n_0}{n} H(\mathcal{R}_0) + \frac{n_1}{n} H(\mathcal{R}_1),$$

où n_0 et n_1 désignent le nombre d'observations dans chacune des deux régions.

Interprétation. Cette quantité mesure l'incertitude restante sur la variable Y après avoir utilisé la variable explicative X pour partitionner les données.

- Si les deux sous-régions sont très homogènes, l'entropie moyenne est faible : la variable X est informative.
- Si les sous-régions restent très mélangées, l'entropie moyenne reste élevée : la variable X apporte peu d'information.

Choix d'un découpage. La règle à retenir absolument : On choisit la variable explicative qui permet de **réduire le plus possible l'entropie**. Dés lors, on compare l'entropie initiale $H(\mathcal{R})$ avec l'entropie moyenne après découpage $H(Y | X)$, et on sélectionne la variable X pour laquelle cette dernière quantité est la plus petite.
en classification.

2 Applications numériques

Entropie du jeu de données initial

Dans notre exemple, on observe les classes suivantes : $Y = (V, F, F, V, V, V, V)$. On compte donc :

$$\#\{Y = V\} = 5, \quad \#\{Y = F\} = 2, \quad n = 7.$$

Les proportions empiriques des deux classes sont alors


$$p_V = \frac{5}{7}, \quad p_F = \frac{2}{7}.$$

L'entropie de la région initiale $\mathcal{R}$ vaut donc

$$H(\mathcal{R}) = - \sum_{k \in \{V, F\}} p_k \log p_k = - (p_V \log p_V + p_F \log p_F).$$

En remplaçant par les valeurs obtenues, on trouve

$$H(\mathcal{R}) = - \left(\frac{5}{7} \log \frac{5}{7} + \frac{2}{7} \log \frac{2}{7} \right) \approx \boxed{0.598}.$$



$$H(Y) \approx 0.598$$

Découpage selon $X^{(1)}$

On commence par étudier le découpage induit par la variable $X^{(1)}$. Cette variable prend ici deux modalités :

$$X^{(1)} = 0 \quad \text{ou} \quad X^{(1)} = 1.$$

On partitionne donc les données en deux sous-régions.

Région $X^{(1)} = 0$ Les observations telles que $X^{(1)} = 0$ sont les observations $i = 1, 2, 3$. Les classes correspondantes sont

$$(Y_1, Y_2, Y_3) = (V, F, F).$$

Les proportions empiriques sont alors

$$p_V^{(0)} = \frac{1}{3}, \quad p_F^{(0)} = \frac{2}{3}.$$

L'entropie de cette région vaut donc

$$H_0 = - \left(p_V^{(0)} \log p_V^{(0)} + p_F^{(0)} \log p_F^{(0)} \right).$$

Par application numérique,

$$H_0 = - \left(\frac{1}{3} \log \frac{1}{3} + \frac{2}{3} \log \frac{2}{3} \right) \approx 0.636.$$


Région $X^{(1)} = 1$ Les observations telles que $X^{(1)} = 1$ sont les observations $i = 4, 5, 6, 7$. Pour toutes ces observations, $Y_i = V$, d'où les proportions empiriques :

$$p_V^{(1)} = 1, \quad p_F^{(1)} = 0.$$

L'entropie vaut alors

$$H_1 = - (1 \cdot \log 1 + 0 \cdot \log 0) = H_1 = 0.$$

car par convention, on prend $0 \log 0 = 0$. C'est cohérent avec l'interprétation de l'entropie : cette région est *pure*, car toutes les observations y appartiennent à la même classe.



Entropie conditionnelle associée au *split* sur $X^{(1)}$ Pour évaluer la qualité de ce découpage, on calcule l'entropie conditionnelle, c'est-à-dire la moyenne pondérée des entropies des sous-régions obtenues. La première région contient 3 observations sur 7, et la seconde contient 4 observations sur 7. Ainsi,

$$H(Y \mid X^{(1)}) = \frac{3}{7} H_0 + \frac{4}{7} H_1.$$

En remplaçant par les valeurs précédentes,

$$H(Y \mid X^{(1)}) = \frac{3}{7} \times 0.636 + \frac{4}{7} \times 0 \approx 0.273.$$

Ainsi, le *split* selon $X^{(1)}$ fait passer l'entropie de $H(\mathcal{R}) \approx 0.598$ à

$$H(Y \mid X^{(1)}) \approx 0.273,$$

ce qui constitue une nette amélioration.

Découpage selon $X^{(2)}$

Étudions maintenant le découpage selon la variable $X^{(2)}$, qui prend les deux modalités A ou B .

Région $X^{(2)} = A$ Les observations telles que $X^{(2)} = A$ sont $i = 2, 3, 5, 7$ avec comme classes correspondantes

$$(Y_2, Y_3, Y_5, Y_7) = (F, F, V, V).$$

On compte donc

$$\#\{Y = V\} = 2, \quad \#\{Y = F\} = 2, \quad n_A = 4.$$

Les proportions empiriques se calculent simplement :

$$p_V^{(A)} = \frac{2}{4} = \frac{1}{2}, \quad p_F^{(A)} = \frac{2}{4} = \frac{1}{2}.$$

L'entropie vaut alors


$$H_A = -\left(\frac{1}{2} \log \frac{1}{2} + \frac{1}{2} \log \frac{1}{2}\right) = \log 2 \approx 0.693.$$

Région $X^{(2)} = B$ Les observations telles que $X^{(2)} = B$ sont pour $i = 1, 4, 6$.
Les classes correspondantes sont

$$(Y_1, Y_4, Y_6) = (V, V, V).$$

On obtient donc

$$p_V^{(B)} = 1, \quad p_F^{(B)} = 0, \quad \text{d'où } H_B = 0.$$



Entropie conditionnelle associée au *split* sur $X^{(2)}$ On obtient

$$H(Y | X^{(2)}) = \frac{4}{7}H_A + \frac{3}{7}H_B.$$

Donc

$$H(Y | X^{(2)}) = \frac{4}{7} \times 0.693 + \frac{3}{7} \times 0 \approx \boxed{0.396}.$$

Choix du premier *split*

On compare maintenant les deux entropies conditionnelles obtenues :

$$H(Y | X^{(1)}) \approx 0.273, \quad H(Y | X^{(2)}) \approx 0.481.$$

Comme on cherche à obtenir les régions les plus pures possibles, on choisit le *split* qui minimise l'entropie conditionnelle. Ici,

$$H(Y | X^{(1)}) < H(Y | X^{(2)}).$$

Le meilleur premier découpage est donc obtenu en séparant selon $X^{(1)}$. **La racine de l'arbre de décision est le test portant sur la variable $X^{(1)}$.**

Suite de la construction de l'arbre

Nous avons vu précédemment que le premier *split* optimal est obtenu en séparant selon la variable $X^{(1)}$. L'échantillon est donc partitionné en deux régions :

$$X^{(1)} = 0 \quad \text{et} \quad X^{(1)} = 1.$$

Région $X^{(1)} = 1$ Les observations appartenant à cette région sont $i = 4, 5, 6, 7$, où tout $Y_i = V$. Toutes les observations appartiennent à la même classe, donc la région est donc *pure* avec une entropie valant $H = 0$. On n'a donc pas besoin de subdiviser davantage cette région : elle constitue directement une feuille de l'arbre avec la prédiction

$$\hat{Y} = V.$$

Région $X^{(1)} = 0$ Les observations de cette région sont celles pour $i = 1, 2, 3$, de classes correspondantes

$$(Y_1, Y_2, Y_3) = (V, F, F).$$

Les deux classes sont encore mélangées. La région n'est pas pure. Les proportions empiriques valent d'ailleurs

$$p_V = \frac{1}{3}, \quad p_F = \frac{2}{3}.$$

D'où une entropie pour cette région valant

$$H = -\frac{1}{3} \log \frac{1}{3} - \frac{2}{3} \log \frac{2}{3} \approx 0.636.$$

Comme cette entropie est strictement positive, on peut chercher un nouveau découpage pour rendre les sous-régions plus homogènes.

Split selon $X^{(2)}$ On étudie donc le découpage de cette région selon la variable $X^{(2)}$.

Sous-région $X^{(1)} = 0$ et $X^{(2)} = A$ Les observations de cette région sont $i = 2$ et $i = 3$, où toutes les classes observées valent $Y_i = F$. D'où une entropie nulle $H_A = 0$.

Sous-région $X^{(1)} = 0$ et $X^{(2)} = B$ Seule l'observation $i = 1$ avec comme classe observée $Y_1 = V$ constitue la région. La région est donc pure avec $H_B = 0$.

Conclusion Le découpage selon $X^{(2)}$ permet donc de transformer la région initiale (entropie 0.636) en deux régions parfaitement pures (entropie nulle). Ce *split* **apporte donc un gain d'information maximal**. On subdivise donc la région $X^{(1)} = 0$ selon la variable $X^{(2)}$.

Arbre final L'arbre de décision obtenu est le suivant :

- si $X^{(1)} = 1$, on prédit V ;
- si $X^{(1)} = 0$:
 - si $X^{(2)} = A$, on prédit F ;
 - si $X^{(2)} = B$, on prédit V .

Construction de l'arbre

