Construction d'un intervalle de confiance pour les estimateurs

Paul MINCHELLA, Stéphane CHRÉTIEN

Note de cours et TD - 12 Février 2026

Table des matières

1 Motivations **2**
1.1 Principe général. 2
1.2 Remarque sur le seuil d'erreur. 2

2 Définitions et notations probabilistes **3**
2.1 Remarque, motivation et interprétation. 3

3 Cas pour des variables gaussiennes **4**
3.1 Calcul de l'espérance. 4
3.2 Calcul de la variance. 5
3.3 Loi de $\bar{X}_n$. 5

4 Centrage et réduction **7**
4.1 Contexte général. 7
4.2 Motivation : comparaison de grandeurs hétérogènes. 7
4.3 Remise à l'échelle par la variabilité. 7

5 Construction explicite de l'intervalle de confiance **8**
5.1 Étude de la variable centrée-réduite. 8
5.2 Intervalle de confiance explicite. 9

6 Cas des coefficients pour une régression linéaire. **10**
6.1 Contexte. 10
6.2 À RETENIR - Cas pratique. 11

7 Annexe – Propriétés fondamentales de la variance et de la loi normale **12**
7.1 Caractère quadratique et invariance par translation de la variance 12
7.2 Variance d'une somme de variables indépendantes 12
7.3 Fonction caractéristique de la loi normale 13

1 Motivations

On dispose d'un estimateur (ou d'un modèle) pour un paramètre θ. Considérer par exemple que l'on prélève un échantillon $X_1, \ldots, X_n$ d'une population $\mathcal{P}(m, \sigma^2)$ et que l'on souhaite estimer le paramètre d'espérance de cette dernière, notée m ici. Une construction toute naturelle pour ce faire consiste à prendre

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i$$

mais comment garantir (avec un petit seuil d'erreur toléré) que cette estimation est bonne pour caractériser et approximer le "vrai" paramètre m ?

$\bar{X}_n$ est une construction assez simple des variables aléatoires X_i, et est donc elle-même une variable aléatoire. Par conséquent, on peut calculer $\mathbb{E}[\bar{X}_n]$ et $\mathrm{Var}(\bar{X}_n)$ *(on suppose que ces valeurs existent car la population admet des paramètres finis d'espérance m et de variance σ^2).*

De plus, comment quantifier et illustrer l'aléa inhérent à cette estimation, et construire un objet qui permettrait de dire, à partir de notre réalisation observée $\bar{X}_n$, où se situe vraisemblablement le paramètre inconnu m ? Si l'on répétait l'expérience d'échantillonnage un grand nombre de fois, on obtiendrait à chaque répétition une valeur différente de $\bar{X}_n$. Il existe donc une *variabilité d'échantillonnage* autour du paramètre "vrai" m.

Notez bien que même si $\bar{X}_n$ est centré autour de m en moyenne, une réalisation particulière peut s'en écarter, parfois faiblement, parfois davantage. Il est donc nécessaire de mesurer cette dispersion afin d'évaluer la précision de notre estimation.

La question fondamentale devient alors la suivante : peut-on associer à notre évaluation empirique $\bar{X}_n$ un intervalle aléatoire qui, avec une probabilité donnée (par exemple 95%), contiendrait le paramètre inconnu m ? Une telle construction permettrait de passer d'une simple estimation ponctuelle à une *quantification explicite de l'incertitude.*

1.1 Principe général.

Soit θ un paramètre inconnu et $\hat{\theta}$ un estimateur construit à partir d'un échantillon aléatoire.

Définition 1.1 (Intervalle de confiance à seuil $1-\alpha$)**.** *Un* intervalle de confiance *est un intervalle aléatoire, noté* $\mathrm{IC}_{1-\alpha}(\hat{\theta})$*, construit à partir des données, tel que*

$$\mathbb{P}_\theta\Big(\theta \in \mathrm{IC}_{1-\alpha}(\hat{\theta})\Big) \geq 1 - \alpha, \tag{1}$$

où $\alpha \in (0,1)$ *est le* niveau de risque *et* $1-\alpha$ *le* niveau de confiance.

Dans des cas usuels où l'on peut expliciter la loi et obtenir une forme explicite de l'intervalle, l'égalité est atteinte :

$$\mathbb{P}_\theta\Big(\theta \in \mathrm{IC}_{1-\alpha}(\hat{\theta})\Big) = 1 - \alpha.$$

1.2 Remarque sur le seuil d'erreur.

On s'autorise un petit niveau de risque, par exemple $\alpha = 0.05$, c'est-à-dire un risque de 5% de ne pas couvrir le vrai paramètre m. Ce choix n'est pas arbitraire : il correspond à un compromis entre deux exigences antagonistes.

D'une part, si l'on souhaite être *très sûr* de couvrir m (en prenant α extrêmement petit), l'intervalle de confiance doit nécessairement s'élargir. En effet, garantir une probabilité de couverture proche de 1 implique de prendre une marge d'erreur très grande. Dans la limite où l'on imposerait $\alpha = 0$, on exigerait une probabilité de couverture égale à 1, et l'intervalle de confiance deviendrait alors

$$[-\infty, +\infty] \ni m,$$

donc autant vous dire que ce n'est pas très informatif... On couvre toujours le paramètre au prix de ne rien apprendre.

D'autre part, si l'on accepte un petit risque contrôlé, comme $\alpha = 0.05$, on obtient un intervalle plus resserré, donc plus informatif. On accepte la possibilité – certes rare mais non nulle – de se tromper, afin de produire une estimation exploitable.

Il s'agit donc d'un compromis fondamental : mieux vaut un intervalle raisonnablement étroit, avec un faible risque d'erreur maîtrisé, qu'une certitude absolue qui ne fournit aucune information pratique.

2 Définitions et notations probabilistes

Pour un maximum de clarté, on présente ici les notations fondamentales.

Définition 2.1 (Loi de probabilité d'une variable aléatoire réelle)**.** *La* loi *(ou* distribution*) d'une variable aléatoire décrit la manière dont ses valeurs possibles se répartissent dans l'espace des nombres réels, avec leurs probabilités associées.*

Pour une variable aléatoire continue T, cette loi est décrite par :

- *une* ***fonction de répartition*** $F(t) = \mathbb{P}(T \leq t)$*, qui donne la probabilité que T prenne une valeur inférieure ou égale à t ;*
- *une* ***densité de probabilité*** $f(t)$ *telle que $F'(t) = f(t)$ pour tout t réel.*

Il est tout naturelle de considérer l'individu "médian", c'est-à-dire celui qui, lorsque l'on ordonne les données du plus petit au plus grand, séparer le jeu de données en deux. La médiane med est donc le nombre de la distribution tel que $\mathbb{P}(T \leq \text{med}) = F(\text{med}) = 50\%$. En introduisant F^{-1} comme notation pour exprimer la réciproque de la fonction de répartition, on obtient simplement $\text{med} = F^{-1}(0.5)$.

Et si on remplaçait 50% par une probabilité générale $\tau \in]0, 1[$?

Définition 2.2 (Quantile d'ordre τ)**.** *Soit T une variable aléatoire réelle de fonction de répartition F. Pour $\tau \in]0, 1[$, on appelle* quantile d'ordre τ *le réel*

$$q_\tau = \inf \big\{ x \in \mathbb{R} \ : \ F(x) \geq \tau \big\}.$$

Lorsque F est continue et strictement croissante, le quantile est unique et s'écrit simplement

$$q_\tau = F^{-1}(\tau).$$

Autrement dit, q_τ est la première valeur (dans les observations ordonnées) telle qu'au moins une proportion τ de la distribution se situe en dessous. Referez-vous à la Figure 1 pour une belle illustration de cette notion.

2.1 Remarque, motivation et interprétation.

Le quantile d'ordre τ généralise naturellement la médiane (cas $\tau = 0.5$). Il représente le seuil en dessous duquel se situe une proportion τ de la distribution. En notant donc $\mathbb{P}(T \leq q_\tau) = \tau$, on a :

- $q_{0.25}$ correspond au premier quartile ;
- $q_{0.50}$ est la médiane ;
- $q_{0.75}$ est le troisième quartile.

Cette notion permet de décrire la structure d'une distribution sans faire intervenir sa moyenne, ce qui est particulièrement pertinent en présence d'asymétrie ou de valeurs extrêmes. Plus généralement, les quantiles fournissent une description robuste de la dispersion et de la position d'une variable aléatoire, ce qui va nous servir pour construire un intervalle de confiance.

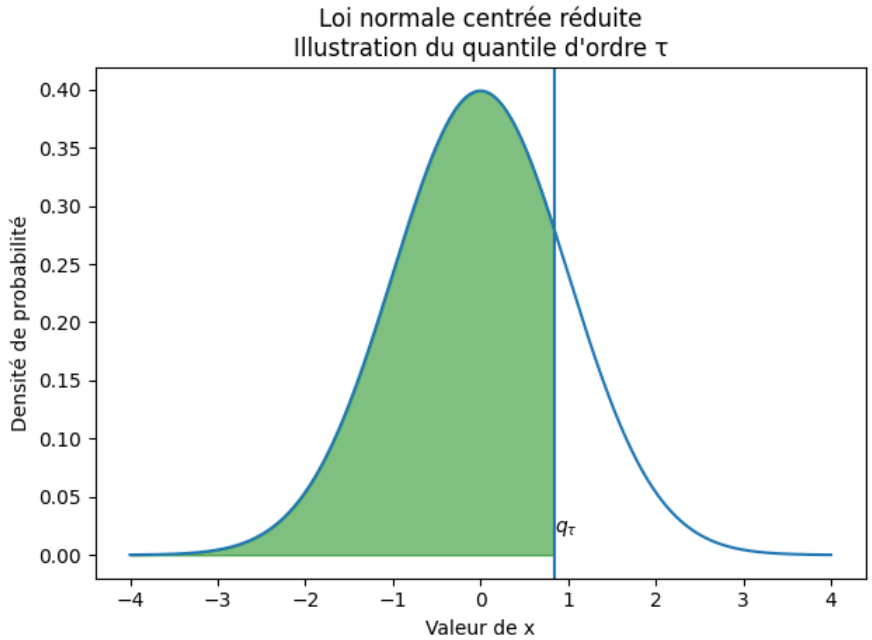

FIGURE 1 – Illustration du quantile q_τ pour une loi normale centrée réduite. La zone colorée en vert représente la probabilité $\mathbb{P}(Z \leq q_\tau) = \tau$, c'est-à-dire la proportion τ de la distribution située à gauche du quantile.

3 Cas pour des variables gaussiennes

Une première approche qui simplifie grandement les choses mais reste très performante sur le plan formel et pratique étudie le cas où :

$$X_1, \ldots, X_n \overset{\text{i.i.d}}{\sim} \mathcal{N}(m, \sigma^2).$$

Considérer toujours la même moyenne empirique dont l'estimateur s'écrit

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i,$$

on cherche à déterminer l'espérance et la variance de ce dernier. Il s'agit ici de comprendre la moyenne probabiliste de $\bar{X}_n$ (et on espère bien qu'en moyenne, la moyenne estimée est bien la moyenne probabiliste de la population... !) – c'est-à-dire, la valeur attendue de l'estimateur $\bar{X}_n$, mais aussi comment celui-ci se disperse autour de la moyenne.

3.1 Calcul de l'espérance.

On applique l'opérateur de l'espérance $\mathbb{E}$ à la variable $\bar{X}_n$:

$$\begin{aligned}
\mathbb{E}[\bar{X}_n] &= \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] \\
&= \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}\left[X_i\right] && \text{par linéarité de l'espérance} \\
&= \frac{1}{n}\sum_{i=1}^{n} m && \text{car tous les } X_i \text{ sont d'espérance } m \\
&= \frac{1}{n} n \times m = m
\end{aligned}$$

Ainsi, on a bien un estimateur non biaisé car en moyenne (dans un monde où l'on répète l'expérience un très grand nombre de fois), l'estimateur $\bar{X}_n$ estime bien l'espérance m :

$$\boxed{\mathbb{E}[\bar{X}_n] = m} \tag{2}$$

ce qui est très rassurant.

3.2 Calcul de la variance.

On applique désormais l'opérateur de variance à l'estimateur.

$$\begin{aligned}
\mathrm{Var}(\bar{X}_n) &= \mathrm{Var}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] \\
&= \frac{1}{n^2}\mathrm{Var}\left[\sum_{i=1}^{n} X_i\right] && \text{car la variance est quadratique} \\
&= \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}\left[X_i\right] && \text{car les variables } X_i \text{ sont indépendantes} \\
&= \frac{1}{n^2}\sum_{i=1}^{n}\sigma^2 && \text{car tous les } X_i \text{ sont de variance } \sigma^2 \\
&= \frac{1}{n^2} n \times \sigma^2
\end{aligned}$$

et donc conduit au résultat :

$$\boxed{\mathrm{Var}(\bar{X}_n) = \frac{\sigma^2}{n}}$$

Ce résultat est remarquable car la moyenne empirique réduit la variance des individus. Et c'est aussi un résultat très rassurant car il évoque l'idée suivante : Plus on augmente la taille de l'échantillon, plus la variabilité autour de la moyenne diminue et on converge bien vers une constante, cette même constant m que l'on cherche à estimer ! C'est la loi des grands nombre.

Le caractère quadratique, invariant par translation et somme de variables indépendantes de la variance sont discutés plus loin, en annexe.

On notera que si X et Y sont indépendantes (c'est donc dire qu'elles ne s'influencent ni l'autre ni l'autre), alors la variabilité d'information de la somme des deux $\mathrm{Var}(X+Y)$ est la même quantité que si je somme la variabilité d'information de chacun de ces variables $\mathrm{Var}(X) + \mathrm{Var}(Y)$.

3.3 Loi de $\bar{X}_n$.

Enfin, une propriété important de la somme de variables gaussiennes indépendantes est qu'il s'agit d'une variable gaussienne.

Proposition 3.1 (Somme de gaussiennes indépendantes)**.** *Étant donné les observations* $X_1, \ldots, X_n \overset{i.i.d}{\sim} \mathcal{N}(m, \sigma^2)$ ***indépendantes****, la moyenne empirique* $\bar{X}_n$ *suit une loi gaussienne :*

$$\bar{X}_n \sim \mathcal{N}\left(m, \frac{\sigma^2}{n}\right) \tag{3}$$

Preuve. On manipule les variables via leur fonction caractéristique. Il s'agit d'une transformée aux propriétés remarquables qui s'exprime comme

$$\phi_X : t \mapsto \mathbb{E}\left[\exp(itX)\right]$$

où $i^2 = -1$ est le célèbre imaginaire pur, $t \in \mathbb{R}$ et X une variable aléatoire réelle. Cette transformée **caractérise la loi d'une variable aléatoire** et a le bon goût, pour deux variables aléatoire **indépendantes** X et Y, de vérifier :

$$\phi_{X+Y} = \phi_X \cdot \phi_Y$$

c'est-à-dire que la fonction caractéristique d'une somme indépendante est le produit des fonctions caractéristiques. *On peut d'ailleurs relever que la transformée d'une somme en produit provient naturellement de l'exponentielle dans la définition de la transformée.* Ce qui est valable pour une somme de 2 variables indépendantes l'est pour n variables indépendantes. Toutes les propriétés citées ici sont démontrées en Section 7.3, pour les curieuses et curieux.

Par théorème du transfert, on peut montrer que pour $X \sim \mathcal{N}(m, \sigma^2)$, alors le terme de sa fonction caractéristique s'exprime pour $t \in \mathbb{R}$ comme :

$$\phi_X(t) = \exp\left(imt - \frac{1}{2}\sigma^2 t^2\right). \tag{4}$$

On démontre cela en Proposition 7.3. Dans ce cas, la fonction caractéristique de $\bar{X}_n$ va s'exprimer pour $t \in \mathbb{R}$ comme :

$$\begin{aligned}
\phi_{\bar{X}_n}(t) &= \mathbb{E}\left[\exp\left(it\bar{X}_n\right)\right] \\
&= \mathbb{E}\left[\exp\left(it\frac{1}{n}\sum_{i=1}^{n} X_i\right)\right] \\
&= \mathbb{E}\left[\prod_{i=1}^{n} \exp\left(it\frac{1}{n}X_i\right)\right] && \text{par propriété de l'exponentielle} \\
&= \prod_{i=1}^{n} \mathbb{E}\left[\exp\left(it\frac{1}{n}X_i\right)\right] && \text{par indépendance des variables} \\
&= \prod_{i=1}^{n} \phi_{X_i}\left(\frac{t}{n}\right) \\
&= \left(\phi_{X_1}\left(\frac{t}{n}\right)\right)^n && \text{par identique distribution} \\
&= \left(\exp\left(imt/n - \frac{1}{2}\sigma^2 t^2/n^2\right)\right)^n && \text{par l'équation (4)} \\
&= \exp\left(imt - \frac{1}{2}\frac{\sigma^2}{n}t^2\right) && \text{par propriété de l'exponentielle (4)}
\end{aligned}$$

C'est exactement la fonction caractéristique d'une loi normale d'espérance m et de variance σ^2/n. $\square$

En fait on n'avait même pas besoin de calculer explicitement $\mathbb{E}[\bar{X}_n]$ et $\mathrm{Var}(\bar{X}_n)$ vu qu'on pouvait directement lire ces informations dans la fonction caractéristique... Mais ça reste très important de savoir faire ces calculs.

4 Centrage et réduction

4.1 Contexte général.

On peut se demander s'il existe statistiquement une façon pertinente de ramener toutes les variables à la même échelle sans dimension. On comprend tout de suite qu'une telle procédure nous permettrait de comparer l'incomparable : recentrer par rapport à la moyenne et standardiser (c'est-à-dire, diviser par l'écart-type de la distribution) nous offre la possibilité de comparer l'ordre de grandeur du nombre de banane par individu à celui de leur consommation annuel d'essence. *Mais prenons un exemple plus sérieux pour bien comprendre les enjeux ici.*

4.2 Motivation : comparaison de grandeurs hétérogènes.

Pour illustrer le centrage et la réduction dans un contexte concret, considérons une campagne de mesures de qualité de l'air intérieur réalisée dans plusieurs logements. On mesure :

- X : Concentration en dioxyde de carbone (CO_2), exprimée en parties par million (ppm) ;
- Y : Concentration en particules fines PM2.5, exprimée en microgrammes par mètre cube (μg/m^3).

Les ordres de grandeur sont très différents. la concentration en CO_2 dans un logement bien ventilé est typiquement de l'ordre de 400 à 1000 ppm. Pour les PM2.5, des valeurs de l'ordre de 10 à 25 μg/m^3 sont déjà considérées comme significatives, et au-delà de 25 μg/m^3 (recommandation OMS sur 24h), la qualité de l'air est jugée préoccupante. Ainsi, les unités diffèrent, les amplitudes diffèrent, et les seuils sanitaires ne sont pas comparables directement. Si l'on souhaite comparer la dispersion relative de ces deux variables, ou les utiliser conjointement dans un modèle statistique, il est nécessaire de les ramener à une échelle commune.

4.3 Remise à l'échelle par la variabilité.

Diviser une variable par son écart-type permet de la ramener à une échelle sans dimension, exprimée en nombre d'écarts-types. On obtient ainsi une variable dont la dispersion est normalisée. Pour que cette opération fasse sens , il faut recentrer les variables, car l'écart-type mesure la dispersion autour de la moyenne.

Définition 4.1 (Centrage et réduction)**.** *Soit X une variable aléatoire réelle de moyenne m et d'écart-type $\sigma > 0$.*

- *La variable* centrée *associée à X est : $\tilde{X} = X - m$.*
- *La variable* centrée-réduite *(ou standardisée) est :*

$$Z = \frac{X - m}{\sigma}.$$

Notons que l'on a pour espérance

$$\mathbb{E}[Z] = \mathbb{E}\left[\frac{X - m}{\sigma}\right] = \frac{1}{\sigma}\left(\mathbb{E}\left[X\right] - m\right) = 0$$

et pour variance

$$\mathrm{Var}(Z) = \mathrm{Var}\left(\frac{X - m}{\sigma}\right) = \mathrm{Var}\left(\frac{X}{\sigma} - \frac{m}{\sigma}\right) = \mathrm{Var}\left(\frac{X}{\sigma}\right) = \frac{1}{\sigma^2}\mathrm{Var}(X) = 1.$$

N'oubliez pas que la variance est invariante par translation et constitue un opérateur quadratique.

Interprétation. La variable Z s'interprète comme le nombre d'écarts-types séparant une observation de la moyenne. Et donc, dans notre exemple concret, même si X (CO_2) est de l'ordre de plusieurs centaines de ppm et Y (PM2.5) de l'ordre de quelques dizaines de μg/m^3, leurs versions centrées-réduites deviennent comparables : elles sont désormais exprimées dans une unité abstraite commune, fondée sur leur variabilité propre.

5 Construction explicite de l'intervalle de confiance

5.1 Étude de la variable centrée-réduite.

Reprenons notre scénario $X_1, \ldots, X_n \overset{\text{i.i.d}}{\sim} \mathcal{N}(m, \sigma^2)$. On sait désormais que

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i \sim \mathcal{N}\left(m, \frac{\sigma^2}{n}\right)$$

et donc par centrage et réduction ;

$$Z = \frac{\bar{X}_n - m}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$$

La gaussienne centrée-réduite est bien connue et simple à manipuler, et c'est précisément pour cette raison qu'elle intervient naturellement dans la construction des intervalles de confiance. Gardons en tête notre objectif : à partir de l'estimation $\bar{X}_n$, construire un intervalle aléatoire

$$\mathrm{IC}_{1-\alpha}(\bar{X}_n)$$

tel que

$$\mathbb{P}\big(m \in \mathrm{IC}_{1-\alpha}(\bar{X}_n)\big) = 1 - \alpha.$$

Pour atteindre cette propriété de couverture, introduisons le quantile d'ordre $1 - \alpha/2$ de la loi normale centrée réduite, que l'on note

$$q_{1-\alpha/2}.$$

On s'appuiera sur la Figure 2 pour se convaincre visuellement des arguments analytiques.

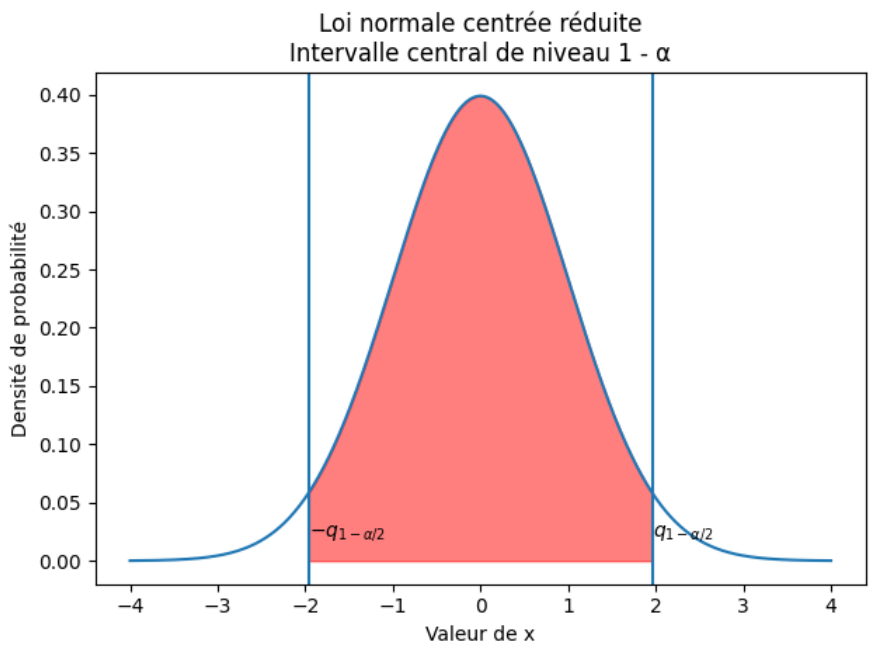

FIGURE 2 – Loi normale centrée réduite. La zone rouge représente la probabilité centrale $1-\alpha$, délimitée par les quantiles $\pm q_{1-\alpha/2}$.

Par définition du quantile, si $Z \sim \mathcal{N}(0,1)$, on a

$$\mathbb{P}(Z \leq q_{1-\alpha/2}) = 1 - \frac{\alpha}{2}.$$

Cependant, notre objectif n'est pas de construire une borne unilatérale, mais un intervalle *symétrique* autour de 0 qui couvre une probabilité totale égale à $1-\alpha$. Observons alors que, par symétrie de la loi normale centrée réduite,

$$\mathbb{P}(Z \in [0, q_{1-\alpha/2}]) = \mathbb{P}(Z \in [-q_{1-\alpha/2}, 0]) = 1 - \frac{\alpha}{2}$$

(on peut s'en convaincre en explicitant la formule avec l'intégrale et en effectuant un changement variable naturelle $z = -x, \mathrm{d}z = -\mathrm{d}x$.) Et donc, par complémentarité :

$$\mathbb{P}(Z \leq -q_{1-\alpha/2}) = \frac{\alpha}{2}.$$

Ainsi, la probabilité que Z appartienne à l'intervalle central

$$[-q_{1-\alpha/2},\, q_{1-\alpha/2}]$$

est donnée par

$$\begin{aligned}\mathbb{P}\big(-q_{1-\alpha/2} \leq Z \leq q_{1-\alpha/2}\big) &= \mathbb{P}(Z \leq q_{1-\alpha/2}) - \mathbb{P}(Z \leq -q_{1-\alpha/2}) \\ &= \left(1 - \frac{\alpha}{2}\right) - \frac{\alpha}{2} \\ &= 1 - \alpha.\end{aligned} \tag{Eqα}$$

Autrement dit, l'intervalle central

$$[-q_{1-\alpha/2},\, q_{1-\alpha/2}]$$

contient exactement une proportion $1-\alpha$ de la distribution normale centrée réduite.

Cette observation est le cœur du mécanisme : en contrôlant la probabilité centrale sous la loi normale, on obtient exactement la proportion souhaitée $1-\alpha$. Il ne restera alors qu'à ramener cette construction à la variable aléatoire normalisée associée à $\bar{X}_n$.

5.2 Intervalle de confiance explicite.

Il ne nous plus qu'une petite étape pour obtenir l'intervalle de confiance souhaité. Repartons du résultat (Eqα).

$$\begin{aligned}&\mathbb{P}\big(-q_{1-\alpha/2} \leq Z \leq q_{1-\alpha/2}\big) = 1-\alpha \\ &\mathbb{P}\left(-q_{1-\alpha/2} \leq \frac{\bar{X}_n - m}{\sigma/\sqrt{n}} \leq q_{1-\alpha/2}\right) = 1-\alpha \\ &\mathbb{P}\left(-\frac{\sigma}{\sqrt{n}} q_{1-\alpha/2} \leq \bar{X}_n - m \leq \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2}\right) = 1-\alpha \\ &\mathbb{P}\left(\bar{X}_n - \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2} \leq m \leq \bar{X}_n + \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2}\right) = 1-\alpha\end{aligned} \tag{5}$$

Ça y est ! On vient enfin de construire un intervalle aléatoire :

$$\mathrm{IC}_{1-\alpha}(\bar{X}_n) = \left[\bar{X}_n - \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2}\ ,\ \bar{X}_n + \frac{\sigma}{\sqrt{n}} q_{1-\alpha/2}\right]$$

tel que

$$\mathbb{P}\big(m \in \mathrm{IC}_{1-\alpha}(\bar{X}_n)\big) = 1-\alpha.$$

Il est essentiel de bien comprendre la nature de cet objet : l'intervalle est aléatoire (car il dépend de $\bar{X}_n$), tandis que le paramètre m est fixe mais inconnu. La probabilité $1-\alpha$ porte donc sur le mécanisme d'échantillonnage, et non sur le paramètre lui-même. Notez qu'en pratique, une fois l'échantillon observé, $\bar{X}_n$ prend une valeur numérique, et l'intervalle devient un intervalle déterminé. On dira alors que l'on dispose d'un intervalle de confiance au niveau $1-\alpha$ pour m.

6 Cas des coefficients pour une régression linéaire.

6.1 Contexte.

On considère le modèle linéaire

$$Y_i = \beta_0 + \beta_1 X^{(1)} + \cdots + \beta_p X^{(p)} + \varepsilon_i, \quad i = 1, \ldots, n$$

avec

$$\varepsilon_i \overset{\text{i.i.d}}{\sim} \mathcal{N}(0, \sigma^2).$$

On souhaite savoir si la variable $X^{(j)}$ est significative au modèle et donc si le "vrai" coefficient β_j est significativement non nul. Pour ce faire, comme $\hat{\beta}_j$ est une variable aléatoire, on peut établir l'intervalle de confiance de ce dernier. Notons deux choses :

1. Avec les hypothèses usuelles : $\mathbb{E}[\hat{\beta}_j] = \beta_j$.
2. On définit l'erreur standard comme $\widehat{\text{se}}(\beta_j) = \sqrt{\widehat{\text{Var}}(\beta_j)}$(on verra plus tard en TD ce que vaut cette variance).

On peut donc centrer et réduire cet estimateur, définit comme :

$$T_j = \frac{\hat{\beta}_j - \beta_j}{\widehat{\text{se}}(\beta_j)}$$

On admettra le résultat suivant, sous de bonnes hypothèses *(matrice de design de rang plein, erreurs normales, variance estimée de façon non biaisée)* :

$$T_j \sim \text{St}(n - p - 1)$$

c'est-à-dire que T_j suit une loi de Student à $n - p - 1$ degré de liberté.

Et cela tombe bien. La construction de l'intervalle de confiance pour β_j suit exactement la même logique que dans le cas normal : centrée en 0 et symétrique. On peut donc introduire le quantile d'ordre $1 - \alpha/2$ de la loi de Student à $n - p - 1$ degrés de liberté, que l'on note

$$t_{1-\alpha/2}.$$

Par définition du quantile et par symétrie de la loi de Student, on a

$$\mathbb{P}\big(-t_{1-\alpha/2} \leq T_j \leq t_{1-\alpha/2}\big) = 1 - \alpha.$$

En remplaçant T_j par son expression, on obtient

$$\mathbb{P}\left(-t_{1-\alpha/2} \leq \frac{\hat{\beta}_j - \beta_j}{\widehat{\text{se}}(\hat{\beta}_j)} \leq t_{1-\alpha/2}\right) = 1 - \alpha.$$

Il suffit alors de réarranger l'inégalité pour isoler β_j, ce qui conduit à l'intervalle de confiance

$$\text{IC}_{1-\alpha}(\hat{\beta}_j) = \left[\hat{\beta}_j - t_{1-\alpha/2}\,\widehat{\text{se}}(\hat{\beta}_j)\ ,\ \hat{\beta}_j + t_{1-\alpha/2}\,\widehat{\text{se}}(\hat{\beta}_j)\right].$$

c'est-à-dire que le vrai paramètre β_j appartient à $\text{IC}_{1-\alpha}(\hat{\beta}_j)$ avec probabilité $1 - \alpha$. On retrouve ainsi exactement la même structure que dans le cas normal :

$$\text{estimateur} \ \pm\ \text{quantile} \times \text{erreur standard},$$

la seule différence étant que le quantile provient désormais d'une loi de Student au lieu de la loi normale.

6.2 À RETENIR - Cas pratique.

Chaque coefficient β_j du modèle multi-linéaire mesure l'effet marginal de la variable $X^{(j)}$ sur la variable réponse Y, toutes choses égales par ailleurs. Autrement dit, β_j quantifie la variation moyenne de Y associée à une variation unitaire de $X^{(j)}$.

Or, comme $\hat{\beta}_j$ est un estimateur aléatoire, nous ne pouvons pas nous contenter de sa valeur numérique observée. Il faut déterminer si l'effet estimé est réellement différent de zéro, ou s'il peut simplement s'expliquer par la variabilité d'échantillonnage. C'est bien le rôle de l'intervalle de confiance :

$$\beta_j \in \mathrm{IC}_{1-\alpha}(\hat{\beta}_j),$$

qui est, comme nous l'avons vu, construit sur l'estimateur $\hat{\beta}_j$ **standardisé** (et donc, ramené à une échelle faisant sens). Si

$$0 \in \mathrm{IC}_{1-\alpha}(\hat{\beta}_j),$$

alors la valeur $\beta_j = 0$ reste compatible avec les données au niveau de confiance $1-\alpha$. Nous **ne** disposons donc **pas** d'éléments suffisants pour affirmer que $X^{(j)}$ a un effet linéaire significatif sur Y. En pratique, on dira alors que la variable $X^{(j)}$ n'est pas significative au seuil α.

À l'inverse, si

$$0 \notin \mathrm{IC}_{1-\alpha}(\hat{\beta}_j),$$

alors l'hypothèse $\beta_j = 0$ est incompatible avec les données au niveau $1-\alpha$. On conclut que **la variable $X^{(j)}$ contribue significativement à l'explication de Y** dans le cadre du modèle linéaire considéré.

Bref, les intervalles de confiance ne servent pas uniquement à quantifier l'incertitude d'un paramètre : ils constituent un outil fondamental pour décider, de manière statistiquement contrôlée, quelles variables doivent être conservées dans un modèle.

7 Annexe – Propriétés fondamentales de la variance et de la loi normale

7.1 Caractère quadratique et invariance par translation de la variance

Définition 7.1 (Variance d'une variable aléatoire)**.** *Pour une variable aléatoire réelle X admettant un moment d'ordre 2 fini, on définit*

$$\mathrm{Var}(X) = \mathbb{E}\big[(X - \mathbb{E}[X])^2\big] .$$

Proposition 7.1. *Pour toute variable aléatoire réelle X de variance finie et pour tous $\lambda, \alpha \in \mathbb{R}$,*

$$\mathrm{Var}(\lambda X + \alpha) = \lambda^2 \,\mathrm{Var}(X).$$

Preuve. Posons $Y = \lambda X + \alpha$. Par linéarité de l'espérance,

$$\mathbb{E}[Y] = \lambda \mathbb{E}[X] + \alpha.$$

On calcule alors

$$Y - \mathbb{E}[Y] = \lambda X + \alpha - (\lambda \mathbb{E}[X] + \alpha) = \lambda(X - \mathbb{E}[X]).$$

En élevant au carré :

$$(Y - \mathbb{E}[Y])^2 = \lambda^2 (X - \mathbb{E}[X])^2.$$

En prenant l'espérance :

$$\mathrm{Var}(Y) = \mathbb{E}\big[(Y - \mathbb{E}[Y])^2\big] = \lambda^2 \mathbb{E}\big[(X - \mathbb{E}[X])^2\big] = \lambda^2 \,\mathrm{Var}(X).$$

Le terme α disparaît naturellement, ce qui montre simultanément l'invariance par translation et le caractère quadratique (homogénéité de degré 2). □

7.2 Variance d'une somme de variables indépendantes

Rappelons que la covariance de deux variables aléatoires réelles X et Y de moment d'ordre 2 fini est définie par

$$\mathrm{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

Cela mesure l'effet aléatoire qu'à une variable X sur Y et symétriquement.

Rappelez vous bien de la définition : Si X et Y sont indépendantes, alors pour toute fonction mesurable f et g intégrables, on a

$$\mathbb{E}[f(X)g(Y)] = \mathbb{E}[f(X)]\,\mathbb{E}[g(Y)].$$

En particulier, en prenant f et g comme étant l'identité id, on obtient

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y].$$

Par conséquent,

$$\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0.$$

Ainsi, l'indépendance implique l'absence de corrélation. Il est important de noter que la réciproque est fausse en général : une covariance nulle n'implique pas nécessairement l'indépendance. On peut proposer ensuite une propriété essentielle sur la variance.

Proposition 7.2 (Variance d'une somme de variables indépendantes)**.** *Si X et Y sont deux variables aléatoires indépendantes de variance finie, alors*

$$\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y).$$

Preuve. On utilise l'identité générale

$$\mathrm{Var}(X+Y) = \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\,\mathrm{Cov}(X,Y).$$

Or, si X et Y sont indépendantes,

$$\mathrm{Cov}(X,Y) = 0.$$

D'où le résultat. Par récurrence immédiate, si $X_1, \ldots, X_n$ sont indépendantes,

$$\mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{Var}(X_i).$$

□

7.3 Fonction caractéristique de la loi normale

Les notions abordées dans cette sous-section sont purement hors programmes, mais elles exposent et démontrent l'utilité d'outils essentielles en probabilité, eux-mêmes sous-jacents aux propriétés statistiques abordées dans notre cours.

Définition 7.2 (Fonction caractéristique)**.** *La fonction caractéristique d'une variable aléatoire X est définie par*

$$\varphi_X(t) = \mathbb{E}\left[e^{itX}\right], \qquad t \in \mathbb{R}.$$

On peut voir la fonction caractéristique comme une manière élégante de « résumer » toute l'information de la loi de X à l'aide d'exponentielles complexes. Son intérêt profond est qu'elle simplifie considérablement l'étude des sommes de variables aléatoires et permet d'identifier les lois via leurs transformées. Cette fonction φ joue en probabilité le même rôle que la transformée de Fourier en analyse : elle permet de passer du domaine des variables aléatoires au domaine fréquentiel, où les convolutions *(ou sommes indépendantes de variables aléatoires)* deviennent des produits.

On peut voir $t \mapsto e^{itX}$ comme une "onde test" construite avec les valeurs "fréquentes" que peut prendre X via sa densité de probabilité, dont on étudie la valeur attendue (d'où la fameuse intervention de l'espérance $\mathbb{E}$). On passe d'une description "spatiale" (en x) à une description "spectrale" (en t).

Une propriété ultra essentielle, au même titre que la fonction de répartition, est que la **fonction caractéristique caractérise la loi** *(le nom est plutôt bien choisi, n'est-ce pas ?)*.

Théorème 7.1 (Caractérisation de la loi par la fonction caractéristique)**.** *Soient X et Y deux variables aléatoires réelles. Si leurs fonctions caractéristiques coïncident, c'est-à-dire si*

$$\forall t \in \mathbb{R}, \qquad \varphi_X(t) = \varphi_Y(t),$$

alors X et Y ont la même loi. Autrement dit, la fonction caractéristique ***détermine entièrement*** *la loi.*

Preuve. On donne ici l'idée principale de la démonstration.

Supposons que $\varphi_X(t) = \varphi_Y(t)$ pour tout t. Si X et Y admettent des densités f_X et f_Y intégrables, on a

$$\varphi_X(t) = \int_{\mathbb{R}} e^{itx} f_X(x)\,dx, \qquad \varphi_Y(t) = \int_{\mathbb{R}} e^{itx} f_Y(x)\,dx.$$

L'égalité des fonctions caractéristiques implique que

$$\forall t \in \mathbb{R}, \qquad \int_{\mathbb{R}} e^{itx} f_X(x)\,dx = \int_{\mathbb{R}} e^{itx} f_Y(x)\,dx.$$

En soustrayant les deux expressions, on obtient

$$\forall t \in \mathbb{R}, \qquad \int_{\mathbb{R}} e^{itx} \big(f_X(x) - f_Y(x)\big)\,dx = 0.$$

Posons

$$g(x) = f_X(x) - f_Y(x).$$

Alors $g \in L^1(\mathbb{R})$ et sa transformée de Fourier vérifie

$$\forall t \in \mathbb{R}, \qquad \int_{\mathbb{R}} e^{itx} g(x)\,dx = 0.$$

Autrement dit, la transformée de Fourier de g est identiquement nulle. Sous l'hypothèse $g \in L^1(\mathbb{R})$, le théorème d'unicité (ou injectivité) de la transformée de Fourier implique que

$$g(x) = 0 \quad \text{pour presque tout } x.$$

Donc

$$f_X(x) = f_Y(x) \quad \text{pour presque tout } x,$$

ce qui montre que X et Y ont la même densité, donc la même loi.

Dans le cas général (sans hypothèse d'existence d'une densité), la démonstration repose sur le théorème d'inversion de Lévy, qui affirme que la loi peut être reconstruite à partir de la fonction caractéristique. L'égalité des fonctions caractéristiques entraîne alors l'égalité des fonctions de répartition, et donc l'égalité des lois. □

Mais présentons directement un résultat qui nous importe dans ces notes de cours :

Proposition 7.3 (Caractéristique d'une gaussienne)**.** *Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors*

$$\varphi_X(t) = \exp\left(i\mu t - \frac{1}{2}\sigma^2 t^2\right).$$

Preuve.
La densité de X s'exprime par

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

On calcule

$$\varphi_X(t) = \int_{-\infty}^{+\infty} e^{itx} f(x)\,\mathrm{d}x = \int_{-\infty}^{+\infty} e^{itx} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}\,\mathrm{d}x.$$

Un produit d'exponentielle conduit à sommer les termes à l'intérieur de l'exponentielle. Regardons l'intérieur de celle-ci :

$$itx - \frac{(x-\mu)^2}{2\sigma^2}.$$

On complète le carré dans l'exposant en jouant sur sa forme canonique. On observe que :

$$itx - \frac{(x-\mu)^2}{2\sigma^2} = -\frac{1}{2\sigma^2}\left[(x-\mu-i\sigma^2 t)^2 - \sigma^4 t^2\right] + i\mu t.$$

Ainsi,

$$\varphi_X(t) = e^{i\mu t} e^{-\frac{1}{2}\sigma^2 t^2} \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{+\infty} \exp\left(-\frac{(x-\mu-i\sigma^2 t)^2}{2\sigma^2}\right) \mathrm{d}x.$$

Or l'intégrale en bleu vaut $\sqrt{2\pi\sigma^2}$ (translation complexe d'une gaussienne). Il reste donc le terme en vert :

$$\varphi_X(t) = \exp\left(i\mu t - \frac{1}{2}\sigma^2 t^2\right).$$

□

Conséquence fondamentale. La loi normale est stable par convolution *(c'est-à-dire, stable par sommes indépendantes de variables elle-mêmes gaussiennes)* : le produit de fonctions caractéristiques gaussiennes reste gaussien, ce qui explique la stabilité de la loi normale par somme de variables indépendantes.