

Algorithme des k -plus proches voisins



1 Motivations

2 Topologie

3 Les k -plus proches voisins

4 La variante des ε -voisins

5 Conclusion générale

Idée intuitive

On souhaite prédire la classe d'une nouvelle observation x à partir d'un jeu d'apprentissage $(X_1, Y_1), \dots, (X_n, Y_n)$.

Principe :

Les observations “similaires”^a ont des réponses similaires

Donc :

- on cherche l'observation la plus proche de x
- puis on lui associe sa classe

^aIl faut définir ce terme avec rigueur !

Idée intuitive

On souhaite prédire la classe d'une nouvelle observation x à partir d'un jeu d'apprentissage $(X_1, Y_1), \dots, (X_n, Y_n)$.

Principe :

Les observations “similaires”^a ont des réponses similaires


Donc :

- on cherche l'observation la plus proche de x
- puis on lui associe sa classe

^aIl faut définir ce terme avec rigueur !

On prédit :

$$\hat{Y}(x) = Y_{i^*} \quad \text{où} \quad i^* = \underset{i=1, \dots, n}{\operatorname{argmin}} d(x, X_i)$$



Idée intuitive

On souhaite prédire la classe d'une nouvelle observation x à partir d'un jeu d'apprentissage $(X_1, Y_1), \dots, (X_n, Y_n)$.

Principe :

Les observations “similaires”^a ont des réponses similaires


Donc :

- on cherche l'observation la plus proche de x
- puis on lui associe sa classe

^aIl faut définir ce terme avec rigueur !

On prédit :

$$\hat{Y}(x) = Y_{i^*} \quad \text{où} \quad i^* = \underset{i=1, \dots, n}{\operatorname{argmin}} d(x, X_i)$$



On attribue à x la classe de son **plus proche voisin**.
 => **méthode du Nearest Neighbor**

1 Motivations

2 Topologie

3 Les k -plus proches voisins

4 La variante des ε -voisins

5 Conclusion générale

Observation fondamentale en machine learning

De nombreux algorithmes reposent sur une notion de proximité :

- k plus proches voisins
- clustering
- méthodes à noyaux
- réduction de dimension (ACP, t-SNE, UMAP)
- graphes de voisinage

Observation fondamentale en machine learning

De nombreux algorithmes reposent sur une notion de proximité :

- k plus proches voisins
- clustering
- méthodes à noyaux
- réduction de dimension (ACP, t-SNE, UMAP)
- graphes de voisinage

Que signifie exactement *être proche* ?

Observation fondamentale en machine learning

De nombreux algorithmes reposent sur une notion de proximité :

- k plus proches voisins
- clustering
- méthodes à noyaux
- réduction de dimension (ACP, t-SNE, UMAP)
- graphes de voisinage

Que signifie exactement *être proche* ?

⇒ Cela dépend de la **distance choisie** !

Soit $\mathcal{X}$ un ensemble d'éléments quelconques.

Soit $\mathcal{X}$ un ensemble d'éléments quelconques.

Définition : distance

Une distance sur $\mathcal{X}$ est une fonction

$$d : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_+$$

telle que pour tous $x, y, z \in \mathcal{X}$:

(1) séparation :

$$d(x, y) = 0 \iff x = y$$

(2) symétrie :

$$d(x, y) = d(y, x)$$

(3) inégalité triangulaire :

$$d(x, z) \leq d(x, y) + d(y, z)$$

On parle alors d'**espace métrique** $(\mathcal{X}, d)$.

Une distance permet de définir un voisinage autour d'un point.

Une distance permet de définir un voisinage autour d'un point.

Boule ouverte

Pour $x \in \mathcal{X}$ et $r > 0$:

$$B(x, r) = \{y \in \mathcal{X} : d(x, y) < r\}$$

Une distance permet de définir un voisinage autour d'un point.

Boule ouverte

Pour $x \in \mathcal{X}$ et $r > 0$:

$$B(x, r) = \{y \in \mathcal{X} : d(x, y) < r\}$$

→ Il s'agit de l'ensemble des points *arbitrairement* proches de x .

Une distance permet de définir un voisinage autour d'un point.

Boule ouverte

Pour $x \in \mathcal{X}$ et $r > 0$:

$$B(x, r) = \{y \in \mathcal{X} : d(x, y) < r\}$$

→ Il s'agit de l'ensemble des points *arbitrairement* proches de x .

Ces voisinages définissent naturellement une structure appelée

Topologie induite par la distance.

Une distance permet de définir un voisinage autour d'un point.

Boule ouverte


Pour $x \in \mathcal{X}$ et $r > 0$:

$$B(x, r) = \{y \in \mathcal{X} : d(x, y) < r\}$$

→ Il s'agit de l'ensemble des points *arbitrairement* proches de x .

Ces voisinages définissent naturellement une structure appelée

Topologie induite par la distance.



Distance de Minkowski

Soient $x = (x^1, \dots, x^p)$ et $y = (y^1, \dots, y^p)$ deux vecteurs de $\mathbb{R}^p$. Pour tout entier $q \geq 1$:

$$d_q(x, y) = \left(\sum_{j=1}^p |x^j - y^j|^q \right)^{1/q}$$

Distance de Minkowski

Soient $x = (x^1, \dots, x^p)$ et $y = (y^1, \dots, y^p)$ deux vecteurs de $\mathbb{R}^p$. Pour tout entier $q \geq 1$:

$$d_q(x, y) = \left(\sum_{j=1}^p |x^j - y^j|^q \right)^{1/q}$$

Cas particuliers importants :

- Distance Manhattan

$$d_1(x, y) = \sum |x^j - y^j|$$

- Distance euclidienne

$$d_2(x, y) = \left(\sum (x^j - y^j)^2 \right)^{1/2}$$

- Distance maximum

$$d_\infty(x, y) = \max |x^j - y^j|$$

Problème fréquent

Si les variables n'ont pas la même échelle :

- euros
- années
- kilomètres

alors une variable peut dominer la distance.

Problème fréquent

Si les variables n'ont pas la même échelle :

- euros
- années
- kilomètres

alors une variable peut dominer la distance.

Solution classique : On “*centre*” et on “*réduit*” les variables avant d'utiliser une distance euclidienne.

$$Z = \frac{X - \mu_X}{\sigma_X}$$

Parfois on préfère mesurer une similarité plutôt qu'une distance.

Pourquoi introduire une similarité ?

Une distance indique à *quelle distance* deux observations se trouvent.

Mais dans de nombreux algorithmes, on souhaite plutôt mesurer :

le degré d'influence d'une observation sur une autre

Transformer une distance en similarité permet donc :

- ✓ d'accorder plus de poids aux observations proches,
- ✓ de réduire l'influence des observations éloignées,
- ✓ de construire des modèles **locaux et lissés**.

Similarité

Une similarité est une fonction

$$s : (x, y) \mapsto s(x, y)$$

d'autant plus grande que x et y sont proches.

Exemple important :
similarité gaussienne construite sur d :

$$s(x, y) = \exp \left(-\frac{d(x, y)^2}{2h^2} \right)$$

Paramètre clé

h contrôle le caractère local de la proximité.

Toutes les données ne sont pas numériques.

Exemples :

- profession
- groupe sanguin
- catégorie socio-professionnelle

Toutes les données ne sont pas numériques.

Exemples :

- profession
- groupe sanguin
- catégorie socio-professionnelle

Distance la plus simple :

Distance discrète

$$d(x, y) = \mathbb{1}_{\{x=y\}} = \begin{cases} 0, & x = y \\ 1, & x \neq y \end{cases}$$

Si plusieurs variables catégorielles :

$$x = (x^1, \dots, x^p)$$

on définit :

Distance de Hamming

$$d(x, y) = \sum_{j=1}^p \mathbb{1}_{\{x^j \neq y^j\}}$$

⇒ Cela revient directement à **compter** le nombre de coordonnées différentes.

Si plusieurs variables catégorielles :

$$x = (x^1, \dots, x^p)$$

on définit :

Distance de Hamming

$$d(x, y) = \sum_{j=1}^p \mathbb{1}_{\{x^j \neq y^j\}}$$

⇒ Cela revient directement à **compter** le nombre de coordonnées différentes.

Très utilisée en :

- ✓ clustering
- ✓ k-NN catégoriel
- ✓ bioinformatique

Transformer une variable catégorielle en vecteur numérique.

Transformer une variable catégorielle en vecteur numérique.

Exemple :

Couleur = Rouge / Vert / Bleu

Rouge = $(1, 0, 0)$

Vert = $(0, 1, 0)$

Bleu = $(0, 0, 1)$

Transformer une variable catégorielle en vecteur numérique.

Exemple :

Couleur = Rouge / Vert / Bleu

Rouge = $(1, 0, 0)$

Vert = $(0, 1, 0)$

Bleu = $(0, 0, 1)$

Après encodage :

on peut utiliser une distance euclidienne.

Conclusion

La distance choisie définit la notion de proximité. Donc :

Elle influence directement le comportement des algorithmes de machine learning !

Exemples :

- classification k-NN
- clustering
- graphes de voisinage
- méthodes à noyaux

- 1 Motivations
- 2 Topologie
- 3 Les k -plus proches voisins**
- 4 La variante des ε -voisins
- 5 Conclusion générale

Idée géométrique fondamentale

La règle du *Nearest Neighbor* associe à chaque point x la classe de son observation la plus proche.

Cette règle induit une **partition naturelle** de l'espace des covariables $\mathcal{X}$.

Idée géométrique fondamentale

La règle du *Nearest Neighbor* associe à chaque point x la classe de son observation la plus proche.

Cette règle induit une **partition naturelle** de l'espace des covariables $\mathcal{X}$.

Pour chaque observation du jeu d'apprentissage $X_1, \dots, X_n$, on définit :

$$V_i = \{x \in \mathcal{X} : \forall j \neq i, d(x, X_i) \leq d(x, X_j)\}$$

Idée géométrique fondamentale

La règle du *Nearest Neighbor* associe à chaque point x la classe de son observation la plus proche.

Cette règle induit une **partition naturelle** de l'espace des covariables $\mathcal{X}$.

Pour chaque observation du jeu d'apprentissage $X_1, \dots, X_n$, on définit :

$$V_i = \{x \in \mathcal{X} : \forall j \neq i, d(x, X_i) \leq d(x, X_j)\}$$

Ces régions vérifient :

$$\mathcal{X} = \bigcup_{i=1}^n V_i \quad \text{et} \quad V_i \cap V_j = \emptyset \quad (i \neq j)$$

Idée géométrique fondamentale

La règle du *Nearest Neighbor* associe à chaque point x la classe de son observation la plus proche.

Cette règle induit une **partition naturelle** de l'espace des covariables $\mathcal{X}$.

Pour chaque observation du jeu d'apprentissage $X_1, \dots, X_n$, on définit :


$$V_i = \{x \in \mathcal{X} : \forall j \neq i, d(x, X_i) \leq d(x, X_j)\}$$

Ces régions vérifient :


$$\mathcal{X} = \bigcup_{i=1}^n V_i \quad \text{et} \quad V_i \cap V_j = \emptyset \quad (i \neq j)$$

Interprétation

Chaque région V_i contient tous les points dont X_i est le plus proche voisin. On obtient ainsi une partition appelée **diagramme de Voronoï**.



Chaque point de l'espace voit sa classe affecté selon celle de son plus proche voisin.
Les frontières correspondent aux zones d'égalité entre classes.




Limite du Nearest Neighbor

Une seule observation aberrante peut modifier localement la frontière de décision.

Ainsi :

$k = 1 \Rightarrow$ modèle très sensible au bruit




Limite du Nearest Neighbor

Une seule observation aberrante peut modifier localement la frontière de décision.

Ainsi :

$k = 1 \Rightarrow$ modèle très sensible au bruit

Solution naturelle :
considérer plusieurs voisins ($k > 1$)



Principe du k -NN

Chaque point de l'espace est affecté à la classe majoritaire parmi ses k plus proches voisins.

Les frontières deviennent plus stables lorsque k augmente.

Limite du plus proche voisin ($k = 1$)

La règle du *Nearest Neighbor* attribue à x la classe de son unique voisin le plus proche.

Problème :

une seule observation peut être atypique

Donc la prédiction peut être **instable**.

Principe des k plus proches voisins

On considère maintenant les k observations les plus proches de x :

$$X_{(1)}(x), \dots, X_{(k)}(x)$$

Puis on attribue à x la **classe majoritaire** parmi ces voisins.

Rôle du paramètre k

Le choix de k contrôle la complexité du modèle :

- petit $k \Rightarrow$ modèle très flexible (variance élevée)
- grand $k \Rightarrow$ modèle plus stable (biais plus élevé)

Donc :

k est un hyperparamètre à ajuster

Choisir k revient à trouver un compromis

biais $\longleftrightarrow$ variance

Cadre d'application

La méthode des k plus proches voisins s'applique lorsque :

- les covariables sont numériques (ou munies d'une distance),
- la variable réponse peut être :
 - catégorielle (**classification**),
 - numérique (**régression**).

Définition du voisinage

On note $\mathcal{N}_K(x)$ l'ensemble des indices des K observations les plus proches de x :

$$\mathcal{N}_K(x) = \left\{ i \in \{1, \dots, n\} : d(x, X_i) \leq d(x, X_{(K)}) \right\}$$

où $d(x, X_{(K)})$ est la K -ième plus petite distance parmi

$$\{d(x, X_1), \dots, d(x, X_n)\}.$$

Définition du voisinage

On note $\mathcal{N}_K(x)$ l'ensemble des indices des K observations les plus proches de x :

$$\mathcal{N}_K(x) = \left\{ i \in \{1, \dots, n\} : d(x, X_i) \leq d(x, X_{(K)}) \right\}$$

où $d(x, X_{(K)})$ est la K -ième plus petite distance parmi

$$\{d(x, X_1), \dots, d(x, X_n)\}.$$

Cas classification

Vote majoritaire :

$$\hat{f}(x) = \operatorname{argmax}_{c \in \mathcal{Y}} \sum_{i \in \mathcal{N}_K(x)} \mathbb{1}_{\{Y_i = c\}}$$

Définition du voisinage

On note $\mathcal{N}_K(x)$ l'ensemble des indices des K observations les plus proches de x :

$$\mathcal{N}_K(x) = \left\{ i \in \{1, \dots, n\} : d(x, X_i) \leq d(x, X_{(K)}) \right\}$$

où $d(x, X_{(K)})$ est la K -ième plus petite distance parmi

$$\{d(x, X_1), \dots, d(x, X_n)\}.$$

Cas classification

Vote majoritaire :


$$\hat{f}(x) = \operatorname{argmax}_{c \in \mathcal{Y}} \sum_{i \in \mathcal{N}_K(x)} \mathbb{1}_{\{Y_i = c\}}$$

Cas régression

Moyenne locale :

$$\hat{f}(x) = \frac{1}{K} \sum_{i \in \mathcal{N}_K(x)} Y_i$$

Prédire la valeur d'une nouvelle observation



Objectif


On observe les valeurs Y_i associées aux observations du jeu d'apprentissage.

On souhaite prédire la valeur :

$$Y(x)$$

pour une nouvelle observation x .

Prédire la valeur d'une nouvelle observation



Objectif

On observe les valeurs Y_i associées aux observations du jeu d'apprentissage.

On souhaite prédire la valeur :


$$Y(x)$$

pour une nouvelle observation x .

Comment exploiter l'information locale autour de x ?

Principe du k-NN régressif ($k = 3$)

k-NN régressif (k=3) : prédiction par moyenne locale



Principe


On sélectionne les $k = 3$ observations les plus proches de x .

La prédiction est la moyenne locale :

$$\hat{f}(x) = \frac{1}{3} \sum_{i \in \mathcal{N}_3(x)} Y_i$$

Principe du k-NN régressif ($k = 3$)

k-NN régressif (k=3) : prédiction par moyenne locale



Principe

On sélectionne les $k = 3$ observations les plus proches de x .

La prédiction est la moyenne locale :

$$\hat{f}(x) = \frac{1}{3} \sum_{i \in \mathcal{N}_3(x)} Y_i$$

Le modèle k-NN régressif réalise une **approximation locale de la fonction inconnue**.

- 1 Motivations
- 2 Topologie
- 3 Les k -plus proches voisins
- 4 La variante des ε -voisins**
- 5 Conclusion générale

Limite du paramètre K

Dans l'algorithme des k plus proches voisins :

K est fixé a priori

indépendamment de la densité locale des données.

Limite du paramètre K

Dans l'algorithme des k plus proches voisins :

K est fixé a priori

indépendamment de la densité locale des données.

Conséquence :

- ⇒ dans les régions denses : trop peu d'observations utilisées
- ⇒ dans les régions rares : observations parfois trop éloignées

Limite du paramètre K

Dans l'algorithme des k plus proches voisins :

K est fixé a priori

indépendamment de la densité locale des données.

Conséquence :

- ⇒ dans les régions denses : trop peu d'observations utilisées
- ⇒ dans les régions rares : observations parfois trop éloignées

Idée alternative :

fixer une **distance maximale** plutôt qu'un nombre de voisins

Voisinage de rayon ε

On considère toutes les observations situées à distance inférieure à ε :

$$\mathcal{N}_{\varepsilon}(x) = \{i \in \{1, \dots, n\} : d(x, X_i) \leq \varepsilon\}$$

Voisinage de rayon ε

On considère toutes les observations situées à distance inférieure à ε :

$$\mathcal{N}_{\varepsilon}(x) = \{i \in \{1, \dots, n\} : d(x, X_i) \leq \varepsilon\}$$

Différence avec k-NN :

le nombre de voisins dépend de la densité locale

Voisinage de rayon ε

On considère toutes les observations situées à distance inférieure à ε :

$$\mathcal{N}_\varepsilon(x) = \{i \in \{1, \dots, n\} : d(x, X_i) \leq \varepsilon\}$$

Différence avec k-NN :

le nombre de voisins dépend de la densité locale

- région dense $\Rightarrow$ beaucoup de voisins
- région rare $\Rightarrow$ peu de voisins

Classification

Vote majoritaire :

$$\hat{f}(x) = \operatorname{argmax}_{c \in \mathcal{Y}} \sum_{i \in \mathcal{N}_{\varepsilon}(x)} \mathbb{1}_{\{Y_i = c\}}$$

Régression

Moyenne locale :

$$\hat{f}(x) = \frac{1}{|\mathcal{N}_{\varepsilon}(x)|} \sum_{i \in \mathcal{N}_{\varepsilon}(x)} Y_i$$

Pondération par similarité

Toutes les observations du voisinage peuvent être pondérées :

$$w_i(x) = \phi(d(x, X_i))$$

avec ϕ décroissante.

Exemples :

$$w_i(x) = \frac{1}{d(x, X_i)} \quad \text{ou} \quad w_i(x) = \exp\left(-\frac{1}{2}d(x, X_i)^2\right)$$

Limites du modèle

La performance dépend fortement :

- du choix de la distance
- des variables pertinentes utilisées
- de la dimension de l'espace

En grande dimension :

la notion de voisinage devient moins informative

(*malédiction de la dimension*)

- 1 Motivations
- 2 Topologie
- 3 Les k -plus proches voisins
- 4 La variante des ε -voisins
- 5 Conclusion générale

Principe général

La méthode des plus proches voisins repose sur une idée simple :

prédire une observation à partir de ses voisins

Elle réalise une approximation **locale** de la fonction inconnue.

Paramètres essentiels

Les performances dépendent principalement :

- du choix de la distance d

- du nombre de voisins K

- ou du rayon ε

Ces paramètres contrôlent le compromis :

biais $\longleftrightarrow$ variance

Extensions naturelles

Plusieurs variantes améliorent la méthode :

- ε -voisins

- pondération par similarité

- choix adapté de la métrique

Limites

La méthode devient moins efficace :

- en grande dimension

- en présence de variables non pertinentes

- lorsque la distance est mal choisie

(*malédiction de la dimension*)

Mais cela reste une méthode très intuitive !