
Évaluation mi-semestrielle

CORRECTION – Statistiques Descriptives 2

Exercice 1 – Régression linéaire

On note dans cet exercice :

- $X^{(1)}$: âge du patient (en années),
- $X^{(2)}$: indice de masse corporelle (IMC),
- $X^{(3)}$: nombre moyen d'heures d'activité physique par semaine,
- Y : pression artérielle systolique (en mmHg).

1. Régression linéaire simple

On considère dans un premier temps le modèle de régression linéaire simple reliant Y à $X^{(1)}$.

a) Soit $i \in \{1, \dots, n\}$ l'index d'une observation. Le modèle de régression linéaire simple s'écrit

$$(M1) \quad Y_i = \beta_0 + \beta_1 X_i^{(1)} + \varepsilon_i,$$

où les erreurs vérifient

$$\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2).$$

b) Les coefficients sont estimés par la méthode des *moindres carrés*. On minimise donc le critère

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{(\beta_0, \beta_1) \in \mathbb{R}^2} \left\{ \frac{1}{n} \sum_{i=1}^n \left(Y_i - (\beta_0 + \beta_1 X_i^{(1)}) \right)^2 \right\}.$$

c) La variable $X^{(1)}$ est significative dans le modèle car l'intervalle de confiance à 95% associé à son coefficient ne contient pas 0. On rejette donc l'hypothèse

$$H_0 : \beta_1 = 0.$$

d) On observe que $\hat{\beta}_1 > 0$. Ainsi, toutes choses égales par ailleurs dans le cadre du modèle simple, lorsque l'âge augmente, la pression artérielle systolique a tendance à augmenter. Le lien estimé entre l'âge et la tension artérielle est donc croissant.

2. Régression linéaire multiple

On considère maintenant le modèle complet de régression linéaire multiple.

a) Le modèle s'écrit

$$(M2) \quad Y_i = \beta_0 + \beta_1 X_i^{(1)} + \beta_2 X_i^{(2)} + \beta_3 X_i^{(3)} + \varepsilon_i.$$

b) Les erreurs gaussiennes vérifient

$$\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2).$$

c) La solution des moindres carrés pour l'estimateur en régression linéaire multiple est

$$\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top Y.$$

d) Les dimensions des objets sont :

$$\mathbb{X} \in \mathbb{R}^{n \times (p+1)}, \quad Y \in \mathbb{R}^n, \quad \hat{\beta} \in \mathbb{R}^{p+1}.$$

Ici, comme il y a $p = 3$ variables explicatives,

$$\mathbb{X} \in \mathbb{R}^{n \times 4}, \quad \hat{\beta} \in \mathbb{R}^4.$$

3. Interprétation de la sortie logicielle

a) **Argument avec les intervalles de confiance.** Les variables $X^{(1)}$ et $X^{(2)}$ sont significatives au seuil de 5%, car leurs intervalles de confiance à 95% ne contiennent pas 0. En revanche, $X^{(3)}$ n'est pas significative, car son intervalle de confiance contient 0.

Argument avec les p-values. De manière équivalente, on peut raisonner à partir des p-values associées aux tests de Student des coefficients. Les p-values des variables $X^{(1)}$ et $X^{(2)}$ sont inférieures au seuil $\alpha = 0.05$, ce qui conduit à rejeter l'hypothèse, pour $j \in \{1, 2\}$:

$$H_0 : \beta_j = 0.$$

Ces variables sont donc statistiquement significatives.

En revanche, la p-value associée à $X^{(3)}$ est supérieure à 0.05. On ne rejette donc pas l'hypothèse $H_0 : \beta_3 = 0$, ce qui confirme que cette variable n'est pas significative dans le modèle.

b) Notons le modèle ajusté par $\hat{Y} = \beta_0 + \beta_1 X_i^{(1)} + \beta_2 X_i^{(2)} + \beta_3 X_i^{(3)}$. Le coefficient de détermination

$$R^2 = \frac{\text{somme des carrés expliquée}}{\text{somme des carrés totale}} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}.$$

mesure la proportion de la variabilité de Y expliquée par le modèle.

Ici, $R^2 = 0.995$ est très proche de 1, ce qui signifie que le modèle explique une très grande partie de la variabilité observée de la pression artérielle systolique. Le modèle apparaît donc de très bonne qualité selon ce critère.

c) Le test global de Fisher permet de tester la significativité globale du modèle. Plus précisément, il teste

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0$$

contre l'hypothèse alternative selon laquelle au moins un coefficient explicatif est non nul. Ici, la p-value vaut

$$2.5 \times 10^{-7},$$

ce qui est très inférieur à 5%. On rejette donc H_0 . Le modèle (M2) est globalement significatif.

d) Concernant les résidus, plusieurs éléments vont dans le sens d'une adéquation satisfaisante du modèle :

- la moyenne empirique des résidus est très proche de 0, de l'ordre de 10^{-17} . Un test de Student pour $(H_0) : \mathbb{E}[\varepsilon] = 0$ donne $t = 9.70 \times 10^{-17}$ et une p-value égale à 1, ce qui conduit à ne pas rejeter H_0 .
- l'histogramme des résidus présente une forme proche de celle d'une loi normale ;
- surtout, le test de Shapiro–Wilk donne une p-value d'environ 0.68, ce qui conduit à ne pas rejeter l'hypothèse de normalité des résidus.

Ainsi, l'hypothèse de normalité des erreurs semble raisonnable dans ce cadre.

e) Le modèle **(M2)** paraît plus pertinent que le modèle **(M1)**. En effet :

- ses métriques R^2 et R^2 ajusté sont meilleures ;
- il permet d'intégrer davantage d'information explicative ;
- parmi les variables ajoutées, au moins l'une d'entre elles est significative.

Le modèle multiple fournit donc une modélisation plus riche et plus performante de la pression artérielle systolique.

Correction Exercice 2 – Application numérique de l'estimateur

On rappelle que l'estimateur des moindres carrés en régression linéaire multiple est donné par

$$\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top Y.$$

1. Calcul de $\mathbb{X}^\top \mathbb{X}$.

On commence par calculer :

$$\mathbb{X}^\top = \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & -1 & 1 \end{pmatrix}.$$

On obtient alors :

$$\mathbb{X}^\top \mathbb{X} = \begin{pmatrix} 4 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 4 \end{pmatrix} = 4I_3.$$

Ainsi,

$$(\mathbb{X}^\top \mathbb{X})^{-1} = \frac{1}{4}I_3 = \begin{pmatrix} \frac{1}{4} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{4} \end{pmatrix}.$$

2. Calcul de $\hat{\beta}$.

On calcule d'abord :

$$\mathbb{X}^\top Y = \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 3 \\ 5 \\ 7 \end{pmatrix} = \begin{pmatrix} 16 \\ 8 \\ 4 \end{pmatrix}.$$

Donc

$$\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top Y = \frac{1}{4} \begin{pmatrix} 16 \\ 8 \\ 4 \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \\ 1 \end{pmatrix}.$$

On obtient ainsi le modèle ajusté :

$$\hat{Y}_i = 4 + 2X_i^{(1)} + X_i^{(2)}.$$

Correction Exercice 3 – Régression logistique

1. Questions théoriques

- a) La variable $Y \mid \{X = \mathbf{x}\}$ suit une loi de Bernoulli de paramètre $p(\mathbf{x})$. Une loi de Bernoulli est entièrement caractérisée par un seul paramètre, puisque

$$\mathbb{P}(Y = 0 \mid X = \mathbf{x}) = 1 - p(\mathbf{x}).$$

Ainsi, la connaissance de $p(\mathbf{x}) = \mathbb{P}(Y = 1 \mid X = \mathbf{x})$ suffit à décrire complètement la loi conditionnelle de Y .

- b) La régression logistique est adaptée car :

- la variable réponse Y est binaire ;
- les variables explicatives $X^{(1)}$ et $X^{(2)}$ sont numériques ;
- on souhaite modéliser une probabilité, comprise entre 0 et 1.

Un modèle linéaire classique pourrait donner des valeurs hors de $[0, 1]$. La fonction logistique garantit que la probabilité estimée reste dans cet intervalle.

- c) On a

$$p(\mathbf{x}) = \frac{\exp(\eta_{\beta}(\mathbf{x}))}{1 + \exp(\eta_{\beta}(\mathbf{x}))}, \quad \text{avec } \eta_{\beta}(\mathbf{x}) = \beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)}.$$

Comme $\exp(u) > 0$ pour tout u , on a :

$$p(\mathbf{x}) > 0.$$

De plus,

$$p(\mathbf{x}) = \frac{\exp(\eta_{\beta}(\mathbf{x}))}{1 + \exp(\eta_{\beta}(\mathbf{x}))} < 1,$$

car le dénominateur est strictement plus grand que le numérateur.

Ainsi,

$$0 < p(\mathbf{x}) < 1.$$

2. Prédiction pour un nouveau patient

- a) On calcule d'abord le prédicteur linéaire :

$$\hat{\eta}_A = -6.20 + 0.15 \times 6.5 + 3.10 \times 1.8.$$

$$\hat{\eta}_A = -6.20 + 0.975 + 5.58 = 0.355.$$

La probabilité estimée vaut alors :

$$\hat{p}_A = \frac{e^{0.355}}{1 + e^{0.355}} \approx 0.588.$$

- b) La probabilité estimée d'hospitalisation est d'environ 58.8%.

Cela signifie que, compte tenu des caractéristiques biologiques du patient, le modèle estime qu'il y a plus d'une chance sur deux qu'une hospitalisation immédiate soit nécessaire. Dans un contexte médical, cela peut orienter la décision vers une prise en charge rapide.

———— Fin Correction Exercice 3 ————