
Évaluation mi-semestrielle

Statistiques Descriptives 2

Durée : 1h30

Calculatrice autorisée.

Seule une feuille de notes manuscrite est autorisée comme document.

Ce sujet comporte deux exercices indépendants. Toute réponse doit être justifiée. La clarté de la rédaction et la rigueur des raisonnements seront prises en compte dans l'évaluation. Le barème s'avère purement indicatif et est amené à changer.

Exercice 1 – Régression linéaire

(12pts)

Une équipe médicale souhaite analyser les facteurs qui influencent la pression artérielle systolique de patients lors d'un examen clinique. Pour cela, plusieurs caractéristiques ont été relevées pour dix patients :

- $X^{(1)}$: âge du patient (en années),
- $X^{(2)}$: indice de masse corporelle (IMC),
- $X^{(3)}$: nombre moyen d'heures d'activité physique par semaine,
- Y : pression artérielle systolique mesurée lors de la consultation (en mmHg).

Les données observées sont présentées dans le tableau suivant.

Patient	$X^{(1)}$	$X^{(2)}$	$X^{(3)}$	Y
1	25	22.1	6	112
2	32	27.5	3	124
3	37	23.8	5	118
4	44	30.2	2	135
5	50	26.4	4	132
6	56	31.0	1	145
7	61	24.9	3	134
8	66	33.5	0	154
9	72	28.7	2	148
10	78	34.1	0	160

1. Régression linéaire simple

On souhaite d'abord étudier l'influence de l'âge $X^{(1)}$ sur la tension artérielle Y , via un modèle linéaire simple à **erreurs gaussiennes**.

- Écrire la forme du modèle de régression linéaire simple reliant Y à $X^{(1)}$. On nommera ce modèle **(M1)**. (0.5pt)
- Quel critère minimiser afin d'obtenir les estimateurs des coefficients du modèle **(M1)**? Le nommer et écrire son expression formelle. (1pt)
- À partir de la table de résumé ci-dessous, indiquer si la variable $X^{(1)}$ est significative dans le modèle linéaire simple **(M1)**. (0.5pt)
- Interpréter le signe du coefficient estimé $\hat{\beta}_1$ dans ce contexte clinique. (0.5pt)

Régression linéaire simple (M1)

	Estimate	Std. Error	t value	p-value
Intercept (β_0)	93.12	6.14	15.16	< 0.001
Âge (β_1)	0.83	0.11	7.37	< 0.001

$$R^2 = 0.872, \quad R^2_{\text{ajusté}} = 0.856, \quad F(1, 8) = 54.28, \quad \text{Fisher p-value} < 0.001.$$

$$\text{IC}_{95\%}(\hat{\beta}_1) = [0.57 ; 1.09].$$

2. Régression linéaire multiple

L'équipe médical souhaite désormais prendre en compte l'ensemble des variables explicatives, via un modèle linéaire multiple à **erreurs gaussiennes**.

- Écrire la forme du modèle de régression linéaire multiple reliant Y aux variables $X^{(1)}$, $X^{(2)}$ et $X^{(3)}$. Ce modèle sera nommé **(M2)**. (0.5pt)
- Rappeler l'hypothèse formelle sur l'erreur ε_i pour toute observation i . (1pt)
- Rappeler ce qu'est la matrice de design et pourquoi sa première colonne ne contient que des "1". La matrice de design sera notée $\mathbb{X} = [\mathbf{1} \ X^{(1)} \ X^{(2)} \ X^{(3)}]$. (1pt)
- Exprimer l'estimateur du vecteur des coefficients $\hat{\beta}$ en fonction de la cible Y et de la matrice de design $\mathbb{X} = [\mathbf{1} \ X^{(1)} \ X^{(2)} \ X^{(3)}]$. (1pt)
- Notons n le nombre d'observations et p le nombre de variables explicatives. Préciser la dimension des matrices et vecteurs intervenant dans l'expression de $\hat{\beta}$. (1pt)

3. Interprétation d'une sortie logicielle

On ajuste le modèle linéaire multiple dans le logiciel R avec la commande `lm(Y ~ X1 + X2 + X3)` et on obtient le résumé **(M2)** renseigné sur la page suivante.

- Pour chaque variables $X^{(1)}$, $X^{(2)}$, $X^{(3)}$, justifier soigneusement si elles sont significatives au modèle **(M2)**. (1pt)
- Interpréter la valeur de R^2 . Donner sa valeur. (1pt)
- Que permet de tester le test global de Fisher? Que peut-on conclure ici? (1pt)
- Les résidus respectent-ils l'hypothèse de normalité centrée? Justifier. (1pt)

- e) Parmi les modèles (M1) et (M2) qui visent à modéliser Y , lequel vous semble le plus pertinent ? Justifier. (1pt)

Résumé du modèle linéaire multiple (M2)

Après ajustement du modèle, la commande `summary` renvoie le tableau suivant :

	Estimate	Std. Error	t value	p-value
Intercept (β_0)	57.86	16.96	3.41	0.014
$X^{(1)}$: âge (β_1)	0.51	0.04	11.44	< 0.001
$X^{(2)}$: IMC (β_2)	1.85	0.47	3.97	0.007
$X^{(3)}$: activité (β_3)	-0.18	1.08	-0.17	0.872

On donne également les estimations de la variance des résidus ainsi que les scores de qualité du modèle :

$$\hat{\sigma} = 1.331, \quad R^2 = 0.995, \quad R_{\text{ajusté}}^2 = 0.993.$$

Le test global de Fisher renvoie :

$$F = 409.9, \quad \text{ddl} = (3, 6), \quad \text{Fisher p-value} = 2.5 \times 10^{-7}.$$

Les intervalles de confiance à 95% sont :

$$\begin{aligned} \text{IC}_{95\%}(\hat{\beta}_0) &= [16.36 ; 99.35], & \text{IC}_{95\%}(\hat{\beta}_1) &= [0.40 ; 0.62], \\ \text{IC}_{95\%}(\hat{\beta}_2) &= [0.71 ; 2.99], & \text{IC}_{95\%}(\hat{\beta}_3) &= [-2.83 ; 2.47]. \end{aligned}$$




FIGURE 1 – Histogramme des résidus du modèle de régression linéaire multiple.

Test de Student pour

$$\begin{aligned} (H_0) : \mathbb{E}[\varepsilon] &= 0 \\ \text{mean}(\varepsilon) = \bar{\varepsilon} &= 3.3 \times 10^{-17}, \quad t = 9.70 \times 10^{-17}, \quad \text{p-value} = 1. \end{aligned}$$

———— Fin Exercice 1 ————

Exercice 2 – Régression linéaire : application numérique pour la formule de l'estimateur (3pts)

On considère le modèle de régression linéaire multiple avec deux covariables

$$y_i = \mathbb{X}\beta + \varepsilon_i, \quad i = 1, \dots, n \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix},$$

et on dispose de $n = 4$ observations. On donne la matrice de design correspondant à ces observations :

$$\mathbb{X} = (\mathbf{1} \quad \mathbf{x}^1 \quad \mathbf{x}^2) = \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & -1 \\ 1 & 1 & 1 \end{pmatrix} \quad \text{ainsi que le vecteur des réponses associées } y = \begin{pmatrix} 1 \\ 3 \\ 5 \\ 7 \end{pmatrix}.$$

1. Justifier par le calcul que (1pt)

$$(\mathbb{X}^\top \mathbb{X})^{-1} = \frac{1}{4} I_3 = \begin{pmatrix} \frac{1}{4} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{4} \end{pmatrix}.$$

2. Calculer le vecteur $\hat{\beta}$ obtenu par minimisation du carrés des erreurs pour ces données. (2pts)

————— Fin Exercice 2 —————

Exercice 3 – Questions de cours sur la régression logistique (5pts)

Dans un service d'urgences hospitalières, les médecins souhaitent mettre au point un outil d'aide à la décision permettant de déterminer si un patient doit être **hospitalisé immédiatement** ou non. Pour cela, on observe chez chaque patient deux indicateurs biologiques :

- $X^{(1)}$: taux de glycémie dans le sang (mmol/L),
- $X^{(2)}$: taux d'acétone dans le sang (mmol/L).

Notre but étant de modéliser la variable binaire indiquant si le patient doit être hospitalisé en urgence, notée :

$$Y = \begin{cases} 1 & \text{hospitalisation immédiate;} \\ 0 & \text{retour à domicile.} \end{cases}$$

1. On modélise la réponse Y en prescrivant une loi de Bernoulli :

$$Y \mid \{X = \mathbf{x}\} \sim \mathcal{B}(p(\mathbf{x})).$$

- a) Expliquer pourquoi, dans ce modèle, la connaissance de la seule quantité

$$p(\mathbf{x}) = \mathbb{P}(Y = 1 \mid X = \mathbf{x})$$

suffit à décrire entièrement la loi de $Y \mid \{X = \mathbf{x}\}$. (1pt)

- b) Justifier pourquoi la régression logistique est une modélisation pertinente dans ce contexte. (1pt)

c) Dans le cours et les TD sur le modèle logistique, on a spécifié

$$p(\mathbf{x}) = \frac{\exp(\beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)})}{1 + \exp(\beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)})}.$$

Est-ce que cela garantit que $p(\mathbf{x})$ ainsi défini est toujours positif? Est-ce que cela garantit également que $p(\mathbf{x})$ est toujours inférieur à 1? Justifier. (1pts)

2. Lorsque $\hat{\beta}_0$, $\hat{\beta}_1$ et $\hat{\beta}_2$ sont des estimations de, respectivement, β_0 , β_1 et β_2 , la quantité $\hat{p}(x)$ obtenue par la formule

$$\hat{p}(\mathbf{x}) = \frac{\exp(\hat{\beta}_0 + \hat{\beta}_1 x^{(1)} + \hat{\beta}_2 x^{(2)})}{1 + \exp(\hat{\beta}_0 + \hat{\beta}_1 x^{(1)} + \hat{\beta}_2 x^{(2)})}$$

pour un vecteur $\mathbf{x} = (x^{(1)}, x^{(2)})$ donné est considérée comme une bonne estimation de $p(\mathbf{x})$.

Un nouveau patient A arrive aux urgences avec les valeurs suivantes :

$$x_A^{(1)} = 6.5 \quad \text{et} \quad x_A^{(2)} = 1.8.$$

et on dispose des estimations $\hat{\beta}_0 = -6.20$, $\hat{\beta}_1 = 0.15$ et $\hat{\beta}_2 = 3.10$ obtenues à partir de nombreuses données après calculs sous le logiciel R.

- a) Que vaut numériquement la probabilité estimée $\hat{p}(x_A^{(1)}, x_A^{(2)})$ pour ce patient? (1pt)
b) Interpréter cette valeur dans ce contexte clinique. (1pt)

———— Fin Exercice 3 ————