
Correction Examen mi-semestrielle

Session de rattrapage

Statistiques Descriptives 2

Correction – Exercice 1

1. Modèle linéaire simple

- a) Le modèle de régression linéaire simple s'écrit

$$Y_i = \beta_0 + \beta_1 X_i^{(1)} + \varepsilon_i, \quad i = 1, \dots, n,$$

avec

$$\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2).$$

- b) Les coefficients sont estimés par la méthode des **moindres carrés**. On minimise le critère :

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{(\beta_0, \beta_1) \in \mathbb{R}^2} \left\{ \frac{1}{n} \sum_{i=1}^n (Y_i - (\beta_0 + \beta_1 X_i^{(1)}))^2 \right\}.$$

- c) La variable $X^{(1)}$ est significative au modèle car :

- la p-value associée est < 0.001 ;
- l'intervalle de confiance à 95% ne contient pas 0.

On rejette donc $H_0 : \beta_1 = 0$.

- d) Le coefficient de détermination

$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = 1 - \frac{\sum_{i=1}^n (\hat{Y}_i - Y)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

mesure la proportion de la variance de Y expliquée par le modèle. Le modèle est ici considéré comme bon, puisqu'on relève un R^2 (et même un $R^2_{\text{ajusté}}$) supérieur à 0.5. Un R^2 plus élevée (au delà, e.g., de 0.8) serait préférable.

2. Régression linéaire multiple

- a) Le modèle devient, pour toute observation $i = 1, \dots, n$:

$$Y_i = \beta_0 + \beta_1 X_i^{(1)} + \beta_2 X_i^{(2)} + \varepsilon_i.$$

- b) Les hypothèses sur les erreurs sont, pour toute observation $i = 1, \dots, n$:

$$\varepsilon_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2),$$

c'est-à-dire indépendance des observations, espérance nulle, variance constante et identique pour tout le monde (homoscédasticité), et plus spécifiquement de loi normale.

- c) Les variables $X^{(1)}$ et $X^{(2)}$ sont significatives puisque leurs p-values sont inférieures à 0.05 et que leurs intervalles (au seuil de 95%) de confiance ne contiennent pas 0. Cela signifie, qu'avec probabilité 95%, la vraie valeur de chaque coefficient β_j ($j = 1$ ou 2) ne peut pas être nul, d'où la significativité de la variable dans le modèle considéré.

- d) Le modèle **(M2)** semble globalement significatif, puisque les coefficients associés aux variables explicatives $X^{(1)}$ et $X^{(2)}$ sont individuellement significatifs : leurs p-values sont inférieures à 0.05 et leurs intervalles de confiance à 95% ne contiennent pas 0.

Cependant, pour conclure rigoureusement à la significativité globale du modèle, il conviendrait d'examiner le résultat du **test global de Fisher**, qui teste l'hypothèse

$$H_0 : \beta_1 = \beta_2 = 0.$$

Si la p-value associée à ce test est suffisamment faible (par exemple inférieure à 0.05), on rejette H_0 et on conclut que le modèle est globalement significatif.

- e) Le modèle **(M2)** semble plus pertinent que le modèle **(M1)**.

En effet, le coefficient de détermination augmente sensiblement :

$$R^2 : 0.74 \longrightarrow 0.89,$$

ce qui signifie que le modèle multiple explique une proportion plus importante de la variabilité de la variable réponse Y . De plus, la nouvelle variable explicative prise en compte $X^{(2)}$ est significative (p-value < 0.05, intervalle de confiance à 95% ne contient pas 0). Ainsi, l'ajout de la variable $X^{(2)}$ améliore la qualité d'ajustement du modèle sans introduire de variable non significative. Le modèle **(M2)** est donc préférable au modèle **(M1)**.

- f) Pour vérifier la normalité des résidus, on peut examiner la forme de leur histogramme ainsi que le graphique quantile-quantile (QQ-plot) et compléter cette analyse par le **test de Shapiro-Wilk**, qui teste l'hypothèse

$$H_0 : \varepsilon \sim \mathcal{N}(0, \sigma^2);$$

si la p-value n'est pas suffisamment petite (par exemple supérieure à 0.05), on ne rejette pas H_0 et l'hypothèse de normalité des résidus est considérée comme compatible avec les données.

Pour vérifier la centralité des résidus (c'est-à-dire que leur espérance est nulle), on peut vérifier que la moyenne empirique des résidus est proche de 0, puis effectuer un **test de Student** pour tester

$$H_0 : \mathbb{E}[\varepsilon] = 0.$$

- g) Pour vérifier les hypothèses du modèle linéaire gaussien, on peut étudier l'histogramme des résidus pour vérifier l'allure gaussienne, le QQ-plot pour vérifier la distribution des quantiles empiriques par rapport à ceux d'une loi normale ; mais aussi le graphique des résidus en fonction des valeurs ajustées afin de détecter une éventuelle hétéroscédasticité.

3. Application numérique

- a) La matrice $\mathbb{X}$ s'appelle matrice de design. Elle contient l'observation des variables explicatives. De plus, l'ajout en première colonne d'un vecteur uniquement constitué de 1 permet l'ajustement de l'intercept β_0 .
- b) L'estimateur des moindres carrés s'écrit

$$\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top Y.$$

- c) On commence par écrire la transposée de $\mathbb{X}$:

$$\mathbb{X}^\top = \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & 0 & 0 \end{pmatrix}.$$

On calcule alors le produit matriciel

$$\mathbb{X}^\top \mathbb{X} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ -1 & -1 & 1 & 1 \\ -1 & 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \end{pmatrix}.$$

En détaillant les produits scalaires coefficient par coefficient, on obtient :

$$\mathbb{X}^\top \mathbb{X} = \begin{pmatrix} 1+1+1+1 & -1-1+1+1 & -1+1+0+0 \\ -1-1+1+1 & (-1)^2+(-1)^2+1^2+1^2 & (-1)(-1)+(-1)(1)+1\cdot 0+1\cdot 0 \\ -1+1+0+0 & (-1)(-1)+1(-1)+0\cdot 1+0\cdot 1 & (-1)^2+1^2+0^2+0^2 \end{pmatrix}.$$

Ainsi,

$$\mathbb{X}^\top \mathbb{X} = \begin{pmatrix} 4 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 2 \end{pmatrix}.$$

Cette matrice étant diagonale, son inverse est :

$$(\mathbb{X}^\top \mathbb{X})^{-1} = \begin{pmatrix} \frac{1}{4} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{2} \end{pmatrix}.$$

On calcule :

$$\mathbb{X}^\top Y = \begin{pmatrix} 14 \\ 6 \\ 2 \end{pmatrix}.$$

D'où le résultat final,

$$\hat{\beta} = \begin{pmatrix} \frac{1}{4} & 0 & 0 \\ 0 & \frac{1}{4} & 0 \\ 0 & 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} 14 \\ 6 \\ 2 \end{pmatrix} = \begin{pmatrix} 3.5 \\ 1.5 \\ 1 \end{pmatrix}.$$

————— *Fin Correction Exercice 1* —————

Correction – Exercice 2

1. La régression logistique est adaptée car :

- i) on souhaite modéliser une variable réponse Y **binaire** (ou plus généralité, à *modalités* ou dit encore *catégorielle*) ;
- ii) pour ce faire, on souhaite estimer la probabilité du succès $Y = 1$ étant donné les covariables **numériques** (ou dites aussi **quantitatives**) relevées $X = \mathbf{x}$;
- iii) la fonction logistique

$$\mathcal{S} : t \mapsto \frac{\exp(t)}{\exp(t) + 1} = \frac{1}{1 + \exp(-t)}$$

permet d'obtenir, à partir d'une entrée réelle quelconque, une valeur dans $[0, 1]$.

2. Dans le modèle logistique :

$$p(\mathbf{x}) = \frac{\exp(\beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)})}{1 + \exp(\beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)})}.$$

3. Pour tout $z \in \mathbb{R}$, on a $\exp(z) > 0$. De plus, puisque $0 < 1$, on a $\exp(z) < 1 + \exp(z)$ pour tout réel z . Ainsi :

$$0 < \frac{\exp(z)}{1 + \exp(z)} < 1,$$

d'où $p(\mathbf{x}) \in]0, 1[$ (*de facto*, $p(\mathbf{x}) \in [0, 1]$).

4. On calcule :

$$\hat{\eta}_A = -4.20 + 0.35 \times 3 + 1.10 \times 3.6 = 0.81.$$

Donc

$$\hat{p}_A = \frac{\exp(\hat{\eta}_A)}{1 + \exp(\hat{\eta}_A)} = \frac{\exp(0.81)}{1 + \exp(0.81)} \approx 0.69.$$

5. La probabilité estimée d'un placement en détention provisoire de l'individu A est d'environ 69%. Cela signifie que, selon le modèle, l'individu A a une probabilité un peu élevée d'être placé en détention. Au seuil décisionnel $\tau = 50\%$, on le placerait en détention provisoire.

———— Fin Correction Exercice 2 ————