

Évaluation mi-semestrielle

Statistiques Descriptives 2

Durée : 1h30

Calculatrice autorisée.

Seule une feuille de notes manuscrite est autorisée comme document.

Ce sujet comporte deux exercices indépendants. Toute réponse doit être justifiée. La clarté de la rédaction et la rigueur des raisonnements seront prises en compte dans l'évaluation. *Le barème s'avère purement indicatif et est amené à changer.*

Pour chaque exercice, on ne fournit pas les données mais directement les résultats ajustés sur R. On notera le nombre total d'individus par n si besoin.

Exercice 1 – Régression linéaire

(14pts)

Une étude en sciences humaines cherche à modéliser l'évolution du score de bien-être déclaré par des individus après exposition à différents facteurs environnementaux. On note :

- $X^{(1)}$: variation du niveau de bruit dans l'environnement (en unités normalisées),
- $X^{(2)}$: variation du niveau d'interactions sociales (en unités normalisées),
- Y : variation du score de bien-être déclarée par l'individu après observation (en points).

1. Modèle linéaire simple

On commence par modéliser Y uniquement en fonction de $X^{(1)}$.

- Écrire le modèle de régression linéaire simple reliant Y à $X^{(1)}$. On l'appellera **(M1)**. (1pt)
- Quel critère doit-on minimiser pour obtenir les coefficients estimés du modèle ? Donner son nom ainsi que sa formule. (1pt)

Après ajustement sous R, on obtient la sortie suivante :

Résumé du modèle linéaire simple (M1)

	Estimate	Std. Error	t value	p-value
Intercept (β_0)	2.10	0.36	5.90	< 0.001
Variation du bruit sonore (β_1)	1.85	0.32	5.78	< 0.001

$$R^2 = 0.74, \quad R^2_{\text{ajusté}} = 0.72.$$

$$\text{IC}_{95\%}(\hat{\beta}_1) = [1.12 ; 2.58].$$

- c) Conclure quant à la significativité de la variable $X^{(1)}$ dans ce modèle par l'argument de votre choix. (1pt)
- d) Rappeler ce que mesure le coefficient de détermination R^2 , ainsi que sa formule. Le modèle (M1) peut-il être considéré comme bon ? (1pt)

2. Ajout d'une nouvelle variable

On complète maintenant le modèle en introduisant la variable $X^{(2)}$, la variation des interactions sociales.

- a) Écrire le nouveau modèle linéaire obtenu. On le nommera (M2). (1pt)
- b) On suppose les erreurs *gaussiennes*. Quelles sont les hypothèses formelles que doit vérifier le vecteur des erreurs ? (1pt)

Après ajustement sous R, on obtient :

Résumé du modèle linéaire multiple (M2)

	Estimate	Std. Error	t value	p-value
Intercept (β_0)	3.50	0.80	4.38	0.003
$X^{(1)}$: variation du bruit sonore (β_1)	1.50	0.35	4.29	0.003
$X^{(2)}$: variation des interactions sociales (β_2)	1.00	0.25	4.00	0.005

$$R^2 = 0.89, \quad R_{\text{ajusté}}^2 = 0.87.$$

$$\text{IC}_{95\%}(\hat{\beta}_1) = [0.60; 2.40], \quad \text{IC}_{95\%}(\hat{\beta}_2) = [0.35; 1.65].$$

- c) Conclure à la significativité des coefficients du nouveau modèle (M2). (1pt)
- d) Ce nouveau modèle vous semble-t-il **globalement** significatif ? Quel autre résultat de test statistique pourrait-on vérifier pour répondre pleinement à cette question ? (1pt)
- e) Comparer ce nouveau modèle (M2) au précédent (M1). Lequel vous semble le plus pertinent ? Justifier soigneusement au moins deux arguments. (1pt)
- f) Quel(s) test(s) statistique(s) pourrait-on employer pour vérifier la normalité des résidus ? La centralité ? (1pt)
- g) Quel(s) autre(s) graphe(s) pourrait-on étudier pour vérifier les hypothèses des erreurs gaussiennes ? (1pt)

3. Application numérique

On relève pour ce contexte physique les données suivantes :

$$\mathbb{X} = \begin{pmatrix} 1 & -1 & -1 \\ 1 & -1 & 1 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \end{pmatrix}, \quad Y = \begin{pmatrix} 1 \\ 3 \\ 4 \\ 6 \end{pmatrix}.$$

- a) Comment se nomme la matrice $\mathbb{X}$? Que représente-elle ? Quel est le rôle de la première colonne constituée uniquement de 1 ? (1pt)
- b) Rappeler l'expression de l'estimateur obtenu $\hat{\beta}$ en minimisant le carré des erreurs. (0.5pt)
- c) Calculer $\hat{\beta}$, en justifiant correctement le calcul de $(\mathbb{X}^\top \mathbb{X})^{-1}$. (1.5pts)

———— Fin Exercice 1 ————

Exercice 2 – Régression logistique

(6pts)

Dans un contexte juridique, on cherche à modéliser la décision de **placement en détention provisoire** d'un individu. On observe pour chaque dossier :

- $X^{(1)}$: nombre d'antécédents judiciaires ;
- $X^{(2)}$: score de gravité du dossier ;
- Y : variable binaire définie par

$$Y = \begin{cases} 1 & \text{placement en détention provisoire,} \\ 0 & \text{remise en liberté sous contrôle judiciaire.} \end{cases}$$

1. Justifier pourquoi un modèle de régression logistique est adapté à ce contexte. Citer au moins deux raisons. (2pts)
2. On note $\mathcal{S}$ l'application sigmoïde. Rappeler la formule explicite de la probabilité

$$p(\mathbf{x}) = \mathbb{P}(Y = 1 \mid X = \mathbf{x}) = \mathcal{S}(\beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)}).$$

dans le modèle logistique à deux variables explicatives dénotées par $\mathbf{x} = (x^{(1)}, x^{(2)})$. (1pt)

3. Pourquoi a-t-on la garantie que $p(\mathbf{x})$ est bien dans l'intervalle $[0, 1]$? (1pt)
4. On dispose des estimations

$$\hat{\beta}_0 = -4.20, \quad \hat{\beta}_1 = 0.35, \quad \hat{\beta}_2 = 1.10.$$

Pour un individu A tel que

$$x_A^{(1)} = 3 \quad \text{et} \quad x_A^{(2)} = 3.6,$$

calculer la probabilité estimée (1pt)

$$\hat{p}_A = \mathbb{P}(Y = 1 \mid X = \mathbf{x}_A).$$

5. Interpréter cette probabilité dans le contexte juridique étudié. (1pt)

———— Fin Exercice 2 ————