

Évaluation mi-semestrielle

Remarques générales – Statistiques Descriptives 2

Ce document rassemble plusieurs remarques importantes suite à la correction de l'examen, et relève certaines des erreurs les plus courantes.

Régression linéaire – aspects statistiques

- Il faut impérativement écrire le terme d'erreur ε dans le modèle :

$$Y_i = \beta_0 + \beta_1 X_i^{(1)} + \dots + \beta_J X_i^{(J)} + \varepsilon_i.$$

C'est ce terme qui garantit que le modèle a un **sens statistique**!! Les résidus représentent l'écart entre la valeur observée Y_i et la valeur prédite / ajustée $\hat{Y}_i$. C'est précisément la variance de ces résidus que l'on cherche à minimiser dans la méthode des moindres carrés.

- Attention à la rigueur de notation. Si vous introduisez un indice i , il doit apparaître partout sur les variables observées. :

$$X_i^{(j)}, \quad Y_i, \quad \varepsilon_i.$$

Sinon vous n'écrivez plus le modèle appliqué aux observations mais seulement sa forme générale. Mais pas d'entre-deux ! Il faut choisir.

- La matrice

$$\mathbb{X}$$

est la matrice des variables **explicatives** observées. Sa première colonne est constituée de 1 afin de permettre **l'estimation** / **l'ajustement** de l'intercept β_0 .

- Le test de Fisher teste la **significativité globale du modèle**. On pose

$$H_0 : \beta_1 = \dots = \beta_J = 0.$$

Si la p-value est suffisamment faible (par exemple < 0.05), on rejette H_0 . Cela signifie qu'*au moins une variable explicative influence significativement la variable cible* Y . Le modèle est alors pertinent du point de vue statistique.

- Lorsque l'on demande de vérifier que les résidus sont **normaux centrés**, il faut vérifier deux choses :

1. la normalité (histogramme, QQ-plot, test de Shapiro-Wilk) ;
2. le centrage (moyenne empirique proche de 0, test de Student).

Beaucoup d'entre vous n'ont vérifié qu'un seul de ces deux points.

- Lorsque l'on demande d'interpréter un coefficient $\hat{\beta}_1 > 0$, la réponse attendue est la suivante :

après avoir vérifié que la variable $X^{(1)}$ est significative, une augmentation de 1 unité de $X^{(1)}$ entraîne en moyenne une augmentation de $\hat{\beta}_1$ unités de la variable Y . Tout simplement.

Notations matricielles

- Attention : une matrice de taille $n \times m$ n'est pas un vecteur de taille nm .

Les espaces

$$\mathbb{R}^{n \times m} \quad \text{et} \quad \mathbb{R}^{nm}$$

sont certes isomorphes ($\mathbb{R}^{10 \times 4} \simeq \mathbb{R}^{40}$) mais ce ne sont pas les mêmes objets.

Svp, **n'écrivez plus jamais que ces deux espaces sont égaux**. En l'occurrence :

$$\mathbb{R}^{10 \times 4} \neq \mathbb{R}^{40}.$$

- Si

$$D = \text{diag}(d_1, d_2, \dots, d_n) = \begin{pmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{pmatrix}.$$

est une matrice diagonale inversible (c'est-à-dire $d_i \neq 0$ car on veut $\det(D) = d_1 \cdots d_n \neq 0$), alors pour tout scalaire non nul λ ,

$$(\lambda D)^{-1} = \frac{1}{\lambda} D^{-1}, \quad \text{avec} \quad D^{-1} = \text{diag}(d_1^{-1}, d_2^{-1}, \dots, d_n^{-1}).$$

Ce résultat provient de votre cours sur le calcul matriciel. Il ne faut pas s'attarder et s'obstiner avec le pivot de Gauss dans ce cas.

Régression logistique – aspects statistiques

- La régression logistique intervient lorsque la variable réponse Y est binaire (*ou plus généralement, à K modalités*).

On cherche alors à modéliser

$$p(x) = \mathbb{P}(Y = 1 \mid X = x).$$

Par complémentarité,

$$\mathbb{P}(Y = 0 \mid X = x) = 1 - p(x).$$

Donc si on connaît $p(x)$, on a nécessairement $\mathbb{P}(Y = 0 \mid X = x)!$

On utilise un modèle linéaire transformé par la fonction logistique (sigmoïde) :

$$p(x) = \frac{\exp(\beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)})}{1 + \exp(\beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)})} = \frac{1}{1 + \exp\left(-(\beta_0 + \beta_1 x^{(1)} + \beta_2 x^{(2)})\right)}.$$

Cette transformation permet d'obtenir une probabilité comprise entre 0 et 1.

- Lorsque l'on demande d'interpréter une probabilité estimée, la réponse attendue est simple : un individu ayant telles covariables observées possède telle probabilité d'être classé dans la catégorie $Y = 1$.

Il est également possible d'introduire un seuil de décision arbitraire (souvent $\tau = 50\%$) pour conclure en termes de classification.