Introduction à la modélisation statistique

Présentation des principes inférentiels et de modèles supervisés usuels.

Paul MINCHELLA, Stéphane CHRÉTIEN

Janvier 2025

Licence & Master MIASHS

Table des matières

1 Motivation de la modélisation statistique inférentielle **4**
1.1 Probabilités et statistique : une dualité fondamentale . . . 4
1.2 Variable aléatoire et observation . . . 5
1.3 Population et échantillon . . . 5
1.4 Apprentissage supervisé et non supervisé . . . 5
1.5 Modèles paramétriques et non paramétriques . . . 6

2 Outils probabilistes fondamentaux **7**
2.1 Loi de probabilité : description du comportement du hasard . . . 7
2.2 Espérance : valeur moyenne et centre de gravité . . . 8
2.3 Indépendance et espérance . . . 9
2.4 La variance comme mesure de la dispersion . . . 10
2.4.1 Covariance : dépendance linéaire entre variables . . . 10
2.4.2 Matrice de variance–covariance et interprétation géométrique . . . 12
2.5 Corrélation . . . 14
2.6 Fonction caractéristique : définition, exemples et intérêt . . . 15
2.6.1 Définition . . . 15
2.6.2 Intérêts majeurs . . . 16

3 Statistiques descriptives et lois usuelles **17**
3.1 Statistiques descriptives . . . 17
3.1.1 Grandeurs de position . . . 17
3.1.2 Grandeurs de dispersion . . . 18
3.2 Deux lois discrètes fondamentales . . . 18
3.3 La loi normale, indispensable des lois continues fondamentales . . . 19
3.3.1 Définition de la gaussienne . . . 19
3.3.2 Le Z-score . . . 19

4 Inférence statistique **21**
4.1 Le problème fondamental de l'estimation . . . 21
4.2 Estimateurs et paramètres . . . 21
4.3 Qualité des estimateurs . . . 21
4.3.1 Biais et variance . . . 22
4.3.2 Consistance et loi des grands nombres . . . 22
4.3.3 Compromis biais–variance . . . 23
4.4 Principe du maximum de vraisemblance . . . 23
4.4.1 Définition . . . 24
4.4.2 Propriétés asymptotiques . . . 24
4.5 Intervalles de confiance . . . 25
4.5.1 Principe général . . . 25
4.5.2 Choix du niveau α : un compromis . . . 25
4.5.3 Intervalle de confiance pour la moyenne . . . 26

5 Outils topologiques pour la modélisation **27**
5.1 Convexité et notions d'optimisation . . . 27
5.1.1 Définition de la convexité . . . 27
5.1.2 Convexité et unicité du minimum . . . 28
5.2 Topologie sur des données quantitatives . . . 29
5.2.1 Distance, métrique et topologie induite . . . 29
5.2.2 Distances de Minkowski sur $\mathbb{R}^p$ . . . 29
5.2.3 Similarités . . . 30
5.3 Topologie et proximités pour des données catégorielles . . . 31
5.3.1 Distance minimale : la métrique discrète . . . 31
5.3.2 Encodage *one-hot* et retour aux distances euclidiennes . . . 31

6 Comprendre le processus d'apprentissage d'un modèle **33**
6.1 Comprendre un modèle, c'est comprendre sa fonction de perte . . . 33
6.2 Apprentissage et généralisation . . . 34
6.2.1 Train–test *split* . . . 35
6.3 Optimisation par descente de gradient . . . 35

7 La régression linéaire **37**
7.1 Contexte et motivation . . . 37
7.2 Régression linéaire simple . . . 38
7.3 Estimation par la méthode des moindres carrés . . . 38
7.4 Régression linéaire multiple . . . 40
7.4.1 Le modèle . . . 41
7.4.2 Hypothèses essentielles . . . 41
7.4.3 Écriture matricielle . . . 41
7.4.4 Estimation par la méthode des moindres carrés . . . 41
7.5 Qualité du modèle . . . 43
7.5.1 Sommes des carrés et décomposition de la variabilité . . . 43
7.5.2 Coefficient de détermination R^2 . . . 44
7.5.3 Le R^2 ajusté . . . 45
7.5.4 Critères d'information : AIC et BIC . . . 46

8 La régression logistique **47**
8.1 Contexte et motivation . . . 47
8.2 Limites de la régression linéaire . . . 47
8.3 La fonction sigmoïde . . . 48
8.4 Le modèle de régression logistique . . . 48
8.5 Fonction de perte et estimation . . . 48
8.5.1 Modèle probabiliste et vraisemblance . . . 49
8.5.2 Perte d'entropie croisée . . . 49
8.5.3 Optimisation . . . 50
8.6 Interprétation et décision . . . 50
8.7 Avantages et limites . . . 50

9 Arbre de décision **51**
9.1 Contexte et motivations . . . 51
9.2 Cadre statistique . . . 52
9.3 Apprentissage d'un arbre de décision . . . 53
9.3.1 Fonction de perte . . . 53
9.3.2 Principe d'apprentissage . . . 54
9.3.3 Prédiction dans une feuille . . . 54
9.3.4 Arbres de décision avec variables catégorielles . . . 54
9.3.5 Sur-apprentissage et régularisation . . . 57

10 Les forêts aléatoires **58**
10.1 L'union fait la force . . . 58
10.1.1 Principe général du bagging . . . 58
10.1.2 Le bootstrap . . . 58
10.1.3 Réduction de la variance par agrégation . . . 59
10.1.4 Limites du bagging . . . 59
10.2 Les forêts aléatoires . . . 60
10.2.1 Motivations . . . 61
10.2.2 Apprentissage d'une forêt aléatoire . . . 61
10.2.3 Avantages et limites . . . 63

11 La méthode des k plus proches voisins **64**
11.1 Principe du plus proche voisin . . . 64
11.2 Motivation des k voisins . . . 65
11.3 La variante des ε-voisins . . . 66
11.3.1 Principe des ε-voisins . . . 67
11.3.2 Pondération par une fonction de similarité . . . 67
11.3.3 Discussion et portée du modèle . . . 68
11.4 Choix d'un nombre élevé de voisins : avantages et limites . . . 68
11.5 Fonction de perte et construction des frontières de décision . . . 69
11.6 Un algorithme supervisé et non paramétrique . . . 70

Chapitre 1

Motivation de la modélisation statistique inférentielle

La statistique inférentielle cherche à comprendre un phénomène global à partir d'un nombre fini d'observations. Dans la pratique, nous n'avons jamais accès à la population entière : nous ne disposons que d'un échantillon, nécessairement limité et bruité. L'enjeu central consiste alors à relier les données observées à un modèle probabiliste sous-jacent afin d'en extraire des informations générales et quantifiées. Avant d'introduire des outils techniques, il faut impérativement clarifier le cadre conceptuel dans lequel s'inscrit cette démarche.

1.1 Probabilités et statistique : une dualité fondamentale

Les probabilités et la statistique reposent sur les mêmes objets mathématiques, mais elles les interrogent selon des perspectives opposées.

Point de vue probabiliste. En probabilités, le modèle est supposé connu. On se donne un espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P}_\theta)$ et une famille de lois indexée par un paramètre $\theta \in \Theta$, considéré comme fixé.

L'objectif consiste alors à étudier le comportement des variables aléatoires sous cette loi : calcul de probabilités, espérances, variances, transformations, convergences, etc. L'aléa provient uniquement des réalisations possibles des variables.

Autrement dit, la question probabiliste est :

> Sachant que le paramètre vaut θ, comment se répartissent les valeurs possibles de la variable X ?

Point de vue statistique. En statistique, la situation est inversée. Le paramètre θ est inconnu. Ce que l'on observe, ce sont des données issues d'un phénomène réel que l'on modélise par une variable aléatoire.

Une fois l'observation x réalisée, on considère la fonction

$$L(\theta; x) = f(x; \theta),$$

appelée *vraisemblance*, que l'on regarde cette fois comme une fonction du paramètre.

La question devient alors :

> Quelles valeurs du paramètre sont compatibles avec les données observées ?

Il s'agit d'une même expression mathématique, mais interprétée différemment :

— en probabilités, $f(x; \theta)$ est vue comme fonction de x ;

— en statistique, elle est vue comme fonction de θ.

Cette dualité constitue le socle de toute modélisation statistique : les probabilités décrivent le modèle, la statistique l'interroge à partir des données.

1.2 Variable aléatoire et observation

Une variable aléatoire est une fonction

$$T : \Omega \longrightarrow \mathbb{R},$$

qui associe à chaque issue possible ω une valeur numérique $T(\omega)$. Elle représente un phénomène incertain sous forme quantitative : durée de vie, score, température, nombre d'événements, etc. Avant l'expérience, sa valeur est inconnue ; après réalisation, elle prend une valeur précise. La quantité observée $T(\omega)$ est appelée *réalisation* ou *trajectoire*. Il est essentiel de distinguer :

- la variable aléatoire, objet théorique du modèle ;
- sa réalisation, donnée concrète.

Lorsque l'on observe un échantillon de taille n, on observe en réalité

$$T(\omega_1), \ldots, T(\omega_n),$$

souvent notées $T_1, \ldots, T_n$. Ce qu'on appelle "*estimateur*" (ou "*statistique*") consiste précisément à utiliser ces réalisations pour apprendre quelque chose sur la loi qui gouverne T.

1.3 Population et échantillon

La *population* désigne l'ensemble théorique de toutes les observations possibles d'un phénomène. Elle est décrite par une loi de probabilité inconnue, caractérisée par des paramètres (par exemple une moyenne ou une variance). En pratique, on n'observe qu'un *échantillon*

$$(X_1, \ldots, X_n),$$

issu du même mécanisme aléatoire. De même, il faut distinguer clairement :

- les variables aléatoires X_i, objets du modèle ;
- leurs valeurs observées x_i, données empiriques.

Toute l'inférence statistique repose sur ce passage délicat de l'échantillon observé à la population inconnue.

1.4 Apprentissage supervisé et non supervisé

Dans le cadre moderne de l'apprentissage statistique, deux grandes situations se présentent.

Apprentissage supervisé. On observe des couples

$$(X_1, Y_1), \ldots, (X_n, Y_n),$$

où $X_i \in \mathbb{R}^p$ représente les p variables explicatives et Y_i une variable réponse.

L'objectif est de prédire Y à partir de X, c'est-à-dire d'approximer des quantités comme $\mathbb{E}[Y \mid X = x]$ en régression ou $\mathbb{P}(Y = c \mid X = x)$ en classification. La démarche est intrinsèquement inférentielle : on estime une relation à partir des données pour généraliser à de nouvelles observations.

Apprentissage non supervisé. On observe uniquement

$$X_1, \ldots, X_n,$$

sans variable réponse. Le but ici n'est plus de prédire, mais de révéler une structure : regroupements, dépendances, directions principales de variation, représentation plus compacte des données (par exemple : observe-t-on des *clusters* ?). L'approche est exploratoire et vise à organiser l'information plutôt qu'à anticiper une réponse.

1.5 Modèles paramétriques et non paramétriques

Une autre distinction fondamentale concerne la forme du modèle.

Modèles paramétriques. On suppose que la relation entre les variables dépend d'un nombre fini de paramètres $\theta \in \mathbb{R}^p$. L'apprentissage consiste alors à estimer ce vecteur de paramètres.

Exemple 1.5.1. Deux exemples usuels :

1. Loi normale. Dans la promo des L2, on suppose que la taille T des n garçons suit une loi normale. Dans ce cas :
$$T_1, \dots, T_n \overset{\text{i.i.d}}{\sim} \mathcal{N}(\mu, \sigma^2).$$
Puisque la loi normale est intégralement caractérisée par son espérance μ et sa variance σ^2, le but sera d'estimer ces paramètres là. On note naturellement $\theta = \begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix} \in \mathbb{R} \times \mathbb{R}_+^*$.
2. Loi binaire. Un lancé de pièce (non nécessairement équilibré) se modélise par une variable $X \sim \mathcal{B}(p)$, loi de Bernouilli de paramètre $\theta = p \in [0, 1]$, vérifiant
$$\mathbb{P}(X = 1) = p$$
$$\mathbb{P}(X = 0) = 1 - p.$$

Ces modèles reposent sur des hypothèses structurelles fortes, mais offrent une interprétabilité claire et un cadre théorique bien maîtrisé.

Modèles non paramétriques. Aucune forme fonctionnelle globale n'est imposée a priori. La complexité du modèle peut croître avec la taille de l'échantillon. Ces méthodes sont plus flexibles et capables de capturer des relations complexes, mais elles exigent un contrôle fin du compromis biais–variance.

Perspective

La modélisation statistique inférentielle repose sur une articulation précise entre modèle probabiliste et données observées. Les probabilités décrivent le mécanisme aléatoire supposé ; la statistique utilise les réalisations pour estimer, tester et prédire. Les distinctions entre variable aléatoire et observation, population et échantillon, supervisé et non supervisé, paramétrique et non paramétrique constituent le socle conceptuel sur lequel reposera l'ensemble du cours.

Chapitre 2

Outils probabilistes fondamentaux

2.1 Loi de probabilité : description du comportement du hasard

Définition 2.1.1 (Loi de probabilité d'une variable aléatoire réelle)**.** La *loi* (ou *distribution*) d'une variable aléatoire décrit la manière dont ses valeurs possibles se répartissent dans l'espace des nombres réels, avec leurs probabilités associées.

Pour une variable aléatoire continue T, cette loi est décrite par :

— une **fonction de répartition** $F(t) = \mathbb{P}(T \leq t)$, qui donne la probabilité que T prenne une valeur inférieure ou égale à t ;

— une **fonction de survie** $\mathcal{S}(t) = 1 - F(t) = \mathbb{P}(T > t)$, utile en analyse de survie ;

— une **densité de probabilité** $f(t)$ telle que $F'(t) = f(t)$ pour presque tout t.

La loi d'une variable aléatoire est au hasard ce que la *carte de répartition* est à un territoire : elle indique quelles valeurs sont les plus ou les moins probables. Dans l'exemple de la survie, la loi de T décrit la distribution des durées de vie possibles dans la population : certaines pannes arrivent très tôt, d'autres très tard, et cette répartition est caractérisée par $\mathcal{S}$, f ou h.

Proposition 2.1.1 (La loi de probabilité comme mesure)**.** La loi d'une variable aléatoire réelle définit une *mesure de probabilité* sur l'espace mesurable $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$, où $\mathcal{B}(\mathbb{R})$ désigne la tribu borélienne de $\mathbb{R}$. Plus précisément, il existe une application

$$\mathbb{P}_T : \mathcal{B}(\mathbb{R}) \longrightarrow [0, 1],$$

telle que, pour tout ensemble borélien $A \subset \mathbb{R}$,

$$\mathbb{P}_T(A) = \mathbb{P}(T \in A),$$

et vérifiant les propriétés suivantes :

1. **Positivité :** pour tout $A \in \mathcal{B}(\mathbb{R})$, $\mathbb{P}_T(A) \geq 0$;
2. **Normalisation :** $\mathbb{P}_T(\mathbb{R}) = 1$;
3. **σ-additivité :** pour toute famille dénombrable $(A_n)_{n\geq 1}$ d'ensembles deux à deux **disjoints** de $\mathcal{B}(\mathbb{R})$,
$$\mathbb{P}_T\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}_T(A_n).$$

2.2 Espérance : valeur moyenne et centre de gravité

L'une des grandeurs fondamentales associées à une variable aléatoire est son *espérance*. Elle représente la valeur moyenne autour de laquelle la variable aléatoire tend à se concentrer.

Définition 2.2.1 (Espérance d'une variable aléatoire continue)**.** Soit T une variable aléatoire réelle continue de densité f. Si l'intégrale

$$\mathbb{E}[T] = \int_{\mathbb{R}} t\, f(t)\, \mathrm{d}t$$

existe et est finie, on appelle *espérance* de T cette quantité.

L'espérance peut être interprétée comme le *centre de gravité* de la loi de probabilité. Si l'on imagine la densité $f(t)$ comme une répartition de masse sur l'axe réel, alors $\mathbb{E}[T]$ est le point d'équilibre autour duquel la masse se répartit.

Dans un cadre de survie, l'espérance correspond à la durée de vie moyenne dans la population. Il s'agit d'une caractéristique globale : deux lois différentes peuvent partager la même espérance tout en ayant des comportements très différents.

Propriétés fondamentales de l'espérance. L'espérance possède des propriétés algébriques essentielles.

Proposition 2.2.1 (Linéarité de l'espérance)**.** Soient X et Y deux variables aléatoires admettant une espérance, et $\alpha, \beta \in \mathbb{R}$. Alors

$$\mathbb{E}[\alpha X + \beta Y] = \alpha\, \mathbb{E}[X] + \beta\, \mathbb{E}[Y].$$

Cette propriété est valable sans hypothèse d'indépendance. Elle traduit le fait que l'espérance se comporte comme une application linéaire, ce qui en fait un outil particulièrement maniable dans les calculs probabilistes.

Théorème du transfert. Le calcul des espérances repose souvent sur un principe fondamental appelé *théorème du transfert*. Ce résultat permet d'exprimer l'espérance d'une fonction d'une variable aléatoire directement à partir de la loi de cette variable, sans avoir à déterminer explicitement la loi de l'image.

Théorème 2.2.1 (Théorème du transfert)**.** *Soit X une variable aléatoire réelle de densité f_X, et soit $\varphi : \mathbb{R} \to \mathbb{R}$ une fonction mesurable telle que l'intégrale ci-dessous soit définie. Alors*

$$\mathbb{E}[\varphi(X)] = \int_{\mathbb{R}} \varphi(x)\, f_X(x)\, \mathrm{d}x.$$

Preuve. Admise. □

Exemple 2.2.1. Soit X une variable aléatoire réelle admettant une densité f_X. En appliquant le théorème du transfert avec différentes fonctions φ, on obtient :

1. Pour $\varphi(x) = x^2$:
$$\mathbb{E}[X^2] = \int_{\mathbb{R}} x^2 f_X(x)\, \mathrm{d}x.$$
2. Pour $\varphi(x) = |x|$:
$$\mathbb{E}[|X|] = \int_{\mathbb{R}} |x|\, f_X(x)\, \mathrm{d}x.$$

3. Pour $\varphi(x) = \exp(x)$:

$$\mathbb{E}[\exp(X)] = \int_{\mathbb{R}} e^x f_X(x)\,\mathrm{d}x.$$

Ces formules illustrent que l'espérance d'une transformation de X se calcule simplement en intégrant cette transformation pondérée par la densité.

Intuition. Le théorème du transfert affirme que pour calculer une moyenne de la quantité $\varphi(X)$, il suffit de moyenner les valeurs $\varphi(x)$ pondérées par la probabilité que X prenne la valeur x, tout simplement ! On "transfère" donc la transformation φ à l'intérieur de l'intégrale, sans transformer explicitement la loi de X.

Intérêt. Ce théorème est d'un intérêt pratique majeur. Il permet notamment :

— de calculer des moments comme $\mathbb{E}[X^2]$, $\mathbb{E}[|X|]$ ou $\mathbb{E}[\exp(X)]$;

— d'établir des formules générales pour la variance et la covariance ;

— de simplifier considérablement les calculs d'espérance en statistique et en apprentissage automatique, où l'on manipule fréquemment des fonctions non linéaires de variables aléatoires.

Le théorème du transfert constitue ainsi un pont fondamental entre la loi d'une variable aléatoire et les quantités moyennes dérivées de cette loi.

2.3 Indépendance et espérance

Lorsque l'on manipule plusieurs variables aléatoires, une question centrale apparaît naturellement : le comportement de l'une influence-t-il celui de l'autre ? Dans de nombreuses situations, on modélise des phénomènes supposés ne pas interagir. Cette idée, certes intuitive, conduit à la notion fondamentale d'indépendance.

Définition 2.3.1 (Indépendance de deux variables aléatoires)**.** Deux variables aléatoires X et Y sont dites *indépendantes* si, pour tous ensembles mesurables $A, B \subset \mathbb{R}$,

$$\mathbb{P}(X \in A,\ Y \in B) = \mathbb{P}(X \in A)\,\mathbb{P}(Y \in B).$$

En bref, connaître la valeur (ou un événement concernant) X n'apporte aucune information sur Y, et réciproquement. Dans le cas où X et Y admettent une densité jointe $f_{X,Y}$, l'indépendance est équivalente à la séparabilité de la densité conjointe en produit de densité marginale :

$$f_{X,Y}(x, y) = f_X(x)\, f_Y(y).$$

L'intérêt de l'indépendance est majeur en calcul d'espérance.

Proposition 2.3.1 (Factorisation de l'espérance sous indépendance)**.** Soient X et Y deux variables aléatoires réelles indépendantes et intégrables. Alors

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y].$$

Preuve. On note la densité jointe de X et Y comme étant $f_{X,Y}$. Par définition de l'espérance d'un couple continu,

$$\mathbb{E}[XY] = \int_{\mathbb{R}^2} xy\, f_{X,Y}(x, y)\,\mathrm{d}x\,\mathrm{d}y.$$

L'indépendance implique la factorisation

$$f_{X,Y}(x, y) = f_X(x) f_Y(y).$$

On obtient donc

$$\mathbb{E}[XY] = \int_{\mathbb{R}^2} xy\, f_X(x) f_Y(y)\,\mathrm{d}x\,\mathrm{d}y = \int_{\mathbb{R}}\int_{\mathbb{R}} y f_Y(y) \cdot \big(x\, f_X(x)\big)\,\mathrm{d}x\,\mathrm{d}y.$$

On peut séparer les intégrales (produit de fonctions dépendant de variables distinctes) :

$$\mathbb{E}[XY] = \left(\int_{\mathbb{R}} x f_X(x)\,\mathrm{d}x\right)\left(\int_{\mathbb{R}} y f_Y(y)\,\mathrm{d}y\right).$$

Or ces deux termes sont précisément $\mathbb{E}[X]$ et $\mathbb{E}[Y]$, d'où

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y].$$

Le raisonnement est analogue dans le cas discret en remplaçant les intégrales par des sommes. □

Cette propriété simplifie considérablement de nombreux calculs, notamment pour les sommes de variables indépendantes, l'étude des variances ou les modèles statistiques.

2.4 La variance comme mesure de la dispersion

Si l'espérance renseigne sur la position centrale de la distribution, elle ne dit rien sur la manière dont les valeurs sont dispersées autour de cette position. C'est le rôle de la variance.

Définition 2.4.1 (Variance)**.** Soit X une variable aléatoire d'espérance $\mu = \mathbb{E}[X]$. On appelle *variance* de X la quantité

$$\mathrm{Var}(X) = \mathbb{E}\big[(X-\mu)^2\big],$$

lorsqu'elle est finie. On dispose également de l'identité utile :

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2,$$

lorsque ces quantités sont bien définies.

La variance mesure la *dispersion quadratique* de la variable aléatoire autour de son espérance. Plus la variance est grande, plus les valeurs prises par X sont éloignées, en moyenne, du centre de gravité μ.

Le caractère quadratique de cette mesure est essentiel : les écarts positifs et négatifs ne s'annulent pas, et les grandes déviations sont davantage pénalisées.

Propriétés de la variance. Deux remarques importantes concernant la variance.

Proposition 2.4.1. Pour toute variable aléatoire X et tout $\alpha, \lambda \in \mathbb{R}$,

$$\mathrm{Var}(\lambda X + \alpha) = \lambda^2\,\mathrm{Var}(X).$$

Cette propriété montre que la variance est homogène de degré 2, ce qui explique pourquoi elle s'exprime dans le carré de l'unité de X.

2.4.1 Covariance : dépendance linéaire entre variables

Lorsque l'on considère plusieurs variables aléatoires, il devient nécessaire de mesurer la manière dont elles varient conjointement.

Définition 2.4.2 (Covariance)**.** Soient X et Y deux variables aléatoires admettant une espérance. On appelle *covariance* de X et Y la quantité

$$\mathrm{Cov}(X,Y) = \mathbb{E}\big[(X-\mathbb{E}[X])(Y-\mathbb{E}[Y])\big].$$

La covariance mesure la dépendance *linéaire* entre deux variables aléatoires :

- si $\mathrm{Cov}(X,Y) > 0$, les grandes valeurs de X tendent à être associées à de grandes valeurs de Y ;
- si $\mathrm{Cov}(X,Y) < 0$, les grandes valeurs de X tendent à être associées à de petites valeurs de Y ;
- si $\mathrm{Cov}(X,Y) = 0$, il n'existe pas de dépendance linéaire entre X et Y.

Propriétés algébriques. Ci-dessous les propriétés les plus importantes de l'opérateur de covariance.

Proposition 2.4.2. La covariance est une forme bilinéaire symétrique :
- $\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X)$;
- $\mathrm{Cov}(\alpha X + \beta Y, Z) = \alpha \,\mathrm{Cov}(X, Z) + \beta \,\mathrm{Cov}(Y, Z)$;
- $\mathrm{Cov}(X, X) = \mathrm{Var}(X)$.

Preuve. Preuve quasi-immédiate par définition et propriété de l'espérance ! □

Ces propriétés rapprochent la covariance d'un produit scalaire. La différence essentielle réside dans le fait que $\mathrm{Cov}(X, X) = 0$ n'implique pas nécessairement que X est la variable aléatoire nulle.

Parlons d'ailleurs du cas où la covariance entre deux variables est nulle.

Puisque l'indépendance représente l'absence totale d'influence entre deux variables. On se demande naturellement comment cette notion se traduit au niveau de la covariance, qui mesure précisément la dépendance linéaire entre deux variables.

Proposition 2.4.3 (Indépendance $\Rightarrow$ covariance nulle)**.** Soient X et Y deux variables aléatoires intégrables et indépendantes. Alors

$$\mathrm{Cov}(X, Y) = 0.$$

Preuve. Par définition,

$$\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y].$$

Or, si X et Y sont indépendantes et intégrables, on sait que

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y].$$

En substituant dans la définition, on obtient immédiatement

$$\mathrm{Cov}(X, Y) = \mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[X]\mathbb{E}[Y] = 0.$$

□

Ce résultat montre que l'indépendance implique l'absence de dépendance linéaire. Il est cependant crucial de retenir que la réciproque est fausse : une covariance nulle n'implique pas nécessairement l'indépendance. La covariance ne capture que les relations linéaires entre les variables.

Variance d'une somme. La covariance permet d'exprimer de manière générale la variance d'une somme de variables aléatoires.

Proposition 2.4.4 (Variance d'une somme)**.** Soient $X_1, \ldots, X_n$ des variables aléatoires admettant une variance. Alors

$$\mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{Var}(X_i) + 2 \sum_{1 \leq i < j \leq n} \mathrm{Cov}(X_i, X_j).$$

Preuve. On part de l'écriture via la covariance :

$$\mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \mathrm{Cov}\left(\sum_{i=1}^{n} X_i, \sum_{j=1}^{n} X_j\right).$$

La covariance étant bilinéaire, on peut développer terme à terme :

$$\mathrm{Cov}\left(\sum_{i=1}^{n} X_i, \sum_{j=1}^{n} X_j\right) = \sum_{i=1}^{n} \sum_{j=1}^{n} \mathrm{Cov}(X_i, X_j).$$

On obtient donc une somme double portant sur *tous* les couples d'indices (i, j), avec $1 \leq i, j \leq n$. Il est maintenant essentiel de distinguer deux types de termes : les termes pour lesquels $i = j$; et les termes pour lesquels $i \neq j$.

- Cas $i = j$. Lorsque $i = j$, on a
$$\mathrm{Cov}(X_i, X_i) = \mathrm{Var}(X_i).$$
Ces termes correspondent exactement à la somme
$$\sum_{i=1}^{n} \mathrm{Var}(X_i).$$

- Cas $i \neq j$. Lorsque $i \neq j$, les termes apparaissent deux fois dans la somme double :
$$\mathrm{Cov}(X_i, X_j) \quad \text{et} \quad \mathrm{Cov}(X_j, X_i).$$
Or la covariance est symétrique :
$$\mathrm{Cov}(X_i, X_j) = \mathrm{Cov}(X_j, X_i).$$
Ainsi, chaque paire distincte $\{i, j\}$ contribue deux fois la même quantité.
Pour préciser ce double comptage, on regroupe les termes en ne sommant que sur les couples tels que $i < j$ et en précisant un facteur 2, ce qui donne
$$\sum_{\substack{1 \leq i,j \leq n \\ i \neq j}} \mathrm{Cov}(X_i, X_j) = 2 \sum_{1 \leq i < j \leq n} \mathrm{Cov}(X_i, X_j).$$

En combinant les deux contributions (indices égaux et indices distincts), on obtient finalement
$$\mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{Var}(X_i) + 2 \sum_{1 \leq i < j \leq n} \mathrm{Cov}(X_i, X_j),$$
ce qui conclut la démonstration. □

Proposition 2.4.5 (Corollaire induit de la variance de variables indépendantes)**.** Si les variables $X_1, \ldots, X_n$ sont **indépendantes**, alors
$$\mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{Var}(X_i).$$

Preuve. Preuve immédiate en combinant les Propositions 2.4.4 et 2.4.3. □

Ce résultat fondamental explique pourquoi l'indépendance joue un rôle central en probabilités : elle permet une propagation simple et additive de la variabilité.

2.4.2 Matrice de variance–covariance et interprétation géométrique

Les notions de variance et de covariance se généralisent naturellement lorsque l'on considère non plus une variable aléatoire réelle, mais un vecteur aléatoire
$$X = (X^1, \ldots, X^p)^\top \in \mathbb{R}^p.$$

Dans ce cadre, la moyenne $\mu = \mathbb{E}[X] \in \mathbb{R}^p$ joue le même rôle que dans le cas unidimensionnel : elle représente un opérateur de position, c'est-à-dire le *centre* du nuage de points associé aux réalisations de X dans l'espace $\mathbb{R}^p$. La dispersion et les dépendances linéaires entre coordonnées sont quant à elles décrites par une matrice, appelée matrice de variance–covariance.

Définition 2.4.3 (Matrice de variance–covariance)**.** Soit $X = (X^1, \dots, X^p)^\top$ un vecteur aléatoire de moyenne $\mu = \mathbb{E}[X]$. On appelle *matrice de variance–covariance* de X la matrice $\Sigma \in \mathbb{R}^{p\times p}$ définie par

$$\Sigma = \mathrm{Var}(X) = \mathbb{E}\big[(X-\mu)(X-\mu)^\top\big]\,.$$

Ses coefficients sont donnés par

$$\Sigma_{jk} = \mathrm{Cov}(X^j, X^k), \qquad 1 \le j, k \le p.$$

En particulier, les termes diagonaux vérifient $\Sigma_{jj} = \mathrm{Var}(X^j)$.

Par construction, la matrice Σ est symétrique et positive semi-définie, ce qui reflète le fait qu'elle encode une dispersion quadratique.

Exemple 2.4.1 (Illustration en dimension 2.)**.** Considérons $X = (X^1, X^2)^\top$ et notons

$$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} = \begin{pmatrix} \mathbb{E}[X^1] \\ \mathbb{E}[X^2] \end{pmatrix}.$$

Alors,

$$\begin{aligned}\Sigma &= \mathbb{E}\left[\begin{pmatrix} X^1-\mu_1 \\ X^2-\mu_2 \end{pmatrix}\begin{pmatrix} X^1-\mu_1 & X^2-\mu_2 \end{pmatrix}\right] \\ &= \begin{pmatrix} \mathbb{E}\big[(X^1-\mu_1)^2\big] & \mathbb{E}\big[(X^1-\mu_1)(X^2-\mu_2)\big] \\ \mathbb{E}\big[(X^2-\mu_2)(X^1-\mu_1)\big] & \mathbb{E}\big[(X^2-\mu_2)^2\big] \end{pmatrix}.\end{aligned}$$

On retrouve donc explicitement

$$\Sigma = \begin{pmatrix} \mathrm{Var}(X^1) & \mathrm{Cov}(X^1, X^2) \\ \mathrm{Cov}(X^1, X^2) & \mathrm{Var}(X^2) \end{pmatrix}.$$

Comme étayéen section précédente, le terme $\mathrm{Cov}(X^1, X^2)$ mesure la dépendance linéaire entre les deux coordonnées : son signe indique si les variations de X^1 et X^2 tendent à aller dans le même sens (covariance positive) ou en sens opposé (covariance négative), et sa valeur absolue quantifie l'intensité de cette relation en unités quadratiques.

Interprétation géométrique : ellipses de dispersion. Prenons le cas de la dimension 2, comme illustré en figure 2.1. La matrice de variance–covariance admet une interprétation géométrique particulièrement instructive. Intuitivement, la moyenne μ indique la position centrale du nuage de points, tandis que Σ – dont le rôle est d'illustrer la dispersion autour de la moyenne μ – décrit sa forme et son orientation. Considérons l'ensemble défini par

$$\mathcal{E}_c = \left\{x \in \mathbb{R}^2 \ : \ (x-\mu)^\top \Sigma^{-1}(x-\mu) \le c^2\right\},$$

où $c > 0$ est une constante et où l'on suppose Σ inversible. Cet ensemble est une ellipse centrée en μ. Les axes principaux de l'ellipse sont orientés selon les vecteurs propres de Σ, et leurs longueurs sont proportionnelles aux racines carrées des valeurs propres de Σ. Autrement dit :

— la moyenne μ joue le rôle de *centre* (opérateur de position) ;

— les variances déterminent la dispersion selon les directions principales ;

— la covariance oriente l'ellipse : si $\mathrm{Cov}(X^1, X^2) \neq 0$, l'ellipse est inclinée par rapport aux axes.

Cette représentation est particulièrement utile en statistique multivariée et en apprentissage automatique : elle permet de visualiser en un coup d'œil la dispersion d'un groupe d'observations, la présence de corrélations entre variables, et la structure géométrique induite par la matrice de covariance. Elle constitue également le point de départ naturel de méthodes de réduction de dimension (telles que l'ACP), qui cherchent précisément à identifier les directions de plus grande variance.

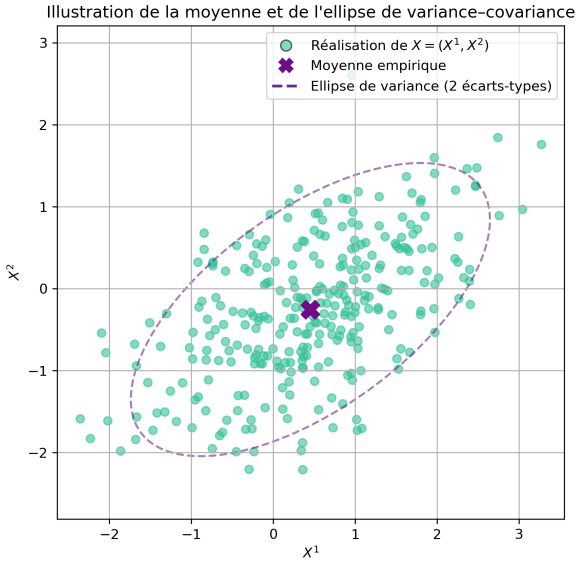

FIGURE 2.1 – Illustration géométrique de la moyenne et de la matrice de variance–covariance pour un vecteur aléatoire bidimensionnel $X = (X^1, X^2)$. Les points représentent des réalisations de X, la croix indique la moyenne empirique, qui joue le rôle d'opérateur de position du nuage de points dans le plan. L'ellipse en pointillé correspond à une courbe d'iso-dispersion associée à la matrice de variance–covariance : sa taille traduit l'intensité de la dispersion, tandis que son orientation reflète la présence d'une covariance non nulle entre X^1 et X^2.

2.5 Corrélation

La covariance introduite précédemment permet de mesurer la dépendance linéaire entre deux variables aléatoires. Toutefois, sa valeur dépend des unités de mesure de X et Y, ce qui rend les comparaisons délicates. La *corrélation* vise précisément à pallier cette difficulté en proposant une version *normalisée* de la covariance.

Définition 2.5.1 (Corrélation linéaire)**.** Soient X et Y deux variables aléatoires admettant une espérance et une variance strictement positive. On appelle *corrélation* (ou coefficient de corrélation linéaire de Pearson) entre X et Y la quantité

$$\rho_{X,Y} = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)}\,\sqrt{\mathrm{Var}(Y)}}.$$

Par construction, la corrélation est une quantité *sans dimension* : elle ne dépend pas des unités dans lesquelles X et Y sont mesurées.

Intuition et interprétation. La corrélation peut être interprétée comme une mesure du *lien linéaire* entre X et Y, évalué de manière symétrique. Le numérateur, la covariance, mesure la manière dont X et Y varient conjointement. Le dénominateur, produit des écarts types de X et Y, joue un rôle de normalisation : il ramène cette mesure à une échelle comparable, comprise entre -1 et 1. Ainsi :

- ⋆ $\rho_{X,Y} > 0$ indique que les grandes valeurs de X sont en moyenne associées à de grandes valeurs de Y ;
- ⋆ $\rho_{X,Y} < 0$ indique une association inverse ;
- ⋆ $\rho_{X,Y} \approx 0$ suggère l'absence de dépendance linéaire significative.

D'un point de vue géométrique, la corrélation peut être vue comme le *cosinus de l'angle* entre les variables centrées $X - \mathbb{E}[X]$ et $Y - \mathbb{E}[Y]$ dans un espace de Hilbert probabiliste. Cette lecture explique naturellement pourquoi la corrélation est bornée par -1 et 1, et pourquoi elle quantifie un alignement linéaire entre les deux variables.

Propriétés fondamentales. Quelques propriétés remarquables associées :

Proposition 2.5.1. Soient X et Y deux variables aléatoires de variance non nulle. Alors :

- $-1 \leq \rho_{X,Y} \leq 1$;
- $\rho_{X,Y} = \rho_{Y,X}$ (symétrie) ;
- pour tout $\alpha, \beta \in \mathbb{R} \setminus \{0\}$,
$$\rho_{\alpha X, \beta Y} = \operatorname{sign}(\alpha\beta)\, \rho_{X,Y};$$
- $\rho_{X,Y} = \pm 1$ si et seulement si il existe $a \in \mathbb{R}$ et $b \in \mathbb{R}$ tels que
$$Y = aX + b.$$

La dernière propriété montre que la corrélation égale à ± 1 correspond à une dépendance linéaire parfaite, sans bruit.

Lien avec la régression linéaire. La corrélation joue un rôle central dans l'étude de la régression linéaire simple. En effet, lorsque l'on cherche à expliquer Y comme une fonction linéaire de X à un terme d'erreur près,
$$Y = \beta_0 + \beta_1 X + \varepsilon,$$
le coefficient de corrélation mesure l'intensité de la relation linéaire entre X et Y, indépendamment de l'échelle des variables. On montrera ultérieurement que le coefficient de régression β_1 est directement lié à la covariance entre X et Y, et donc à leur corrélation, ce qui confère à cette dernière une interprétation statistique et géométrique fondamentale.

Points de vigilance. Il est important de souligner qu'une corrélation nulle n'implique pas nécessairement l'indépendance entre X et Y, sauf dans des cas particuliers (notamment lorsque les variables sont gaussiennes). La corrélation ne capture que les dépendances *linéaires* et peut être aveugle à des relations non linéaires pourtant marquées.

2.6 Fonction caractéristique : définition, exemples et intérêt

La *fonction caractéristique* est l'outil fondamental de la théorie de la convergence en loi, notamment parce qu'elle existe toujours (sans hypothèse d'intégrabilité).

2.6.1 Définition

Définition 2.6.1 (Fonction caractéristique)**.** Soit X une variable aléatoire réelle. Sa *fonction caractéristique* est la fonction
$$\varphi_X(t) := \mathbb{E}\big[e^{itX}\big], \qquad t \in \mathbb{R}, \tag{2.1}$$
où $i^2 = -1$ désigne l'imaginaire pur.

Remarque 1. Comme $|e^{itX}| = 1$, on a toujours $|\varphi_X(t)| \leq 1$ et (2.1) est toujours bien défini.

Exemple 2.6.1. Quelques exemples typiques :

1. Si X est une variable aléatoire constante, notons $X = a$, alors
$$\varphi_X(t) = e^{ita}.$$
2. Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors
$$\varphi_X(t) = \exp\big(i\mu t - \tfrac{1}{2}\sigma^2 t^2\big)\,.$$

3. Si $X \sim \mathcal{P}(\lambda)$, alors
$$\varphi_X(t) = \exp\big(\lambda(e^{it} - 1)\big)\,.$$
4. Si $X \sim \mathrm{Exp}(\lambda)$, alors
$$\varphi_X(t) = \frac{\lambda}{\lambda - it}.$$

2.6.2 Intérêts majeurs

1) Unicité (caractérisation de la loi). La fonction caractéristique *détermine* la loi : si X et Y sont deux variables aléatoires telles que, pour tout réel t,

$$\varphi_X(t) = \varphi_Y(t), \tag{2.2}$$

alors X et Y ont la même loi.

2) Sommes de variables indépendantes. Si X et Y sont indépendantes, alors

$$\varphi_{X+Y}(t) = \varphi_X(t)\,\varphi_Y(t). \tag{2.3}$$

La preuve est immédiate quand on combine le fait que l'exponentielle d'une somme devient le produit des exponentielle et la Proposition 2.3.1. Cette propriété rend les fonctions caractéristiques particulièrement efficaces pour étudier des sommes et établir des théorèmes limites.

Chapitre 3

Statistiques descriptives et lois usuelles

Ce chapitre fournit quelques rappels au combien importants pour la suite de ce cours.

Cadre. On observe un échantillon réel $(x_1, \ldots, x_n)$ issu d'une variable aléatoire X. L'objectif est de synthétiser cet échantillon numériquement et graphiquement avant toute démarche inférentielle.

3.1 Statistiques descriptives

Les indicateurs descriptifs se divisent naturellement en deux familles : les grandeurs de position et les grandeurs de dispersion.

3.1.1 Grandeurs de position

Ces indicateurs décrivent le centre ou la localisation des données.

Définition 3.1.1 (Moyenne empirique)**.** La moyenne empirique est définie par

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Elle correspond au centre de gravité du nuage de points.

La moyenne joue le rôle de la "meilleur" constante pour représenter un jeu de données, de part sa définition barycentrique, mais elle est aussi sensible aux valeurs extrêmes. Il est essentiel de toujours citer d'autres indicateurs en parallèle. La médiane est une valeur $m_{0.5}$ telle que

$$\mathbb{P}(X \leq m_{0.5}) \geq \tfrac{1}{2} \quad \text{et} \quad \mathbb{P}(X \geq m_{0.5}) \geq \tfrac{1}{2}.$$

Elle partage l'échantillon en deux parties de taille égale et est plus robuste aux valeurs aberrantes.

Cependant, on peut généraliser cette notion pour tout quantile $\tau \in [0, 1]$.

Définition 3.1.2 (Quantile d'ordre τ)**.** Pour $\tau \in [0, 1]$, le *quantile d'ordre* τ d'une variable aléatoire X est défini par

$$q_\tau = \inf\{x \in \mathbb{R} : F_X(x) \geq \tau\},$$

où F_X désigne la fonction de répartition de X.

Ainsi, q_τ est la plus petite valeur telle que la probabilité d'observer une réalisation inférieure ou égale à cette valeur soit au moins égale à τ. Les quantiles décrivent ainsi la structure globale d'une distribution :

- ⋆ les quartiles correspondent aux niveaux $\tau = 0.25, 0.5, 0.75$;
- ⋆ les déciles divisent la distribution en dix parts égales ;
- ⋆ plus généralement, ils permettent d'analyser la répartition de la masse de probabilité.

Les quantiles jouent un rôle central en inférence statistique. La construction d'intervalles de confiance repose précisément sur l'idée d'encadrer un paramètre inconnu de sorte que l'intervalle contienne la vraie valeur avec une probabilité élevée (par exemple 95%). Ils matérialisent un compromis essentiel : couvrir une proportion importante de la distribution tout en conservant une précision suffisante pour que le résultat reste informatif.

3.1.2 Grandeurs de dispersion

Ces indicateurs mesurent la variabilité autour du centre.

Définition 3.1.3 (Variance empirique)**.** La variance empirique est

$$V_n = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Cette définition incanre donc le penchant empirique sur les données observées de la variance en Définition 2.4.1. Sa racine carrée,

$$\sigma_n = \sqrt{V_n},$$

est l'écart-type empirique.

D'autres mesures existent comme l'étendue ($\max_i x_i - \min_i x_i$), l'écart moyen absolu ou encore le coefficient de variation : $\sigma/\bar{x}$, mais ils ont quand même beaucoup moins d'impact tant sur le conceptuel que dans la pratique.

Les indicateurs descriptifs fournissent une première lecture des données, mais ne constituent pas encore un modèle probabiliste.

3.2 Deux lois discrètes fondamentales

Les lois discrètes modélisent des phénomènes de comptage ou des expériences à issues finies.

Loi de Bernoulli. Une variable X suit une loi de Bernoulli $\mathcal{B}(p)$ si

$$\mathbb{P}(X = 1) = p, \qquad \mathbb{P}(X = 0) = 1 - p.$$

Elle modélise une expérience à deux issues (succès/échec).

$$\mathbb{E}[X] = p, \qquad \mathrm{Var}(X) = p(1 - p).$$

Elle constitue la brique élémentaire de nombreux modèles statistiques.

Loi binomiale. Si $X = \sum_{i=1}^{n} X_i$ avec $X_i \sim \mathcal{B}(p)$ indépendantes, alors

$$X \sim \mathcal{B}(n, p).$$

Sa loi est

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}.$$

Elle modélise le nombre de succès sur n essais indépendants.

3.3 La loi normale, indispensable des lois continues fondamentales

Les lois continues interviennent dès que l'on modélise des grandeurs mesurables (temps, tailles, scores...). On se concentre dans ces rappels de cours uniquement à la loi normale.

3.3.1 Définition de la gaussienne

Une variable suit une loi normale $\mathcal{N}(m, \sigma^2)$ si elle admet la densité

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right).$$

Interprétation des paramètres. Le paramètre m correspond au centre de la distribution (et à son espérance), tandis que σ^2 mesure la dispersion autour de ce centre. La densité est symétrique par rapport à m et décroît rapidement lorsque l'on s'en éloigne, ce qui reflète la concentration de la masse de probabilité autour de la moyenne.

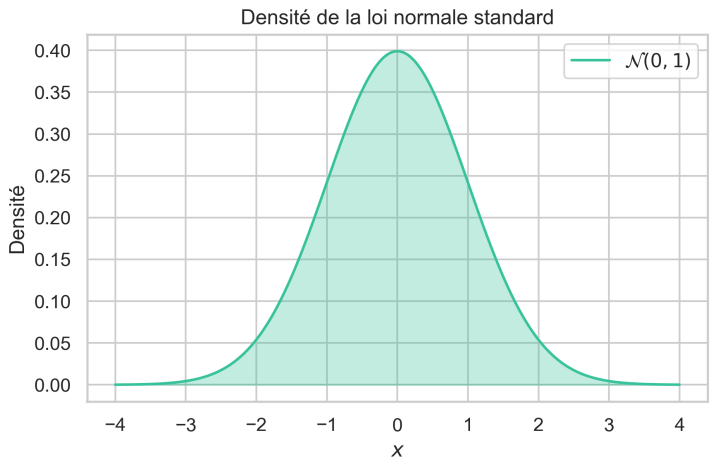

FIGURE 3.1 – Densité de la loi normale standard $\mathcal{N}(0, 1)$. Cette loi symétrique est caractérisée par sa moyenne nulle et sa variance unitaire, et joue un rôle central en statistique et en inférence.

Stabilité par addition. Une propriété structurelle majeure de la loi normale est sa *stabilité par addition* : si $X \sim \mathcal{N}(m_1, \sigma_1^2)$ et $Y \sim \mathcal{N}(m_2, \sigma_2^2)$ sont **indépendantes**, alors

$$X + Y \sim \mathcal{N}(m_1 + m_2,\ \sigma_1^2 + \sigma_2^2).$$

Cette propriété explique pourquoi la loi normale apparaît naturellement comme loi limite pour des sommes de variables aléatoires indépendantes *(coucou le théorème centre limite...)*.

3.3.2 Le Z-score

Étant donnée une variable aléatoire réelle X, une question naturelle se pose : à partir de quel moment peut-on considérer qu'une observation est *singulière*, c'est-à-dire éloignée du comportement central de la distribution ?

Pour répondre à cette question, il faut disposer d'une mesure d'écart à la moyenne qui soit comparable d'une variable à l'autre. En effet, un écart de 10 unités n'a pas la même signification selon que la dispersion naturelle des données est faible ou élevée. Dans le cas d'une distribution approximativement normale, l'intuition est claire : plus une observation s'éloigne de la moyenne en nombre d'écarts-types, plus elle est rare. La loi normale fournit même une quantification précise de cette rareté. Cela conduit à définir la variable *centrée réduite*.

Définition 3.3.1 (Centrage–réduction)**.** Soit X une variable aléatoire de moyenne m et d'écart-type $\sigma > 0$. On définit le *Z-score* par

$$Z = \frac{X - m}{\sigma}.$$

Par construction,

$$\mathbb{E}[Z] = 0 \quad \text{et} \quad \mathrm{Var}(Z) = 1.$$

Ainsi, le Z-score mesure l'écart d'une observation à la moyenne en unités d'écart-type. Lorsque X suit une loi normale $\mathcal{N}(m, \sigma^2)$, on obtient

$$Z \sim \mathcal{N}(0, 1),$$

ce qui permet d'interpréter directement la rareté d'une observation à l'aide des tables de la loi normale centrée réduite.

Interprétation. Le Z-score mesure l'écart à la moyenne en nombre d'écarts-types. Pour rappel, si $Z \sim \mathcal{N}(0, 1)$:

$$\mathbb{P}(|Z| \leq 1.96) \simeq 0.95, \qquad \mathbb{P}(|Z| \leq 3) \simeq 0.99.$$

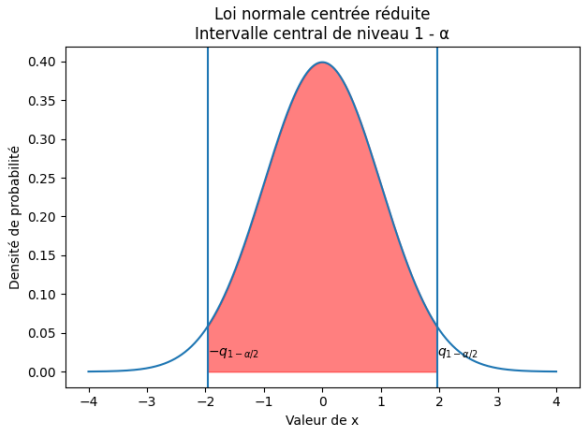

FIGURE 3.2 – Loi normale centrée réduite. La zone rouge représente la probabilité centrale $1 - \alpha$, délimitée par les quantiles $\pm q_{1-\alpha/2}$.

Ces seuils servent de repères pour détecter des observations atypiques.

Prudence. Le Z-score est pertinent lorsque la distribution est approximativement symétrique et bien résumée par sa moyenne et son écart-type. En présence d'asymétrie ou de queues lourdes, des méthodes plus robustes sont préférables.

En deux-trois mots...

La statistique descriptive permet de comprendre et structurer les données. Les lois usuelles fournissent des modèles probabilistes de référence.

Cette double approche prépare naturellement l'étude des méthodes d'inférence et de modélisation statistique développées dans les chapitres suivants.

Chapitre 4

Inférence statistique

4.1 Le problème fondamental de l'estimation

Le but de l'inférence statistique est d'utiliser l'échantillon observé pour construire des *estimations* des paramètres inconnus de la population.

Exemple fondamental : l'espérance. Supposons que la population $\mathcal{P}$ admette une espérance $\mu = \mathbb{E}[X_1]$, inconnue. Une question naturelle consiste à chercher une quantité calculable à partir des données qui fournisse une approximation raisonnable de μ.

L'estimateur le plus intuitif est la moyenne empirique :

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i. \tag{4.1}$$

Il s'agit d'une variable aléatoire, puisqu'elle est construite à partir des X_i. Une fois les données observées, elle prend la valeur numérique

$$\bar{x}_n = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Interprétation. La moyenne empirique représente le centre de gravité de l'échantillon. Elle synthétise l'information contenue dans les données en une seule valeur, destinée à approcher l'espérance théorique de la population.

4.2 Estimateurs et paramètres

Définition 4.2.1 (Estimateur)**.** On appelle *estimateur* (ou *statistique)* d'un paramètre θ toute variable aléatoire $\widehat{\theta}_n$, construite à partir de l'échantillon $(X_1, \ldots, X_n)$, et destinée à approcher la valeur inconnue θ.

Ainsi, $\bar{X}_n$ est un estimateur de μ. De même, on pourra définir des estimateurs de la variance, de proportions, ou de paramètres plus complexes. Un point fondamental est qu'un estimateur n'est pas un nombre fixe, mais une **variable aléatoire**, dont on peut étudier les propriétés probabilistes.

4.3 Qualité des estimateurs

Tous les estimateurs ne se valent pas. La statistique inférentielle cherche à formaliser des critères permettant d'évaluer leur qualité.

4.3.1 Biais et variance

Définition 4.3.1 (Biais)**.** Un estimateur $\widehat{\theta}_n$ est dit *sans biais* pour θ si

$$\mathbb{E}[\widehat{\theta}_n] = \theta.$$

Le biais mesure l'erreur systématique d'un estimateur. Par exemple, la moyenne empirique vérifie

$$\mathbb{E}[\bar{X}_n] = \mu,$$

elle est donc sans biais pour l'espérance, c'est-à-dire qu'en espérance, la moyenne estimée donne bien l'espérance de la population !

Définition 4.3.2 (Variance et erreur standard)**.** La variance d'un estimateur est

$$\mathrm{Var}(\widehat{\theta}_n).$$

Sa racine carrée,

$$\mathrm{se}\big(\widehat{\theta}_n\big) = \sqrt{\mathrm{Var}(\widehat{\theta}_n)},$$

est appelée *erreur standard*.

La variance (ou l'erreur standard) mesure la variabilité de l'estimateur d'un échantillon à l'autre.

4.3.2 Consistance et loi des grands nombres

La consistance formalise une idée simple mais fondamentale : plus on observe de données, plus l'estimateur doit se rapprocher de la vraie valeur du paramètre. En bref, lorsque la taille de l'échantillon augmente, l'erreur d'estimation doit pleinement s'atténuer.

Définition 4.3.3 (Consistance)**.** Un estimateur $\widehat{\theta}_n$ est *consistant* si

$$\widehat{\theta}_n \xrightarrow[n\to\infty]{\mathbb{P}} \theta.$$

Un résultat remarquable qui illustre cette notion est celui que vous connaissez tous : la loi des grands nombres.

Supposez que vous souhaitiez estimer la moyenne en mathématiques des élèves de $3^{\text{ème}}$ en France. Si vous calculez la moyenne sur 20 élèves, votre estimation sera approximative. Si vous la calculez sur 2 000 élèves, elle sera plus précise. Et si vous pouviez interroger tous les élèves du pays, vous obtiendriez exactement la moyenne de la population.

La loi des grands nombres affirme précisément que, lorsque la taille de l'échantillon tend vers l'infini, la moyenne empirique converge vers la vraie espérance de la population.

Théorème 4.3.1 (Loi des grands nombres)**.** *Si $X_1, \dots, X_n$ sont i.i.d. et si $\mathbb{E}[|X_1|] < +\infty$, alors la moyenne empirique (4.1) converge vers l'espérance de la population :*

$$\bar{X}_n \xrightarrow[n\to\infty]{\mathbb{P}} \mu \qquad \Longleftrightarrow \qquad \forall \varepsilon > 0,\ \mathbb{P}\big(|\bar{X}_n - \mu| > \varepsilon\big) \xrightarrow[n\to\infty]{} 0.$$

Intuition. Pour tout seuil d'erreur $\varepsilon > 0$, la probabilité que la moyenne empirique s'écarte de la vraie moyenne de plus de ε devient arbitrairement petite à mesure que la taille de l'échantillon augmente. Dés lors, avec suffisamment de données, une grande déviation devient de plus en plus improbable.

Preuve. Admise. □

Ce résultat, un des plus connus des mathématiques appliquées, justifie pleinement l'usage de $\bar{X}_n$ comme estimateur : non seulement il est sans biais, mais il devient arbitrairement proche de la vraie moyenne lorsque la taille de l'échantillon croît.

4.3.3 Compromis biais–variance

Pour évaluer globalement la qualité d'un estimateur, il est insuffisant de regarder uniquement son biais ou uniquement sa variance. On introduit donc un critère synthétique : l'*erreur quadratique moyenne* (Mean Squared Error, MSE).

Définition 4.3.4 (Erreur quadratique moyenne)**.** Soit $\widehat{\theta}$ un estimateur du paramètre θ. On définit son erreur quadratique moyenne par

$$\mathrm{MSE}(\widehat{\theta}) = \mathbb{E}\big[(\widehat{\theta} - \theta)^2\big].$$

La MSE mesure l'erreur moyenne commise par l'estimateur, en pénalisant davantage les grandes erreurs (à cause du carré). Elle combine donc en une seule quantité l'erreur systématique et l'instabilité de l'estimateur. Une identité fondamentale permet de comprendre précisément cette combinaison.

Proposition 4.3.1 (Décomposition biais–variance)**.** Pour tout estimateur $\widehat{\theta}$ de θ, on a

$$\mathrm{MSE}(\widehat{\theta}) = \mathrm{Var}(\widehat{\theta}) + \big(\mathbb{E}[\widehat{\theta}] - \theta\big)^2.$$

Preuve. On ajoute et soustrait l'espérence de l'estimateur :

$$\widehat{\theta} - \theta = \big(\widehat{\theta} - \mathbb{E}[\widehat{\theta}]\big) + \big(\mathbb{E}[\widehat{\theta}] - \theta\big).$$

En élevant au carré,

$$(\widehat{\theta} - \theta)^2 = (\widehat{\theta} - \mathbb{E}[\widehat{\theta}])^2 + 2(\widehat{\theta} - \mathbb{E}[\widehat{\theta}])(\mathbb{E}[\widehat{\theta}] - \theta) + (\mathbb{E}[\widehat{\theta}] - \theta)^2.$$

On prend l'espérance des deux côtés. Le terme croisé disparaît car

$$\mathbb{E}[\widehat{\theta} - \mathbb{E}[\widehat{\theta}]] = 0.$$

On obtient donc

$$\mathrm{MSE}(\widehat{\theta}) = \mathbb{E}\big[(\widehat{\theta} - \mathbb{E}[\widehat{\theta}])^2\big] + (\mathbb{E}[\widehat{\theta}] - \theta)^2,$$

c'est-à-dire

$$\mathrm{MSE}(\widehat{\theta}) = \mathrm{Var}(\widehat{\theta}) + \big(\mathbb{E}[\widehat{\theta}] - \theta\big)^2.$$

□

Cette décomposition met en lumière le *compromis biais–variance* via une identité type Pythagore. Un estimateur très flexible peut avoir un biais faible mais une variance élevée. À l'inverse, un estimateur plus contraint peut introduire un biais, mais réduire fortement la variance. L'objectif n'est donc pas toujours de supprimer totalement le biais, mais de minimiser l'erreur quadratique moyenne globale. Cette relation met en évidence le *compromis biais–variance* :

— La variance mesure l'instabilité de l'estimateur ;

— Le biais mesure son erreur systématique.

Un estimateur sans biais peut être peu performant s'il est très variable. Inversement, un estimateur légèrement biaisé mais plus stable peut présenter une erreur globale plus faible. En pratique, la construction d'un bon estimateur consiste souvent à trouver un équilibre entre ces deux sources d'erreur.

4.4 Principe du maximum de vraisemblance

L'inférence statistique vise à estimer un paramètre inconnu θ à partir d'un échantillon observé. Le principe du maximum de vraisemblance repose sur une idée simple : choisir la valeur du paramètre qui rend les données observées les plus plausibles sous le modèle considéré. Parmi tous les paramètres possibles, on retient celui qui maximise la probabilité (ou la densité) d'observer l'échantillon effectivement mesuré.

On répond donc à la question : Si mes données observées sont issues de telle loi, quelle vaut *vraisemblablement* son vecteur de paramètre ?

4.4.1 Définition

Soit un échantillon i.i.d.

$$X_1, \ldots, X_n \sim f(x; \theta),$$

où $\theta \in \Theta \subset \mathbb{R}^p$ est un paramètre inconnu.

Définition 4.4.1 (Vraisemblance)**.** La fonction de vraisemblance est définie par

$$L(\theta) = \prod_{i=1}^{n} f(x_i; \theta),$$

où les observations $(x_1, \ldots, x_n)$ sont fixées et θ est la variable.

L'hypothèse d'indépendance justifie la forme multiplicative. Ce produit ne sort pas de nul part mais traduit bien une chose : la "probabilité" d'observer x_1, et x_2 et ... et x_n se traduit pas la multiplication de la densité de la loi de X. Vue comme une fonction du paramètre θ, on (arg-)maximise la vraisemblance vis-à-vis des données observées pour obtenir le paramètre le plus vraisemblable aux données observées... *(un peu redondant n'est-ce pas ? Mais la terminologie est logique !)*

Définition 4.4.2 (Estimateur du maximum de vraisemblance)**.** L'estimateur du maximum de vraisemblance (EMV) est

$$\hat{\theta}_{\text{MLE}} = \arg\max_{\theta \in \Theta} L(\theta) = \arg\max_{\theta \in \Theta} \ell(\theta),$$

où

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^{n} \log f(x_i; \theta)$$

est la log-vraisemblance.

On travaille presque toujours avec la log-vraisemblance, plus simple à manipuler, sans changer le point de maximum. Sous des conditions de régularité, l'estimateur vérifie

$$\nabla \ell(\hat{\theta}) = 0,$$

et la matrice hessienne en ce point est négative définie *(en bref, une fonction convexe).*

4.4.2 Propriétés asymptotiques

Sous des hypothèses générales, l'EMV possède des propriétés remarquables :

— **Consistance :** $\hat{\theta}_{\text{MLE}} \to \theta^\star$ lorsque $n \to \infty$;

— **Normalité asymptotique :**

$$\sqrt{n}\big(\hat{\theta}_{\text{MLE}} - \theta^\star\big) \xrightarrow{\mathcal{L}} \mathcal{N}\big(0, \mathcal{I}(\theta^\star)^{-1}\big),$$

où $\mathcal{I}(\theta)$ désigne la *matrice d'information de Fisher*, définie comme l'espérance opposée de la hessienne de la log-vraisemblance, et qui traduit la quantité d'information que l'échantillon apporte sur le paramètre θ :

$$\mathcal{I}(\theta) = -\,\mathbb{E}\big[\nabla^2 \ell(\theta)\big]\,.$$

Intuitivement, plus la log-vraisemblance est fortement courbée autour de son maximum, plus l'information est grande et plus l'estimateur est précis (variance asymptotique faible). À l'inverse, une log-vraisemblance "plate" correspond à une information faible et à une estimation plus incertaine.

Ainsi, lorsque n est grand, l'EMV est approximativement normal, centré sur le vrai paramètre, avec une variance gouvernée par l'information de Fisher. Le maximum de vraisemblance constitue aujourd'hui l'un des principes les plus utilisés en statistique et en apprentissage, en raison de sa généralité et de ses fortes garanties asymptotiques et théoriques.

4.5 Intervalles de confiance

Une estimation ponctuelle, comme la moyenne empirique $\bar{X}_n$, fournit une valeur numérique. Mais une question essentielle demeure :

Quelle est la précision de cette estimation ?

Comment construire un intervalle aléatoire qui, avec une probabilité donnée (par exemple 95%), contiendrait le paramètre inconnu m ? Un intervalle de confiance permet précisément de passer d'une estimation ponctuelle à une *quantification explicite de l'incertitude*.

4.5.1 Principe général

Soit θ un paramètre inconnu et $\widehat{\theta}$ un estimateur construit à partir d'un échantillon.

Définition 4.5.1 (Intervalle de confiance de niveau $1-\alpha$)**.** Un *intervalle de confiance* de niveau $1-\alpha$ est un intervalle aléatoire

$$\mathrm{IC}_{1-\alpha}(\widehat{\theta}),$$

tel que

$$\mathbb{P}_\theta\Big(\theta \in \mathrm{IC}_{1-\alpha}(\widehat{\theta})\Big) \geq 1-\alpha,$$

où $\alpha \in (0,1)$ est le niveau de risque.

Il est fondamental de bien comprendre que le paramètre θ est fixe (mais inconnu) et l'intervalle est quant à lui aléatoire car il dépend de l'échantillon. La probabilité porte donc sur la procédure de construction de l'intervalle, et non sur le paramètre lui-même.

Dans de nombreux cas usuels, l'égalité est atteinte :

$$\mathbb{P}_\theta\Big(\theta \in \mathrm{IC}_{1-\alpha}(\widehat{\theta})\Big) = 1-\alpha.$$

4.5.2 Choix du niveau α : un compromis

On choisit souvent $\alpha = 0.05$, correspondant à un niveau de confiance de 95%. Ce choix reflète un compromis fondamental :

— Si l'on veut une probabilité de couverture très proche de 1, l'intervalle doit être très large, donc peu informatif.

— Si l'on accepte un petit risque contrôlé d'erreur, l'intervalle devient plus resserré et plus exploitable.

À la limite, exiger une probabilité de couverture égale à 1 conduirait à un intervalle infini, donc inutile en pratique. Un intervalle de confiance est donc toujours le résultat d'un arbitrage entre *certitude* et *précision*.

Les intervalles de confiance sont centraux en statistique car ils :

— quantifient la précision d'un estimateur ;

— apportent plus d'information qu'une estimation ponctuelle ;

— sont étroitement liés aux tests statistiques. Typiquement, si $0 \in \mathrm{IC}_{1-\alpha}(\widehat{\theta})$, alors on ne peut pas conclure que le vrai coefficient θ est significativement différent de 0, avec probabilité $1-\alpha$. **À l'inverse, si $0 \notin \mathrm{IC}_{1-\alpha}(\widehat{\theta})$, on conclura que θ est significativement non nul avec confiance $1-\alpha$** ;

— permettent d'évaluer la fiabilité des conclusions issues de données finies.

4.5.3 Intervalle de confiance pour la moyenne

Supposons que

$$X_1, \ldots, X_n$$

soient i.i.d., de moyenne μ et de variance finie σ^2.

On note

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2,$$

où S_n est l'écart-type empirique *non biaisé*. Par le théorème central limite, lorsque n est grand,

$$\frac{\bar{X}_n - \mu}{S_n/\sqrt{n}} \approx \mathcal{N}(0,1).$$

On en déduit un intervalle de confiance asymptotique de niveau $1-\alpha$:

$$\mathrm{IC}_{1-\alpha}(\mu) = \left[\bar{X}_n - q_{1-\alpha/2}\,\frac{S_n}{\sqrt{n}},\ \bar{X}_n + q_{1-\alpha/2}\,\frac{S_n}{\sqrt{n}}\right],$$

où $q_{1-\alpha/2}$ est le quantile d'ordre $1-\alpha/2$ de la loi normale standard.

Interprétation

La largeur de l'intervalle est proportionnelle à :

— la variabilité des données (S_n) ;

— l'inverse de $\sqrt{n}$ (plus l'échantillon est grand, plus l'intervalle se resserre) ;

— le niveau de confiance choisi.

Et donc...

⋆ plus les données sont dispersées, plus l'incertitude est grande ;

⋆ plus l'échantillon est grand, plus l'estimation est précise ;

⋆ plus on exige de confiance, plus l'intervalle est large.

L'intervalle de confiance traduit donc quantitativement l'équilibre entre information disponible et incertitude inhérente à l'aléa statistique.

Chapitre 5

Outils topologiques pour la modélisation

5.1 Convexité et notions d'optimisation

Pour garantir l'apprentissage d'un modèle, il faut atteindre un minimum optimal :

$$\hat{\theta} = \underset{\theta}{\operatorname{argmin}}\, \mathcal{L}\Big(\theta; (X_i, Y_i)\Big),$$

où la fonction perte notée ici $\mathcal{L}$ peut être les moindres carrées ou l'opposée du maximum de la (log-)vraisemblance.

Pour ce faire, une des propriétés les plus souhaitable que l'on peut demander à une fonction réside dans le fait d'être convexe.

La convexité joue un rôle fondamental en analyse, et donc en modélisation statistique et en apprentissage automatique. Elle permet de comprendre la structure des fonctions que l'on cherche à minimiser (fonctions de perte, critères de vraisemblance, etc.) et garantit dans de nombreux cas l'existence et l'unicité de solutions optimales.

5.1.1 Définition de la convexité

La convexité est une propriété géométrique forte, qui contrôle la forme globale d'une fonction.

Définition 5.1.1 (Fonction convexe)**.** Une fonction $f : \mathbb{R}^d \to \mathbb{R}$ est dite **convexe** si, pour tous $x, y \in \mathbb{R}^d$ et tout $\lambda \in [0, 1]$,

$$f\big(\lambda x + (1-\lambda)y\big) \;\leq\; \lambda f(x) + (1-\lambda) f(y).$$

Géométriquement, le graphe de f est situé en dessous de toute corde reliant deux points du graphe.

Si l'inégalité est stricte pour $x \neq y$ et $\lambda \in (0, 1)$, la fonction est dite *strictement convexe*. On définit de manière analogue la **concavité** en inversant l'inégalité.

Cas des fonctions de $\mathbb{R}$ dans $\mathbb{R}$. Si $f : \mathbb{R} \to \mathbb{R}$ est deux fois dérivable, alors :

$$f \text{ convexe} \iff f''(x) \geq 0 \quad \text{pour tout } x.$$

Si $f''(x) > 0$, la fonction est strictement convexe.

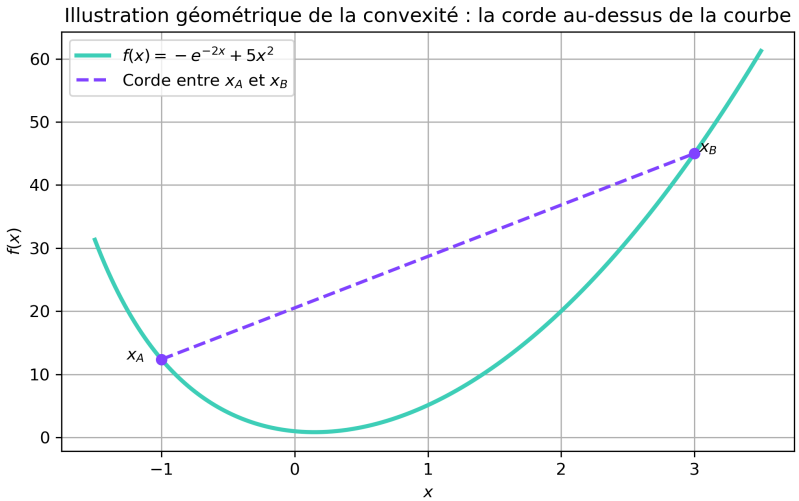

FIGURE 5.1 – Illustration géométrique de la convexité : pour x_A, x_B fixés et $\lambda \in [0, 1]$, le point de la courbe en $x = \lambda x_A + (1 - \lambda)x_B$ est situé sous (ou sur) la corde reliant $(x_A, f(x_A))$ et $(x_B, f(x_B))$.

5.1.2 Convexité et unicité du minimum

La convexité fournit une information essentielle sur la structure des minima.

Proposition 5.1.1 (Convexité et minimum)**.** Si $f : \mathbb{R}^d \to \mathbb{R}$ est convexe et différentiable, alors tout point $x^\star$ tel que

$$\nabla f(x^\star) = 0$$

est un minimum global de f. Si f est strictement convexe, ce minimum est unique.

Preuve. Admise. □

Ainsi, pour une fonction *convexe* (et dérivable), il n'existe pas de "minimum local trompeur" : tout point où la pente s'annule est automatiquement un *minimum global*. Intuitivement, la courbe a une forme de "bol". En optimisation et en apprentissage de façon générale, la convexité est précieuse car elle garantit :

— **unicité du minimum global** (si f est strictement convexe) ;
— **fiabilité des algorithmes** : des méthodes comme la descente de gradient convergent vers le bon minimum sans se bloquer dans des minima locaux ;
— **robustesse en apprentissage statistique** : de nombreux modèles (par exemple la régression linéaire aux moindres carrés, la régression logistique sans réseaux profonds) reposent sur des fonctions de perte convexes, ce qui rend l'entraînement stable et interprétable.

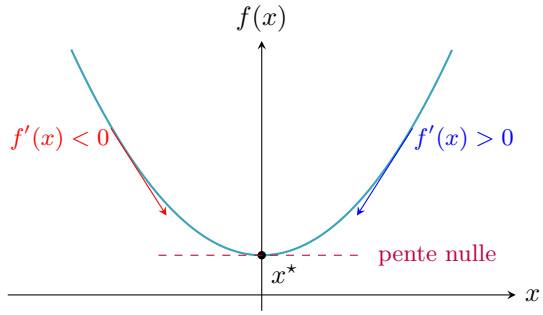

FIGURE 5.2 – Pour une fonction convexe dérivable, le point où $f'(x) = 0$ correspond au minimum global : il n'existe pas de minima locaux distincts.

5.2 Topologie sur des données quantitatives

De nombreux algorithmes de machine learning reposent, explicitement ou implicitement, sur une notion de *proximité* entre observations : classification par plus proches voisins, méthodes à noyaux, clustering, réduction de dimension, arbres et forêts (via des critères de séparation), etc. Avant d'introduire ces modèles, il est donc utile de formaliser ce que signifie "être proche" dans un espace de données $\mathcal{X}$. Cette formalisation passe naturellement par la *topologie*, généralement induite par une *distance* (métrique) ou par une *similarité*.

5.2.1 Distance, métrique et topologie induite

Soit $\mathcal{X}$ un ensemble représentant l'espace des observations (par exemple $\mathbb{R}^p$ lorsque l'on manipule p variables quantitatives). Une manière standard de structurer $\mathcal{X}$ consiste à définir une distance entre ses éléments.

Définition 5.2.1 (Distance (métrique))**.** On appelle *distance* sur $\mathcal{X}$ toute application

$$d : \mathcal{X} \times \mathcal{X} \to \mathbb{R}_+$$

telle que pour tous $x, y, z \in \mathcal{X}$:

1. **Séparation :** $d(x, y) = 0 \iff x = y$;
2. **Symétrie :** $d(x, y) = d(y, x)$;
3. **Inégalité triangulaire :** $d(x, z) \leq d(x, y) + d(y, z)$.

Le couple $(\mathcal{X}, d)$ est alors appelé *espace métrique*.

Une distance induit une topologie sur $\mathcal{X}$ via les *boules ouvertes*.

Définition 5.2.2 (Boule ouverte et topologie induite)**.** Soit $(\mathcal{X}, d)$ un espace métrique. Pour $x \in \mathcal{X}$ et $r > 0$, la boule ouverte de centre x et de rayon r est

$$B(x, r) = \{y \in \mathcal{X} \ : \ d(x, y) < r\}.$$

On appelle *ouverts* de la topologie induite par d les ensembles $U \subset \mathcal{X}$ tels que pour tout $x \in U$, il existe $r > 0$ vérifiant $B(x, r) \subset U$.

Cette construction formalise l'idée intuitive suivante : un point x est "intérieur" à un ensemble U si l'on peut se déplacer *un peu* autour de x sans sortir de U. C'est exactement ce dont ont besoin de nombreux algorithmes : comparer localement des points selon la proximité définie par d.

5.2.2 Distances de Minkowski sur $\mathbb{R}^p$

Lorsque les données sont quantitatives, l'espace naturel est $\mathbb{R}^p$. Les distances les plus utilisées proviennent des normes ℓ_q.

Définition 5.2.3 (Distance de Minkowski)**.** Pour $q \geq 1$, la distance de Minkowski d'ordre q sur $\mathbb{R}^p$ est définie, pour $x = (x^1, \ldots, x^p)$ et $y = (y^1, \ldots, y^p)$, par

$$d_q(x, y) = \left(\sum_{j=1}^{p} |x^j - y^j|^q \right)^{1/q}.$$

Quelques cas particuliers sont fondamentaux en pratique :

— $q = 1$: distance de Manhattan

$$d_1(x, y) = \sum_{j=1}^{p} |x^j - y^j|;$$

— $q = 2$: distance euclidienne

$$d_2(x, y) = \left(\sum_{j=1}^{p} (x^j - y^j)^2 \right)^{1/2} ;$$

— $q = \infty$: distance du maximum (ou ℓ_∞)

$$d_\infty(x, y) = \max_{1 \leq j \leq p} |x^j - y^j|.$$

Exemple 5.2.1 (Distance euclidienne en dimension p)**.** Dans $\mathbb{R}^p$, la distance euclidienne mesure la longueur du segment reliant x à y. Elle est adaptée lorsque les variables sont comparables (mêmes unités ou variables préalablement normalisées).

Remarque (importance du prétraitement). Lorsque les variables n'ont pas la même échelle (par exemple une variable en euros et une autre en années), la distance euclidienne peut être dominée par la variable de plus grande amplitude. Cela justifie en pratique des normalisations (centrage-réduction) avant d'utiliser une distance de type Minkowski.

5.2.3 Similarités

Dans certains modèles (méthodes à noyaux, graphes de voisinage, spectral clustering), on préfère travailler avec une *similarité* plutôt qu'avec une distance : deux observations sont d'autant plus proches que leur similarité est grande.

Définition 5.2.4 (Similarité)**.** On appelle *similarité* sur $\mathcal{X}$ toute application

$$s : \mathcal{X} \times \mathcal{X} \to \mathbb{R}_+$$

telle que $s(x, y)$ est d'autant plus grande que x et y sont jugés "semblables" (au sens choisi par l'utilisateur ou le modèle).

Transformer une distance en similarité. Une manière classique de construire une similarité consiste à composer une distance avec une fonction décroissante. Deux constructions usuelles sont :

— **Similarité gaussienne (noyau RBF)** :

$$s(x, y) = \exp\left(-\frac{d(x, y)^2}{2h^2} \right),$$

où $h > 0$ est un paramètre d'échelle. Cette transformée se révèle en pratique assez pertinente pour plusieurs raison :

(i) elle renvoie toujours une valeur dans $(0, 1]$;
(ii) elle vaut 1 lorsque $x = y$, traduisant une similarité maximale ;
(iii) elle décroît rapidement quand la distance augmente, ce qui favorise un comportement "local".

— **Similarité rationnelle** :

$$s(x, y) = \frac{1}{1 + d(x, y)}.$$

Cette transformation est plus douce : la décroissance est plus lente et peut être utile lorsque l'on souhaite conserver l'influence de points plus éloignés.

Choix du paramètre h. Dans la similarité gaussienne, h joue un rôle clé : un petit h rend la similarité très locale (seuls les points très proches comptent), un grand h lisse davantage la notion de proximité. Ce paramètre se règle généralement par validation.

5.3 Topologie et proximités pour des données catégorielles

Les variables catégorielles apparaissent très fréquemment en pratique : sexe, groupe sanguin, stade d'une maladie, catégorie socio-professionnelle, type de produit, etc. Le problème est qu'il n'existe pas toujours de notion naturelle de distance entre catégories.

Par exemple, la catégorie "cadre de la fonction publique" est-elle plus proche de "artisan" ou de "employé de commerce" ? Sans information externe (hiérarchie, sémantique, ontologie), ce type de proximité est ambigu.

5.3.1 Distance minimale : la métrique discrète

Lorsque l'on ne dispose que de l'information "égal / différent", on peut utiliser la distance la plus simple possible.

Définition 5.3.1 (Distance discrète)**.** Soit $\mathcal{X}$ un ensemble (par exemple un ensemble de catégories). La *distance discrète* est définie par

$$d_{\text{disc}}(x, y) = \begin{cases} 0 & \text{si } x = y, \\ 1 & \text{sinon.} \end{cases}$$

Cette distance formalise l'idée que deux catégories ne sont proches que si elles sont identiques. Elle est souvent suffisante lorsque les catégories sont nominales sans structure additionnelle.

Variables catégorielles multiples. Si l'observation possède plusieurs attributs catégoriels, par exemple $X = (X^1, \ldots, X^p)$ où chaque X^j prend des valeurs dans un ensemble fini, une distance naturelle est la distance de Hamming :

$$d_{\text{Ham}}(x, y) = \sum_{j=1}^{p} \mathbb{1}_{\{x^j \neq y^j\}},$$

qui compte le nombre de coordonnées différentes.

5.3.2 Encodage *one-hot* et retour aux distances euclidiennes

Pour appliquer des méthodes qui exigent des vecteurs réels (régression, SVM linéaire, k-NN avec norme ℓ_q, réseaux de neurones), on transforme souvent les variables catégorielles en variables numériques via un encodage.

Définition 5.3.2 (Encodage *one-hot*)**.** Soit C le nombre de modalités possibles d'une variable catégorielle $Z \in \{1, \ldots, C\}$. On appelle *encodage one-hot* la représentation de Z par un vecteur binaire $e(Z) \in \{0, 1\}^C$ défini par

$$e(Z) = (e_1, \ldots, e_C) \quad \text{où} \quad e_k = \mathbb{1}_{\{Z=k\}}.$$

Ainsi, une modalité est représentée par un vecteur qui contient un unique 1 à la position correspondant à la modalité, et des 0 ailleurs.

Exemple 5.3.1 (Encodage one-hot)**.** On considère la variable catégorielle `Couleur` pouvant prendre $C = 3$ modalités :

$$\{\text{Rouge}, \ \text{Vert}, \ \text{Bleu}\}.$$

On fixe l'ordre (Rouge, Vert, Bleu). L'encodage one-hot donne :

$$e(\text{Rouge}) = (1, 0, 0), \qquad e(\text{Vert}) = (0, 1, 0), \qquad e(\text{Bleu}) = (0, 0, 1).$$

Remarque (distance induite par l'encodage). Une fois encodées, les catégories vivent dans $\mathbb{R}^C$ et l'on peut utiliser une norme ℓ_q. Par exemple, avec la distance euclidienne :

$$d_2\big(e(a), e(b)\big) = \begin{cases} 0 & \text{si } a = b, \\ \sqrt{2} & \text{si } a \neq b, \end{cases}$$

ce qui revient à distinguer seulement "égal / différent", mais dans un espace vectoriel compatible avec les méthodes numériques.

Message clé. La topologie (via une distance ou une similarité) n'est pas un choix secondaire : elle encode la notion de proximité que les algorithmes vont exploiter. Pour des variables quantitatives, les normes ℓ_q fournissent un cadre naturel. Pour des variables catégorielles, on utilise soit des distances discrètes (ou de Hamming), soit des encodages (one-hot) permettant de réutiliser des outils géométriques sur $\mathbb{R}^p$.

Chapitre 6

Comprendre le processus d'apprentissage d'un modèle

Avant d'entrer dans le détail des méthodes spécifiques au traitement automatique du langage naturel (NLP), il est indispensable de rappeler les principes fondamentaux qui gouvernent l'apprentissage d'un modèle statistique. En effet, tous les systèmes prédictifs en apprentissage automatique – de la régression linéaire aux réseaux de neurones profonds – reposent sur une même structure conceptuelle : définir un modèle, choisir une *fonction de perte* qui quantifie ses erreurs, puis ajuster ses paramètres afin de minimiser cette perte.

Ce chapitre introduit ces idées essentielles de manière simple mais rigoureuse, avant de les appliquer ultérieurement à des données textuelles.

6.1 Comprendre un modèle, c'est comprendre sa fonction de perte

Supposons que l'on dispose d'un ensemble de points de données observés, représentés dans le plan ci-dessous.

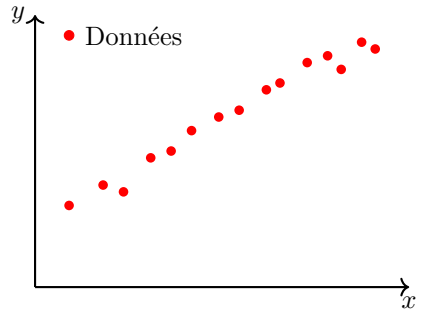

Un modèle peut être vu comme une fonction mathématique

$$\mu_\theta : \mathcal{X} \to \mathcal{Y},$$

où θ désigne l'ensemble de ses paramètres (poids, biais, etc.). Étant donné un jeu de données $\{(x_i, y_i)\}_{i=1}^n$, l'objectif de l'apprentissage consiste à trouver des paramètres θ tels que $\mu_\theta(x_i)$ se rapproche le plus possible de la valeur réelle y_i.

Exemple simple. Supposons que le nuage de points observé suggère une relation approximativement linéaire entre deux variables x et y. Un modèle naturel consiste alors à considérer une fonction affine :

$$\hat{y} = \theta_0 + \theta_1 x.$$

La qualité de cette approximation est mesurée par l'*énergie résiduelle*, c'est-à-dire la moyenne des carrés des écarts entre les valeurs prédites et les valeurs observées :

$$\mathcal{L}(\theta_0, \theta_1) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

Cette quantité est appelée *fonction de perte*. Minimiser cette perte revient à déterminer la droite qui s'ajuste au mieux aux données au sens des moindres carrés.

Illustration : séparation apprentissage / test et évaluation de la perte. En apprentissage supervisé, les données disponibles sont généralement séparées en deux sous-ensembles :

— un **jeu d'apprentissage** (environ 80 %) utilisé pour estimer les paramètres du modèle ;

— un **jeu de test** (environ 20 %) utilisé pour évaluer sa capacité de généralisation.

La figure suivante illustre ce principe : les points rouges correspondent aux données d'apprentissage, tandis que les points verts représentent des données jamais vues par le modèle. La droite ajustée minimise la perte uniquement sur les données d'apprentissage.

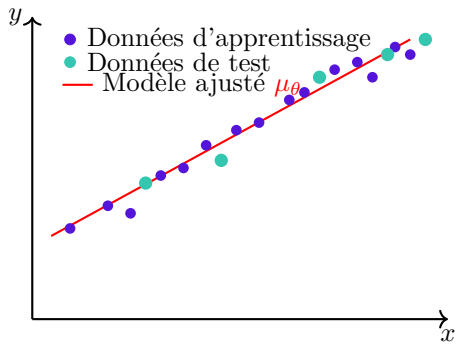

La fonction de perte quantifie ainsi l'écart entre les prédictions du modèle et la réalité observée. Le modèle appris est celui qui minimise cette perte sur les données d'apprentissage.

6.2 Apprentissage et généralisation

Un enjeu central de l'apprentissage automatique n'est pas seulement de bien ajuster les données disponibles, mais de *généraliser* à de nouvelles données. Un modèle qui reproduit parfaitement les données d'apprentissage mais échoue sur des données inédites est dit *sur-ajusté* (*overfitting*). À l'inverse, un modèle trop simple qui ne parvient pas à capturer la structure des données est dit *sous-ajusté* (*underfitting*).

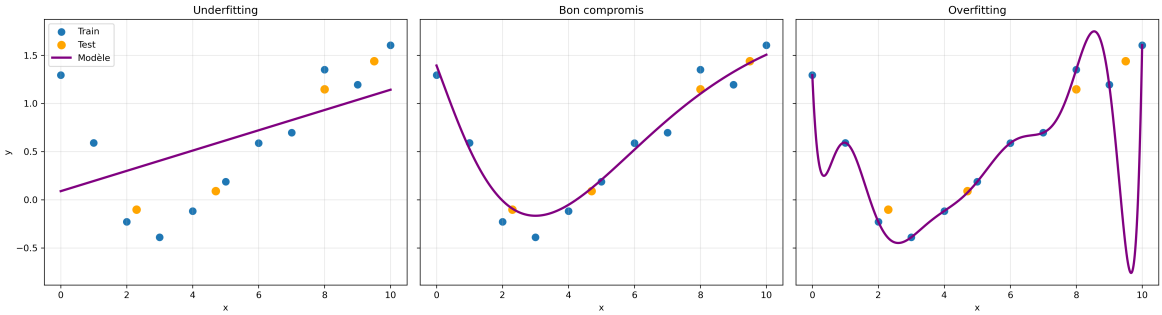

FIGURE 6.1 – Illustration du compromis biais–variance. À gauche, le modèle est sous-ajusté (biais élevé). Au centre, l'ajustement est équilibré. À droite, le modèle est sur-ajusté (variance élevée).

Compromis biais–variance. La figure 6.1 illustre exactement le **compromis biais–variance**, quantifiée par l'erreur quadratique de la Définition 4.3.4. Un modèle trop rigide présente un biais élevé, tandis qu'un modèle trop flexible présente une variance élevée. L'objectif de l'apprentissage statistique est de trouver un équilibre permettant de minimiser l'erreur globale de prédiction.

6.2.1 Train–test *split*

Pour évaluer correctement un modèle et limiter le sur-apprentissage, il est indispensable de séparer les données en deux ensembles disjoints : un *jeu d'apprentissage* et un *jeu de test*. Le premier sert à estimer les paramètres du modèle, le second à mesurer sa performance sur des données non utilisées pendant l'entraînement. Cette séparation évite une erreur classique : juger un modèle sur les données qu'il a déjà vues conduit presque toujours à une estimation trop optimiste de ses capacités prédictives.

Formellement, si $\mathbb{P}$ désigne la distribution réelle des données et $\mathcal{L}$ une fonction de perte, la performance intrinsèque d'un modèle paramétré par θ est mesurée par le *risque*

$$R(\theta) = \mathbb{E}_{(x,y)\sim\mathbb{P}}\big[\mathcal{L}(\mu_\theta(x), y)\big].$$

Ce risque correspond à l'erreur moyenne sur de nouvelles observations issues de la même population. Comme $\mathbb{P}$ est inconnue, on l'estime empiriquement.

On calcule ainsi une erreur d'apprentissage

$$\hat{R}_{\text{train}}(\theta) = \frac{1}{n_{\text{train}}} \sum_{i\in\mathcal{I}_{\text{train}}} \mathcal{L}\big(\mu_\theta(x_i), y_i\big),$$

et une erreur de test

$$\hat{R}_{\text{test}}(\theta) = \frac{1}{n_{\text{test}}} \sum_{i\in\mathcal{I}_{\text{test}}} \mathcal{L}\big(\mu_\theta(x_i), y_i\big).$$

Un modèle qui généralise correctement présente des performances comparables sur ces deux ensembles. Un écart marqué, avec une erreur d'apprentissage très faible mais une erreur de test élevée, révèle un sur-apprentissage. En pratique, le découpage s'écrit

$$\mathcal{D} = \mathcal{D}_{\text{train}} \cup \mathcal{D}_{\text{test}}, \qquad \mathcal{D}_{\text{train}} \cap \mathcal{D}_{\text{test}} = \varnothing.$$

Le jeu d'apprentissage permet d'ajuster le modèle, tandis que le jeu de test fournit une estimation réaliste de sa performance future. Cette étape est essentielle : elle garantit que l'évaluation reflète la capacité réelle du modèle à prédire sur des données nouvelles.

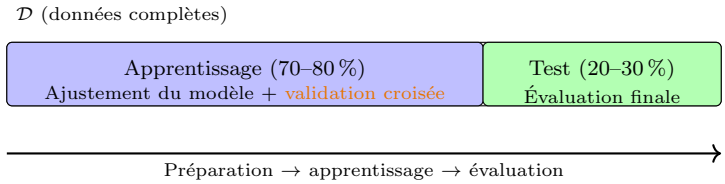

Remarque 2 (Bonnes pratiques). Dans les problèmes de classification déséquilibrée ou de survie, il est recommandé de réaliser un découpage *stratifié*, afin de préserver des proportions comparables de classes ou d'évènements entre les jeux d'apprentissage et de test. Cette précaution garantit une évaluation plus fiable et évite des biais artificiels dans les métriques de performance.

6.3 Optimisation par descente de gradient

Une fois la fonction de perte définie, l'apprentissage du modèle consiste à la minimiser. Dans la majorité des cas, cette minimisation est réalisée à l'aide de la **descente de gradient**.

Principe. Soit $\theta \in \mathbb{R}^d$ le vecteur des paramètres et $\mathcal{L}(\theta)$ une fonction différentiable. À partir d'une valeur initiale $\theta^{(0)}$, la descente de gradient itérative s'écrit :

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla_\theta \mathcal{L}(\theta^{(t)}),$$

où $\eta > 0$ est le *taux d'apprentissage*. L'algorithme est itéré jusqu'à convergence, c'est-à-dire jusqu'à ce que les paramètres estimés se stabilisent. Plus précisément, on arrête les itérations lorsque la variation entre deux itérations successives devient suffisamment faible, par exemple lorsque $\|\theta^{(t+1)} - \theta^{(t)}\| \leq \varepsilon$ où $\varepsilon > 0$ est un seuil de tolérance fixé à l'avance. En pratique, afin de garantir l'arrêt de l'algorithme même en l'absence de convergence stricte, on impose également un nombre maximal d'itérations.

Intuition géométrique. La descente de gradient peut être interprétée comme le mouvement d'une bille roulant le long d'un paysage d'énergie, cherchant à atteindre le point le plus bas.

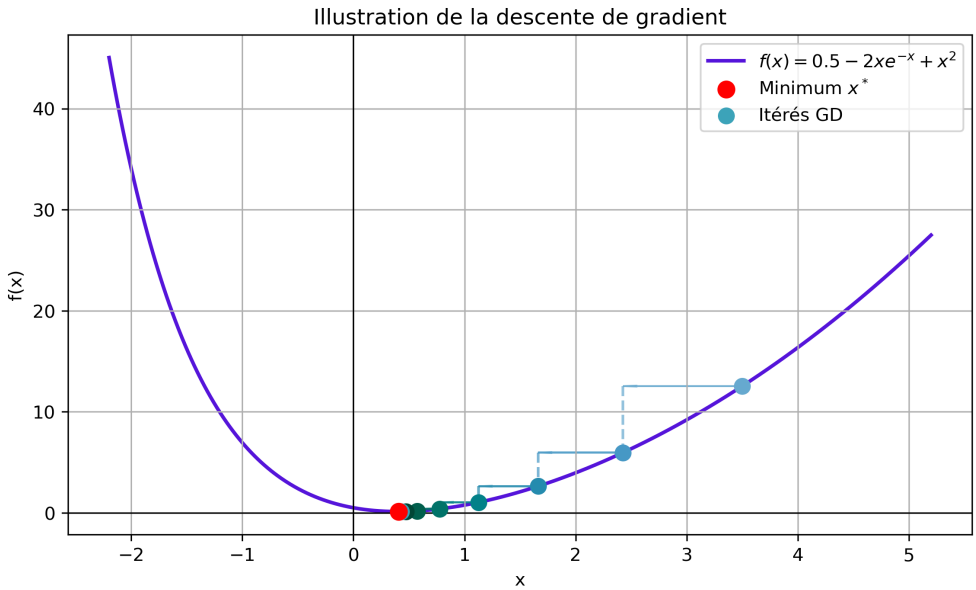

FIGURE 6.2 – Illustration de la descente de gradient appliquée à la fonction $f(x) = 0.5 - 2xe^{-x} + x^2$. À partir d'un point initial $x_0 = 3.5$ situé à droite du minimum, l'algorithme met à jour successivement les itérés selon la règle $x_{k+1} = x_k - \eta f'(x_k)$. Les segments horizontaux indiquent la direction de descente (opposée au gradient) à chaque étape, montrant comment les itérations se rapprochent progressivement du minimum x^*.

La descente de gradient est essentielle. Elle est l'un des algorithmes d'optimisation les plus fondamentaux en apprentissage automatique et permet d'optimiser des fonctions complexes et de grande dimension, pour lesquelles aucune solution analytique n'est disponible. En s'appuyant uniquement sur le gradient local de la perte, elle constitue le socle de l'entraînement des réseaux de neurones profonds.

Enfin, elle offre une interprétation unificatrice de l'apprentissage : apprendre un modèle revient à minimiser une énergie, jusqu'à atteindre un état d'équilibre correspondant aux paramètres optimaux.

Chapitre 7

La régression linéaire

7.1 Contexte et motivation

La régression linéaire est l'un des modèles fondamentaux de la statistique. Elle formalise une idée simple : expliquer une variable d'intérêt Y à partir d'une variable explicative X.

Dans de nombreuses situations concrètes, on cherche à comprendre comment une grandeur évolue en fonction d'une autre : salaire et niveau d'études, consommation et température, rendement et quantité d'engrais. La régression linéaire propose un cadre mathématique pour analyser ce type de relation.

Données. On observe un échantillon indépendant

$$\{(X_1, Y_1), \ldots, (X_n, Y_n)\},$$

où $X_i \in \mathbb{R}$ est la variable explicative et $Y_i \in \mathbb{R}$ la variable réponse.

Une première étape consiste à représenter les couples (X_i, Y_i) sous forme de nuage de points. Très souvent, on observe une tendance approximativement linéaire : les points semblent se répartir autour d'une droite.

Exemple 7.1.1. En économie, le revenu moyen augmente souvent avec le nombre d'années d'études. En biologie, la taille d'un organe peut croître approximativement de façon linéaire avec l'âge sur une période donnée.

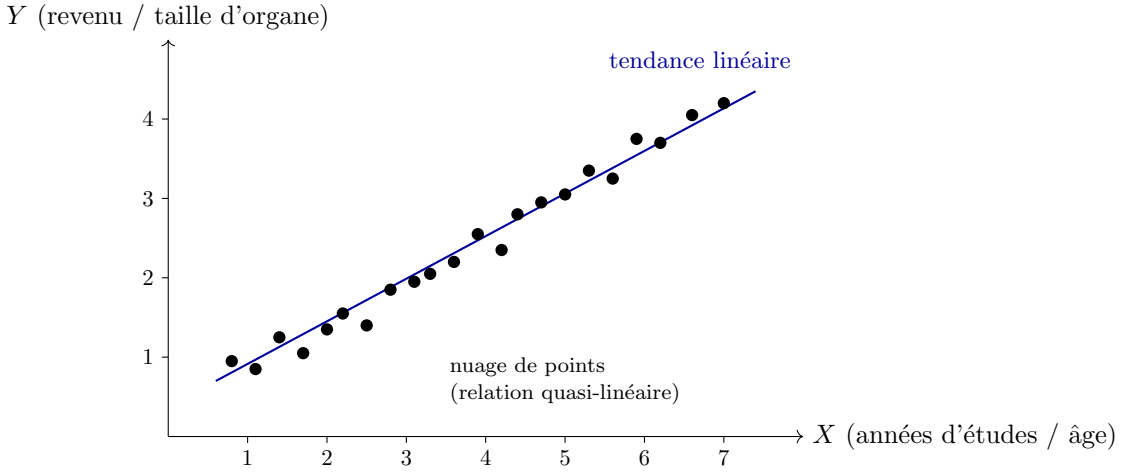

Face à une telle configuration, la question devient : peut-on résumer cette relation par une droite choisie de manière optimale ?

Deux objectifs. La régression linéaire poursuit deux objectifs :

D'abord un objectif descriptif : résumer la relation moyenne entre X et Y par une formule simple et interprétable.

Ensuite un objectif inférentiel et prédictif : mesurer l'effet de X sur Y et prédire la valeur de Y pour une nouvelle valeur de X.

7.2 Régression linéaire simple

On considère le cas d'une seule variable explicative.

Définition 7.2.1 (Modèle de régression linéaire simple)**.** Pour toute observation i, on modélise la réponse Y_i comme telle :

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

où β_0 est l'intercept, β_1 la pente, et chaque ε_i un terme d'erreur aléatoire.

Interprétation géométrique. La droite

$$y = \beta_0 + \beta_1 x$$

représente la relation moyenne entre X et Y. Pour une observation X_i, la valeur prédite est

$$\hat{Y}_i = \beta_0 + \beta_1 X_i.$$

La différence $Y_i - \hat{Y}_i$ est appelée *résidu*.

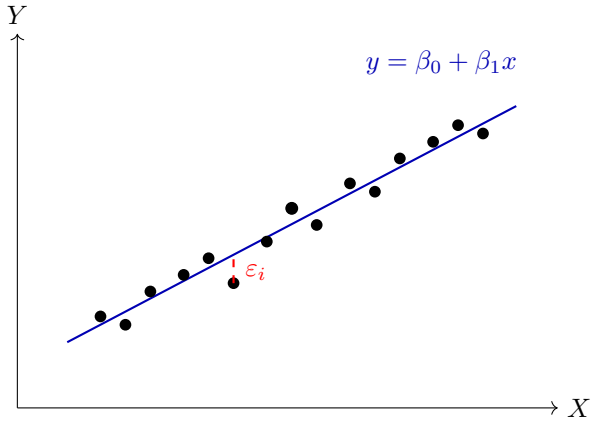

Les points ne sont jamais parfaitement alignés : ils se répartissent autour de la droite avec une certaine dispersion.

Rôle du terme d'erreur. Le terme ε modélise la variabilité non expliquée par X : facteurs non observés, fluctuations naturelles, erreurs de mesure.

On suppose classiquement

$$\varepsilon \sim \mathcal{N}(0, \sigma^2).$$

L'espérance nulle signifie que la droite décrit correctement la tendance moyenne, tandis que σ^2 mesure la dispersion autour de cette tendance.

Les paramètres inconnus du modèle sont donc β_0, β_1 et σ^2, qui devront être estimés à partir des données.

7.3 Estimation par la méthode des moindres carrés

Principe. L'idée est de choisir la droite qui minimise l'**énergie des erreurs**, c'est-à-dire la somme des carrés des résidus.

Définition 7.3.1. Les estimateurs des moindres carrés $(\hat{\beta}_0, \hat{\beta}_1)$ sont définis par :

$$(\hat{\beta}_0, \hat{\beta}_1) = \underset{(\beta_0,\beta_1)\in\mathbb{R}^2}{\operatorname{argmin}} \left\{ \sum_{i=1}^{n} \big(Y_i - (\beta_0 + \beta_1 X_i)\big)^2 \right\}.$$

Cette approche pénalise fortement les grandes erreurs et conduit à un problème mathématique bien posé. On note J la fonction objective à (arg-)minimiser :

$$J(\beta_0, \beta_1) = \sum_{i=1}^{n} \big(Y_i - (\beta_0 + \beta_1 X_i)\big)^2$$

Proposition 7.3.1. Supposons que $\sum_{i=1}^{n}(X_i - \bar{X})^2 > 0$ (c'est-à-dire que les X_i ne sont pas tous égaux). Alors la fonction J admet un unique minimiseur $(\hat{\beta}_0, \hat{\beta}_1)$, donné explicitement par

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X},$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2}.$$

Preuve. En plusieurs étapes :

1) Régularité et convexité du critère. La fonction J est un polynôme (somme de carrés) en (β_0, β_1), donc elle est de classe $\mathcal{C}^2$. De plus, comme il s'agit d'une somme de termes quadratiques, on s'attend à une convexité globale. Nous allons de toute façon déterminer explicitement le point critique, puis vérifier qu'il correspond bien à un minimum *(unique sous l'hypothèse $\sum_{i=1}^{n}(X_i - \bar{X})^2 > 0$)*.

2) Calcul des dérivées partielles. On dérive J par rapport à β_0 puis à β_1.
Pour β_0 :

$$\frac{\partial J}{\partial \beta_0}(\beta_0, \beta_1) = \sum_{i=1}^{n} 2\big(Y_i - (\beta_0 + \beta_1 X_i)\big) \cdot (-1) = -2 \sum_{i=1}^{n} \big(Y_i - \beta_0 - \beta_1 X_i\big).$$

Pour β_1 :

$$\frac{\partial J}{\partial \beta_1}(\beta_0, \beta_1) = \sum_{i=1}^{n} 2\big(Y_i - (\beta_0 + \beta_1 X_i)\big) \cdot (-X_i) = -2 \sum_{i=1}^{n} X_i\big(Y_i - \beta_0 - \beta_1 X_i\big).$$

Les conditions d'optimalité du premier ordre (annulation du gradient) imposent donc :

$$\begin{cases} \sum_{i=1}^{n} \big(Y_i - \beta_0 - \beta_1 X_i\big) = 0, \\ \sum_{i=1}^{n} X_i\big(Y_i - \beta_0 - \beta_1 X_i\big) = 0. \end{cases}$$

On appelle ce système les *équations normales* des moindres carrés.

3) Résolution des équations normales.
Première équation. On développe :

$$\sum_{i=1}^{n}(Y_i - \beta_0 - \beta_1 X_i) = 0 \quad \Longleftrightarrow \quad \sum_{i=1}^{n} Y_i - n\beta_0 - \beta_1 \sum_{i=1}^{n} X_i = 0.$$

En divisant par n et en utilisant $\bar{X} = \frac{1}{n}\sum X_i$ et $\bar{Y} = \frac{1}{n}\sum Y_i$, on obtient :

$$\bar{Y} - \beta_0 - \beta_1 \bar{X} = 0 \quad \Longleftrightarrow \quad \beta_0 = \bar{Y} - \beta_1 \bar{X}.$$

Ainsi, tout point critique vérifie nécessairement

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Deuxième équation. On développe :

$$\sum_{i=1}^{n} X_i(Y_i - \beta_0 - \beta_1 X_i) = 0 \quad \Longleftrightarrow \quad \sum_{i=1}^{n} X_i Y_i - \beta_0 \sum_{i=1}^{n} X_i - \beta_1 \sum_{i=1}^{n} X_i^2 = 0.$$

On remplace β_0 par $\bar{Y} - \beta_1 \bar{X}$:

$$\sum_{i=1}^{n} X_i Y_i - (\bar{Y} - \beta_1 \bar{X}) \sum_{i=1}^{n} X_i - \beta_1 \sum_{i=1}^{n} X_i^2 = 0.$$

Or $\sum\limits_{i=1}^{n} X_i = n\bar{X}$, donc

$$\sum_{i=1}^{n} X_i Y_i - n\bar{X}\,\bar{Y} + \beta_1 n \bar{X}^2 - \beta_1 \sum_{i=1}^{n} X_i^2 = 0,$$

c'est-à-dire

$$\beta_1 \Big(\sum_{i=1}^{n} X_i^2 - n\bar{X}^2 \Big) = \sum_{i=1}^{n} X_i Y_i - n\bar{X}\,\bar{Y}.$$

On reconnaît maintenant les identités classiques

$$\sum_{i=1}^{n} (X_i - \bar{X})^2 = \sum_{i=1}^{n} X_i^2 - n\bar{X}^2, \qquad \sum_{i=1}^{n} (X_i - \bar{X})(Y_i - \bar{Y}) = \sum_{i=1}^{n} X_i Y_i - n\bar{X}\,\bar{Y}.$$

Ainsi,

$$\beta_1 \sum_{i=1}^{n} (X_i - \bar{X})^2 = \sum_{i=1}^{n} (X_i - \bar{X})(Y_i - \bar{Y}),$$

et, sous l'hypothèse $\sum_{i=1}^{n} (X_i - \bar{X})^2 > 0$, on peut diviser pour obtenir :

$$\hat{\beta}_1 = \frac{\sum\limits_{i=1}^{n} (X_i - \bar{X})(Y_i - \bar{Y})}{\sum\limits_{i=1}^{n} (X_i - \bar{X})^2}.$$

En reportant dans $\beta_0 = \bar{Y} - \beta_1 \bar{X}$, on obtient bien

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

4) Unicité et nature du point critique.

Le système des équations normales admet donc une *unique* solution $(\hat{\beta}_0, \hat{\beta}_1)$ dès que $\sum_{i=1}^{n} (X_i - \bar{X})^2 > 0$. De plus, J est une somme de carrés, donc une fonction convexe en (β_0, β_1). Ainsi, tout point critique est un minimum global. L'unicité du point critique implique alors que ce minimum global est unique.

On a donc montré que J admet un unique minimiseur, donné par les formules annoncées. □

7.4 Régression linéaire multiple

Dans la pratique, une variable réponse dépend rarement d'un seul facteur. La régression linéaire multiple généralise le cas simple en permettant à Y de dépendre simultanément de plusieurs variables explicatives.

7.4.1 Le modèle

On observe

$$\{(X_i^1, \dots, X_i^p, Y_i)\}_{i=1}^n,$$

où X_i^j est la j-ième variable explicative. Le modèle s'écrit

$$Y = \beta_0 + \beta_1 X^1 + \cdots + \beta_p X^p + \varepsilon.$$

Chaque coefficient β_j mesure l'effet de X^j sur Y, *toutes choses égales par ailleurs*. Le terme ε regroupe les facteurs non observés et la variabilité résiduelle. Géométriquement, la droite du cas simple devient un *hyperplan* dans $\mathbb{R}^{p+1}$.

7.4.2 Hypothèses essentielles

Le modèle classique repose sur les hypothèses suivantes :

1. Linéarité du modèle ajusté en les paramètres β_j ;
2. Indépendance des observations ;
3. Espérance conditionnelle nulle : $\mathbb{E}[\varepsilon \mid X] = 0$;
4. Homoscédasticité : $\mathrm{Var}(\varepsilon \mid X) = \sigma^2$;
5. Absence de colinéarité parfaite (inversibilité de $\mathbb{X}^\top \mathbb{X}$).

Si on suppose de surcroît la normalité des erreurs, alors on peut condenser toutes les hypothèses des résidus en une écriture. Pour toute observation $i = 1, \dots, n$:

$$\varepsilon_i \overset{\text{i.i.d}}{\sim} \mathcal{N}(0, \sigma^2),$$

n'est pas nécessaire pour estimer les coefficients, mais elle intervient dans l'inférence.

7.4.3 Écriture matricielle

On introduit la matrice de design

$$\mathbb{X} = \begin{pmatrix} 1 & X_1^1 & \dots & X_1^p \\ \vdots & \vdots & & \vdots \\ 1 & X_n^1 & \dots & X_n^p \end{pmatrix} \in \mathbb{R}^{n \times (p+1)},$$

le vecteur des paramètres

$$\boldsymbol{\beta} = (\beta_0, \dots, \beta_p)^\top \in \mathbb{R}^{p+1},$$

et le vecteur des observations $\boldsymbol{Y}$. Le modèle s'écrit alors

$$\boldsymbol{Y} = \mathbb{X}\boldsymbol{\beta} + \varepsilon \in \mathbb{R}^n.$$

7.4.4 Estimation par la méthode des moindres carrés

Comme dans le cas univarié, les coefficients du modèle sont estimés par la méthode des moindres carrés. L'idée consiste à choisir le vecteur $\boldsymbol{\beta}$ qui minimise la somme des carrés des résidus, c'est-à-dire la norme euclidienne du vecteur des erreurs. On cherche donc à résoudre le problème d'optimisation :

$$\hat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta} \in \mathbb{R}^{p+1}}{\operatorname{argmin}} \left\{ \frac{1}{n} \sum_{i=1}^n \Big(Y_i - (\mathbb{X}\boldsymbol{\beta})_i \Big)^2 = \|\boldsymbol{Y} - \mathbb{X}\boldsymbol{\beta}\|_2^2 \right\}.$$

Ce critère généralise naturellement celui introduit dans le cas de la régression linéaire simple. Il s'agit toujours de minimiser une fonction quadratique strictement convexe, sous réserve que la matrice $\mathbb{X}$ contienne suffisamment d'information.

Théorème 7.4.1. *Si la matrice $\mathbb{X}^\top\mathbb{X}$ est inversible, alors le problème des moindres carrés admet une solution unique, donnée par*

$$\hat{\boldsymbol{\beta}} = (\mathbb{X}^\top\mathbb{X})^{-1}\mathbb{X}^\top\boldsymbol{Y}.$$

Preuve. On considère la fonction objectif des moindres carrés

$$J(\boldsymbol{\beta}) = \|\boldsymbol{Y} - \mathbb{X}\boldsymbol{\beta}\|_2^2 = (\boldsymbol{Y} - \mathbb{X}\boldsymbol{\beta})^\top(\boldsymbol{Y} - \mathbb{X}\boldsymbol{\beta}), \qquad \boldsymbol{\beta} \in \mathbb{R}^{p+1}.$$

En développant, on obtient

$$J(\boldsymbol{\beta}) = \boldsymbol{Y}^\top\boldsymbol{Y} - 2\,\boldsymbol{\beta}^\top\mathbb{X}^\top\boldsymbol{Y} + \boldsymbol{\beta}^\top\mathbb{X}^\top\mathbb{X}\,\boldsymbol{\beta}.$$

Cette fonction est de classe $\mathcal{C}^1$ (c'est un polynôme) et son gradient vaut

$$\nabla J(\boldsymbol{\beta}) = -2\,\mathbb{X}^\top\boldsymbol{Y} + 2\,\mathbb{X}^\top\mathbb{X}\,\boldsymbol{\beta}.$$

Un point minimiseur $\hat{\boldsymbol{\beta}}$ doit vérifier la condition d'optimalité du premier ordre

$$\nabla J(\hat{\boldsymbol{\beta}}) = 0 \quad \Longleftrightarrow \quad \mathbb{X}^\top\mathbb{X}\,\hat{\boldsymbol{\beta}} = \mathbb{X}^\top\boldsymbol{Y}.$$

Ce système est appelé *équation normale*. Si $\mathbb{X}^\top\mathbb{X}$ est inversible, il admet une unique solution donnée par

$$\hat{\boldsymbol{\beta}} = (\mathbb{X}^\top\mathbb{X})^{-1}\mathbb{X}^\top\boldsymbol{Y}.$$

Il reste à justifier qu'il s'agit bien d'un *minimum* (et non d'un maximum ou d'un point selle). La hessienne de J est constante et vaut

$$\nabla^2 J(\boldsymbol{\beta}) = 2\,\mathbb{X}^\top\mathbb{X}.$$

Sous l'hypothèse d'inversibilité, $\mathbb{X}^\top\mathbb{X}$ est définie positive, donc la hessienne est définie positive : J est alors strictement convexe sur $\mathbb{R}^{p+1}$. Par stricte convexité, le point critique est nécessairement l'unique minimiseur global de J. □

Commentaires et interprétation. La matrice $\mathbb{X}^\top\mathbb{X}$ joue un rôle central dans la régression linéaire multiple. Elle est appelée *matrice de Gram* associée aux colonnes de la matrice de design $\mathbb{X}$ et regroupe l'ensemble des produits scalaires entre les vecteurs colonnes de $\mathbb{X}$, c'est-à-dire entre les différentes variables explicatives, y compris la colonne de 1 correspondant à l'intercept. En notant $\mathbb{X} = (\mathbf{x}_0, \mathbf{x}_1, \ldots, \mathbf{x}_p)$, où $\mathbf{x}_0$ désigne la colonne de 1 et $\mathbf{x}_j$ la colonne associée à la variable X^j, on a

$$(\mathbb{X}^\top\mathbb{X})_{jk} = \langle \mathbf{x}_j, \mathbf{x}_k \rangle,$$

où $\langle \cdot, \cdot \rangle$ désigne le produit scalaire usuel dans $\mathbb{R}^n$.

D'un point de vue géométrique, cette matrice mesure les relations de dépendance linéaire entre les covariables : lorsque deux colonnes sont fortement corrélées, leur produit scalaire est élevé, ce qui traduit une redondance d'information. L'hypothèse d'inversibilité de $\mathbb{X}^\top\mathbb{X}$ équivaut à l'indépendance linéaire des colonnes de $\mathbb{X}$, c'est-à-dire au fait qu'aucune variable explicative ne peut être exprimée comme une combinaison linéaire exacte des autres. Cette condition est essentielle pour garantir l'identifiabilité du modèle et l'unicité de l'estimateur des moindres carrés.

Sur le plan statistique, la non-inversibilité de $\mathbb{X}^\top\mathbb{X}$ correspond à une situation de *multicolinéarité parfaite*, dans laquelle il devient impossible de distinguer l'effet propre de certaines variables sur la variable réponse. Enfin, la formule

$$\hat{\boldsymbol{\beta}} = (\mathbb{X}^\top\mathbb{X})^{-1}\mathbb{X}^\top Y$$

met en évidence la nature géométrique de l'estimation : elle peut être interprétée comme la projection orthogonale du vecteur des observations Y sur l'espace vectoriel engendré par les colonnes de $\mathbb{X}$, suivie de la résolution d'un système linéaire. Cette expression constitue le cœur de la régression linéaire multiple et servira de point de départ à de nombreuses extensions du modèle linéaire, notamment les méthodes de régularisation étudiées ultérieurement.

7.5 Qualité du modèle

Ajuster une régression linéaire (simple ou multiple) revient à construire une fonction de prédiction

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i^1 + \cdots + \hat{\beta}_p X_i^p$$

qui approxime au mieux les valeurs observées Y_i. Une question essentielle est alors la suivante : *dans quelle mesure le modèle explique-t-il réellement les données ?* Pour répondre à cette question, on introduit des grandeurs qui mesurent la variabilité de Y et la part de cette variabilité capturée (ou non) par le modèle.

7.5.1 Sommes des carrés et décomposition de la variabilité

On note $\bar{Y} = \frac{1}{n}\sum_{i=1}^n Y_i$ la moyenne empirique de la variable réponse. Comme on l'a déjà souligné, $\bar{Y}$ représente une valeur centrale : si l'on devait prédire Y sans utiliser aucune covariable, la prédiction la plus naturelle (au sens des moindres carrés) serait précisément la constante $\bar{Y}$.

Somme totale des carrés.

Définition 7.5.1 (Somme totale des carrés)**.** On appelle *somme totale des carrés* (en anglais *Total Sum of Squares*) la quantité

$$\mathrm{SST} = \sum_{i=1}^n (Y_i - \bar{Y})^2,$$

où

$$\bar{Y} = \frac{1}{n}\sum_{i=1}^n Y_i$$

désigne la moyenne empirique des observations.

La somme totale des carrés mesure la variabilité globale de la variable réponse autour de sa moyenne. Elle constitue une référence absolue : elle correspond à l'erreur que l'on commettrait si l'on cherchait à prédire toutes les observations par une constante unique, égale à $\bar{Y}$. Une valeur élevée de SST traduit une forte dispersion des données, tandis qu'une valeur faible indique que les observations sont proches de leur moyenne.

Somme des carrés résiduels.

Définition 7.5.2 (Somme des carrés résiduels)**.** Après ajustement du modèle, on définit les résidus par

$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i,$$

où $\hat{Y}_i$ désigne la valeur prédite par le modèle pour l'observation i. La *somme des carrés résiduels* (en anglais *Residual Sum of Squares*) est alors définie par

$$\mathrm{SSR} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n \hat{\varepsilon}_i^2.$$

La quantité SSR mesure l'erreur globale commise par le modèle sur les données observées. Elle évalue la part de la variabilité des données qui n'est pas expliquée par le modèle. Plus SSR est petite, plus l'ajustement est précis. Dans le cadre de la méthode des moindres carrés, l'estimation des paramètres vise précisément à minimiser cette somme.

Somme des carrés expliqués.

Définition 7.5.3 (Somme des carrés expliqués)**.** On appelle *somme des carrés expliqués* (en anglais *Explained Sum of Squares*) la quantité

$$\mathrm{SSE} = \sum_{i=1}^{n} (\hat{Y}_i - \bar{Y})^2,$$

où $\hat{Y}_i$ sont les valeurs prédites par le modèle et $\bar{Y}$ la moyenne empirique des observations.

La somme des carrés expliqués mesure la variabilité des prédictions produites par le modèle autour de la moyenne. Elle représente la part de la variabilité totale des données que le modèle parvient à capturer à l'aide des variables explicatives. Plus SSE est grande, plus le modèle explique une part importante de la structure présente dans les données.

Proposition 7.5.1 (Décomposition de la variabilité)**.** Dans le cadre des moindres carrés (avec intercept), on a la décomposition fondamentale

$$\mathrm{SST} = \mathrm{SSE} + \mathrm{SSR}.$$

Preuve. On écrit

$$Y_i - \bar{Y} = (Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y}).$$

En élevant au carré puis en sommant, on obtient

$$\sum_{i=1}^{n} (Y_i - \bar{Y})^2 = \sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^{n} (\hat{Y}_i - \bar{Y})^2 + 2 \sum_{i=1}^{n} (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y}).$$

Il reste à montrer que le dernier terme est nul. Or, dans la régression aux moindres carrés avec intercept, le vecteur des résidus est orthogonal à l'espace engendré par les colonnes de $\mathbb{X}$, donc en particulier orthogonal au vecteur $(\hat{Y}_1 - \bar{Y}, \ldots, \hat{Y}_n - \bar{Y})$ qui appartient à cet espace. Ainsi

$$\sum_{i=1}^{n} (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y}) = 0,$$

ce qui donne bien $\mathrm{SST} = \mathrm{SSR} + \mathrm{SSE}$. □

Remarque 3. Cette décomposition est l'analogue, en statistiques, d'un théorème de Pythagore : SST mesure l'énergie totale, SSR l'énergie résiduelle (non expliquée), et SSE l'énergie expliquée par le modèle.

7.5.2 Coefficient de détermination R^2

Définition.

Définition 7.5.4 (Coefficient de détermination)**.** On appelle *coefficient de détermination* le nombre

$$R^2 = 1 - \frac{\mathrm{SSR}}{\mathrm{SST}} = \frac{\mathrm{SSE}}{\mathrm{SST}}.$$

Cette formule s'interprète immédiatement : R^2 compare l'erreur du modèle (SSR) à l'erreur du modèle le plus naïf possible (prédire $\bar{Y}$ pour tout le monde), qui correspond à SST. Ainsi :

- si SSR est très petite devant SST, alors le modèle explique bien les données et R^2 est proche de 1 ;
- si SSR est proche de SST, alors le modèle n'apporte presque rien par rapport à la simple moyenne et R^2 est proche de 0.

Propriété 7.5.1. *Dans une régression linéaire estimée par moindres carrés avec intercept, on a toujours*

$$0 \leq R^2 \leq 1.$$

Preuve. Immédiate. Positivité par définition. Inférieure à 1 par Proposition 7.5.1. □

Exemples d'interprétation.

Exemple 7.5.1. Deux exemples un peu extrêmes.

1. Supposons que $R^2 = 0.05$. Cela signifie que le modèle n'explique qu'environ 5% de la variabilité de Y. Autrement dit, même en connaissant les covariables, l'incertitude sur Y reste très grande : le modèle est probablement trop simple, les covariables sont peu pertinentes, ou bien la relation n'est pas linéaire.
2. Si $R^2 = 0.90$, alors le modèle explique environ 90% de la variabilité de Y. Cela indique une forte capacité descriptive : la prédiction $\hat{Y}$ suit étroitement les données, et les résidus sont globalement faibles.

Remarque 4. Un R^2 élevé ne garantit pas à lui seul que le modèle est "bon" au sens scientifique : il peut résulter d'un sur-ajustement (trop de variables), d'une relation accidentelle sur l'échantillon, ou encore d'un phénomène déterministe dans les données. L'analyse des résidus et des hypothèses du modèle reste indispensable.

7.5.3 Le R^2 ajusté

Un point important mérite d'être compris : lorsque l'on ajoute des variables explicatives, la somme des carrés résiduels SSR ne peut qu'*diminuer* (ou rester constante), car on augmente la flexibilité du modèle. Par conséquent, R^2 ne peut qu'augmenter (ou rester constant). Cela rend R^2 peu fiable pour comparer des modèles de tailles différentes, car il favorise mécaniquement les modèles plus complexes.

Pour corriger cet effet, on introduit une version pénalisée : le R^2 ajusté.

Définition 7.5.5 (R^2 ajusté)**.** Dans un modèle de régression linéaire multiple comportant p variables explicatives (et donc $p+1$ paramètres en comptant l'intercept), on définit

$$R^2_{\text{adj}} = 1 - (1 - R^2)\frac{n-1}{n-p-1}.$$

Interprétation. Le facteur $\frac{n-1}{n-p-1}$ est supérieur à 1 et augmente avec p. Ainsi, à R^2 fixé, plus le modèle contient de variables, plus la pénalisation est forte. Le R^2_{adj} ne récompense donc l'ajout d'une variable que si cette variable améliore suffisamment l'ajustement pour compenser l'augmentation de complexité.

Exemple 7.5.2 (Comparaison de deux modèles)**.** Supposons que l'on compare deux modèles sur les mêmes données (même n) :

— Modèle A : $p = 2$ variables explicatives, $R^2 = 0.72$.

— Modèle B : $p = 6$ variables explicatives, $R^2 = 0.74$.

Même si R^2 augmente légèrement, le R^2_{adj} du modèle B peut être inférieur à celui du modèle A si les variables supplémentaires n'apportent qu'un gain marginal. Dans ce cas, le modèle A est à préférer : il est plus simple et presque aussi explicatif.

Remarque 5. Le R^2_{adj} constitue un premier outil de comparaison de modèles, mais il ne remplace pas une analyse plus complète (validation croisée, critères AIC/BIC, diagnostic des résidus, etc.). Il a néanmoins l'avantage d'être simple et directement interprétable dans le cadre des régressions linéaires.

7.5.4 Critères d'information : AIC et BIC

Motivation. Le coefficient de détermination ajusté constitue une première tentative pour pénaliser la complexité d'un modèle. Une approche plus générale repose sur la théorie du maximum de vraisemblance : plutôt que de mesurer uniquement la qualité d'ajustement, on cherche à équilibrer *adéquation aux données* et *complexité du modèle*. Les critères d'information AIC et BIC répondent précisément à cet objectif.

Définitions. Soit un modèle paramétrique estimé par maximum de vraisemblance, de log-vraisemblance maximale $\ell(\hat{\theta})$, comportant k paramètres libres (intercept inclus), et construit à partir d'un échantillon de taille n.

Définition 7.5.6 (AIC)**.** Le critère d'information d'Akaike est défini par

$$\mathrm{AIC} = -2\,\ell(\hat{\theta}) + 2k.$$

Définition 7.5.7 (BIC)**.** Le critère d'information bayésien est défini par

$$\mathrm{BIC} = -2\,\ell(\hat{\theta}) + k\log n.$$

Dans les deux cas :

— le terme $-2\,\ell(\hat{\theta})$ mesure le défaut d'ajustement (plus il est petit, meilleur est le modèle) ;

— le terme de pénalisation ($2k$ ou $k\log n$) augmente avec la complexité.

Comparaison et interprétation. Ces critères servent uniquement à comparer des modèles estimés sur *les mêmes données*. On retient le modèle ayant la plus petite valeur du critère. La différence essentielle réside dans la pénalisation :

$$2k \quad (\mathrm{AIC}) \qquad \text{vs} \qquad k\log n \quad (\mathrm{BIC}).$$

Comme $\log n > 2$ dès que n est modérément grand, le BIC pénalise plus fortement la complexité. Il tend donc à sélectionner des modèles plus parcimonieux que l'AIC.

Exemple 7.5.3. Supposons deux modèles ajustés sur le même échantillon ($n = 200$) :

— Modèle M1 : $k = 3$, $-2\ell(\hat{\theta}) = 420$.

— Modèle M2 : $k = 7$, $-2\ell(\hat{\theta}) = 410$.

On obtient :

$$\mathrm{AIC}_{\mathrm{M1}} = 420 + 2\times 3 = 426, \qquad \mathrm{AIC}_{\mathrm{M2}} = 410 + 2\times 7 = 424,$$

donc l'AIC préfère le modèle B. En revanche,

$$\mathrm{BIC}_{\mathrm{M1}} = 420 + 3\log(200), \qquad \mathrm{BIC}_{\mathrm{M2}} = 410 + 7\log(200).$$

Comme $\log(200) \approx 5.3$, la pénalisation supplémentaire du modèle M2 devient importante et peut conduire le BIC à préférer le modèle M1.

Intérêts et limites.

— L'AIC vise une bonne performance prédictive (minimisation d'un risque d'information).

— Le BIC est cohérent pour la sélection du "vrai" modèle lorsque celui-ci appartient à la famille considérée.

Ces critères permettent de comparer des modèles non emboîtés *(c'est-à-dire que le modèle* 1 *n'est pas simplement un cas particulier du modèle* 2*)*. Ils ne remplacent toutefois ni la validation croisée ni l'analyse des résidus : ils constituent un outil complémentaire de sélection de modèle dans un cadre paramétrique.

Chapitre 8

La régression logistique

La régression logistique constitue une extension naturelle de la régression linéaire lorsque la variable réponse n'est plus quantitative, mais *catégorielle*. Dans ce chapitre, on se concentre sur le cas fondamental où la variable à prédire est binaire, prenant ses valeurs dans $\{0, 1\}$. Ce cadre est omniprésent en pratique : diagnostic médical (malade / non malade), détection de fraude (fraude / non fraude), réussite à un examen (oui / non), etc.

L'objectif est de modéliser la probabilité d'appartenance à l'une des deux classes à partir de variables explicatives quantitatives.

8.1 Contexte et motivation

On considère un échantillon de données

$$\big\{(X_1^1, \dots, X_1^p, Y_1), \dots, (X_n^1, \dots, X_n^p, Y_n)\big\},$$

où $(X_i^1, \dots, X_i^p) \in \mathbb{R}^p$ représentent les variables explicatives et $Y_i \in \{0, 1\}$ la variable réponse.

Puisque Y est binaire, elle suit naturellement une loi de Bernoulli. Plus précisément, conditionnellement aux variables explicatives, on suppose que

$$Y \mid (X^1, \dots, X^p) \sim \mathcal{B}(q),$$

où le paramètre q satisfait

$$q \in [0, 1], \qquad \mathbb{E}[Y \mid X^1, \dots, X^p] = q.$$

Ainsi, le problème fondamental de la régression logistique consiste à estimer la probabilité conditionnelle

$$q(x) = \mathbb{P}(Y = 1 \mid X = x),$$

en fonction des covariables.

8.2 Limites de la régression linéaire

Une première idée naturelle serait de modéliser directement $q(x)$ par une fonction linéaire des covariables ; car après tout, c'est ce que l'on connaît de mieux :

$$q(x) \approx \beta_0 + \sum_{j=1}^{p} \beta_j x^j.$$

Cependant, cette approche est inadéquate : une fonction linéaire à valeurs réelles peut produire des valeurs négatives ou supérieures à 1, ce qui est bien entendu incompatible avec une interprétation probabiliste. Il est donc nécessaire de contraindre la prédiction à appartenir à l'intervalle $[0, 1]$. Pour cela, on introduit une fonction de lien

$$g : \mathbb{R} \longrightarrow [0, 1],$$

qui transforme une combinaison linéaire des covariables en une probabilité valide.

8.3 La fonction sigmoïde

Parmi les fonctions de lien possibles, la plus utilisée est la *fonction logistique*, ou sigmoïde, définie par

$$g(x) = \frac{\mathrm{e}^x}{1 + \mathrm{e}^x}.$$

Cette fonction a le bon goût de posséder plusieurs propriétés essentielles :

- elle est strictement croissante et bijective de $\mathbb{R}$ vers $]0, 1[$;
- elle est symétrique autour du point $x = 0$;
- elle vérifie $g(0) = \frac{1}{2}$, ce qui correspond à une situation d'incertitude maximale ;
- elle possède un point d'inflexion en $x = 0$.

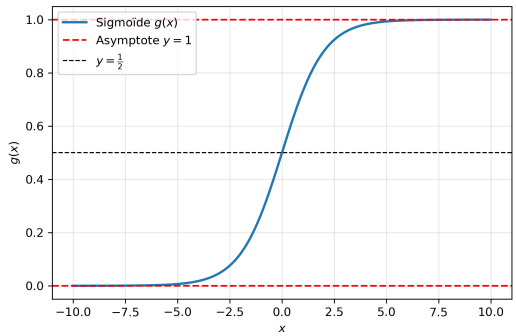

8.4 Le modèle de régression logistique

Définition 8.4.1 (Régression logistique)**.** Le modèle de régression logistique est défini par

$$\mathbb{P}(Y = 1 \mid X = x) = g\left(\beta_0 + \sum_{j=1}^{p} \beta_j x^j\right) = \frac{\exp\left(\beta_0 + \sum\limits_{j=1}^{p} \beta_j x^j\right)}{1 + \exp\left(\beta_0 + \sum\limits_{j=1}^{p} \beta_j x^j\right)}.$$

Ainsi, le modèle suppose que le *log-rapport de chances* (log-odds)

$$\log\left(\frac{q(x)}{1 - q(x)}\right) = \beta_0 + \sum_{j=1}^{p} \beta_j x^j$$

est une fonction linéaire des covariables. Cette écriture explique le nom de *régression logistique*.

Remarque 6. Pour une probabilité $q(x) = \mathbb{P}(Y = 1 \mid X = x)$, on appelle "cote" (ou *odds*) la quantité

$$\frac{q(x)}{1 - q(x)},$$

qui mesure combien l'événement $Y = 1$ est probable relativement à son complément $Y = 0$. Cette transformation présente deux propriétés fondamentales :

(i.) elle transforme l'intervalle $(0, 1)$ des probabilités en tout $\mathbb{R}$;

(ii.) elle rend l'effet des variables explicatives *additif* sur l'échelle des log-cotes.

Ainsi, dans le modèle logistique, chaque coefficient β_j représente la variation additive du log-rapport de chances lorsque x^j augmente d'une unité. Exponentier ce coefficient donne alors un "rapport de cotes" (*odds ratio*), interprétation centrale en pratique.

8.5 Fonction de perte et estimation

Dans la régression logistique, on ne cherche pas à prédire directement une valeur réelle, mais une probabilité

$$q(X) = \mathbb{P}(Y = 1 \mid X).$$

Les coefficients $\boldsymbol{\beta}$ paramètrent cette probabilité via la fonction sigmoïde :

$$q(X) = g(\boldsymbol{\beta}^\top X) = \frac{1}{1 + \exp\big(-\boldsymbol{\beta}^\top X\big)}.$$

Il reste à déterminer comment estimer ces coefficients à partir des données.

8.5.1 Modèle probabiliste et vraisemblance

On suppose que, conditionnellement à X_i, la variable réponse suit une loi de Bernoulli :

$$Y_i \mid X_i \sim \mathcal{B}(q(X_i)).$$

Rappelons que si $Y \sim \mathcal{B}(p)$, alors

$$\mathbb{P}(Y = y) = p^y (1-p)^{1-y}, \qquad y \in \{0, 1\}.$$

Cette écriture compacte permet d'englober simultanément les deux cas $y = 0$ et $y = 1$. Sous l'hypothèse d'indépendance des observations, la vraisemblance [1] du modèle est donc

$$L(\boldsymbol{\beta}) = \prod_{i=1}^{n} q(X_i)^{Y_i} \big(1 - q(X_i)\big)^{1-Y_i}.$$

On travaille en pratique avec la log-vraisemblance :

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \Big(Y_i \log q(X_i) + (1 - Y_i) \log(1 - q(X_i)) \Big).$$

L'estimateur des paramètres est alors défini par

$$\hat{\boldsymbol{\beta}} = \operatorname*{argmax}_{\boldsymbol{\beta}} \ell(\boldsymbol{\beta}).$$

8.5.2 Perte d'entropie croisée

Maximiser la log-vraisemblance revient à minimiser son opposé. Cette quantité correspond exactement à l'estimateur empirique de l'entropie croisée conditionnelle entre la vraie loi et le modèle. On introduit ainsi la *perte d'entropie croisée* :

Définition 8.5.1 (Perte empirique logistique)**.**

$$\mathcal{L}_n(\boldsymbol{\beta}) = -\frac{1}{n} \sum_{i=1}^{n} \Big(Y_i \log q(X_i) + (1 - Y_i) \log(1 - q(X_i)) \Big).$$

Cette fonction de perte est donc exactement la log-vraisemblance négative moyenne.

Interprétation. La perte d'entropie croisée pénalise fortement les prédictions très confiantes mais incorrectes. Concrètement :

- si $Y_i = 1$ et que $q(X_i) \approx 0$, le terme $\log q(X_i)$ devient très négatif ;
- si $Y_i = 0$ et que $q(X_i) \approx 1$, le terme $\log(1 - q(X_i))$ explose également.

Contrairement à la perte quadratique, cette fonction est adaptée à la modélisation probabiliste et découle directement du principe du maximum de vraisemblance.

1. Cette notion est pleinement expliquée en Section 4.4.

8.5.3 Optimisation

La fonction $\mathcal{L}_n$ est convexe en $\boldsymbol{\beta}$ (par convexité de l'exponentielle puis par combinaison convexe d'applications elles-mêmes convexes), ce qui garantit l'unicité du minimum global et la stabilité des méthodes d'optimisation.

Néanmoins, contrairement à la régression linéaire, il n'existe pas de solution fermée explicite pour $\hat{\boldsymbol{\beta}}$. On résout donc le problème

$$\hat{\boldsymbol{\beta}} = \operatorname*{argmin}_{\boldsymbol{\beta}} \mathcal{L}_n(\boldsymbol{\beta})$$

par des méthodes numériques d'optimisation, typiquement par la descente de gradient présentée en Section 6.3.

À chaque itération t, les paramètres sont mis à jour selon

$$\boldsymbol{\beta}^{(t+1)} = \boldsymbol{\beta}^{(t)} - \eta \nabla \mathcal{L}_n\big(\boldsymbol{\beta}^{(t)}\big),$$

où $\eta > 0$ est le pas d'apprentissage.

8.6 Interprétation et décision

Une fois appris, le modèle fournit une probabilité $\hat{q}(x)$. Pour produire une prédiction binaire, on introduit un seuil, généralement 0.5 :

$$\hat{Y} = \begin{cases} 1 & \text{si } \hat{q}(x) \geq \frac{1}{2}, \\ 0 & \text{sinon.} \end{cases}$$

La frontière de décision correspond alors à l'hyperplan

$$\beta_0 + \sum_{j=1}^{p} \beta_j x^j = 0,$$

ce qui montre que la régression logistique induit une *séparation linéaire* de l'espace des covariables.

8.7 Avantages et limites

Avantages. La régression logistique présente de nombreux atouts :

— elle fournit des probabilités interprétables ;

— elle repose sur un cadre probabiliste rigoureux ;

— elle est simple à mettre en œuvre et à interpréter ;

— elle constitue un modèle de référence en classification binaire.

Limites. Sa principale limitation réside dans l'hypothèse de séparation linéaire des classes. Lorsque la frontière réelle entre les classes est fortement non linéaire, le modèle peut présenter un biais important. De plus, comme tout modèle paramétrique, sa performance dépend fortement de la qualité et de la pertinence des variables explicatives.

Ces limitations motivent l'étude de modèles plus flexibles, tels que les méthodes à noyaux, les arbres de décision ou les réseaux de neurones, qui généralisent les principes introduits ici.

Chapitre 9

Arbre de décision

9.1 Contexte et motivations

Les arbres de décision constituent une famille de modèles prédictifs non paramétriques largement utilisés en statistique et en apprentissage automatique. Leur principe repose sur une idée intuitive : *partitionner l'espace des variables explicatives en régions homogènes*, puis associer à chaque région une prédiction simple.

Contrairement aux modèles linéaires, les arbres de décision ne supposent aucune relation fonctionnelle globale entre la variable réponse et les covariables. Ils construisent une approximation locale, par découpage successif de l'espace des données.

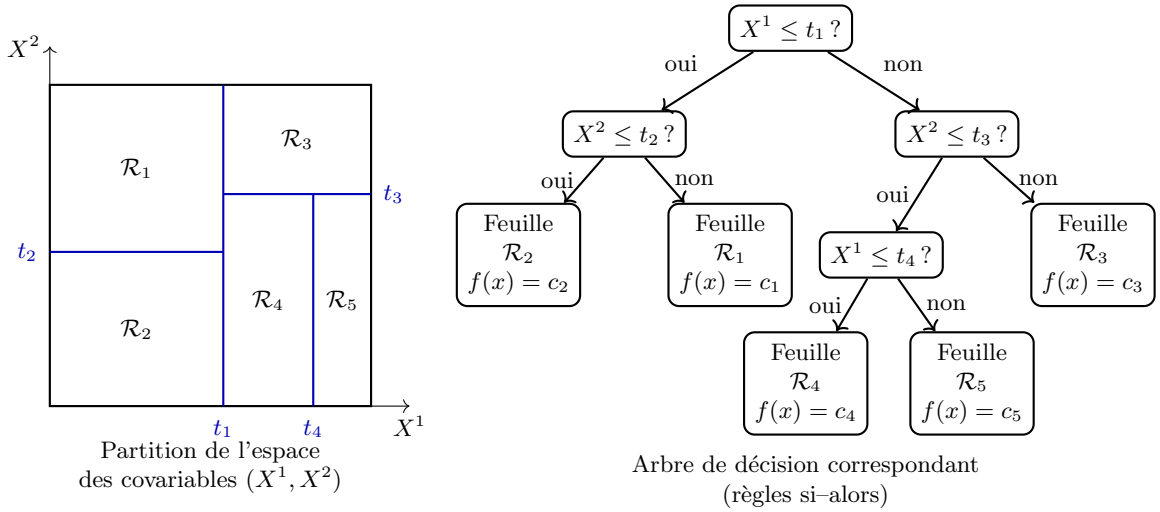

FIGURE 9.1 – Illustration d'un arbre de décision

Arbre de décision en dimension 2. Soit un échantillon de données

$$\big\{(X_1^1, X_1^2, Y_1),\ \ldots,\ (X_n^1, X_n^2, Y_n)\big\},$$

où $(X_i^1, X_i^2) \in \mathbb{R}^2$ désignent les variables explicatives et $Y_i \in \mathbb{R}$ la variable réponse. On cherche à modéliser la relation entre Y et (X^1, X^2) à l'aide d'un arbre de décision de régression.

i. La partie gauche de la Figure 9.1 représente une partition de l'espace des covariables (X^1, X^2) obtenue après apprentissage. Chaque région $\mathcal{R}_m$ correspond à une feuille de l'arbre et regroupe des observations considérées comme homogènes du point de vue de la variable réponse. Dans chaque région, la prédiction repose sur l'agrégation locale des valeurs observées de Y (typiquement par moyenne empirique).

ii. La partie droite de la figure fournit la représentation arborescente équivalente de cette partition. Elle explicite la suite de règles de décision de type *si–alors* permettant d'assigner toute nouvelle observation $x = (x^1, x^2)$ à une région donnée. Cette structure met en évidence le caractère hiérarchique et récursif de l'apprentissage par arbres de décision.

Définition 9.1.1 (Forme fonctionnelle d'un arbre de décision)**.** D'un point de vue formel, le modèle appris par un arbre de décision peut s'écrire sous la forme

$$f(x) = \sum_{m=1}^{M} c_m \, \mathbb{1}_{\{x \in \mathcal{R}_m\}},$$

où $\{\mathcal{R}_1, \ldots, \mathcal{R}_M\}$ est la partition de l'espace des covariables induite par l'arbre, et où c_m désigne la valeur prédite sur la région (ou feuille) $\mathcal{R}_m$.

Les constantes c_m ne sont pas choisies arbitrairement : elles sont définies comme les solutions de problèmes de minimisation locale de la fonction de perte restreinte à chaque région. Plus précisément, pour une région $\mathcal{R}_m$, on définit

$$c_m = \operatorname*{argmin}_{c \in \mathcal{Y}} \sum_{i:\, X_i \in \mathcal{R}_m} \ell(Y_i, c),$$

où ℓ est la fonction de perte associée au problème considéré.

Remarque 7 (Interprétation de c_m selon la perte). Le choix explicite de c_m dépend de la nature du problème et de la fonction de perte utilisée :

— dans le cas de la régression avec perte quadratique $\ell(y, c) = (y - c)^2$, on obtient

$$c_m = \frac{1}{|\mathcal{R}_m|} \sum_{i:\, X_i \in \mathcal{R}_m} Y_i,$$

c'est-à-dire la moyenne empirique des valeurs observées dans la région $\mathcal{R}_m$;

— dans le cas de la classification avec perte 0–1, la valeur optimale c_m est la classe majoritaire dans la région ;

— pour des critères d'impureté tels que l'entropie ou l'indice de Gini, la prédiction associée à la feuille correspond également à la classe maximisant la probabilité empirique conditionnelle.

Ainsi, un arbre de décision peut être vu comme une approximation locale de la fonction de régression $\mathbb{E}[Y \mid X = x]$ (en régression) ou de la règle de Bayes (en classification).

9.2 Cadre statistique

On se place dans le cadre classique de l'apprentissage supervisé. On dispose d'un échantillon de données

$$\mathcal{D}_n = \{(X_1, Y_1), \ldots, (X_n, Y_n)\},$$

où :

— $X_i = (X_i^1, \ldots, X_i^p) \in \mathbb{R}^p$ est le vecteur de covariables,

— $Y_i \in \mathbb{R}$ (régression) ou $Y_i \in \{1, \ldots, K\}$ (classification),

que l'on modélise comme des réalisations i.i.d. de variables aléatoires (X, Y).

L'objectif est de construire une fonction de prédiction

$$f : \mathbb{R}^p \to \mathcal{Y},$$

qui approxime au mieux la relation entre X et Y.

Principe général d'un arbre de décision. Un arbre de décision est une fonction f définie par une suite de règles de type *si–alors*, organisées sous forme arborescente.

Partition de l'espace. L'espace des covariables $\mathbb{R}^p$ est découpé en régions **disjointes**

$$\mathbb{R}^p = \bigsqcup_{m=1}^{M} \mathcal{R}_m,$$

appelées *feuilles* de l'arbre. Chaque région $\mathcal{R}_m$ est définie par une suite de contraintes simples du type

$$X^j \leq t \quad \text{ou} \quad X^j > t,$$

où $j \in \{1, \ldots, p\}$ et $t \in \mathbb{R}$.

Prédiction locale. À chaque région $\mathcal{R}_m$ est associée une prédiction constante :

$$f(x) = \sum_{m=1}^{M} c_m \, \mathbb{1}_{\{x \in \mathcal{R}_m\}},$$

Ainsi, un arbre de décision est une fonction *par morceaux constante*.

9.3 Apprentissage d'un arbre de décision

L'apprentissage d'un arbre de décision consiste à construire une partition de l'espace des covariables

$$\mathcal{X} = \bigcup_{m=1}^{M} \mathcal{R}_m$$

et une fonction par morceaux

$$f(x) = \sum_{m=1}^{M} c_m \, \mathbf{1}_{\{x \in \mathcal{R}_m\}},$$

de sorte à minimiser une perte empirique.

9.3.1 Fonction de perte

Le choix de la perte dépend de la nature de Y.

Régression. Si $Y \in \mathbb{R}$, on minimise la perte quadratique

$$\mathcal{L}_n(f) = \frac{1}{n} \sum_{i=1}^{n} (Y_i - f(X_i))^2.$$

Sur une région $\mathcal{R}$, le minimiseur est

$$c_{\mathcal{R}} = \frac{1}{|\mathcal{R}|} \sum_{i : X_i \in \mathcal{R}} Y_i,$$

c'est-à-dire la moyenne empirique.

Classification. Si $Y \in \{1, \ldots, K\}$, la perte 0–1 n'est pas adaptée à l'optimisation locale. On utilise une mesure d'impureté. Posons donc

$$p_k(\mathcal{R}) = \mathbb{P}(Y = k \mid X \in \mathcal{R}).$$

Deux critères classiques peuvent être optimiser :

$$\textbf{Entropie :} \; H(\mathcal{R}) = -\sum_{k=1}^{K} p_k \log p_k,$$

$$\textbf{Gini :} \; G(\mathcal{R}) = 1 - \sum_{k=1}^{K} p_k^2.$$

Ces quantités sont nulles lorsque la région est pure.

9.3.2 Principe d'apprentissage

L'arbre est construit par *découpage récursif glouton*. À partir d'une région $\mathcal{R}$, on considère des coupures de la forme

$$X^j \leq t,$$

qui scindent $\mathcal{R}$ en deux sous-régions $\mathcal{R}_g$ et $\mathcal{R}_d$. La coupure optimale minimise l'impureté pondérée :

$$\frac{|\mathcal{R}_g|}{|\mathcal{R}|}\mathcal{I}(\mathcal{R}_g) + \frac{|\mathcal{R}_d|}{|\mathcal{R}|}\mathcal{I}(\mathcal{R}_d).$$

En classification avec entropie, cela revient à maximiser le *gain d'information* :

$$H(\mathcal{R}) - \frac{|\mathcal{R}_g|}{|\mathcal{R}|}H(\mathcal{R}_g) - \frac{|\mathcal{R}_d|}{|\mathcal{R}|}H(\mathcal{R}_d).$$

Le processus est appliqué récursivement jusqu'à un critère d'arrêt.

9.3.3 Prédiction dans une feuille

Dans une région terminale $\mathcal{R}_m$:

$$\text{Régression : } c_m = \text{moyenne empirique.}$$

$$\text{Classification : } c_m = \arg\max_k p_k(\mathcal{R}_m).$$

L'arbre fournit ainsi une approximation par morceaux de la relation $x \mapsto \mathbb{E}[Y \mid X = x]$ ou de la classe majoritaire.

9.3.4 Arbres de décision avec variables catégorielles

Jusqu'à présent, nous avons principalement considéré le cas où les variables explicatives sont quantitatives. Les arbres de décision se prêtent toutefois particulièrement bien au traitement de *variables catégorielles*, tant du côté des covariables que de la variable réponse. Cette capacité constitue l'un de leurs principaux atouts par rapport aux modèles paramétriques classiques.

On propose ci-dessous un exemple précis pour deux variables explicatives et une réponse, qui peut se généraliser très facilement à autant de variables explicatives que voulues.

Cadre du problème. On considère un échantillon de la forme

$$\{(X_i^1, X_i^2, Y_i)\}_{i=1}^n,$$

où :

- X^1 et X^2 sont des variables catégorielles finies (par exemple : couleur, type, catégorie socio-professionnelle, etc.) ;
- Y est une variable catégorielle, que l'on supposera ici prendre ses valeurs dans un ensemble fini $\mathcal{Y} = \{1, \ldots, C\}$.

L'objectif est de construire un modèle prédictif permettant d'associer à toute observation (X^1, X^2) une classe prédite pour Y.

Principe des coupures pour variables catégorielles. Contrairement au cas quantitatif, une variable catégorielle ne se prête pas naturellement à une coupure de type seuil. Les règles de décision prennent alors la forme de tests d'appartenance à un sous-ensemble de modalités. Par exemple :

$$X^1 \in \{\mathrm{A}, \mathrm{C}\} \quad \text{vs} \quad X^1 \in \{\mathrm{B}\}.$$

Chaque nœud interne de l'arbre correspond ainsi à une partition de l'ensemble des modalités d'une variable explicative, induisant une séparation de l'échantillon en sous-groupes plus homogènes du point de vue de la variable réponse.

Fonction de perte : l'entropie. Dans le cadre de la classification, l'apprentissage de l'arbre repose sur la minimisation d'une mesure d'impureté des régions. La plus couramment utilisée est l'*entropie de Shannon*.

Définition 9.3.1 (Entropie d'une région)**.** Soit $\mathcal{R}$ une région contenant un sous-échantillon. On note

$$p_k = \mathbb{P}(Y = k \mid X \in \mathcal{R}), \qquad k = 1, \dots, C,$$

les proportions empiriques des classes dans cette région. L'entropie de $\mathcal{R}$ est définie par

$$H(\mathcal{R}) = -\sum_{k=1}^{C} p_k \log p_k.$$

L'entropie mesure l'incertitude associée à la distribution des classes dans une région :

— elle est minimale (nulle) lorsque la région est *pure*, c'est-à-dire composée d'une seule classe ;

— elle est maximale lorsque les classes sont réparties de manière uniforme.

Remarque 8 (Entropie vs entropie croisée)*.* Il est important de ne pas confondre l'entropie de Shannon avec l'entropie croisée.

→ L'entropie $H(\mathcal{R})$ ne dépend que de la distribution empirique des classes dans la région considérée : elle mesure une incertitude intrinsèque, sans faire intervenir de modèle paramétrique.

→ À l'inverse, l'entropie croisée compare deux distributions — la distribution vraie et une distribution prédite par un modèle — et sert de fonction de perte en classification probabiliste (par exemple en régression logistique ou dans les réseaux neuronaux).

Dans un arbre de décision, on utilise donc l'entropie seule comme critère d'impureté, et non l'entropie croisée.

Motivation et justification de la définition de l'entropie. On cherche à définir une quantité permettant de mesurer l'**incertitude** associée à une variable aléatoire discrète Y, à valeurs dans un ensemble fini $\mathcal{Y}$.

1. **Information associée à un événement élémentaire.**
   Considérons un événement élémentaire $\{Y = y\}$, de probabilité $\mathbb{P}(Y = y) = p$. Intuitivement, plus p est grand, moins l'observation de $Y = y$ est surprenante. À l'inverse, plus p est petit, plus l'observation de $Y = y$ est informative. On cherche donc une fonction $I(p)$, appelée *quantité d'information*, vérifiant les propriétés suivantes :
   (i) I est décroissante sur $(0, 1]$,
   (ii) $I(1) = 0$ (aucune information lorsqu'un événement est certain),
   (iii) l'information est *additive* pour des événements indépendants :

   $$\forall\, p, q \in (0, 1], \quad I(pq) = I(p) + I(q).$$

   Sous ces hypothèses naturelles (continuité, additivité, normalisation), on montre que la seule solution est, à constante multiplicative près :

   $$I(p) = -\log p,$$

   où log désigne le logarithme (la base n'ayant d'effet que sur l'unité de mesure).

2. **De l'information ponctuelle à l'entropie.**
   La variable aléatoire Y n'est pas déterministe : avant observation, on ne sait pas quelle valeur $y \in \mathcal{Y}$ sera réalisée. L'information associée à l'observation de Y est donc elle-même une variable aléatoire :

   $$I(Y) = -\log \mathbb{P}(Y).$$

La quantité pertinente pour mesurer l'incertitude moyenne de Y est alors l'**espérance** de cette information :

$$H(Y) := \mathbb{E}[I(Y)]\,.$$

Dans le cas discret et par Théorème du transfert 2.2.1, on obtient ainsi :

$$H(Y) = -\sum_{y\in\mathcal{Y}} \mathbb{P}(Y=y)\,\log\big(\mathbb{P}(Y=y)\big)$$

Cette quantité est appelée *entropie de Shannon* de la variable Y.

3. **Propriétés immédiates.**
   La définition précédente implique les propriétés suivantes :
   (i) $H(Y) \geq 0$,
   (ii) $H(Y) = 0$ si et seulement si Y est une variable aléatoire constante,
   (iii) $H(Y)$ est maximale lorsque la loi de Y est uniforme sur $\mathcal{Y}$.

   Ainsi, l'entropie quantifie le **degré d'incertitude** ou de **dispersion probabiliste** d'une variable aléatoire.

4. **Extension naturelle : entropie conditionnelle.**
   Lorsque l'on dispose d'une information supplémentaire sous la forme d'une variable aléatoire X, l'incertitude sur Y peut être réduite. Conditionnellement à une valeur $\{X = x\}$, l'entropie de Y est définie par :

$$H(Y \mid X=x) = -\sum_{y\in\mathcal{Y}} \mathbb{P}(Y=y \mid X=x)\,\log\big(\,\mathbb{P}(Y=y \mid X=x)\,\big).$$

   Avant observation de X, l'entropie conditionnelle globale est définie comme l'espérance de $H(Y \mid X = x)$ par rapport à la loi de X :

$$H(Y \mid X) = \sum_{x\in\mathcal{X}} \mathbb{P}(X=x)\,H(Y \mid X=x)$$

   Cette quantité mesure l'incertitude moyenne restante sur Y lorsque l'on connaît X.

5. **Lien avec les arbres de décision.**
   Dans un arbre de décision, chaque découpe consiste à remplacer l'entropie initiale $H(Y)$ par une entropie conditionnelle $H(Y \mid X)$. La variable retenue est celle qui maximise la réduction moyenne d'incertitude, appelée *gain d'information* :

$$IG(Y,X) := H(Y) - H(Y \mid X).$$

Ainsi, le critère d'entropie possède une interprétation directe en termes de réduction d'incertitude probabiliste. L'algorithme des arbres de décision choisit, de manière gloutonne, la variable et la partition des modalités maximisant ce gain :

$$\text{Gain} = H(\mathcal{R}) - \frac{|\mathcal{R}_{\text{gauche}}|}{|\mathcal{R}|}H(\mathcal{R}_{\text{gauche}}) - \frac{|\mathcal{R}_{\text{droite}}|}{|\mathcal{R}|}H(\mathcal{R}_{\text{droite}}).$$

Prédiction dans une feuille. Une fois l'arbre construit, chaque feuille $\mathcal{R}_m$ correspond à une région terminale dans laquelle la prédiction est constante. Dans le cas de la classification, la valeur prédite est la classe majoritaire :

$$c_m = \arg\max_{k\in\mathcal{Y}} \mathbb{P}(Y=k \mid X\in\mathcal{R}_m).$$

Ainsi, l'arbre fournit une approximation par morceaux de la probabilité conditionnelle $\mathbb{P}(Y \mid X)$.

Illustration : arbre de décision catégoriel.

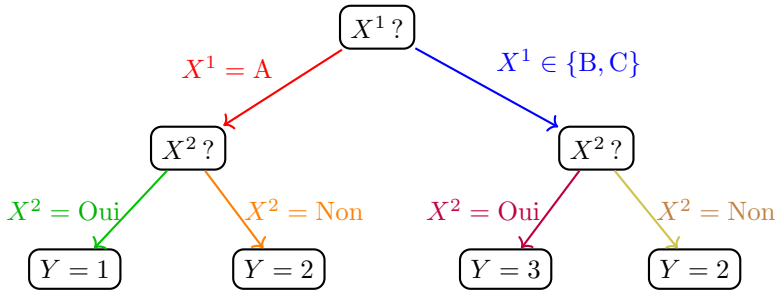

Arbre de décision avec variables catégorielles
(règles conditionnelles sur les modalités)

Cet exemple illustre la capacité des arbres de décision à manipuler directement des variables catégorielles, sans nécessiter de transformation préalable (encodage numérique, variables indicatrices, embeddings ou autres méthodes farfelues). Les règles de décision sont explicites, interprétables et proches d'un raisonnement logique humain. En contrepartie, lorsque le nombre de modalités est élevé, le nombre de partitions possibles croît rapidement, ce qui renforce la nécessité de mécanismes de régularisation pour éviter le sur-apprentissage.

9.3.5 Sur-apprentissage et régularisation

Les arbres de décision présentent une très grande capacité d'adaptation aux données. En particulier, lorsqu'un arbre est autorisé à croître sans contrainte, il peut continuer à scinder l'espace des covariables jusqu'à isoler presque chaque observation dans une feuille distincte. Dans une telle situation, le modèle reproduit quasi parfaitement les données d'apprentissage, mais devient extrêmement sensible aux fluctuations de l'échantillon : on parle alors de *sur-apprentissage* (*overfitting*), et ce phénomène est **à éviter absolument**.

Principe de la régularisation. Afin de contrôler le sur-apprentissage et d'améliorer les performances de généralisation, on introduit des mécanismes de *régularisation*. Leur objectif est de limiter la complexité effective de l'arbre, en empêchant des découpages trop fins de l'espace des covariables. Parmi les stratégies les plus courantes, on peut citer :

— la limitation de la profondeur maximale de l'arbre, qui borne le nombre de décisions successives ;
— l'imposition d'un nombre minimal d'observations par feuille, afin d'éviter des régions trop petites et peu représentatives ;
— la pénalisation explicite de la complexité de l'arbre, par exemple en ajoutant un terme de coût lié au nombre de feuilles ou de nœuds internes.

Ces contraintes reviennent à accepter un biais légèrement plus élevé en échange d'une réduction significative de la variance, ce qui conduit généralement à une diminution de l'erreur de prédiction sur des données non observées.

Positionnement conceptuel. Les arbres de décision occupent ainsi une place particulière parmi les modèles statistiques et d'apprentissage automatique. Ils offrent :

— une grande flexibilité, leur permettant de capturer des interactions complexes entre variables ;
— une interprétabilité directe, grâce à leur structure hiérarchique et à leurs règles de décision explicites ;
— une absence d'hypothèses paramétriques fortes sur la forme de la relation entre X et Y.

En contrepartie, lorsqu'ils sont utilisés isolément, les arbres de décision souffrent d'une variance élevée, en particulier dans des contextes de données bruitées ou de taille modérée (cas typique de la *vraie vie*...). Cette limitation motive le développement de méthodes d'agrégation, telles que les forêts aléatoires ou les méthodes de boosting, qui combinent plusieurs arbres afin de réduire la variance tout en conservant leur capacité de modélisation. Ces approches seront justement étudiées dans le chapitre suivant.

Chapitre 10

Les forêts aléatoires

Avant d'introduire formellement les forêts aléatoires, il est essentiel de comprendre la motivation statistique qui sous-tend leur construction : *réduire la variance d'un modèle instable en combinant plusieurs modèles appris sur des échantillons légèrement différents*. Cette approche est connue sous le nom de *bagging* (*bootstrap aggregating*).

10.1 L'union fait la force

Nous l'avons énoncé, les arbres de décision sont certes interprétables et pratiques à utiliser mais constituent des modèles à *forte variance*.

En pratique, une légère modification du jeu de données peut conduire à un arbre très différent, tant dans sa structure que dans ses prédictions. On vise donc à de "meilleurs" modèles dans un sens où ils "généralisent" mieux.

Le but du bagging consiste à corriger ce défaut en construisant plusieurs arbres, puis en combinant leurs prédictions.

10.1.1 Principe général du bagging

Supposons que l'on dispose d'un modèle d'apprentissage μ, par exemple un arbre de décision. Le bagging construit plusieurs versions de ce modèle à partir de versions légèrement différentes du jeu de données initial, puis à agréger ces modèles pour former un prédicteur plus stable. Le but est double :

($\star$) améliorer la capacité de généralisation du modèle ;

($\star$) réduire la variance sans augmenter significativement le biais.

Cette stratégie repose sur une technique clé de rééchantillonnage : le *bootstrap*.

10.1.2 Le bootstrap

On considère un échantillon d'apprentissage de taille N,

$$\mathcal{D} = \left\{(X_i^1, \ldots, X_i^p, Y_i)\right\}_{i=1}^N,$$

où Y est la variable réponse expliquée par les variables explicatives $X^1, \ldots, X^p$.

Définition 10.1.1 (Échantillon bootstrap)**.** Un échantillon bootstrap est obtenu en tirant, *avec remise*, N observations dans $\mathcal{D}$. Certaines observations peuvent apparaître plusieurs fois, tandis que d'autres peuvent ne pas être sélectionnées.

On répète cette opération B fois, ce qui conduit à B jeux de données bootstrap indépendants conditionnellement aux données initiales. Pour chaque échantillon bootstrap $k \in \{1, \ldots, B\}$, on entraîne un modèle μ_k (par exemple un arbre de décision).

Agrégation des modèles. Une fois les B modèles appris, on définit le modèle agrégé μ^+ par :

$$\mu^+(x) = \begin{cases} \dfrac{1}{B}\sum_{k=1}^{B} \mu_k(x), & \text{en régression,} \\ \text{vote majoritaire des } \big(\mu_k(x)\big)_{k=1}^{B}, & \text{en classification.} \end{cases}$$

Le formalisme associé au vote majoritaire est rédigé dans l'équation (10.1). Cette agrégation constitue le cœur du bagging.

10.1.3 Réduction de la variance par agrégation

L'efficacité du bagging repose sur un principe statistique fondamental : la moyenne de plusieurs estimateurs aléatoires est moins variable qu'un estimateur pris isolément.

Proposition 10.1.1. Soient $Z_1, \dots, Z_B$ des variables aléatoires indépendantes et identiquement distribuées, d'espérance m et de variance σ^2. Alors

$$\mathbb{E}\left[\frac{1}{B}\sum_{k=1}^{B} Z_k\right] = m, \qquad \mathrm{Var}\left(\frac{1}{B}\sum_{k=1}^{B} Z_k\right) = \frac{\sigma^2}{B}.$$

Preuve. L'expression pour l'espérance est induite par son caractère linéaire, chaque Z_k étant de même moyenne m. C'est encore ici le caractère ***sans biais*** de la moyenne empirique qui s'illustre.

Ensuite, par additivité et caractère quadratique de la variance pour des variables **indépendantes**,

$$\mathrm{Var}\left(\frac{1}{B}\sum_{k=1}^{B} Z_k\right) = \frac{1}{B^2}\sum_{k=1}^{B} \mathrm{Var}(Z_k) = \frac{1}{B^2}\cdot B\sigma^2 = \frac{\sigma^2}{B}.$$

□

L'agrégation de prédicteurs indépendants permet ainsi, en théorie, de faire décroître la variance comme $1/B$. C'est précisément ce mécanisme que le bagging cherche à exploiter.

10.1.4 Limites du bagging

En pratique, les modèles $\mu_1, \dots, \mu_B$ ne sont pas indépendants. En effet, les échantillons bootstrap sont construits à partir du même jeu de données initial, ce qui induit une corrélation entre les modèles appris. Pour comprendre l'impact de cette corrélation, regardons la proposition suivante.

Proposition 10.1.2 (Effet de la corrélation sur la variance d'une moyenne)**.** Soient $Z_1, \dots, Z_B$ des variables aléatoires de même espérance m et de même variance σ^2. On suppose que, pour tout $k \neq \ell$,

$$\mathrm{Corr}(Z_k, Z_\ell) = \rho.$$

Alors la variance de leur moyenne est donnée par

$$\mathrm{Var}\left(\frac{1}{B}\sum_{k=1}^{B} Z_k\right) = \rho\,\sigma^2 + \frac{1-\rho}{B}\,\sigma^2.$$

Preuve. La variance étant une forme quadratique,

$$\mathrm{Var}\left(\frac{1}{B}\sum_{k=1}^{B} Z_k\right) = \frac{1}{B^2}\,\mathrm{Var}\left(\sum_{k=1}^{B} Z_k\right).$$

Or, pour une somme de variables aléatoires quelconques,

$$
\begin{aligned}
\operatorname{Var}\left(\sum_{k=1}^{B} Z_k\right) &= \operatorname{Cov}\left(\sum_{k=1}^{B} Z_k, \sum_{\ell=1}^{B} Z_\ell\right) \\
&= \sum_{k=1}^{B}\sum_{\ell=1}^{B} \operatorname{Cov}(Z_k, Z_\ell) && \text{Bilinéarité de l'opérateur de covariance} \\
&= \sum_{k=1}^{B} \operatorname{Cov}(Z_k, Z_k) \;+\; \sum_{\substack{1\le k,\ell\le B\\ k\neq \ell}} \operatorname{Cov}(Z_k, Z_\ell) \\
&= \sum_{k=1}^{B} \operatorname{Var}(Z_k) \;+\; \sum_{1\le k<\ell\le B} \operatorname{Cov}(Z_k, Z_\ell) \\
&\quad + \sum_{1\le \ell<k\le B} \operatorname{Cov}(Z_k, Z_\ell) \\
&= \sum_{k=1}^{B} \operatorname{Var}(Z_k) \;+\; 2\sum_{1\le k<\ell\le B} \operatorname{Cov}(Z_k, Z_\ell), && \text{Symétrie de l'opérateur de covariance}
\end{aligned}
$$

Comme $\operatorname{Var}(Z_k) = \sigma^2$ pour tout k et

$$\operatorname{Cov}(Z_k, Z_\ell) = \operatorname{Corr}(Z_k, Z_\ell)\,\sigma^2 = \rho\,\sigma^2,$$

on obtient

$$\operatorname{Var}\left(\sum_{k=1}^{B} Z_k\right) = B\sigma^2 + 2\binom{B}{2}\rho\,\sigma^2 = B\sigma^2 + B(B-1)\rho\,\sigma^2.$$

En divisant par B^2, il en résulte :

$$\operatorname{Var}\left(\frac{1}{B}\sum_{k=1}^{B} Z_k\right) = \frac{\sigma^2}{B} + \frac{B-1}{B}\,\rho\,\sigma^2 = \rho\,\sigma^2 + \frac{1-\rho}{B}\,\sigma^2.$$

□

Cette expression met en évidence une limite fondamentale du bagging : lorsque la corrélation ρ entre les modèles est non négligeable, le premier terme $\rho\,\sigma^2$ ne disparaît pas, même lorsque B est très grand. La réduction de variance est alors partielle.

Conséquence. Le bagging permet de réduire efficacement la variance des modèles instables, comme les arbres de décision, mais son efficacité est limitée par la corrélation entre les modèles agrégés. La question naturelle devient alors : *comment réduire cette corrélation tout en conservant des modèles performants individuellement ?*

C'est précisément à cette question que répondent les *forêts aléatoires*, en introduisant une source supplémentaire d'aléa lors de la construction des arbres, idée développée dans la section suivante.

10.2 Les forêts aléatoires

La forêt aléatoire (*Random Forest*) est une méthode d'apprentissage statistique qui prolonge naturellement le bagging. Elle repose sur la même idée centrale — agréger de nombreux arbres — mais introduit une source supplémentaire d'aléa lors de la construction de chaque arbre afin de réduire la corrélation entre modèles. Ce mécanisme permet d'améliorer la réduction de variance obtenue par l'agrégation et explique en grande partie les bonnes performances empiriques des forêts aléatoires, en particulier lorsque la dimension p est grande.

10.2.1 Motivations

Pourquoi aller au-delà du bagging ? Le bagging réduit la variance d'un modèle instable (comme un arbre de décision) en moyennant les prédictions de nombreux modèles entraînés sur des échantillons bootstrap. Toutefois, comme discuté précédemment, l'efficacité de cette réduction est limitée par la corrélation entre les modèles agrégés. Si les arbres appris se ressemblent trop, la variance de la moyenne ne décroît pas fortement, à cause du terme de corrélation

$$\mathrm{Var}\left(\frac{1}{B}\sum_{k=1}^{B} Z_k\right) = \rho\,\sigma^2 + \frac{1-\rho}{B}\sigma^2.$$

Réduire ρ devient alors un objectif prioritaire.

Idée clé des forêts aléatoires. Le principe des forêts aléatoires est d'introduire un aléa supplémentaire, *au moment des coupures*, en limitant le choix des variables explicatives disponibles à chaque nœud. Cela force les arbres à explorer des structures différentes, même lorsqu'ils sont entraînés sur des échantillons bootstrap proches, et diminue ainsi la corrélation entre arbres.

Caractéristiques pratiques. Les forêts aléatoires sont appréciées car elles offrent généralement :

- ($\star$) de très bons résultats prédictifs, notamment en grande dimension ;
- ($\star$) une mise en œuvre simple et robuste ;
- ($\star$) peu d'hyperparamètres à régler (nombre d'arbres, profondeur, nombre de variables testées à chaque nœud) ;
- ($\star$) une capacité à gérer naturellement des interactions non linéaires et des variables de types variés.

10.2.2 Apprentissage d'une forêt aléatoire

On se place dans le cadre supervisé. On dispose d'un échantillon

$$\mathcal{D} = \{(X_1, Y_1), \ldots, (X_N, Y_N)\}, \qquad X_i = (X_i^1, \ldots, X_i^p) \in \mathbb{R}^p,$$

où $Y_i \in \mathbb{R}$ (régression) ou $Y_i \in \{1, \ldots, C\}$ (classification, où C désigne le nombre total de différentes modalité que peut prendre la réponse).

Rééchantillonnage bootstrap

Comme pour le bagging, on construit B échantillons bootstrap. Pour $k \in \{1, \ldots, B\}$, on définit

$$\mathcal{D}^{(k)} = \{(X_1^{(k)}, Y_1^{(k)}), \ldots, (X_N^{(k)}, Y_N^{(k)})\},$$

obtenu en tirant *avec remise* N observations dans $\mathcal{D}$. On entraîne ensuite un arbre de décision μ_k sur chaque échantillon $\mathcal{D}^{(k)}$.

Aléa sur le choix des variables au moment des coupures

La différence fondamentale avec le bagging apparaît ici. Dans un arbre de décision standard, lorsqu'on traite un nœud contenant un sous-échantillon, on explore l'ensemble des variables explicatives $\{1, \ldots, p\}$ afin de choisir la meilleure coupure (au sens d'un critère d'impureté ou d'erreur).

Dans une forêt aléatoire, à chaque nœud :

1. on tire uniformément au hasard un sous-ensemble $J \subset \{1, \ldots, p\}$ de cardinal m (avec $m \ll p$ en général) ;
2. on cherche la meilleure coupure *uniquement* parmi les variables indexées par J ;
3. on effectue la séparation correspondante et l'on poursuit récursivement.

Définition 10.2.1 (Paramètre m_{try})**.** Le paramètre noté m_{try} désigne le nombre de variables explicatives tirées aléatoirement à chaque nœud et parmi lesquelles on recherche la meilleure coupure.

Formalisation du choix de coupure (classification). Soit $\mathcal{R}$ une région (nœud) de l'arbre, et J le sous-ensemble de variables tiré au hasard. Pour une coupure candidate (j, t) avec $j \in J$, on obtient deux sous-régions $\mathcal{R}_{\text{gauche}}$ et $\mathcal{R}_{\text{droite}}$. Si l'on utilise l'entropie comme critère d'impureté, la coupure est évaluée via

$$\frac{|\mathcal{R}_{\text{gauche}}|}{|\mathcal{R}|} H(\mathcal{R}_{\text{gauche}}) + \frac{|\mathcal{R}_{\text{droite}}|}{|\mathcal{R}|} H(\mathcal{R}_{\text{droite}}),$$

et l'on choisit la coupure minimisant cette quantité (équivalemment : maximisant le gain d'information).

Formalisation du choix de coupure (régression). En régression, un critère standard consiste à minimiser l'erreur quadratique intra-région. La coupure est choisie de manière à minimiser la somme des variances (ou des sommes de carrés résiduels) des sous-régions obtenues :

$$\sum_{i:\, X_i \in \mathcal{R}_{\text{gauche}}} \left(Y_i - \bar{Y}_{\text{gauche}}\right)^2 + \sum_{i:\, X_i \in \mathcal{R}_{\text{droite}}} \left(Y_i - \bar{Y}_{\text{droite}}\right)^2.$$

Remarque sur la réduction de corrélation. Même si deux arbres μ_k et μ_ℓ sont entraînés sur des échantillons bootstrap proches, ils peuvent diverger fortement en forêt aléatoire, car les variables candidates aux coupures ne sont pas les mêmes d'un nœud à l'autre. Ce mécanisme produit une diversité structurelle supplémentaire, ce qui réduit la corrélation entre arbres et améliore l'efficacité de l'agrégation.

Agrégation des arbres

Une fois les B arbres entraînés, on définit le prédicteur final μ^+ par agrégation.

Cas de la régression. Chaque arbre μ_k fournit une prédiction réelle $\mu_k(x) \in \mathbb{R}$. Le prédicteur final est la moyenne :

$$\mu^+(x) = \frac{1}{B} \sum_{k=1}^{B} \mu_k(x).$$

La perte associée est typiquement la perte quadratique, ce qui rend l'agrégation par moyenne particulièrement naturelle.

Cas de la classification. Chaque arbre μ_k fournit une classe prédite dans $\{1, \ldots, C\}$. Le prédicteur final est défini par vote majoritaire :

$$\mu^+(x) = \operatorname*{argmax}_{c \in \{1,\ldots,C\}} \sum_{k=1}^{B} \mathbb{1}_{\{\mu_k(x)=c\}}. \tag{10.1}$$

Cette règle correspond au choix le plus fréquent parmi les prédictions individuelles. Elle est cohérente avec la minimisation empirique d'une perte de type 0–1.

Comparaison rigoureuse avec le bagging

Remarque 9 (Bagging vs forêts aléatoires). Le bagging et les forêts aléatoires partagent deux points communs : l'utilisation du bootstrap et l'agrégation de nombreux arbres. La différence essentielle est la suivante :

- **Bagging :** à chaque nœud, toutes les variables explicatives sont candidates pour choisir la meilleure coupure ;
- **Forêt aléatoire :** à chaque nœud, on restreint aléatoirement les variables candidates à un sous-ensemble de taille m.

Cette restriction augmente la diversité des arbres et tend à diminuer la corrélation entre modèles, ce qui rend la réduction de variance plus efficace lorsque l'on agrège les prédictions.

10.2.3 Avantages et limites

Avantages. Les forêts aléatoires présentent des avantages importants :

- **Excellente performance prédictive** dans de nombreux contextes, notamment en grande dimension ;
- **Robustesse** : peu sensibles au bruit et aux transformations monotones des variables ;
- **Simplicité d'usage** : peu d'hyperparamètres critiques ;
- **Réduction effective de variance** grâce à l'agrégation et à la réduction de corrélation.

Limites. Elles possèdent néanmoins certaines limites :

- **Perte d'interprétabilité** : une forêt de centaines d'arbres est moins lisible qu'un arbre unique ;
- **Coût de calcul** : apprentissage et prédiction plus lourds qu'un arbre seul, surtout si B est grand ;
- **Données très déséquilibrées** : la performance peut nécessiter des ajustements (pondération des classes, rééchantillonnage) ;
- **Modèle non paramétrique** : les garanties théoriques et l'inférence classique sont moins directes que pour les modèles linéaires.

Ces éléments expliquent pourquoi les forêts aléatoires constituent souvent un excellent compromis entre performance et robustesse, tout en servant de point d'entrée vers d'autres méthodes d'ensemble plus sophistiquées (boosting, gradient boosting, etc.).

Chapitre 11

La méthode des k plus proches voisins

11.1 Principe du plus proche voisin

Nous avons vu dans le chapitre précédent que les arbres de décision, et par extension les forêts aléatoires, construisent des modèles prédictifs en découpant l'espace des covariables au moyen de conditions explicites portant sur les coordonnées des observations. Ces découpages sont donc intrinsèquement axis-aligned et reposent sur une succession de séparations rectangulaires de l'espace.

Nous présentons à présent une approche conceptuellement différente, qui consiste à définir des régions de décision à partir d'une notion de *proximité* entre observations. Cette notion découle directement des outils topologiques introduits au chapitre 5. L'idée centrale est que des observations proches dans l'espace des variables explicatives devraient partager des réponses similaires. Ce principe informel est souvent résumé par l'adage « qui se ressemble s'assemble ».

L'algorithme dit du *plus proche voisin* repose entièrement sur cette intuition. Il s'agit d'une méthode non paramétrique, dans laquelle aucune hypothèse n'est faite sur la forme de la fonction reliant les variables explicatives à la variable réponse.

Considérons un échantillon d'apprentissage constitué de n observations

$$\big\{(X_1^1, \dots, X_1^p, Y_1), \dots, (X_n^1, \dots, X_n^p, Y_n)\big\},$$

où $(X_i^1, \dots, X_i^p) \in \mathbb{R}^p$ désignent les variables explicatives et $Y_i \in \{0, 1\}$ la variable réponse associée. Plus généralement, les variables explicatives vivent dans un espace $\mathcal{X}$ muni d'une distance d, au sens de la définition 5.2.1.

Définition 11.1.1. On appelle *algorithme du plus proche voisin* l'algorithme qui, à une nouvelle observation $x \in \mathcal{X}$, associe la réponse de l'observation du jeu d'apprentissage la plus proche de x pour la distance d. Autrement dit, le prédicteur est défini par

$$\hat{f}(x) = Y_{i^\star} \quad \text{où} \quad i^\star = \operatorname*{argmin}_{i=1,\dots,n} d(x, X_i).$$

Cette règle de décision induit une partition naturelle de l'espace $\mathcal{X}$. Pour chaque observation X_i du jeu d'apprentissage, on définit la région

$$V_i = \big\{x \in \mathcal{X} \ : \ \forall\, j \neq i,\ d(x, X_i) \leq d(x, X_j)\big\}.$$

Ces régions forment une partition de $\mathcal{X}$, appelée *diagramme de Voronoï*, au sens où

$$\mathcal{X} = \bigcup_{i=1}^{n} V_i, \quad V_i \cap V_j = \varnothing \text{ si } i \neq j.$$

Chaque région regroupe l'ensemble des points de l'espace dont l'observation X_i est le plus proche voisin.

La Figure 11.1 dans le cas bidimensionnel permet d'illustrer géométriquement le mécanisme de cette partition. On pourra représenter des observations de différentes classes dans le plan (X^1, X^2) et visualiser les cellules de Voronoï associées, colorées selon l'étiquette Y_i de leur générateur. Ceci met en évidence la complexité potentielle des frontières de décision, qui ne sont ni linéaires ni nécessairement régulières.

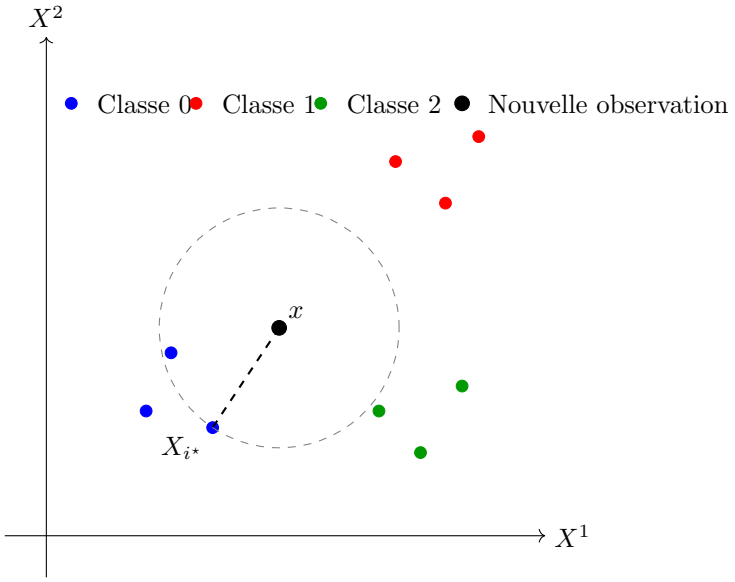

FIGURE 11.1 – Illustration du principe du plus proche voisin. La prédiction associée à x est celle de l'observation $X_{i^\star}$ minimisant la distance $d(x, X_i)$.

11.2 Motivation des k voisins

Bien que conceptuellement simple, la méthode du plus proche voisin présente une faiblesse majeure : elle est extrêmement sensible au bruit. En effet, si une observation du jeu d'apprentissage est mal étiquetée ou aberrante, alors l'ensemble de la cellule de Voronoï associée héritera de cette erreur. Dans un contexte réel, où les données sont presque toujours bruitées, ce phénomène peut conduire à des prédictions très instables.

Afin de rendre la méthode plus robuste, il est naturel de ne plus se fier à l'opinion d'un seul voisin, mais de considérer simultanément plusieurs observations proches de x. Cette idée conduit à l'algorithme des *k plus proches voisins*, souvent abrégé en KNN pour *k nearest neighbors*.

Définition 11.2.1. Soit $K \in \mathbb{N}^*$. L'algorithme des *k plus proches voisins* consiste à associer à une observation $x \in \mathcal{X}$ une réponse construite à partir des réponses des K observations du jeu d'apprentissage les plus proches de x pour la distance d.

On note $\mathcal{N}_K(x)$ l'ensemble des indices des K observations du jeu d'apprentissage les plus proches de x, défini par

$$\mathcal{N}_K(x) = \Big\{ i \in \{1, \dots, n\} \ : \ d(x, X_i) \leq d\big(x, X_{(K)}\big) \Big\},$$

où $d\big(x, X_{(K)}\big)$ désigne la K-ième plus petite valeur parmi les distances

$$\big\{ d(x, X_1), \dots, d(x, X_n) \big\}.$$

- Dans un problème de classification, la règle de décision usuelle est le vote majoritaire. Le

prédicteur s'écrit alors

$$\hat{f}(x) = \operatorname*{argmax}_{c \in \mathcal{Y}} \sum_{i \in \mathcal{N}_K(x)} \mathbb{1}_{\{Y_i = c\}},$$

où $\mathbb{1}_{\{\cdot\}}$ désigne la fonction indicatrice.

- Dans un problème de régression, la prédiction associée à x est définie comme la moyenne des réponses de ses K plus proches voisins :

$$\hat{f}(x) = \frac{1}{K} \sum_{i \in \mathcal{N}_K(x)} Y_i.$$

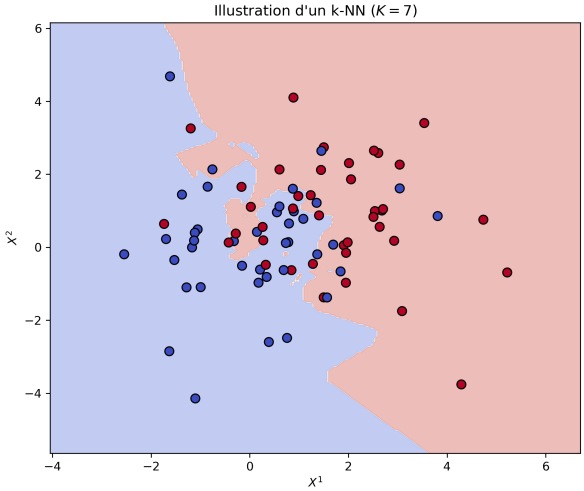

FIGURE 11.2 – Illustration de l'algorithme des k plus proches voisins ($K = 7$) pour une réponse binaire. La frontière de décision est non linéaire et dépend de la densité locale des observations.

Frontières de décision et effet du paramètre K. La frontière de décision induite par l'algorithme des k plus proches voisins est, en général, non linéaire. Elle est constituée de morceaux de segments ou de surfaces correspondant aux régions où la majorité des voisins change. Pour des valeurs faibles de K, ces frontières peuvent être très irrégulières et fortement influencées par des observations isolées.

Lorsque K augmente, l'effet du vote majoritaire conduit à un lissage progressif de la frontière de décision. Les fluctuations locales dues au bruit sont atténuées, au prix d'une perte de finesse dans la représentation des structures complexes des données. Ce phénomène illustre une fois encore le compromis biais–variance : un petit K engendre une faible biais mais une variance élevée, tandis qu'un grand K produit des prédictions plus stables mais potentiellement trop grossières.

Une illustration graphique dans le plan permet de visualiser cet effet. En représentant les régions de décision pour différentes valeurs de K, on observe clairement la simplification progressive des frontières lorsque K augmente, mettant en évidence le rôle central de ce paramètre dans le comportement de l'algorithme.

11.3 La variante des ε-voisins

Dans l'algorithme des k plus proches voisins, le nombre de voisins utilisés pour effectuer une prédiction est fixé *a priori* par le paramètre K, indépendamment de la densité locale des données. Cette approche peut s'avérer sous-optimale lorsque la distribution des observations est très hétérogène : dans certaines régions de l'espace des covariables, les données sont denses, tandis que dans d'autres elles sont rares.

11.3.1 Principe des ε-voisins

Une alternative naturelle consiste à ne plus fixer le nombre de voisins, mais à considérer tous les exemples d'apprentissage suffisamment proches de l'observation à étiqueter, au sens d'une distance absolue. L'idée sous-jacente est que les prédictions fondées sur des observations réellement proches sont intuitivement plus fiables que celles reposant sur des observations éloignées, même si ces dernières figurent parmi les plus proches relativement au reste de l'échantillon.

Cette idée conduit à l'algorithme dit des *ε-voisins*, qui repose sur le réglage d'un paramètre $\varepsilon > 0$ définissant un voisinage autour de l'observation x.

Définition 11.3.1. On appelle *algorithme des ε-voisins*, ou *ε-ball neighbors*, l'algorithme qui associe à une observation $x \in \mathcal{X}$ une réponse construite à partir de l'ensemble des observations du jeu d'apprentissage situées à une distance inférieure ou égale à ε de x, c'est-à-dire

$$\mathcal{N}_\varepsilon(x) = \big\{ i \in \{1, \dots, n\} \ : \ d(x, X_i) \leq \varepsilon \big\}.$$

- Dans un problème de régression, la prédiction associée à x est définie comme la moyenne des réponses des observations appartenant à ce voisinage :

$$\hat{f}(x) = \frac{1}{|\mathcal{N}_\varepsilon(x)|} \sum_{i \in \mathcal{N}_\varepsilon(x)} Y_i,$$

  à condition que $\mathcal{N}_\varepsilon(x)$ soit non vide.
- Dans un problème de classification, la règle usuelle repose sur un vote majoritaire parmi les observations du voisinage :

$$\hat{f}(x) = \operatorname*{argmax}_{c \in \mathcal{Y}} \sum_{i \in \mathcal{N}_\varepsilon(x)} \mathbb{1}_{\{Y_i = c\}}.$$

Remarque 10. Contrairement à la méthode des k plus proches voisins, le nombre d'observations utilisées pour la prédiction dépend ici de la densité locale des données. Dans les régions denses, le voisinage ε contient de nombreuses observations, tandis que dans les régions peu peuplées, il peut en contenir très peu, voire aucune.

11.3.2 Pondération par une fonction de similarité

Une limitation naturelle de la version non pondérée des ε-voisins est que toutes les observations situées dans la boule de rayon ε autour de x contribuent de manière identique à la prédiction, quelle que soit leur distance exacte à x. Or, il est raisonnable de penser que les observations les plus proches de x devraient avoir une influence plus importante que celles situées à la frontière du voisinage.

Pour remédier à cela, on introduit des poids dépendant de la distance, interprétés comme des mesures de similarité. Typiquement, on définit des poids

$$w_i(x) = \phi\big(d(x, X_i)\big),$$

où ϕ est une fonction décroissante. Deux choix classiques sont

$$w_i(x) = \frac{1}{d(x, X_i)} \qquad \text{ou} \qquad w_i(x) = \exp\left(-\frac{1}{2} d(x, X_i)^2\right).$$

Ces pondérations présentent un intérêt pratique majeur : elles permettent d'utiliser un voisinage relativement large tout en accordant une importance prédominante aux observations réellement proches de x. Elles offrent ainsi un compromis entre robustesse et précision locale.

Dans un problème de régression, le prédicteur pondéré s'écrit alors

$$\hat{f}(x) = \frac{1}{\sum\limits_{i \in \mathcal{N}_\varepsilon(x)} w_i(x)} \cdot \sum_{i \in \mathcal{N}_\varepsilon(x)} w_i(x)\, Y_i.$$

Dans un problème de classification, la règle de décision devient

$$\hat{f}(x) = \operatorname*{argmax}_{c \in \mathcal{Y}} \sum_{i \in \mathcal{N}_\varepsilon(x)} w_i(x)\, \mathbb{1}_{\{Y_i = c\}}.$$

11.3.3 Discussion et portée du modèle

Les variantes k-NN et ε-voisins mettent en évidence un point fondamental : l'ingrédient essentiel de ces algorithmes est la distance utilisée pour mesurer la proximité entre les observations. Le choix de la métrique, et plus généralement de la représentation des données dans l'espace $\mathcal{X}$, conditionne entièrement la qualité des prédictions.

Il convient toutefois d'être prudent. Ces méthodes sont particulièrement sensibles à la présence de covariables non pertinentes, qui interviennent néanmoins dans le calcul de la distance et peuvent en biaiser l'interprétation. De plus, en grande dimension, elles souffrent du phénomène connu sous le nom de *malédiction de la dimension* : lorsque la dimension de l'espace augmente, toutes les observations tendent à être éloignées les unes des autres, et la notion même de voisinage perd son sens. Dans ce contexte, l'intuition selon laquelle on peut prédire à partir des exemples proches cesse d'être valable, ce qui limite fortement l'efficacité de ces approches.

11.4 Choix d'un nombre élevé de voisins : avantages et limites

On se place dans le cadre où le nombre d'observations n est très grand, ce qui autorise le choix d'un paramètre K élevé sans contrainte liée à la taille de l'échantillon. Dans ce régime, l'algorithme des k plus proches voisins présente des propriétés asymptotiques intéressantes, mais également des limitations structurelles qui doivent être clairement identifiées.

Avantages. Un des premiers avantages que l'on peut soulever dans ce cadre est celui de la rédaction de la variance par moyennage. En effet, le prédicteur k-NN repose sur une moyenne empirique locale, ce qui s'écrit en régression comme tel :

$$\hat{f}(x) = \frac{1}{K} \sum_{i \in \mathcal{N}_K(x)} Y_i.$$

Sous des hypothèses de régularité usuelles, on peut approximer la variance conditionnelle de cet estimateur par

$$\operatorname{Var}\big(\hat{f}(x) \mid X_1, \ldots, X_n\big) \approx \frac{1}{K} \operatorname{Var}(Y \mid X \approx x),$$

ce qui montre que l'augmentation de K entraîne une diminution de la variance de la prédiction. En classification, le vote majoritaire repose sur une estimation empirique de la probabilité conditionnelle

$$\mathbb{P}(Y = c \mid X = x) \approx \frac{1}{K} \sum_{i \in \mathcal{N}_K(x)} \mathbb{1}_{\{Y_i = c\}},$$

dont la stabilité s'améliore lorsque K augmente. Cette réduction de la variance rend les prédictions plus robustes au bruit et aux erreurs d'étiquetage.

Un second avantage à souligner est celui du lissage des frontières dans un cadre asymptotique. Lorsque K augmente, les frontières de décision induites par l'algorithme deviennent plus régulières. Les fluctuations locales dues à des observations isolées sont atténuées, et la frontière reflète davantage la structure moyenne des données. Dans un cadre asymptotique, il est possible de montrer que si

$$K \longrightarrow \infty \quad \text{et} \quad \frac{K}{n} \longrightarrow 0,$$

alors le prédicteur k-NN converge vers le prédicteur optimal, c'est-à-dire vers le classifieur de Bayes en classification ou vers l'espérance conditionnelle $\mathbb{E}[Y \mid X = x]$ en régression.

Limites. Une première limitation connu lorsque l'on cherche à réduire la variance du prédicteur est celle de la hausse du biais qui lui est induite. L'augmentation de K élargit mécaniquement le voisinage utilisé pour estimer la réponse en x. L'estimateur

$$\hat{f}(x) = \frac{1}{K} \sum_{i \in \mathcal{N}_K(x)} Y_i$$

n'approxime alors plus la quantité locale $\mathbb{E}[Y \mid X = x]$, mais une moyenne sur une région étendue de l'espace des covariables. Cette approximation introduit un biais croissant, car les observations éloignées de x peuvent avoir un comportement différent. Le caractère local de l'estimation, qui constitue la force principale de k-NN, est alors progressivement perdu.

Une autre limitation possible est celle d'un lissage excessif des frontières de décision. Lorsque K est trop grand, les frontières de décision deviennent artificiellement simples et peuvent ignorer des structures fines mais réelles des données. Dans le cas extrême où $K = n$, la prédiction devient indépendante de x :

$$\hat{f}(x) = \begin{cases} \mathbb{E}[Y] & \text{(régression)}, \\ \text{classe majoritaire globale} & \text{(classification)}. \end{cases}$$

L'algorithme cesse alors de tirer parti de la proximité entre observations et perd tout intérêt prédictif.

Enfin, un dernière limite à exposer est celle de l'interaction avec la dimension de l'espace. Même lorsque n est très grand, un nombre élevé de voisins ne permet pas de contourner le phénomène de la malédiction de la dimension (*curse of dimensionality*). Lorsque la dimension de l'espace des covariables augmente, les distances deviennent peu discriminantes et les voisins sélectionnés sont souvent éloignés de l'observation à étiqueter. L'augmentation de K peut alors aggraver ce phénomène en intégrant dans la prédiction des observations peu informatives, ce qui limite fortement l'efficacité de l'algorithme en grande dimension.

Ainsi, le paramètre K joue le rôle d'un véritable paramètre de régularisation. Son choix correspond à un compromis entre réduction de la variance et augmentation du biais, et doit être adapté à la structure géométrique et statistique des données plutôt qu'à la seule taille de l'échantillon.

11.5 Fonction de perte et construction des frontières de décision

Contrairement aux modèles paramétriques classiques étudiés précédemment, tels que la régression linéaire ou la régression logistique, les algorithmes de type k plus proches voisins ne reposent pas sur la minimisation explicite d'une fonction de perte globale lors d'une phase d'apprentissage. Il n'existe donc pas, à proprement parler, de *fonction de perte optimisée* au sens usuel du terme.

L'algorithme des k plus proches voisins relève d'une approche dite *paresseuse* (*lazy learning*) : l'apprentissage se limite à la mémorisation du jeu de données, et toute la complexité du modèle est reportée sur la phase de prédiction. Pour chaque nouvelle observation x, la décision est prise localement, en se fondant sur les observations du jeu d'apprentissage situées dans un voisinage de x.

D'un point de vue théorique, cette procédure peut être interprétée comme une approximation locale des prédicteurs optimaux issus de la théorie du risque. En classification, le classifieur de Bayes minimise la perte 0–1 et s'écrit

$$f^*(x) = \operatorname*{argmax}_{c \in \mathcal{Y}} \mathbb{P}(Y = c \mid X = x).$$

L'algorithme k-NN remplace alors la probabilité conditionnelle inconnue par une estimation empirique locale, obtenue à partir des étiquettes des voisins de x. Le vote majoritaire correspond ainsi à une minimisation locale du risque de classification.

De manière analogue, en régression avec perte quadratique, le prédicteur optimal est donné par l'espérance conditionnelle $f^*(x) = \mathbb{E}[Y \mid X = x]$, que k-NN approxime par la moyenne empirique des réponses des voisins de x. Là encore, aucune optimisation globale n'est effectuée : l'estimation est purement locale.

Les frontières de décision associées à k-NN ne sont donc pas construites explicitement. Elles émergent implicitement de la règle de décision locale et de la géométrie de l'espace des covariables.

Dans le cas $K = 1$, la frontière correspond à un diagramme de Voronoï exact, tandis que pour $K > 1$, le vote majoritaire induit un lissage progressif des frontières, dont la forme dépend fortement de la densité des données et du choix de la distance. Ce mécanisme explique à la fois la grande flexibilité de k-NN et sa sensibilité au bruit et à la dimension de l'espace.

11.6 Un algorithme supervisé et non paramétrique

L'algorithme des k plus proches voisins s'inscrit pleinement dans le cadre de l'apprentissage supervisé. En effet, le jeu de données d'apprentissage est constitué de couples (X_i, Y_i), où les variables explicatives X_i sont observées conjointement avec une variable réponse Y_i. La connaissance des étiquettes Y_i est indispensable au fonctionnement de l'algorithme : ce sont elles qui sont utilisées pour prédire la réponse associée à une nouvelle observation x.

Plus précisément, lors de la phase de prédiction, l'algorithme identifie les observations X_i les plus proches de x dans l'espace des covariables, puis exploite les valeurs correspondantes de Y_i pour construire la prédiction. En classification, la prédiction repose sur un vote majoritaire des étiquettes des voisins, tandis qu'en régression elle correspond à une moyenne locale des réponses. Sans l'accès aux valeurs Y_i, aucune règle de décision ne pourrait être définie, ce qui distingue fondamentalement k-NN des méthodes non supervisées telles que le clustering.

En revanche, l'algorithme des k plus proches voisins est dit *non paramétrique*. Contrairement aux modèles paramétriques classiques, tels que la régression linéaire ou la régression logistique, il ne suppose pas l'existence d'une fonction f appartenant à une famille paramétrée de dimension finie reliant X à Y. Il n'y a pas de vecteur de paramètres à estimer, ni de forme fonctionnelle globale imposée au modèle. La complexité du prédicteur n'est pas contrôlée par un nombre fini de paramètres, mais dépend directement de la taille et de la structure du jeu de données.

Cette absence de paramétrisation se traduit par un comportement très flexible : le prédicteur k-NN s'adapte localement à la géométrie des données et peut, en principe, approximer des relations très complexes entre les variables. En contrepartie, cette flexibilité s'accompagne d'une dépendance forte à la distance choisie et à la densité des observations, ainsi que d'un coût computationnel reporté sur la phase de prédiction plutôt que sur l'apprentissage.

Ainsi, k-NN illustre une distinction fondamentale en apprentissage statistique : un algorithme peut être supervisé sans être paramétrique. Il utilise explicitement les étiquettes observées pour apprendre à prédire, tout en s'affranchissant de toute hypothèse de forme globale sur la relation entre les variables explicatives et la variable réponse.