Fiche de synthèse — Régression linéaire et régression logistique

1 Régression linéaire

1.1 Contexte

On observe :

- $X^{(1)}, \dots, X^{(J)}$: variables explicatives numériques ;
- Y : variable cible numérique.

Le but est de modéliser Y en fonction des variables explicatives.

1.2 Modèle linéaire simple et multiple

Régression linéaire simple. Lorsqu'on n'utilise qu'une seule variable explicative $X^{(1)}$, le modèle s'écrit

$$Y_i = \underbrace{\beta_0 + \beta_1 X_i^{(1)}}_{\widehat{Y}_i} + \varepsilon_i, \qquad i = 1, \dots, n.$$

Régression linéaire multiple. Lorsqu'on utilise plusieurs variables explicatives $X^{(1)}, \dots, X^{(J)}$, le modèle s'écrit

$$Y_i = \underbrace{\beta_0 + \beta_1 X_i^{(1)} + \cdots + \beta_J X_i^{(J)}}_{\widehat{Y}_i} + \varepsilon_i, \qquad i = 1, \dots, n.$$

Dans tous les cas, $\widehat{Y}_i$ est appelé la valeur ajustée.

1.3 Hypothèses sur l'erreur

On suppose généralement que les erreurs vérifient :

$$\varepsilon_1, \dots, \varepsilon_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2).$$

Cela signifie :

(H1) indépendance des observations ;

(H2) toutes de même loi ;

(H3) moyenne nulle ;

(H4) variance constante σ^2 ;

(H5) en particulier, de loi gaussienne.

1.4 Critère à minimiser : les moindres carrés

Nom du critère. Les coefficients sont estimés par la méthode des *moindres carrés* qui vise dans tous les cas à minimiser la variance des résidus de façon équilibré autour du modèle affine ajusté.

Régression simple. On cherche

$$(\hat{\beta}_0, \hat{\beta}_1) = \underset{(\beta_0, \beta_1) \in \mathbb{R}^2}{\operatorname{argmin}} \left\{ \frac{1}{n} \sum_{i=1}^{n} \left(Y_i - (\beta_0 + \beta_1 X_i^{(1)}) \right)^2 \right\}.$$

Régression multiple. On cherche

$$(\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_J) = \underset{(\beta_0,\ldots,\beta_J)\in\mathbb{R}^{J+1}}{\operatorname{argmin}} \left\{ \frac{1}{n} \sum_{i=1}^{n} \left(Y_i - \beta_0 - \sum_{j=1}^{J} \beta_j X_i^{(j)} \right)^2 \right\} = \underset{(\beta_0,\ldots,\beta_J)\in\mathbb{R}^{J+1}}{\operatorname{argmin}} \left\{ \|Y - \mathbb{X}\boldsymbol{\beta}\|_2^2 \right\}.$$

1.5 Écriture matricielle

On note la matrice de design

$$\mathbb{X} = [\,\mathbf{1}\ X^{(1)}\ \cdots\ X^{(J)}\,] = \begin{bmatrix} 1 & X_1^{(1)} & \cdots & X_1^{(J)} \\ 1 & X_2^{(1)} & \cdots & X_2^{(J)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_n^{(1)} & \cdots & X_n^{(J)} \end{bmatrix} \in \mathbb{R}^{n\times(J+1)},$$

le vecteur des réponses

$$Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} \in \mathbb{R}^n,$$

et le vecteur des paramètres

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_J \end{bmatrix} \in \mathbb{R}^{J+1}.$$

Le modèle s'écrit alors

$$Y = \mathbb{X}\boldsymbol{\beta} + \varepsilon.$$

L'estimateur des moindres carrés est

$$\hat{\boldsymbol{\beta}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top Y,$$

lorsque $\mathbb{X}^\top\mathbb{X}$ est inversible.

1.6 Les tests statistiques

Avant de s'attarder sur l'interprétation détaillée d'un `summary`, il est utile de rappeler brièvement le principe des tests statistiques.

Dans un test statistique, on commence par formuler une **hypothèse nulle** H_0, qui correspond généralement à l'absence d'effet ou de relation (par exemple : un coefficient est égal à 0 ou bien vérifier si une variable suit la loi normale). L'objectif du test est de déterminer si les données observées apportent suffisamment d'évidence pour **rejeter cette hypothèse**.

Pour cela, on calcule une **statistique de test**, dont on déduit une **p-value**. La p-value mesure la probabilité d'observer un résultat au moins aussi extrême que celui obtenu si l'hypothèse H_0 était vraie. On peut l'interpréter comme étant le **risque de se tromper en rejetant l'hypothèse nulle alors qu'elle est vraie**.

En pratique, on compare la p-value à un seuil appelé **niveau de risque** ou **niveau de significativité**, généralement

$$\alpha = 0.05.$$

- Si la p-value est inférieure à α, on rejette H_0 : les données fournissent suffisamment d'évidence contre l'hypothèse nulle.
- Si la p-value est supérieure à α, on ne rejette pas H_0.

Autrement dit, la p-value quantifie le risque que l'on prend en rejetant H_0 alors qu'elle serait en réalité vraie.

1.7 Lire un `summary()` de régression linéaire

Dans la sortie d'un `summary(lm(...))`, on lit notamment :

- **Estimate** : estimation du coefficient ;
- **Std. Error** : écart-type estimé du coefficient ;
- **t value** : statistique de test de Student ;
- **Pr(>** $|t|$**)** : p-value du test $H_0 : \beta_j = 0$.

Significativité d'un coefficient. Un coefficient est dit *significatif* au seuil 5% si sa p-value est inférieure à 0.05. Cela revient à rejeter l'hypothèse

$$H_0 : \beta_j = 0.$$

1.8 Interpréter un intervalle de confiance à 95%

Un intervalle de confiance à 95% pour β_j est de la forme

$$\mathrm{IC}_{95\%}(\hat{\beta}_j) = [a\,,\,b].$$

- Si $0 \notin [a, b]$, alors β_j est significativement différent de 0 au seuil 5%.
- Si $0 \in [a, b]$, alors on ne peut pas conclure que β_j est différent de 0 au seuil 5%.

L'argument par intervalle de confiance est équivalent à l'argument par p-value.

1.9 Interpréter R^2 et R^2_{adj}

On note $\hat{Y}_i$ la valeur prédite pour l'observation i. Le coefficient de détermination est

$$R^2 = \frac{\sum_{i=1}^{n}(\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2} = 1 - \frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2}.$$

- R^2 mesure la proportion de la variance de Y expliquée par le modèle.
- Plus R^2 est proche de 1, plus le modèle explique bien les données.

Le coefficient ajusté R^2_{adj} pénalise l'ajout de variables inutiles. Il est souvent plus pertinent que R^2 pour comparer deux modèles de complexité différente.

1.10 Test global de Fisher

Le test global de Fisher répond à la question :

Le modèle est-il globalement significatif ?

En régression multiple, on teste

$$H_0 : \beta_1 = \cdots = \beta_J = 0$$

contre

$$H_1 : \text{au moins un coefficient est non nul.}$$

- Si la p-value du test de Fisher est petite (par exemple < 0.05), on rejette H_0.
- On conclut alors que le modèle est globalement significatif.

1.11 Moyenne nulle des résidus : test de Student

On peut tester

$$H_0 : \mathbb{E}[\varepsilon] = 0$$

à l'aide d'un test de Student sur les résidus.

- Si la p-value est grande, on ne rejette pas H_0.
- Si la p-value est petite, on rejette H_0.

En pratique, dans un modèle linéaire avec intercept, la moyenne empirique des résidus est très proche de 0, voire exactement nulle par construction.

1.12 Comment comparer deux modèles linéaires ?

Pour dire qu'un modèle est plus pertinent qu'un autre, on peut regarder :

($\star$) a-t-on ajouté des variables significatives ?

($\star$) a-t-on retiré des variables non significatives ?

($\star$) R^2 est-il sensiblement meilleur ?

($\star$) R^2_{adj} est-il meilleur ?

($\star$) le modèle reste-t-il interprétable ?

($\star$) les hypothèses sur les résidus restent-elles raisonnables ? (si on peut, on regarde la centralité, l'homoscédasticité, la normalité, ...)

Idée importante

Un modèle plus complexe n'est pas automatiquement meilleur. Ajouter une variable non significative peut compliquer l'interprétation sans améliorer réellement le pouvoir explicatif.

2 Régression logistique

2.1 Contexte

On considère maintenant une variable réponse binaire :

$$Y \in \{0, 1\}.$$

Le but n'est plus de prédire directement une valeur numérique, mais d'estimer la probabilité

$$p(x) = \mathbb{P}(Y = 1 \mid X = x)$$

à partir des variables explicatives $X^{(1)}, \ldots, X^{(J)}$.

2.2 Modèle logistique

La régression logistique suppose

$$p(x; \boldsymbol{\beta}) = \frac{\exp\left(\beta_0 + \sum_{j=1}^{J} \beta_j x^{(j)}\right)}{1 + \exp\left(\beta_0 + \sum_{j=1}^{J} \beta_j x^{(j)}\right)}.$$

Autrement dit,

$$p(x; \boldsymbol{\beta}) = \mathcal{S}\left(\beta_0 + \sum_{j=1}^{J} \beta_j x^{(j)}\right),$$

où la sigmoïde est définie par

$$\mathcal{S}(u) = \frac{1}{1 + e^{-u}}.$$

2.3 Interprétation du modèle

Le terme

$$\eta_{\boldsymbol{\beta}}(x) = \beta_0 + \sum_{j=1}^{J} \beta_j x^{(j)}$$

est appelé *prédicteur linéaire*. La sigmoïde transforme cette quantité en une probabilité comprise entre 0 et 1.

2.4 Estimation des paramètres

En régression logistique, on estime les paramètres par *maximum de vraisemblance*.

Idée. On maximise la vraisemblance du modèle ; de manière équivalente, on minimise la *négative log-vraisemblance*, aussi appelée *cross-entropie*.

Forme mathématique. Pour des observations (x_i, y_i), la fonction à optimiser pour apprendre les paramètres (aussi appelée "fonction perte") est donnée par

$$\mathcal{L}(\boldsymbol{\beta}) = -\frac{1}{n} \sum_{i=1}^{n} \Big[y_i \log\big(p(x_i, \boldsymbol{\beta})\big) + (1 - y_i) \log\big(1 - p(x_i, \boldsymbol{\beta})\big) \Big],$$

où

$$p(x_i, \boldsymbol{\beta}) = \frac{\exp\left(\beta_0 + \sum_{j=1}^{J} \beta_j x_i^{(j)}\right)}{1 + \exp\left(\beta_0 + \sum_{j=1}^{J} \beta_j x_i^{(j)}\right)}.$$

2.5 Lire un `summary()` de régression logistique

Dans un `summary(glm(..., family = binomial))` qui encode sur `R` le modèle logisitique, on lit souvent :

- **Estimate** : estimation du coefficient ;
- **Std. Error** : écart-type estimé ;
- **z value** : statistique de test ;
- **Pr(**$> |z|$**)** : p-value du test $H_0 : \beta_j = 0$.

Significativité. Comme en régression linéaire :

- si la p-value est < 0.05, le coefficient est significatif ;
- si l'IC95% ne contient pas 0, le coefficient est significatif ;
- les deux raisonnements sont équivalents.

2.6 Interpréter les coefficients

- Si $\hat{\beta}_j > 0$, une augmentation de $X^{(j)}$ augmente la probabilité que $Y = 1$, toutes choses égales par ailleurs.
- Si $\hat{\beta}_j < 0$, une augmentation de $X^{(j)}$ diminue la probabilité que $Y = 1$.

2.7 Calculer une probabilité pour une nouvelle observation

Pour une nouvelle observation

$$x = (x^{(1)}, \ldots, x^{(J)}),$$

on calcule d'abord le prédicteur linéaire

$$\hat{\eta}_{\boldsymbol{\beta}}(x) = \hat{\beta}_0 + \sum_{j=1}^{J} \hat{\beta}_j x^{(j)}.$$

Puis on en déduit la probabilité estimée

$$\hat{p}(x;\boldsymbol{\beta}) = \frac{\exp(\hat{\eta}_{\boldsymbol{\beta}}(x))}{1+\exp(\hat{\eta}_{\boldsymbol{\beta}}(x))} = \frac{1}{1+\exp(-\hat{\eta}_{\boldsymbol{\beta}}(x))}.$$

Méthode à retenir

Pour calculer une probabilité prédite en régression logistique :

$$\text{combinaison linéaire} \xrightarrow{\text{sigmoïde}} \text{probabilité.}$$

En bref, l'essentiel :

Essentiel

- **Régression linéaire :** Y numérique, estimation par moindres carrés.
- **Régression logistique :** Y binaire, estimation par maximum de vraisemblance et minimisation de la parte *cross-entropy*.
- **IC95% et p-values :** deux façons équivalentes de juger la significativité d'un coefficient.
- R^2 **et** R^2_{adj} **:** qualité globale du modèle linéaire.
- **Fisher :** significativité globale du modèle.
- **Prédiction logistique :** combinaison linéaire puis sigmoïde.