TD2 – Régression linéaire multiple

Paul MINCHELLA, Stéphane CHRÉTIEN

Second Semestre 2025-2026

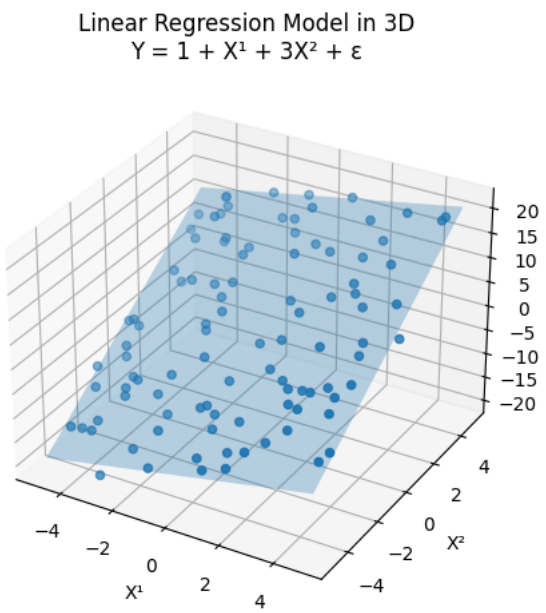

Licence MIASHS

2 Régression linéaire multiple

Exercice 1

Contexte. On s'intéresse à la performance académique d'étudiants lors d'un contrôle écrit. La variable réponse est :

$$Y \ : \ \text{note obtenue au contrôle (sur 20).}$$

On dispose de deux variables explicatives :

- $X^{(1)}$: **temps de travail personnel (en minute)** consacré à la matière (en heures sur le semestre précédant l'examen final) ;
- $X^{(2)}$: **distance (en km) du logement de l'étudiant à l'université**.

Les données observées pour $n = 10$ étudiants sont données dans la table 1.

Étudiant **i**	$X^{(1)}$ (minutes)	$X^{(2)}$ (distance, km)	Y (note/20)
1	1120	0.08	19
2	800	0.018	16
3	930	0.013	17
4	530	0.011	12
5	1020	0.027	18
6	740	0.05	15
7	380	0.02	9
8	410	0.022	11
9	210	0.0155	8
10	690	0.025	14

Table 1 – Données pour l'Exercice 4.

Premier modèle étudié. On considère tout d'abord le modèle de régression linéaire multiple :

$$Y = \beta_0 + \beta_1 X^{(1)} + \beta_2 X^{(2)} + \varepsilon, \tag{1-M1}$$

où ε désigne un terme d'erreur centré.

1. **Ajustement du modèle multiple.** On ajuste le modèle (1-M1).
   a) Écrire la matrice de design associée à ce modèle.
   b) Interpréter le rôle des coefficients β_1 et β_2.
   c) À l'aide du tableau de résumé du modèle, commenter la significativité des coefficients. Les sorties dans `R` sont résumées dans le tableau 2.

Résumé – Modèle (1-M1) (régression linéaire multiple)

Les sorties dans `R` pour le modèle multiple (1-M1) sont résumées dans le tableau 2.

Variable	**Estimate**	**Std. Error**	**t-value**	**p-value**
Intercept ($\hat{\beta}_0$)	4.9506	0.4786	10.345	1.71×10^{-5}
$X^{(1)}$ ($\hat{\beta}_1$)	0.0125	0.0006	22.301	9.22×10^{-8}
$X^{(2)}$ ($\hat{\beta}_2$)	2.7021	1.9820	1.363	0.215

Table 2 – Résumé du modèle de régression linéaire multiple [Modèle (1-M1)].

Indicateurs globaux d'ajustement du modèle :

- écart-type résiduel : $\hat{\sigma} = 0.4973$ (pour 7 degrés de liberté) ;

- coefficient de détermination et critères de sélection :

$$R^2 = 0.9866, \quad R^2_{\text{ajusté}} = 0.9827; \qquad \text{AIC} = 18.840, \quad \text{BIC} = 20.051.$$

- statistique de Fisher globale :

$$F = 257.1 \quad (\text{ddl : 2 et 7}), \quad \text{p-value} = 2.807 \times 10^{-7}.$$

- intervalles de confiance pour les estimations des coefficients β_1 et β_2 :

$$\text{IC}_{1-\alpha}(\beta_1) = [\,0.0112\ ;\ 0.0139\,],$$
$$\text{IC}_{1-\alpha}(\beta_2) = [\,-1.9845\ ;\ 7.3886\,].$$

2. **Intervalles de confiance.** Les intervalles de confiance à 95% des coefficients sont fournis dans la table.
   a) Indiquer si 0 appartient ou non à chacun de ces intervalles.
   b) Que peut-on en déduire sur l'utilité de $X^{(2)}$ dans le modèle ?

Second modèle étudié. On considère ensuite le modèle réduit :

$$Y = \beta_0 + \beta_1 X^{(1)} + \varepsilon. \tag{1-M2}$$

Résumé – Modèle (1-M2) (régression linéaire simple)

Les sorties dans `R` pour le modèle réduit (1-M2) sont résumées dans le tableau 3.

Variable	Estimate	Std. Error	t-value	p-value
Intercept ($\hat{\beta}_0$)	5.2828	0.4334	12.19	1.9×10^{-6}
$X^{(1)}$ ($\hat{\beta}_1$)	0.0126	0.0006	21.51	2.3×10^{-8}

Table 3 – Résumé du modèle de régression linéaire simple [Modèle (1-M2)].

Indicateurs globaux d'ajustement :

- écart-type résiduel : $\hat{\sigma} = 0.5233$ (pour 8 degrés de liberté) ;
- coefficient de détermination et critères de sélection :

$$R^2 = 0.9830, \quad R^2_{\text{ajusté}} = 0.9809; \qquad \text{AIC} = 19.195, \quad \text{BIC} = 20.103.$$

- statistique de Fisher globale : $F = 462.7$ (ddl : 1 et 8), p-value $= 2.297 \times 10^{-8}$.
- intervalle de confiance pour l'estimation du coefficient β_1 :

$$\text{IC}_{1-\alpha}(\beta_1) = [\,0.0113\ ;\ 0.0140\,].$$

3. **Ajustement du modèle réduit.** On ajuste maintenant le modèle (1-M2).
   a) Comparer les coefficients estimés de β_1 dans les deux modèles.
   b) Comparer les valeurs de R^2 et de R^2_{adj}.

4. **Comparaison des modèles.** À l'aide des critères R^2, R^2_{adj}, AIC et BIC :
   a) Comparer les modèles (1-M1) et (1-M2) ;
   b) Indiquer lequel vous semble le plus pertinent. Justifier votre réponse en une ou deux phrases.

——— *Fin Exercice 1* ———

Exercice 2

On rappelle que le modèle de régression linéaire multiple peut s'écrire sous la forme

$$\boldsymbol{Y} = \mathbb{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \tag{RLM}$$

pour n observations $\big\{(X_i^1, \dots, X_i^p, Y_i)\big\}$, $i = 1, \dots, n$, où :

- $\mathbb{X} \in \mathbb{R}^{n\times(p+1)}$ désigne la matrice de design *(la première colonne est constituée de 1 afin de modéliser l'intercepte)* ;
- $\boldsymbol{\beta} \in \mathbb{R}^{(p+1)\times 1}$ est le vecteur des paramètres ;
- $\boldsymbol{Y} \in \mathbb{R}^{n\times 1}$ est le vecteur des observations ;
- $\boldsymbol{\varepsilon} \in \mathbb{R}^{n\times 1}$ est le vecteur d'erreurs.

On suppose que le vecteur d'erreurs $\boldsymbol{\varepsilon}$ vérifie

$$\mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0} \qquad \text{et} \qquad \mathrm{Var}(\boldsymbol{\varepsilon}) = \sigma^2 I_n,$$

c'est-à-dire que ses composantes sont centrées, de variance σ^2, et non corrélées.

1. Retrouver l'expression de l'estimateur des moindres carrés $\hat{\boldsymbol{\beta}}$ pour le modèle linéaire multiple.

On se place désormais dans le cas particulier $p = 1$, correspondant au modèle de régression linéaire simple étudié au Chapitre 1. Le modèle s'écrit alors

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \qquad i = 1, \dots, n. \tag{RLS}$$

L'objectif est de montrer que le modèle (RLS) peut être naturellement interprété comme un cas particulier du modèle de régression linéaire multiple (RLM), et de retrouver les résultats du Chapitre 1 à l'aide du formalisme matriciel.

2. En utilisant l'expression générale de l'estimateur des moindres carrés dans le modèle matriciel, retrouver explicitement les formules des estimateurs $\hat{\beta}_0$ et $\hat{\beta}_1$ du modèle de régression linéaire simple.

——— *Fin Exercice 2* ———

Exercice 3

On considère toujours un modèle de régression linéaire multiple de la forme

$$Y_i = \beta_0 + \boldsymbol{\beta}^\top X_i + \varepsilon_i, \qquad i = 1, \dots, n,$$

où $X_i \in \mathbb{R}^p$ désigne le vecteur des variables explicatives associé à la i-ème observation.

1. Montrer qu'il est possible de transformer les données X_i en de nouveaux vecteurs $\boldsymbol{x}_{i,*} \in \mathbb{R}^{p+1}$ de telle sorte que le modèle puisse s'écrire sous la forme

   $$Y_i = \boldsymbol{\beta}_*^\top \boldsymbol{x}_{i,*} + \varepsilon_i,$$

   pour un certain vecteur de paramètres $\boldsymbol{\beta}_* \in \mathbb{R}^{p+1}$. On pourra alors supposer, sans perte de généralité, que tous les modèles linéaires considérés sont de ce type.

   Dans la suite, on notera simplement $\boldsymbol{\beta} = \boldsymbol{\beta}_*$ pour alléger les notations.
2. Rappeler la solution du problème d'estimation des moindres carrés dans le modèle linéaire gaussien, notée $\hat{\boldsymbol{\beta}}$. Calculer $\mathbb{E}[\hat{\boldsymbol{\beta}}]$ et interpréter ce résultat.
3. Montrer que la matrice de covariance de l'estimateur $\hat{\boldsymbol{\beta}}$, définie par

   $$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \mathbb{E}\Big[(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^\top\Big],$$

   peut s'exprimer explicitement sous la forme

   $$\mathrm{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbb{X}^\top\mathbb{X})^{-1},$$

   où $\mathbb{X}$ désigne la matrice de design associée aux vecteurs $\boldsymbol{x}_{i,*}$.

4. En déduire que, dans le cas de la régression linéaire simple, on a

$$\hat{\beta}_1 \sim \mathcal{N}\left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^{n}(X_i - \bar{X})^2}\right),$$

et

$$\hat{\beta}_0 \sim \mathcal{N}\left(\beta_0, \frac{\sigma^2 \sum_{i=1}^{n} X_i^2}{n \sum_{i=1}^{n}(X_i - \bar{X})^2}\right),$$

où $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$.

——— *Fin Exercice 3* ———

Exercice 4

On s'intéresse à l'étude du taux de cholestérol sanguin en fonction de plusieurs caractéristiques morphologiques et démographiques. On dispose des données suivantes, mesurées sur $n = 15$ individus :

Cholestérol (ml/100 ml)	**Poids** (kg)	**Âge** (ans)	**Taille** (cm)
354	84	46	180
190	73	20	190
405	65	52	160
263	70	30	155
451	76	57	165
302	69	25	170
288	63	28	175
385	72	36	180
402	79	57	150
365	75	44	165
209	47	24	160
290	89	31	165
346	65	52	165
254	57	23	170
395	59	60	175

On note :

$$Y = \text{Cholestérol}, \qquad X^{(1)} = \text{Poids}, \qquad X^{(2)} = \text{Âge}, \qquad X^{(3)} = \text{Taille}.$$

1) Modélisation Pour tout observation $i = 1, \ldots, n$, on considère le modèle de régression linéaire multiple à erreur gaussienne :

$$Y_i = \beta_0 + \beta_1 X_i^{(1)} + \beta_2 X_i^{(2)} + \beta_3 X_i^{(3)} + \varepsilon_i. \tag{M4}$$

a) Rappeler les hypothèses du modèle linéaire.

b) Écrire ce modèle sous forme matricielle $\boldsymbol{Y} = \mathbb{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, en précisant la dimension de chaque objet.

c) Rappeler l'expression de l'estimateur des moindres carrés $\hat{\boldsymbol{\beta}} \in \Theta$ (Θ *est à préciser dans la question précédente*).

2) Estimation et significativité des coefficients (TP) À l'aide des commandes `lm` et `summary`, estimer les coefficients du modèle.

a) Donner les valeurs estimées de $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3$.

b) Donner l'estimation $\hat{\sigma}^2$ de la variance des erreurs.

c) Parmi les variables explicatives $X^{(1)}, X^{(2)}, X^{(3)}$, indiquer la ou les variables statistiquement significatives au seuil $\alpha = 0.05$, en justifiant à l'aide des p-values.

3) Intervalles de confiance Donner les intervalles de confiance à niveau $1 - \alpha$ avec $\alpha = 0.05$ pour chacun des coefficients du modèle. Interpréter.

4) Significativité globale du modèle À partir des résultats du `summary` recensés dans la table *Résumé – Modèle linéaire multiple (Cholestérol)*, discuter la significativité globale du modèle linéaire multiple à erreurs gaussiennes *(il faudra investiguer les hypothèses concernant les résidus)*.

5) Discussion et prolongements Le modèle linéaire multiple est-il satisfaisant pour expliquer la variabilité du taux de cholestérol ? Proposer un autre type de modèle ou une modification du modèle existant (transformation de variables, sélection de variables, interaction, etc.) et justifier brièvement ce choix, notamment par les critères qui comparent $R^2, R^2_{\text{adj}}, \text{AIC}, \text{BIC}$. Le comparer au modèle (M4).

Résumé – Modèle linéaire multiple (Cholestérol)

Les sorties dans `R` pour le modèle (M4) sont résumées ci-dessous.

Variable	Estimate	Std. Error	t-value	p-value
Intercept ($\hat{\beta}_0$)	42.2614	183.7279	0.230	0.822
weight ($\hat{\beta}_1$)	0.9241	0.9581	0.964	0.356
age ($\hat{\beta}_2$)	4.7523	0.7640	6.220	6.53×10^{-5}
height ($\hat{\beta}_3$)	0.2064	1.0124	0.204	0.842

Table 4 – Résumé du modèle multiple [Modèle (M4)].

Indicateurs globaux d'ajustement :

- écart-type résiduel : $\hat{\sigma} = 37.4$ (pour 11 degrés de liberté) ;
- estimation de la variance du bruit : $\hat{\sigma}^2 = 1399.12$;
- coefficient de détermination et critères globaux :

$$R^2 = 0.8151, \quad R^2_{\text{adj}} = 0.7647; \qquad \text{AIC} = 156.57, \quad \text{BIC} = 160.11.$$

- statistique de Fisher globale : $F = 16.16$ (ddl : 3 et 11), p-value $= 2.408 \times 10^{-4}$.

Intervalles de confiance à 95% :

$$IC_{95\%}(\beta_0) = [\,-362.121\ ;\ 446.644\,], \qquad IC_{95\%}(\beta_1) = [\,-1.185\ ;\ 3.033\,],$$
$$IC_{95\%}(\beta_2) = [\,3.071\ ;\ 6.434\,], \qquad IC_{95\%}(\beta_3) = [\,-2.022\ ;\ 2.435\,].$$

Analyse des résidus :

- moyenne empirique des résidus : 0 ;
- test de Student pour $(H_0) : \mathbb{E}[\varepsilon] = 0$:

$$\hat{T} = 0, \quad \text{ddl} = 14, \quad \text{p-value} = 1.$$

- test de Shapiro-Wilk pour $(H_0) : \varepsilon \sim \mathcal{N}$:

$$\hat{W} = 0.96, \quad \text{p-value} = 0.67.$$

- test de Durbin-Watson pour (H_0) : absence d'autocorrélation d'ordre 1 :

$$\widehat{\text{DW}} = 1.8047, \quad \text{p-value} = 0.3695.$$

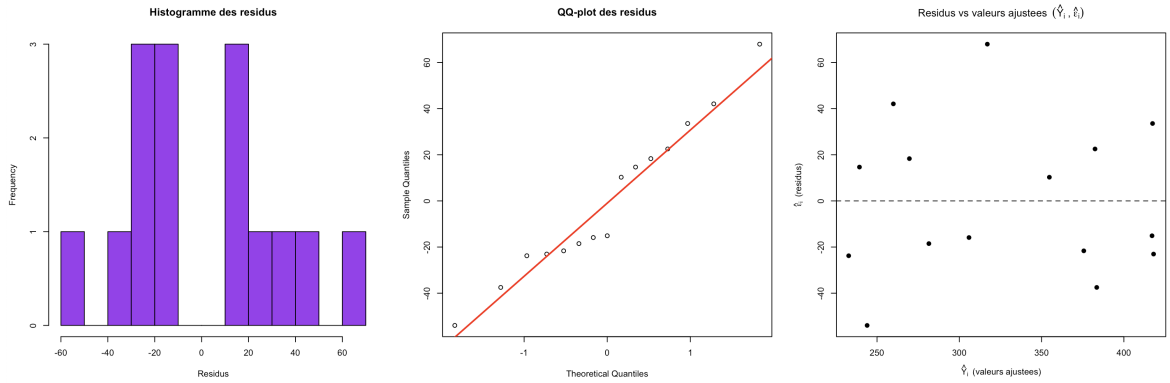

FIGURE 1 – **Diagnostics des résidus du modèle linéaire multiple** (M4)**.** À gauche : histogramme des résidus. Au centre : QQ-plot comparant les quantiles empiriques aux quantiles d'une loi normale. À droite : nuage des points $(\hat{Y}_i, \hat{\varepsilon}_i)$.

Résumé – Modèle linéaire réduit (Cholestérol)

Les sorties dans `R` pour le modèle réduit `cholesterol` $\sim$ `age` sont résumées ci-dessous.

Variable	Estimate	Std. Error	t-value	p-value
Intercept ($\hat{\beta}_0$)	137.1714	28.0536	4.890	2.96×10^{-4}
age ($\hat{\beta}_1$)	4.8571	0.6787	7.157	7.40×10^{-6}

TABLE 5 – Résumé du modèle réduit (cholestérol expliqué par l'âge).

Indicateurs globaux d'ajustement :

- écart-type résiduel : $\hat{\sigma} = 36$ (pour 13 degrés de liberté) ;
- coefficient de détermination :

$$R^2 = 0.7976, \quad R^2_{\text{adj}} = 0.7820, \qquad \text{AIC} = 153.93, \quad \text{BIC} = 156.05.;$$

- statistique de Fisher globale : $F = 51.22$ (ddl : 1 et 13), p-value $= 7.404 \times 10^{-6}$.

Intervalles de confiance à 95% :

$$IC_{95\%}(\beta_0) = [\,76.565\ ;\ 197.778\,], \qquad IC_{95\%}(\beta_1) = [\,3.391\ ;\ 6.323\,].$$

Analyse des résidus :

- moyenne empirique des résidus : 0 ;
- test de Student pour $(H_0) : \mathbb{E}[\varepsilon] = 0 : \hat{T} = 0$, ddl $= 14$, p-value $= 1$;
- test de Shapiro–Wilk pour $(H_0) : \varepsilon \sim \mathcal{N}$:

$$\hat{W} = 0.949, \quad \text{p-value} = 0.505.$$

- test de Durbin-Watson pour (H_0) : absence d'autocorrélation d'ordre 1 :

$$\widehat{\text{DW}} = 1.97, \quad \text{p-value} = 0.5249.$$

——— *Fin Exercice 4* ———