TD3 – Régression logistique

Paul MINCHELLA, Stéphane CHRÉTIEN

Second Semestre 2025-2026

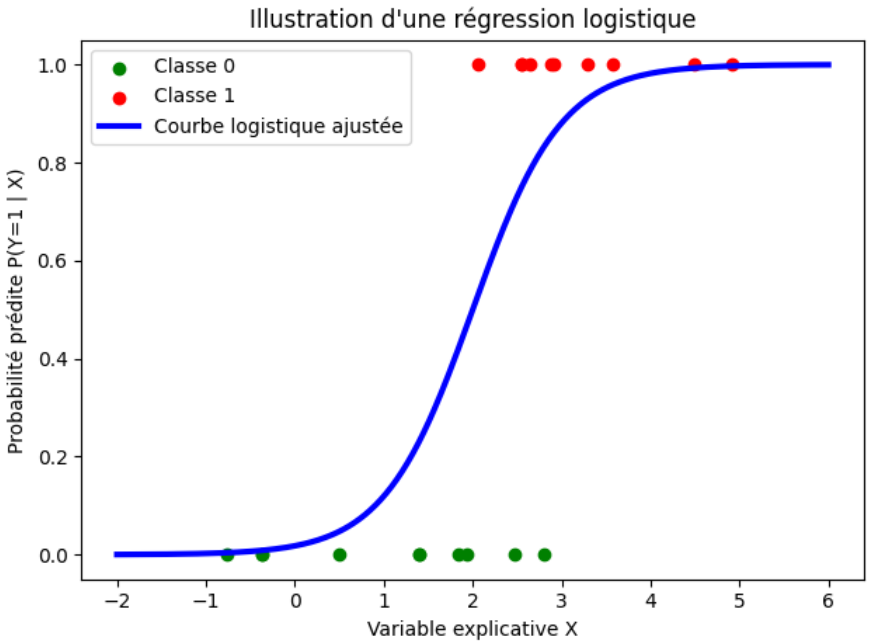

Licence MIASHS

3 Régression logistique

Exercice 1 – Régression logistique binaire à deux covariables

Contexte. Un site de commerce en ligne souhaite prédire si un visiteur finalisera un achat lors de sa session. On note :

$$Y = \begin{cases} 1 & \text{la session se termine par un achat,} \\ 0 & \text{aucun achat n'est effectué.} \end{cases}$$

Pour chaque session, deux variables explicatives numériques sont observées :

- $X^{(1)}$: **durée de la session** sur le site (en minutes) ;
- $X^{(2)}$: **nombre de pages consultées** durant la session.

L'objectif est de modéliser la probabilité $\mathbb{P}(Y = 1 \mid X^{(1)}, X^{(2)})$ à partir de ces deux covariables.

Préliminaires théoriques.

1. **Pourquoi la régression logistique ?**
   Justifier pourquoi un modèle logistique constitue un choix plus judicieux qu'une régression linéaire standard pour prédire Y expliquée par $X^{(1)}$ et $X^{(2)}$.

2. **Étude de la sigmoïde.**
   On considère la fonction sigmoïde $\mathcal{S} : t \longmapsto \frac{\exp(t)}{1+\exp(t)}$.
   a) Quel est le domaine de définition de $\mathcal{S}$? Quelle est son image ?
   b) Montrer que $\mathcal{S}$ est strictement croissante sur $\mathbb{R}$ et en déduire qu'elle est bijective de son domaine de définition à son image.
   c) Montrer que $\mathcal{S}$ admet un point d'inflexion et préciser sa localisation.
   Indication : calculer $\mathcal{S}'(t)$ puis $\mathcal{S}''(t)$. On pourra montrer que $\mathcal{S}$ vérifie cette jolie équation différentielle pour $t \in \mathbb{R}$: $\mathcal{S}'(t) = \mathcal{S}(t)\big(1 - \mathcal{S}(t)\big)$.
   d) Quel est l'intérêt d'une telle application dans un modèle de classification binaire ?

3. **Formule de la probabilité prédite.**
   On considère le modèle logistique :

   $$\mathbb{P}(Y = 1 \mid X^{(1)}, X^{(2)}) = \mathcal{S}\big(w_0 + w_1 X^{(1)} + w_2 X^{(2)}\big).$$

   Rappeler la formule de l'estimateur de la probabilité d'appartenir à la classe 1, notée $\widehat{p}(\mathbf{x})$, pour une observation $\mathbf{x} = (x^{(1)}, x^{(2)})$ donnée et une estimation $\hat{\boldsymbol{w}} = (\hat{w}_0, \hat{w}_1, \hat{w}_2)$.

4. **Critère optimisé.**
   Quel score (ou critère) est optimisé pour estimer les coefficients (w_0, w_1, w_2) ? Quelle méthode permet la résolution numérique à cette optimisation ?

Application TD. Après ajustement du modèle, on obtient :

$$\begin{aligned} \hat{w}_0 &= -4.20 & \mathrm{IC}_{95\%}(w_0) &= [\,-6.10\ ;\ -2.30\,], \\ \hat{w}_1 &= 1.00 & \mathrm{IC}_{95\%}(w_1) &= [\,0.20\ ;\ 2.20\,], \\ \hat{w}_2 &= 0.015 & \mathrm{IC}_{95\%}(w_2) &= [\,-0.005\ ;\ 0.035\,]. \end{aligned}$$

1. **Interprétation et significativité.**
   a) Que signifie le fait que $\hat{w}_1$ soit positif dans ce contexte ?
   b) $\hat{w}_1$ est-il significatif dans le modèle ? Justifier.
   c) Même question pour $\hat{w}_2$.

2. **Calcul de probabilités prédites.**
On considère trois sessions caractérisées par :

$$(X_1^{(1)}, X_1^{(2)}) = (5,\, 3), \qquad (X_2^{(1)}, X_2^{(2)}) = (12,\, 8), \qquad (X_3^{(1)}, X_3^{(2)}) = (25,\, 15).$$

Calculer les probabilités prédites d'appartenir à la classe 1 :

$$\widehat{p}_k = \mathbb{P}(Y = 1 \mid X^{(1)} = X_k^{(1)},\, X^{(2)} = X_k^{(2)}), \qquad k = 1, 2, 3,$$

en explicitant l'expression de $\widehat{p}_k$ en fonction de la sigmoïde $\mathcal{S}$ et des coefficients estimés $(\hat{w}_0, \hat{w}_1, \hat{w}_2)$.

3. **Prédictions.**
Soit le seuil décisionnel $\tau \in [0, 1]$. On considère le prédicteur logistique binaire de la session k :

$$\hat{\mu}\big(X_k^{(1)}, X_k^{(2)}\big) = \mathbb{1}\left(\hat{p}_k \geq \tau\right).$$

Pour les sessions $i = 1, 2,$ et 3, prédire à seuil $\tau = \frac{1}{2}$ si le client finira sa session par un achat, ou non.

——— *Fin Exercice 1* ———

Exercice 2 – Régression logistique sur `R`

Contexte. On s'intéresse à la prédiction du risque de diabète chez des patientes à partir de relevés cliniques structurés. On utilise pour cela le jeu de données `Pima.tr` du package `MASS`. Ce jeu de données contient des informations cliniques recueillies chez des femmes d'origine Pima (population amérindienne), dans le cadre d'une étude épidémiologique sur le diabète. Chaque ligne correspond à une patiente. On note :

$$Y = \begin{cases} 1 & \text{si la patiente est diagnostiquée diabétique,} \\ 0 & \text{sinon.} \end{cases}$$

Dans le jeu de données, la variable réponse est `type`, facteur prenant les modalités `Yes` (diabétique) et `No` (non diabétique), *que l'on peut convertir numériquement en 0 ou 1 via* $Y = \mathbb{1}(\texttt{type} = \texttt{Yes})$.

Variables explicatives retenues. Parmi les variables disponibles dans `Pima.tr`, on considère les covariables quantitatives suivantes :

- $X^{(1)}$: `npreg` – nombre de grossesses ;
- $X^{(2)}$: `glu` – concentration plasmatique en glucose ;
- $X^{(3)}$: `bmi` – indice de masse corporelle (Body Mass Index) ;
- $X^{(4)}$: `age` – âge de la patiente (en années).

L'objectif est de modéliser la probabilité conditionnelle

$$\mathbb{P}(Y = 1 \mid X^{(1)}, X^{(2)}, X^{(3)}, X^{(4)})$$

à l'aide d'un modèle de régression logistique binaire.

On cherche donc à déterminer si ces variables cliniques permettent d'expliquer significativement le risque de diabète, et à construire un outil de prédiction probabiliste.

Notations. On pourra écrire $\boldsymbol{X}_i = \left(X_i^{(1)},\, X_i^{(2)},\, X_i^{(3)},\, X_i^{(4)}\right)$ et $\boldsymbol{w} = (w_0, \ldots, w_p)$.

1) Analyse descriptive des données

a) **Statistiques descriptives.**
Après avoir chargé le jeu de données choisi, déterminer :

- la taille de l'échantillon n ;
- le nombre de variables explicatives p ;
- pour chaque variable explicative $X^{(j)}$: la moyenne empirique ; l'écart-type ; le minimum et le maximum ; la médiane ; la présence éventuelle de valeurs manquantes (`NA`).
- la proportion d'observations dans chaque classe de Y.

On pourra utiliser notamment les commandes : `summary`, `mean`, `sd`, `is.na`, `table`, etc.

b) **Visualisation.**
Afficher la matrice de nuages de points des variables explicatives à l'aide de `pairs`, en distinguant les observations selon la classe de Y. Commenter brièvement la séparation visuelle éventuelle des classes ; la présence possible de corrélations entre variables explicatives ; la présence d'observations atypiques.

2) Rappels théoriques

a) **Forme du modèle logistique.**
Rappeler la forme du modèle logistique binaire. Préciser les hypothèses principales. On écrira la probabilité provenant du logit $p(\boldsymbol{X}, \boldsymbol{w})$.

b) **Critère optimisé.** Rappeler le critère optimisé pour estimer les paramètres $\boldsymbol{w} = (w_0, \ldots, w_p)$, *basé sur la vraisemblance du modèle Bernoulli.*

3) Apprentissage du modèle dans `R`

a) **Estimation des coefficients.**
Ajuster le modèle logistique à l'aide de la fonction `glm` avec l'argument `family = binomial`.

- Relever les coefficients estimés $\hat{w}_0, \ldots, \hat{w}_p$;
- Donner les intervalles de confiance à 95% pour chaque coefficient.

b) **Significativité.**
Pour chaque coefficient :

- vérifier s'ils sont significativement non nuls ;
- interpréter pour les variables significatives les signes des coefficients $\hat{w}_j$.

Commenter globalement la pertinence du modèle.

4) Prédiction sur de nouvelles observations On considère trois nouvelles observations correspondant à trois patientes présentant les caractéristiques suivantes :

$$\boldsymbol{X}_1 = (1,\ 90,\ 22,\ 22), \qquad \boldsymbol{X}_2 = (3,\ 130,\ 30,\ 35), \qquad \boldsymbol{X}_3 = (6,\ 170,\ 36,\ 50),$$

où les composantes correspondent respectivement à

$$(X^{(1)}, X^{(2)}, X^{(3)}, X^{(4)}) = (\texttt{npreg},\ \texttt{glu},\ \texttt{bmi},\ \texttt{age}).$$

a) Calculer pour chacune la probabilité d'appartenir à la classe 1 : $\widehat{p}_k(\boldsymbol{w}) = \mathbb{P}(Y = 1 \mid \boldsymbol{X} = \boldsymbol{X}_k)$ pour chaque nouvelle observation $k = 1, 2, 3$.

b) En utilisant le seuil décisionnel $\tau = \frac{1}{2}$, déterminer la classe prédite :

$$\widehat{\mu}(\boldsymbol{X}_k) = \mathbb{1}\big(\widehat{p}_k \geq \tau\big).$$

c) Interpréter les résultats obtenus.

Sorties R – Exercice 2

Variable	mean	sd	min	med	max	NA
`npreg`	3.57	3.366	0.0	2.0	14.0	0
`glu`	123.97	31.667	56.0	120.5	199.0	0
`bmi`	32.31	6.130	18.2	32.8	47.9	0
`age`	32.11	10.975	21.0	28.0	63.0	0

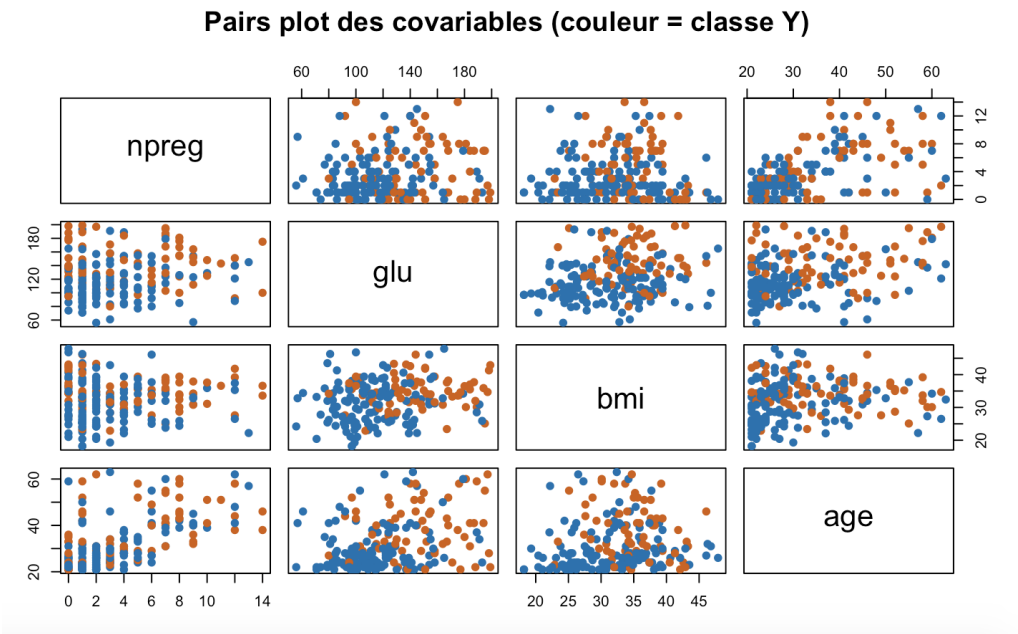

FIGURE 1 – Matrice des nuages de points des covariables, séparées selon la classe Y (bleu = non diabétique, orange = diabétique).

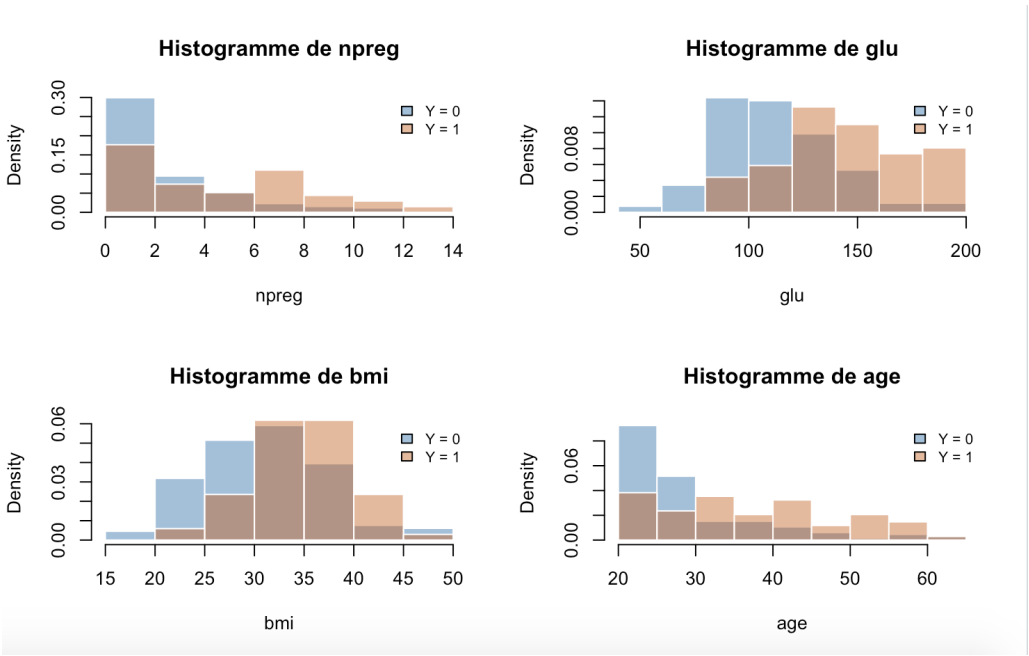

FIGURE 2 – Histogrammes des covariables selon la classe binaire.

Coefficient		Estimate	IC 95%
`Intercept`	β_0	-9.347	$[-12.26; -6.43]$
`npreg`	β_1	0.084	$[-0.038; 0.206]$
`glu`	β_2	0.031	$[0.0186; 0.0439]$
`bmi`	β_3	0.095	$[0.030; 0.159]$
`age`	β_4	0.0366	$[-0.003; 0.076]$

Indicateurs globaux :

$$\text{Null deviance} = 256.41, \qquad \text{Residual deviance} = 186.55, \qquad \text{AIC} = 196.55.$$

——— *Fin Exercice 2* ———

Exercice 3 – Régression logistique multinomiale (jeu de données `iris`)

On considère le jeu de données classique `iris`, contenant des mesures morphologiques de fleurs appartenant à trois espèces distinctes.

Contexte. On note :

$$Y = \begin{cases} 1 & \text{Species} = \text{setosa}, \\ 2 & \text{Species} = \text{versicolor}, \\ 3 & \text{Species} = \text{virginica}. \end{cases}$$

Les variables explicatives numériques sont :

$$\boldsymbol{X} = \left(X^{(1)}, X^{(2)}, X^{(3)}, X^{(4)}\right),$$

où :

- $X^{(1)}$: longueur du sépale (`Sepal.Length`),
- $X^{(2)}$: largeur du sépale (`Sepal.Width`),
- $X^{(3)}$: longueur du pétale (`Petal.Length`),
- $X^{(4)}$: largeur du pétale (`Petal.Width`).

1. Analyse descriptive.

a) Déterminer la taille de l'échantillon n et le nombre de variables explicatives p.

b) Identifier la nature des variables (quantitative continue, qualitative nominale, etc.). Afficher les statistiques descriptives usuelles (moyenne, écart-type, quartiles, min et max, `NA`).

c) Afficher la matrice des graphiques des covariables (plot 4×4). Un plot est proposé en Figure 3.
Indication : utiliser `pairs(iris[ ,1:4], col = iris$Species)`.

d) Observer les nuages de points par couleur (selon l'espèce).
Existe-t-il une séparabilité (approximativement) linéaire entre les classes dans certains plans de covariables ?

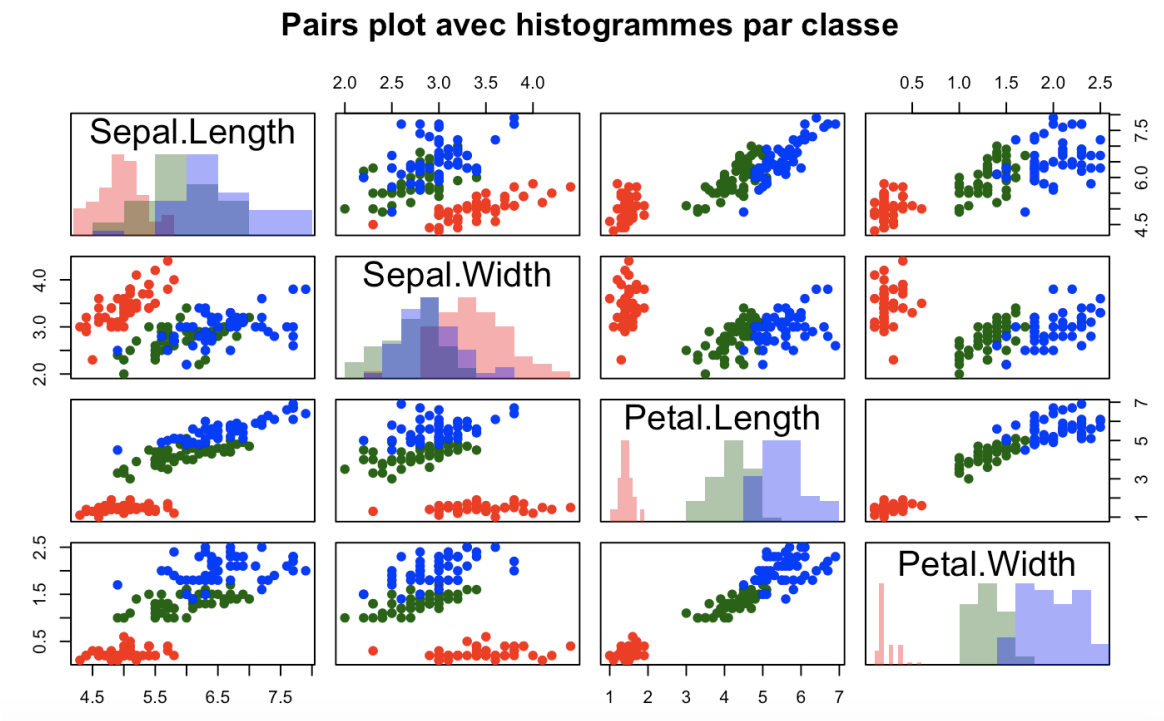

FIGURE 3 – Matrice des graphiques des quatre covariables du jeu de données `iris`. Les points sont colorés selon l'espèce (rouge = *setosa*, vert = *versicolor*, bleu = *virginica*).

2. Modélisation logistique.

a) Rappeler la forme du modèle logistique multinomial permettant de modéliser

$$\mathbb{P}(Y = j \mid \boldsymbol{X}), \qquad j = 1, 2, 3.$$

b) Justifier en quoi ce modèle est pertinent pour une variable réponse qualitative à trois modalités.

3. Probabilités prédites. Après ajustement du modèle logistique multinomial, on considère trois individus caractérisés par :

$$\boldsymbol{X}_1 = (5.1, 3.5, 1.4, 0.2), \qquad \boldsymbol{X}_2 = (6.0, 2.9, 4.5, 1.5), \qquad \boldsymbol{X}_3 = (6.5, 3.0, 5.5, 2.0).$$

a) Calculer les probabilités prédites :

$$\widehat{p}_k^{(j)} = \mathbb{P}(Y = j \mid \boldsymbol{X} = \boldsymbol{X}_k), \qquad j = 1, 2, 3, \quad k = 1, 2, 3.$$

b) Vérifier que pour chaque individu k :

$$\widehat{p}_k^{(1)} + \widehat{p}_k^{(2)} + \widehat{p}_k^{(3)} = 1.$$

4. Règle de décision.

a) Quel critère utiliser pour prédire la classe d'appartenance d'un individu à partir des probabilités estimées ?

b) Déterminer la classe prédite pour les individus $k = 1, 2, 3$.

——— *Fin Exercice 3* ———