TD4 – Arbre de décision

Paul MINCHELLA, Stéphane CHRÉTIEN

Second Semestre 2025-2026

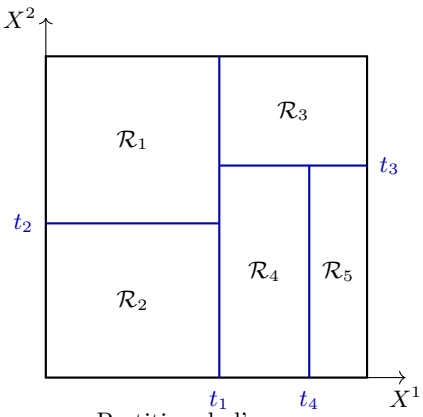

Partition de l'espace des covariables (X^1, X^2)

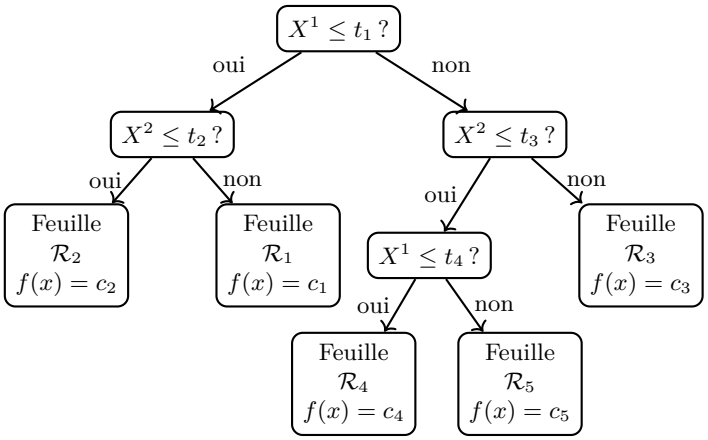

Arbre de décision correspondant (règles si–alors)

Licence MIASHS

4 Arbre de décision

Exercice 0 – Reconstruction d'un arbre de décision

On considère un problème de régression avec deux variables explicatives

$$X = \left(X^{(1)}, X^{(2)}\right) \in \mathbb{R}^2.$$

La figure ci-dessous représente une partition de l'espace des variables explicatives induite par un arbre de régression. Dans chaque région est indiquée la valeur prédite par le modèle.

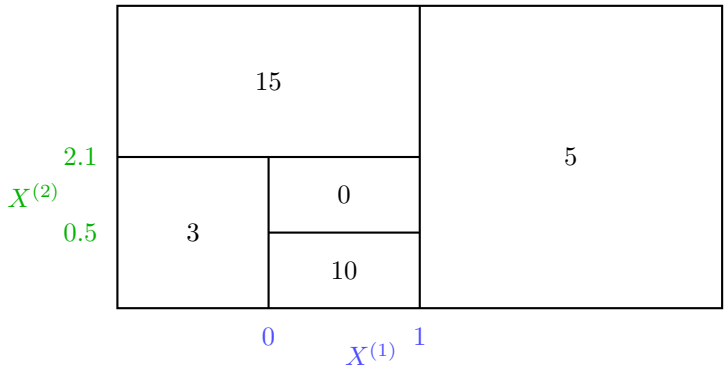

FIGURE 1 – Partition de l'espace $(X^{(1)}, X^{(2)})$ induite par un arbre de régression.

1. Donner explicitement la suite des règles de découpage (*splits*) associées à cet arbre.
2. Dessiner l'arbre de décision (ou arbre de régression) qui conduit à cette partition de l'espace.
3. Écrire la fonction de prédiction $f\left(x^{(1)}, x^{(2)}\right)$ sous forme *piecewise* en fonction des différentes régions de l'espace.

——— *Fin Exercice 0* ———

Exercice 1 – Introduction aux arbres de décision

Jeu de données. On utilisera le jeu de données `mtcars`, qui contient des caractéristiques de différents modèles de voitures. La variable réponse est :

`mpg` (consommation, miles par gallon),

et les variables explicatives sont :

`wt` (poids du véhicule), `hp` (puissance du moteur).

1) Chargement des bibliothèques et des données

a) Afficher les premières lignes du jeu de données.

b) Donner une interprétation rapide des variables `mpg`, `wt` et `hp`.

2) Apprentissage d'un arbre de régression

```r
# Apprentissage de l'arbre de régression
tree <- rpart(mpg ~ wt + hp, data = mtcars)
```

a) Que représente la formule `mpg` $\sim$ `wt + hp` ? Écrire le modèle de prédicteur associé.

b) Quel type de problème est résolu ici : classification ou régression ?

c) Quel critère est utilisé pour choisir les coupures dans un arbre de régression ?

3) Visualisation de l'arbre

a) Identifier la première variable de coupure de l'arbre. Interpréter le seuil utilisé pour cette coupure.

b) Que représente la valeur affichée dans chaque feuille ?

4) Interprétation géométrique des prédictions

a) Pourquoi les prédictions sont-elles constantes par régions ?

b) Expliquer le lien entre les feuilles de l'arbre et ces régions.

5) Visualisation des régions de décision

a) Expliquer pourquoi ces régions sont nécessairement rectangulaires.

b) Que se passerait-il si l'arbre était plus profond ?

6) Discussion et ouverture

a) Citer un avantage majeur des arbres de décision.

b) Citer une limite importante de ce type de modèle. En quoi les forêts aléatoires peuvent-elles répondre à cette limite ?

Sorties R

Premières observations du jeu de données.

Observation (modèle du véhicule)	wt	hp	mpg
Mazda RX4	2.620	110	21.0
Mazda RX4 Wag	2.875	110	21.0
Datsun 710	2.320	93	22.8
Hornet 4 Drive	3.215	110	21.4
Hornet Sportabout	3.440	175	18.7
Valiant	3.460	105	18.1

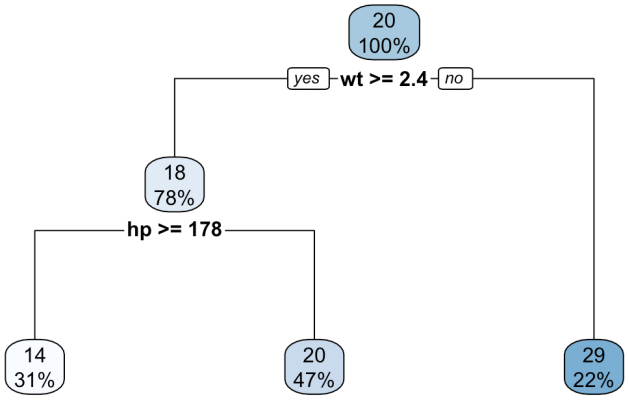

FIGURE 2 – Arbre de décision appris pour prédire la consommation `mpg` en fonction de `wt` et `hp`.

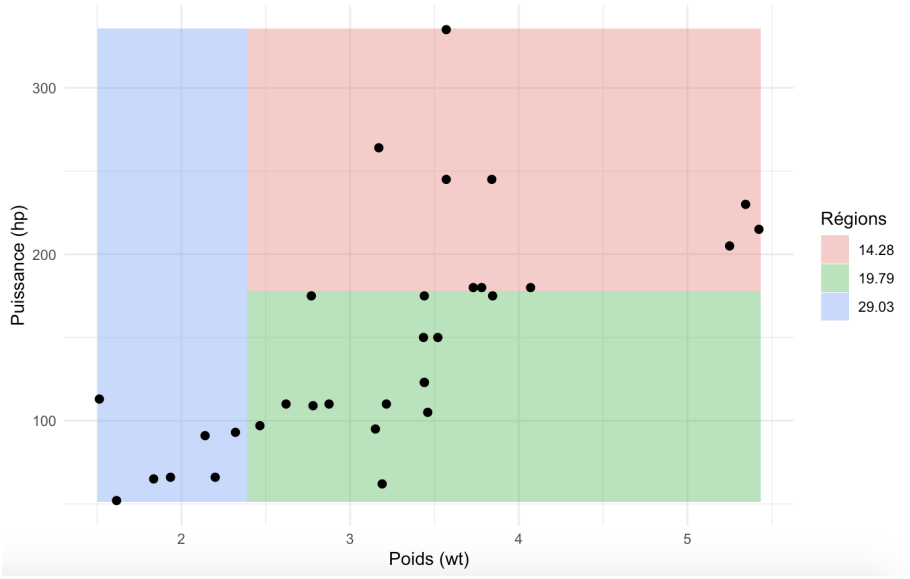

FIGURE 3 – Régions de prédiction induites par l'arbre de décision dans l'espace (`wt`, `hp`).

Fin Exercice 1

Exercice 2 – Calcul d'entropie et dessin d'un arbre de décision

On s'intéresse à un problème de diagnostic chez des patients atteints d'une tumeur, afin de déterminer si celle-ci est **maligne** ou non. Pour chaque patient, trois critères binaires sont relevés :

- $X^{(1)}$: la tumeur est-elle **grosse** (Large) ?
- $X^{(2)}$: la tumeur est-elle **dure** (Hard) ?
- $X^{(3)}$: la tumeur est-elle **symétrique** (Symmetric) ?

Chaque variable explicative est codée de la manière suivante :

$$1 = \text{Oui}, \qquad 0 = \text{Non}.$$

La variable réponse Y indique si la tumeur est maligne :

$$Y = 1 \text{ (maligne)}, \qquad Y = 0 \text{ (bénigne)}.$$

Les données observées sont les suivantes :

Patient	$X^{(1)}$ (Large)	$X^{(2)}$ (Hard)	$X^{(3)}$ (Symmetric)	Y (Maligne)
1	1	0	0	1
2	0	0	0	1
3	0	1	1	1
4	0	0	1	0
5	1	0	1	0

Travail demandé.

1. Calculer l'entropie de la variable réponse Y.
2. Pour chacune des variables explicatives $X^{(1)}$, $X^{(2)}$ et $X^{(3)}$, calculer l'entropie conditionnelle $H(Y \mid X^{(j)})$. En déduire le gain d'information associé à chaque variable. Identifier ainsi la variable à utiliser pour le premier nœud de l'arbre de décision.
3. Déterminer la variable à utiliser pour la seconde découpe de l'arbre de décision, en s'appuyant à nouveau sur le critère d'entropie conditionnelle. *Attention : il se peut qu'aucune autre découpe ne soit nécessaire.*
4. Construire l'arbre de décision complet correspondant à ce critère.
5. Quel prédiction a-t-on pour le patient 6 et 7 de covariables :

$$\boldsymbol{X}_6 = \left(X_6^{(1)} = 0,\, X_6^{(2)} = 0,\, X_6^{(3)} = 1\right), \qquad \boldsymbol{X}_7 = \left(X_7^{(1)} = 1,\, X_7^{(2)} = 1,\, X_7^{(3)} = 1\right) \quad ?$$

——— *Fin Exercice 2* ———

Exercice 3 – Analyse du comportement client par arbre de décision

Un site de vente en ligne de musique souhaite analyser le comportement de ses clients afin de comprendre les facteurs influençant la finalisation d'une transaction. Pour chaque client, deux variables explicatives sont observées :

- $X^{(1)}$: **type de musique** consulté par le client. Trois modalités sont possibles :

$$X^{(1)} = \begin{cases} (C) & \text{Classique,} \\ (P) & \text{Pop,} \\ (R) & \text{RnB.} \end{cases}$$

- $X^{(2)}$: **niveau de prix** du produit. Cette variable est binaire et codée par :

$$X^{(2)} = \begin{cases} 1 & \text{prix élevé,} \\ 0 & \text{prix bas.} \end{cases}$$

La variable réponse est définie comme suit :

$$Y = \begin{cases} 1 & \text{le client finalise la transaction,} \\ 0 & \text{le client abandonne la transaction.} \end{cases}$$

Les données observées pour $n = 13$ clients sont résumées dans le tableau ci-dessous.

Client	$X^{(1)}$ (Type de musique)	$X^{(2)}$ (Prix)	Y (Transaction)
1	C	1	1
2	R	0	1
3	R	1	1
4	C	0	1
5	P	0	1
6	R	1	0
7	P	1	0
8	P	0	0
9	C	1	1
10	P	1	0
11	R	1	0
12	P	0	1
13	R	1	0

Dans un contexte réel, ce type de données serait naturellement disponible en quantité bien plus importante (plusieurs centaines de milliers d'observations). Dans cet exercice, on se limite volontairement à un jeu de données réduit afin de permettre une analyse complète à la main.

Travail demandé.

1. Calculer l'entropie marginale de la variable réponse Y.
2. Calculer l'entropie conditionnelle de Y sachant chacune des variables explicatives $X^{(1)}$ et $X^{(2)}$. En déduire le gain d'information associé à chaque variable.
3. Construire l'arbre de décision correspondant au critère d'entropie.
4. Peut-on prédire si la transaction va avoir lieu pour un client avec les valeurs $X^{(1)} = C$ et $X^{(2)} = 1$.
5. Interpréter les règles de décision obtenues du point de vue métier.

——— *Fin Exercice 3* ———

Exercice 4 – Prédire le nombre d'achat à partir de variables catégorielles

On souhaite construire un **arbre de régression** afin de prédire le nombre de ventes d'un site web de vêtements. La variable réponse est :

$$Y = \text{nombre d'achats.}$$

Les variables explicatives sont catégorielles et notées :

$$\begin{aligned}
X^{(1)} &= \text{Météo} \in \{E, N, P\} && (E = \text{Ensoleillé},\ N = \text{Nuageux},\ P = \text{Pluvieux}),\\
X^{(2)} &= \text{Température} \in \{C, M, F\} && (C = \text{Chaud},\ M = \text{Moyen},\ F = \text{Frais}),\\
X^{(3)} &= \text{Humidité} \in \{0, 1\} && (1 = \text{Forte},\ 0 = \text{Normale}),\\
X^{(4)} &= \text{Soldes} \in \{0, 1\} && (1 = \text{Soldes},\ 0 = \text{Sans soldes}).
\end{aligned}$$

Les données observées ($n = 14$) sont :

i	$X^{(1)}$ Météo	$X^{(2)}$ Température	$X^{(3)}$ Humidité	$X^{(4)}$ Soldes	Y Achats
1	E	C	1	1	25
2	E	C	1	0	30
3	N	C	1	1	46
4	P	M	1	1	45
5	P	F	0	1	52
6	P	F	0	0	23
7	N	F	0	0	43
8	E	M	1	1	35
9	E	F	0	1	38
10	P	M	0	1	46
11	E	M	0	0	48
12	N	M	1	0	52
13	N	C	0	1	44
14	P	M	1	0	30

Travail demandé. On utilisera comme critère de découpe la **RSS** (la **SCR** en français) :

$$\text{RSS} = \sum_{i \in \text{noeud}} (Y_i - \bar{Y}_{\text{noeud}})^2.$$

1. Calculer la moyenne globale $\bar{Y}$ et l'écart-type de Y.
2. Pour chaque variable $X^{(j)}$, calculer la RSS obtenue après séparation selon ses modalités :
   - $X^{(1)}$ (Météo),
   - $X^{(2)}$ (Température),
   - $X^{(3)}$ (Humidité),
   - $X^{(4)}$ (Soldes).
3. Identifier la variable minimisant la RSS : elle constitue la **racine** de l'arbre.
4. On suppose que la racine retenue est $X^{(1)}$. Pour chaque modalité $x \in \{E, N, P\}$, rechercher la meilleure variable parmi $X^{(2)}, X^{(3)}, X^{(4)}$ en recalculant la RSS conditionnelle.
5. Déterminer la structure complète de l'arbre de régression jusqu'à ce qu'aucune réduction significative de la RSS ne soit possible.
6. Construire et visualiser l'arbre obtenu sous `R`.

——— *Fin Exercice 4* ———