

Correction TD - Statistiques

Paul MINCHELLA, Stéphane CHRÉTIEN

Second Semestre 2025-2026



Table des matières

1	TD1 - Régression linéaire	1
	Correction Exercice 1	1
	Correction Exercice 2	11
	Correction Exercice 3	15
2	TD2 - Régression linéaire multiple	18
	Correction Exercice 1	18
	Correction Exercice 2	20
	Correction Exercice 3	23
	Correction Exercice 4	26
3	TD3 - Régression logistique	29
	Correction Exercice 1	29
	Correction Exercice 2	32
	Correction Exercice 3	35
4	TD4 - Arbre de décision	39
	Correction Exercice 0	39
	Correction Exercice 1	42
	Correction Exercice 2	45
	Correction Exercice 3	50
	Correction Exercice 4	53
	Correction Exercice 5	58
5	TD5 - Forêt aléatoire	63
	Correction Exercice 1	63
6	TD6 - kNN	69
	Correction Exercice 1	69
	Correction Exercice 2	71
	Correction Exercice 3	73
	Correction Exercice 4	75
	Correction Exercice 5	78

Chapitre 1

TD1 - Régression linéaire

Correction Exercice 1

Question 1 – Statistique descriptive du jeu de données (TP)


1.1) **Structure et résumé numérique** `str(df)` permet de vérifier la nature des objets (ici 2 variables numériques); `summary(df)` donne min, quartiles, médiane, moyenne, max. Le jeu contient $n=50$ observations et $p=2$ variables.

1.2) Nature des variables, unités, ordres de grandeur

- `speed` : vitesse (mph), variable quantitative.
- `dist` : distance de freinage (ft), variable quantitative.
- Un résumé via :

```
> summary(df)
      speed      dist
Min.   : 4.0   Min.   :  2.00
1st Qu.:12.0   1st Qu.: 26.00
Median :15.0   Median : 36.00
Mean   :15.4   Mean   : 42.98
3rd Qu.:19.0   3rd Qu.: 56.00
Max.   :25.0   Max.   :120.00
```

1.3) **Recherche de valeurs atypiques + histogrammes** Les histogrammes aident à repérer asymétrie, concentration, valeurs extrêmes possibles.



1.4) Étendues et dispersion En plus du `summary(df)`, il est **essentiel d'étudier également la dispersion (écart-type) des variables étudiées**. Cela permet d'appréhender la variable même au sein des variables.

```
sd(df$speed)
sd(df$dist)
```


1.5) Commentaire de forme Points attendus au commentaire :

- **speed** : distribution souvent assez étalée, pas forcément symétrique parfaite.
- **dist** : souvent plus asymétrique (queue à droite possible), dispersion plus marquée.

L'objectif est d'insister sur le fait de **décrire avant de modéliser** (compréhension du contexte et des variables, échelle, valeurs extrêmes, forme, premiers commentaires possibles).

Question 2 – Visualisation des données (TP)

Nuage de points – *Scatter plot*. On observe une relation globalement croissante : plus la vitesse est grande, plus la distance de freinage augmente. La relation n'est pas parfaitement alignée : présence de variabilité (bruit) et dispersion possiblement non constante.



Question 3 – Pertinence du modèle (TD)

3.1) Pourquoi une régression linéaire ? Le nuage de points suggère une tendance moyenne croissante. La régression linéaire est un premier modèle simple pour approximer $\mathbb{E}[Y | X]$ par une fonction affine. C'est un modèle interprétable : l'effet marginal de la vitesse est résumé par une pente.

3.2) Forme du modèle On note $X_i = \text{speed}_i$ et $Y_i = \text{dist}_i$. Le modèle est

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n$$

3.3) Interprétation de β_0 et β_1

- β_0 : distance moyenne prédite quand la vitesse vaut 0 mph (interception). Ici, c'est surtout un paramètre d'ajustement (interprétation physique limitée).
- β_1 : variation moyenne de la distance de freinage (en pieds) pour +1 mph de vitesse (pente).

Question 4 – Hypothèses et estimation (TD)

4.1) Hypothèses usuelles (régression linéaire)

- (Linéarité) $\mathbb{E}[Y | X] = \beta_0 + \beta_1 X$.
- (Centrage) $\mathbb{E}[\varepsilon_i | X_i] = 0$.
- (Homoscedasticité) $\text{Var}(\varepsilon_i | X_i) = \sigma^2$ constante.
- (Indépendance) les (ε_i) (ou les observations) sont indépendants.
- (Normalité) $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ (utile pour tests/IC exacts).

4.2) Fonction de perte (moindres carrés) Les moindres carrés minimisent la somme des carrés des résidus :

$$\mathcal{L}(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2.$$

4.3) Formules des estimateurs

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Question 5 – Ajustement du modèle et interprétation (TP + TD)

5.1) Ajuster le modèle et afficher le résumé On ajuste avec `lm` sur `df` (bonne pratique, on peut préciser : `data=df`). Ensuite, **la commande `summary` constitue la commande clé une fois un modèle établi. Elle est indispensable à connaître et à analyser finement.** Voici son rendu dans le cadre de cet exercice :

```
> summary(model)

Call:
lm(formula = dist ~ speed, data = df)

Residuals:
    Min       1Q   Median       3Q      Max
-29.069  -9.525  -2.272   9.215  43.201

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -17.5791     6.7584  -2.601   0.0123 *
speed         3.9324     0.4155   9.464 1.49e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.38 on 48 degrees of freedom
Multiple R-squared:  0.6511, Adjusted R-squared:  0.6438
F-statistic: 89.57 on 1 and 48 DF, p-value: 1.49e-12
```

L'ordonnée à l'origine estimée vaut $\hat{\beta}_0 = -17.58$. Elle correspond à la distance de freinage moyenne prédite pour une vitesse nulle. Cette valeur doit être interprétée avec prudence, car une vitesse de 0 mph ne fait pas partie du domaine pertinent des données ; l'intercepte joue ici principalement un rôle d'ajustement de la droite.

Le coefficient associé à la variable `speed` vaut $\hat{\beta}_1 = 3.93$. En moyenne, une augmentation de la vitesse de 1 mph entraîne donc une augmentation d'environ 3.93 pieds de la distance de freinage, ce qui est cohérent avec l'intuition physique.

5.2) Intervalles de confiance des coefficients estimés. La commande exécutée renvoie :

```
> confint(model, level = 0.95)

                2.5 %    97.5 %
(Intercept) -31.167850 -3.990340
speed        3.096964   4.767853
```

Les intervalles de confiance à 95 % des paramètres du modèle sont donnés par

$$IC_{0.95}(\beta_0) = [-31.17; -3.99], \quad IC_{0.95}(\beta_1) = [3.10; 4.77].$$

L'intervalle de confiance associé à l'ordonnée à l'origine β_0 ne contient pas la valeur 0, ce qui indique que l'intercept est significativement différent de zéro au seuil de 5 %. Toutefois, comme précédemment discuté, cette interprétation reste d'un intérêt pratique limité dans le contexte étudié.

En revanche, l'intervalle de confiance associé au coefficient de pente β_1 est strictement positif et ne contient pas la valeur 0. On en déduit que

$$H_0 : \beta_1 = 0$$

est rejetée au seuil de 5 %. La variable explicative exerce donc un effet linéaire statistiquement significatif sur la variable réponse.

Cette conclusion est cohérente avec les résultats du test de Student sur β_1 et avec le test global de Fisher. Le fait que 0 n'appartienne pas à $IC_{0.95}(\beta_1)$ confirme que le modèle de régression linéaire est globalement significatif et qu'il met en évidence une relation linéaire non nulle entre la vitesse et la distance de freinage.

Formalisme théorique. La commande `confint(model, level = 0.95)` calcule les intervalles de confiance à 95 % des paramètres β_0 et β_1 du modèle. Le formalisme mathématique sous-jacent repose sur l'inférence dans le modèle de régression linéaire gaussien

$$Y = X\beta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I_n),$$

où X est la matrice de design, $\beta = (\beta_0, \beta_1)^\top$, et σ^2 la variance des erreurs.

Sous ces hypothèses, l'estimateur des moindres carrés $\hat{\beta}$ est normal et vérifie

$$\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2 (X^\top X)^{-1}).$$

Comme σ^2 est inconnue, elle est estimée – de façon **non biaisée** – par

$$\hat{\sigma}^2 = \frac{1}{n - p - 1} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

où p désigne le nombre de paramètres (ici $p = 2$). Il en résulte que, pour chaque coefficient β_j , la statistique

$$\frac{\hat{\beta}_j - \beta_j}{\widehat{\text{se}}(\hat{\beta}_j)}$$

suit une loi de Student à $n - p$ degrés de liberté, avec :

$$\widehat{\text{se}}(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 [(X^\top X)^{-1}]_{jj}}.$$

Un intervalle de confiance à niveau $1 - \alpha$ s'écrit donc

$$\text{IC}_{1-\alpha}(\beta_j) = \left[\hat{\beta}_j - t_{1-\alpha/2, n-p} \widehat{\text{se}}(\hat{\beta}_j), \hat{\beta}_j + t_{1-\alpha/2, n-p} \widehat{\text{se}}(\hat{\beta}_j) \right],$$

où $t_{1-\alpha/2, n-p}$ est le quantile d'ordre $1 - \alpha/2$ de la loi de Student à $n - p$ degrés de liberté.

Ces intervalles de confiance nécessitent principalement les hypothèses suivantes :

- la relation linéaire du modèle et l'inclusion d'un terme d'erreur additif;
- l'indépendance des erreurs ;
- l'homoscedasticité : $\text{Var}(\varepsilon_i) = \sigma^2$ constante ;
- la normalité des erreurs, indispensable pour obtenir des intervalles *exactement* basés sur la loi de Student (sinon, l'argument est asymptotique).

Le modèle est jugé significatif au sens du test sur la pente si l'intervalle de confiance de β_1 ne contient pas 0. Dans ce cas, on rejette

$$H_0 : \beta_1 = 0$$

au seuil $\alpha = 5\%$, et on conclut que X a un effet linéaire statistiquement significatif sur Y .

5.3) Que représente le tableau des coefficients ? Le tableau `Coefficients` fourni par `summary(model)` synthétise l'estimation et l'inférence statistique associées aux paramètres du modèle de régression linéaire.

- **Estimate** correspond à l'estimation des coefficients du modèle ($\hat{\beta}_0$ et $\hat{\beta}_1$).
- **Std. Error** mesure l'incertitude associée à chaque estimation, via l'écart-type estimé de l'estimateur.
- **t value** est la statistique de test utilisée pour tester l'hypothèse nulle $H_0 : \beta = \beta^{(0)}$ (en général $\beta^{(0)} = 0$), définie par

$$t = \frac{\hat{\beta} - \beta^{(0)}}{\widehat{\text{se}}(\hat{\beta})}.$$

- **Pr(>|t|)** est la p-value associée au test. Dans notre cas, la p-value associée au coefficient **speed** est extrêmement faible (1.49×10^{-12}), ce qui conduit à **rejeter** sans ambiguïté l'hypothèse $H_0 : \beta_1 = 0$. La vitesse a donc un effet statistiquement significatif sur la distance de freinage.

5.4) Quelles métriques globales regarder ? Le résumé du modèle fournit également plusieurs indicateurs globaux permettant d'évaluer la qualité de l'ajustement.

- L'erreur standard des résidus vaut **15.38**, indiquant que l'erreur typique de prédiction du modèle est de l'ordre de 15 pieds.
- Le coefficient de détermination vaut $R^2 = 0.6511$, ce qui signifie qu'environ **65 %** de la variabilité observée de la distance de freinage est expliquée **linéairement** par la vitesse. Par définition, le coefficient de détermination s'écrit

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2},$$

où $\hat{y}_i$ désigne la valeur prédite par le modèle et $\bar{y}$ la moyenne empirique des observations.

- Le R^2 ajusté, égal à **0.6438**, est très proche du R^2 , ce qui est attendu pour un modèle simple à une seule variable explicative. Il est défini par

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1},$$

où n est le nombre d'observations et p le nombre de variables explicatives. Ce critère pénalise les modèles trop complexes.

- La statistique de Fisher vaut **89.57**, avec une p-value associée de 1.49×10^{-12} , confirmant que le modèle est globalement statistiquement significatif.

Remarque (test global de Fisher). Le test de Fisher permet d'évaluer la significativité globale du modèle de régression linéaire. L'hypothèse nulle associée à ce test est

$$H_0 : \beta_1 = 0,$$

c'est-à-dire l'absence de relation linéaire entre la variable explicative (**speed**) et la variable réponse (**dist**). Sous l'hypothèse nulle, la statistique de test suit une loi de Fisher,

$$F \sim \mathcal{F}(p - 1, n - p),$$

où n désigne le nombre d'observations et $p = 2$ le nombre de paramètres (intercepte et coefficient directeur).

La p-value associée est ensuite comparée à un seuil (usuellement, $\alpha = 5\%$) pour conclure qu'il existe une relation linéaire non nulle entre la vitesse et la distance de freinage (p-value $< \alpha$) ; ou pas (p-value $> \alpha$).

Lecture du coefficient de détermination. En pratique, un coefficient de détermination R^2 compris entre 0.5 et 0.7 est généralement considéré comme **plutôt bon** pour un modèle linéaire en sciences expérimentales, tandis qu'un R^2 supérieur à 0.8 est souvent jugé **très bon**. Ces seuils restent toutefois indicatifs et doivent toujours être interprétés en tenant compte du contexte et de la variabilité intrinsèque des données.


5.5) Conclusion Le modèle de régression linéaire met en évidence une relation claire et statistiquement significative entre la vitesse et la distance de freinage. Il explique une part substantielle de la variabilité observée, tout en laissant subsister une dispersion non négligeable autour de la droite de régression. Il constitue ainsi une première approximation pertinente, sans prétendre décrire parfaitement le phénomène étudié.

Question 6 – Analyse des résidus (TP + TD)


6.1) Scatter plot, droite régressive et résidus. Objectif : visualiser la droite ajustée et les résidus $\varepsilon_i = y_i - \hat{y}_i$ comme distances verticales.

Commentaire attendu

- Les segments violets représentent l'erreur de prédiction (résidu) pour chaque point.
- Si beaucoup de segments sont longs dans certaines zones de **speed**, cela peut suggérer une variance non constante (hétéroscédasticité).



6.2) Histogramme des résidus L'histogramme des résidus montre une distribution empirique que l'on peut juger à l'œil comme étant gaussienne, centrée en zéro. Les hypothèses sur les résidus semblent respectées.



6.3) Résidus centrés ? Attendu : la moyenne des résidus est proche de 0 (propriété des moindres carrés avec intercepte). On peut vérifier :

```
> mean(res)
[1] 8.65974e-17
```

Afin de vérifier rigoureusement si la moyenne des résidus est statistiquement différente de zéro, on peut effectuer un test de Student à un échantillon, en testant l'hypothèse nulle

$$H_0 : \mathbb{E}[\varepsilon] = 0 \quad \text{contre} \quad H_1 : \mathbb{E}[\varepsilon] \neq 0.$$

Le test s'écrit sous la forme

$$t = \frac{\bar{\varepsilon}}{s_{\varepsilon}/\sqrt{n}},$$

où s_{ε} désigne l'écart-type empirique des résidus et n le nombre d'observations.

On implémente ce test dans R à l'aide de la fonction `t.test` :

```
# Test de Student : moyenne des résidus nulle ?
t.test(res, mu = 0)
```

Ceci renvoie :

```
> t.test(res, mu = 0)

One Sample t-test

data:  res
t = 4.0227e-17, df = 49, p-value = 1
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -4.326  4.326
sample estimates:
```

```
mean of x
8.65974e-17
```


Par conséquent, on ne rejette pas l'hypothèse nulle au seuil usuel de 5% (*ni à aucun seuil raisonnable d'ailleurs...*). **L'intervalle de confiance à 95%** pour la moyenne des résidus est donné par

$$[-4.326; 4.326],$$

et **contient largement la valeur 0**, ce qui confirme ce résultat. On conclut donc que la moyenne des résidus n'est pas significativement différente de zéro. Cette conclusion est parfaitement cohérente avec la théorie des moindres carrés : en présence d'un intercepte, les résidus sont nécessairement centrés (à des erreurs d'arrondi numérique près).

6.4) Compatibilité avec la normalité ? L'histogramme donne une indication grossière. Un diagnostic plus informatif (optionnel) est le QQ-plot :

```
qqnorm(res, main = "QQ-plot des résidus")
qqline(res, col = "red", lwd = 2)
```



Le QQ-plot des résidus montre un alignement globalement satisfaisant des points le long de la droite théorique, ce qui suggère que l'hypothèse de normalité des résidus est raisonnable. On observe toutefois de légers écarts dans les queues de distribution, en particulier pour les valeurs extrêmes, indiquant une déviation modérée par rapport à la normalité parfaite, mais cela ne remet pas vraiment en cause l'utilisation du modèle linéaire dans ce cadre introductif.

6.5) Conclusion sur les hypothèses Points à conclure :

- Centrage : généralement OK (résidus centrés).
- Normalité : semble OK (à juger avec histogramme et aussi QQ-plot, pour être rigoureux).
- Homoscedasticité : à discuter (si la dispersion des résidus augmente avec **speed**).
- Conclusion : le modèle linéaire est un bon premier niveau, mais certaines hypothèses peuvent être approximatives.

Code R Exercice 1

```
# CORRECTION -- EXERCICE 1 : RÉGRESSION LINÉAIRE SIMPLE ####

# 1. Chargement du jeu de données
data(cars)

# 2. Construction explicite du data frame de travail
df <- data.frame(
  speed = cars$speed,
  dist  = cars$dist
)

# 3. Statistique descriptive du jeu de données
str(df)
summary(df)

# 4. Histogrammes des variables
par(mfrow = c(1, 2))

hist(df$speed,
     breaks = 10,
     main   = "Histogramme de la vitesse",
     xlab   = "Vitesse (mph)",
     col    = "lightgray")

hist(df$dist,
     breaks = 10,
     main   = "Histogramme de la distance de freinage",
     xlab   = "Distance de freinage (ft)",
     col    = "darkgreen")

# 5. Nuage de points : distance en fonction de la vitesse
par(mfrow = c(1, 1))

plot(df$speed, df$dist,
     pch = 19,
     col = "darkgreen",
     xlab = "Vitesse (mph)",
     ylab = "Distance de freinage (ft)",
     main = "Distance de freinage en fonction de la vitesse")

# 6. Ajustement du modèle de régression linéaire
model <- lm(dist ~ speed, data = df)

# 7. Résumé global du modèle
summary(model)

# 8. Visualisation : points, droite de régression et résidus
# Droite de régression
abline(model, col = "red", lwd = 2)
```

```

# Résidus (distances verticales à la droite)
segments(x0 = df$speed,
          y0 = fitted(model),
          x1 = df$speed,
          y1 = df$dist,
          col = "purple",
          lty = 2)

# Légende
legend("topleft",
       legend = c("Observations", "Droite de régression", "Résidus"),
       col = c("darkgreen", "red", "purple"),
       pch = c(19, NA, NA),
       lty = c(NA, 1, 2),
       lwd = c(NA, 2, 1),
       bty = "n")

# 9. Analyse des résidus
res <- residuals(model)

hist(res,
      breaks = 10,
      main = "Histogramme des résidus",
      xlab = "Résidus",
      col = "purple")

# Vérification du centrage des résidus
mean(res)

# Test de Student : moyenne des résidus nulle ?
t.test(res, mu = 0)

# Diagnostic de normalité : QQ-plot
qqnorm(res, main = "QQ-plot des résidus")
qqline(res, col = "red", lwd = 2)

```

———— Fin Correction Exercice 1 ————

Correction Exercice 2

On étudie la relation entre le temps d'attente X (variable **waiting**, en minutes) et la durée d'éruption Y (variable **eruptions**, en minutes) à l'aide d'un modèle de régression linéaire simple. On dispose de $n = 272$ observations.

1) Statistique descriptive Le résumé statistique indique que X varie entre 43 et 96 minutes, avec une médiane 76 et une moyenne 70.9. La variable Y varie entre 1.6 et 5.1 minutes, avec une médiane 4.0 et une moyenne 3.488. Ces ordres de grandeur confirment que l'on travaille sur des variables quantitatives continues, avec une dispersion non négligeable.

2) Visualisation (scatter plot) Le nuage de points (X, Y) met en évidence une tendance croissante nette : lorsque le temps d'attente augmente, la durée de l'éruption suivante tend à augmenter, ce qui justifie l'étude d'un modèle linéaire comme première approximation de la relation moyenne $E[Y | X]$.

3) Modèle, coefficients estimés et intervalle de confiance On considère le modèle linéaire

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

où les erreurs satisfont les hypothèses usuelles du modèle linéaire (indépendance, centrage conditionnel, variance constante, et normalité pour l'inférence exacte).

Les estimations obtenues sont

$$\hat{\beta}_0 = -1.874 \quad \text{et} \quad \hat{\beta}_1 = 0.07563.$$

Ainsi, le modèle ajusté s'écrit

$$\hat{Y} = -1.874 + 0.07563 X.$$

L'interprétation de la pente est directe : une augmentation de 1 minute du temps d'attente est associée, en moyenne, à une augmentation d'environ 0.0756 minute de la durée de l'éruption, soit environ 4.54 secondes. L'intercepte $\hat{\beta}_0$ correspond à la valeur prédite pour $X = 0$, ce qui est hors du domaine des données ; il s'agit d'un paramètre d'ajustement.

L'intervalle de confiance à 95 % du coefficient de pente est

$$IC_{0.95}(\beta_1) = [0.07126; 0.079996].$$

Cet intervalle ne contient pas 0, ce qui implique que l'hypothèse

$$H_0 : \beta_1 = 0$$

est rejetée au seuil de 5 %. On conclut donc que **l'effet linéaire de X sur Y est statistiquement significatif**.

4) Validité du modèle : résidus et indicateurs globaux L'écart-type résiduel (erreur standard des résidus) vaut

$$\hat{\sigma} = 0.4965,$$

ce qui signifie qu'en moyenne l'erreur de prédiction du modèle est de l'ordre de 0.5 minute (environ 30 secondes), en unités de Y .

La proportion de variabilité expliquée linéairement par X est donnée par le(s) coefficient(s) de détermination

$$R^2 = 0.8115, \quad R_{\text{adj}}^2 = 0.8108.$$

Environ 81 % de la variabilité observée de la durée des éruptions est expliquée par une relation linéaire avec le temps d'attente. Le R^2 ajusté est très proche de R^2 , ce qui est attendu dans un modèle à une seule variable explicative.

Enfin, le test global de Fisher fournit une statistique

$$F = 1162,$$

avec une p-value $< 2.2 \times 10^{-16}$. On rejette donc très nettement l'hypothèse nulle globale de non-explicativité du modèle, ce qui confirme à nouveau que la pente est non nulle et que le modèle est globalement significatif.

5) Conclusion Les résultats montrent un effet linéaire très marqué du temps d'attente sur la durée d'éruption : la pente estimée est positive et hautement significative, et son intervalle de confiance à 95 % est strictement positif. Le modèle explique une proportion élevée de la variabilité des données ($R^2 \approx 0.81$), et l'erreur typique de prédiction est d'environ 0.5 minute. On conclut donc que le modèle linéaire fournit une description satisfaisante de la relation observée, et que l'effet de X sur Y est statistiquement significatif.

Code R Exercice 2

```
# CORRECTION -- EXERCICE 2 : RÉGRESSION LINÉAIRE SIMPLE ####

# 1. Chargement du jeu de données
data(faithful)

# Construction explicite du data frame de travail
df <- data.frame(
  waiting = faithful$waiting,
  eruptions = faithful$eruptions
)

# 2. Statistique descriptive du jeu de données
str(df)
summary(df)

# Histogrammes des variables
par(mfrow = c(1, 2))

hist(df$waiting,
     breaks = 15,
     main = "Histogramme du temps d'attente",
     xlab = "Temps d'attente (min)",
     col = "lightgray")

hist(df$eruptions,
     breaks = 15,
     main = "Histogramme de la durée des éruptions",
     xlab = "Durée des éruptions (min)",
     col = "darkgreen")

# 3. Visualisation bivariée : scatter plot
par(mfrow = c(1, 1))

plot(df$waiting, df$eruptions,
     pch = 19,
     col = "darkgreen",
     xlab = "Temps d'attente (min)",
     ylab = "Durée des éruptions (min)",
     main = "Durée des éruptions en fonction du temps d'attente")

# 4. Ajustement du modèle de régression linéaire
model <- lm(eruptions ~ waiting, data = df)

# Résumé global du modèle
summary(model)

# 5. Intervalles de confiance à 95 % des coefficients
confint(model, level = 0.95)
```

```

# 6. Visualisation : points, droite de régression et résidus
plot(df$waiting, df$eruptions,
     pch = 19,
     col = "darkgreen",
     xlab = "Temps d'attente (min)",
     ylab = "Durée des éruptions (min)",
     main = "Régression linéaire : eruptions ~ waiting")

# Droite de régression
abline(model, col = "red", lwd = 2)

# Résidus (distances verticales à la droite)
segments(x0 = df$waiting,
         y0 = fitted(model),
         x1 = df$waiting,
         y1 = df$eruptions,
         col = "purple",
         lty = 2)

# Légende
legend("topleft",
      legend = c("Observations", "Droite de régression", "Résidus"),
      col = c("darkgreen", "red", "purple"),
      pch = c(19, NA, NA),
      lty = c(NA, 1, 2),
      lwd = c(NA, 2, 1),
      bty = "n")

# 7. Analyse des résidus
res <- residuals(model)

# Histogramme des résidus
hist(res,
     breaks = 15,
     main = "Histogramme des résidus",
     xlab = "Résidus",
     col = "purple")

# Vérification du centrage des résidus
mean(res)

# Test de Student : moyenne des résidus nulle ?
t.test(res, mu = 0)

# Diagnostic de normalité : QQ-plot
qqnorm(res, main = "QQ-plot des résidus")
qqline(res, col = "red", lwd = 2)

```


Correction Exercice 3

Il s'agit d'un exercice hors programme mais très formateur qui justifie le caractère aléatoire de l'estimateur $\hat{\beta}_1$ (conditionnellement à X) pour une régression linéaire simple. On calcule ici son espérance et sa variance, et on se doit de connaître un peu le calcul d'espérance conditionnel avec ses propriétés phares pour finaliser l'exercice.

Cadre du modèle, notations et hypothèses. On observe $(X_i, Y_i)_{1 \leq i \leq n}$ et l'on considère le modèle de régression linéaire simple

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n. \quad (1.1)$$

On se place dans le cadre classique de l'OLS (moindres carrés ordinaires) avec *design fixé* : on raisonne **conditionnellement à $X = (X_1, \dots, X_n)$** . Les hypothèses usuelles sur le bruit, conditionnellement à X , sont :

$$\mathbb{E}[\varepsilon_i | X] = 0, \quad \text{Var}(\varepsilon_i | X) = \sigma^2, \quad \text{Cov}(\varepsilon_i, \varepsilon_j | X) = 0 \quad (i \neq j). \quad (1.2)$$

On note

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i, \quad S_{xx} = \sum_{i=1}^n (X_i - \bar{X})^2.$$

On suppose $S_{xx} > 0$ (i.e. les X_i ne sont pas tous égaux), afin que l'estimateur de pente soit bien défini.

Expression de $\hat{\beta}_1$ comme quotient de covariance et variance empiriques. L'estimateur OLS de la pente β_1 (avec intercept) s'écrit

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\widehat{\text{Cov}}(X, Y)}{\widehat{\text{Var}}(X)}. \quad (1.3)$$

La dernière écriture correspond aux versions empiriques de covariance et variance (à un facteur n ou $n - 1$ près, qui se simplifie dans le quotient).

Question 1) Linéarité en ε conditionnellement à X . On démontre ci-dessous une représentation fondamentale : *conditionnellement à X , l'estimateur $\hat{\beta}_1$ est une quantité affine en $(\varepsilon_1, \dots, \varepsilon_n)$.*

Proposition 1.0.1 (Représentation linéaire de $\hat{\beta}_1$). *Sous le modèle $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$, on a, conditionnellement à X ,*

$$\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (X_i - \bar{X}) \varepsilon_i}{S_{xx}}. \quad (1.4)$$

En particulier,

$$\mathbb{E}[\hat{\beta}_1 | X] = \beta_1.$$

Preuve. On part de (1.3) et on remplace Y_i par sa décomposition :

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

On a

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i = \beta_0 + \beta_1 \bar{X} + \bar{\varepsilon}, \quad \text{où } \bar{\varepsilon} = \frac{1}{n} \sum_{i=1}^n \varepsilon_i.$$

Donc

$$Y_i - \bar{Y} = \beta_1 (X_i - \bar{X}) + (\varepsilon_i - \bar{\varepsilon}).$$

En multipliant par $(X_i - \bar{X})$ et en sommant :

$$\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \beta_1 \sum_{i=1}^n (X_i - \bar{X})^2 + \sum_{i=1}^n (X_i - \bar{X})(\varepsilon_i - \bar{\varepsilon}).$$

Or

$$\sum_{i=1}^n (X_i - \bar{X})\bar{\varepsilon} = \bar{\varepsilon} \sum_{i=1}^n (X_i - \bar{X}) = \bar{\varepsilon}(n\bar{X} - n\bar{X}) = 0,$$

d'où

$$\sum_{i=1}^n (X_i - \bar{X})(\varepsilon_i - \bar{\varepsilon}) = \sum_{i=1}^n (X_i - \bar{X})\varepsilon_i.$$

Ainsi,

$$\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \beta_1 S_{xx} + \sum_{i=1}^n (X_i - \bar{X})\varepsilon_i.$$

En divisant par S_{xx} , on obtient bien (1.4) :

$$\boxed{\hat{\beta}_1 = \beta_1 + \frac{\sum_{i=1}^n (X_i - \bar{X}) \varepsilon_i}{S_{xx}}}.$$

Question 2) Espérance de l'estimateur. Par linéarité de l'espérance, on obtient facilement :

$$\mathbb{E}[\hat{\beta}_1 \mid X] = \beta_1 + \frac{\sum_{i=1}^n (X_i - \bar{X}) \mathbb{E}[\varepsilon_i \mid X]}{S_{xx}} = \boxed{\beta_1},$$

car $\mathbb{E}[\varepsilon_i \mid X] = 0$. □

Question 3) Variance conditionnelle $\text{Var}(\hat{\beta}_1 \mid X)$. À partir de (1.4), on a

$$\text{Var}(\hat{\beta}_1 \mid X) = \text{Var}\left(\frac{\sum_{i=1}^n (X_i - \bar{X})\varepsilon_i}{S_{xx}} \mid X\right) = \frac{1}{S_{xx}^2} \text{Var}\left(\sum_{i=1}^n (X_i - \bar{X})\varepsilon_i \mid X\right).$$

En utilisant l'absence de corrélation conditionnelle et l'homoscédasticité $\text{Var}(\varepsilon_i \mid X) = \sigma^2$:

$$\text{Var}\left(\sum_{i=1}^n a_i \varepsilon_i \mid X\right) = \sum_{i=1}^n a_i^2 \text{Var}(\varepsilon_i \mid X) = \sigma^2 \sum_{i=1}^n a_i^2,$$

avec $a_i = X_i - \bar{X}$, par propriété sur les espérances conditionnelles¹. Par conséquent,

$$\text{Var}(\hat{\beta}_1 \mid X) = \frac{\sigma^2 \sum_{i=1}^n (X_i - \bar{X})^2}{S_{xx}^2} = \boxed{\frac{\sigma^2}{S_{xx}}}. \quad (1.5)$$

Question 4) Erreur standard en pratique : estimation de σ^2 . En pratique, σ^2 est inconnu. On l'estime par l'estimateur (non biaisé)

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{\varepsilon}_i^2, \quad \text{où } \hat{\varepsilon}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i. \quad (1.6)$$

1. Si $f(X)$ est une construction mesurable de X et Z une variable aléatoire indépendante de X , alors on a l'égalité $\text{Var}(f(X)Z \mid X) = f(X)^2 \text{Var}(Z)$.

En combinant (1.5) et (1.6), on obtient l'estimation usuelle de l'erreur standard :

$$\widehat{\text{se}}(\hat{\beta}_1) = \sqrt{\frac{\hat{\sigma}^2}{S_{xx}}}. \quad (1.7)$$

Cette quantité est celle qui intervient dans la statistique de Student $T = \frac{\hat{\beta}_1 - \beta_1}{\widehat{\text{se}}(\hat{\beta}_1)}$.

Question 5) Intervalle de confiance associé. On considère la statistique pivot

$$T = \frac{\hat{\beta}_1 - \beta_1}{\widehat{\text{se}}(\hat{\beta}_1)}.$$

Par hypothèse, on admet que

$$T \sim \text{St}(n-2).$$

Brève justification : Sous l'hypothèse de normalité des erreurs, $\hat{\beta}_1$ est une combinaison linéaire de variables normales indépendantes, comme exprimée en (1.4), d'où

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\sigma^2/S_{xx}}} \sim \mathcal{N}(0, 1).$$

De plus, en régression linéaire simple avec intercepte, la somme des carrés des résidus est une somme de carrés de variables normales indépendantes – vu en équation (1.6) –, ce qui implique

$$\frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-2).$$

Enfin, on peut justifier pour des erreurs gaussiennes que $\hat{\beta}_1$ et $\hat{\sigma}^2$ sont indépendants ! Par conséquent, la statistique

$$T = \frac{\hat{\beta}_1 - \beta_1}{\widehat{\text{se}}(\hat{\beta}_1)}$$

suit une loi de Student à $n-2$ degrés de liberté.

Soit $t_{1-\frac{\alpha}{2}}$ le quantile d'ordre $1-\alpha/2$ de la loi de Student à $n-2$ degrés de liberté (*l'écriture du terme $(n-2)$ est omis ici car il n'y aucune amabilité*). Par symétrie de la loi de Student,

$$\mathbb{P}(-t_{1-\frac{\alpha}{2}} \leq T \leq t_{1-\frac{\alpha}{2}} \mid X) = 1 - \alpha.$$

En remplaçant T par son expression, on obtient

$$\mathbb{P}\left(-t_{1-\frac{\alpha}{2}} \leq \frac{\hat{\beta}_1 - \beta_1}{\widehat{\text{se}}(\hat{\beta}_1)} \leq t_{1-\frac{\alpha}{2}} \mid X\right) = 1 - \alpha.$$

Comme $\widehat{\text{se}}(\hat{\beta}_1) > 0$, on peut multiplier l'inégalité par $\widehat{\text{se}}(\hat{\beta}_1)$ puis isoler β_1 :

$$\mathbb{P}\left(\hat{\beta}_1 - t_{1-\frac{\alpha}{2}} \widehat{\text{se}}(\hat{\beta}_1) \leq \beta_1 \leq \hat{\beta}_1 + t_{1-\frac{\alpha}{2}} \widehat{\text{se}}(\hat{\beta}_1) \mid X\right) = 1 - \alpha.$$

On en déduit l'intervalle de confiance bilatéral de niveau $1-\alpha$:

$$\boxed{\text{IC}_{1-\alpha}(\beta_1) = \left[\hat{\beta}_1 - t_{1-\frac{\alpha}{2}} \widehat{\text{se}}(\hat{\beta}_1), \hat{\beta}_1 + t_{1-\frac{\alpha}{2}} \widehat{\text{se}}(\hat{\beta}_1) \right]}.$$

Chapitre 2

TD2 - Régression linéaire multiple

Correction – Exercice 1

On considère le modèle de régression linéaire multiple

$$Y = \beta_0 + \beta_1 X^{(1)} + \beta_2 X^{(2)} + \varepsilon, \quad (2.1)$$

où ε est un terme d'erreur centré. On note $n = 10$.

1. Ajustement du modèle multiple.

a) **Matrice de design.** On introduit le vecteur réponse

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

La matrice de design associée au modèle (2.1) est

$$\mathbb{X} = \begin{pmatrix} 1 & X_1^{(1)} & X_1^{(2)} \\ \vdots & \vdots & \vdots \\ 1 & X_n^{(1)} & X_n^{(2)} \end{pmatrix} \in \mathbb{R}^{n \times 3}.$$

L'écriture matricielle du modèle est alors :

$$\mathbf{Y} = \mathbb{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

L'estimateur des moindres carrés s'écrit (lorsque $\mathbb{X}^\top \mathbb{X}$ est inversible)

$$\hat{\boldsymbol{\beta}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y}.$$

b) Interprétation des coefficients.

- β_1 mesure l'effet moyen de $X^{(1)}$ sur la note Y à distance $X^{(2)}$ fixée : si $X^{(1)}$ augmente d'une unité (ici, une minute), alors Y varie en moyenne de β_1 points.
- β_2 mesure l'effet moyen de $X^{(2)}$ sur la note Y à temps de travail $X^{(1)}$ fixé : si la distance augmente d'un km, alors Y varie en moyenne de β_2 points.
- β_0 est l'ordonnée à l'origine (valeur moyenne de Y lorsque $X^{(1)} = X^{(2)} = 0$), interprétation parfois uniquement technique selon le contexte.

c) Significativité des coefficients.

Les résultats issus de R (tableau 1) montrent que :

- le coefficient associé à $X^{(1)}$ est hautement significatif (p-value = 9.22×10^{-8}), ce qui indique une relation linéaire nette entre le temps de travail et la note ;
- le coefficient associé à $X^{(2)}$ n'est pas significatif au seuil usuel de 5% (p-value = 0.215), ce qui signifie que, dans ce jeu de données, l'effet de la distance n'est pas mis en évidence une fois l'effet de $X^{(1)}$ pris en compte.

De plus, le test global de Fisher est très significatif ($p\text{-value} = 2.807 \times 10^{-7}$), indiquant qu'au moins une variable explicative contribue à expliquer Y .

2. **Intervalles de confiance.** D'après les intervalles fournis :

$$\text{IC}_{0.95}(\beta_1) = [0.0112; 0.0139], \quad \text{IC}_{0.95}(\beta_2) = [-1.9845; 7.3886].$$

- a) On a $0 \notin \text{IC}_{0.95}(\beta_1)$, tandis que $0 \in \text{IC}_{0.95}(\beta_2)$.
- b) On en déduit que l'effet de $X^{(1)}$ est statistiquement non nul (au niveau 5%), alors que l'effet de $X^{(2)}$ n'est pas détecté : l'ajout de $X^{(2)}$ n'est pas justifié du point de vue de l'inférence sur les coefficients.

3. **Ajustement du modèle réduit.** On considère le modèle

$$Y = \beta_0 + \beta_1 X^{(1)} + \varepsilon. \quad (1\text{-M2})$$

soit

$$\mathbf{Y} = \mathbb{X}_{\text{red}} \boldsymbol{\beta}_{\text{red}} + \boldsymbol{\varepsilon},$$

avec

$$\boldsymbol{\beta}_{\text{red}} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \quad \mathbb{X}_{\text{red}} = \begin{pmatrix} 1 & X_1^{(1)} \\ \vdots & \vdots \\ 1 & X_n^{(1)} \end{pmatrix} \in \mathbb{R}^{n \times 2}.$$

- a) **Comparaison des estimations de β_1 .** On obtient $\hat{\beta}_1 = 0.0125$ dans le modèle multiple et $\hat{\beta}_1 = 0.0126$ dans le modèle réduit. Les valeurs sont très proches : l'ajout de $X^{(2)}$ ne modifie pratiquement pas l'estimation de l'effet de $X^{(1)}$.
- b) **Comparaison de R^2 et R_{adj}^2 .** On observe une légère amélioration des indicateurs d'ajustement dans le modèle multiple :

$$R_{\text{mult}}^2 = 0.9866 > R_{\text{red}}^2 = 0.9830, \quad R_{\text{adj,mult}}^2 = 0.9827 > R_{\text{adj,red}}^2 = 0.9809.$$

Cela est cohérent : ajouter une variable explicative peut améliorer l'ajustement, même si cette variable n'est pas significative individuellement.

4. **Comparaison des modèles.**

- a) Les critères indiquent :

$$\text{AIC}_{\text{mult}} = 18.840 < \text{AIC}_{\text{red}} = 19.195, \quad \text{BIC}_{\text{mult}} = 20.051 < \text{BIC}_{\text{red}} = 20.103,$$

et les coefficients de détermination sont légèrement meilleurs pour le modèle multiple.

- b) Néanmoins, la variable $X^{(2)}$ n'étant pas significative ($p\text{-value} = 0.215$ et intervalle de confiance contenant 0), le gain d'ajustement reste marginal et l'interprétation se complique.
- c) **Choix recommandé.** Par principe de parcimonie, on privilégie le modèle réduit (1-M2), plus simple, plus interprétable et plus stable, puisque la contribution de $X^{(2)}$ n'est pas établie.

Discussion et conclusion. On rappelle que le coefficient de détermination s'écrit

$$R^2 = 1 - \frac{\sum_{i=1}^n \hat{\varepsilon}_i^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}.$$

Par construction, l'ajout d'une variable explicative ne peut qu'améliorer (ou laisser inchangée) l'ajustement du modèle (*le modèle réduit n'est qu'un cas particulier du modèle multiple pour $\beta_2 = 0$*), et donc augmenter R^2 , même si cette variable n'est pas pertinente. Le coefficient de détermination ajusté,

$$R_{\text{adj}}^2 = 1 - \frac{n-1}{n-p} (1 - R^2),$$

introduit une pénalisation liée au nombre de paramètres estimés p , mais celle-ci peut rester insuffisante lorsque le gain d'ajustement compense la complexité supplémentaire.

De même, les critères d'information

$$\text{AIC} = -2\ell(\hat{\theta}) + 2p, \quad \text{BIC} = -2\ell(\hat{\theta}) + p \log n,$$

opèrent un compromis entre qualité d'ajustement et complexité du modèle. Dans un contexte de faible taille d'échantillon, la pénalisation associée à l'ajout d'une variable peut demeurer modérée, ce qui explique que le modèle multiple présente ici des valeurs de AIC et BIC légèrement plus faibles.

Il est toutefois essentiel de souligner que la significativité d'un coefficient répond à une question différente de celle de la qualité globale du modèle : un coefficient peut ne pas être significativement différent de zéro tout en améliorant marginalement l'ajustement global. Enfin, le principe de parcimonie demeure central en modélisation statistique : à qualité d'ajustement comparable, on privilégie le modèle le plus simple, le plus interprétable et le plus stable. Ainsi, bien que le modèle multiple présente des indicateurs d'ajustement légèrement supérieurs et des critères d'information plus faibles, la variable $X^{(2)}$ reste néanmoins non significative, ce qui conduit à préférer le modèle réduit.

Correction – Exercice 2

On rappelle le modèle de régression linéaire multiple :

$$\mathbf{Y} = \mathbb{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (2.2)$$

où $\mathbb{X} \in \mathbb{R}^{n \times (p+1)}$, $\boldsymbol{\beta} \in \mathbb{R}^{(p+1) \times 1}$, $\mathbf{Y} \in \mathbb{R}^{n \times 1}$ et $\boldsymbol{\varepsilon} \in \mathbb{R}^{n \times 1}$.

1. Expression de l'estimateur des moindres carrés.

Modèle des moindres carrés. On cherche un estimateur $\hat{\boldsymbol{\beta}}$ minimisant la somme des carrés des résidus :

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= \underset{\boldsymbol{\beta}}{\operatorname{argmin}} \left\{ \sum_{i=1}^n (Y_i - (\mathbb{X}\boldsymbol{\beta})_i)^2 \right\} \\ &= \underset{\boldsymbol{\beta}}{\operatorname{argmin}} \{ \|\mathbf{Y} - \mathbb{X}\boldsymbol{\beta}\|_2^2 \}. \end{aligned}$$

Fonction objective. On introduit la fonction

$$f(\mathbf{b}) = \|\mathbf{Y} - \mathbb{X}\mathbf{b}\|_2^2, \quad \mathbf{b} \in \mathbb{R}^{p+1},$$

où $\|\cdot\|_2$ désigne la norme euclidienne issue du produit scalaire usuel $\langle \cdot, \cdot \rangle$ sur $\mathbb{R}^n$.

On peut écrire

$$f(\mathbf{b}) = \langle \mathbf{Y} - \mathbb{X}\mathbf{b}, \mathbf{Y} - \mathbb{X}\mathbf{b} \rangle.$$

Convexité. La fonction f est une fonction quadratique en $\mathbf{b}$, de Hessienne $2\mathbb{X}^\top \mathbb{X}$, donc convexe (et strictement convexe si $\mathbb{X}^\top \mathbb{X}$ est définie positive, *i.e.* si $\mathbb{X}$ est de rang colonne plein).

Dérivée directionnelle. Soit $\mathbf{h} \in \mathbb{R}^{p+1}$ une direction arbitraire. La dérivée directionnelle de f en $\mathbf{b}$ selon $\mathbf{h}$ est

$$f'(\mathbf{b}; \mathbf{h}) = \lim_{t \rightarrow 0^+} \frac{f(\mathbf{b} + t\mathbf{h}) - f(\mathbf{b})}{t}.$$

Calculons $f(\mathbf{b} + t\mathbf{h})$:

$$\begin{aligned} f(\mathbf{b} + t\mathbf{h}) &= \|\mathbf{Y} - \mathbb{X}(\mathbf{b} + t\mathbf{h})\|_2^2 \\ &= \|\mathbf{Y} - \mathbb{X}\mathbf{b} - t\mathbb{X}\mathbf{h}\|_2^2 \\ &= \langle \mathbf{Y} - \mathbb{X}\mathbf{b} - t\mathbb{X}\mathbf{h}, \mathbf{Y} - \mathbb{X}\mathbf{b} - t\mathbb{X}\mathbf{h} \rangle. \end{aligned}$$

En utilisant la bilinéarité et la symétrie du produit scalaire, on obtient :

$$\begin{aligned} f(\mathbf{b} + t\mathbf{h}) &= \langle \mathbf{Y} - \mathbb{X}\mathbf{b}, \mathbf{Y} - \mathbb{X}\mathbf{b} \rangle - 2\langle \mathbf{Y} - \mathbb{X}\mathbf{b}, t\mathbb{X}\mathbf{h} \rangle + \langle t\mathbb{X}\mathbf{h}, t\mathbb{X}\mathbf{h} \rangle \\ &= \|\mathbf{Y} - \mathbb{X}\mathbf{b}\|_2^2 - 2t\langle \mathbf{Y} - \mathbb{X}\mathbf{b}, \mathbb{X}\mathbf{h} \rangle + t^2\|\mathbb{X}\mathbf{h}\|_2^2. \end{aligned}$$

On en déduit :

$$\begin{aligned} f'(\mathbf{b}; \mathbf{h}) &= \lim_{t \rightarrow 0^+} \frac{f(\mathbf{b} + t\mathbf{h}) - f(\mathbf{b})}{t} \\ &= \lim_{t \rightarrow 0^+} \frac{-2t \langle \mathbf{Y} - \mathbb{X}\mathbf{b}, \mathbb{X}\mathbf{h} \rangle + t^2 \|\mathbb{X}\mathbf{h}\|_2^2}{t} \\ &= \lim_{t \rightarrow 0^+} (-2 \langle \mathbf{Y} - \mathbb{X}\mathbf{b}, \mathbb{X}\mathbf{h} \rangle + t \|\mathbb{X}\mathbf{h}\|_2^2). \end{aligned}$$

En faisant tendre $t \rightarrow 0^+$, le second terme disparaît et l'on trouve :

$$f'(\mathbf{b}; \mathbf{h}) = -2 \langle \mathbf{Y} - \mathbb{X}\mathbf{b}, \mathbb{X}\mathbf{h} \rangle.$$

Condition d'optimalité. Si f est convexe, un point $\hat{\beta}$ est minimiseur global si et seulement si la dérivée directionnelle est nulle pour toute direction $\mathbf{h}$:

$$\forall \mathbf{h} \in \mathbb{R}^{p+1}, \quad f'(\hat{\beta}; \mathbf{h}) = 0.$$

Donc

$$\forall \mathbf{h} \in \mathbb{R}^{p+1}, \quad \langle \mathbf{Y} - \mathbb{X}\hat{\beta}, \mathbb{X}\mathbf{h} \rangle = 0.$$

Or

$$\langle \mathbf{Y} - \mathbb{X}\hat{\beta}, \mathbb{X}\mathbf{h} \rangle = (\mathbf{Y} - \mathbb{X}\hat{\beta})^\top (\mathbb{X}\mathbf{h}) = (\mathbb{X}^\top (\mathbf{Y} - \mathbb{X}\hat{\beta}))^\top \mathbf{h}.$$

La dernière quantité est un produit scalaire dans $\mathbb{R}^{p+1}$ entre $\mathbb{X}^\top (\mathbf{Y} - \mathbb{X}\hat{\beta})$ et $\mathbf{h}$. Si elle vaut 0 pour tout $\mathbf{h}$, alors nécessairement

$$\mathbb{X}^\top (\mathbf{Y} - \mathbb{X}\hat{\beta}) = \mathbf{0}.$$

On obtient ainsi les **équations normales** :

$$\mathbb{X}^\top \mathbf{Y} = \mathbb{X}^\top \mathbb{X} \hat{\beta}.$$

Expression explicite. Si $\mathbb{X}^\top \mathbb{X}$ est inversible, on conclut :

$$\boxed{\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y}}.$$

2. Cas $p = 1$: forme matricielle et formules de $\hat{\beta}_0, \hat{\beta}_1$.

Le modèle de régression linéaire simple est

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n.$$

Il s'écrit sous forme matricielle :

$$\mathbf{Y} = \mathbb{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

avec

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \quad \mathbb{X} = \begin{pmatrix} 1 & X_1 \\ 1 & X_2 \\ \vdots & \vdots \\ 1 & X_n \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}.$$

D'après la question 1, on a

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y}.$$

Calcul de $\mathbb{X}^\top \mathbb{X}$ et $\mathbb{X}^\top \mathbf{Y}$. On a

$$\mathbb{X}^\top \mathbb{X} = \begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n X_i \\ \sum_{i=1}^n X_i & \sum_{i=1}^n X_i^2 \end{pmatrix} = \begin{pmatrix} n & \sum_i X_i \\ \sum_i X_i & \sum_i X_i^2 \end{pmatrix},$$

et

$$\mathbb{X}^\top \mathbf{Y} = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n X_i Y_i \end{pmatrix} = \begin{pmatrix} \sum_i Y_i \\ \sum_i X_i Y_i \end{pmatrix}.$$

Inverse via comatrice. Pour une matrice 2×2 ,

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} \quad \text{si } ad - bc \neq 0.$$

Ici $a = n$, $b = \sum_i X_i$, $c = \sum_i X_i$, $d = \sum_i X_i^2$, donc

$$\det(\mathbb{X}^\top \mathbb{X}) = n \sum_i X_i^2 - \left(\sum_i X_i \right)^2.$$

Ainsi,

$$(\mathbb{X}^\top \mathbb{X})^{-1} = \frac{1}{n \sum_i X_i^2 - \left(\sum_i X_i \right)^2} \begin{pmatrix} \sum_i X_i^2 & -\sum_i X_i \\ -\sum_i X_i & n \end{pmatrix}.$$

Produit matriciel. On obtient

$$\begin{aligned} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} &= \frac{1}{n \sum_i X_i^2 - \left(\sum_i X_i \right)^2} \begin{pmatrix} \sum_i X_i^2 & -\sum_i X_i \\ -\sum_i X_i & n \end{pmatrix} \begin{pmatrix} \sum_i Y_i \\ \sum_i X_i Y_i \end{pmatrix} \\ &= \frac{1}{n \sum_i X_i^2 - \left(\sum_i X_i \right)^2} \begin{pmatrix} \left(\sum_i X_i^2 \right) \left(\sum_i Y_i \right) - \left(\sum_i X_i \right) \left(\sum_i X_i Y_i \right) \\ - \left(\sum_i X_i \right) \left(\sum_i Y_i \right) + n \left(\sum_i X_i Y_i \right) \end{pmatrix}. \end{aligned}$$

Donc

$$\boxed{\hat{\beta}_1 = \frac{n \sum_{i=1}^n X_i Y_i - \left(\sum_{i=1}^n X_i \right) \left(\sum_{i=1}^n Y_i \right)}{n \sum_{i=1}^n X_i^2 - \left(\sum_{i=1}^n X_i \right)^2}} \quad \text{et} \quad \boxed{\hat{\beta}_0 = \frac{\left(\sum_{i=1}^n X_i^2 \right) \left(\sum_{i=1}^n Y_i \right) - \left(\sum_{i=1}^n X_i \right) \left(\sum_{i=1}^n X_i Y_i \right)}{n \sum_{i=1}^n X_i^2 - \left(\sum_{i=1}^n X_i \right)^2}}.$$

Réécriture sous les formes usuelles. En notant $\bar{X} = \frac{1}{n} \sum_i X_i$ et $\bar{Y} = \frac{1}{n} \sum_i Y_i$, on vérifie l'identité :

$$n \sum_i X_i^2 - \left(\sum_i X_i \right)^2 = n \sum_{i=1}^n (X_i - \bar{X})^2.$$

De même,

$$n \sum_i X_i Y_i - \left(\sum_i X_i \right) \left(\sum_i Y_i \right) = n \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}).$$

On obtient donc la formule classique :

$$\boxed{\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}} \quad \text{et} \quad \boxed{\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}}.$$

———— Fin correction Exercice 2 ————

Correction – Exercice 3

On considère le modèle de régression linéaire multiple

$$Y_i = \beta_0 + \beta^\top X_i + \varepsilon_i, \quad i = 1, \dots, n, \quad (2.3)$$

où $X_i \in \mathbb{R}^p$, $\beta \in \mathbb{R}^p$ et $(\varepsilon_i)_{i=1}^n$ est un bruit centré, de variance σ^2 , non corrélé.

1. Réécriture du modèle par introduction de la constante 1.

L'objectif est de réécrire le modèle sous une forme purement linéaire, sans terme constant explicite. Pour cela, on introduit le vecteur étendu

$$\mathbf{X}_{i,*} = \begin{pmatrix} 1 \\ X_i \end{pmatrix} \in \mathbb{R}^{p+1}, \quad \beta_* = \begin{pmatrix} \beta_0 \\ \beta \end{pmatrix} \in \mathbb{R}^{p+1}.$$

On a alors

$$\beta_*^\top \mathbf{X}_{i,*} = \beta_0 + \beta^\top X_i,$$

et donc le modèle peut s'écrire

$$Y_i = \beta_*^\top \mathbf{X}_{i,*} + \varepsilon_i.$$

Sans perte de généralité, on supposera désormais que tous les modèles linéaires considérés sont de cette forme. Dans la suite, on notera simplement β au lieu de β_* .

En notation matricielle, en posant

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}, \quad \mathbb{X} = \begin{pmatrix} \mathbf{X}_{1,*}^\top \\ \vdots \\ \mathbf{X}_{n,*}^\top \end{pmatrix},$$

le modèle s'écrit

$$\mathbf{Y} = \mathbb{X}\beta + \boldsymbol{\varepsilon}. \quad (2.4)$$

2. Espérance de l'estimateur des moindres carrés.

Remarque. Dans cet exercice, on se place toujours et encore dans un scénario où la matrice de design $\mathbb{X}$ est supposée relevée (observée) et donc fixée. Ainsi, quand on applique les opérateurs d'espérance et de variance, on considère implicitement qu'ils sont conditionnés à $\mathbb{X}$: l'aléa provient uniquement du vecteur d'erreurs $\boldsymbol{\varepsilon}$.

Dans le modèle linéaire gaussien, l'estimateur des moindres carrés s'écrit

$$\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y},$$

supposant que $\mathbb{X}^\top \mathbb{X}$ est inversible. On calcule son espérance :

$$\mathbb{E}[\hat{\beta}] = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbb{E}[\mathbf{Y}].$$

Or, par le modèle,

$$\mathbf{Y} = \mathbb{X}\beta + \boldsymbol{\varepsilon},$$

et comme $\mathbb{E}[\boldsymbol{\varepsilon}] = \mathbf{0}$ (une des hypothèses donne que le bruit est centré), on a

$$\mathbb{E}[\mathbf{Y}] = \mathbb{X}\beta + \mathbb{E}[\boldsymbol{\varepsilon}] = \mathbb{X}\beta.$$

Ainsi,

$$\mathbb{E}[\hat{\beta}] = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbb{X}\beta = \beta.$$

$$\boxed{\mathbb{E}[\hat{\beta}] = \beta} \quad (2.5)$$

Interprétation : l'estimateur des moindres carrés est **sans biais**. Cela signifie qu'en moyenne, sur un grand nombre d'échantillons issus du même modèle, l'estimateur $\hat{\beta}$ restitue exactement la vraie valeur du paramètre β .

Cette propriété est **fondamentale en statistique**, car elle garantit que les écarts entre $\hat{\beta}$ et β sont uniquement dus à l'aléa d'échantillonnage, et non à un défaut intrinsèque de la méthode d'estimation !

3. **Matrice de covariance de $\hat{\beta}$.** Par abus de notation, on notera $\text{Var}(\hat{\beta})$ au lieu de $\text{Var}(\hat{\beta} \mid \mathbb{X})$.

Par définition,

$$\text{Var}(\hat{\beta}) = \mathbb{E}[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^\top].$$

Notez qu'il s'agit d'une matrice ici ! Explicitement, en l'écrivant en terme de covariance, on obtient :

$$\text{Var}(\hat{\beta}) = (\text{Cov}(\hat{\beta}_i, \hat{\beta}_j))_{1 \leq i, j \leq (p+1)} \in \mathbb{R}^{(p+1) \times (p+1)}.$$

On écrit

$$\begin{aligned} \hat{\beta} - \beta &= (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y} - \beta \\ &= (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top (\mathbb{X} \beta + \varepsilon) - \beta \\ &= \beta + (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \varepsilon - \beta \\ &= \boxed{(\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \varepsilon}. \end{aligned} \tag{2.6}$$

Par conséquent¹,

$$\text{Var}(\hat{\beta}) = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbb{E}[\varepsilon \varepsilon^\top] \mathbb{X} (\mathbb{X}^\top \mathbb{X})^{-1}.$$

Or $\text{Var}(\varepsilon) = \sigma^2 I_n$, donc

$$\mathbb{E}[\varepsilon \varepsilon^\top] = \sigma^2 I_n.$$

Ainsi,

$$\begin{aligned} \text{Var}(\hat{\beta}) &= \sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbb{X} (\mathbb{X}^\top \mathbb{X})^{-1} \\ &= \sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1}. \end{aligned}$$

$$\boxed{\text{Var}(\hat{\beta}) = \sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1}} \tag{2.7}$$

4. Cas de la régression linéaire simple.

On se place dans le cas $p = 1$. La matrice de design s'écrit alors

$$\mathbb{X} = \begin{pmatrix} 1 & X_1 \\ 1 & X_2 \\ \vdots & \vdots \\ 1 & X_n \end{pmatrix} \in \mathbb{R}^{n \times 2}.$$

Calcul explicite de $\mathbb{X}^\top \mathbb{X}$. On a

$$\mathbb{X}^\top \mathbb{X} = \begin{pmatrix} \sum_{i=1}^n 1 & \sum_{i=1}^n X_i \\ \sum_{i=1}^n X_i & \sum_{i=1}^n X_i^2 \end{pmatrix} = \begin{pmatrix} n & \sum_i X_i \\ \sum_i X_i & \sum_i X_i^2 \end{pmatrix}.$$

Son déterminant vaut

$$\det(\mathbb{X}^\top \mathbb{X}) = n \sum_{i=1}^n X_i^2 - \left(\sum_{i=1}^n X_i \right)^2 = n \sum_{i=1}^n (X_i - \bar{X})^2,$$

qui est strictement positif dès lors que les X_i ne sont pas tous égaux.

1. On utilise le fait que, pour toute matrice inversible M , on a $(M^{-1}M)^\top = I_n \iff M^\top (M^{-1})^\top = I_n \iff$

$$\boxed{(M^{-1})^\top = (M^\top)^{-1}}$$

Inverse de $\mathbb{X}^\top \mathbb{X}$. On en déduit

$$(\mathbb{X}^\top \mathbb{X})^{-1} = \frac{1}{n \sum_{i=1}^n (X_i - \bar{X})^2} \begin{pmatrix} \sum_{i=1}^n X_i^2 & -\sum_{i=1}^n X_i \\ -\sum_{i=1}^n X_i & n \end{pmatrix}.$$

Matrice de covariance de $(\hat{\beta}_0, \hat{\beta}_1)$. D'après la formule générale établie précédemment,

$$\text{Var}(\hat{\beta}) = \sigma^2 (\mathbb{X}^\top \mathbb{X})^{-1}.$$

Ainsi,

$$\text{Var}(\hat{\beta}) = \frac{\sigma^2}{n \sum_{i=1}^n (X_i - \bar{X})^2} \begin{pmatrix} \sum_{i=1}^n X_i^2 & -\sum_{i=1}^n X_i \\ -\sum_{i=1}^n X_i & n \end{pmatrix}.$$

La variance de $\hat{\beta}_1$ correspond au coefficient situé en position (2, 2) :

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

Toujours par abus de notation, on rappelle ici que les résultats sont conditionnés par les X_i observés. Comme le modèle est gaussien, $\hat{\beta}_1$ est une combinaison linéaire de variables gaussiennes, et suit donc une loi normale. En effet, on combine trois informations ici :

- a) L'écriture (2.6) nous donne que l'estimateur recentré est une combinaison linéaire de variables gaussiennes indépendantes. Donc $\hat{\beta}$ est une variable gaussienne.
- b) Le résultat (2.5) nous donne l'espérance de cet estimateur.
- c) Le résultat (2.7) nous donne sa variance.

D'où le résultat final :

$$\hat{\beta}_1 \sim \mathcal{N}\left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n (X_i - \bar{X})^2}\right).$$

Cas de l'ordonnée à l'origine. La variance de $\hat{\beta}_0$ est donnée par le coefficient (1, 1) :

$$\text{Var}(\hat{\beta}_0) = \frac{\sigma^2 \sum_{i=1}^n X_i^2}{n \sum_{i=1}^n (X_i - \bar{X})^2}.$$

On en déduit

$$\hat{\beta}_0 \sim \mathcal{N}\left(\beta_0, \frac{\sigma^2 \sum_{i=1}^n X_i^2}{n \sum_{i=1}^n (X_i - \bar{X})^2}\right).$$

Justification qu'une somme de gaussiennes est une gaussienne. Soient $Z_1, \dots, Z_m$ des variables aléatoires gaussiennes qu'on suppose indépendantes et $a_1, \dots, a_m \in \mathbb{R}$. Alors la combinaison linéaire $L = \sum_{j=1}^m a_j Z_j$ est gaussienne. En effet, pour tout $t \in \mathbb{R}$, la fonction caractéristique de L vaut

$$\varphi_L(t) = \mathbb{E}\left[e^{it \sum_{j=1}^m a_j Z_j}\right] = \prod_{j=1}^m \mathbb{E}[e^{ita_j Z_j}] = \prod_{j=1}^m \exp(it a_j \mu_j - \frac{1}{2} t^2 a_j^2 \sigma_j^2) = \exp(it \mu_L - \frac{1}{2} t^2 \sigma_L^2),$$

où $\mu_L = \sum_{j=1}^m a_j \mu_j$ et $\sigma_L^2 = \sum_{j=1}^m a_j^2 \sigma_j^2$. $t \mapsto \varphi_L(t)$ est précisément une fonction caractéristique d'une loi normale : $L \sim \mathcal{N}(\mu_L, \sigma_L^2)$. $\square$

———— Fin correction Exercice 3 ————

Correction – Exercice 4

On rappelle les notations :

$$Y = \text{Cholestérol}, \quad X^{(1)} = \text{Poids}, \quad X^{(2)} = \text{Âge}, \quad X^{(3)} = \text{Taille}.$$

Le modèle considéré est

$$Y_i = \beta_0 + \beta_1 X_i^{(1)} + \beta_2 X_i^{(2)} + \beta_3 X_i^{(3)} + \varepsilon_i, \quad i = 1, \dots, n. \quad (\text{M4})$$

1) Modélisation

a) **Hypothèses du modèle linéaire.** Le modèle linéaire multiple à erreurs gaussiennes repose classiquement sur les hypothèses suivantes :

- **Linéarité du modèle** : la réponse est une combinaison linéaire des variables explicatives et d'une erreur,

$$Y_i = \beta_0 + \beta_1 X_i^{(1)} + \beta_2 X_i^{(2)} + \beta_3 X_i^{(3)} + \varepsilon_i.$$

- **Centrage des erreurs** : pour tout i , $\mathbb{E}[\varepsilon_i] = 0$.
- **Homoscédasticité** : $\text{Var}(\varepsilon_i) = \sigma^2$ (constante, indépendante de i).
- **Indépendance** : les erreurs $(\varepsilon_i)_{1 \leq i \leq n}$ sont indépendantes.
- **Normalité** (pour l'inférence) : $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$.

b) **Écriture matricielle et dimensions.** On pose

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \in \mathbb{R}^n, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} \in \mathbb{R}^4, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix} \in \mathbb{R}^n,$$

et la matrice de design

$$\mathbb{X} = \begin{pmatrix} 1 & X_1^{(1)} & X_1^{(2)} & X_1^{(3)} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & X_n^{(1)} & X_n^{(2)} & X_n^{(3)} \end{pmatrix} \in \mathbb{R}^{n \times 4}.$$

Alors le modèle s'écrit

$$\mathbf{Y} = \mathbb{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

Ici $n = 15$, donc $\mathbf{Y} \in \mathbb{R}^{15}$, $\mathbb{X} \in \mathbb{R}^{15 \times 4}$, $\boldsymbol{\beta} \in \mathbb{R}^4$, $\boldsymbol{\varepsilon} \in \mathbb{R}^{15}$. Ainsi l'espace des paramètres est

$$\Theta = \mathbb{R}^4.$$

c) **Estimateur des moindres carrés.** L'estimateur des moindres carrés (MCO) est défini par

$$\hat{\boldsymbol{\beta}} \in \arg \min_{\boldsymbol{\beta} \in \Theta} \|\mathbf{Y} - \mathbb{X}\boldsymbol{\beta}\|_2^2.$$

Lorsque $\mathbb{X}^\top \mathbb{X}$ est inversible (colonnes de $\mathbb{X}$ linéairement indépendantes), on obtient l'expression fermée :

$$\hat{\boldsymbol{\beta}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y}.$$

2) Estimation et significativité des coefficients (TP) Les sorties R (commandes `lm` et `summary`) donnent :

a) **Valeurs estimées.**

$$\hat{\beta}_0 = 42.2614, \quad \hat{\beta}_1 = 0.9241, \quad \hat{\beta}_2 = 4.7523, \quad \hat{\beta}_3 = 0.2064.$$

Le modèle ajusté s'écrit donc :

$$\hat{Y}_i = 42.2614 + 0.9241 X_i^{(1)} + 4.7523 X_i^{(2)} + 0.2064 X_i^{(3)}.$$

b) **Estimation de la variance des erreurs.** L'écart-type résiduel est $\hat{\sigma} = 37.4$ (ddl = 11), donc :

$$\hat{\sigma}^2 = 1399.12.$$

c) **Variables significatives au seuil $\alpha = 0.05$.** On teste pour chaque coefficient

$$(H_0) : \beta_j = 0 \quad \text{vs} \quad (H_1) : \beta_j \neq 0.$$

À partir des p-values :

- **weight** : p-value = $0.356 > 0.05 \Rightarrow$ non significatif;
- **age** : p-value = $6.53 \times 10^{-5} < 0.05 \Rightarrow$ significatif;
- **height** : p-value = $0.842 > 0.05 \Rightarrow$ non significatif.

Conclusion : **seule la variable Âge $X^{(2)}$ est statistiquement significative** au seuil 5% dans ce modèle.

3) **Intervalles de confiance** Au niveau 95% (i.e. $1 - \alpha$ avec $\alpha = 0.05$), on obtient :

$$\text{IC}_{95\%}(\beta_0) = [-362.121 ; 446.644],$$

$$\text{IC}_{95\%}(\beta_1) = [-1.185 ; 3.033],$$

$$\text{IC}_{95\%}(\beta_2) = [3.071 ; 6.434],$$

$$\text{IC}_{95\%}(\beta_3) = [-2.022 ; 2.435].$$

Interprétation.

- L'intervalle de β_2 (Âge) est strictement positif : **l'effet de l'âge est positif et significatif.** En moyenne, **à poids et taille constants**, une année supplémentaire augmente le cholestérol d'environ 4.75 (ml/100 ml), avec une incertitude compatible avec [3.07; 6.43].
- Les intervalles de β_1 (Poids) et β_3 (Taille) contiennent 0 : **pas d'effet significatif détecté** dans ce jeu de données, au seuil 5%.
- L'intervalle de l'ordonnée à l'origine β_0 contient largement 0 : cela n'a pas d'interprétation physique forte ici (valeurs $X^{(1)}, X^{(2)}, X^{(3)}$ nulles hors domaine), mais reflète une grande incertitude sur l'interception.

4) **Significativité globale du modèle** On teste la significativité globale par un test de Fisher :

$$(H_0) : \beta_1 = \beta_2 = \beta_3 = 0 \quad \text{vs} \quad (H_1) : \exists j \in \{1, 2, 3\} \text{ tel que } \beta_j \neq 0.$$

La sortie **summary** fournit :

$$F = 16.16 \text{ (ddl : 3 et 11),} \quad \text{p-value} = 2.408 \times 10^{-4}.$$

Comme $2.408 \times 10^{-4} < 0.05$, on rejette (H_0) au seuil 5% : **le modèle est globalement significatif** (au moins une variable explicative contribue à expliquer Y).

Vérification des hypothèses sur les résidus. Les diagnostics fournis indiquent :

- moyenne empirique des résidus : 0 (cohérent avec l'hypothèse $\mathbb{E}[\varepsilon] = 0$);
- test de Shapiro–Wilk : p-value = 0.67 $\Rightarrow$ **pas de remise en cause de la normalité**;
- le nuage $(\hat{Y}_i, \hat{\varepsilon}_i)$ ne doit pas présenter de structure marquée : si la dispersion est à peu près constante autour de 0, cela va dans le sens de l'homoscédasticité.

Dans l'ensemble, **les hypothèses gaussiennes semblent compatibles** avec les diagnostics fournis sur ce jeu de données.

5) **Discussion et prolongements** Le modèle multiple présente un bon niveau d'ajustement :

$$R^2 = 0.8151, \quad R_{\text{adj}}^2 = 0.7647.$$

Cependant, l'analyse individuelle montre que **seule l'âge est significatif**, tandis que **poids et taille** ne contribuent pas de manière détectable (p-values élevées, IC contenant 0).

Proposition : modèle réduit sur l'âge uniquement. On considère le modèle réduit

$$Y_i = \beta_0 + \beta_1 X_i^{(2)} + \varepsilon_i.$$

Les sorties R donnent :

$$\hat{\beta}_0 = 137.1714, \quad \hat{\beta}_1 = 4.8571, \quad R^2 = 0.7976, \quad R_{\text{adj}}^2 = 0.7820, \quad \text{AIC} = 153.93, \quad \text{BIC} = 156.05.$$

Comparaison des modèles.

- Le passage au modèle réduit entraîne une baisse très modérée de R^2 (de 0.8151 à 0.7976), et R_{adj}^2 est même **légèrement meilleur** dans le modèle réduit (0.7820 vs 0.7647), ce qui favorise un modèle plus parcimonieux.
- Les critères d'information diminuent nettement (**AIC** et **BIC** plus petits), ce qui indique un meilleur compromis biais/variance lorsque l'on pénalise la complexité.

Conclusion. Sur ces données, un modèle linéaire **réduit à l'âge** est souvent préférable : il est plus simple, plus interprétable, et ses performances globales restent comparables. En prolongement, on pourrait aussi envisager :

- une **sélection de variables** systématique (forward/backward, LASSO) ;
- une **interaction** (ex. âge $\times$ poids) si une justification biologique existe ;
- une **transformation** (ex. centrage-réduction, ou transformation de Y) si les diagnostics indiquent des écarts à l'homoscédasticité ou une non-normalité.

———— *Fin Correction Exercice 4* ————

Chapitre 3

TD3 - Régression logistique

Correction Exercice 1

Contexte. On cherche à modéliser la probabilité d'achat conditionnelle aux covariables $X^{(1)}$ (durée de session) et $X^{(2)}$ (nombre de pages consultées), où

$$Y \in \{0, 1\}, \quad Y = 1 \Leftrightarrow \text{achat.}$$

Preliminaires théoriques.

1. **On adopte le modèle de régression logistique.**

Une régression linéaire standard sur une variable binaire $Y \in \{0, 1\}$ n'est pas adaptée car :

- elle peut produire des **prédictions hors** de l'intervalle $[0, 1]$ (donc non interprétables comme des probabilités) ;
- les hypothèses usuelles de bruit gaussien et d'homoscédasticité sont en général **violées** avec une réponse binaire ;
- la relation entre covariables et probabilité est souvent **non linéaire** et sature vers 0 et 1.

Le modèle logistique impose naturellement une probabilité $\hat{p}(x) \in (0, 1)$ via une fonction sigmoïde, et s'appuie sur une vraisemblance Bernoulli.

2. **Étude de la sigmoïde.** On considère

$$\mathcal{S}(t) = \frac{e^t}{1 + e^t} = \frac{1}{1 + e^{-t}}.$$

a) **Domaine et image.** Le domaine de définition est $\mathbb{R}$. De plus, pour tout $t \in \mathbb{R}$, $e^t > 0$ donc

$$0 < \frac{e^t}{1 + e^t} < 1,$$

et l'image de $\mathcal{S}$ est $(0, 1)$.

b) **Monotonie et bijectivité.** On calcule la dérivée :

$$\mathcal{S}'(t) = \frac{e^t(1 + e^t) - e^t \cdot e^t}{(1 + e^t)^2} = \frac{e^t}{(1 + e^t)^2} = \frac{e^t}{(1 + e^t)} \cdot \frac{1}{(1 + e^t)} = \mathcal{S}(t)(1 - \mathcal{S}(t)).$$

Or $e^t > 0$ et $(1 + e^t)^2 > 0$, donc $\mathcal{S}'(t) > 0$ pour tout t : $\mathcal{S}$ est **strictement croissante** sur $\mathbb{R}$. Comme $\lim_{t \rightarrow -\infty} \mathcal{S}(t) = 0$ et $\lim_{t \rightarrow +\infty} \mathcal{S}(t) = 1$, elle est bijective de $\mathbb{R}$ sur $(0, 1)$.

c) **Point d'inflexion.** On étudie sur tout $\mathbb{R}$. À partir de $\mathcal{S}'(t) = \mathcal{S}(t)(1 - \mathcal{S}(t))$, on obtient

$$\mathcal{S}''(t) = \mathcal{S}'(t)(1 - 2\mathcal{S}(t)).$$

Comme $\mathcal{S}'(t) > 0$, le signe de $\mathcal{S}''(t)$ est celui de $1 - 2\mathcal{S}(t)$. Puisque $t \mapsto \mathcal{S}(t)$ est bijective croissante, alors $t \mapsto 1 - 2\mathcal{S}(t)$ est bijective décroissante et s'annule uniquement en $t = 0$ car $\mathcal{S}(0) = \frac{1}{2}$. D'où donc $\mathcal{S}''(0) = 0$. Le signe change de part et d'autre : $\mathcal{S}$ admet un **unique point d'inflexion en** $t = 0$. Le point d'inflexion est donc $(0, \frac{1}{2})$.

- d) **Intérêt en classification binaire.** La sigmoïde transforme un score réel (le *logit*) en une **probabilité** dans $(0, 1)$, ce qui permet une décision par seuil (par exemple $\tau = \frac{1}{2}$) et une interprétation probabiliste.

3. Formule de la probabilité prédite.

Pour une observation $x = (x^{(1)}, x^{(2)})$, le modèle logistique est :

$$\hat{p}(x) = \mathbb{P}(Y = 1 \mid X^{(1)} = x^{(1)}, X^{(2)} = x^{(2)}) = \mathcal{S}(\hat{w}_0 + \hat{w}_1 x^{(1)} + \hat{w}_2 x^{(2)}).$$

Autrement dit

$$\hat{p}(x) = \frac{1}{1 + \exp(-(\hat{w}_0 + \hat{w}_1 x^{(1)} + \hat{w}_2 x^{(2)}))}.$$

4. Critère optimisé et méthode numérique.

On estime $\mathbf{w} = (w_0, w_1, w_2)$ par **maximum de vraisemblance** (données Bernoulli) :

$$L(\mathbf{w}) = \prod_{i=1}^n \hat{p}(x_i)^{y_i} (1 - \hat{p}(x_i))^{1-y_i}, \quad \text{ou, équivalamment, maximiser } \ell(\mathbf{w}) = \log L(\mathbf{w}).$$

Maximiser $\ell(\mathbf{w})$ revient à **minimiser** la **log-loss** (entropie croisée) :

$$\mathcal{J}(\mathbf{w}) = - \sum_{i=1}^n \left(y_i \log \hat{p}(x_i) + (1 - y_i) \log (1 - \hat{p}(x_i)) \right).$$

*La résolution est effectuée numériquement par des méthodes d'optimisation, typiquement **Newton-Raphson** (ou **IRLS**), ou d'autres variantes de **descente de gradient**.*

Aparté théorique sur la construction des intervalles de confiance. Une fois l'estimateur du maximum de vraisemblance obtenu

$$\hat{\mathbf{w}} = \arg \max_{\mathbf{w}} \ell(\mathbf{w}),$$

on exploite le résultat fondamental d'**asymptotique du maximum de vraisemblance**. Sous des hypothèses régulières (modèle bien spécifié, indépendance, n grand), on a :

$$\hat{\mathbf{w}} \sim \mathcal{N}(\mathbf{w}, \mathcal{I}(\hat{\mathbf{w}})^{-1}),$$

où $\mathcal{I}(\hat{\mathbf{w}})$ désigne la matrice d'information de Fisher observée :

$$\mathcal{I}(\hat{\mathbf{w}}) = \mathbb{X}^\top \mathbf{W} \mathbb{X}, \quad \mathbf{W} = \text{diag}(\hat{p}_i(1 - \hat{p}_i)).$$

On en déduit une estimation de la matrice de covariance :

$$\widehat{\text{Var}}(\hat{\mathbf{w}}) = (\mathbb{X}^\top \mathbf{W} \mathbb{X})^{-1}.$$

L'erreur standard associée au coefficient $\hat{w}_\ell$ est alors

$$\widehat{\text{se}}(\hat{w}_\ell) = \sqrt{[(\mathbb{X}^\top \mathbf{W} \mathbb{X})^{-1}]_{jj}}.$$

On construit finalement un intervalle de confiance asymptotique de niveau $1 - \alpha$:

$$\text{IC}_{1-\alpha}(w_\ell) = [\hat{w}_\ell - z_{1-\alpha/2} \widehat{\text{se}}(\hat{w}_\ell), \hat{w}_\ell + z_{1-\alpha/2} \widehat{\text{se}}(\hat{w}_\ell)],$$

où $z_{1-\alpha/2}$ est le quantile de la loi normale standard. Ces intervalles sont dits **intervalles de Wald**. Des alternatives plus robustes (profil de vraisemblance ou bootstrap) peuvent également être utilisées.

Application TD. On dispose des estimations :

$$\hat{w}_0 = -4.20, \quad \hat{w}_1 = 1.00, \quad \hat{w}_2 = 0.015,$$

$$\text{IC}_{95\%}(w_0) = [-6.10; -2.30], \quad \text{IC}_{95\%}(w_1) = [0.20; 2.20], \quad \text{IC}_{95\%}(w_2) = [-0.005; 0.035].$$

1. Interprétation et significativité.

- a) **Signe de $\hat{w}_1$.** Comme $\hat{w}_1 > 0$, quand la durée de session $X^{(1)}$ augmente (toutes choses égales par ailleurs), le score $\hat{w}_0 + \hat{w}_1 X^{(1)} + \hat{w}_2 X^{(2)}$ augmente, donc la probabilité d'achat $\hat{p}$ **augmente**. Une session plus longue est associée à une probabilité d'achat plus élevée.
- b) **Significativité de $\hat{w}_1$.** Comme $\text{IC}_{95\%}(w_1) = [0.20; 2.20]$ ne contient pas 0, le coefficient w_1 est **significatif** au seuil 5%.
- c) **Significativité de $\hat{w}_2$.** Comme $\text{IC}_{95\%}(w_2) = [-0.005; 0.035]$ contient 0, le coefficient w_2 **n'est pas significatif** au seuil 5% (au sens d'un test bilatéral).

2. Calcul de probabilités prédites.

Pour $k \in \{1, 2, 3\}$, on pose

$$z_k = \hat{w}_0 + \hat{w}_1 X_k^{(1)} + \hat{w}_2 X_k^{(2)}, \quad \hat{p}_k = \mathcal{S}(z_k) = \frac{1}{1 + e^{-z_k}}.$$

- Session 1 : $(X_1^{(1)}, X_1^{(2)}) = (5, 3)$

$$z_1 = -4.20 + 1.00 \times 5 + 0.015 \times 3 = -4.20 + 5 + 0.045 = 0.845,$$

$$\hat{p}_1 = \mathcal{S}(0.845) = \frac{1}{1 + e^{-0.845}} \approx 0.699.$$

- Session 2 : $(X_2^{(1)}, X_2^{(2)}) = (12, 8)$

$$z_2 = -4.20 + 1.00 \times 12 + 0.015 \times 8 = -4.20 + 12 + 0.120 = 7.92,$$

$$\hat{p}_2 = \mathcal{S}(7.92) \approx 0.9996.$$

- Session 3 ¹ : $(X_3^{(1)}, X_3^{(2)}) = (2, 15)$

$$z_3 = -4.20 + 1.00 \times 2 + 0.015 \times 15 = -4.20 + 2 + 0.225 = -1.975,$$

$$\hat{p}_3 = \mathcal{S}(-1.975) \approx 0.122.$$

3. Prédiction au seuil $\tau = \frac{1}{2}$.

Le prédicteur est

$$\hat{\mu}(X_k^{(1)}, X_k^{(2)}) = \mathbb{1}(\hat{p}_k \geq \frac{1}{2}).$$

On obtient :

$$\hat{p}_1 \approx 0.699 > \frac{1}{2}, \quad \hat{p}_2 \approx 0.9996 > \frac{1}{2}, \quad \hat{p}_3 \approx 0.122 < \frac{1}{2},$$

donc :

$$\hat{\mu}(x_1) = 1, \quad \hat{\mu}(x_2) = 1, \quad \hat{\mu}(x_3) = 0.$$

Conclusion : au seuil $\tau = \frac{1}{2}$, le modèle prédit **achat** pour les sessions 1 et 2, et **absence d'achat** pour la session 3.

———— Fin Correction Exercice 1 ————

1. Il y a une erreur dans l'énoncé du sujet : $X_3^{(1)}$ est égal à 2 et non 25.

Correction Exercice 2

1) Analyse descriptive des données

a) Statistiques descriptives.

Le jeu de données contient $n = 200$ observations pour $p = 4$ covariables explicatives.

Proportions de classes :

$$\mathbb{P}(Y = 0) = 0.66, \quad \mathbb{P}(Y = 1) = 0.34.$$

Le jeu de données est donc **déséquilibré modérément**, avec environ un tiers de patientes diabétiques.

Statistiques descriptives des covariables :

Variable	mean	sd	min	med	max	NA
npreg	3.57	3.366	0.0	2.0	14.0	0
glu	123.97	31.667	56.0	120.5	199.0	0
bmi	32.31	6.130	18.2	32.8	47.9	0
age	32.11	10.975	21.0	28.0	63.0	0

Aucune valeur manquante n'est présente.

On observe notamment :

- une glycémie moyenne d'environ 124 ;
- un IMC moyen de 32.3 (population en moyenne en surpoids) ;
- une forte variabilité pour `glu` et `age`.

b) Visualisation.

Les représentations graphiques suivantes permettent d'explorer la structure des données :




FIGURE 3.1 – Matrice des nuages de points des covariables, séparées selon la classe `Y`.




FIGURE 3.2 – Histogrammes des covariables selon la classe binaire.

On observe notamment :

- une séparation visuelle marquée sur la variable `glu` ;
- une tendance également visible pour `bmi` ;
- une séparation moins nette pour `npreg` et `age`.

Cela suggère déjà que la glycémie pourrait jouer un rôle déterminant.

2) Rappels théoriques

a) Forme du modèle logistique.

Le modèle logistique binaire s'écrit :

$$\mathbb{P}(Y = 1 \mid \mathbf{X}) = \frac{1}{1 + \exp(-(w_0 + w_1 X^{(1)} + \dots + w_p X^{(p)}))}.$$

Équivalent sous forme logit :

$$\log\left(\frac{p(\mathbf{X}, \mathbf{w})}{1 - p(\mathbf{X}, \mathbf{w})}\right) = w_0 + \sum_{\ell=1}^p w_{\ell} X^{(\ell)}.$$

Hypothèses principales :

- les observations sont indépendantes ;
- conditionnellement à $\mathbf{X}$, la variable Y suit une loi de Bernoulli ;
- le logit est linéaire en les covariables.

b) Critère optimisé.

Les paramètres sont estimés par maximum de vraisemblance. On note $\hat{p}(\mathbf{x}_i, \mathbf{w})$ l'estimation de $\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}_i)$. On estime $\mathbf{w} = (w_0, w_1, w_2, w_3, w_4)$ par **maximum de vraisemblance** (données Bernoulli) :

$$L(\mathbf{w}) = \prod_{i=1}^n \hat{p}(x_i, \mathbf{w})^{y_i} (1 - \hat{p}(x_i, \mathbf{w}))^{1-y_i}, \quad \text{ou, équivalamment, maximiser } \ell(\mathbf{w}) = \log L(\mathbf{w}).$$

Maximiser $\ell(\mathbf{w})$ revient à **minimiser** la **log-loss** (entropie croisée) :

$$\hat{\mathbf{w}} = \underset{\mathbf{w} \in \mathbb{R}^5}{\operatorname{argmin}} \left\{ - \sum_{i=1}^n \left(y_i \log \hat{p}(x_i, \mathbf{w}) + (1 - y_i) \log (1 - \hat{p}(x_i, \mathbf{w})) \right) \right\}.$$

La résolution se fait numériquement via des algorithmes type descente de gradient.

3) Apprentissage du modèle

a) **Estimation des coefficients.** Les estimations obtenues sont :

Coefficient	Estimate	IC 95%	Signif.
Intercept β_0	-9.347	[-12.26; -6.43]	Oui
npreg	0.084	[-0.038; 0.206]	Non
glu	0.031	[0.0186; 0.0439]	Oui
bmi	0.095	[0.030; 0.159]	Oui
age	0.0366	[-0.003; 0.076]	Non

Indicateurs globaux :

$$\text{Null deviance} = 256.41, \quad \text{Residual deviance} = 186.55, \quad \text{AIC} = 196.55.$$

La *null deviance* correspond à la déviance du modèle le plus simple possible (intercept seul), tandis que la *residual deviance* mesure la déviance du modèle ajusté avec les variables explicatives. La forte diminution observée ($256.41 \rightarrow 186.55$) indique que les covariables apportent une amélioration substantielle de l'ajustement : le modèle explique donc une part significative de l'information contenue dans les données. Enfin, l'AIC (196.55) combine qualité d'ajustement et pénalisation de la complexité ; sa valeur relativement proche de la déviance résiduelle confirme que le modèle obtenu reste parcimonieux tout en améliorant nettement l'ajustement par rapport au modèle nul.

b) **Significativité et pertinence globale.** Les variables significatives au seuil 5% sont **glu** et **bmi**.

Interprétation des signes :

- $\hat{w}_{\text{glu}} > 0$: une augmentation de la glycémie augmente les log-odds, donc augmente la probabilité de que l'individu ait le diabète.
- $\hat{w}_{\text{bmi}} > 0$: un IMC plus élevé est associé à un risque accru.

Les variables **npreg** et **age** ne sont pas significatives au seuil 5%.

La **forte diminution de la déviance** ($256.41 \rightarrow 186.55$) indique une amélioration substantielle par rapport au modèle nul.

4) **Prédiction sur de nouvelles observations** On obtient :

New	npreg	glu	bmi	age	$\hat{p}_k$	$\hat{y}_k$
1	1	90	22	22	0.0275	0
2	3	130	30	35	0.2863	0
3	6	170	36	50	0.8464	1

Conclusion :

- Les deux premières patientes ont une probabilité prédite inférieure à $\tau = \frac{1}{2}$: classification en non diabétique.
- La troisième patiente présente une probabilité prédite élevée (≈ 0.85) : classification en diabétique.

Correction Exercice 3

1) Analyse descriptive.

a) Taille de l'échantillon et nombre de variables explicatives.

Le jeu de données `iris` contient $n = 150$ observations, correspondant à 150 fleurs. On dispose de $p = 4$ variables explicatives numériques :

$$X^{(1)} = \text{Sepal.Length}, \quad X^{(2)} = \text{Sepal.Width}, \quad X^{(3)} = \text{Petal.Length}, \quad X^{(4)} = \text{Petal.Width}.$$

La variable réponse est l'espèce de la fleur, codée ici par

$$Y \in \{1, 2, 3\},$$

avec la correspondance :

$$1 = \text{setosa}, \quad 2 = \text{versicolor}, \quad 3 = \text{virginica}.$$

b) Nature des variables et statistiques descriptives.

Les quatre variables explicatives sont **quantitatives continues** : elles mesurent des longueurs ou largeurs de sépales et de pétales.

La variable `Species` est une variable **qualitative nominale** à trois modalités :

$$\text{setosa}, \quad \text{versicolor}, \quad \text{virginica}.$$

Les sorties R indiquent qu'il n'y a **aucune donnée manquante** puisque l'on lit :

$$\text{NA} = 0 \quad \text{pour toutes les variables}.$$

Les statistiques descriptives usuelles des covariables sont les suivantes :

Variable	Moyenne	Écart-type	Min	Max
Sepal.Length	5.843	0.828	4.3	7.9
Sepal.Width	3.057	0.436	2.0	4.4
Petal.Length	3.758	1.765	1.0	6.9
Petal.Width	1.199	0.762	0.1	2.5

Le résumé R fournit également les quartiles et la médiane :

Variable	1er quartile	Médiane	3e quartile
Sepal.Length	5.1	5.8	6.4
Sepal.Width	2.8	3.0	3.3
Petal.Length	1.6	4.35	5.1
Petal.Width	0.3	1.3	1.8

On remarque déjà que les variables liées aux **pétales** (`Petal.Length` et `Petal.Width`) présentent une dispersion importante et semblent particulièrement informatives pour distinguer les espèces.

c) Matrice des graphiques des covariables.

La commande

```
pairs(iris[,1:4], col = iris$Species)
```

permet de représenter tous les nuages de points deux à deux entre les quatre covariables.

La figure obtenue met en évidence la structure du jeu de données et permet de visualiser les groupes formés par les différentes espèces.

d) **Observation de la séparabilité des classes.**

À la lecture de la matrice de graphiques, on constate que la classe *setosa* apparaît très nettement séparée des deux autres, en particulier dans les plans faisant intervenir `Petal.Length` et `Petal.Width`.

En revanche, les classes *versicolor* et *virginica* sont plus proches et présentent un léger recouvrement, même si la séparation reste globalement bonne dans certains plans.

On peut donc conclure que :

- la classe *setosa* est **presque linéairement séparée** des autres ;
- la distinction entre *versicolor* et *virginica* est **plus délicate**, mais demeure exploitable.

Cela justifie l'utilisation d'un modèle de classification multinomiale.

2) Modélisation logistique.

a) **Forme du modèle logistique multinomial.**

Lorsque la variable réponse Y possède $K = 3$ modalités, le modèle logistique multinomial permet de modéliser les probabilités conditionnelles

$$\mathbb{P}(Y = j \mid \mathbf{X} = \mathbf{x}), \quad j = 1, 2, 3.$$

En choisissant par exemple la classe 1 comme **classe de référence**, une bonne procédure consiste à étudier les *log-odds*, c'est-à-dire les logarithmes des rapports de probabilités entre une classe donnée et la classe de référence.

En effet, comme dans le cas de la régression logistique binaire, l'idée est de transformer une probabilité (comprise entre 0 et 1) en une quantité réelle pouvant être modélisée par une combinaison linéaire des variables explicatives.

On modélise ainsi, pour chaque classe $j \neq 1$, le rapport $\mathbb{P}(Y = j \mid \mathbf{X}) / \mathbb{P}(Y = 1 \mid \mathbf{X})$, puis on applique le logarithme afin d'obtenir une relation affine en fonction des covariables.

On écrit ainsi, pour $j = 2, 3$,

$$\log \left(\frac{\mathbb{P}(Y = j \mid \mathbf{X} = \mathbf{x})}{\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})} \right) = \beta_{j,0} + \beta_{j,1}x^{(1)} + \beta_{j,2}x^{(2)} + \beta_{j,3}x^{(3)} + \beta_{j,4}x^{(4)}.$$

Autrement dit, on modélise les **log-rapports de probabilités** entre chaque classe et la classe de référence comme une fonction affine des variables explicatives.

Les probabilités s'écrivent alors :

$$\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) = \frac{1}{1 + \sum_{j=2}^3 \exp(\eta_j(\mathbf{x}))},$$
$$\mathbb{P}(Y = j \mid \mathbf{X} = \mathbf{x}) = \frac{\exp(\eta_j(\mathbf{x}))}{1 + \sum_{\ell=2}^3 \exp(\eta_\ell(\mathbf{x}))}, \quad j = 2, 3,$$

où

$$\eta_j(\mathbf{x}) = \beta_{j,0} + \beta_{j,1}x^{(1)} + \beta_{j,2}x^{(2)} + \beta_{j,3}x^{(3)} + \beta_{j,4}x^{(4)}.$$

b) **Modèle pertinent ici ?**

Ce modèle est adapté car :

- la variable réponse est **qualitative nominale** ;
- elle possède **trois modalités**, donc un modèle logistique binaire n'est pas suffisant ;
- on souhaite estimer, pour chaque individu, la probabilité d'appartenance à chacune des trois espèces ;
- les covariables sont numériques, ce qui se prête naturellement à une modélisation paramétrique par combinaison linéaire.

Le modèle ajusté sous R est obtenu par :

```
model_multi <- multinom(Species ~ Sepal.Length + Sepal.Width +
                        Petal.Length + Petal.Width,
                        data = df, trace = FALSE)
```

Les coefficients estimés sont :

Classe	Intercept	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
<i>versicolor</i>	18.690	-5.458	-8.707	14.245	-3.098
<i>virginica</i>	-23.836	-7.924	-15.371	23.660	15.135

Le modèle présente une **déviante résiduelle** égale à $\boxed{11.900}$.

*La déviante résiduelle est une mesure de la **qualité d'ajustement** du modèle. Elle joue, pour les modèles logistiques, un rôle analogue à la somme des carrés des résidus en régression linéaire. Plus précisément, elle compare le modèle ajusté au **modèle saturé**, c'est-à-dire un modèle théorique qui ajuste parfaitement les données. Elle s'écrit (schématiquement) :*

$$\text{Deviance} = -2(\log L(\text{modèle ajusté}) - \log L(\text{modèle saturé})),$$

où L désigne la vraisemblance.

*Ainsi, plus la déviante résiduelle est **faible**, meilleur est l'ajustement. Enfin, une déviante proche de 0 correspond à un ajustement presque parfait.*

Dans le cas présent, la déviante résiduelle étant très faible, cela indique que le modèle multinomial ajuste très bien les données du jeu *iris*.

Ces valeurs sont faibles, ce qui traduit ici un très bon ajustement sur le jeu *iris*.

3) Probabilités prédites. On considère les trois individus de l'énoncé :

$$\mathbf{X}_1 = (5.1, 3.5, 1.4, 0.2), \quad \mathbf{X}_2 = (6.0, 2.9, 4.5, 1.5), \quad \mathbf{X}_3 = (6.5, 3.0, 5.5, 2.0).$$

a) **Calcul des probabilités prédites.**

À l'aide de la commande R :

```
predict(model_multi, newdata = X_new, type = "probs")
```

on obtient les probabilités estimées suivantes :

Individu	$\hat{\mathbb{P}}(Y = 1 \mathbf{X})$	$\hat{\mathbb{P}}(Y = 2 \mathbf{X})$	$\hat{\mathbb{P}}(Y = 3 \mathbf{X})$
X_1	1.000000	0.000000	0.000000
X_2	0.000000	0.999018	0.000982
X_3	0.000000	0.000061	0.999939

En remplaçant les numéros de classes par les espèces :

Individu	<i>setosa</i>	<i>versicolor</i>	<i>virginica</i>
X_1	1.000000	0.000000	0.000000
X_2	0.000000	0.999018	0.000982
X_3	0.000000	0.000061	0.999939

Interprétation :

- l'individu X_1 est prédit avec une probabilité égale à 1 dans la classe *setosa* ;
- l'individu X_2 est très fortement associé à la classe *versicolor* ;
- l'individu X_3 est très fortement associé à la classe *virginica*.

b) **Vérification que les probabilités somment à 1.**

Par définition d'un modèle multinomial, la somme des probabilités prédites sur l'ensemble des classes doit être égale à 1 pour chaque individu.

On lit facilement que les sorties R donnent :

$$\hat{p}_k^{(1)} + \hat{p}_k^{(2)} + \hat{p}_k^{(3)} = 1, \quad k = 1, 2, 3.$$

La contrainte probabiliste est donc bien vérifiée.

4) **Règle de décision.**

a) **Critère de prédiction de la classe.**

Pour attribuer une classe à un nouvel individu, on utilise la règle du **maximum de probabilité estimée** :

$$\hat{Y}(\mathbf{x}) = \arg \max_{j \in \{1,2,3\}} \hat{\mathbb{P}}(Y = j \mid \mathbf{X} = \mathbf{x}).$$

Autrement dit, on affecte l'individu à la classe dont la probabilité prédite est la plus grande.

b) **Classe prédite pour X_1 , X_2 et X_3 .**

D'après les probabilités obtenues précédemment :

$$\begin{aligned}\hat{Y}(X_1) &= 1 \rightarrow \text{setosa}, \\ \hat{Y}(X_2) &= 2 \rightarrow \text{versicolor}, \\ \hat{Y}(X_3) &= 3 \rightarrow \text{virginica}.\end{aligned}$$

On peut résumer dans le tableau suivant :

Individu	Classe prédite	Espèce prédite
X_1	1	<i>setosa</i>
X_2	2	<i>versicolor</i>
X_3	3	<i>virginica</i>

Les prédictions sont ici très tranchées : chaque individu est associé à une espèce avec une probabilité extrêmement élevée. Cela confirme que le modèle sépare très bien les profils proposés (*ou que les données sont bien choisies... La réalité est souvent plus compliquée que ce que les jeux de données académiques suggèrent.*).

Conclusion. Cet exercice illustre le fonctionnement de la **régression logistique multinomiale** dans un cadre simple et classique. À partir des quatre mesures morphologiques disponibles, le modèle permet :

- d'estimer les probabilités d'appartenance à chacune des trois espèces ;
- de construire une règle de décision naturelle par maximum de probabilité ;
- d'obtenir, sur le jeu **iris**, des classifications très convaincantes.

En particulier, les variables liées aux **pétales** jouent un rôle majeur dans la discrimination des espèces, ce qui était déjà visible à l'étape descriptive.

Chapitre 4

TD4 - Arbre de décision

Correction – Exercice 0

L'objectif de cet exercice est de reconstruire l'arbre de régression correspondant à la partition de l'espace représentée dans la figure. Rappelons qu'un arbre de régression construit une fonction de prédiction constante par morceaux en découpant récursivement l'espace des variables explicatives à l'aide de règles de la forme

$$X^{(j)} \leq s.$$

Chaque feuille de l'arbre correspond alors à une région de l'espace dans laquelle la prédiction est constante.

1) Règles de découpe

Lecture de la première séparation. On observe tout d'abord que l'espace est séparé en deux grandes régions par une droite verticale située en

$$x^{(1)} = 1.$$

Cette séparation constitue donc le **premier split de l'arbre** :

$$x^{(1)} \leq 1.$$

La région située à droite de cette séparation correspond à une feuille de l'arbre dans laquelle la prédiction est constante et vaut

$$\hat{Y} = 5.$$

La région située à gauche de cette coupure est ensuite subdivisée par d'autres règles.

Deuxième séparation. Dans la partie gauche, c'est-à-dire lorsque

$$x^{(1)} \leq 1,$$

on observe une séparation horizontale située en

$$x^{(2)} = 2.1.$$

Cette règle correspond donc au second nœud de décision :

$$x^{(2)} \leq 2.1.$$

La région située au-dessus de cette coupure constitue une feuille dans laquelle la prédiction vaut

$$\hat{Y} = 15.$$

La région située en dessous, correspondant à

$$x^{(2)} \leq 2.1,$$

est encore subdivisée.

Troisième séparation. Dans la partie inférieure gauche, on observe ensuite une séparation verticale en

$$x^{(1)} = 0.$$

Cette règle constitue le troisième split :

$$x^{(1)} \leq 0.$$

Elle produit deux régions :

- la région de gauche correspond à une feuille de prédiction

$$\hat{Y} = 3,$$

- la région de droite est encore subdivisée.

Quatrième séparation. Dans la dernière région restante, on observe enfin une séparation horizontale en

$$x^{(2)} = 0.5.$$

Cette règle correspond au dernier split :

$$x^{(2)} \leq 0.5.$$


Elle conduit aux deux feuilles terminales :

$$\hat{Y} = \begin{cases} 10 & \text{si } x^{(2)} \leq 0.5, \\ 0 & \text{si } x^{(2)} > 0.5. \end{cases}$$

Ainsi, la suite des règles de découpe est donnée par

$$x^{(1)} \leq 1, \quad x^{(2)} \leq 2.1, \quad x^{(1)} \leq 0, \quad x^{(2)} \leq 0.5.$$

2) Arbre de décision correspondant



3) Fonction de prédiction

L'arbre de régression construit une fonction constante sur chacune des régions de l'espace des variables explicatives. La partition induite par l'arbre peut être décrite à l'aide des régions suivantes :

$$\begin{aligned}\mathcal{R}_1 &= \left\{ (x^{(1)}, x^{(2)}) : x^{(1)} > 1 \right\}, \\ \mathcal{R}_2 &= \left\{ (x^{(1)}, x^{(2)}) : x^{(1)} \leq 1 \text{ et } x^{(2)} > 2.1 \right\}, \\ \mathcal{R}_3 &= \left\{ (x^{(1)}, x^{(2)}) : x^{(1)} \leq 0 \text{ et } x^{(2)} \leq 2.1 \right\}, \\ \mathcal{R}_4 &= \left\{ (x^{(1)}, x^{(2)}) : 0 < x^{(1)} \leq 1 \text{ et } 0.5 < x^{(2)} \leq 2.1 \right\}, \\ \mathcal{R}_5 &= \left\{ (x^{(1)}, x^{(2)}) : 0 < x^{(1)} \leq 1 \text{ et } x^{(2)} \leq 0.5 \right\}.\end{aligned}$$

Dans chacune de ces régions, la prédiction de l'arbre est constante. La fonction de régression peut donc s'écrire sous forme *piecewise* :

$$f(x^{(1)}, x^{(2)}) = \begin{cases} 5 & \text{si } (x^{(1)}, x^{(2)}) \in \mathcal{R}_1, \\ 15 & \text{si } (x^{(1)}, x^{(2)}) \in \mathcal{R}_2, \\ 3 & \text{si } (x^{(1)}, x^{(2)}) \in \mathcal{R}_3, \\ 0 & \text{si } (x^{(1)}, x^{(2)}) \in \mathcal{R}_4, \\ 10 & \text{si } (x^{(1)}, x^{(2)}) \in \mathcal{R}_5. \end{cases}$$

Une écriture plus compacte consiste à utiliser les fonctions indicatrices des régions. La fonction de prédiction s'écrit alors On peut également écrire la fonction de prédiction sous forme d'une somme sur les régions terminales de l'arbre. En notant

$$\hat{y}_1 = 5, \quad \hat{y}_2 = 15, \quad \hat{y}_3 = 3, \quad \hat{y}_4 = 0, \quad \hat{y}_5 = 10,$$

on obtient

$$f(x^{(1)}, x^{(2)}) = \sum_{m=1}^5 \hat{y}_m \mathbb{1}_{\{(x^{(1)}, x^{(2)}) \in \mathcal{R}_m\}}.$$

En développant, cela donne :

$$\begin{aligned}f(x^{(1)}, x^{(2)}) &= 5 \times \mathbb{1}_{\{(x^{(1)}, x^{(2)}) \in \mathcal{R}_1\}} + 15 \times \mathbb{1}_{\{(x^{(1)}, x^{(2)}) \in \mathcal{R}_2\}} + 3 \times \mathbb{1}_{\{(x^{(1)}, x^{(2)}) \in \mathcal{R}_3\}} \\ &\quad + 0 \times \mathbb{1}_{\{(x^{(1)}, x^{(2)}) \in \mathcal{R}_4\}} + 10 \times \mathbb{1}_{\{(x^{(1)}, x^{(2)}) \in \mathcal{R}_5\}}.\end{aligned}$$

L'arbre de régression définit une fonction *constante par morceaux* sur la partition $\{\mathcal{R}_1, \dots, \mathcal{R}_5\}$ de l'espace des variables explicatives.

Conclusion. Cet exercice illustre un point fondamental des arbres de décision : un arbre de régression est équivalent à une partition récursive de l'espace des variables explicatives. Chaque feuille correspond à une région rectangulaire de l'espace $\mathbb{R}^2$ dans laquelle la prédiction du modèle est constante.

Correction – Exercice 1 : Introduction aux arbres de décision

Jeu de données. On travaille sur le jeu de données `mtcars`. On note

$$Y = \text{mpg} \quad (\text{Consommation}), \quad X^{(1)} = \text{wt} \quad (\text{Poids}), \quad X^{(2)} = \text{hp} \quad (\text{Puissance}),$$

$$X = (X^{(1)}, X^{(2)}) \in \mathbb{R}^2.$$

1) Chargement des bibliothèques et des données

1. **Affichage des premières lignes.** L'instruction `head(mtcars)` (ou équivalent) permet d'afficher les premières observations et de vérifier la présence des variables `mpg`, `wt`, `hp`.
2. **Interprétation des variables.**
 - `mpg` : consommation (miles par gallon). Plus `mpg` est grand, plus la voiture est économe.
 - `wt` : poids du véhicule (en milliers de livres). Plus `wt` est grand, plus la voiture est lourde.
 - `hp` : puissance du moteur (horsepower). Plus `hp` est grand, plus le moteur est puissant.

2) Apprentissage d'un arbre de régression

1. **Sens de la formule `mpg ~ wt + hp` et modèle de prédicteur associé.**

La formule indique que l'on cherche à prédire $Y = \text{mpg}$ à partir des covariables $X^{(1)} = \text{wt}$ et $X^{(2)} = \text{hp}$. Le modèle appris est un **prédicteur** (fonction de régression empirique) noté

$$\mu : \mathbb{R}^2 \rightarrow \mathbb{R}, \quad \hat{Y} = \mu(X).$$

Un arbre de décision produit une fonction *constante par morceaux* :

$$\mu(x) = \sum_{m=1}^M c_m \mathbb{1}_{\{x \in \mathcal{R}_m\}},$$

où $\{\mathcal{R}_1, \dots, \mathcal{R}_M\}$ est la partition de l'espace des covariables induite par l'arbre, et c_m est la prédiction associée à la feuille (région) $\mathcal{R}_m$.

2. **Type de problème.** Il s'agit d'un problème de **régression**, car $Y = \text{mpg}$ est une variable quantitative continue. (En classification, Y prendrait un nombre fini de modalités.)
3. **Critère de choix des coupures.** En régression, le critère est basé sur la **perte quadratique**. Si l'arbre induit une partition $\{\mathcal{R}_1, \dots, \mathcal{R}_M\}$, on cherche une approximation μ minimisant l'erreur quadratique globale :

$$\min_{\{\mathcal{R}_m\}, \{c_m\}} \sum_{m=1}^M \sum_{i: X_i \in \mathcal{R}_m} (Y_i - c_m)^2.$$

Pour une partition fixée, la meilleure constante sur une région $\mathcal{R}_m$ est obtenue par minimisation locale :

$$c_m = \operatorname{argmin}_{c \in \mathbb{R}} \sum_{i: X_i \in \mathcal{R}_m} (Y_i - c)^2 = \frac{1}{|\mathcal{R}_m|} \sum_{i: X_i \in \mathcal{R}_m} Y_i.$$

Ainsi, lors de la construction de l'arbre, une coupure candidate est choisie de façon à **réduire au maximum** la somme des carrés des résidus (SSE) dans les sous-régions obtenues, i.e. à améliorer le critère quadratique.

3) Lecture et interprétation de l'arbre




FIGURE 4.1 – Arbre de décision de régression appris pour prédire `mpg` à partir de `wt` et `hp`.

a) Première variable de coupure.

D'après la Figure 4.1, la première coupure porte sur la variable `wt`. Cela signifie que cette variable est celle qui permet, au premier niveau de l'arbre, de réduire le plus l'erreur quadratique lorsqu'on partitionne les données. Autrement dit, le poids du véhicule constitue ici la variable la plus discriminante pour expliquer la consommation `mpg`.

b) Signification des valeurs dans les feuilles.

Dans un arbre de régression, la valeur affichée dans une **feuille** correspond à la constante c_m prédite sur la région correspondante $\mathcal{R}_m$. Cette constante est la **moyenne empirique** des valeurs observées de $Y = \text{mpg}$ dans cette région :

$$c_m = \frac{1}{|\mathcal{R}_m|} \sum_{i: X_i \in \mathcal{R}_m} Y_i.$$

Ainsi, pour toute observation dont les variables explicatives appartiennent à la région $\mathcal{R}_m$, la prédiction du modèle est donnée par

$$\hat{y} = c_m.$$

4) Interprétation géométrique des prédictions

a) Pourquoi les prédictions sont-elles constantes par régions ?

Dans un arbre de régression, la prédiction associée à une région $\mathcal{R}_m$ est choisie comme la constante c_m qui minimise l'erreur quadratique moyenne sur cette région :

$$c_m = \arg \min_c \sum_{i: X_i \in \mathcal{R}_m} (Y_i - c)^2.$$

La solution de ce problème est précisément la moyenne empirique des observations dans la région. Par conséquent, la fonction de prédiction est **constante par morceaux** sur la partition induite par l'arbre.

b) Pourquoi les régions sont-elles rectangulaires ? Que se passe-t-il si l'arbre est plus profond ?

Chaque coupure d'un arbre de décision est de la forme

$$X^{(j)} \leq s \quad \text{ou} \quad X^{(j)} > s,$$

c'est-à-dire une contrainte portant sur une seule variable à la fois (*coupure axis-aligned*). Dans le plan (wt, hp), l'intersection successive de telles contraintes définit des régions rectangulaires. Lorsque la profondeur de l'arbre augmente, le nombre de coupures augmente également :

- la partition de l'espace devient plus fine ;
- les régions deviennent plus petites ;
- les prédictions sont plus localisées ;
- le modèle gagne en flexibilité, mais le risque de **sur-apprentissage** augmente.




FIGURE 4.2 – Partition de l'espace (wt, hp) induite par l'arbre : chaque couleur représente une feuille, donc une prédiction constante de mpg .

Remarque sur le modèle obtenu : La variable mpg mesurant le nombre de miles parcourus par gallon, une valeur élevée de mpg correspond à une meilleure efficacité énergétique. Il nous paraît donc assez logique qu'un véhicule léger et de faible puissance présente en moyenne un mpg plus élevé, c'est-à-dire qu'il permette de parcourir une plus grande distance pour une même quantité de carburant.

5) Discussion et ouverture

1. **Un avantage majeur des arbres.** Les arbres de décision sont **interprétables** : la règle de décision est explicite, sous forme de tests successifs, et la partition de l'espace des covariables est facilement visualisable.
2. **Une des limites.** Une limite importante est leur **instabilité** : de petites variations des données peuvent conduire à un arbre très différent, et un arbre profond peut avoir une variance élevée (sur-apprentissage). Les **forêts aléatoires** réduisent cette variance en construisant de nombreux arbres sur des échantillons bootstrap (et en randomisant les variables candidates aux coupures), puis en **moyennant** leurs prédictions.

Correction – Exercice 2 : Entropie et arbre de décision

Rappels – Entropie marginale et conditionnelle.

Soient X et Y deux variables aléatoires discrètes, et notons $\mathcal{X}$ l'ensemble des valeurs possibles prises par X et $\mathcal{Y}$ l'ensemble des valeurs possibles de Y .

L'entropie marginale de la variable réponse Y est définie par :

$$H(Y) = - \sum_{y \in \mathcal{Y}} \mathbb{P}(Y = y) \log(\mathbb{P}(Y = y)).$$

Pour $x \in \mathcal{X}$, on définit les probabilités conditionnelles

$$p_{y|x} := \mathbb{P}(Y = y \mid X = x).$$

L'entropie conditionnelle de Y sachant $X = x$ est alors donnée par :

$$H(Y \mid X = x) = - \sum_{y \in \mathcal{Y}} p_{y|x} \log(p_{y|x}).$$

Enfin, analogue à la formule des probabilités totales, l'entropie conditionnelle de Y sachant X est définie comme l'espérance de $H(Y \mid X = x)$ par rapport à la loi de X :

$$H(Y \mid X) = \sum_{x \in \mathcal{X}} \mathbb{P}(X = x) H(Y \mid X = x).$$

Cette quantité mesure l'incertitude moyenne restante sur Y lorsque la valeur de X est connue.

On dispose de $n = 5$ observations et d'une variable réponse binaire Y , indiquant si la tumeur est maligne ($Y = 1$) ou bénigne ($Y = 0$).

1) Entropie de la variable réponse Y . On compte dans l'échantillon :

$$\#\{Y = 1\} = 3, \quad \#\{Y = 0\} = 2.$$

Ainsi,

$$\mathbb{P}(Y = 1) = \frac{3}{5}, \quad \mathbb{P}(Y = 0) = \frac{2}{5}.$$

Par définition, l'entropie (au sens de Shannon) de Y est :

$$H(Y) = - \sum_{y \in \{0,1\}} \mathbb{P}(Y = y) \log \mathbb{P}(Y = y),$$

où $\log$ désigne le logarithme naturel. D'où :

$$H(Y) = -\frac{3}{5} \log\left(\frac{3}{5}\right) - \frac{2}{5} \log\left(\frac{2}{5}\right) \approx \boxed{0.673}.$$

2) Entropies conditionnelles.

Variable $X^{(1)}$ (Large). On distingue les deux sous-populations :

- $X^{(1)} = 1$: patients 1 et 5. D'après le tableau d'observations, Y prend une fois la valeur 1 et une fois la valeur 0. Ainsi

$$\mathbb{P}(Y = 1 \mid X^{(1)} = 1) = \frac{1}{2}, \quad \mathbb{P}(Y = 0 \mid X^{(1)} = 1) = \frac{1}{2}.$$

On obtient donc :

$$H(Y \mid X^{(1)} = 1) = -\frac{1}{2} \log\left(\frac{1}{2}\right) - \frac{1}{2} \log\left(\frac{1}{2}\right) = \log 2 \approx 0.693.$$

- $X^{(1)} = 0$: patients 2, 3 et 4. Puisque Y prend deux fois la valeur 1 et une fois la valeur 0, on a

$$\mathbb{P}(Y = 1 \mid X^{(1)} = 0) = \frac{2}{3}, \quad \mathbb{P}(Y = 0 \mid X^{(1)} = 0) = \frac{1}{3}.$$

Ainsi :

$$H(Y \mid X^{(1)} = 0) = -\frac{2}{3} \log\left(\frac{2}{3}\right) - \frac{1}{3} \log\left(\frac{1}{3}\right) \approx 0.637.$$

Les poids sont :

$$\mathbb{P}(X^{(1)} = 1) = \frac{2}{5}, \quad \mathbb{P}(X^{(1)} = 0) = \frac{3}{5}.$$

Ainsi :

$$H(Y \mid X^{(1)}) = \frac{2}{5} \times 0.693 + \frac{3}{5} \times 0.637 \approx \boxed{0.659}.$$

Variable $X^{(2)}$ (Hard).

- $X^{(2)} = 1$: patient 3 uniquement, avec $Y = 1$. On a alors

$$\mathbb{P}(Y = 1 \mid X^{(2)} = 1) = 1, \quad \mathbb{P}(Y = 0 \mid X^{(2)} = 1) = 0.$$

Par conséquent :

$$H(Y \mid X^{(2)} = 1) = -1 \cdot \log(1) - 0 \cdot \log(0).$$

Or $\log(1) = 0$ et, *par croissance comparée*,

$$\lim_{p \rightarrow 0^+} p \log(p) = 0,$$

d'où la convention $0 \cdot \log(0) = 0$. On obtient finalement

$$H(Y \mid X^{(2)} = 1) = 0.$$

- $X^{(2)} = 0$: patients 1, 2, 4 et 5. On observe

$$\mathbb{P}(Y = 1 \mid X^{(2)} = 0) = \frac{1}{2}, \quad \mathbb{P}(Y = 0 \mid X^{(2)} = 0) = \frac{1}{2}.$$

Ainsi :

$$H(Y \mid X^{(2)} = 0) = \log 2 \approx 0.693.$$

Les poids sont :

$$\mathbb{P}(X^{(2)} = 1) = \frac{1}{5}, \quad \mathbb{P}(X^{(2)} = 0) = \frac{4}{5}.$$

Ainsi :

$$H(Y \mid X^{(2)}) = \frac{1}{5} \times 0 + \frac{4}{5} \times 0.693 \approx \boxed{0.554}.$$

Variable $X^{(3)}$ (Symmetric).

- $X^{(3)} = 1$: patients 3, 4 et 5. On observe

$$\mathbb{P}(Y = 1 \mid X^{(3)} = 1) = \frac{1}{3}, \quad \mathbb{P}(Y = 0 \mid X^{(3)} = 1) = \frac{2}{3}.$$

D'où :

$$H(Y \mid X^{(3)} = 1) = -\frac{1}{3} \log\left(\frac{1}{3}\right) - \frac{2}{3} \log\left(\frac{2}{3}\right) \approx 0.637.$$

- $X^{(3)} = 0$: patients 1 et 2. Dans ce cas,

$$\mathbb{P}(Y = 1 \mid X^{(3)} = 0) = 1, \quad \mathbb{P}(Y = 0 \mid X^{(3)} = 0) = 0,$$

et donc, comme précédemment,

$$H(Y \mid X^{(3)} = 0) = 0.$$

Les poids sont :

$$\mathbb{P}(X^{(3)} = 1) = \frac{3}{5}, \quad \mathbb{P}(X^{(3)} = 0) = \frac{2}{5}.$$

Ainsi :

$$H(Y \mid X^{(3)}) = \frac{3}{5} \times 0.637 + \frac{2}{5} \times 0 \approx \boxed{0.382}.$$

Gains d'information. Le gain d'information associé à $X^{(j)}$ est défini par :

$$IG(Y, X^{(j)}) = H(Y) - H(Y \mid X^{(j)}).$$

On obtient :

$$IG(Y, X^{(1)}) \approx 0.673 - 0.659 = 0.014,$$

$$IG(Y, X^{(2)}) \approx 0.673 - 0.554 = 0.119,$$

$$IG(Y, X^{(3)}) \approx 0.673 - 0.382 = 0.291.$$

Premier nœud de l'arbre. Le gain d'information est maximal pour la variable $X^{(3)}$ et servira donc de premier nœud à l'arbre de décision.

3) Choix de la seconde découpe de l'arbre de décision. On a établi à la question précédente que la variable $X^{(3)}$ (caractère symétrique) constitue le premier nœud de l'arbre de décision. On cherche maintenant à déterminer s'il est nécessaire d'introduire une seconde découpe, et le cas échéant, quelle variable explicative utiliser.

On raisonne donc conditionnellement à la valeur prise par $X^{(3)}$.

- **Cas $X^{(3)} = 0$.**

D'après le tableau de données, lorsque $X^{(3)} = 0$, on observe uniquement des patients pour lesquels $Y = 1$. Ainsi :

$$\mathbb{P}(Y = 1 \mid X^{(3)} = 0) = 1, \quad \mathbb{P}(Y = 0 \mid X^{(3)} = 0) = 0.$$

Par conséquent :

$$H(Y \mid X^{(3)} = 0) = -1 \cdot \log(1) - 0 \cdot \log(0) = \boxed{0}.$$

Cette branche est donc **pure** et ne nécessite aucune autre découpe.

- **Cas** $X^{(3)} = 1$.

Lorsque $X^{(3)} = 1$, les patients concernés sont les patients 3, 4 et 5. On observe alors :

$$Y = (1, 0, 0),$$

et donc :

$$\mathbb{P}(Y = 1 \mid X^{(3)} = 1) = \frac{1}{3}, \quad \mathbb{P}(Y = 0 \mid X^{(3)} = 1) = \frac{2}{3}.$$

L'entropie au nœud correspondant vaut :

$$H(Y \mid X^{(3)} = 1) = -\frac{1}{3} \log\left(\frac{1}{3}\right) - \frac{2}{3} \log\left(\frac{2}{3}\right) > 0.$$

Une nouvelle découpe peut s'avérer nécessaire si les entropies calculées par la suite sont moindres.

On compare alors les deux variables restantes $X^{(1)}$ (Large) et $X^{(2)}$ (Hard).

Calcul de $H(Y \mid X^{(1)}, X^{(3)} = 1)$.

Conditionnellement à $X^{(3)} = 1$, on observe :

$$\mathbb{P}(X^{(1)} = 1 \mid X^{(3)} = 1) = \frac{1}{3}, \quad \mathbb{P}(X^{(1)} = 0 \mid X^{(3)} = 1) = \frac{2}{3}.$$

- Si $X^{(1)} = 1$, alors $Y = 0$ avec certitude, donc

$$H(Y \mid X^{(1)} = 1, X^{(3)} = 1) = 0.$$

- Si $X^{(1)} = 0$, alors Y prend les valeurs 1 et 0 avec probabilité 1/2 chacune, et

$$H(Y \mid X^{(1)} = 0, X^{(3)} = 1) = -\frac{1}{2} \log\left(\frac{1}{2}\right) - \frac{1}{2} \log\left(\frac{1}{2}\right) = \log 2 \approx 0.3.$$

Ainsi :

$$H(Y \mid X^{(1)}, X^{(3)} = 1) = \frac{1}{3} \times 0 + \frac{2}{3} \times \log 2 \approx \boxed{0.46}.$$

Calcul de $H(Y \mid X^{(2)}, X^{(3)} = 1)$.

Conditionnellement à $X^{(3)} = 1$, on a :

$$\mathbb{P}(X^{(2)} = 1 \mid X^{(3)} = 1) = \frac{1}{3}, \quad \mathbb{P}(X^{(2)} = 0 \mid X^{(3)} = 1) = \frac{2}{3}.$$

- Si $X^{(2)} = 1$, alors $Y = 1$ avec certitude, donc

$$H(Y \mid X^{(2)} = 1, X^{(3)} = 1) = 0.$$

- Si $X^{(2)} = 0$, alors $Y = 0$ avec certitude, donc

$$H(Y \mid X^{(2)} = 0, X^{(3)} = 1) = 0.$$

Ainsi :

$$H(Y \mid X^{(2)}, X^{(3)} = 1) = \frac{1}{3} \times 0 + \frac{2}{3} \times 0 = \boxed{0}.$$

Conclusion.


Dans la branche $X^{(3)} = 1$, la variable $X^{(2)}$ minimise l'entropie conditionnelle. La seconde découpe de l'arbre de décision est donc effectuée selon $X^{(2)}$.

Après cette découpe, toutes les feuilles sont pures et **aucune autre question n'est nécessaire**.

La structure finale de l'arbre de décision est donc la suivante :

- Si $X^{(3)} = 0$, alors $Y = 1$.
- Si $X^{(3)} = 1$:
 - si $X^{(2)} = 1$, alors $Y = 1$,
 - si $X^{(2)} = 0$, alors $Y = 0$.

4) Arbre de décision obtenu. La question précédente nous permet maintenant de dessiner l'arbre appris sur les données de l'énoncé.



5) Prédictions.

- Patient $X^{(1)} = 0$, $X^{(2)} = 0$, $X^{(3)} = 1$:

$$\hat{Y} = 0 \quad (\text{tumeur bénigne}).$$

- Patient $X^{(1)} = 1$, $X^{(2)} = 1$, $X^{(3)} = 1$:

$$\hat{Y} = 1 \quad (\text{tumeur maligne}).$$

Remarques.

- Le changement de base du logarithme modifie les valeurs numériques mais **pas l'ordre des gains d'information**.
- Une entropie nulle correspond à une situation de **pureté parfaite** du sous-échantillon.
- Sur un échantillon de très petite taille, l'arbre obtenu ajuste exactement les données, illustrant le phénomène de **sur-apprentissage**. Le fait que les conclusions soient sans appel et qu'aucune donnée ne contredise les décisions est tout de même très suspect. Il est impossible qu'avec des données réelles, on n'ait pas de fluctuations contradictoires. *Ceci n'est pas très surprenant vu que l'énoncé ne s'appuie que sur 5 observations.*

Correction – Exercice 3 : Analyse du comportement client par arbre de décision

On dispose de $n = 13$ clients, de deux variables explicatives $X^{(1)}$ (type de musique) et $X^{(2)}$ (prix), ainsi que d'une variable réponse binaire Y , où

$$Y = 1 \iff \text{transaction finalisée}, \quad Y = 0 \iff \text{transaction abandonnée}.$$

Dans toute la correction, on utilise le logarithme naturel $\log$.

1) **Entropie marginale de Y .** À partir du tableau :

$$\#\{Y = 1\} = 7, \quad \#\{Y = 0\} = 6,$$

d'où

$$\mathbb{P}(Y = 1) = \frac{7}{13}, \quad \mathbb{P}(Y = 0) = \frac{6}{13}.$$

Ainsi :

$$H(Y) = -\frac{7}{13} \log\left(\frac{7}{13}\right) - \frac{6}{13} \log\left(\frac{6}{13}\right) \approx 0.690.$$

2) **Entropies conditionnelles et gains d'information.**

Conditionnement par $X^{(2)}$ (Prix). On sépare selon $X^{(2)} \in \{0, 1\}$.

- **Cas $X^{(2)} = 0$.** Les clients concernés sont 2, 4, 5, 8, 12, soit 5 observations. Les réponses observées sont $Y = (1, 1, 1, 0, 1)$, donc :

$$\mathbb{P}(Y = 1 \mid X^{(2)} = 0) = \frac{4}{5}, \quad \mathbb{P}(Y = 0 \mid X^{(2)} = 0) = \frac{1}{5}.$$

Ainsi :

$$H(Y \mid X^{(2)} = 0) = -\frac{4}{5} \log\left(\frac{4}{5}\right) - \frac{1}{5} \log\left(\frac{1}{5}\right) \approx 0.500.$$

- **Cas $X^{(2)} = 1$.** Les clients concernés sont 1, 3, 6, 7, 9, 10, 11, 13, soit 8 observations. On observe $Y = (1, 1, 0, 0, 1, 0, 0, 0)$, donc :

$$\mathbb{P}(Y = 1 \mid X^{(2)} = 1) = \frac{3}{8}, \quad \mathbb{P}(Y = 0 \mid X^{(2)} = 1) = \frac{5}{8}.$$

Ainsi :

$$H(Y \mid X^{(2)} = 1) = -\frac{3}{8} \log\left(\frac{3}{8}\right) - \frac{5}{8} \log\left(\frac{5}{8}\right) \approx 0.662.$$

Les poids étant $\mathbb{P}(X^{(2)} = 0) = \frac{5}{13}$ et $\mathbb{P}(X^{(2)} = 1) = \frac{8}{13}$, on obtient :

$$\begin{aligned} H(Y \mid X^{(2)}) &= \frac{5}{13} H(Y \mid X^{(2)} = 0) + \frac{8}{13} H(Y \mid X^{(2)} = 1) \\ &\approx \frac{5}{13} \times 0.500 + \frac{8}{13} \times 0.662 \\ &\approx 0.600. \end{aligned}$$

Le gain d'information correspondant vaut alors :

$$IG(Y, X^{(2)}) = H(Y) - H(Y \mid X^{(2)}) \approx 0.690 - 0.600 = 0.090.$$

Conditionnement par $X^{(1)}$ (Type de musique). On sépare selon $X^{(1)} \in \{C, P, R\}$.

- **Cas $X^{(1)} = C$.** Clients 1, 4, 9 (3 observations) et $Y = (1, 1, 1)$. Donc $\mathbb{P}(Y = 1 \mid X^{(1)} = C) = 1$ et

$$H(Y \mid X^{(1)} = C) = -1 \log(1) - 0 \log(0) = 0.$$

- **Cas $X^{(1)} = P$.** Clients 5, 7, 8, 10, 12 (5 observations) et $Y = (1, 0, 0, 0, 1)$. Donc $\mathbb{P}(Y = 1 \mid X^{(1)} = P) = \frac{2}{5}$ et

$$H(Y \mid X^{(1)} = P) = -\frac{2}{5} \log\left(\frac{2}{5}\right) - \frac{3}{5} \log\left(\frac{3}{5}\right) \approx 0.673.$$

- **Cas $X^{(1)} = R$.** Clients 2, 3, 6, 11, 13 (5 observations) et $Y = (1, 1, 0, 0, 0)$. Donc $\mathbb{P}(Y = 1 \mid X^{(1)} = R) = \frac{2}{5}$ et

$$H(Y \mid X^{(1)} = R) = -\frac{2}{5} \log\left(\frac{2}{5}\right) - \frac{3}{5} \log\left(\frac{3}{5}\right) \approx 0.673.$$

Les poids étant $\mathbb{P}(X^{(1)} = C) = \frac{3}{13}$, $\mathbb{P}(X^{(1)} = P) = \frac{5}{13}$ et $\mathbb{P}(X^{(1)} = R) = \frac{5}{13}$, on obtient :

$$\begin{aligned} H(Y \mid X^{(1)}) &= \frac{3}{13} \times 0 + \frac{5}{13} \times 0.673 + \frac{5}{13} \times 0.673 \\ &= \frac{10}{13} \times 0.673 \\ &\approx 0.518. \end{aligned}$$

Le gain d'information correspondant vaut alors :

$$IG(Y, X^{(1)}) = H(Y) - H(Y \mid X^{(1)}) \approx 0.690 - 0.518 = 0.172.$$

Conclusion : le gain d'information est plus grand pour $X^{(1)}$ que pour $X^{(2)}$. Le premier nœud de l'arbre (critère entropie) est donc $X^{(1)}$.

3) Construction de l'arbre de décision (critère d'entropie).

Faut-il poursuivre la subdivision dans la région $X^{(1)} \neq C$? Après le premier découpage selon $X^{(1)}$, la région $X^{(1)} = C$ est **pure** : toutes les observations vérifient $Y = 1$. On crée donc immédiatement une feuille associée à cette région. Il reste à étudier la région complémentaire $X^{(1)} \neq C$, qui regroupe les observations telles que

$$X^{(1)} \in \{P, R\}.$$

Dans cette région, on observe encore un mélange des classes. On cherche donc à déterminer si une nouvelle subdivision permet de réduire l'entropie.

Peut-on découper selon $X^{(1)} = P$ ou $X^{(1)} = R$? On a déjà observé que

$$H(Y \mid X^{(1)} = P) = H(Y \mid X^{(1)} = R) = 0.673.$$

Ainsi, distinguer les modalités P et R ne permet pas de réduire davantage l'incertitude : cette séparation n'apporte donc **aucun gain d'information supplémentaire**. Il est donc naturel d'examiner maintenant un découpage selon la variable $X^{(2)}$.

Découpage selon $X^{(2)}$ dans la région $X^{(1)} \neq C$. On souhaite calculer l'entropie conditionnelle

$$H(Y \mid X^{(1)} \neq C, X^{(2)}).$$

Par définition, cette quantité est la moyenne pondérée des entropies des deux sous-régions obtenues :

$$H(Y \mid X^{(1)} \neq C, X^{(2)}) = \frac{n_{X^{(2)}=0}}{n_{X^{(1)} \neq C}} H(Y \mid X^{(1)} \neq C, X^{(2)} = 0) + \frac{n_{X^{(2)}=1}}{n_{X^{(1)} \neq C}} H(Y \mid X^{(1)} \neq C, X^{(2)} = 1).$$

Dans notre cas,

$$\frac{n_{X^{(2)}=0}}{n_{X^{(1)} \neq C}} = \frac{4}{10}, \quad \frac{n_{X^{(2)}=1}}{n_{X^{(1)} \neq C}} = \frac{6}{10}.$$

Calcul de $H(Y \mid X^{(1)} \neq C, X^{(2)} = 0)$. Dans la région

$$X^{(1)} \neq C \quad \text{et} \quad X^{(2)} = 0,$$

on observe les valeurs suivantes :

$$Y = (1, 0, 1, 1).$$

On obtient donc

$$p(Y = 1) = \frac{3}{4}, \quad p(Y = 0) = \frac{1}{4}.$$

Ainsi,

$$H(Y \mid X^{(1)} \neq C, X^{(2)} = 0) = -\frac{3}{4} \log\left(\frac{3}{4}\right) - \frac{1}{4} \log\left(\frac{1}{4}\right) \approx 0.562.$$

Calcul de $H(Y \mid X^{(1)} \neq C, X^{(2)} = 1)$. Dans la région

$$X^{(1)} \neq C \quad \text{et} \quad X^{(2)} = 1,$$

on observe

$$Y = (1, 0, 0, 0, 0, 0).$$

Ainsi,

$$p(Y = 1) = \frac{1}{6}, \quad p(Y = 0) = \frac{5}{6}.$$


Donc

$$H(Y \mid X^{(1)} \neq C, X^{(2)} = 1) = -\frac{1}{6} \log\left(\frac{1}{6}\right) - \frac{5}{6} \log\left(\frac{5}{6}\right) \approx 0.451.$$

Entropie conditionnelle obtenue. On obtient finalement

$$H(Y \mid X^{(1)} \neq C, X^{(2)}) = \frac{4}{10} \times 0.562 + \frac{6}{10} \times 0.451 \approx \boxed{0.495}.$$

Conclusion. Cette valeur est inférieure à l'entropie initiale de la région $X^{(1)} \neq C$ (égale à 0.673). Le découpage selon $X^{(2)}$ permet donc de **réduire l'entropie**. Il est donc pertinent de poursuivre la construction de l'arbre en introduisant un second nœud de décision basé sur la variable $X^{(2)}$.



On part de la racine $X^{(1)}$.

- **Branche $X^{(1)} = C$.** Les observations sont toutes de classe $Y = 1$. La feuille est donc pure et la prédiction est

$$X^{(1)} = C \Rightarrow \hat{Y} = 1.$$

- **Branche** $X^{(1)} \in \{P, R\}$ (i.e. $X^{(1)} \neq C$). Les observations ne sont pas pures. On effectue donc un nouveau découpage selon $X^{(2)}$:

- Si $X^{(2)} = 0$, les observations correspondantes donnent **majoritairement** $Y = 1$. La prédiction est donc

$$\hat{Y} = 1.$$

- Si $X^{(2)} = 1$, les observations correspondantes donnent **majoritairement** $Y = 0$. La prédiction est donc

$$\hat{Y} = 0.$$

4) Prédiction pour un nouveau client. La question demande une prédiction pour un client ayant $X^{(1)} = C$ et $X^{(2)} = 1$. Dans l'arbre, la branche $X^{(1)} = C$ mène directement à une feuille :

$$X^{(1)} = C \Rightarrow \hat{Y} = 1.$$

On prédit donc que la transaction sera finalisée.

5) Interprétation métier.

- Les clients intéressés par la musique **Classique** finalisent systématiquement la transaction dans les données observées.
- Pour les clients intéressés par la **Pop**, le **prix** joue un rôle : un prix élevé est associé à un abandon, tandis qu'un prix bas est plus favorable à la finalisation.
- Pour les clients intéressés par le **RnB**, un prix bas mène ici à une transaction, tandis qu'un prix élevé est majoritairement associé à un abandon.

———— Fin correction Exercice 3 ————

Correction – Exercice 4 : achat à partir de variables catégorielles

Objectif. On souhaite construire un **arbre de régression**. À chaque nœud, on choisit la variable qui minimise la **RSS** (*Residual Sum of Squares*) :

$$\text{RSS} = \sum_{i \in \text{nœud}} (Y_i - \bar{Y}_{\text{nœud}})^2.$$

L'idée est simple : une bonne séparation doit produire des sous-régions dans lesquelles les valeurs de Y sont les plus homogènes possible.

1. Statistiques globales

Les valeurs observées sont :

$$Y = (25, 30, 46, 45, 52, 23, 43, 35, 38, 46, 48, 52, 44, 30).$$

La moyenne empirique est

$$\bar{Y} = \frac{1}{14} \sum_{i=1}^{14} Y_i = \frac{557}{14} \approx 39.79.$$

L'écart-type empirique est

$$s_Y = \sqrt{\frac{1}{14} \sum_{i=1}^{14} (Y_i - \bar{Y})^2} \approx 9.4.$$

Ces statistiques donnent une idée de la dispersion globale des ventes.

2. Calcul de la RSS pour chaque variable

On calcule la RSS obtenue après séparation selon chaque variable.

Variable $X^{(1)}$: Météo Commençons par examiner la variable **Météo**. L'idée est de séparer les observations selon les différentes modalités de cette variable, puis de mesurer l'homogénéité des valeurs de Y dans chacune des régions obtenues.

Pour cela, on regroupe les observations partageant la même modalité de $X^{(1)}$. On obtient alors les trois sous-régions suivantes :

Modalité	Y
E	(25, 30, 35, 38, 48)
N	(46, 43, 52, 44)
P	(45, 52, 23, 46, 30)

Cette table permet simplement de visualiser comment les valeurs de la variable réponse se répartissent dans chaque groupe. L'objectif est maintenant de mesurer l'homogénéité de ces groupes.

Pour chaque modalité, on calcule donc la moyenne locale :

$$\bar{Y}_E = 35.2 \quad \bar{Y}_N = 46.25 \quad \bar{Y}_P = 39.2$$

Dans un arbre de régression, la prédiction associée à une région est précisément cette moyenne. La qualité de la séparation est ensuite évaluée en calculant la **RSS** dans chaque région, c'est-à-dire la somme des carrés des écarts à la moyenne locale :

$$RSS_E = (25 - \bar{Y}_E)^2 + (30 - \bar{Y}_E)^2 + (35 - \bar{Y}_E)^2 + (38 - \bar{Y}_E)^2 + (48 - \bar{Y}_E)^2 = 308.8$$

$$RSS_N = (46 - \bar{Y}_N)^2 + (43 - \bar{Y}_N)^2 + (52 - \bar{Y}_N)^2 + (44 - \bar{Y}_N)^2 = 46.75$$

$$RSS_P = (45 - \bar{Y}_P)^2 + (52 - \bar{Y}_P)^2 + (23 - \bar{Y}_P)^2 + (46 - \bar{Y}_P)^2 + (30 - \bar{Y}_P)^2 = 603.2$$

La RSS totale obtenue après séparation selon la météo est donc

$$RSS_{X^{(1)}} = RSS_E + RSS_N + RSS_P = 958.75.$$

Cette quantité mesure l'hétérogénéité globale restante après la séparation. Plus cette valeur est faible, plus la variable explicative permet de produire des régions homogènes.

On a simplement à répéter la même procédure pour les autres variables explicatives, afin *in fine* d'identifier celle qui réduit le plus la RSS.

Variable $X^{(2)}$: Température

Modalité	Y
C	(25, 30, 46, 44)
M	(45, 35, 46, 48, 52, 30)
F	(52, 23, 43, 38)

$$\bar{Y}_C = 36.25 \quad \bar{Y}_M = 42.67 \quad \bar{Y}_F = 39$$

$$RSS_C = 314.75 \quad RSS_M = 261.33 \quad RSS_F = 458$$

$$RSS_{X^{(2)}} \approx 1034.1$$

Variable $X^{(3)}$: Humidité

Modalité	Y
1	(25, 30, 46, 45, 35, 52, 30)
0	(52, 23, 43, 38, 46, 48, 44)

$$\bar{Y}_1 \approx 37.57 \quad \bar{Y}_0 = 42$$

$$\text{RSS}_1 \approx 636.7 \quad \text{RSS}_0 \approx 564$$

$$\text{RSS}_{X^{(3)}} \approx 1200.7$$

Variable $X^{(4)}$: Soldes

Modalité	Y
1	(25, 46, 45, 52, 35, 38, 46, 44)
0	(30, 23, 43, 48, 52, 30)

$$\bar{Y}_1 = 41.375 \quad \bar{Y}_0 = 37.67$$

$$\text{RSS}_1 \approx 525.9 \quad \text{RSS}_0 \approx 597.3$$

$$\text{RSS}_{X^{(4)}} \approx 1123.2$$

3. Choix de la racine

On compare les RSS :

Variable	RSS
$X^{(1)}$ (Météo)	958.75
$X^{(2)}$ (Température)	1034.1
$X^{(3)}$ (Humidité)	1200.7
$X^{(4)}$ (Soldes)	1123.2

La plus petite RSS est obtenue pour :

$$X^{(1)} = \text{Météo.}$$

Cette variable constitue donc la **racine de l'arbre**.

4. Deuxième niveau de l'arbre

La variable explicative de la **Météo** minimise la RSS globale. Elle constitue donc la **racine de l'arbre**. L'échantillon est alors partitionné en trois régions correspondant aux modalités de $X^{(1)}$:

$$E, \quad N, \quad P.$$

L'algorithme de construction d'un arbre de régression est *récuratif* : on applique exactement la même procédure dans chacune des régions obtenues. Autrement dit, pour chaque sous-région conditionnée par $X^{(1)} = E, N$ ou P , on cherche parmi les variables restantes $\{X^{(2)}, X^{(3)}, X^{(4)}\}$ celle qui permet de réduire au maximum la RSS.

Région $X^{(1)} = E$ Les observations correspondant à une météo ensoleillée sont :

$$Y = (25, 30, 35, 38, 48).$$

La moyenne dans cette région est

$$\bar{Y}_E = 35.2.$$

Cependant, on observe une dispersion encore importante entre les valeurs :

$$\text{RSS}_E = (25 - 35.2)^2 + (30 - 35.2)^2 + (35 - 35.2)^2 + (38 - 35.2)^2 + (48 - 35.2)^2 = 308.8.$$

Il est donc pertinent de tester une nouvelle séparation. On examine alors les variables restantes (**Température**, **Humidité**, **Soldes**) afin de déterminer laquelle permet de produire les sous-régions les plus homogènes.

Par exemple, en séparant selon la variable **Soldes**, les données se répartissent en deux groupes :

Soldes	Y
1	(25, 35, 38)
0	(30, 48)

Les moyennes correspondantes sont

$$\bar{Y}_{E,1} = 32.7, \quad \bar{Y}_{E,0} = 39.$$

La variance à l'intérieur des groupes est alors plus faible que dans la région initiale.

En effet :

$$\text{RSS}_{E,1} = (25 - 32.7)^2 + (35 - 32.7)^2 + (38 - 32.7)^2 \approx 91.9$$

$$\text{RSS}_{E,0} = (30 - 39)^2 + (48 - 39)^2 = 162$$

La RSS totale après séparation est donc

$$\text{RSS}_{E|\text{Soldes}} = \text{RSS}_{E,1} + \text{RSS}_{E,0} \approx 253.9,$$

ce qui est inférieur à la RSS initiale de la région E (308.8). La séparation selon la variable **Soldes** améliore donc l'homogénéité des sous-régions.

La variable **Soldes** constitue donc une bonne candidate pour effectuer la deuxième séparation dans cette branche.

Région $X^{(1)} = N$ Les observations associées à une météo nuageuse sont

$$Y = (46, 43, 52, 44).$$

La moyenne est

$$\bar{Y}_N = 46.25.$$

Les valeurs sont relativement proches les unes des autres, la dispersion est faible :

$$\text{RSS}_N = (46 - 46.25)^2 + (43 - 46.25)^2 + (52 - 46.25)^2 + (44 - 46.25)^2 = 46.75.$$

Cette valeur relativement faible indique que les observations sont déjà assez homogènes. Une nouvelle séparation réduirait donc peu la RSS, ce qui suggère de conserver cette région comme feuille de l'arbre.

Autrement dit, cette région est déjà relativement homogène. Il est donc raisonnable de la conserver comme **feuille de l'arbre** avec une prédiction égale à la moyenne :

$$\hat{Y} = 46.25.$$

Région $X^{(1)} = P$ Enfin, lorsque la météo est pluvieuse, les observations sont

$$Y = (45, 52, 23, 46, 30).$$

La moyenne est

$$\bar{Y}_P = 39.2.$$

On remarque cependant une forte dispersion dans ces valeurs, notamment à cause de l'observation $Y = 23$. Il est donc pertinent d'envisager une nouvelle séparation.

En testant les variables restantes, on observe que des variables comme **Soldes** ou **Humidité** permettent de mieux structurer les données et de réduire sensiblement la variance dans les sous-groupes.

Une telle séparation permet donc d'obtenir des régions plus homogènes et améliore la qualité de la prédiction.

On poursuit ensuite ce processus récursif jusqu'à ce qu'aucune séparation supplémentaire ne permette de réduire de manière significative la RSS.

5. Structure finale de l'arbre




FIGURE 4.3 – Arbre de décision obtenu après apprentissage sous R.

Il se lit de la façon suivante.

(★) Si la météo $X^{(1)} \notin \{E, P\}$ (c'est-à-dire $X^{(1)} = N$), alors la prédiction est

$$\hat{Y} = 46.$$

(★) Si $X^{(1)} \in \{E, P\}$, on regarde alors la température $X^{(2)}$:

→ si la température $X^{(2)} = C$, alors la prédiction est $\hat{Y} = 28$;

→ sinon ($X^{(2)} \neq C$), la prédiction est $\hat{Y} = 40$.

Ainsi, l'arbre partitionne l'espace des variables explicatives en trois régions et associe à chacune la moyenne des valeurs observées de Y dans cette région.

Conclusion. Les arbres de régression construisent une approximation **par morceaux constants** de la fonction de prédiction.

Chaque division vise à réduire la variance des observations dans les régions, ce qui revient à minimiser la RSS.

Correction – Exercice 5 : Gain numérique à partir de variables catégorielles

1) Moyenne empirique globale

On dispose de $n = 9$ observations :

$$Y = (42, 55, 38, 47, 52, 28, 35, 31, 50).$$

La moyenne empirique globale vaut

$$\bar{Y} = \frac{42 + 55 + 38 + 47 + 52 + 28 + 35 + 31 + 50}{9} = \frac{378}{9} = 42.$$

Dans un arbre de régression sans découpage (arbre réduit à une seule feuille), la prédiction du modèle serait constante et égale à

$$\hat{Y} = 42.$$

Autrement dit, en absence d'information sur les variables explicatives, la meilleure prédiction (au sens des moindres carrés) est simplement la moyenne des observations.

L'erreur quadratique associée à cette prédiction constante, c'est-à-dire la somme des carrés des écarts à la moyenne, se calcule comme :

$$\text{SSE}(Y) = \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

Ici, comme $\bar{Y} = 42$, on obtient

$$\begin{aligned} \text{SSE}(Y) &= (42 - 42)^2 + (55 - 42)^2 + (38 - 42)^2 + (47 - 42)^2 + (52 - 42)^2 \\ &\quad + (28 - 42)^2 + (35 - 42)^2 + (31 - 42)^2 + (50 - 42)^2 \\ &= 0^2 + 13^2 + (-4)^2 + 5^2 + 10^2 + (-14)^2 + (-7)^2 + (-11)^2 + 8^2 \\ &= 0 + 169 + 16 + 25 + 100 + 196 + 49 + 121 + 64 \\ &= 740. \end{aligned}$$

Ainsi, dans un arbre sans découpage, la prédiction est constante et égale à $\hat{Y} = 42$, avec une erreur quadratique totale égale à

$\text{SSE}(Y) = 740.$

Peut-on la réduire suivant un découpage selon les covariables ?

2) Découpage selon la variable $X^{(1)}$

On regroupe maintenant les observations selon la variable $X^{(1)}$.

Cas $X^{(1)} = \text{Email}$ Observations : 42, 55, 50

$$\hat{Y}_{\text{Email}} = \frac{42 + 55 + 50}{3} = 49.$$

Cas $X^{(1)} = \text{SMS}$ Observations : 38, 47, 52

$$\hat{Y}_{\text{SMS}} = \frac{38 + 47 + 52}{3} = 45.67.$$

Cas $X^{(1)} = \text{Réseaux}$ Observations : 28, 35, 31

$$\hat{Y}_{\text{Réseaux}} = \frac{28 + 35 + 31}{3} = 31.33.$$

Ces valeurs correspondent aux prédictions naturelles dans chacune des régions obtenues car, dans un arbre de régression, la constante optimale dans une région $\mathcal{R}_m$ est la moyenne empirique :

$$\hat{y}_m = \frac{1}{|\mathcal{R}_m|} \sum_{i: X_i \in \mathcal{R}_m} Y_i.$$

Elle minimise l'erreur quadratique

$$\sum_{i: X_i \in \mathcal{R}_m} (Y_i - \hat{y}_m)^2.$$

3) Découpage selon la variable $X^{(2)}$

On procède de la même manière avec la variable $X^{(2)}$.

Cas $X^{(2)} = \text{Matin}$ Observations : 42, 38, 28

$$\hat{Y}_{\text{Matin}} = \frac{42 + 38 + 28}{3} = 36.$$

Cas $X^{(2)} = \text{Après-midi}$ Observations : 47, 35, 50

$$\hat{Y}_{\text{Après-midi}} = \frac{47 + 35 + 50}{3} = 44.$$

Cas $X^{(2)} = \text{Soir}$ Observations : 55, 52, 31

$$\hat{Y}_{\text{Soir}} = \frac{55 + 52 + 31}{3} = 46.$$

Pour comparer les deux découpages possibles, on utilise le critère des moindres carrés intra-régions :

$$\sum_m \sum_{i: X_i \in \mathcal{R}_m} (Y_i - \hat{y}_m)^2.$$

On choisit le découpage qui minimise cette quantité.

4) Comparaison des deux découpages

Calculons l'erreur quadratique pour chaque partition.

Erreur associée au découpage selon $X^{(1)}$

$$\text{Email : } (42 - 49)^2 + (55 - 49)^2 + (50 - 49)^2 = 49 + 36 + 1 = 86$$

$$\text{SMS : } (38 - 45.67)^2 + (47 - 45.67)^2 + (52 - 45.67)^2 \approx 58.78 + 1.78 + 40.11 = 100.67$$

$$\text{Réseaux : } (28 - 31.33)^2 + (35 - 31.33)^2 + (31 - 31.33)^2 \approx 11.09 + 13.44 + 0.11 = 24.64$$

Donc

$$\boxed{\text{SSE}(Y \mid X^{(1)}) \approx 86 + 100.67 + 24.64 = 211.31}.$$

Erreur associée au découpage selon $X^{(2)}$

$$\text{Matin} : (42 - 36)^2 + (38 - 36)^2 + (28 - 36)^2 = 36 + 4 + 64 = 104$$

$$\text{Après-midi} : (47 - 44)^2 + (35 - 44)^2 + (50 - 44)^2 = 9 + 81 + 36 = 126$$

$$\text{Soir} : (55 - 46)^2 + (52 - 46)^2 + (31 - 46)^2 = 81 + 36 + 225 = 342$$

Donc

$$\boxed{\text{SSE}(Y \mid X^{(2)}) = 104 + 126 + 342 = 572.}$$

Comme

$$\text{SSE}(Y \mid X^{(1)}) < \text{SSE}(Y \mid X^{(2)}) < \text{SSE}(Y),$$

le **meilleur premier découpage** est obtenu avec la variable $X^{(1)}$. Elle constitue donc la racine de l'arbre.

Remarque de rigueur : choix du *split* binaire optimal sur $X^{(1)}$. Comme $X^{(1)}$ est une variable catégorielle à trois modalités,

$$X^{(1)} \in \{\text{Email}, \text{SMS}, \text{Réseaux}\},$$

un arbre binaire de type CART ne découpe pas directement en trois branches. Il faut comparer les **trois découpages binaires possibles** :

$$\{\text{Email}\} \mid \{\text{SMS}, \text{Réseaux}\}, \quad \{\text{SMS}\} \mid \{\text{Email}, \text{Réseaux}\}, \quad \{\text{Réseaux}\} \mid \{\text{Email}^1, \text{SMS}\}.$$

On retient ensuite le découpage qui minimise la somme des carrés intra-régions. On rappelle les observations associées à chaque modalité :

$$\text{Email} : (42, 55, 50), \quad \text{SMS} : (38, 47, 52), \quad \text{Réseaux} : (28, 35, 31).$$

1) Découpage $\{\text{Email}\} \mid \{\text{SMS}, \text{Réseaux}\}$. Dans la première région, on a

$$\mathcal{R}_1 = \{\text{Email}\}, \quad Y_{\mathcal{R}_1} = (42, 55, 50), \quad \hat{y}_1 = \frac{42 + 55 + 50}{3} = 49.$$

La somme des carrés intra-région vaut

$$\begin{aligned} \text{SSE}(\mathcal{R}_1) &= (42 - 49)^2 + (55 - 49)^2 + (50 - 49)^2 \\ &= 49 + 36 + 1 = 86. \end{aligned}$$

Dans la seconde région, on regroupe SMS et Réseaux :

$$\mathcal{R}_2 = \{\text{SMS}, \text{Réseaux}\}, \quad Y_{\mathcal{R}_2} = (38, 47, 52, 28, 35, 31).$$

La moyenne vaut

$$\hat{y}_2 = \frac{38 + 47 + 52 + 28 + 35 + 31}{6} = \frac{231}{6} = 38.5.$$

Donc

$$\begin{aligned} \text{SSE}(\mathcal{R}_2) &= (38 - 38.5)^2 + (47 - 38.5)^2 + (52 - 38.5)^2 \\ &\quad + (28 - 38.5)^2 + (35 - 38.5)^2 + (31 - 38.5)^2 \\ &= 0.25 + 72.25 + 182.25 + 110.25 + 12.25 + 56.25 \\ &= 433.5. \end{aligned}$$

Ainsi,

$$\boxed{\text{SSE}(\{\text{Email}\} \mid \{\text{SMS}, \text{Réseaux}\}) = 86 + 433.5 = 519.5.}$$

1. Cela se lit comme « on partitionne l'espace selon le test $X^{(1)} = \text{Réseaux}$ contre $X^{(1)} \neq \text{Réseaux}$ ».

2) Découpage $\{\text{SMS}\} \mid \{\text{Email, Réseaux}\}$. Dans la première région,

$$\mathcal{R}_1 = \{\text{SMS}\}, \quad Y_{\mathcal{R}_1} = (38, 47, 52), \quad \hat{y}_1 = \frac{38 + 47 + 52}{3} = \frac{137}{3} \approx 45.67.$$

On obtient

$$\begin{aligned} \text{SSE}(\mathcal{R}_1) &= \left(38 - \frac{137}{3}\right)^2 + \left(47 - \frac{137}{3}\right)^2 + \left(52 - \frac{137}{3}\right)^2 \\ &= \left(-\frac{23}{3}\right)^2 + \left(\frac{4}{3}\right)^2 + \left(\frac{19}{3}\right)^2 \\ &= \frac{529 + 16 + 361}{9} = \frac{906}{9} = \frac{302}{3} \approx 100.67. \end{aligned}$$

Dans la seconde région,

$$\mathcal{R}_2 = \{\text{Email, Réseaux}\}, \quad Y_{\mathcal{R}_2} = (42, 55, 50, 28, 35, 31).$$

La moyenne vaut

$$\hat{y}_2 = \frac{42 + 55 + 50 + 28 + 35 + 31}{6} = \frac{241}{6} \approx 40.17.$$

Donc

$$\begin{aligned} \text{SSE}(\mathcal{R}_2) &= (42 - 40.17)^2 + (55 - 40.17)^2 + (50 - 40.17)^2 \\ &\quad + (28 - 40.17)^2 + (35 - 40.17)^2 + (31 - 40.17)^2 \\ &\approx 3.36 + 220.03 + 96.69 + 148.03 + 26.69 + 84.03 \\ &\approx 578.83. \end{aligned}$$

Ainsi,

$$\boxed{\text{SSE}(\{\text{SMS}\} \mid \{\text{Email, Réseaux}\}) \approx 100.67 + 578.83 = 679.5}.$$

3) Découpage $\{\text{Réseaux}\} \mid \{\text{Email, SMS}\}$. Dans la première région,

$$\mathcal{R}_1 = \{\text{Réseaux}\}, \quad Y_{\mathcal{R}_1} = (28, 35, 31), \quad \hat{y}_1 = \frac{28 + 35 + 31}{3} = \frac{94}{3} \approx 31.33.$$

On obtient

$$\begin{aligned} \text{SSE}(\mathcal{R}_1) &= \left(28 - \frac{94}{3}\right)^2 + \left(35 - \frac{94}{3}\right)^2 + \left(31 - \frac{94}{3}\right)^2 \\ &= \left(-\frac{10}{3}\right)^2 + \left(\frac{11}{3}\right)^2 + \left(-\frac{1}{3}\right)^2 \\ &= \frac{100 + 121 + 1}{9} = \frac{222}{9} = \frac{74}{3} \approx 24.67. \end{aligned}$$

Dans la seconde région,

$$\mathcal{R}_2 = \{\text{Email, SMS}\}, \quad Y_{\mathcal{R}_2} = (42, 55, 50, 38, 47, 52).$$

La moyenne vaut

$$\hat{y}_2 = \frac{42 + 55 + 50 + 38 + 47 + 52}{6} = \frac{284}{6} = \frac{142}{3} \approx 47.33.$$

Donc

$$\begin{aligned} \text{SSE}(\mathcal{R}_2) &= \left(42 - \frac{142}{3}\right)^2 + \left(55 - \frac{142}{3}\right)^2 + \left(50 - \frac{142}{3}\right)^2 \\ &\quad + \left(38 - \frac{142}{3}\right)^2 + \left(47 - \frac{142}{3}\right)^2 + \left(52 - \frac{142}{3}\right)^2 \\ &= \left(-\frac{16}{3}\right)^2 + \left(\frac{23}{3}\right)^2 + \left(\frac{8}{3}\right)^2 + \left(-\frac{28}{3}\right)^2 + \left(-\frac{1}{3}\right)^2 + \left(\frac{14}{3}\right)^2 \\ &= \frac{256 + 529 + 64 + 784 + 1 + 196}{9} = \frac{1830}{9} = \frac{610}{3} \approx 203.33. \end{aligned}$$

Ainsi,

$$\boxed{\text{SSE}(\{\text{Réseaux}\} \mid \{\text{Email, SMS}\}) \approx 24.67 + 203.33 = 228}.$$

Conclusion sur la première découpe. On compare les trois valeurs obtenues :

$$519.5, \quad 679.5, \quad 228.$$

Le meilleur découpage binaire sur $X^{(1)}$ est donc

$$\{\text{Réseaux}\} \mid \{\text{Email, SMS}\},$$

car c'est celui qui minimise la somme des carrés intra-régions. Ainsi, en toute rigueur, si l'on construit un arbre binaire de régression de type CART, la racine optimale associée à la variable $X^{(1)}$ consiste à séparer d'abord les clients issus des **Réseaux** des clients issus des campagnes **Email** ou **SMS**.

La suite du calcul de découpes successives étant d'autant plus fastidieuse, on se contentera de générer les résultats estimés sur R.




FIGURE 4.4 – Arbre appris sur R.

5) Interprétation

Cet exemple montre qu'un arbre de régression peut utiliser des variables explicatives **catégorielles** pour prédire une variable réponse **quantitative continue**. En effet :

- chaque modalité d'une variable catégorielle définit une région de l'espace des covariables ;
- dans chaque région, la prédiction est simplement la moyenne empirique des observations présentes ;
- le choix du découpage optimal repose sur la minimisation de l'erreur quadratique intra-régions.

Ainsi, même en absence de relation linéaire entre variables, les arbres de régression permettent de construire un modèle prédictif d'une réponse continue, interprétable et efficace, à partir de variables catégorielles. *La classe, non ?*

———— Fin correction Exercice 5 ————

Chapitre 5

TD5 - Forêt aléatoire

Correction – Exercice 1 : Arbres de décision et forêts aléatoires

On considère le jeu de données `mtcars`, composé de $n = 32$ observations, et le problème de classification suivant :

$$Y = \text{am} \in \{0, 1\},$$

où $Y = 0$ correspond à une boîte automatique et $Y = 1$ à une boîte manuelle. Les variables explicatives sont notées $X^{(1)}, \dots, X^{(6)}$ comme dans l'énoncé.

1) Séparation apprentissage / test. Le jeu de données est séparé aléatoirement en deux sous-échantillons :

- un échantillon d'apprentissage (50 % des données),
- un échantillon de test (50 % des données).

Cette séparation permet d'évaluer la capacité de **généralisation** d'un modèle, c'est-à-dire sa performance sur des données non utilisées lors de l'apprentissage. Une performance élevée sur l'échantillon d'apprentissage mais faible sur l'échantillon de test est le signe d'un **sur-apprentissage** et est donc à éviter le plus possible.

2) Apprentissage d'un arbre de décision. Un arbre de décision de classification est appris sur l'échantillon d'apprentissage pour le modèle :

$$Y = \hat{\mu}(X^{(1)}, \dots, X^{(6)}).$$

L'arbre obtenu dépend fortement des données utilisées pour l'apprentissage, en particulier lorsque l'échantillon est de petite taille.

3) Évaluation des performances. Les performances obtenues sont les suivantes :

Modèle	Accuracy train	Accuracy test
Arbre (seed 777)	1.00	0.8125
Arbre (seed 42)	1.00	0.75

On observe que :

- l'arbre ajuste parfaitement les données d'apprentissage (accuracy = 1),
 - les performances sur l'échantillon de test sont sensiblement plus faibles et varient selon la **seed**.
- Cela illustre clairement un phénomène de **sur-apprentissage**.

4) **Variabilité des arbres de décision.** En changeant la **seed**, on modifie la séparation apprentissage / test, ce qui conduit à des arbres de structures différentes.

On constate que trois choses essentielles non voulues :

- (i) les variables sélectionnées aux premiers nœuds peuvent changer,
- (ii) les seuils de décision sont différents,
- (iii) les prédictions sur l'échantillon de test varient.

Cette forte sensibilité aux données d'apprentissage traduit une **variance élevée** du modèle arbre de décision.




FIGURE 5.1 – Deux arbres de décision appris sur `mtcars` pour deux séparations apprentissage/test différentes (seed 777 et seed 42).

5) **Principe des forêts aléatoires.** Une forêt aléatoire repose sur deux mécanismes fondamentaux :

- le **bootstrap** : chaque arbre est appris sur un échantillon bootstrap des données d'apprentissage ;
- la **sélection aléatoire de variables** : à chaque nœud, seule une sous-partie des variables explicatives est candidate pour la découpe.

Ces deux sources d'aléa visent à décorrélérer les arbres individuels.

Rappel : principe du bootstrap

On part d'un échantillon d'apprentissage de taille $n = 5$:

$$[(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), (\mathbf{x}_3, y_3), (\mathbf{x}_4, y_4), (\mathbf{x}_5, y_5)].$$

Le **bootstrap** consiste à générer de nouveaux échantillons de taille n en effectuant des **tirages avec remise** dans cet échantillon initial.

Par exemple, on peut obtenir les échantillons bootstrap suivants :

$$\mathcal{D}_1^* = [(\mathbf{x}_3, y_3), (\mathbf{x}_2, y_2), (\mathbf{x}_3, y_3), (\mathbf{x}_4, y_4), (\mathbf{x}_1, y_1)]$$

$$\mathcal{D}_2^* = [(\mathbf{x}_5, y_5), (\mathbf{x}_5, y_5), (\mathbf{x}_2, y_2), (\mathbf{x}_1, y_1), (\mathbf{x}_4, y_4)]$$

$$\mathcal{D}_3^* = [(\mathbf{x}_4, y_4), (\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), (\mathbf{x}_4, y_4), (\mathbf{x}_3, y_3)]$$

$$\mathcal{D}_4^* = [(\mathbf{x}_2, y_2), (\mathbf{x}_3, y_3), (\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), (\mathbf{x}_5, y_5)].$$

Chaque échantillon bootstrap contient donc naturellement certaines observations répétées ; d'autres absentes. *Il faut imaginer ce tirage pour B très grand, et pas seulement $B = 4$...*

L'échantillon observé est considéré comme une approximation de la loi inconnue des données. Tirer avec remise dans cet échantillon revient donc à simuler de nouveaux échantillons plausibles issus de cette même loi. Le bootstrap permet ainsi de reconstruire artificiellement la **variabilité d'apprentissage** du modèle.

Dans une forêt aléatoire, **on construit alors plusieurs arbres T_b appris $\mathcal{D}_b^*$, et à chaque nœud de chaque arbre, on sélectionne aléatoirement un sous-ensemble de variables explicatives candidates pour réaliser la coupure**, ce qui permet de rendre les arbres **moins corrélés entre eux** et donc de réduire la variance du modèle agrégé.

6) Réduction de variance par agrégation : justification théorique. Soient $T_1, \dots, T_B$ des estimateurs (arbres de décision) d'une même quantité θ , supposés pour tout $b = 1, \dots, B$:

- de même espérance $\mathbb{E}[T_b] = \theta$,
- de variance $\text{Var}(T_b) = \sigma^2$,
- deux à deux faiblement corrélés, avec $\text{Corr}(T_b, T_{b'}) = \rho$ *puisque*

$$\text{Corr}(T_b, T_{b'}) = \frac{\text{Cov}(T_b, T_{b'})}{\sqrt{\text{Var}(T_b)\text{Var}(T_{b'})}},$$

on a donc

$$\text{Cov}(T_b, T_{b'}) = \rho\sigma^2,$$

pour tous $b, b' = 1, \dots, B$.

La forêt aléatoire correspond à l'estimateur agrégé :

$$\bar{T}_B = \frac{1}{B} \sum_{b=1}^B T_b.$$

Principe du bagging

Cette méthode d'**agrégation** d'arbres s'appelle le **bagging** (*bootstrap aggregating*) : on construit plusieurs arbres de décision sur des échantillons légèrement différents, puis on moyenne leurs prédictions.

On peut alors s'interroger sur la pertinence statistique de cette stratégie : en quoi moyenner plusieurs estimateurs améliore-t-il la qualité du modèle ?

Pour répondre à cette question, on étudie le comportement aléatoire de l'estimateur agrégé

$$\bar{T}_B = \frac{1}{B} \sum_{b=1}^B T_b.$$

Comme chaque estimateur vérifiant $\mathbb{E}[T_b] = \theta$, on obtient immédiatement que

$$\mathbb{E}[\bar{T}_B] = \theta,$$

par linéarité de l'espérance et uniforme espérance.

L'agrégation, *heureusement*, ne modifie pas la moyenne du modèle. La question essentielle devient alors :

La variance de l'estimateur agrégé est-elle plus faible que celle d'un arbre seul ?

C'est précisément ce calcul qui explique pourquoi les forêts aléatoires permettent de **stabiliser** les prédictions par rapport à un arbre de décision unique.

Calculons la variance du modèle agrégé pour vérifier si on a pu la réduire et donc "stabiliser" le modèle.

$$\begin{aligned} \text{Var}(\bar{T}_B) &= \text{Var}\left(\frac{1}{B} \sum_{b=1}^B T_b\right) && \text{définition de } \bar{T}_B \\ &= \frac{1}{B^2} \text{Var}\left(\sum_{b=1}^B T_b\right) && \text{car la variance est quadratique} \\ &= \frac{1}{B^2} \text{Cov}\left(\sum_{b=1}^B T_b, \sum_{b'=1}^B T_{b'}\right) && \text{car } \text{Var}(X) = \text{Cov}(X, X) \\ &= \frac{1}{B^2} \sum_{b=1}^B \sum_{b'=1}^B \text{Cov}(T_b, T_{b'}) && \text{bilinéarité de la covariance} \\ &= \frac{1}{B^2} \sum_{b=1}^B \text{Var}(T_b) + \sum_{\substack{1 \leq b, b' \leq B \\ b \neq b'}} \text{Cov}(T_b, T_{b'}) && \text{séparation termes diagonaux / hors diagonaux} \\ &= \frac{1}{B^2} \sum_{b=1}^B \text{Var}(T_b) + 2 \sum_{1 \leq b < b' \leq B} \text{Cov}(T_b, T_{b'}) && \text{car la covariance est symétrique.} \\ &= \frac{1}{B^2} \sum_{b=1}^B \sigma^2 + 2 \sum_{1 \leq b < b' \leq B} \rho \sigma^2 \\ &= \frac{1}{B^2} \left(B \sigma^2 + 2 \frac{(B-1)B}{2} \rho \sigma^2 \right) \end{aligned}$$

Ainsi,

$$\text{Var}(\bar{T}_B) = \frac{\sigma^2}{B} + \rho \frac{B-1}{B} \sigma^2 \quad (\text{Var-Bag})$$

En particulier, si les estimateurs sont indépendants ($\rho = 0$) : $\text{Var}(\bar{T}_B) = \frac{\sigma^2}{B}$.

Principe de la forêt aléatoire

L'expression (Var-Bag) montre que la variance de la moyenne des arbres dépend de deux termes.

1. Le premier terme, étant $\frac{\sigma^2}{B}$, diminue lorsque le nombre d'arbres B augmente (*il faudrait une infinité d'experts pour tendre vers 0, résultat asymptotique en accord avec la loi des grands nombres !*).
2. Le second terme quant à lui vaut $\rho \frac{B-1}{B} \sigma^2$. De deux choses l'une. Pour une infinité d'expert, si ρ n'est pas nul, on ne peut le réduire que jusqu'à $\rho \frac{B-1}{B} \sigma^2 \underset{B \rightarrow \infty}{\sim} \rho \sigma^2$, donc la corrélation entre les experts intervient quand même dans la variance du modèle agrégé. Cependant, si on instaure une méthode permettant la réduction de ρ , alors on est gagnant sur tous les points.

La forêt aléatoire vise justement à réduire ρ (corrélation deux à deux des experts supposée la même pour tous les experts) en introduisant de l'**aléa contrôlé** lors de la construction des arbres. Plus précisément :

- chaque arbre est appris sur un **échantillon bootstrap** différent du jeu de données d'origine ;
- à chaque nœud de l'arbre, on ne considère qu'un **sous-ensemble aléatoire de variables explicatives** pour effectuer la coupure.

Ces deux mécanismes rendent les arbres **moins similaires entre eux**, donc moins corrélés. On diminue ainsi la valeur de ρ , ce qui permet de réduire la variance globale de l'estimateur agrégé $\bar{T}_B$. Cette double stratégie (bootstrap + sélection aléatoire de variables) explique la **stabilité et l'efficacité prédictive** des forêts aléatoires par rapport à un arbre de décision unique.

Ainsi, l'agrégation d'un grand nombre d'arbres faiblement corrélés permet de **réduire significativement la variance**, sans augmenter le biais.

Modèle	Accuracy train	Accuracy test
RandomForest (seed 777)	1.00	0.8125
RandomForest (seed 42)	1.00	0.8125

On note que selon la *seed*, la forêt aléatoire reste plus stable et s'aligne justement avec le meilleur expert, au vu de ses performances !

7) Forêt aléatoire et importance des variables. La forêt aléatoire apprise fournit les importances suivantes :

Variable	mpg	cyl	disp	hp	wt	qsec
Importance	1.32	0.17	1.55	0.34	2.68	0.25

Ces valeurs correspondent à une mesure d'importance dite **importance par réduction d'impureté** (*impurity importance*).

Dans une forêt aléatoire, chaque arbre est construit en réalisant des découpages successifs de l'espace des variables explicatives. À chaque nœud, la variable choisie est celle qui permet de réduire le plus l'impureté (l'indice de Gini ou l'entropie de Shannon en classification ; ou l'erreur quadratique en régression). L'importance d'une variable est alors calculée comme la somme des **réductions d'impureté qu'elle produit** sur l'ensemble des arbres de la forêt :

$$\text{Importance}(X^{(j)}) = \sum_{\text{arbres}} \sum_{\text{splits sur } X^{(j)}} \Delta \text{Impureté}.$$

Ainsi, une variable est jugée importante si elle intervient souvent dans les découpages et si ces découpages améliorent fortement la qualité de la prédiction.

La variable `wt` (poids) apparaît ici comme la plus discriminante pour la prédiction du type de boîte de vitesse. Cela signifie qu'elle contribue le plus à réduire l'erreur de classification dans les arbres de la forêt. Ce résultat est cohérent avec une interprétation mécanique : les véhicules lourds sont majoritairement équipés de boîtes automatiques.

Conclusion.

- Les arbres de décision sont interprétables mais très sensibles aux données d'apprentissage.
- Cette instabilité se traduit par une variance élevée et un sur-apprentissage.
- Les forêts aléatoires réduisent la variance par agrégation de nombreux arbres faiblement corrélés, améliorant ainsi la généralisation.

Chapitre 6

TD6 - kNN

Correction Exercice 1 – Introduction à la méthode des k plus proches voisins

Question 1) Chaque observation est représentée par un point du plan

$$(X^{(1)}, X^{(2)}) = (\text{âge}, \text{temps libre}).$$


La classe $Y = 1$ correspond aux personnes qui s'inscrivent, tandis que la classe $Y = 0$ correspond aux personnes qui ne s'inscrivent pas.

La méthode du plus proche voisin consiste, pour une nouvelle observation x , à chercher l'observation du jeu d'apprentissage la plus proche au sens de la distance euclidienne. On attribue alors à x la classe de ce voisin.

$$\hat{Y}(x) = Y_{i^*}, \quad i^* = \underset{i=1, \dots, n}{\operatorname{argmin}} d(x, X_i).$$

Observation	Plus proche voisin	Classe du voisin	Classe prédite
$x_A = (27, 9)$	$(25, 10)$	$Y = 1$	$\hat{Y}(x_A) = 1$
$x_B = (37, 8.5)$	$(40, 8)$	$Y = 1$	$\hat{Y}(x_B) = 1$
$x_C = (33, 5)$	$(35, 6)$	$Y = 0$	$\hat{Y}(x_C) = 0$

TABLE 6.1 – Prédictions obtenues par la méthode du plus proche voisin (1-NN).



La frontière de décision associée à la méthode 1-NN est construite à partir des zones d'influence de chaque observation et est liée au diagramme de Voronoï des points d'apprentissage. Cette frontière est généralement très irrégulière, car elle peut changer brutalement dès qu'un point du plan devient plus proche d'une observation d'une autre classe. Elle est donc sensible aux observations isolées ou mal étiquetées.

Question 2) Avec la méthode 3-NN, on ne se limite plus au plus proche voisin. Pour une nouvelle observation x , on identifie les trois observations les plus proches, puis on attribue à x la classe majoritaire parmi ces trois voisins.


Observation	3 plus proches voisins	Classes	Classe prédite
$x_A = (27, 9)$	(25, 10), (30, 11), (28, 4)	(1, 1, 0)	$\hat{Y}_{3\text{-NN}}(x_A) = 1$
$x_B = (37, 8.5)$	(40, 8), (38, 9), (35, 6)	(0, 1, 0)	$\hat{Y}_{3\text{-NN}}(x_B) = 0$
$x_C = (33, 5)$	(35, 6), (28, 4), (38, 9)	(0, 0, 1)	$\hat{Y}_{3\text{-NN}}(x_C) = 0$

TABLE 6.2 – Prédictions obtenues par la méthode des 3 plus proches voisins (3-NN).

Notez ici que la prédiction de la classe du point B a changé ! La logique de décision est différente : 1-NN dépend d'une seule observation, tandis que 3-NN s'appuie sur un vote local.

La frontière de décision pour $k = 3$ est généralement plus régulière que celle obtenue avec $k = 1$. En effet, une observation isolée influence moins fortement la prédiction, puisqu'elle ne représente qu'un vote parmi trois. Lorsque k augmente, les frontières ont tendance à être plus lissées.

Si k devient très grand, la prédiction repose sur un voisinage très large. Le modèle devient alors plus stable, mais moins local. Dans le cas extrême où $k = n$, la prédiction ne dépend presque plus de la position du point x : on prédit simplement la classe majoritaire globale du jeu d'apprentissage.



Question 3) La méthode 1-NN est très flexible : elle peut construire des frontières complexes et s'adapter très précisément aux données observées. En contrepartie, elle est très sensible au bruit et aux observations atypiques. Une seule observation mal placée peut modifier localement la prédiction. La méthode 3-NN est plus stable, car elle repose sur un vote majoritaire parmi plusieurs voisins. Elle réduit donc l'influence d'une observation isolée. Sa frontière de décision est généralement moins irrégulière que celle de 1-NN. En revanche, elle peut perdre un peu de précision locale si des structures fines existent dans les données. *Enfin, il peut être important que les variables explicatives soient mesurées sur des échelles comparables. Ici, l'âge est mesuré en années et le temps libre en heures par semaine. Si une variable prend des valeurs beaucoup plus grandes que l'autre, elle peut dominer la distance euclidienne et donc influencer artificiellement la sélection des voisins.*


Correction Exercice 2 – Frontières de décision et influence de la distance

La distance utilisée est la distance euclidienne.

1) Frontière de décision pour $k = 1$ Avec la méthode du plus proche voisin (1-NN), chaque point du plan est affecté à la classe de l'observation la plus proche.


La frontière de décision correspond donc à l'ensemble des points du plan situés à égale distance de deux observations appartenant à des classes différentes (et est donc constituée des médiatrices des segments reliant ces observations), ce qui donne le diagramme de Voronoï associé aux observations. Chaque observation engendre une région d'influence ; la frontière est formée de segments de médiatrices et est généralement polygonale et irrégulière.

En bref, la frontière 1-NN dépend fortement de la position exacte des observations et peut changer localement dès qu'un point du jeu d'apprentissage est déplacé.



2) Effet d'un changement d'échelle On multiplie maintenant la coordonnée verticale de chaque point par 5. Cela revient à remplacer chaque point $(x, y) \leftarrow (x, 5y)$. Dans ce cas, la distance euclidienne devient

$$d((x_1, y_1), (x_2, y_2)) = \sqrt{(x_1 - x_2)^2 + 25(y_1 - y_2)^2}.$$



Ainsi, la coordonnée verticale devient beaucoup plus influente dans le calcul des distances. Puisque les voisinages changent, la frontière de décision s'en retrouve modifiée et certaines régions **peuvent changer de classe**.

Ce phénomène peut poser problème en analyse de données réelles car une variable mesurée sur une échelle plus grande peut dominer artificiellement la distance. Il est donc **souvent nécessaire de normaliser les variables** avant d'appliquer la méthode des plus proches voisins.

3) Classification avec $k = 3$ On considère maintenant le point $x = (1, 2)$. On calcule les distances aux observations :

$$d(x, (0, 1)) = \sqrt{2}, \quad d(x, (2, 3)) = \sqrt{2}, \quad d(x, (2, 0)) = \sqrt{5}.$$

Ces trois observations sont les plus proches de x . Leurs classes sont :

$$(0, 1) \Rightarrow \text{rouge}, \quad (2, 3) \Rightarrow \text{rouge}, \quad (2, 0) \Rightarrow \text{bleu}.$$

La classe majoritaire est donc la classe rouge. Ainsi,

$$\hat{Y}(x) = \text{rouge}.$$

Nombre minimal de points à ajouter pour modifier la classification Actuellement, les trois plus proches voisins sont : **rouge, rouge, bleu**. La classe majoritaire est donc **rouge**.

Pour modifier la classification avec $k = 3$, il faut que la majorité devienne bleue. Comme un seul voisin bleu est actuellement présent parmi les trois plus proches, il faut ajouter au minimum **deux nouveaux points bleus** suffisamment proches du point $x = (1, 2)$ pour entrer dans les trois plus proches voisins.




FIGURE 6.1 – Frontière de décision obtenue avec la méthode des 3 plus proches voisins. La règle majoritaire parmi les trois voisins les plus proches produit une frontière plus régulière que celle obtenue avec $k = 1$. Le point test $x = (1, 2)$ est ici classé dans la classe rouge.

Correction Exercice 3 – Prédiction du diabète gestationnel par la méthode des k plus proches voisins

Dans cet exercice, on cherche à prédire la présence d'un diabète gestationnel à partir de deux variables explicatives :

$$X^{(1)} = \text{BMI}, \quad X^{(2)} = \text{glucose}.$$

On applique pour cela la méthode des k plus proches voisins (k -NN), qui repose sur une interprétation géométrique des données dans le plan des covariables.

1) Interprétation géométrique du nuage de points

Chaque observation correspond à une patiente représentée par un point dans le plan

$$(X^{(1)}, X^{(2)}) = (\text{BMI}, \text{glucose}).$$

La position du point décrit ses caractéristiques cliniques, tandis que la couleur (ou le symbole) indique la classe associée :

$$Y = 0 \quad (\text{non diabétique}), \quad Y = 1 \quad (\text{diabétique}).$$

On observe que :

- les patientes ayant un BMI élevé et un taux de glucose élevé semblent plus souvent diabétiques ;
- les patientes ayant des valeurs plus faibles de ces variables semblent majoritairement non diabétiques ;

Les deux groupes ne sont cependant pas parfaitement séparés. Cela suggère que la frontière de décision entre les deux classes n'est pas linéaire et dépend localement des observations voisines.

2) Principe de la méthode des k plus proches voisins

La méthode des k plus proches voisins consiste à :

1. mesurer la distance entre une nouvelle observation $\mathbf{x}$ et toutes les observations du jeu d'apprentissage ;
2. sélectionner les k observations les plus proches ;
3. attribuer à $\mathbf{x}$ la classe majoritaire parmi ces voisins.

La prédiction s'écrit donc :

$$\hat{Y}(\mathbf{x}) = \operatorname{argmax}_{c \in \{0,1\}} \sum_{i \in N_k(\mathbf{x})} \mathbb{1}_{\{Y_i=c\}}.$$

Autrement dit, la décision repose sur un vote majoritaire local.

3) Classification de la patiente $\mathbf{x} = (30, 115)$ avec $k = 3$

On représente graphiquement la patiente

$$\mathbf{x} = (30, 115)$$

dans le plan (BMI, glucose). On identifie ensuite les trois observations les plus proches de ce point au sens de la distance euclidienne :

$$d(\mathbf{x}, \mathbf{x}_i) = \sqrt{\left(x_1 - X_i^{(1)}\right)^2 + \left(x_2 - X_i^{(2)}\right)^2}.$$

D'après la figure fournie, ces trois voisines appartiennent majoritairement à la classe $Y = 0$. On obtient donc la prédiction :

$$\boxed{\hat{Y}(\mathbf{x}) = 0}.$$

La patiente est donc classée comme **non diabétique** par la méthode 3-NN.

4) Classification avec la méthode 1-NN

La méthode du plus proche voisin (1-NN) consiste à ne considérer que l'observation la plus proche. Si cette observation appartient à la classe

$$Y = 1,$$

alors la prédiction devient :

$$\hat{Y}(\mathbf{x}) = 1.$$

On observe donc que la méthode 1-NN peut conduire à une prédiction différente de celle obtenue avec $k = 3$.

Cela s'explique par le fait que :

- 1-NN dépend d'une seule observation ;
- 3-NN dépend de plusieurs observations.

La méthode 3-NN est donc généralement plus stable.

5) Évolution de la frontière de décision lorsque k augmente

La frontière de décision correspond à l'ensemble des points du plan pour lesquels la classe prédite change.

On observe :

- pour $k = 1$, la frontière est très irrégulière et suit de près les observations ;
- pour $k = 3$, la frontière devient plus lisse ;
- lorsque k augmente encore, la frontière devient de plus en plus régulière.

Cela s'explique par le fait que la prédiction dépend d'un voisinage de plus en plus large.

Ainsi :

$$k \uparrow \implies \text{frontière plus lisse.}$$

6) Compromis biais-variance et capacité de généralisation

Le choix du paramètre k correspond à un compromis entre biais et variance.

Cas où k est petit. Lorsque la valeur de k est faible, la frontière de décision suit très précisément la position des observations du jeu d'apprentissage. Le modèle est alors très flexible et s'adapte fortement aux données observées, y compris à leurs fluctuations locales. Cette forte adaptabilité se traduit cependant par une variance élevée : la prédiction peut varier sensiblement si l'on modifie légèrement le jeu de données. Le modèle devient ainsi particulièrement sensible au bruit présent dans les observations. On parle dans ce cas de **surapprentissage** (*overfitting*).

Cas où k est grand. À l'inverse, lorsque la valeur de k augmente, la frontière de décision devient plus régulière car la prédiction repose sur un voisinage plus large. La variance du modèle diminue alors, ce qui rend la classification plus stable. En revanche, cette stabilisation s'accompagne d'une augmentation du biais : certaines structures locales des données peuvent ne plus être correctement prises en compte. Le modèle devient alors moins sensible aux particularités locales du nuage de points et peut perdre en précision dans certaines régions de l'espace des covariables.

Conclusion. Un choix intermédiaire de k permet généralement d'obtenir une meilleure capacité de généralisation. Dans ce contexte, la méthode 3-NN semble fournir une frontière plus stable que 1-NN, tout en restant suffisamment sensible à la structure locale des données.

———— Fin Correction Exercice 3 ————

Correction Exercice 4 – kNN régressif

Dans cet exercice, on applique la méthode des k plus proches voisins dans un contexte de **régression**. Contrairement à la classification, la variable réponse Y est ici quantitative.

1) Visualisation et principe de la méthode

a) Les observations sont représentées dans le plan


$$(X^{(1)}, X^{(2)}) = (\text{surface}, \text{heures de chauffage})$$

chaque point étant associé à une valeur de consommation électrique Y .

On observe que la consommation augmente globalement lorsque :

- la surface augmente,
- la durée de chauffage augmente.

Cela suggère une relation croissante entre les covariables et la réponse.



b) La méthode des k plus proches voisins consiste à :

- identifier les k observations les plus proches d'un point x ,
- calculer la moyenne des valeurs Y correspondantes.

La prédiction s'écrit alors :

$$\hat{f}(x) = \frac{1}{k} \sum_{i \in N_k(x)} Y_i$$

c) En classification, la prédiction repose sur un **vote majoritaire** des voisins.

En régression, la prédiction repose sur une **moyenne locale** des valeurs observées.

d) La prédiction est appelée moyenne locale car elle est calculée uniquement à partir d'observations situées dans un voisinage de x . Plus précisément, elle approxime :

$$\mathbb{E}[Y \mid X = x]$$

2) Prédiction par 1-NN puis par 3-NN

On souhaite estimer la consommation électrique d'un logement caractérisé par $x = (55, 5)$. La méthode des k plus proches voisins consiste à comparer ce logement à ceux du jeu de données en mesurant leur proximité dans le plan des covariables (surface, heures de chauffage).

Calcul des distances Pour identifier les voisins les plus proches de x , on utilise la distance euclidienne :

$$d(x, X_i) = \sqrt{\left(x_1 - X_i^{(1)}\right)^2 + \left(x_2 - X_i^{(2)}\right)^2}.$$

On calcule par exemple :

$$d((55, 5), (50, 4)) = \sqrt{(55 - 50)^2 + (5 - 4)^2} = \sqrt{25 + 1} = \sqrt{26} \approx 5.10,$$

et

$$d((55, 5), (60, 5)) = \sqrt{(55 - 60)^2 + (5 - 5)^2} = 5.$$

En répétant ce calcul pour toutes les observations du tableau, on constate que les trois logements les plus proches de x sont :

$$(50, 4), \quad (60, 5), \quad (65, 6).$$

Ces observations constituent donc les voisins les plus proches de x .

Prédiction par la méthode du plus proche voisin (1-NN) La méthode 1-NN consiste à ne considérer que l'observation la plus proche. Ici, il s'agit du logement $(60, 5)$, dont la consommation observée est $Y = 190$. La prédiction obtenue est donc :

$$\widehat{f}_{1\text{-NN}}(x) = 190.$$

On attribue donc au logement étudié la consommation du logement le plus proche dans le plan des covariables.

Prédiction par la méthode 3-NN La méthode 3-NN consiste cette fois à utiliser les trois voisins les plus proches. Leur consommation est respectivement :

$$160, \quad 190, \quad 210.$$

La prédiction est alors obtenue en calculant leur moyenne :

$$\widehat{f}_{3\text{-NN}}(x) = \frac{160 + 190 + 210}{3} = 186.67.$$

Ainsi, la méthode 3-NN fournit une estimation fondée sur plusieurs observations voisines plutôt que sur une seule.

Comparaison des deux prédictions La prédiction obtenue par la méthode 1-NN dépend uniquement d'une observation et peut donc être fortement influencée par une valeur atypique. À l'inverse, la méthode 3-NN repose sur plusieurs voisins proches et fournit ainsi une estimation plus stable et généralement plus robuste. Elle correspond à une moyenne locale des consommations observées dans le voisinage du point étudié.

3) Nouvelle estimation locale

On considère maintenant un second logement caractérisé par $x' = (78, 6)$. Comme précédemment, on commence par identifier les observations du jeu de données les plus proches de ce point dans le plan des covariables. En calculant les distances euclidiennes entre x' et les logements observés, on constate que les trois plus proches voisins sont

$$(75, 5), \quad (80, 7), \quad (65, 6),$$

dont les consommations électriques associées sont respectivement

$$220, \quad 260, \quad 210.$$

La prédiction obtenue par la méthode 3-NN est donc la moyenne de ces trois valeurs :

$$\hat{f}_{3\text{-NN}}(x') = \frac{220 + 260 + 210}{3} = 230.$$

On peut ensuite améliorer la stabilité de l'estimation en augmentant la taille du voisinage considéré. Les cinq observations les plus proches de x' deviennent alors

$$(75, 5), \quad (80, 7), \quad (65, 6), \quad (60, 5), \quad (90, 8),$$

avec des consommations respectives

$$220, \quad 260, \quad 210, \quad 190, \quad 300.$$

La prédiction obtenue par la méthode 5-NN est donc

$$\hat{f}_{5\text{-NN}}(x') = \frac{220 + 260 + 210 + 190 + 300}{5} = 236.$$

On observe que l'augmentation de la valeur de k modifie légèrement la prédiction. Cela s'explique par le fait que l'on prend en compte un voisinage plus large, incluant des observations un peu plus éloignées du point étudié. La prédiction devient ainsi plus stable, mais elle reflète moins fidèlement la structure locale immédiate des données.

4) Discussion autour du paramètre k

Le choix du paramètre k joue un rôle essentiel dans la qualité de la prédiction de la méthode des plus proches voisins.

Lorsque k est petit, la prédiction repose sur très peu d'observations : elle est sensible aux fluctuations locales des données. La variance du modèle est alors élevée.

Lorsque k augmente, la prédiction devient plus stable car elle repose sur un voisinage plus large. En revanche, certaines structures locales peuvent être lissées : le biais augmente.

Le choix de k correspond donc à un compromis classique entre biais et variance : un k trop petit rend la prédiction instable, un k trop grand la rend trop lissée.

D'ailleurs, dans le cas extrême où $k = n$, la prédiction devient simplement la moyenne de toutes les consommations observées dans l'échantillon :

$$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Elle ne dépend alors plus du point x considéré. Le modèle perd donc toute capacité à s'adapter localement aux caractéristiques du logement étudié. *C'est une prédiction bien naïve...*

5) Interprétation géométrique

- a) Les voisins correspondent aux observations situées dans un voisinage géométrique de x dans l'espace des covariables.

La prédiction est donc construite à partir d'une région locale autour de x .

- b) La qualité de la prédiction dépend fortement de la distance utilisée car elle détermine quelles observations sont considérées comme proches.

- c) Si les variables ne sont pas normalisées, une variable peut dominer le calcul des distances et biaiser la sélection des voisins.

Il est donc souvent nécessaire de centrer et réduire les variables avant d'appliquer la méthode kNN.

Correction Exercice 5 – Méthode des voisins ε

On considère la nouvelle observation

$$\mathbf{x} = (20, 30).$$

Dans tout l'exercice, on utilise la distance euclidienne

$$d(\mathbf{x}, \mathbf{X}_i) = \sqrt{(x^{(1)} - X_i^{(1)})^2 + (x^{(2)} - X_i^{(2)})^2}.$$

1) Classification par la méthode des k plus proches voisins

a) Représentation graphique Les observations doivent être placées dans le plan $(X^{(1)}, X^{(2)})$ ainsi que le point

$$\mathbf{x} = (20, 30).$$

Cette représentation permet d'identifier visuellement les voisins les plus proches.

b) Calcul des distances On calcule les distances entre $\mathbf{x}$ et chaque observation :

$X^{(1)}$	$X^{(2)}$	Y	$d(\mathbf{x}, \mathbf{X}_i)$
12	18	0	$\sqrt{64 + 144} = \sqrt{208} \approx 14.42$
15	22	0	$\sqrt{25 + 64} = \sqrt{89} \approx 9.43$
18	25	0	$\sqrt{4 + 25} = \sqrt{29} \approx 5.39$
22	30	1	$\sqrt{4 + 0} = \sqrt{4} = 2$
25	35	1	$\sqrt{25 + 25} = \sqrt{50} \approx 7.07$
28	38	1	$\sqrt{64 + 64} = \sqrt{128} \approx 11.31$
30	40	1	$\sqrt{100 + 100} = \sqrt{200} \approx 14.14$
20	28	0	$\sqrt{0 + 4} = \sqrt{4} = 2$

c) Identification des 3 plus proches voisins Les trois distances les plus petites sont

$$2, \quad 2, \quad 5.39.$$

Les observations correspondantes sont

$$(22, 30), \quad (20, 28), \quad (18, 25).$$

Les classes associées sont

$$1, \quad 0, \quad 0.$$

d) Classification par la méthode 3-NN On effectue un vote majoritaire :

$$0, 0, 1.$$

La classe majoritaire est

$$\hat{Y} = 0.$$

Donc la qualité de l'air est prédite comme satisfaisante.

e) **Classification par la méthode 5-NN** Les cinq distances les plus petites sont

$$2, \quad 2, \quad 5.39, \quad 7.07, \quad 9.43.$$

Les classes correspondantes sont

$$1, \quad 0, \quad 0, \quad 1, \quad 0.$$

Vote majoritaire :

$$0, 0, 0, 1, 1.$$

Donc

$$\hat{Y} = 0.$$

La prédiction reste identique.

2) Méthode des voisins ε avec $\varepsilon = 6$

On considère le voisinage

$$V_\varepsilon(\mathbf{x}) = \{\mathbf{X}_i : d(\mathbf{x}, \mathbf{X}_i) \leq 6\}.$$

a) **Identification des observations du voisinage** Les distances inférieures ou égales à 6 sont

$$2, \quad 2, \quad 5.39.$$

Les observations correspondantes sont

$$(22, 30), \quad (20, 28), \quad (18, 25).$$

b) **Classe prédite** Les classes associées sont

$$1, \quad 0, \quad 0.$$

Vote majoritaire :

$$\hat{Y} = 0.$$

c) **Comparaison avec la méthode 3-NN** On observe que

$$|V_\varepsilon(\mathbf{x})| = 3.$$

Dans ce cas précis, la méthode des voisins ε utilise le même nombre d'observations que la méthode 3-NN.

d) **Avantage principal** La méthode des voisins ε adapte automatiquement le nombre d'observations utilisées à la densité locale :

- régions denses : beaucoup d'observations
- régions peu denses : peu d'observations

Elle peut donc être plus pertinente lorsque les données sont réparties de manière hétérogène.

3) Influence du paramètre ε

a) **Cas $\varepsilon = 3$** Observations retenues :

$$(22, 30), \quad (20, 28)$$

Donc

$$|V_\varepsilon(\mathbf{x})| = 2.$$

Classes :

$$1, \quad 0.$$

Situation d'égalité : la décision dépend alors d'une règle complémentaire (par exemple choisir le plus proche voisin parmi les deux).

Cas $\varepsilon = 10$ Observations retenues :

$$(22, 30), (20, 28), (18, 25), (25, 35), (15, 22)$$

Donc

$$|V_\varepsilon(\mathbf{x})| = 5.$$

Classes :

$$1, \quad 0, \quad 0, \quad 1, \quad 0.$$

Classe majoritaire :

$$\hat{Y} = 0.$$

b) **Évolution de la classe prédite** Lorsque ε augmente :

- le nombre d'observations utilisées augmente
- la prédiction devient plus stable

c) **Influence qualitative de ε**

ε petit $\Rightarrow$ forte variance

ε grand $\Rightarrow$ fort biais

Le paramètre ε contrôle donc le compromis biais–variance.

4) Comparaison entre k -NN et ε -voisins

a) **Différence principale**

- méthode k -NN : nombre d'observations fixé
- méthode ε -voisins : rayon fixé

b) Situation favorable aux voisins ε La méthode des voisins ε est préférable lorsque :

- les données sont réparties de manière non uniforme
- certaines régions sont très denses
- d'autres régions sont peu peuplées

c) Choix extrêmes de ε Si

ε est trop petit

alors

$$V_\varepsilon(\mathbf{x}) = \emptyset$$

et aucune prédiction n'est possible.

Si

ε est trop grand

alors

$$V_\varepsilon(\mathbf{x}) \approx \text{tout l'échantillon}$$

et la méthode perd son caractère local.

Conclusion :

ε contrôle le compromis biais–variance