



TD4 – Arbre de décision

Paul MINCHELLA, Stéphane CHRÉTIEN

Second Semestre 2025-2026

UNIVERSITÉ
LUMIÈRE
LYON 2



4 Arbre de décision

Exercice 0 – Reconstruction d’un arbre de décision

On considère un problème de régression avec deux variables explicatives

$$X = (X^{(1)}, X^{(2)}) \in \mathbb{R}^2.$$

La figure ci-dessous représente une partition de l’espace des variables explicatives induite par un arbre de régression. Dans chaque région est indiquée la valeur prédite par le modèle.




FIGURE 1 – Partition de l’espace $(X^{(1)}, X^{(2)})$ induite par un arbre de régression.

1. Donner explicitement la suite des règles de découpage (*splits*) associées à cet arbre. *Attention : les découpages doivent être décrits dans l’ordre de construction de l’arbre. Chaque règle s’applique uniquement à la région issue du découpage précédent, de sorte que les régions obtenues soient bien disjointes.*
2. Dessiner l’arbre de décision (ou arbre de régression) qui conduit à cette partition de l’espace.
3. Écrire la fonction de prédiction $f(x^{(1)}, x^{(2)})$ sous forme *piecewise* en fonction des différentes régions de l’espace.

———— Fin Exercice 0 ————

Exercice 1 – Introduction aux arbres de décision

Jeu de données. On utilisera le jeu de données `mtcars`, qui contient des caractéristiques de différents modèles de voitures. La variable réponse est : `mpg` (consommation, miles par gallon), et les variables explicatives sont :

`wt` (poids du véhicule), `hp` (puissance du moteur).

1) Chargement des bibliothèques et des données

- a) Afficher les premières lignes du jeu de données.
- b) Donner une interprétation rapide des variables `mpg`, `wt` et `hp`.

2) Apprentissage d’un arbre de régression

```
# Apprentissage de l'arbre de régression
tree <- rpart(mpg ~ wt + hp, data = mtcars)
```

- a) Que représente la formule `mpg ~ wt + hp` ? Écrire le modèle de prédicteur associé.
- b) Quel type de problème est résolu ici : classification ou régression ?
- c) Quel critère est utilisé pour choisir les coupures dans un arbre de régression ?

3) Lecture et interprétation de l'arbre

- Identifier la première variable utilisée pour réaliser la coupure de l'espace.
- Expliquer la signification des valeurs affichées dans les feuilles de l'arbre et décrire comment elles permettent de construire la prédiction du modèle.

4) Interprétation géométrique des prédictions

- Expliquer pourquoi les prédictions du modèle sont constantes sur les régions de l'espace des variables explicatives. *Indice : s'interroger, étant donnée une région $\mathcal{R}$, sur le critère à minimiser pour obtenir $\hat{y}$.*
- Justifier pourquoi ces régions sont rectangulaires dans le plan ($\mathbf{wt}, \mathbf{hp}$), et expliquer comment elles évoluent lorsque la profondeur de l'arbre augmente.

5) Discussion et ouverture

- Citer un avantage majeur des arbres de décision.
- Citer une limite importante de ce type de modèle.

Sorties R

Observation (modèle du véhicule)	wt	hp	mpg
Mazda RX4	2.620	110	21.0
Mazda RX4 Wag	2.875	110	21.0
Datsun 710	2.320	93	22.8
Hornet 4 Drive	3.215	110	21.4

FIGURE 2 – Premières observations du jeu de données `mtcars`.

Variable	N_OBS	NA	Mean	Std	Min	Med	Max
wt	32	0	3.217	0.978	1.513	3.325	5.424
hp	32	0	146.688	68.563	52.000	123.000	335.000
mpg	32	0	20.091	6.027	10.400	19.200	33.900

FIGURE 3 – Statistiques descriptives des variables `wt`, `hp` et `mpg`.




FIGURE 4 – Arbre de décision appris pour prédire la consommation `mpg` en fonction de `wt` et `hp`.




FIGURE 5 – Régions de prédiction induites par l'arbre dans l'espace ($\mathbf{wt}, \mathbf{hp}$).

— Fin Exercice 1 —

Exercice 2 – Calcul d’entropie et dessin d’un arbre de décision

On s’intéresse à un problème de diagnostic chez des patients atteints d’une tumeur, afin de déterminer si celle-ci est **maligne** ou non. Pour chaque patient, trois critères binaires sont relevés :

- $X^{(1)}$: la tumeur est-elle **grosse** (Large) ?
- $X^{(2)}$: la tumeur est-elle **dure** (Hard) ?
- $X^{(3)}$: la tumeur est-elle **symétrique** (Symmetric) ?

Chaque variable explicative est codée de la manière suivante :

$$1 = \text{Oui}, \quad 0 = \text{Non}.$$

La variable réponse Y indique si la tumeur est maligne :

$$Y = 1 \text{ (maligne)}, \quad Y = 0 \text{ (bénigne)}.$$

Les données observées sont les suivantes :

Patient	$X^{(1)}$ (Large)	$X^{(2)}$ (Hard)	$X^{(3)}$ (Symmetric)	Y (Maligne)
1	1	0	0	1
2	0	0	0	1
3	0	1	1	1
4	0	0	1	0
5	1	0	1	0

Travail demandé.

1. Calculer l’entropie de la variable réponse Y .
2. Pour chacune des variables explicatives $X^{(1)}$, $X^{(2)}$ et $X^{(3)}$, calculer l’entropie conditionnelle $H(Y \mid X^{(j)})$. En déduire le gain d’information associé à chaque variable. Identifier ainsi la variable à utiliser pour le premier nœud de l’arbre de décision.
3. Déterminer la variable à utiliser pour la seconde découpe de l’arbre de décision, en s’appuyant à nouveau sur le critère d’entropie conditionnelle. *Attention : il se peut qu’aucune autre découpe ne soit nécessaire.*
4. Construire l’arbre de décision complet correspondant à ce critère.
5. Quel prédiction a-t-on pour les patients 6 et 7 de covariables :

$$\mathbf{X}_6 = (X_6^{(1)} = 0, X_6^{(2)} = 0, X_6^{(3)} = 1), \quad \mathbf{X}_7 = (X_7^{(1)} = 1, X_7^{(2)} = 1, X_7^{(3)} = 1) \quad ?$$

Exercice 3 – Analyse du comportement client par arbre de décision

Un site de vente en ligne de musique souhaite analyser le comportement de ses clients afin de comprendre les facteurs influençant la finalisation d'une transaction. Pour chaque client, deux variables explicatives sont observées :

- $X^{(1)}$: **type de musique** consulté par le client. Trois modalités sont possibles :

$$X^{(1)} = \begin{cases} (C) & \text{Classique,} \\ (P) & \text{Pop,} \\ (R) & \text{RnB.} \end{cases}$$

- $X^{(2)}$: **niveau de prix** du produit. Cette variable est binaire et codée par :

$$X^{(2)} = \begin{cases} 1 & \text{prix élevé,} \\ 0 & \text{prix bas.} \end{cases}$$

La variable réponse est définie comme suit :

$$Y = \begin{cases} 1 & \text{le client finalise la transaction,} \\ 0 & \text{le client abandonne la transaction.} \end{cases}$$

Les données observées pour $n = 13$ clients sont résumées dans le tableau ci-dessous.

Client	$X^{(1)}$ (Type de musique)	$X^{(2)}$ (Prix)	Y (Transaction)
1	C	1	1
2	R	0	1
3	R	1	1
4	C	0	1
5	P	0	1
6	R	1	0
7	P	1	0
8	P	0	0
9	C	1	1
10	P	1	0
11	R	1	0
12	P	0	1
13	R	1	0

Dans un contexte réel, ce type de données serait naturellement disponible en quantité bien plus importante (plusieurs centaines de milliers d'observations). Dans cet exercice, on se limite volontairement à un jeu de données réduit afin de permettre une analyse complète à la main.

Travail demandé.

1. Calculer l'entropie marginale de la variable réponse Y .
2. Calculer l'entropie conditionnelle de Y sachant chacune des variables explicatives $X^{(1)}$ et $X^{(2)}$.
En déduire le gain d'information associé à chaque variable.
3. Une autre découpe est-elle nécessaire ?
4. Construire l'arbre de décision correspondant au critère d'entropie.
5. Peut-on prédire si la transaction va avoir lieu pour un client avec les valeurs $X^{(1)} = C$ et $X^{(2)} = 1$.
6. Interpréter les règles de décision obtenues du point de vue métier.

———— Fin Exercice 3 ————

Exercice 4 – Prédire le nombre d’achat à partir de variables catégorielles

On souhaite construire un **arbre de régression** afin de prédire le nombre de ventes d’un site web de vêtements. La variable réponse est :

$$Y = \text{nombre d’achats.}$$

Les variables explicatives sont catégorielles et notées :

$$\begin{aligned} X^{(1)} &= \text{Météo} \in \{E, N, P\} & (E = \text{Ensoleillé}, N = \text{Nuageux}, P = \text{Pluvieux}), \\ X^{(2)} &= \text{Température} \in \{C, M, F\} & (C = \text{Chaud}, M = \text{Moyen}, F = \text{Frais}), \\ X^{(3)} &= \text{Humidité} \in \{0, 1\} & (1 = \text{Forte}, 0 = \text{Normale}), \\ X^{(4)} &= \text{Soldes} \in \{0, 1\} & (1 = \text{Soldes}, 0 = \text{Sans soldes}). \end{aligned}$$

Les données observées ($n = 14$) sont :

i	$X^{(1)}$ Météo	$X^{(2)}$ Température	$X^{(3)}$ Humidité	$X^{(4)}$ Soldes	Y Achats
1	E	C	1	1	25
2	E	C	1	0	30
3	N	C	1	1	46
4	P	M	1	1	45
5	P	F	0	1	52
6	P	F	0	0	23
7	N	F	0	0	43
8	E	M	1	1	35
9	E	F	0	1	38
10	P	M	0	1	46
11	E	M	0	0	48
12	N	M	1	0	52
13	N	C	0	1	44
14	P	M	1	0	30

Travail demandé. On utilisera comme critère de découpe la **RSS** (la **SCR** en français) :

$$\text{RSS} = \sum_{i \in \text{noeud}} (Y_i - \bar{Y}_{\text{noeud}})^2.$$

1. Calculer la moyenne globale $\bar{Y}$ et l’écart-type de Y .
2. Pour chaque variable $X^{(j)}$, calculer la RSS obtenue après séparation selon ses modalités :
 - $X^{(1)}$ (Météo),
 - $X^{(2)}$ (Température),
 - $X^{(3)}$ (Humidité),
 - $X^{(4)}$ (Soldes).
3. Identifier la variable minimisant la RSS : elle constitue la **racine** de l’arbre.
4. On suppose que la racine retenue est $X^{(1)}$. Pour chaque modalité $x \in \{E, N, P\}$, rechercher la meilleure variable parmi $X^{(2)}, X^{(3)}, X^{(4)}$ en recalculant la RSS conditionnelle.
5. Déterminer la structure complète de l’arbre de régression jusqu’à ce qu’aucune réduction significative de la RSS ne soit possible.
6. Construire et visualiser l’arbre obtenu sous R.

———— Fin Exercice 4 ————

Exercice 5 – Arbre de régression avec variables catégorielles

Une entreprise de commerce en ligne souhaite modéliser le **montant moyen d'un achat** effectué par un client lors d'une visite sur son site.

On observe pour chaque client :

- $X^{(1)}$: le **type de campagne marketing** reçue avant la visite :

$$X^{(1)} \in \{\text{Email, SMS, Réseaux}\}$$

- $X^{(2)}$: le **moment de la journée** de la visite :

$$X^{(2)} \in \{\text{Matin, Après-midi, Soir}\}$$

- Y : le **montant de l'achat** (en euros), variable quantitative continue.

i	$X^{(1)}$	$X^{(2)}$	Y
1	Email	Matin	42
2	Email	Soir	55
3	SMS	Matin	38
4	SMS	Après-midi	47
5	SMS	Soir	52
6	Réseaux	Matin	28
7	Réseaux	Après-midi	35
8	Réseaux	Soir	31
9	Email	Après-midi	50

Travail demandé. On souhaite construire un **arbre de régression** permettant de prédire le montant d'achat Y à partir des variables explicatives $X^{(1)}$ et $X^{(2)}$.

1. Calculer la moyenne empirique globale

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Que représenterait cette valeur dans un arbre de régression sans découpage ? Quelle est la *Sum Square Error* (somme des carrés résiduels) totale ici ?

2. On considère maintenant un premier découpage selon la variable $X^{(1)}$.

- (a) Calculer la moyenne des valeurs de Y dans chacune des régions :

$$X^{(1)} = \text{Email}, \quad X^{(1)} = \text{SMS}, \quad X^{(1)} = \text{Réseaux}.$$

- (b) Expliquer pourquoi ces moyennes constituent les prédictions naturelles dans chacune des régions obtenues.

3. On souhaite comparer ce découpage avec un découpage selon la variable $X^{(2)}$.

- (a) Calculer les moyennes de Y dans chacune des régions :

$$X^{(2)} = \text{Matin}, \quad X^{(2)} = \text{Après-midi}, \quad X^{(2)} = \text{Soir}.$$

- (b) Proposer un critère permettant de comparer les deux découpages.

4. Dans un arbre de régression, on choisit le découpage qui minimise l'erreur quadratique intra-régions :

$$\sum_m \sum_{i: X_i \in \mathcal{R}_m} (Y_i - \hat{y}_m)^2.$$

- (a) Expliquer pourquoi la constante optimale dans chaque région $\mathcal{R}_m$ est la moyenne empirique des observations présentes dans cette région.
- (b) Déterminer quelle variable explicative doit être choisie pour réaliser le premier découpage de l'arbre.

5. Interprétation.

Expliquer pourquoi cet exemple montre qu'il est possible d'utiliser des variables explicatives **catégorielles** pour prédire une variable réponse **quantitative continue** à l'aide d'un arbre de régression.

———— Fin Exercice 5 ————