


TD5 – Forêt Aléatoire

Paul MINCHELLA, Stéphane CHRÉTIEN

Second Semestre 2025-2026

UNIVERSITÉ
LUMIÈRE
LYON 2



Forêt aléatoire : agrégation de B arbres

Bootstrap + sélection aléatoire de variables

5 Forêts aléatoires

Exercice 1 – Arbres de décision et forêts aléatoires

L'objectif de ce TD-TP est d'introduire les méthodes d'arbres de décision et de forêts aléatoires, largement utilisées en apprentissage automatique pour des problèmes de classification et de régression. On utilisera le jeu de données `mtcars`, fourni nativement dans le logiciel R.

Ce dataset contient $n = 32$ observations correspondant à différents modèles de voitures. Chaque observation est décrite par plusieurs caractéristiques mécaniques et de performance. Dans ce TD, on s'intéresse au problème de **classification** suivant :

- La variable réponse est

$$Y = \text{am},$$

qui indique le type de boîte de vitesse du véhicule :

$$Y = \begin{cases} 0 & \text{boîte automatique,} \\ 1 & \text{boîte manuelle.} \end{cases}$$

- Les variables explicatives considérées sont :

$$\begin{aligned} X^{(1)} &= \text{mpg} && (\text{consommation}), \\ X^{(2)} &= \text{cyl} && (\text{nombre de cylindres}), \\ X^{(3)} &= \text{disp} && (\text{cylindrée}), \\ X^{(4)} &= \text{hp} && (\text{puissance}), \\ X^{(5)} &= \text{wt} && (\text{poids}), \\ X^{(6)} &= \text{qsec} && (\text{temps au quart de mile}). \end{aligned}$$

L'objectif est de construire un modèle permettant de prédire le type de boîte de vitesse d'un véhicule à partir de ces variables explicatives, puis d'évaluer ses performances de généralisation.

Question 1 – Séparation apprentissage / test. On rappelle qu'en apprentissage supervisé, il est essentiel d'évaluer les performances d'un modèle sur des données *non utilisées* lors de son apprentissage.

- Expliquer le principe de la séparation **train** / **test** et justifier son intérêt du point de vue de la généralisation.
- Proposer une séparation aléatoire du jeu de données `mtcars` en :
 - un échantillon d'apprentissage (50 % des données),
 - un échantillon de test (50 % des données).

Question 2 – Apprentissage d'un arbre de décision. On souhaite prédire la variable $Y = \text{am}$ à partir des variables explicatives $X^{(1)}, \dots, X^{(6)}$.

- Apprendre un arbre de décision $\hat{T}$ de classification sur l'échantillon d'apprentissage pour le modèle

$$Y = \hat{T}(X^{(1)}, X^{(2)}, X^{(3)}, X^{(4)}, X^{(5)}, X^{(6)}).$$

- Représenter graphiquement l'arbre obtenu.
- Commenter la structure de l'arbre (profondeur, nombre de feuilles, variables sélectionnées aux premiers nœuds).

Question 3 – Évaluation sur l'échantillon de test.

- Utiliser l'arbre appris pour prédire la variable Y sur l'échantillon de test.
- Calculer le taux de bonne classification sur l'échantillon d'apprentissage puis sur l'échantillon de test. Comparer ces deux performances et commenter les résultats obtenus.

Question 4 – Limites de l’arbre de décision.

- a) Expliquer pourquoi un arbre de décision peut présenter une forte variabilité vis-à-vis des données d’apprentissage.
- b) Que se passe-t-il si l’on modifie l’échantillon d’apprentissage ? Relancer votre code **R** pour un nouveau *train-test split* (pour cela, changer la **seed**) et comparer les arbres et les performances obtenues.

Question 5 – Principe des forêts aléatoires. On introduit maintenant la méthode des **forêts aléatoires** (*Random Forest*).

- a) Rappeler le principe du **bootstrap**.
- b) Expliquer comment une forêt aléatoire combine :
 - plusieurs arbres appris sur des échantillons bootstrap,
 - une sélection aléatoire de variables explicatives à chaque nœud.
- c) Quel est l’effet attendu de cette méthode sur la variance du modèle ? Pour y répondre, considérer les arbres de décision $T_1, \dots, T_B$ pour une même estimation, noter

$$\bar{T} = \frac{1}{B} \sum_{b=1}^B T_b$$

et calculer formellement sa variance, notée de $\text{Var}[\bar{T}]$ pour conclure.

Question 6 – Implémentation d’une forêt aléatoire.

- a) Apprendre une forêt aléatoire de classification pour le même modèle que précédemment, sur l’échantillon d’apprentissage.
- b) Préciser le nombre d’arbres utilisés et expliquer le rôle de ce paramètre.
- c) Évaluer les performances de la forêt aléatoire sur l’échantillon de test.

Question 7 – Comparaison arbre vs forêt.

- a) Comparer les performances sur l’échantillon de test entre l’arbre de décision et la forêt aléatoire.
- b) Conclure sur l’intérêt des forêts aléatoires du point de vue de la généralisation et de la stabilité des prédictions.