


TD5 – Forêt Aléatoire

Paul MINCHELLA, Stéphane CHRÉTIEN

Second Semestre 2025-2026

UNIVERSITÉ
LUMIÈRE
LYON 2



Forêt aléatoire : agrégation de B arbres

Bootstrap + sélection aléatoire de variables

5 Forêts aléatoires

Exercice 1 – Arbres de décision et forêts aléatoires

L'objectif de ce TD-TP est d'introduire les méthodes d'arbres de décision et de forêts aléatoires, largement utilisées en apprentissage automatique pour des problèmes de classification et de régression. On utilisera le jeu de données `mtcars`, fourni nativement dans le logiciel R.

Ce dataset contient $n = 32$ observations correspondant à différents modèles de voitures. Chaque observation est décrite par plusieurs caractéristiques mécaniques et de performance. Dans ce TD, on s'intéresse au problème de **classification** suivant :

- La variable réponse est

$$Y = \text{am},$$

qui indique le type de boîte de vitesse du véhicule :

$$Y = \begin{cases} 0 & \text{boîte automatique,} \\ 1 & \text{boîte manuelle.} \end{cases}$$

- Les variables explicatives considérées sont :

$$X^{(1)} = \text{mpg} \quad (\text{consommation}),$$

$$X^{(2)} = \text{cyl} \quad (\text{nombre de cylindres}),$$

$$X^{(3)} = \text{disp} \quad (\text{cylindrée}),$$

$$X^{(4)} = \text{hp} \quad (\text{puissance}),$$

$$X^{(5)} = \text{wt} \quad (\text{poids}),$$

$$X^{(6)} = \text{qsec} \quad (\text{temps au quart de mile}).$$

L'objectif est de construire un modèle permettant de prédire le type de boîte de vitesse d'un véhicule à partir de ces variables explicatives, puis d'évaluer ses performances de généralisation.

Question 1 – Séparation apprentissage / test. On rappelle qu'en apprentissage supervisé, il est essentiel d'évaluer les performances d'un modèle sur des données *non utilisées* lors de son apprentissage.

- Expliquer le principe de la séparation **train** / **test** et justifier son intérêt du point de vue de la généralisation.
- Proposer une séparation aléatoire du jeu de données `mtcars` en :
 - un échantillon d'apprentissage (50 % des données),
 - un échantillon de test (50 % des données).

Question 2 – Apprentissage d'un arbre de décision. On souhaite prédire la variable $Y = \text{am}$ à partir des variables explicatives $X^{(1)}, \dots, X^{(6)}$.

- Apprendre un arbre de décision $\hat{T}$ de classification sur l'échantillon d'apprentissage pour le modèle

$$Y = \hat{T}(X^{(1)}, X^{(2)}, X^{(3)}, X^{(4)}, X^{(5)}, X^{(6)}).$$

- Représenter graphiquement l'arbre obtenu.
- Commenter la structure de l'arbre (profondeur, nombre de feuilles, variables sélectionnées aux premiers nœuds).

Question 3 – Évaluation sur l'échantillon de test.

- Utiliser l'arbre appris pour prédire la variable Y sur l'échantillon de test.
- Calculer le taux de bonne classification sur l'échantillon d'apprentissage puis sur l'échantillon de test. Comparer ces deux performances et commenter les résultats obtenus.

Question 4 – Limites de l'arbre de décision.

- Expliquer pourquoi un arbre de décision peut présenter une forte variabilité vis-à-vis des données d'apprentissage.
- Que se passe-t-il si l'on modifie l'échantillon d'apprentissage ? Relancer votre code **R** pour un nouveau *train-test split* (pour cela, changer la **seed**) et comparer les arbres et les performances obtenues.

Question 5 – Principe des forêts aléatoires. On introduit maintenant la méthode des **forêts aléatoires** (*Random Forest*).

- Rappeler le principe du **bootstrap**.
- Expliquer comment une forêt aléatoire combine :
 - plusieurs arbres appris sur des échantillons bootstrap,
 - une sélection aléatoire de variables explicatives à chaque nœud.
- Quel est l'effet attendu de cette méthode sur la variance du modèle ? Pour y répondre, considérer les arbres de décision $T_1, \dots, T_B$ pour une même estimation, noter

$$\bar{T} = \frac{1}{B} \sum_{b=1}^B T_b$$

et calculer formellement sa variance, notée de $\text{Var}[\bar{T}]$ pour conclure.

Question 6 – Implémentation d'une forêt aléatoire.

- Apprendre une forêt aléatoire de classification pour le même modèle que précédemment, sur l'échantillon d'apprentissage.
- Préciser le nombre d'arbres utilisés et expliquer le rôle de ce paramètre.
- Évaluer les performances de la forêt aléatoire sur l'échantillon de test.

Question 7 – Comparaison arbre vs forêt.

- Comparer les performances sur l'échantillon de test entre l'arbre de décision et la forêt aléatoire.
- Conclure sur l'intérêt des forêts aléatoires du point de vue de la généralisation et de la stabilité des prédictions.

Sorties R

Performances des modèles. Les performances obtenues pour deux arbres de décision et deux forêts aléatoires appris avec des échantillons d'apprentissage différents (*seed* différentes) sont résumées ci-dessous.


Modèle	Accuracy (train)	Accuracy (test)
Arbre (seed 777)	1.00	0.8125
Arbre (seed 42)	1.00	0.75
Random Forest (seed 777)	1.00	0.8125
Random Forest (seed 42)	1.00	0.8125

Importance des variables dans la forêt aléatoire.

Variable	Importance
wt	2.681
disp	1.551
mpg	1.321
hp	0.337
qsec	0.248
cyl	0.172

Comparaison de deux arbres appris. La figure suivante présente deux arbres appris avec deux graines aléatoires différentes. On constate que leur structure peut varier sensiblement selon l'échantillon d'apprentissage utilisé.

Arbre de décision - Seed 777



Arbre de décision - Seed 42




FIGURE 1 – Comparaison de deux arbres de décision appris avec deux graines aléatoires différentes (seed 777 et seed 42). La structure des arbres varie selon l'échantillon d'apprentissage, ce qui illustre l'instabilité des arbres individuels et l'intérêt des forêts aléatoires.