

TD6 – Méthode des k -plus proches voisins

Paul MINCHELLA, Stéphane CHRÉTIEN

Second Semestre 2025-2026




FIGURE 1 – Illustration du principe du plus proche voisin. La prédiction associée à x est celle de l'observation X_{i^*} minimisant la distance $d(x, X_i)$.

6 k -plus proches voisins

Exercice 1 – Introduction à la méthode des k plus proches voisins

On souhaite prédire si une personne est susceptible de s'inscrire à une salle de sport à partir de deux variables explicatives.

On note :

- $X^{(1)}$: âge (en années),
- $X^{(2)}$: nombre d'heures de temps libre par semaine.

La variable réponse est

$$Y = \begin{cases} 1 & \text{si la personne s'inscrit,} \\ 0 & \text{sinon.} \end{cases}$$

$X^{(1)}$	$X^{(2)}$	Y
22	12	1
25	10	1
28	4	0
35	6	0
40	8	0
45	3	0
30	11	1
38	9	1

On utilisera la distance euclidienne dans le plan.

1) Méthode du plus proche voisin (1-NN).

- a) Représenter les observations dans le plan $(X^{(1)}, X^{(2)})$. On distinguera clairement les observations correspondant à $Y = 0$ et $Y = 1$.
- b) Expliquer le principe de la méthode du plus proche voisin (1-NN).
- c) Déterminer la classe prédite pour les observations suivantes à l'aide de 1-NN :

$$x_A = (27, 9), \quad x_B = (37, 8.5), \quad x_C = (33, 5).$$

Justifier chaque réponse.

- d) Tracer approximativement la frontière de décision associée à la méthode 1-NN. On décrira qualitativement la forme de cette frontière.
- e) La frontière obtenue vous paraît-elle régulière ? Sensible à certaines observations ? Justifier brièvement.

2) Méthode des k plus proches voisins.

On considère maintenant la méthode des k plus proches voisins avec $k = 3$.

- a) Expliquer le principe de la règle de décision utilisée par la méthode 3-NN.
- b) Déterminer la classe prédite pour les observations suivantes :

$$x_A = (27, 9), \quad x_B = (37, 8.5), \quad x_C = (33, 5).$$



Comparer avec les résultats obtenus avec 1-NN.

- c) Tracer approximativement la nouvelle frontière de décision associée à $k = 3$. Comparer sa forme avec celle obtenue pour $k = 1$.
- d) Que se passerait-il si l'on choisissait une valeur très grande de k ? Expliquer qualitativement.

3) Discussion.

- a) Comparer les méthodes 1-NN et 3-NN en termes de stabilité des prédictions, de sensibilité au bruit, de complexité de la frontière de décision, ...
- b) Pourquoi est-il important d'utiliser des variables explicatives mesurées sur des échelles comparables dans la méthode des plus proches voisins ?

Sorties R - Exercice 1



— Fin Exercice 1 —

Exercice 2 – Frontières de décision et influence de la distance

Dans cet exercice, on étudie le comportement de la méthode des k plus proches voisins (k -NN) sur un petit jeu de données bidimensionnel. On considère un ensemble de points appartenant à deux classes :

Classe rouge :

$(0, 1), (2, 3), (4, 4)$

Classe bleue :

$(2, 0), (5, 2), (6, 3)$

On utilise la distance euclidienne dans le plan.

1. Frontière de décision pour $k = 1$.

Tracer la frontière de décision associée à la méthode du plus proche voisin (1-NN).

On rappelle que la frontière de décision correspond à l'ensemble des points du plan pour lesquels la classe prédite change.

Indication : la frontière correspond aux médiatrices entre observations voisines appartenant à des classes différentes (diagramme de Voronoï).

2. Effet d'un changement d'échelle

On suppose maintenant que la coordonnée verticale de chaque point est multipliée par 5.

- Représenter la nouvelle frontière de décision pour $k = 1$.
- Expliquer en deux phrases maximum pourquoi ce phénomène peut poser problème dans l'analyse de données réelles.

3. Classification avec $k = 3$

La frontière de décision pour $k = 3$ est représentée sur la figure suivante.




FIGURE 2 – Frontière de décision pour $k = 3$.


On considère un point test

$$x = (1, 2).$$


- Déterminer sa classe prédite par la méthode des 3 plus proches voisins.
- On suppose que l'on peut ajouter des observations supplémentaires au jeu d'apprentissage. Quel est le nombre minimum de points à ajouter pour modifier la classification du point $x = (1, 2)$?

Sorties R - Exercice 2


Frontière de décision – 1-NN



Frontière 1-NN après changement d'échelle ($y \times 5$)



Frontière de décision – 3-NN



— Fin Exercice 2 —

Exercice 3 – Prédiction du diabète gestationnel par la méthode des k plus proches voisins

On s'intéresse à la détection du diabète gestationnel chez des patientes à partir du jeu de données `PimaIndiansDiabetes` disponible sous R. On considère uniquement deux variables explicatives :

- $X^{(1)}$: indice de masse corporelle (BMI),
- $X^{(2)}$: taux de glucose plasmatique.

La variable réponse est

$$Y = \begin{cases} 1 & \text{présence de diabète,} \\ 0 & \text{absence de diabète,} \end{cases}$$

le but étant de construire un classifieur basé sur la méthode des k plus proches voisins. On utilisera la distance euclidienne dans le plan.

Variable	n	NA	Moyenne	Écart-type	Variance	Min	Médiane	Max
BMI ($X^{(1)}$)	27	0	28.60	5.28	27.88	19.50	28.20	39.40
Glucose ($X^{(2)}$)	27	0	114.81	24.84	616.85	85.00	108.00	184.00

TABLE 1 – Statistiques descriptives des variables explicatives

Classe	Effectif	Proportion
Non diabétique ($Y = 0$)	15	0.56
Diabétique ($Y = 1$)	12	0.44

TABLE 2 – Répartition de la variable réponse

Construction d'un classifieur k -NN À partir du *scatterplot* initial, notre but ici est d'étudier quel k -NN serait le plus pertinent.

1. On donne une représentation graphique des observations dans le plan (BMI, glucose) en distinguant les patientes diabétiques et non diabétiques, via la Figure 3. Comment interpréter géométriquement ce nuage de points ?
2. Expliquer le principe de la méthode des k plus proches voisins dans ce contexte.
3. On considère la nouvelle patiente de covariables :

$$\mathbf{x} = (\text{BMI} = 30, \text{ glucose} = 115).$$

Déterminer graphiquement les 3 plus proches voisines de cette patiente. En déduire la classe prédite pour cette patiente.

4. Même question avec la méthode du plus proche voisin (1-NN). Comparer les deux résultats obtenus.
5. Tracer approximativement la frontière de décision associée à la méthode k -NN pour $k = 1$ et $k = 3$. Comment évolue cette frontière lorsque k augmente ? On pourra s'appuyer sur la Figure ?? pour répondre à cette question.
6. Expliquer pourquoi le choix du paramètre k correspond à un compromis entre biais et variance. Lequel de ces modèles vous semble-t-il "mieux généraliser" ?

Sorties R - Exercice 3





FIGURE 3 – Scatterplot des patientes



— Fin Exercice 3 —

Exercice 4 – kNN régressif

On souhaite estimer la **consommation mensuelle d'électricité** d'un logement (en kWh) à partir de deux caractéristiques quantitatives.

On note :

- $X^{(1)}$: surface du logement (en m^2),
- $X^{(2)}$: nombre moyen d'heures de chauffage par jour.

La variable réponse est

Y = consommation mensuelle d'électricité (en kWh).


$X^{(1)}$	$X^{(2)}$	Y
35	2	120
40	3	135
50	4	160
60	5	190
65	6	210
75	5	220
80	7	260
90	8	300

Dans tout l'exercice, on utilisera la distance euclidienne dans le plan des covariables.

1) Visualisation et principe de la méthode

a) Représenter les observations dans le plan

$(X^{(1)}, X^{(2)}) = (\text{surface}, \text{heures de chauffage})$.



- b) Dans ce contexte, expliquer le principe de la méthode des k plus proches voisins pour un problème de **régression**.
- c) Quelle différence fondamentale y a-t-il entre l'utilisation de la méthode des k plus proches voisins en **classification** et en **régression** ?
- d) Pourquoi peut-on dire que la prédiction obtenue par kNN régressif est une **moyenne locale** ?

2) Prédiction par 1-NN puis par 3-NN

On considère un nouveau logement caractérisé par $x = (55, 5)$.

- Calculer la distance entre ce logement et chacune des observations du tableau.
- Identifier son plus proche voisin.
- En déduire la prédiction obtenue par la méthode du 1 **plus proche voisin**.
- Identifier les **3 plus proches voisins** de x .
- En déduire la prédiction obtenue par la méthode du 3 **plus proches voisins**.
- Comparer les deux prédictions obtenues. Laquelle vous paraît la plus stable ?

3) Nouvelle estimation locale

On considère maintenant le logement $x' = (78, 6)$.

- Déterminer les **3 plus proches voisins** de x' .
- Calculer la prédiction de Y obtenue par la méthode 3-NN.
- Déterminer ensuite la prédiction obtenue par la méthode 5-NN.
- Comparer les deux valeurs estimées et interpréter l'effet de l'augmentation de k .

4) Discussion autour du paramètre k

- Que se passe-t-il si l'on choisit une valeur très petite de k ?
- Que se passe-t-il au contraire si l'on choisit une valeur très grande de k ?
- Expliquer qualitativement pourquoi le choix de k met en jeu un compromis entre **précision locale** et **stabilité**.
- Dans le cas extrême où $k = n$, que devient la prédiction du modèle ?

5) Interprétation géométrique

- Dans un problème de régression kNN, que représentent géométriquement les voisins utilisés pour prédire la réponse en un point donné ?
- Pourquoi la qualité de la prédiction dépend-elle fortement de la distance choisie ?
- Expliquer pourquoi il peut être nécessaire de **normaliser** les variables explicatives avant d'appliquer un kNN.

———— Fin Exercice 4 ————

Exercice 5 – Méthode des voisins ε

On souhaite prédire la qualité de l'air dans une zone urbaine à partir de deux variables explicatives mesurées quotidiennement :

On considère les variables explicatives suivantes :

- $X^{(1)}$: concentration moyenne de particules fines $\text{PM}_{2.5}$ (en $\mu\text{g}/\text{m}^3$),
- $X^{(2)}$: concentration moyenne de dioxyde d'azote NO_2 (en $\mu\text{g}/\text{m}^3$).

La variable réponse est

$$Y = \begin{cases} 1 & \text{qualité de l'air dégradée,} \\ 0 & \text{qualité de l'air satisfaisante.} \end{cases}$$

$X^{(1)}$	$X^{(2)}$	Y
12	18	0
15	22	0
18	25	0
22	30	1
25	35	1
28	38	1
30	40	1
20	28	0

Dans tout l'exercice, on utilisera la distance euclidienne dans le plan des covariables.

1) Classification par la méthode des k plus proches voisins

On considère une nouvelle observation caractérisée par

$$\mathbf{x} = (20, 30).$$

- a) Représenter graphiquement les observations dans le plan $(X^{(1)}, X^{(2)})$.
- b) Calculer la distance entre $\mathbf{x}$ et chacune des observations du tableau.
- c) Identifier les 3 plus proches voisins de $\mathbf{x}$.
- d) En déduire la classe prédite par la méthode 3-NN.
- e) Même question avec la méthode 5-NN. Comparer les deux résultats obtenus.

2) Méthode des voisins ε

Contrairement à la méthode des k plus proches voisins, qui utilise un nombre fixe d'observations, la méthode des voisins ε consiste à considérer toutes les observations situées à une distance inférieure ou égale à un seuil fixé ε autour du point étudié.

On définit ainsi le voisinage

$$V_\varepsilon(\mathbf{x}) = \{\mathbf{X}_i : d(\mathbf{x}, \mathbf{X}_i) \leq \varepsilon\}.$$

On choisit ici

$$\varepsilon = 6.$$

- a) Identifier les observations appartenant au voisinage $V_\varepsilon(\mathbf{x})$.
- b) En déduire la classe prédite pour l'observation $\mathbf{x}$ à l'aide de la méthode des voisins ε .
- c) Comparer le nombre d'observations utilisées dans cette méthode avec celui utilisé par la méthode 3-NN.
- d) Expliquer l'avantage principal de la méthode des voisins ε lorsque les observations ne sont pas réparties uniformément dans le plan.

3) Influence du paramètre ε

On considère maintenant deux nouvelles valeurs possibles du paramètre :

$$\varepsilon = 3 \quad \text{et} \quad \varepsilon = 10.$$

- a) Déterminer, dans chaque cas, le nombre d'observations appartenant au voisinage $V_\varepsilon(x)$.
- b) Comment évolue la classe prédite lorsque ε augmente ?
- c) Expliquer qualitativement l'influence du paramètre ε sur la stabilité de la prédiction.

4) Comparaison entre les méthodes k -NN et ε -voisins

- a) Quelle est la différence principale entre le choix d'un paramètre k et celui d'un paramètre ε ?
- b) Dans quelle situation la méthode des voisins ε peut-elle être plus pertinente que la méthode des k plus proches voisins ?
- c) Que se passe-t-il si ε est choisi trop petit ? trop grand ?

———— Fin Exercice 5 ————