

Paul MINCHELLA, Stéphane CHRÉTIEN

ALGÈBRE LINÉAIRE

APPLIQUÉE À LA DATA SCIENCE




Table des matières

Introduction générale	1
1 Analyse en composantes principales	2
1.1 Du vecteur aléatoire au nuage de données	2
1.2 Matrice de variance-covariance empirique	3
1.3 Décomposition spectrale de la covariance	5
1.4 Variance totale et quantité d'information	6
1.5 Composantes principales	6
1.6 Réduction de dimension	8
1.7 Proportion de variance expliquée	10
1.8 Projection et reconstruction des observations	11
1.9 ACP sur la covariance ou sur la corrélation ?	12
2 Décomposition en valeurs singulières	14
2.1 La matrice symétrique positive $M^T M$	14
2.2 Valeurs propres de $M^T M$	15
2.3 Interprétation de l'endomorphisme $M^T M$	16
2.4 Énoncé et démonstration de la SVD	17
2.5 Relations fondamentales entre les vecteurs singuliers	19
2.6 Description des sous-espaces fondamentaux	21
2.7 Interprétation géométrique de la SVD	22
2.8 Décomposition réduite	23
2.9 Normes et valeurs singulières	24
2.10 Cas d'une matrice carrée inversible	25
2.11 Lien avec les matrices symétriques positives	26
2.12 Cas complexe	26
2.13 Pseudo-inverse de Moore–Penrose	27
3 Projections orthogonales et problèmes des moindres carrés	30
3.1 Du système linéaire au problème des moindres carrés	30
3.2 Interprétation géométrique : projection sur $\text{Im}(X)$	31
3.3 Dérivation analytique des équations normales	32
3.4 Existence et unicité des solutions	33
3.5 Cas de rang colonne plein	34
3.6 Résolution par SVD	35
3.7 Lien entre la formule classique et la pseudo-inverse	37
3.8 Application à la régression linéaire	38
3.9 Multicolinéarité et valeurs singulières	39
3.10 Régularisation et régression ridge	40
3.11 Exemple élémentaire	41
4 Perron–Frobenius et systèmes dynamiques	43
4.1 Matrices stochastiques et systèmes dynamiques	43
4.2 Théorème de Perron–Frobenius	44
4.3 Interprétation spectrale de la convergence	45
4.4 Application : généralisation du modèle des fumeurs de Morioh	45
Conclusion générale	48

Introduction générale

Une grande partie de la statistique et de la data science consiste à transformer des données nombreuses en objets mathématiques plus simples, sans effacer les structures qui portent l'information. Une table de données devient une matrice, un individu devient un vecteur, une régression devient une projection et l'évolution d'une population devient l'itération d'une application linéaire. L'algèbre linéaire ne fournit donc pas seulement une écriture compacte : elle permet d'identifier les directions importantes, les redondances, les pertes d'information et les mécanismes de stabilité ou de convergence.

Ce cours développe quatre idées reliées par un même principe : choisir une représentation adaptée à la géométrie du problème. Le premier chapitre construit l'analyse en composantes principales à partir de la matrice de covariance. Le deuxième étend l'analyse spectrale aux matrices rectangulaires grâce à la décomposition en valeurs singulières. Le troisième montre que les moindres carrés sont avant tout un problème de projection orthogonale, puis relie cette géométrie à la pseudo-inverse et à la régularisation. Le dernier chapitre étudie les systèmes dynamiques positifs et explique comment le spectre d'une matrice de transition gouverne leur comportement à long terme.

Les résultats sont présentés avec leurs preuves afin de rendre visibles les arguments qui les relient : symétrie, positivité, orthogonalité, rang et décomposition spectrale. L'objectif n'est pas d'accumuler des formules, mais de savoir reconnaître la structure linéaire sous-jacente à une méthode de data science et d'en déduire ses propriétés.

Conventions de notation. Dans tout le document, les vecteurs sont des vecteurs colonnes. Les conventions suivantes seront utilisées de manière systématique.

Notation	Signification
$\mathcal{M}_{m,n}(\mathbb{R})$	ensemble des matrices réelles à m lignes et n colonnes ; $\mathcal{M}_n(\mathbb{R}) = \mathcal{M}_{n,n}(\mathbb{R})$;
x, y, β	vecteurs déterministes ; $\mathbf{X}$ désigne un vecteur aléatoire et $\mathbf{x}_i$ sa i -ième observation ;
M	matrice générique représentant une application linéaire ;
$\tilde{\mathbf{X}}, C, X$	matrice des données centrées et matrice de covariance empirique en ACP ; X désigne ensuite la matrice de conception dans les moindres carrés ;
$I_d, \mathbf{0}, \mathbf{1}_d$	matrice identité, vecteur nul et vecteur dont toutes les coordonnées valent 1 ;
$\langle x, y \rangle = x^\top y, \ x\ $	produit scalaire et norme euclidiens ;
$\text{Im}(M), \text{ker}(M), \text{rg}(M)$	image, noyau et rang de l'application linéaire associée à M .

Les dimensions sont toujours indiquées lors de l'introduction d'un objet. Dans les chapitres statistiques, n désigne le nombre d'observations et p le nombre de variables. Dans le chapitre consacré à la SVD, une matrice générique $M \in \mathcal{M}_{m,n}(\mathbb{R})$ représente une application de $\mathbb{R}^n$ vers $\mathbb{R}^m$.

Analyse en composantes principales

Les données statistiques modernes sont fréquemment représentées par des vecteurs de grande dimension : pour chaque individu, on mesure simultanément plusieurs variables numériques. Le vecteur moyen localise le centre du nuage, la matrice de variance-covariance en décrit la dispersion, et ses vecteurs propres déterminent les directions selon lesquelles les observations varient le plus. Cette lecture géométrique conduit à l'analyse en composantes principales (ACP), qui construit des variables synthétiques non corrélées et réduit la dimension en conservant autant que possible la variabilité des données.

1.1 Du vecteur aléatoire au nuage de données

Les notions de variance et de covariance se généralisent naturellement lorsque l'on considère non plus une unique variable aléatoire réelle, mais un vecteur aléatoire

$$\mathbf{X} = \begin{pmatrix} X^1 \\ \vdots \\ X^p \end{pmatrix} \in \mathbb{R}^p.$$

Chaque coordonnée X^j représente une variable statistique. Par exemple, si l'on étudie des individus à partir de leur taille, de leur poids et de leur âge, on peut considérer

$$\mathbf{X} = \begin{pmatrix} \text{taille} \\ \text{poids} \\ \text{âge} \end{pmatrix} \in \mathbb{R}^3.$$

On suppose que l'on dispose de n observations de ce vecteur :

$$\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p \quad \text{où} \quad \mathbf{x}_i = \begin{pmatrix} x_i^1 \\ \vdots \\ x_i^p \end{pmatrix}.$$

L'indice i désigne donc l'individu observé, tandis que l'indice j désigne la variable mesurée. L'ensemble des observations forme un nuage de n points dans $\mathbb{R}^p$.

Définition 1.1.1 (Vecteur moyen empirique). Le *vecteur moyen empirique* est défini par

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i.$$

Sa j -ième coordonnée est $\bar{x}^j = \frac{1}{n} \sum_{i=1}^n x_i^j$. Ainsi,

$$\bar{\mathbf{x}} = \begin{pmatrix} \bar{x}^1 \\ \vdots \\ \bar{x}^p \end{pmatrix}.$$

Le vecteur $\bar{\mathbf{x}}$ constitue le centre de gravité du nuage de données. Chacune de ses coordonnées est la moyenne empirique de la variable correspondante. Il joue donc le rôle d'un opérateur de position : il indique autour de quel point les observations se répartissent.

Définition 1.1.2 (Observations centrées). Pour tout $i \in \{1, \dots, n\}$, on définit le vecteur centré

$$\tilde{\mathbf{x}}_i = \mathbf{x}_i - \bar{\mathbf{x}}.$$

Sa j -ième coordonnée est

$$\tilde{x}_i^j = x_i^j - \bar{x}^j.$$

Le centrage consiste à translater le nuage de données afin que son centre de gravité soit placé à l'origine. En effet,

$$\frac{1}{n} \sum_{i=1}^n \tilde{\mathbf{x}}_i = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) = \mathbf{0}.$$

Cette translation ne modifie ni les distances entre les observations, ni la forme du nuage. Elle permet simplement d'étudier directement sa dispersion autour de l'origine.




Figure 1.1: Moyenne empirique et ellipse de dispersion d'un nuage de données bidimensionnel

La figure 1.1 illustre le cas de deux variables. La croix représente la moyenne empirique du nuage. L'ellipse en décrit la dispersion : sa taille traduit l'amplitude globale de la variabilité, tandis que son orientation oblique révèle une covariance non nulle entre les deux variables.

1.2 Matrice de variance–covariance empirique

Définition 1.2.1 (Matrice de variance–covariance empirique). La matrice de variance–covariance empirique du nuage est la matrice

$$C = \frac{1}{n} \sum_{i=1}^n \tilde{\mathbf{x}}_i \tilde{\mathbf{x}}_i^\top \in \mathcal{M}_p(\mathbb{R}).$$

Son coefficient situé à la ligne j et à la colonne k est

$$C_{jk} = \frac{1}{n} \sum_{i=1}^n \tilde{x}_i^j \tilde{x}_i^k = \frac{1}{n} \sum_{i=1}^n (x_i^j - \bar{x}^j) (x_i^k - \bar{x}^k).$$

Il s'agit de la covariance empirique entre les variables X^j et X^k :

$$C_{jk} = \widehat{\text{Cov}}(X^j, X^k).$$

En particulier, les coefficients diagonaux sont les variances empiriques :

$$C_{jj} = \frac{1}{n} \sum_{i=1}^n (x_i^j - \bar{x}^j)^2 = \widehat{\text{Var}}(X^j).$$

Ainsi, la matrice C prend la forme

$$C = \begin{pmatrix} \widehat{\text{Var}}(X^1) & \widehat{\text{Cov}}(X^1, X^2) & \cdots & \widehat{\text{Cov}}(X^1, X^p) \\ \widehat{\text{Cov}}(X^2, X^1) & \widehat{\text{Var}}(X^2) & \cdots & \widehat{\text{Cov}}(X^2, X^p) \\ \vdots & \vdots & \ddots & \vdots \\ \widehat{\text{Cov}}(X^p, X^1) & \widehat{\text{Cov}}(X^p, X^2) & \cdots & \widehat{\text{Var}}(X^p) \end{pmatrix}.$$

Remarque 1.2.1 (Convention de normalisation). On rencontre également la convention

$$\hat{C} = \frac{1}{n-1} \sum_{i=1}^n \tilde{\mathbf{x}}_i \tilde{\mathbf{x}}_i^\top.$$

Le facteur $1/(n-1)$ permet d'obtenir, sous les hypothèses usuelles, un estimateur sans biais de la matrice de covariance de la population. En ACP, le remplacement de $1/n$ par $1/(n-1)$ multiplie toutes les valeurs propres par une même constante strictement positive, mais ne modifie pas les vecteurs propres, les composantes principales ni les proportions de variance expliquée.

Introduisons la matrice des données centrées

$$\tilde{\mathbf{X}} = \begin{pmatrix} \tilde{\mathbf{x}}_1^\top \\ \vdots \\ \tilde{\mathbf{x}}_n^\top \end{pmatrix} \in \mathcal{M}_{n,p}(\mathbb{R}).$$

Chaque ligne correspond à une observation centrée et chaque colonne à une variable centrée. La matrice de variance-covariance s'écrit alors

$$C = \frac{1}{n} \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}}.$$

Proposition 1.2.1 (Propriétés de la matrice de covariance). La matrice de variance-covariance empirique C est symétrique et positive, au sens où

$$a^\top C a \geq 0 \quad \text{pour tout } a \in \mathbb{R}^p.$$

Elle est définie positive si et seulement si

$$\ker(\tilde{\mathbf{X}}) = \{\mathbf{0}\},$$

c'est-à-dire si et seulement si les colonnes de la matrice des données centrées sont linéairement indépendantes.

Preuve. Comme $C = \frac{1}{n} \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}}$, on obtient

$$C^\top = \frac{1}{n} (\tilde{\mathbf{X}}^\top \tilde{\mathbf{X}})^\top = \frac{1}{n} \tilde{\mathbf{X}}^\top (\tilde{\mathbf{X}}^\top)^\top = \frac{1}{n} \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}} = C.$$

La matrice C est donc symétrique.

Soit maintenant $a \in \mathbb{R}^p$. Alors

$$a^\top C a = \frac{1}{n} a^\top \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}} a = \frac{1}{n} (\tilde{\mathbf{X}} a)^\top (\tilde{\mathbf{X}} a) = \frac{1}{n} \|\tilde{\mathbf{X}} a\|^2 \geq 0.$$

La matrice C est donc positive. De plus,

$$a^\top C a = 0 \iff \|\tilde{\mathbf{X}} a\|^2 = 0 \iff \tilde{\mathbf{X}} a = \mathbf{0}.$$

Par conséquent :

$$\begin{aligned} & \forall a \neq \mathbf{0}, \quad a^\top C a > 0 \\ & \iff [\tilde{\mathbf{X}} a = \mathbf{0} \implies a = \mathbf{0}] \\ & \iff \ker(\tilde{\mathbf{X}}) = \{\mathbf{0}\}. \end{aligned}$$

□

Remarque 1.2.2. Une matrice de covariance empirique n'est pas nécessairement définie positive. Elle peut être singulière lorsque certaines variables sont des combinaisons linéaires des autres ou lorsque le nombre de variables est trop élevé par rapport au nombre d'observations. En effet, puisque les colonnes centrées vérifient

$$\sum_{i=1}^n \tilde{\mathbf{x}}_i = \mathbf{0},$$

on a $\text{rg}(\tilde{\mathbf{X}}) \leq n - 1$. Par conséquent, $\text{rg}(C) = \text{rg}(\tilde{\mathbf{X}}) \leq \min(p, n - 1)$. En particulier, si $p \geq n$, alors C est nécessairement singulière. Elle reste cependant toujours symétrique positive.

La même matrice intervient dans la distance de Mahalanobis. Lorsque C est inversible, la quantité

$$d_C(\mathbf{x}, \bar{\mathbf{x}}) = \sqrt{(\mathbf{x} - \bar{\mathbf{x}})^\top C^{-1} (\mathbf{x} - \bar{\mathbf{x}})}$$

mesure la distance au centre en tenant compte de la dispersion et des corrélations du nuage. Les directions propres de C détermineront précisément les axes principaux des ellipsoïdes associés à cette distance.

1.3 Décomposition spectrale de la covariance

Puisque C est une matrice réelle symétrique, le théorème spectral garantit l'existence d'une matrice orthogonale

$$Q = \begin{pmatrix} | & | & \cdots & | \\ q_1 & q_2 & \cdots & q_p \\ | & | & & | \end{pmatrix}$$

et d'une matrice diagonale $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$ telles que $C = Q\Lambda Q^\top$. Les colonnes $q_1, \dots, q_p$ forment une base orthonormée de $\mathbb{R}^p$ constituée de vecteurs propres de C :

$$C q_k = \lambda_k q_k, \quad k = 1, \dots, p.$$

Comme C est positive, toutes ses valeurs propres sont positives ou nulles. On peut donc les ordonner de manière décroissante :

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0.$$

Les vecteurs propres associés déterminent les axes principaux du nuage de données. Les valeurs propres mesurent, quant à elles, l'amplitude de la dispersion le long de ces axes.

1.4 Variance totale et quantité d'information

Une question naturelle apparaît : comment mesurer la quantité totale de variabilité contenue dans les données ? La trace de la matrice de covariance vaut

$$\text{tr}(C) = \sum_{j=1}^p C_{jj} = \sum_{j=1}^p \widehat{\text{Var}}(X^j).$$

Elle mesure donc la dispersion totale du nuage par rapport à son centre. Cette quantité est appelée *variance totale* ou *inertie totale* du nuage. On peut également l'écrire sous la forme

$$\text{tr}(C) = \frac{1}{n} \sum_{i=1}^n \|\tilde{\mathbf{x}}_i\|^2,$$

puisqu'en effet,

$$\text{tr}(C) = \frac{1}{n} \sum_{i=1}^n \text{tr}(\tilde{\mathbf{x}}_i \tilde{\mathbf{x}}_i^\top) = \frac{1}{n} \sum_{i=1}^n \tilde{\mathbf{x}}_i^\top \tilde{\mathbf{x}}_i = \frac{1}{n} \sum_{i=1}^n \|\tilde{\mathbf{x}}_i\|^2.$$

Ainsi, la variance totale est la moyenne des carrés des distances euclidiennes entre les observations et leur centre. D'autre part, grâce à la décomposition spectrale,

$$\text{tr}(C) = \text{tr}(Q\Lambda Q^\top) = \text{tr}(Q^\top Q\Lambda) = \text{tr}(\Lambda) = \sum_{k=1}^p \lambda_k.$$

On obtient donc l'identité fondamentale

$$\sum_{j=1}^p \widehat{\text{Var}}(X^j) = \sum_{k=1}^p \lambda_k.$$

Autrement dit, la variance totale du jeu de données est égale à la somme des valeurs propres de la matrice de covariance. Le passage de la base canonique à la base orthonormée des vecteurs propres ne détruit aucune variabilité : il ne fait que la redistribuer entre de nouvelles directions.

Remarque 1.4.1 (Variabilité et information). Dans le cadre de l'ACP, une direction est considérée comme informative lorsque les observations y sont fortement dispersées. Une direction de variance nulle est constante sur l'ensemble des observations et ne permet donc pas de les distinguer. C'est en ce sens précis que la variance est utilisée comme mesure de l'information. Cette interprétation dépend toutefois de l'objectif statistique. Une faible variance ne signifie pas nécessairement qu'une variable est inutile pour toute tâche, notamment dans un problème de prédiction supervisée.

1.5 Composantes principales

Considérons une direction unitaire $a \in \mathbb{R}^p$, c'est-à-dire $\|a\| = 1$. Pour chaque observation centrée, on définit le score projeté

$$z_i(a) = a^\top \tilde{\mathbf{x}}_i, \quad i = 1, \dots, n.$$

On note Z_a la variable empirique dont les observations sont $z_1(a), \dots, z_n(a)$. Elle représente la combinaison linéaire des variables centrées de coefficients $a_1, \dots, a_p$.

Proposition 1.5.1 (Variance d'une projection). La variance empirique de la projection sur la direction a est donnée par

$$\widehat{\text{Var}}(Z_a) = a^\top C a.$$

Preuve. Comme les observations sont centrées, la moyenne empirique des $z_i(a)$ est nulle. Par conséquent,

$$\begin{aligned}\widehat{\text{Var}}(Z_a) &= \frac{1}{n} \sum_{i=1}^n z_i(a)^2 \\ &= \frac{1}{n} \sum_{i=1}^n a^\top \tilde{\mathbf{x}}_i \tilde{\mathbf{x}}_i^\top a \\ &= a^\top \left(\frac{1}{n} \sum_{i=1}^n \tilde{\mathbf{x}}_i \tilde{\mathbf{x}}_i^\top \right) a = a^\top C a.\end{aligned}$$

□

La première composante principale est construite en recherchant la direction unitaire le long de laquelle la variance projetée est maximale :

$$\max_{\|a\|=1} a^\top C a.$$

Proposition 1.5.2 (Première composante principale). La valeur maximale de $a^\top C a$ sous la contrainte $\|a\| = 1$ est λ_1 . Elle est atteinte lorsque a est un vecteur propre unitaire associé à la plus grande valeur propre λ_1 . Les scores de la première composante principale sont donc

$$z_{i1} = q_1^\top \tilde{\mathbf{x}}_i, \quad i = 1, \dots, n,$$

et la variable empirique correspondante Z_1 vérifie

$$\widehat{\text{Var}}(Z_1) = \lambda_1.$$

Preuve. Comme $(q_1, \dots, q_p)$ est une base orthonormée, tout vecteur unitaire $a \in \mathbb{R}^p$ s'écrit

$$a = \sum_{k=1}^p \alpha_k q_k, \quad \sum_{k=1}^p \alpha_k^2 = 1.$$

On a alors

$$a^\top C a = \left(\sum_{k=1}^p \alpha_k q_k \right)^\top C \left(\sum_{\ell=1}^p \alpha_\ell q_\ell \right) = \sum_{k=1}^p \lambda_k \alpha_k^2.$$

Puisque $\lambda_k \leq \lambda_1$ pour tout k ,

$$a^\top C a \leq \lambda_1 \sum_{k=1}^p \alpha_k^2 = \lambda_1.$$

Cette borne est atteinte pour $a = q_1$. Ainsi,

$$\max_{\|a\|=1} a^\top C a = \lambda_1.$$

□

On construit ensuite la deuxième composante principale en maximisant la variance parmi les directions unitaires orthogonales à q_1 , puis on poursuit récursivement. La k -ième composante principale est la variable empirique Z_k dont les scores sont

$$z_{ik} = q_k^\top \tilde{\mathbf{x}}_i, \quad i = 1, \dots, n.$$

Proposition 1.5.3 (Variance des composantes principales). Pour tout $k \in \{1, \dots, p\}$, la k -ième composante principale vérifie

$$\widehat{\text{Var}}(Z_k) = \lambda_k.$$

Preuve. En utilisant $Cq_k = \lambda_k q_k$ et $\|q_k\| = 1$, on obtient

$$\widehat{\text{Var}}(Z_k) = q_k^\top C q_k = q_k^\top (\lambda_k q_k) = \lambda_k q_k^\top q_k = \lambda_k.$$

□

Proposition 1.5.4 (Décorrélation des composantes principales). Deux composantes principales distinctes sont non corrélées. Plus précisément, si $k \neq \ell$, alors

$$\widehat{\text{Cov}}(Z_k, Z_\ell) = 0.$$

Preuve. On a

$$\widehat{\text{Cov}}(Z_k, Z_\ell) = q_k^\top C q_\ell = q_k^\top (\lambda_\ell q_\ell) = \lambda_\ell q_k^\top q_\ell = 0,$$

car les vecteurs propres q_k et q_ℓ sont orthogonaux.

□

Ainsi, dans la base des vecteurs propres, la matrice de covariance des nouvelles variables est diagonale :

$$\widehat{\text{Cov}}(\mathbf{Z}) = Q^\top C Q = \Lambda.$$

Ici, $\mathbf{Z} = (Z_1, \dots, Z_p)^\top$ regroupe les composantes principales.

L'ACP transforme donc les variables initiales, qui peuvent être corrélées, en variables synthétiques non corrélées, ordonnées selon leur variance décroissante.

1.6 Réduction de dimension

Le deuxième objectif de l'ACP consiste à remplacer les p variables initiales par un nombre plus faible $d < p$ de variables synthétiques, tout en préservant autant que possible la variabilité du nuage.

Exemple 1.6.1. Supposons que le jeu de données comporte $p = 500$ variables et que l'ACP fournisse les proportions de variance expliquée suivantes :

$$\frac{\lambda_1}{\sum_{k=1}^{500} \lambda_k} = 0.70, \quad \frac{\lambda_2}{\sum_{k=1}^{500} \lambda_k} = 0.20, \quad \frac{\lambda_3}{\sum_{k=1}^{500} \lambda_k} = 0.05.$$

Alors

$$\lambda_1 + \lambda_2 + \lambda_3 = 0.95 \sum_{k=1}^{500} \lambda_k.$$

Les trois premières directions principales concentrent donc 95 % de la variance totale du jeu de données. On peut remplacer les 500 variables initiales par les trois composantes principales Z_1, Z_2 et Z_3 en ne perdant que 5 % de la variabilité mesurée par l'ACP.

Considérons une matrice

$$R = \begin{pmatrix} | & & | \\ r_1 & \cdots & r_d \\ | & & | \end{pmatrix} \in \mathbb{R}^{p \times d}, \quad d < p,$$

dont les colonnes forment une famille orthonormée : $R^\top R = I_d$. Les colonnes de R engendrent un sous-espace de dimension d . Les coordonnées projetées de la i -ième observation centrée sont

$$z_i = R^\top \tilde{x}_i \in \mathbb{R}^d.$$

La matrice de covariance des données projetées est $C_Z = R^\top C R$. La variance totale conservée après projection vaut donc $\text{tr}(C_Z) = \text{tr}(R^\top C R)$. Le problème de réduction de dimension peut ainsi s'écrire

$$\max_{R^\top R = I_d} \text{tr}(R^\top C R).$$

Autrement dit, on recherche un sous-espace de dimension d qui conserve le plus possible la dispersion du nuage.

Théorème 1.6.1 (Sous-espace principal optimal). *Soient $\lambda_1 \geq \cdots \geq \lambda_p \geq 0$ les valeurs propres de C , et $q_1, \dots, q_p$ des vecteurs propres orthonormés associés. Alors*

$$\max_{R^\top R = I_d} \text{tr}(R^\top C R) = \sum_{k=1}^d \lambda_k.$$

Un maximiseur est donné par

$$Q_d = \begin{pmatrix} | & & | \\ q_1 & \cdots & q_d \\ | & & | \end{pmatrix}.$$

Preuve. Notons $r_1, \dots, r_d$ les colonnes de R . Comme $R^\top R = I_d$, ces vecteurs forment une famille orthonormée. On a

$$\text{tr}(R^\top C R) = \sum_{\ell=1}^d r_\ell^\top C r_\ell.$$

Décomposons chaque r_ℓ dans la base orthonormée des vecteurs propres :

$$r_\ell = \sum_{k=1}^p \alpha_{k\ell} q_k.$$

Alors

$$r_\ell^\top C r_\ell = \sum_{k=1}^p \lambda_k \alpha_{k\ell}^2.$$

Par conséquent,

$$\text{tr}(R^\top C R) = \sum_{k=1}^p \lambda_k c_k \quad \text{où} \quad c_k = \sum_{\ell=1}^d \alpha_{k\ell}^2 = \sum_{\ell=1}^d \langle q_k, r_\ell \rangle^2.$$

Le coefficient c_k est le carré de la norme de la projection de q_k sur le sous-espace

engendré par $r_1, \dots, r_d$. Ainsi, $0 \leq c_k \leq 1$. De plus,

$$\sum_{k=1}^p c_k = \sum_{\ell=1}^d \sum_{k=1}^p \alpha_{k\ell}^2 = \sum_{\ell=1}^d \|r_\ell\|^2 = d.$$

On doit donc répartir une masse totale d , avec $0 \leq c_k \leq 1$, entre des valeurs propres ordonnées de manière décroissante. La somme

$$\sum_{k=1}^p \lambda_k c_k$$

est maximale lorsque

$$c_1 = \dots = c_d = 1 \quad \text{et} \quad c_{d+1} = \dots = c_p = 0.$$

Il vient alors

$$\text{tr}(R^\top C R) \leq \sum_{k=1}^d \lambda_k.$$

Cette borne est atteinte en choisissant

$$R = Q_d = \begin{pmatrix} | & & | \\ q_1 & \cdots & q_d \\ | & & | \end{pmatrix}.$$

En effet, $Q_d^\top C Q_d = \text{diag}(\lambda_1, \dots, \lambda_d)$, et donc

$$\text{tr}(Q_d^\top C Q_d) = \sum_{k=1}^d \lambda_k.$$

□

Remarque 1.6.1. Si $\lambda_d > \lambda_{d+1}$, le sous-espace principal de dimension d est unique. En revanche, lorsque $\lambda_d = \lambda_{d+1}$, plusieurs bases orthonormées peuvent fournir la même variance maximale. L'ACP identifie alors un sous-espace optimal, mais pas nécessairement des directions propres uniques à l'intérieur d'un espace propre multiple.

1.7 Proportion de variance expliquée

La variance portée par la k -ième composante principale est λ_k . On suppose ici que $C \neq 0$, c'est-à-dire que la variance totale est strictement positive. Sa proportion de variance expliquée est alors

$$\frac{\lambda_k}{\sum_{j=1}^p \lambda_j}.$$

La proportion cumulée de variance expliquée par les d premières composantes est

$$\frac{\lambda_1 + \dots + \lambda_d}{\lambda_1 + \dots + \lambda_p} = \frac{\sum_{k=1}^d \lambda_k}{\sum_{k=1}^p \lambda_k}. \quad (1.1)$$

Cette quantité appartient à l'intervalle $[0, 1]$. Elle mesure la fraction de la variance totale conservée lorsque l'on projette les observations sur le sous-espace principal $F_d =$

$\text{Vect}\{q_1, \dots, q_d\}$. On peut, par exemple, choisir le plus petit entier d tel que

$$\frac{\sum_{k=1}^d \lambda_k}{\sum_{k=1}^p \lambda_k} \geq \tau,$$

où τ est un seuil fixé à l'avance, tel que 0.90, 0.95 ou 0.99.

Remarque 1.7.1. Le choix de d ne doit pas nécessairement reposer sur un seuil automatique. Il dépend également de l'objectif de l'analyse, de l'interprétabilité des composantes, du bruit présent dans les données et de la performance obtenue dans une éventuelle tâche statistique ultérieure.

1.8 Projection et reconstruction des observations

Pour une observation centrée $\tilde{\mathbf{x}}_i$, ses coordonnées dans l'espace principal de dimension d sont

$$\mathbf{z}_i = Q_d^\top \tilde{\mathbf{x}}_i = \begin{pmatrix} q_1^\top \tilde{\mathbf{x}}_i \\ \vdots \\ q_d^\top \tilde{\mathbf{x}}_i \end{pmatrix}.$$

Ces d coordonnées sont appelées les *scores principaux* de l'observation. À partir de ces coordonnées, on reconstruit une approximation dans l'espace initial par

$$\hat{\tilde{\mathbf{x}}}_i = Q_d \mathbf{z}_i = Q_d Q_d^\top \tilde{\mathbf{x}}_i.$$

La matrice $\Pi_d = Q_d Q_d^\top$ est le projecteur orthogonal sur F_d . Pour revenir aux données non centrées, on pose

$$\hat{\mathbf{x}}_i = \bar{\mathbf{x}} + Q_d Q_d^\top (\mathbf{x}_i - \bar{\mathbf{x}}).$$

L'information perdue correspond à la composante orthogonale au sous-espace principal :

$$\mathbf{x}_i - \hat{\mathbf{x}}_i = (I_p - Q_d Q_d^\top) \tilde{\mathbf{x}}_i.$$

Proposition 1.8.1 (Erreur de reconstruction de l'ACP). L'erreur quadratique moyenne de reconstruction obtenue avec les d premières composantes principales vaut

$$\frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2 = \sum_{k=d+1}^p \lambda_k.$$

Preuve. Chaque observation centrée se décompose dans la base orthonormée des vecteurs propres :

$$\tilde{\mathbf{x}}_i = \sum_{k=1}^p (q_k^\top \tilde{\mathbf{x}}_i) q_k.$$

Sa reconstruction dans F_d est

$$\hat{\tilde{\mathbf{x}}}_i = \sum_{k=1}^d (q_k^\top \tilde{\mathbf{x}}_i) q_k.$$

Par conséquent,

$$\tilde{\mathbf{x}}_i - \hat{\mathbf{x}}_i = \sum_{k=d+1}^p (q_k^\top \tilde{\mathbf{x}}_i) q_k.$$

Comme la famille $(q_1, \dots, q_p)$ est orthonormée,

$$\|\tilde{\mathbf{x}}_i - \hat{\mathbf{x}}_i\|^2 = \sum_{k=d+1}^p (q_k^\top \tilde{\mathbf{x}}_i)^2.$$

En moyennant sur les observations, il vient

$$\frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2 = \sum_{k=d+1}^p \frac{1}{n} \sum_{i=1}^n (q_k^\top \tilde{\mathbf{x}}_i)^2 = \sum_{k=d+1}^p \widehat{\text{Var}}(Z_k) = \sum_{k=d+1}^p \lambda_k.$$

□

La variance conservée et l'erreur de reconstruction sont donc complémentaires :

$$\underbrace{\sum_{k=1}^d \lambda_k}_{\text{variance conservée}} + \underbrace{\sum_{k=d+1}^p \lambda_k}_{\text{variance perdue}} = \underbrace{\sum_{k=1}^p \lambda_k}_{\text{variance totale}}.$$

Ainsi, maximiser la variance conservée revient exactement à minimiser l'erreur quadratique de reconstruction.

1.9 ACP sur la covariance ou sur la corrélation ?

L'ACP construite précédemment repose sur la matrice de covariance. Elle dépend donc des unités dans lesquelles les variables sont exprimées. Une variable dont l'échelle numérique est très grande peut dominer l'analyse, même si cette différence d'échelle provient uniquement du choix des unités. Par exemple, remplacer une variable mesurée en mètres par la même variable mesurée en millimètres multiplie sa variance par 10^6 . Les directions principales peuvent alors être profondément modifiées.

Lorsque les variables ont des unités ou des ordres de grandeur très différents, on peut les centrer et les réduire, à condition que leurs variances empiriques soient strictement positives :

$$Y_i^j = \frac{x_i^j - \bar{x}^j}{s_j} \quad \text{où} \quad s_j = \sqrt{\widehat{\text{Var}}(X^j)}.$$

Chaque variable standardisée possède alors une moyenne nulle et une variance égale à 1. Effectuer l'ACP sur les variables standardisées revient à diagonaliser leur matrice de corrélation.

Remarque 1.9.1. L'ACP sur la covariance est naturelle lorsque les variables sont exprimées dans des unités comparables et que leur amplitude possède un sens substantiel. L'ACP sur la corrélation est souvent préférable lorsque les unités ou les échelles diffèrent fortement. La standardisation n'est donc pas une opération automatique : elle correspond à un choix de géométrie et modifie la notion de variabilité que l'on souhaite préserver.

Synthèse géométrique de l'ACP. L'analyse en composantes principales peut finalement être résumée de la manière suivante. À partir des observations $\mathbf{x}_1, \dots, \mathbf{x}_n$, on commence par centrer le nuage :

$$\tilde{\mathbf{x}}_i = \mathbf{x}_i - \bar{\mathbf{x}}.$$

On construit ensuite la matrice de covariance

$$C = \frac{1}{n} \sum_{i=1}^n \tilde{\mathbf{x}}_i \tilde{\mathbf{x}}_i^\top,$$

puis sa décomposition spectrale

$$C = Q\Lambda Q^\top, \quad \lambda_1 \geq \dots \geq \lambda_p \geq 0.$$

Les vecteurs propres $q_1, \dots, q_p$ fournissent les directions principales du nuage, tandis que les valeurs propres $\lambda_1, \dots, \lambda_p$ donnent les variances portées par ces directions. Les nouvelles variables Z_k , dont les scores sont

$$z_{ik} = q_k^\top \tilde{\mathbf{x}}_i,$$

sont deux à deux non corrélées et vérifient

$$\widehat{\text{Var}}(Z_k) = \lambda_k.$$

Enfin, la projection sur

$$\text{Vect}\{q_1, \dots, q_d\}$$

est, parmi tous les sous-espaces de dimension d , celle qui conserve la plus grande variance totale et minimise l'erreur quadratique de reconstruction. L'ACP transforme ainsi un problème statistique de réduction de dimension en un problème spectral portant sur une matrice symétrique positive.

Décomposition en valeurs singulières

La diagonalisation spectrale fournit une description particulièrement claire des matrices symétriques. Une matrice générale $M \in \mathcal{M}_{m,n}(\mathbb{R})$ n'est bien sûr pas nécessairement carrée et, même lorsqu'elle l'est, elle peut ne pas être diagonalisable. La notion de valeur propre ne suffit donc pas à décrire l'action d'une application linéaire quelconque.

La décomposition en valeurs singulières, ou *SVD* pour *Singular Value Decomposition*, contourne ces difficultés. Elle affirme que toute matrice réelle, carrée ou rectangulaire, peut être décomposée à l'aide de deux matrices orthogonales et d'une matrice diagonale rectangulaire à coefficients positifs. L'idée fondamentale consiste à ne pas étudier directement M , mais les deux matrices symétriques positives

$$M^\top M \in \mathcal{M}_n(\mathbb{R}) \quad \text{et} \quad MM^\top \in \mathcal{M}_m(\mathbb{R}).$$

Le théorème spectral s'applique à ces deux matrices. Leurs valeurs propres strictement positives sont les carrés des valeurs singulières de M , tandis que leurs vecteurs propres décrivent les directions privilégiées dans les espaces de départ et d'arrivée.

2.1 La matrice symétrique positive $M^\top M$

Étudions dans un premier temps les comportements de $M^\top M$ pour une matrice $M \in \mathcal{M}_{m,n}(\mathbb{R})$ quelconque.

Proposition 2.1.1 (Propriétés fondamentales de $S = M^\top M$). Soit $M \in \mathcal{M}_{m,n}(\mathbb{R})$ et posons $S = M^\top M$. Alors :

1. S est symétrique ;
2. S est positive : $x^\top Sx \geq 0$ pour tout $x \in \mathbb{R}^n$;
3. $\ker(S) = \ker(M)$;
4. $\text{rg}(S) = \text{rg}(M)$;
5. S est définie positive si et seulement si M est injective, c'est-à-dire si et seulement si les colonnes de M sont linéairement indépendantes.

Preuve. On démontre ces cinq caractéristiques.

1. La symétrie découle des propriétés de la transposition :

$$S^\top = (M^\top M)^\top = M^\top (M^\top)^\top = M^\top M = S.$$

2. Pour tout $x \in \mathbb{R}^n$, on a ensuite

$$x^\top Sx = x^\top M^\top Mx = (Mx)^\top (Mx) = \|Mx\|^2 = \sum_{i=1}^m ((Mx)_i)^2 \geq 0.$$

La matrice S est donc positive.

3. Montrons maintenant l'égalité des noyaux. Si $x \in \ker(M)$, alors $Mx = 0$, et donc

$$Sx = M^\top \underbrace{Mx}_{=0} = 0.$$

Ainsi, $\ker(M) \subseteq \ker(S)$. Réciproquement, si $x \in \ker(S)$, alors

$$0 = x^\top Sx = \|Mx\|^2.$$

Comme une norme est nulle si et seulement si le vecteur est nul, on obtient $Mx = 0$. Par conséquent, $\ker(S) = \ker(M)$.

4. Les applications linéaires associées à S et à M ont le même espace de départ, à savoir $\mathbb{R}^n$. Le théorème du rang donne donc

$$\text{rg}(S) = n - \dim \ker(S) = n - \dim \ker(M) = \text{rg}(M).$$

5. Enfin, S est définie positive si et seulement si

$$x^\top Sx > 0 \quad \text{pour tout } x \neq 0.$$

Or $x^\top Sx = \|Mx\|^2$. Cette quantité est strictement positive pour tout $x \neq 0$ si et seulement si

$$Mx \neq 0 \quad \text{pour tout } x \neq 0,$$

c'est-à-dire si et seulement si

$$\ker(M) = \{0\}.$$

Cela signifie exactement que l'application $x \mapsto Mx$ est injective, ou, de manière équivalente, que les colonnes de M sont linéairement indépendantes.

□

Remarque 2.1.1. Si $M \in \mathcal{M}_{m,n}(\mathbb{R})$ possède plus de colonnes que de lignes, c'est-à-dire si $n > m$, alors

$$\text{rg}(M) \leq m < n.$$

L'application $M : \mathbb{R}^n \rightarrow \mathbb{R}^m$ ne peut donc pas être injective. Ainsi, $M^\top M$ est nécessairement singulière lorsque $n > m$.

2.2 Valeurs propres de $M^\top M$

La symétrie de $M^\top M$ permet d'appliquer le théorème spectral. Sa positivité impose en outre que toutes ses valeurs propres soient positives ou nulles.

Proposition 2.2.1 (Valeurs propres de $M^\top M$). Soit $M \in \mathcal{M}_{m,n}(\mathbb{R})$.

- (i) Toutes les valeurs propres de $M^\top M$ sont réelles et positives ou nulles.
- (ii) Si M est de surcroît injective, alors toutes les valeurs propres de $M^\top M$ sont strictement positives.

Preuve. On démontre les deux assertions.

- (i) Comme $M^\top M$ est une matrice réelle symétrique, toutes ses valeurs propres sont

réelles d'après le théorème spectral. Soit λ une valeur propre de $M^\top M$, associée à un vecteur propre $v \neq 0$. On a

$$M^\top M v = \lambda v.$$

En multipliant à gauche par $v^\top$, il vient

$$v^\top M^\top M v = \lambda v^\top v.$$

Par conséquent,

$$\lambda \|v\|^2 = \|Mv\|^2 \geq 0.$$

Puisque $v \neq 0$, on a $\|v\|^2 > 0$, et donc $\lambda \geq 0$.

- (ii) Si M est injective, alors $Mv \neq 0$ pour tout $v \neq 0$. On obtient alors $\|Mv\|^2 > 0$, et donc $\lambda > 0$.

□

Proposition 2.2.2 (Nombre de valeurs propres strictement positives). Soit $r = \text{rg}(M)$. La matrice $M^\top M$ possède exactement r valeurs propres strictement positives, comptées avec leur multiplicité, et $n - r$ valeurs propres nulles.

Preuve. Comme $M^\top M$ est symétrique, elle est diagonalisable dans une base ortho-normée. Son rang est donc égal au nombre de valeurs propres non nulles, comptées avec leur multiplicité. Or, d'après la proposition 2.1.1,

$$\text{rg}(M^\top M) = \text{rg}(M) = r.$$

Par ailleurs, toutes les valeurs propres de $M^\top M$ sont positives ou nulles. Elle possède donc exactement r valeurs propres strictement positives et $n - r$ valeurs propres nulles.

□

2.3 Interprétation de l'endomorphisme $M^\top M$

La matrice M transforme un vecteur $x \in \mathbb{R}^n$ en un vecteur $Mx \in \mathbb{R}^m$. Elle peut modifier sa direction, sa norme et éventuellement annuler certaines composantes. La matrice $M^\top M$ ne décrit pas directement la direction finale de Mx , mais décrit plutôt la manière dont M modifie les longueurs et les angles dans l'espace de départ. En effet, pour tous $x, y \in \mathbb{R}^n$,

$$\langle Mx, My \rangle = (Mx)^\top (My) = x^\top M^\top M y = \langle x, M^\top M y \rangle.$$

En particulier,

$$\|Mx\|^2 = x^\top M^\top M x.$$

La forme quadratique associée à $M^\top M$ mesure donc le carré de la longueur du vecteur obtenu après application de M .

Supposons maintenant que v soit un vecteur propre unitaire de $M^\top M$, associé à la valeur propre $\lambda \geq 0$. Alors

$$M^\top M v = \lambda v \quad \text{et} \quad \|Mv\|^2 = v^\top M^\top M v = \lambda \|v\|^2 = \lambda.$$

Ainsi,

$$\|Mv\| = \sqrt{\lambda}.$$

Les vecteurs propres de $M^\top M$ sont donc les directions orthogonales de l'espace de départ dans lesquelles l'action de M se réduit à un changement de longueur bien déterminé.

Le facteur de dilatation dans la direction v est $\sqrt{\lambda}$. C'est précisément ce nombre que l'on appellera une *valeur singulière* de M .

Remarque 2.3.1 (Ce que mesure $M^\top M$). La matrice $M^\top M$ peut être interprétée comme la mesure de la déformation métrique produite par M dans l'espace de départ : $x^\top M^\top M x = \|Mx\|^2$. Elle détecte donc :

- les directions annulées par M , qui constituent $\ker(M)$;
- les directions fortement dilatées, associées aux grandes valeurs propres de $M^\top M$;
- les directions faiblement dilatées, associées aux petites valeurs propres positives.

En revanche, $M^\top M$ ne conserve pas l'information sur la direction de Mx dans $\mathbb{R}^m$. Cette information sera portée par les vecteurs singuliers gauches.

2.4 Énoncé et démonstration de la SVD

Nous pouvons maintenant énoncer le théorème central.

Théorème 2.4.1 (Décomposition en valeurs singulières). *Soit $M \in \mathcal{M}_{m,n}(\mathbb{R})$ une matrice de rang r . Il existe deux matrices orthogonales $U \in \mathcal{M}_m(\mathbb{R})$ et $V \in \mathcal{M}_n(\mathbb{R})$ et une matrice diagonale rectangulaire*

$$\Sigma \in \mathcal{M}_{m,n}(\mathbb{R})$$

telles que

$$M = U\Sigma V^\top.$$

La matrice Σ est définie par

$$\Sigma_{ij} = \begin{cases} \sigma_i, & \text{si } i = j \leq r, \\ 0, & \text{sinon,} \end{cases}$$

où

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0.$$

Les nombres $\sigma_1, \dots, \sigma_r$ sont appelés les valeurs singulières positives de M . En complétant éventuellement par des zéros jusqu'à $\min(m, n)$, on obtient l'ensemble des valeurs singulières de M . Les colonnes $u_1, \dots, u_m$ de U sont appelées les vecteurs singuliers gauches, tandis que les colonnes $v_1, \dots, v_n$ de V sont appelées les vecteurs singuliers droits.

Preuve. La démonstration repose sur le théorème spectral appliqué à la matrice symétrique positive $M^\top M$.

Étape 1 : diagonalisation orthogonale de $M^\top M$.

La matrice $S = M^\top M$ est symétrique positive. D'après le théorème spectral, il existe une base orthonormée

$$(v_1, \dots, v_n)$$

de $\mathbb{R}^n$, constituée de vecteurs propres de S . Comme $\text{rg}(S) = \text{rg}(M) = r$, la matrice S possède exactement r valeurs propres strictement positives. On peut les ordonner de telle sorte que

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0 \quad \text{et} \quad \lambda_{r+1} = \dots = \lambda_n = 0.$$

Pour tout $i \in \{1, \dots, n\}$,

$$M^\top M v_i = \lambda_i v_i.$$

On définit, pour $i = 1, \dots, r$,

$$\sigma_i := \sqrt{\lambda_i}.$$

Comme les λ_i sont strictement positives pour $i \leq r$, les nombres σ_i sont bien définis et vérifient

$$\sigma_1 \geq \dots \geq \sigma_r > 0.$$

Étape 2 : construction des vecteurs singuliers gauches.

Pour tout $i \in \{1, \dots, r\}$, posons

$$u_i = \frac{1}{\sigma_i} M v_i.$$

Cette définition donne immédiatement

$$M v_i = \sigma_i u_i.$$

Montrons que les vecteurs $u_1, \dots, u_r$ forment une famille orthonormée. Pour $i, j \in \{1, \dots, r\}$,

$$u_i^\top u_j = \frac{1}{\sigma_i \sigma_j} (M v_i)^\top (M v_j) = \frac{1}{\sigma_i \sigma_j} v_i^\top M^\top M v_j = \frac{1}{\sigma_i \sigma_j} v_i^\top (\lambda_j v_j) = \frac{\lambda_j}{\sigma_i \sigma_j} v_i^\top v_j.$$

Comme la famille $(v_1, \dots, v_n)$ est orthonormée,

$$v_i^\top v_j = \delta_{ij}.$$

Puisque $\lambda_j = \sigma_j^2$, on obtient

$$u_i^\top u_j = \frac{\sigma_j^2}{\sigma_i \sigma_j} \delta_{ij} = \delta_{ij}.$$

La famille

$$(u_1, \dots, u_r)$$

est donc orthonormée dans $\mathbb{R}^m$.

Étape 3 : complétion en une base orthonormée de $\mathbb{R}^m$.

La famille orthonormée $(u_1, \dots, u_r)$ peut être complétée en une base orthonormée

$$(u_1, \dots, u_r, u_{r+1}, \dots, u_m)$$

de $\mathbb{R}^m$. On définit alors

$$U = \begin{pmatrix} | & & | \\ u_1 & \cdots & u_m \\ | & & | \end{pmatrix} \in \mathcal{M}_m(\mathbb{R}) \quad \text{et} \quad V = \begin{pmatrix} | & & | \\ v_1 & \cdots & v_n \\ | & & | \end{pmatrix} \in \mathcal{M}_n(\mathbb{R}).$$

Comme leurs colonnes forment des bases orthonormées, les matrices U et V sont orthogonales :

$$U^\top U = U U^\top = I_m \quad \text{et} \quad V^\top V = V V^\top = I_n.$$

Étape 4 : action de M sur les vecteurs singuliers droits. Pour $i \leq r$, la définition de u_i donne

$$Mv_i = \sigma_i u_i.$$

Pour $i > r$, on a $\lambda_i = 0$, donc

$$M^\top Mv_i = 0.$$

Par conséquent,

$$\|Mv_i\|^2 = v_i^\top M^\top Mv_i = 0 \quad \text{d'où} \quad Mv_i = 0.$$

Ainsi,

$$Mv_i = \begin{cases} \sigma_i u_i, & 1 \leq i \leq r, \\ 0, & r < i \leq n. \end{cases}$$

Comme les colonnes de MV sont les vecteurs Mv_i , cette relation s'écrit

$$MV = U\Sigma,$$

où $\Sigma \in \mathcal{M}_{m,n}(\mathbb{R})$ est la matrice diagonale rectangulaire définie par

$$\Sigma_{ij} = \begin{cases} \sigma_i, & i = j \leq r, \\ 0, & \text{sinon.} \end{cases}$$

En multipliant à droite par $V^\top = V^{-1}$, on obtient finalement

$$M = U\Sigma V^\top.$$

Cela démontre l'existence de la décomposition en valeurs singulières.

Étape 5 : unicité des valeurs singulières.

Les nombres $\sigma_1^2, \dots, \sigma_r^2$ sont exactement les valeurs propres strictement positives de $M^\top M$. Le spectre de $M^\top M$ étant entièrement déterminé par M , les valeurs singulières $\sigma_i = \sqrt{\lambda_i}$ sont elles aussi entièrement déterminées par M , à l'ordre près. En les rangeant par ordre décroissant,

$$\sigma_1 \geq \dots \geq \sigma_r > 0,$$

leur ordre est fixé. □

Remarque 2.4.1 (Unicité des vecteurs singuliers). Les valeurs singulières sont uniques, mais les vecteurs singuliers ne le sont pas toujours. Si σ_i est une valeur singulière simple, alors v_i est déterminé à un signe près. Comme

$$u_i = \frac{Mv_i}{\sigma_i},$$

le vecteur u_i subit nécessairement le même changement de signe :

$$v_i \longmapsto -v_i, \quad u_i \longmapsto -u_i.$$

Si une valeur singulière σ est multiple, on peut effectuer un changement de base orthogonal dans le sous-espace singulier droit correspondant. Le même changement de base doit être appliqué dans le sous-espace singulier gauche correspondant. Enfin, les vecteurs associés aux valeurs singulières nulles peuvent être choisis de manière non unique afin de compléter les familles orthonormées.

2.5 Relations fondamentales entre les vecteurs singuliers

La preuve précédente fournit les relations

$$Mv_i = \sigma_i u_i, \quad i = 1, \dots, r.$$

En appliquant $M^\top$ à cette égalité, on obtient

$$M^\top Mv_i = \sigma_i M^\top u_i.$$

Or

$$M^\top Mv_i = \sigma_i^2 v_i.$$

Puisque $\sigma_i > 0$, il vient

$$M^\top u_i = \sigma_i v_i.$$

Ainsi, pour tout $i \leq r$,

$$\boxed{Mv_i = \sigma_i u_i, \quad M^\top u_i = \sigma_i v_i.}$$

Ces deux relations montrent que M envoie la direction droite v_i sur la direction gauche u_i , en multipliant sa longueur par σ_i .

Proposition 2.5.1 (Diagonalisation de $M^\top M$ et de $MM^\top$). Soit

$$M = U\Sigma V^\top$$

une décomposition en valeurs singulières. Alors

$$M^\top M = V\Sigma^\top \Sigma V^\top$$

et

$$MM^\top = U\Sigma\Sigma^\top U^\top.$$

En particulier,

$$M^\top M = V \operatorname{diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0) V^\top$$

et

$$MM^\top = U \operatorname{diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0) U^\top,$$

les deux matrices diagonales ayant respectivement les tailles $n \times n$ et $m \times m$.

Preuve. Comme U et V sont orthogonales,

$$U^\top U = I_m \quad \text{et} \quad V^\top V = I_n.$$

On a donc

$$\begin{aligned} M^\top M &= (U\Sigma V^\top)^\top (U\Sigma V^\top) \\ &= V\Sigma^\top U^\top U\Sigma V^\top \\ &= V\Sigma^\top \Sigma V^\top. \end{aligned}$$

De même,

$$\begin{aligned}
MM^\top &= (U\Sigma V^\top)(U\Sigma V^\top)^\top \\
&= U\Sigma V^\top V\Sigma^\top U^\top \\
&= U\Sigma\Sigma^\top U^\top.
\end{aligned}$$

Or

$$\Sigma^\top \Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0) \in \mathcal{M}_n(\mathbb{R})$$

et

$$\Sigma\Sigma^\top = \text{diag}(\sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0) \in \mathcal{M}_m(\mathbb{R}).$$

Les identités annoncées en découlent. $\square$

Remarque 2.5.1. Les matrices $M^\top M$ et $MM^\top$ n'ont pas nécessairement la même taille. Elles possèdent néanmoins les mêmes valeurs propres strictement positives, avec les mêmes multiplicités :

$$\sigma_1^2, \dots, \sigma_r^2.$$

Leurs éventuelles différences spectrales concernent uniquement le nombre de valeurs propres nulles.

2.6 Description des sous-espaces fondamentaux

La SVD fournit directement des bases orthonormées du noyau, de l'image et de leurs orthogonaux.

Proposition 2.6.1 (Sous-espaces fondamentaux associés à M). Soit

$$M = U\Sigma V^\top$$

une décomposition en valeurs singulières de M , avec $r = \text{rg}(M)$. Alors

$$\ker(M) = \text{Vect}\{v_{r+1}, \dots, v_n\},$$

$$\text{Im}(M^\top) = \text{Vect}\{v_1, \dots, v_r\},$$

$$\text{Im}(M) = \text{Vect}\{u_1, \dots, u_r\},$$

et

$$\ker(M^\top) = \text{Vect}\{u_{r+1}, \dots, u_m\}.$$

Preuve. Pour $i \leq r$,

$$Mv_i = \sigma_i u_i \neq 0,$$

tandis que, pour $i > r$,

$$Mv_i = 0.$$

Comme $(v_1, \dots, v_n)$ est une base de $\mathbb{R}^n$, on en déduit

$$\ker(M) = \text{Vect}\{v_{r+1}, \dots, v_n\}.$$

Par ailleurs,

$$\text{Im}(M) = \text{Vect}\{Mv_1, \dots, Mv_n\}.$$

Or

$$Mv_i = \sigma_i u_i \quad \text{pour } i \leq r, \quad Mv_i = 0 \quad \text{pour } i > r.$$

Ainsi,

$$\text{Im}(M) = \text{Vect}\{u_1, \dots, u_r\}.$$

Les deux autres identités s'obtiennent de la même manière en utilisant

$$M^\top u_i = \sigma_i v_i \quad \text{pour } i \leq r,$$

et

$$M^\top u_i = 0 \quad \text{pour } i > r.$$

□

On retrouve ainsi les décompositions orthogonales

$$\mathbb{R}^n = \text{Im}(M^\top) \overset{\perp}{\oplus} \ker(M)$$

et

$$\mathbb{R}^m = \text{Im}(M) \overset{\perp}{\oplus} \ker(M^\top).$$

La SVD ne fournit donc pas uniquement une factorisation matricielle : elle donne simultanément des bases orthonormées adaptées aux quatre sous-espaces fondamentaux associés à M .

2.7 Interprétation géométrique de la SVD

La décomposition

$$M = U\Sigma V^\top$$

permet de décomposer l'action de M en trois transformations élémentaires.

Pour calculer Mx , on écrit

$$Mx = U\Sigma V^\top x.$$

La première transformation,

$$x \longmapsto V^\top x,$$

exprime x dans la base orthonormée des vecteurs singuliers droits. Comme V est orthogonale, cette transformation conserve les longueurs et les angles.

La deuxième transformation,

$$z \longmapsto \Sigma z,$$


multiplie la i -ième coordonnée par σ_i pour $i \leq r$, et annule les coordonnées correspondant aux valeurs singulières nulles. Il s'agit donc d'une dilatation anisotrope, éventuellement accompagnée d'une projection et d'un changement de dimension.

Enfin, la transformation

$$w \longmapsto Uw$$

place le résultat dans la base orthonormée des vecteurs singuliers gauches. Elle conserve également les longueurs et les angles.

On peut donc résumer géométriquement la SVD par le schéma



Plus précisément,

$$v_i \xrightarrow{M} \sigma_i u_i.$$

La direction v_i de l'espace de départ est envoyée sur la direction u_i de l'espace d'arrivée, avec un facteur de dilatation égal à σ_i .

Remarque 2.7.1 (Image de la sphère unité). Considérons la sphère unité de $\mathbb{R}^n$,

$$\mathbb{S}^{n-1} = \{x \in \mathbb{R}^n ; \|x\| = 1\}.$$

Son image par M est un ellipsoïde éventuellement aplati dans $\text{Im}(M)$. Les axes principaux de cet ellipsoïde sont dirigés par

$$u_1, \dots, u_r,$$

et les longueurs de ses demi-axes sont

$$\sigma_1, \dots, \sigma_r.$$

Les valeurs singulières mesurent donc exactement les facteurs de dilatation principaux de l'application linéaire M .

2.8 Décomposition réduite

Lorsque M est de rang $r < \min(m, n)$, les matrices U et V contiennent des vecteurs qui interviennent uniquement pour compléter des bases orthonormées. On peut alors conserver uniquement les vecteurs associés aux valeurs singulières strictement positives.

Posons

$$U_r = \begin{pmatrix} | & & | \\ u_1 & \cdots & u_r \\ | & & | \end{pmatrix} \in \mathcal{M}_{m,r}(\mathbb{R}),$$

$$V_r = \begin{pmatrix} | & & | \\ v_1 & \cdots & v_r \\ | & & | \end{pmatrix} \in \mathcal{M}_{n,r}(\mathbb{R}),$$

et

$$\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r) \in \mathcal{M}_r(\mathbb{R}).$$

On obtient alors

$$M = U_r \Sigma_r V_r^\top.$$

Cette écriture est appelée la *décomposition en valeurs singulières réduite* ou *compacte*. Elle peut également s'écrire sous la forme d'une somme de matrices de rang un :

$$M = \sum_{i=1}^r \sigma_i u_i v_i^\top.$$

En effet,

$$U_r \Sigma_r V_r^\top = \sum_{i=1}^r \sigma_i u_i v_i^\top.$$

Chaque matrice

$$u_i v_i^\top$$

est de rang 1. La SVD décompose donc toute matrice de rang r comme une somme de r transformations élémentaires de rang 1, ordonnées selon l'importance décroissante des coefficients σ_i .

2.9 Normes et valeurs singulières

Les valeurs singulières permettent de quantifier précisément l'amplification produite par M .

Proposition 2.9.1 (Plus grande valeur singulière). Pour toute matrice $M \in \mathcal{M}_{m,n}(\mathbb{R})$,

$$\max_{\|x\|=1} \|Mx\| = \sigma_1.$$

La valeur singulière σ_1 est donc le facteur maximal d'amplification des normes produit par M .

Preuve. Écrivons

$$x = \sum_{i=1}^n \alpha_i v_i, \quad \sum_{i=1}^n \alpha_i^2 = \|x\|^2.$$

Lorsque $\|x\| = 1$, on a

$$\sum_{i=1}^n \alpha_i^2 = 1.$$

Or

$$Mx = \sum_{i=1}^r \alpha_i \sigma_i u_i.$$

Comme les vecteurs u_i sont orthonormés,

$$\|Mx\|^2 = \sum_{i=1}^r \sigma_i^2 \alpha_i^2.$$

Puisque $\sigma_i \leq \sigma_1$,

$$\|Mx\|^2 \leq \sigma_1^2 \sum_{i=1}^r \alpha_i^2 \leq \sigma_1^2.$$

Ainsi,

$$\|Mx\| \leq \sigma_1.$$

Cette borne est atteinte pour $x = v_1$, puisque

$$Mv_1 = \sigma_1 u_1$$

et donc

$$\|Mv_1\| = \sigma_1.$$

□

La norme opératorielle de M , associée à la norme euclidienne, est donc

$$\|M\|_2 = \sup_{x \neq 0} \frac{\|Mx\|}{\|x\|} = \sigma_1.$$

De plus, la norme de Frobenius vérifie

$$\|M\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n M_{ij}^2 = \text{tr}(M^\top M) = \sum_{i=1}^r \sigma_i^2.$$

Ainsi,

$$\boxed{\|M\|_F = \sqrt{\sigma_1^2 + \cdots + \sigma_r^2}}.$$

2.10 Cas d'une matrice carrée inversible

Si $M \in \mathcal{M}_n(\mathbb{R})$ est inversible, alors son rang vaut n et toutes ses valeurs singulières sont strictement positives :

$$\sigma_1 \geq \cdots \geq \sigma_n > 0.$$

La matrice diagonale Σ est alors inversible et

$$M^{-1} = V\Sigma^{-1}U^\top,$$

où

$$\Sigma^{-1} = \text{diag}\left(\frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_n}\right).$$

La plus petite valeur singulière vérifie également

$$\min_{\|x\|=1} \|Mx\| = \sigma_n.$$

Elle mesure donc la contraction maximale produite par M . Lorsque σ_n est très petite, il existe une direction unitaire x telle que Mx soit presque nul. La matrice est alors proche d'être singulière.

Le rapport

$$\kappa_2(M) = \frac{\sigma_1}{\sigma_n}$$

est appelé le *nombre de conditionnement spectral* de M . Un grand nombre de conditionnement indique qu'une petite perturbation des données peut être fortement amplifiée lors de la résolution d'un système linéaire.

2.11 Lien avec les matrices symétriques positives

Si $M \in \mathcal{M}_n(\mathbb{R})$ est elle-même symétrique positive, elle possède une diagonalisation orthogonale

$$M = Q\Lambda Q^\top,$$

avec

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n), \quad \lambda_i \geq 0.$$

Dans ce cas,

$$M^\top M = M^2 = Q\Lambda^2 Q^\top.$$

Les valeurs singulières de M sont alors

$$\sigma_i = \lambda_i.$$

Pour une matrice symétrique générale, dont certaines valeurs propres peuvent être négatives, les valeurs singulières sont les valeurs absolues des valeurs propres :

$$\sigma_i = |\lambda_i|,$$

à un réordonnement près.

La SVD étend donc en un certain sens la diagonalisation orthogonale des matrices symétriques à toutes les matrices réelles. La différence essentielle est que deux bases orthonormées peuvent être nécessaires : une dans l'espace de départ et une dans l'espace d'arrivée.

2.12 Cas complexe

Remarque 2.12.1 (Décomposition en valeurs singulières complexe). Pour une matrice

$$M \in \mathcal{M}_{m,n}(\mathbb{C}),$$

on remplace la transposée $M^\top$ par la transposée conjuguée

$$M^* = \overline{M}^\top.$$

La matrice

$$M^* M$$

est hermitienne positive, car

$$x^* M^* M x = \|Mx\|^2 \geq 0.$$

Le théorème spectral hermitien conduit alors à une factorisation

$$M = U\Sigma V^*,$$

où U et V sont unitaires et où Σ possède des coefficients diagonaux réels positifs ou nuls. La démonstration est identique à celle du cas réel.

Synthèse. La décomposition en valeurs singulières repose sur l'étude spectrale de la matrice

$$M^\top M.$$

Cette matrice est toujours symétrique positive et vérifie

$$x^\top M^\top M x = \|Mx\|^2.$$

Ses vecteurs propres v_i fournissent les directions orthogonales privilégiées dans l'espace de départ. Ses valeurs propres sont les carrés des valeurs singulières :

$$M^\top M v_i = \sigma_i^2 v_i.$$

Les vecteurs correspondants dans l'espace d'arrivée sont définis par

$$u_i = \frac{M v_i}{\sigma_i},$$

de sorte que

$$M v_i = \sigma_i u_i.$$

On obtient finalement

$$M = U \Sigma V^\top.$$

Cette décomposition révèle simultanément :

- les directions principales de l'espace de départ, données par les vecteurs singuliers droits v_i ;
- les directions principales de l'espace d'arrivée, données par les vecteurs singuliers gauches u_i ;
- les facteurs de dilatation associés, donnés par les valeurs singulières σ_i ;
- le rang de la matrice, égal au nombre de valeurs singulières strictement positives ;
- le noyau et l'image de l'application linéaire ;
- les directions dans lesquelles l'application amplifie, contracte ou annule les vecteurs.

La SVD fournit ainsi une description géométrique complète de toute application linéaire entre espaces euclidiens de dimensions finies, y compris lorsque sa matrice est rectangulaire, singulière ou non diagonalisable.

2.13 Pseudo-inverse de Moore–Penrose

La SVD permet de généraliser la notion d'inverse aux matrices rectangulaires ou singulières. Soit

$$M = U \Sigma V^\top \in \mathcal{M}_{m,n}(\mathbb{R})$$

une décomposition en valeurs singulières de rang r , avec

$$\sigma_1 \geq \dots \geq \sigma_r > 0.$$

On définit la matrice $\Sigma^+ \in \mathcal{M}_{n,m}(\mathbb{R})$ en inversant uniquement les valeurs singulières strictement positives :

$$(\Sigma^+)_{ij} = \begin{cases} \frac{1}{\sigma_i}, & \text{si } i = j \leq r, \\ 0, & \text{sinon.} \end{cases}$$

Définition 2.13.1 (Pseudo-inverse de Moore–Penrose). La *pseudo-inverse de Moore–Penrose* de M est la matrice

$$M^+ = V\Sigma^+U^\top \in \mathcal{M}_{n,m}(\mathbb{R}).$$

Dans le cas de la SVD réduite

$$M = U_r \Sigma_r V_r^\top,$$

elle s'écrit plus simplement

$$M^+ = V_r \Sigma_r^{-1} U_r^\top = \sum_{i=1}^r \frac{1}{\sigma_i} v_i u_i^\top.$$

La pseudo-inverse agit comme l'inverse de M sur les directions qui ne sont pas annulées par M . En effet,

$$Mv_i = \sigma_i u_i \quad \implies \quad M^+ u_i = \frac{1}{\sigma_i} v_i, \quad i = 1, \dots, r.$$

En revanche, elle annule les directions appartenant à $\ker(M^\top) = \text{Im}(M)^\perp$.

Proposition 2.13.1 (Caractérisation de Moore–Penrose). La matrice M^+ est l'unique matrice de $\mathcal{M}_{n,m}(\mathbb{R})$ vérifiant les quatre relations

$$MM^+M = M, \quad M^+MM^+ = M^+,$$

$$(MM^+)^\top = MM^+, \quad (M^+M)^\top = M^+M.$$

De plus,

$$MM^+ = U_r U_r^\top$$

est le projecteur orthogonal sur $\text{Im}(M)$, tandis que

$$M^+M = V_r V_r^\top$$

est le projecteur orthogonal sur $\text{Im}(M^\top) = \ker(M)^\perp$.

L'intérêt principal de la pseudo-inverse apparaît dans la résolution d'un système linéaire

$$Mx = b$$

lorsque M n'est pas inversible ou lorsque le système n'admet pas de solution exacte. Le vecteur

$$x^\star = M^+ b$$

minimise l'erreur quadratique :

$$x^\star \in \underset{x \in \mathbb{R}^n}{\text{argmin}} \|Mx - b\|^2.$$

Lorsque ce problème possède plusieurs solutions, M^+b est l'unique solution de norme euclidienne minimale. Ainsi, la pseudo-inverse sélectionne canoniquement, parmi toutes les solutions des moindres carrés, celle qui possède la plus petite norme.

Si M est carrée et inversible, toutes ses valeurs singulières sont strictement positives et

$$M^+ = V\Sigma^{-1}U^\top = M^{-1}.$$

La pseudo-inverse constitue donc une véritable extension de l'inverse usuel.

Remarque 2.13.1 (Sensibilité numérique). Le calcul de M^+ fait intervenir les quantités $1/\sigma_i$. Une très petite valeur singulière peut donc amplifier fortement les perturbations des données. En pratique, on peut remplacer les inverses des valeurs singulières inférieures à un certain seuil par zéro. Cette idée conduit notamment à la pseudo-inverse tronquée et aux méthodes de régularisation utilisées en statistique et en apprentissage.

Projections orthogonales et problèmes des moindres carrés

Les problèmes de moindres carrés occupent une place centrale en statistique, en science des données et en apprentissage automatique. Ils interviennent notamment dans la régression linéaire, l'ajustement de modèles paramétriques, la reconstruction de signaux et de nombreuses méthodes d'optimisation.

Le problème général consiste à résoudre un système linéaire

$$X\beta = y,$$

où

$$X \in \mathcal{M}_{n,p}(\mathbb{R}), \quad \beta \in \mathbb{R}^p, \quad y \in \mathbb{R}^n.$$

En apprentissage statistique, les n lignes de X représentent généralement les observations, tandis que ses p colonnes correspondent aux variables explicatives. Le vecteur y contient les valeurs observées de la variable à prédire et β désigne le vecteur des paramètres du modèle.

Lorsque le système $X\beta = y$ ne possède pas de solution exacte, on cherche un vecteur β tel que $X\beta$ soit aussi proche que possible de y . Cette proximité est mesurée par la norme euclidienne.

3.1 Du système linéaire au problème des moindres carrés

Considérons le modèle linéaire

$$y = X\beta + \varepsilon,$$

où $\varepsilon \in \mathbb{R}^n$ représente l'erreur entre les valeurs observées et celles produites par le modèle. Pour un paramètre β , le vecteur

$$r(\beta) = y - X\beta$$

est appelé le *vecteur des résidus*. Sa i -ième composante vaut

$$r_i(\beta) = y_i - x_i^\top \beta,$$

où $x_i^\top$ désigne la i -ième ligne de X .

La méthode des moindres carrés consiste à choisir β de manière à minimiser la somme des carrés des résidus :

$$\sum_{i=1}^n (y_i - x_i^\top \beta)^2.$$

Or cette quantité est exactement le carré de la norme euclidienne de $y - X\beta$:

$$\|y - X\beta\|^2 = \sum_{i=1}^n (y_i - x_i^\top \beta)^2.$$

Définition 3.1.1 (Problème des moindres carrés). Soient

$$X \in \mathcal{M}_{n,p}(\mathbb{R}) \quad \text{et} \quad y \in \mathbb{R}^n.$$

Le problème des moindres carrés associé à X et y consiste à déterminer

$$\hat{\beta} \in \operatorname{argmin}_{\beta \in \mathbb{R}^p} \|y - X\beta\|^2.$$

Tout vecteur $\hat{\beta}$ réalisant ce minimum est appelé une *solution des moindres carrés*.

Le problème ne demande donc pas nécessairement de résoudre exactement $X\beta = y$. Il demande de trouver, parmi tous les vecteurs de la forme $X\beta$, celui qui est le plus proche de y .

3.2 Interprétation géométrique : projection sur $\operatorname{Im}(X)$

L'ensemble des prédictions que le modèle linéaire peut produire est

$$\{X\beta; \beta \in \mathbb{R}^p\}.$$

Cet ensemble est précisément l'image de l'application linéaire associée à X :

$$\operatorname{Im}(X) = \{X\beta; \beta \in \mathbb{R}^p\} \subset \mathbb{R}^n.$$

Résoudre le problème des moindres carrés revient donc à chercher un vecteur

$$\hat{y} = X\hat{\beta} \in \operatorname{Im}(X)$$

qui minimise la distance à y :

$$\|y - \hat{y}\| = \min_{z \in \operatorname{Im}(X)} \|y - z\|.$$

Le théorème de projection orthogonale assure que ce vecteur existe et qu'il est unique :

$$\hat{y} = p_{\operatorname{Im}(X)}(y).$$

Le résidu optimal

$$\hat{r} = y - X\hat{\beta}$$

est alors orthogonal à $\operatorname{Im}(X)$. Ainsi,

$$\hat{r} \in \operatorname{Im}(X)^\perp.$$

Or, d'après les relations entre image et noyau,

$$\operatorname{Im}(X)^\perp = \ker(X^\top).$$

Par conséquent,

$$X^\top \hat{r} = 0,$$

c'est-à-dire

$$X^\top (y - X\hat{\beta}) = 0.$$

On obtient ainsi les équations fondamentales du problème.

Proposition 3.2.1 (Équations normales). Un vecteur $\hat{\beta} \in \mathbb{R}^p$ est une solution du problème des moindres carrés

$$\min_{\beta \in \mathbb{R}^p} \|y - X\beta\|^2$$

si et seulement s'il vérifie les *équations normales*

$$X^\top X \hat{\beta} = X^\top y.$$

Preuve. Supposons tout d'abord que $\hat{\beta}$ soit une solution des moindres carrés. Le vecteur $X\hat{\beta}$ est alors la projection orthogonale de y sur $\text{Im}(X)$. Par conséquent,

$$y - X\hat{\beta} \perp \text{Im}(X).$$

Les colonnes de X appartenant à $\text{Im}(X)$, le résidu est orthogonal à chacune d'elles. Cette condition s'écrit matriciellement

$$X^\top (y - X\hat{\beta}) = 0,$$

d'où

$$X^\top X \hat{\beta} = X^\top y.$$

Réciproquement, supposons que $\hat{\beta}$ vérifie les équations normales. Alors

$$X^\top (y - X\hat{\beta}) = 0,$$

ce qui signifie que

$$y - X\hat{\beta} \in \ker(X^\top) = \text{Im}(X)^\perp.$$

Ainsi, $X\hat{\beta} \in \text{Im}(X)$ et $y - X\hat{\beta}$ est orthogonal à $\text{Im}(X)$. Le vecteur $X\hat{\beta}$ est donc la projection orthogonale de y sur $\text{Im}(X)$. Par conséquent, $\hat{\beta}$ est une solution des moindres carrés. $\square$

Remarque 3.2.1 (Orthogonalité des résidus). Les équations normales peuvent s'écrire

$$X^\top \hat{r} = 0.$$

Le résidu optimal est donc orthogonal à toutes les colonnes de X . En statistique, cela signifie que les résidus sont orthogonaux aux variables explicatives utilisées dans le modèle.

3.3 Dérivation analytique des équations normales

Les équations normales peuvent également être obtenues en dérivant la fonction objectif

$$L(\beta) = \|y - X\beta\|^2.$$

En développant,

$$\begin{aligned} L(\beta) &= (y - X\beta)^\top (y - X\beta) \\ &= y^\top y - 2\beta^\top X^\top y + \beta^\top X^\top X \beta. \end{aligned}$$

Comme $X^\top X$ est symétrique, le gradient de L est

$$\nabla L(\beta) = -2X^\top y + 2X^\top X \beta.$$

Toute solution minimisant L doit donc vérifier

$$\nabla L(\hat{\beta}) = 0,$$

ce qui donne

$$X^\top X \hat{\beta} = X^\top y.$$

La matrice hessienne de L vaut

$$\nabla^2 L(\beta) = 2X^\top X.$$

Pour tout $z \in \mathbb{R}^p$,

$$z^\top X^\top X z = \|Xz\|^2 \geq 0.$$

La matrice $X^\top X$ est donc symétrique positive, et la fonction L est convexe. Par conséquent, tout point vérifiant les équations normales est bien un minimum global.

Remarque 3.3.1. La fonction L est strictement convexe si et seulement si $X^\top X$ est définie positive. Cette propriété équivaut à

$$\ker(X) = \{0\},$$

c'est-à-dire au fait que les colonnes de X sont linéairement indépendantes. Dans ce cas, la solution des moindres carrés est unique.

3.4 Existence et unicité des solutions

Il faut distinguer l'unicité de la prédiction $X\hat{\beta}$ et celle du paramètre $\hat{\beta}$.

Proposition 3.4.1 (Existence et unicité). Pour toute matrice $X \in \mathcal{M}_{n,p}(\mathbb{R})$ et tout vecteur $y \in \mathbb{R}^n$, le problème

$$\min_{\beta \in \mathbb{R}^p} \|y - X\beta\|^2$$

admet au moins une solution.

Le vecteur ajusté

$$\hat{y} = X\hat{\beta}$$

est toujours unique. En revanche, le paramètre $\hat{\beta}$ est unique si et seulement si

$$\ker(X) = \{0\},$$

c'est-à-dire si et seulement si X est de rang colonne plein :

$$\text{rg}(X) = p.$$

Preuve. L'espace $\text{Im}(X)$ est un sous-espace vectoriel de $\mathbb{R}^n$. Il est donc fermé. Le théorème de projection orthogonale assure l'existence d'un unique vecteur

$$\hat{y} = p_{\text{Im}(X)}(y)$$

minimisant la distance à y .

Puisque $\hat{y} \in \text{Im}(X)$, il existe au moins un vecteur $\hat{\beta} \in \mathbb{R}^p$ tel que

$$X\hat{\beta} = \hat{y}.$$

Le problème des moindres carrés admet donc toujours une solution.

Supposons maintenant que $\ker(X) = \{0\}$. Si $\hat{\beta}_1$ et $\hat{\beta}_2$ sont deux solutions, l'unicité de la projection donne

$$X\hat{\beta}_1 = X\hat{\beta}_2.$$

Par conséquent,

$$X(\hat{\beta}_1 - \hat{\beta}_2) = 0.$$

Comme $\ker(X) = \{0\}$, il vient

$$\hat{\beta}_1 = \hat{\beta}_2.$$

Réciproquement, supposons que $\ker(X) \neq \{0\}$. Il existe alors $h \neq 0$ tel que $Xh = 0$. Si $\hat{\beta}$ est une solution, alors

$$X(\hat{\beta} + h) = X\hat{\beta} + Xh = X\hat{\beta}.$$

Les vecteurs $\hat{\beta}$ et $\hat{\beta} + h$ produisent donc la même prédiction et la même erreur quadratique. La solution en β n'est pas unique. $\square$

3.5 Cas de rang colonne plein

Supposons que les colonnes de X soient linéairement indépendantes. On a alors

$$\text{rg}(X) = p.$$

Dans ce cas, $X^\top X$ est définie positive. En effet, pour tout $z \in \mathbb{R}^p \setminus \{0\}$,

$$z^\top X^\top X z = \|Xz\|^2.$$

Comme $\ker(X) = \{0\}$, on a $Xz \neq 0$, donc

$$z^\top X^\top X z > 0.$$

La matrice $X^\top X$ est donc inversible.

Théorème 3.5.1 (Estimateur des moindres carrés ordinaires). *Si $X \in \mathcal{M}_{n,p}(\mathbb{R})$ est de rang colonne plein, alors le problème*

$$\min_{\beta \in \mathbb{R}^p} \|y - X\beta\|^2$$

possède une unique solution donnée par

$$\hat{\beta} = (X^\top X)^{-1} X^\top y.$$

Le vecteur des valeurs ajustées est

$$\hat{y} = X\hat{\beta} = X(X^\top X)^{-1} X^\top y.$$

La matrice

$$P_X = X(X^\top X)^{-1} X^\top$$

est la matrice du projecteur orthogonal sur $\text{Im}(X)$. Elle vérifie

$$P_X^\top = P_X \quad \text{et} \quad P_X^2 = P_X.$$

Ainsi,

$$\hat{y} = P_X y.$$

La matrice

$$I_n - P_X$$

est le projecteur orthogonal sur

$$\text{Im}(X)^\perp = \ker(X^\top).$$

Le résidu s'écrit donc

$$\hat{r} = y - \hat{y} = (I_n - P_X)y.$$

On obtient la décomposition orthogonale

$$y = \hat{y} + \hat{r}, \quad \hat{y} \perp \hat{r}.$$

Le théorème de Pythagore donne alors

$$\|y\|^2 = \|\hat{y}\|^2 + \|\hat{r}\|^2.$$

3.6 Résolution par SVD

La formule

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

est valable lorsque X est de rang colonne plein. La SVD permet d'en donner une interprétation précise et de traiter également le cas où X est de rang déficient.

Soit

$$X = U_r \Sigma_r V_r^\top$$

la décomposition en valeurs singulières réduite de X , où

$$r = \text{rg}(X),$$

$$U_r = \begin{pmatrix} | & & | \\ u_1 & \cdots & u_r \\ | & & | \end{pmatrix}, \quad V_r = \begin{pmatrix} | & & | \\ v_1 & \cdots & v_r \\ | & & | \end{pmatrix},$$

et

$$\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r), \quad \sigma_1 \geq \dots \geq \sigma_r > 0.$$

Le vecteur y se décompose orthogonalement sous la forme

$$y = \sum_{i=1}^r \langle y, u_i \rangle u_i + y_\perp,$$

où

$$y_{\perp} \in \text{Im}(X)^{\perp}.$$

Comme

$$\text{Im}(X) = \text{Vect}\{u_1, \dots, u_r\},$$

la projection orthogonale de y sur $\text{Im}(X)$ est

$$\hat{y} = \sum_{i=1}^r \langle y, u_i \rangle u_i = U_r U_r^{\top} y.$$

Cherchons maintenant un paramètre $\hat{\beta}$ tel que

$$X\hat{\beta} = \hat{y}.$$

En posant

$$\hat{\beta} = \sum_{i=1}^r a_i v_i,$$

on obtient

$$X\hat{\beta} = \sum_{i=1}^r a_i X v_i = \sum_{i=1}^r a_i \sigma_i u_i.$$

Pour que ce vecteur soit égal à

$$\hat{y} = \sum_{i=1}^r \langle y, u_i \rangle u_i,$$

il suffit de choisir

$$a_i = \frac{\langle y, u_i \rangle}{\sigma_i}.$$

On obtient donc

$$\hat{\beta} = \sum_{i=1}^r \frac{\langle y, u_i \rangle}{\sigma_i} v_i.$$

Cette expression s'écrit matriciellement

$$\hat{\beta} = V_r \Sigma_r^{-1} U_r^{\top} y.$$

Or

$$X^+ = V_r \Sigma_r^{-1} U_r^{\top}$$

est la pseudo-inverse de Moore–Penrose de X .

Théorème 3.6.1 (Solution canonique par pseudo-inverse). *Pour toute matrice $X \in \mathcal{M}_{n,p}(\mathbb{R})$ et tout $y \in \mathbb{R}^n$, le vecteur*

$$\hat{\beta} = X^+ y$$

est une solution du problème des moindres carrés

$$\min_{\beta \in \mathbb{R}^p} \|y - X\beta\|^2.$$

Parmi toutes les solutions des moindres carrés, $X^+ y$ est l'unique solution de norme euclidienne minimale.

Preuve. D'après la SVD réduite,

$$XX^+ = U_r \Sigma_r V_r^\top V_r \Sigma_r^{-1} U_r^\top = U_r U_r^\top.$$

La matrice $U_r U_r^\top$ est le projecteur orthogonal sur $\text{Im}(X)$. Par conséquent,

$$X\hat{\beta} = XX^+y = U_r U_r^\top y = p_{\text{Im}(X)}(y).$$

Le vecteur $\hat{\beta} = X^+y$ est donc une solution des moindres carrés.

Décrivons maintenant toutes les solutions. Si $\tilde{\beta}$ est une autre solution, alors les deux vecteurs $X\tilde{\beta}$ et $X\hat{\beta}$ sont égaux à la projection de y sur $\text{Im}(X)$. Ainsi,

$$X(\tilde{\beta} - \hat{\beta}) = 0.$$

Il existe donc $h \in \ker(X)$ tel que

$$\tilde{\beta} = \hat{\beta} + h.$$

Or

$$\hat{\beta} = V_r \Sigma_r^{-1} U_r^\top y \in \text{Vect}\{v_1, \dots, v_r\} = \ker(X)^\perp.$$

Ainsi,

$$\hat{\beta} \perp h.$$

Le théorème de Pythagore donne

$$\|\tilde{\beta}\|^2 = \|\hat{\beta} + h\|^2 = \|\hat{\beta}\|^2 + \|h\|^2 \geq \|\hat{\beta}\|^2.$$

L'égalité a lieu si et seulement si $h = 0$. Le vecteur X^+y est donc l'unique solution des moindres carrés de norme minimale. $\square$

Remarque 3.6.1 (Ensemble de toutes les solutions). Toutes les solutions du problème des moindres carrés sont de la forme

$$\hat{\beta} = X^+y + h, \quad h \in \ker(X).$$

De manière équivalente,

$$\hat{\beta} = X^+y + (I_p - X^+X)z, \quad z \in \mathbb{R}^p,$$

car $I_p - X^+X$ est le projecteur orthogonal sur $\ker(X)$.

3.7 Lien entre la formule classique et la pseudo-inverse

Lorsque X est de rang colonne plein, on a $r = p$. La SVD réduite s'écrit

$$X = U_p \Sigma_p V^\top,$$

où $V \in \mathcal{M}_p(\mathbb{R})$ est orthogonale. On obtient

$$X^\top X = V \Sigma_p^2 V^\top,$$

puis

$$(X^\top X)^{-1} = V \Sigma_p^{-2} V^\top.$$

Par conséquent,

$$\begin{aligned}
(X^\top X)^{-1} X^\top &= V \Sigma_p^{-2} V^\top V \Sigma_p U_p^\top \\
&= V \Sigma_p^{-1} U_p^\top \\
&= X^+.
\end{aligned}$$

Ainsi,

$$X^+ = (X^\top X)^{-1} X^\top$$

lorsque X est de rang colonne plein. La formule classique des moindres carrés

$$\hat{\beta} = (X^\top X)^{-1} X^\top y$$

est donc un cas particulier de la formule générale

$$\hat{\beta} = X^+ y.$$

De même, si X est de rang ligne plein, alors

$$X^+ = X^\top (X X^\top)^{-1}.$$

3.8 Application à la régression linéaire

Considérons un jeu de données constitué de n observations et de p variables explicatives. Pour chaque observation i , on dispose d'un vecteur

$$x_i = \begin{pmatrix} x_{i1} \\ \vdots \\ x_{ip} \end{pmatrix} \in \mathbb{R}^p$$

et d'une réponse $y_i \in \mathbb{R}$.

Le modèle de régression linéaire suppose que

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i.$$

Pour intégrer l'ordonnée à l'origine β_0 , on introduit une première colonne composée uniquement de 1. La matrice de conception est alors

$$X = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix} \in \mathcal{M}_{n,p+1}(\mathbb{R}),$$

et le vecteur des paramètres est

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}.$$

Le modèle s'écrit alors

$$y = X\beta + \varepsilon.$$

L'estimateur des moindres carrés est défini par

$$\hat{\beta} \in \operatorname{argmin}_{\beta \in \mathbb{R}^{p+1}} \|y - X\beta\|^2.$$

Si les colonnes de X sont linéairement indépendantes, alors

$$\hat{\beta} = (X^\top X)^{-1} X^\top y.$$

Sinon, la solution canonique est

$$\hat{\beta} = X^+ y.$$

Pour une nouvelle observation

$$x_{\text{new}} = \begin{pmatrix} 1 \\ x_{\text{new},1} \\ \vdots \\ x_{\text{new},p} \end{pmatrix},$$

la prédiction du modèle est

$$\hat{y}_{\text{new}} = x_{\text{new}}^\top \hat{\beta}.$$

Remarque 3.8.1 (Présence d'une constante). Lorsque la première colonne de X est le vecteur

$$\mathbf{1}_n = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix},$$

les équations normales impliquent

$$\mathbf{1}_n^\top \hat{r} = 0.$$

Par conséquent,

$$\sum_{i=1}^n \hat{r}_i = 0.$$

Dans un modèle de régression comprenant une constante, la moyenne empirique des résidus est donc nulle.

3.9 Multicolinéarité et valeurs singulières

La SVD permet de comprendre les difficultés rencontrées lorsque certaines variables explicatives sont fortement corrélées.

Supposons que X soit de rang colonne plein et écrivons

$$X = U_p \Sigma_p V^\top.$$

L'estimateur des moindres carrés vaut alors

$$\hat{\beta} = V \Sigma_p^{-1} U_p^\top y = \sum_{i=1}^p \frac{\langle y, u_i \rangle}{\sigma_i} v_i.$$

Chaque composante de y selon la direction u_i est divisée par la valeur singulière σ_i . Si une valeur singulière est très petite, alors le facteur

$$\frac{1}{\sigma_i}$$

est très grand. Une faible perturbation de y peut alors entraîner une variation importante de $\hat{\beta}$.

Lorsque certaines colonnes de X sont presque linéairement dépendantes, la plus petite valeur singulière σ_p est proche de zéro. La matrice $X^\top X$ est alors proche d'être singulière, puisque ses valeurs propres sont

$$\sigma_1^2, \dots, \sigma_p^2.$$

Son nombre de conditionnement spectral vaut

$$\kappa_2(X^\top X) = \frac{\sigma_1^2}{\sigma_p^2} = \kappa_2(X)^2.$$

Ainsi, former les équations normales remplace le nombre de conditionnement de X par son carré. Cette opération peut donc accentuer fortement les erreurs numériques.

Remarque 3.9.1 (Calcul numérique). En pratique, on évite généralement de calculer explicitement

$$(X^\top X)^{-1}.$$

La solution est plutôt obtenue à l'aide d'une factorisation QR ou d'une SVD. La factorisation QR est efficace lorsque X est de rang colonne plein, tandis que la SVD est particulièrement utile pour détecter les problèmes de rang et traiter les matrices mal conditionnées.

3.10 Régularisation et régression ridge

Lorsque certaines valeurs singulières sont très petites, l'estimateur des moindres carrés peut devenir instable. Une solution consiste à pénaliser les paramètres de grande norme.

La régression ridge résout le problème

$$\hat{\beta}_\lambda = \operatorname{argmin}_{\beta \in \mathbb{R}^p} \left\{ \|y - X\beta\|^2 + \lambda \|\beta\|^2 \right\}, \quad \lambda > 0.$$

La condition d'optimalité donne

$$(X^\top X + \lambda I_p) \hat{\beta}_\lambda = X^\top y.$$

Comme $X^\top X + \lambda I_p$ est définie positive, elle est toujours inversible. On obtient

$$\hat{\beta}_\lambda = (X^\top X + \lambda I_p)^{-1} X^\top y.$$

À l'aide de la SVD réduite $X = U_r \Sigma_r V_r^\top$, cette expression devient

$$\hat{\beta}_\lambda = \sum_{i=1}^r \frac{\sigma_i}{\sigma_i^2 + \lambda} \langle y, u_i \rangle v_i.$$

Pour les moindres carrés ordinaires, le coefficient associé à la direction singulière i est

$$\frac{1}{\sigma_i}.$$

Pour la régression ridge, il devient

$$\frac{\sigma_i}{\sigma_i^2 + \lambda}.$$

Lorsque σ_i est petite, ce second coefficient reste contrôlé. La régularisation ridge réduit donc l'influence des directions mal identifiées par les données.

3.11 Exemple élémentaire

Considérons

$$X = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix} \quad \text{et} \quad y = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}.$$

On cherche la droite affine

$$\hat{y}_i = \beta_0 + \beta_1 x_i$$

qui ajuste au mieux les trois observations

$$(0, 1), \quad (1, 2), \quad (2, 2).$$

On calcule

$$X^\top X = \begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix}$$

et

$$X^\top y = \begin{pmatrix} 5 \\ 6 \end{pmatrix}.$$

Les équations normales sont donc

$$\begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} = \begin{pmatrix} 5 \\ 6 \end{pmatrix}.$$

Comme

$$\det(X^\top X) = 15 - 9 = 6 \neq 0,$$

la solution est unique. On obtient

$$\hat{\beta}_0 = \frac{7}{6}, \quad \hat{\beta}_1 = \frac{1}{2}.$$

La droite ajustée est donc

$$\hat{y} = \frac{7}{6} + \frac{1}{2}x.$$

Le vecteur des valeurs ajustées vaut

$$X\hat{\beta} = \begin{pmatrix} \frac{7}{6} \\ \frac{5}{3} \\ \frac{13}{6} \end{pmatrix},$$

et le vecteur des résidus est

$$\hat{r} = y - X\hat{\beta} = \begin{pmatrix} -\frac{1}{6} \\ \frac{1}{3} \\ -\frac{1}{6} \end{pmatrix}.$$

On vérifie bien que

$$X^\top \hat{r} = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{pmatrix} \begin{pmatrix} -\frac{1}{6} \\ \frac{1}{3} \\ -\frac{1}{6} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

Le résidu est donc orthogonal aux deux colonnes de X , conformément aux équations normales.

Synthèse. Le problème des moindres carrés

$$\min_{\beta \in \mathbb{R}^p} \|y - X\beta\|^2$$

possède une interprétation géométrique simple : il consiste à projeter orthogonalement y sur l'espace des prédictions accessibles

$$\text{Im}(X).$$

Le vecteur ajusté est toujours unique :

$$\hat{y} = p_{\text{Im}(X)}(y).$$

Le résidu optimal vérifie

$$y - \hat{y} \perp \text{Im}(X),$$

ce qui conduit aux équations normales

$$X^\top X \hat{\beta} = X^\top y.$$

Lorsque X est de rang colonne plein, la solution est unique et vaut

$$\hat{\beta} = (X^\top X)^{-1} X^\top y.$$

Dans le cas général, la pseudo-inverse fournit la solution canonique

$$\hat{\beta} = X^+ y,$$

qui est l'unique solution des moindres carrés de norme minimale.

Enfin, la SVD révèle directement les directions responsables de l'instabilité numérique :

$$\hat{\beta} = \sum_{i=1}^r \frac{\langle y, u_i \rangle}{\sigma_i} v_i.$$

Les petites valeurs singulières amplifient les perturbations et signalent des dépendances linéaires ou presque linéaires entre les variables explicatives. Cette observation motive l'utilisation de méthodes numériques fondées sur la SVD ainsi que des techniques de régularisation telles que la régression ridge.

Perron–Frobenius et systèmes dynamiques

Le théorème de Perron–Frobenius décrit le comportement spectral des matrices dont les coefficients sont positifs. Il permet notamment de comprendre l'évolution à long terme de nombreux systèmes dynamiques : répartition d'une population, chaînes de Markov, modèles démographiques, diffusion d'une opinion ou évolution du nombre de fumeurs dans plusieurs catégories.

4.1 Matrices stochastiques et systèmes dynamiques

Considérons une population répartie entre n états. On note

$$v(t) = \begin{pmatrix} v_1(t) \\ \vdots \\ v_n(t) \end{pmatrix} \in \mathbb{R}^n$$

le vecteur décrivant la répartition de la population à l'instant t , où $v_i(t)$ représente la proportion d'individus dans l'état i . On a donc

$$v_i(t) \geq 0 \quad \text{et} \quad \sum_{i=1}^n v_i(t) = 1.$$

Supposons que les transitions entre les états soient décrites par une matrice

$$M = (m_{ij}) \in \mathcal{M}_n(\mathbb{R}),$$

où m_{ij} représente la proportion des individus présents dans l'état j qui se trouvent dans l'état i à l'instant suivant. Le système dynamique s'écrit alors

$$v(t+1) = Mv(t).$$

Par récurrence,

$$v(t) = M^t v(0).$$

Définition 4.1.1 (Matrice stochastique par colonnes). Une matrice $M = (m_{ij}) \in \mathcal{M}_n(\mathbb{R})$ est dite *stochastique par colonnes* lorsque $m_{ij} \geq 0$ pour tous i, j , et lorsque la somme des coefficients de chaque colonne vaut 1 :

$$\forall j \in \{1, \dots, n\}, \quad \sum_{i=1}^n m_{ij} = 1.$$

En notant

$$\mathbf{1}_n = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix},$$

la condition précédente s'écrit

$$\mathbf{1}_n^\top M = \mathbf{1}_n^\top.$$

Elle assure la conservation de la somme des composantes :

$$\mathbf{1}_n^\top v(t+1) = \mathbf{1}_n^\top Mv(t) = \mathbf{1}_n^\top v(t).$$

Ainsi, si les composantes de $v(0)$ sont positives ou nulles et de somme 1, il en est de même pour tous les vecteurs $v(t)$.

4.2 Théorème de Perron–Frobenius

Théorème 4.2.1 (Perron–Frobenius, cas strictement positif). *Soit $M \in \mathcal{M}_n(\mathbb{R})$ une matrice stochastique par colonnes dont tous les coefficients sont strictement positifs. Alors :*

- ▷ 1 est une valeur propre de M ;
- ▷ cette valeur propre est simple;
- ▷ il existe un vecteur propre v_∞ associé à 1, dont toutes les composantes sont strictement positives;
- ▷ ce vecteur peut être normalisé de manière unique par la condition $\mathbf{1}_n^\top v_\infty = 1$;
- ▷ toutes les autres valeurs propres λ de M vérifient $|\lambda| < 1$;
- ▷ pour tout vecteur initial $v(0) \in \mathbb{R}^n$,

$$M^t v(0) \xrightarrow[t \rightarrow +\infty]{} (\mathbf{1}_n^\top v(0)) v_\infty.$$

Justification de l'existence de la valeur propre 1. La partie profonde du théorème, portant sur la simplicité, la positivité et la convergence, est admise ici. Montrons pourquoi 1 apparaît nécessairement comme valeur propre. Puisque M est stochastique par colonnes,

$$\mathbf{1}_n^\top M = \mathbf{1}_n^\top.$$

En transposant, on obtient

$$M^\top \mathbf{1}_n = \mathbf{1}_n.$$

Ainsi, 1 est une valeur propre de $M^\top$. Or une matrice et sa transposée ont le même polynôme caractéristique :

$$\det(M^\top - \lambda I_n) = \det((M - \lambda I_n)^\top) = \det(M - \lambda I_n).$$

Elles possèdent donc les mêmes valeurs propres. Par conséquent, 1 est aussi une valeur propre de M . Les autres assertions sont précisément celles qu'apporte le théorème de Perron–Frobenius dans le cas strictement positif. $\square$

Remarque 4.2.1. Le vecteur v_∞ n'est pas nécessairement un vecteur unitaire pour la norme euclidienne. Il est normalisé de façon que ses composantes aient pour somme 1. Il représente ainsi une répartition de probabilité.

Lorsque $v(0)$ décrit une répartition initiale de la population, on a

$$\mathbf{1}_n^\top v(0) = 1.$$

Le théorème donne alors la convergence particulièrement simple

$$v(t) = M^t v(0) \xrightarrow[t \rightarrow +\infty]{} v_\infty.$$

De manière équivalente,

$$M^t \xrightarrow[t \rightarrow +\infty]{} v_\infty \mathbf{1}_n^\top.$$

La matrice limite est de rang 1 : toutes ses colonnes sont égales à v_∞ . À long terme, le système perd donc la mémoire de sa répartition initiale.

4.3 Interprétation spectrale de la convergence

Le vecteur v_∞ vérifie

$$M v_\infty = v_\infty.$$

Il s'agit donc d'un *état stationnaire* : si le système atteint cette répartition, il la conserve à tous les instants suivants.

La convergence s'explique par le comportement des valeurs propres de M . La composante portée par la direction propre associée à 1 reste inchangée, car

$$1^t = 1.$$

En revanche, les composantes associées aux autres valeurs propres disparaissent asymptotiquement puisque

$$|\lambda| < 1 \quad \implies \quad \lambda^t \longrightarrow 0.$$

Ainsi, seule subsiste à long terme la direction propre associée à la valeur propre 1.

Dans le cas où M est diagonalisable, on peut schématiquement écrire

$$v(0) = a_1 v_\infty + a_2 v_2 + \cdots + a_n v_n,$$

puis

$$M^t v(0) = a_1 v_\infty + a_2 \lambda_2^t v_2 + \cdots + a_n \lambda_n^t v_n.$$

Comme $|\lambda_i| < 1$ pour $i \geq 2$, il vient

$$M^t v(0) \longrightarrow a_1 v_\infty.$$

Pour un vecteur de proportions, la conservation de la somme impose $a_1 = 1$. Dans le cas non diagonalisable, les blocs de Jordan associés aux valeurs propres de module strictement inférieur à 1 produisent des termes de la forme $t^k \lambda^t$, qui convergent eux aussi vers 0. Le même mécanisme spectral explique donc la convergence générale.

4.4 Application : généralisation du modèle des fumeurs de Morioh

On peut répartir la population de Morioh entre n catégories, par exemple selon le comportement tabagique :

$$v(t) = \begin{pmatrix} v_1(t) \\ v_2(t) \\ \vdots \\ v_n(t) \end{pmatrix},$$

où les composantes peuvent représenter les proportions de non-fumeurs, de fumeurs occasionnels, de fumeurs réguliers, d'anciens fumeurs, ou toute autre classification pertinente.

La matrice de transition prend la forme

$$M = \begin{pmatrix} m_{11} & m_{12} & \cdots & m_{1n} \\ m_{21} & m_{22} & \cdots & m_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ m_{n1} & m_{n2} & \cdots & m_{nn} \end{pmatrix},$$

où m_{ij} est la proportion des individus de la catégorie j qui appartiendront à la catégorie i à la période suivante. Puisque chaque individu doit se retrouver dans l'une des catégories,

$$\sum_{i=1}^n m_{ij} = 1$$

pour toute catégorie initiale j . La matrice M est donc stochastique par colonnes.

Si toutes les transitions sont possibles avec une probabilité strictement positive, alors le théorème de Perron–Frobenius s'applique. Il existe une unique répartition stationnaire

$$v_\infty = \begin{pmatrix} v_{\infty,1} \\ \vdots \\ v_{\infty,n} \end{pmatrix}, \quad Mv_\infty = v_\infty,$$

telle que

$$v_{\infty,i} > 0 \quad \text{et} \quad \sum_{i=1}^n v_{\infty,i} = 1.$$

Quelle que soit la répartition initiale $v(0)$, on obtient alors

$$v(t) = M^t v(0) \xrightarrow[t \rightarrow +\infty]{} v_\infty.$$

Pour déterminer concrètement cette répartition limite, il suffit donc de résoudre le système

$$Mv_\infty = v_\infty,$$

c'est-à-dire

$$(M - I_n)v_\infty = 0,$$

auquel on ajoute la condition de normalisation

$$\mathbf{1}_n^\top v_\infty = 1.$$

Remarque 4.4.1 (Interprétation). Le théorème ne signifie pas que les individus cessent de changer de catégorie. Il signifie que les flux entre les différentes catégories finissent par s'équilibrer : la répartition globale de la population devient stable.

Remarque 4.4.2 (Rôle de la stricte positivité). L'hypothèse $m_{ij} > 0$ garantit ici l'unicité de la répartition stationnaire et la convergence vers celle-ci. Pour une matrice seulement positive ou nulle, la valeur propre 1 existe toujours, mais la convergence peut échouer. Le système peut notamment posséder plusieurs états stationnaires ou présenter un comportement périodique.

En résumé, l'étude asymptotique du système dynamique

$$v(t+1) = Mv(t)$$

se ramène à l'étude spectrale de M . La valeur propre dominante 1 détermine l'état stationnaire, tandis que les autres valeurs propres, de module strictement inférieur à 1, décrivent la disparition progressive de l'influence de l'état initial.

Conclusion générale

Les quatre chapitres reposent sur une même stratégie : représenter un problème par une application linéaire, puis choisir des bases dans lesquelles son action devient plus lisible. Pour une matrice symétrique, le théorème spectral fournit une base orthonormée de vecteurs propres. Pour une matrice rectangulaire, la SVD remplit un rôle analogue en faisant apparaître deux bases orthonormées et des facteurs de dilatation positifs. Dans les deux cas, une transformation initialement couplée se décompose en directions élémentaires indépendantes.

Cette idée donne une lecture cohérente des méthodes étudiées. En ACP, les vecteurs propres de la covariance définissent les directions de variance maximale, et les valeurs propres quantifient la variabilité portée par chacune d'elles. Dans les moindres carrés, l'image de la matrice de conception est l'espace des prédictions accessibles ; estimer le modèle revient à y projeter orthogonalement le vecteur des réponses. La pseudo-inverse sélectionne une solution canonique lorsque les paramètres ne sont pas identifiables, tandis que les petites valeurs singulières révèlent l'instabilité numérique et motivent la régularisation. Enfin, pour un système dynamique positif, les valeurs propres séparent le mode stationnaire des modes transitoires et expliquent la perte progressive de l'influence de l'état initial.

Ces résultats montrent également que les choix de modélisation ont une portée géométrique. Centrer ou standardiser les variables modifie la matrice étudiée ; choisir une norme détermine la notion de proximité ; tronquer des valeurs singulières ou ajouter une pénalisation ridge réduit l'influence de directions mal déterminées. Une méthode linéaire ne doit donc pas être comprise comme une simple formule, mais comme l'association d'un espace, d'une géométrie et d'une transformation.

L'algèbre linéaire fournit ainsi un socle commun à la réduction de dimension, à la régression, à l'analyse numérique et à l'étude des dynamiques discrètes. La compétence centrale à retenir est la suivante : avant tout calcul, il faut identifier les espaces de départ et d'arrivée, le noyau et l'image, la métrique utilisée, puis les directions spectrales qui concentrent l'action de la matrice. Cette lecture structurelle permet à la fois de justifier les algorithmes, d'en interpréter les résultats et d'en reconnaître les limites.