Projet – Online Learning

Prévision séquentielle, décision sous incertitude et intervalles de confiance

Paul Minchella Groupes de 3 ou 4 étudiants Année 2026/2027

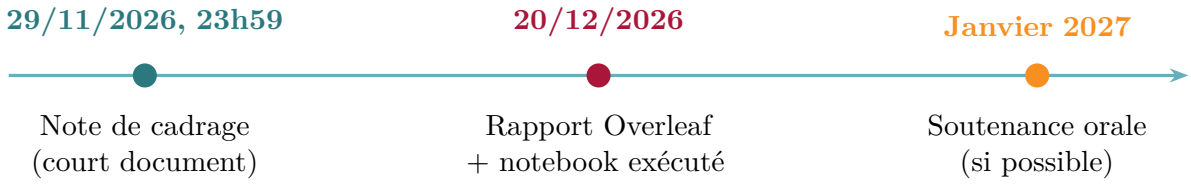
Modalités du projet

- ▷ Groupe de **3 ou 4** étudiants.
- ▷ Rédaction **en anglais ou en français**.
- ▷ Choix du thème à communiquer avant le **29/11/2026, 23h59**.
- ▷ Rendu final avant le **20/12/2026**, à envoyer à mon mail `paul.minchella@univ-lyon2.fr`.
- ▷ Nom de fichier clair, du type `nom1_nom2_nom3.pdf`.
- ▷ Livrables principaux : un **rapport rédigé** et un **notebook** exécuté (ou **code illustratif**, lien **GitHub**, page HTML, ou tout autre format équivalent).

1. Objectif

Chaque groupe choisit un **jeu de données public** (série temporelle ou panel de séries) et met en œuvre une chaîne complète d'**apprentissage en ligne** : les données arrivent une par une, le modèle prédit $\hat{y}_t$ *avant* d'observer y_t, subit une perte $\ell_t(\hat{y}_t, y_t)$, puis se met à jour. L'objectif est de **comparer au moins trois méthodes online**, de **quantifier l'incertitude** de cette comparaison par **bootstrap empirique** sur les métriques finales et, en bonus, de construire des **intervalles de prévision conformes en ligne** (ACI https://arxiv.org/abs/2208.08401).

2. Calendrier et livrables



2.1 Étape 1 – Note de cadrage (au plus tard le 29/11/2026, 23h59)

Un document **court et concis** (Word, Overleaf, . . ., 1 à 2 pages) qui présente :

- ▷ le **dataset** retenu : source, période, fréquence, variable cible, covariables éventuelles ;
- ▷ quelques **statistiques descriptives** : tendance, saisonnalités, valeurs manquantes, zéros, ruptures, distribution de la cible, *summary* usuel sur les variables du dataset, . . . ;
- ▷ les **modèles à tester** et la **tâche** précise (horizon, granularité, quantile visé τ s'il y a lieu) ;
- ▷ le protocole d'**évaluation** (métriques, période de test) et les **interprétations** attendues.

2.2 Étape 2 – Rapport final (au plus tard le 20/12/2026)

Un **rapport rédigé sur Overleaf** accompagné d'un **notebook exécuté proprement** (ou dépôt GitHub, page HTML, ou tout autre livrable équivalent de votre choix), reproductible de bout en bout.

2.3 Étape 3 – Soutenance (si possible courant janvier)

Passage à l'oral par groupe de 3 ou 4 étudiants : présentation des résultats et échange de questions.

3. Plan conseillé du rapport

1. **Introduction et motivation** : pourquoi ce problème, pourquoi un cadre *online* ?
2. **Présentation du dataset et de la tâche** : description, prétraitements, protocole séquentiel.
3. **Apprentissage d'au moins 3 méthodes online** parmi : FTL, FTRL, OGD, OGD régressive, OGD régressive pénalisée, Newsvendor (OGD sur la perte pinball).
   Bonus : d'autres modèles (Trend-Season, ARMA, SARIMA, boosting, réseaux de neurones, ...).
4. **Métriques et interprétations** : comparaison des modèles, regret, analyse des erreurs dans le temps.
5. **Intervalles de confiance empiriques** (bootstrap) sur la ou les métrique(s) retenue(s).
6. Bonus : **intervalles de prévision conformes par ACI**.
7. **Conclusions, intérêts et limites**.

Rappel des méthodes

Méthode	Mise à jour
FTL	$x_{t+1} = \arg\min_{x\in\mathcal{K}} \sum_{s=1}^{t} \ell_s(x)$
FTRL	$x_{t+1} = \arg\min_{x\in\mathcal{K}} \left\{ \sum_{s=1}^{t} \ell_s(x) + \frac{1}{\eta} R(x) \right\}$
OGD	$x_{t+1} = \Pi_{\mathcal{K}}(x_t - \eta_t \nabla \ell_t(x_t))$
OGD régressive	$\hat{y}_t = \theta_t^\top z_t, \quad \theta_{t+1} = \theta_t - \eta_t(\hat{y}_t - y_t)\, z_t$
OGD pénalisée	$\theta_{t+1} = \theta_t - \eta_t \left[(\hat{y}_t - y_t)\, z_t + \lambda \theta_t\right]$ (ridge ; ou pas proximal ℓ_1)
Newsvendor	$q_{t+1} = q_t - \eta_t \left(\mathbf{1}\{y_t < q_t\} - \tau\right), \quad \tau = \frac{c_b}{c_h + c_b}$

Remarque. Une méthode de référence naïve (ou *baseline*, comme la dernière valeur, ou naïve saisonnière $\hat{y}_t = y_{t-s}$) est fortement recommandée : elle donne l'échelle à partir de laquelle une méthode "apprend" réellement quelque chose.

4. Évaluation : métriques et bootstrap empirique

4.1 Métriques

Sur la période de test $t = 1, \dots, T$, chaque modèle m produit une suite de pertes $e_t^{(m)}$. Selon la tâche :

- ▷ **précision ponctuelle** : MAE $= \frac{1}{T}\sum_t |y_t - \hat{y}_t|$, RMSE, MASE ;
- ▷ **quantile / décision** : perte pinball $\rho_\tau(y_t - q_t)$ et coût newsvendor $c_h(q_t - y_t)_+ + c_b(y_t - q_t)_+$, taux de rupture $\frac{1}{T}\sum_t \mathbf{1}\{y_t > q_t\}$;
- ▷ **regret cumulé** : $\mathrm{Reg}_T = \sum_{t=1}^T \ell_t(x_t) - \min_{x \in \mathcal{K}} \sum_{t=1}^T \ell_t(x)$.

4.2 Bootstrap empirique sur le barchart final

Attendu

Le **barchart final** comparant les modèles doit afficher, pour chaque barre, un **intervalle de confiance bootstrap** à $1 - \alpha$ (par ex. 95 %) sur la métrique représentée. Précisez sur quelle(s) métrique(s) vous le calculez et pourquoi.

Les pertes $e_t^{(m)}$ étant **temporellement dépendantes**, on rééchantillonne par **blocs** (bootstrap par blocs circulaires) plutôt que point par point :

1. choisir une longueur de bloc L (ordre de grandeur : $L \approx T^{1/3}$, ou la période saisonnière) ;
2. pour $b = 1, \dots, B$ (par ex. $B = 1000$) : tirer uniformément des débuts de blocs, concaténer des blocs de longueur L (en bouclant sur la fin de la série) jusqu'à obtenir T indices, puis calculer la métrique bootstrap $M_m^{*(b)}$;
3. intervalle percentile : $\left[q_{\alpha/2}\left(M_m^*\right),\ q_{1-\alpha/2}\left(M_m^*\right) \right]$.

Remarque. Utilisez les **mêmes indices rééchantillonnés pour tous les modèles** (bootstrap apparié). Vous pouvez ainsi calculer un intervalle sur la *différence* $M_m - M_{\text{réf}}$: si cet intervalle contient 0, la supériorité du modèle m sur la référence n'est pas établie.

BONUS – Conformal Prediction Online : ACI

On construit en ligne un intervalle de prévision autour de $\hat{y}_t$, avec un niveau cible $1 - \alpha$. Avec le score $s_t = |y_t - \hat{y}_t|$ et $\hat{Q}_t(p)$ le quantile empirique d'ordre p des scores passés (éventuellement sur une fenêtre glissante) :

$$C_t = \left[\hat{y}_t - \hat{Q}_t(1-\alpha_t),\ \hat{y}_t + \hat{Q}_t(1-\alpha_t) \right], \qquad \alpha_{t+1} = \alpha_t + \gamma\left(\alpha - \mathrm{err}_t\right), \quad \mathrm{err}_t = \mathbf{1}\{y_t \notin C_t\}.$$

Après une erreur, α_t diminue et l'intervalle s'élargit ; après une couverture, il se resserre.

- ▷ À rapporter : **couverture empirique** $\frac{1}{T}\sum_t(1 - \mathrm{err}_t)$, **couverture glissante**, **largeur moyenne** des intervalles, et la sensibilité au pas γ.
- ▷ Référence : Gibbs & Candès (2021), *Adaptive Conformal Inference Under Distribution Shift*, NeurIPS.

5. Jeux de données proposés

Liste indicative : vous pouvez choisir un autre jeu de données public, sous réserve de le justifier dans la note de cadrage. Les trois premiers sont des jeux de **demande / inventaire**, naturellement adaptés au newsvendor.

#	Dataset	Contenu	Source
Demande et inventaire			
1	M5 Forecasting (Walmart)	Ventes journalières par produit et magasin, prix, calendrier, hiérarchie produits	https://www.kaggle.com/competitions/m5-forecasting-accuracy
2	Corporación Favorita	Ventes journalières d'une chaîne d'épiceries, promotions, produits périssables	https://www.kaggle.com/competitions/favorita-grocery-sales-forecasting
3	FreshRetailNet-50K	50 000 séries horaires de produits frais, ruptures de stock annotées (demande censurée)	https://huggingface.co/datasets/Dingdong-Inc/FreshRetailNet-50K
Ventes et commerce			
4	Rossmann Store Sales	Ventes journalières de plus de 1 000 magasins, promotions, vacances	https://www.kaggle.com/competitions/rossmann-store-sales
5	Online Retail II (UCI)	Transactions d'un e-commerçant britannique 2009–2011, à agréger par jour/semaine	https://archive.ics.uci.edu/dataset/502/online+retail+ii
Énergie, mobilité, environnement			
6	Electricity Load Diagrams (UCI)	Consommation électrique de 370 clients au pas de 15 min, 2011–2014	https://archive.ics.uci.edu/dataset/321/electricityloaddiagrams20112014
7	Metro Interstate Traffic Volume (UCI)	Trafic horaire sur l'autoroute I-94 (Minneapolis–St Paul), 2012–2018, avec météo et jours fériés	https://archive.ics.uci.edu/dataset/492/metro+interstate+traffic+volume
8	Air Quality (UCI)	Mesures horaires de capteurs de polluants (CO, NO_2, ...)	https://archive.ics.uci.edu/dataset/360/air+quality
9	ETT (Electricity Transformer Temperature)	Température d'huile de transformateurs et charges, horaire et 15 min	https://github.com/zhouhaoyi/ETDataset
Benchmarks généralistes			
10	Monash Forecasting Repository (M4, Tourism, Traffic, ...)	Collection académique de benchmarks de séries temporelles	https://forecastingdata.org

Remarque. Les jeux Kaggle (1, 2, 4) nécessitent un compte gratuit ; les jeux UCI sont aussi accessibles en Python via `ucimlrepo`, et FreshRetailNet-50K via `datasets.load_dataset`. Pour les jeux volumineux, travaillez sur un sous-ensemble (quelques produits ou magasins, ou un niveau agrégé) et justifiez ce choix. **Attention** : en inventaire, les ventes observées ne sont pas la demande (ventes censurées par les ruptures).

Conseils pour réussir

- ▷ Soignez votre rédaction, motivation, formalisme mathématique et inteprétations.
- ▷ Quantifiez bien l'incertitude sur les métriques !
- ▷ **Respecter le cadre online** : aucune information future ne doit servir à prédire y_t (normalisation, choix des hyperparamètres, ...).
- ▷ **Interpréter plutôt qu'empiler** : expliquez *pourquoi* et *quand* un modèle gagne ou perd ; discutez les choix de τ, η, L et les limites.
- ▷ **Soigner le livrable** : figures lisibles et légendées, notebook exécuté de bout en bout, graines aléatoires fixées.

Je reste disponible par mail si vous avez des questions, de quelque nature que ce soit.

Bon devoir !