Introduction au Online Learning

Notes de cours — synthèse des notions fondamentales et de Follow the Leader

1 Du Statistical Learning au Online Learning

1.1 Modèles paramétriques et apprentissage classique

Dans le cadre supervisé classique, on observe un échantillon $(X_i, Y_i)_{i=1}^n \overset{\text{i.i.d.}}{\sim} \mathbb{P}_{(X,Y)}$ et l'on estime un paramètre $\theta \in \Theta$ pour prédire Y à partir de X.

Définition 1.1 (Modèle paramétrique)**.** Une famille de prédicteurs est paramétrique lorsqu'elle s'écrit $\mathcal{M} = \{\mu_\theta : \mathcal{X} \to \mathcal{Y} \,;\, \theta \in \Theta\}$, avec Θ de dimension finie. Apprendre revient à déterminer $\widehat{\theta}$ à partir des observations.

Les exemples usuels relèvent tous de ce cadre, même lorsqu'ils sont non linéaires :

Modèle	**Formalisme / objectif**
Régression linéaire	$Y = \beta_0 + \beta^\top X + \varepsilon$; prévoir une quantité.
Régression logistique	$\mathbb{P}(Y = 1 \mid X = x) = \left[1 + \exp(-\beta_0 - \beta^\top x)\right]^{-1}$; classer.
Modèle linéaire généralisé	$g(\mathbb{E}[Y \mid X = x]) = \beta_0 + \beta^\top x$.
Réseau de neurones	$\mu_\theta = h_L \circ \cdots \circ h_1$; poids et biais forment θ.
ARIMA	Modèle paramétrique temporel intégrant dépendances et différenciation.

Une **série temporelle** correspond à une réalisation observée d'un processus stochastique $(Y_t)_{t\in\mathcal{T}}$. Les ventes quotidiennes de baguettes ou la température horaire en sont deux exemples. Contrairement à un échantillon i.i.d., les observations peuvent dépendre du passé :

$$Y_t = \underbrace{2 + 0.1Y_{t-1}}_{\text{partie prévisible}} + \underbrace{\varepsilon_t}_{\text{innovation}}, \qquad \mathbb{E}[\varepsilon_t] = 0, \quad \mathrm{Var}(\varepsilon_t) = \sigma^2.$$

Sous l'hypothèse que l'innovation est indépendante du passé, $\mathbb{E}[Y_t \mid Y_{t-1}] = 2 + 0.1Y_{t-1}$ et $\mathrm{Var}(Y_t \mid Y_{t-1}) = \sigma^2$. Il s'agit d'un modèle AR(1).

Remarque 1.2. Le caractère temporel n'impose pas une dépendance : un bruit blanc i.i.d. est aussi une série temporelle. La modélisation doit néanmoins distinguer la structure prédictible de l'incertitude résiduelle.

Remarque 1.3 (Deux paradigmes, deux types de garanties). Dans le cadre statistique i.i.d., l'aléa est modélisé par une loi $\mathbb{P}_{(X,Y)}$ et l'on étudie les propriétés d'un estimateur ou d'un prédicteur, notamment son risque hors échantillon. Dans le protocole en ligne, l'analyse peut porter sur une suite de pertes *arbitraire* $\ell_1, \ldots, \ell_T$, sans supposer qu'elle provienne d'une loi stationnaire. L'objet de la garantie est alors le **regret**. Ces cadres ne s'excluent pas : on peut apprendre en ligne sur des données stochastiques, mais les hypothèses et les critères changent.

1.2 Fonction de perte et optimisation statistique

Le choix d'un modèle ne suffit pas : il faut définir le *critère* qui mesure ses erreurs. Pour la régression simple $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$, le résidu vaut $r_i(\beta) = Y_i - \beta_0 - \beta_1 X_i$. Sous les moindres carrés,

$$\mathcal{L}_n(\beta) = \frac{1}{n}\sum_{i=1}^n r_i(\beta)^2, \qquad \widehat{\beta} \in \arg\min_{\beta\in\mathbb{R}^2} \mathcal{L}_n(\beta).$$

Le **risque empirique** $\mathcal{L}_n$ est calculable ; le **risque théorique** $\mathcal{R}(\beta) = \mathbb{E}[\ell(\beta; X, Y)]$ dépend de la loi des données. Le Statistical Learning étudie notamment le passage de l'un à l'autre.

Définition 1.4 (Descente de gradient)**.** Pour une fonction différentiable $f : \mathbb{R}^d \to \mathbb{R}$, le vecteur $\nabla f(\theta)$ indique la direction de croissance locale maximale lorsqu'il est non nul. La descente de gradient suit

$$\boxed{\theta^{(k+1)} = \theta^{(k)} - \eta_k \nabla f(\theta^{(k)}), \qquad \eta_k > 0.}$$

Le sens opposé au gradient est une direction de décroissance *locale*, non nécessairement la direction du minimum global.

Dans la régression simple, le gradient est explicite :

$$\nabla \mathcal{L}_n(\beta) = -\frac{2}{n} \begin{pmatrix} \sum_{i=1}^n r_i(\beta) \\ \sum_{i=1}^n X_i r_i(\beta) \end{pmatrix}.$$

La convexité de la perte quadratique permet d'obtenir des garanties supplémentaires de convergence sous un choix approprié de pas.

Exemple 1.5 (Une itération de descente)**.** Avec $J(z) = \frac{1}{2}(z-15)^2$, on a $J'(z) = z - 15$. Depuis $z^{(0)} = 10$ avec un pas $\eta = 0.2$,

$$z^{(1)} = 10 - 0.2(10 - 15) = 11, \qquad J(10) = 12.5, \quad J(11) = 8.$$

Le nouveau paramètre réduit bien la perte. Contrairement à FTL, la descente de gradient modifie ici *itérativement* un même problème d'optimisation fixé à l'avance.

1.3 Pourquoi la fonction de perte compte

La fonction de perte formalise ce que l'on considère comme une erreur coûteuse. Elle ne découle pas automatiquement de l'architecture du prédicteur. Pour une prédiction scalaire $\widehat{y}$ et une observation y, les choix courants donnent des objectifs différents :

Perte	**Expression**	**Interprétation**
Quadratique	$(y - \widehat{y})^2$	Les grands résidus sont fortement pénalisés.
Absolue	$\lvert y - \widehat{y}\rvert$	Pénalisation linéaire de l'écart.
Asymétrique	$c_-(y - \widehat{y})_+ + c_+(\widehat{y} - y)_+$	Sous-stock et surstock ont des coûts distincts.

Dans le troisième cas, $c_- > 0$ mesure le coût unitaire d'une demande non servie et $c_+ > 0$ celui d'une unité commandée en excès. Cette fonction est plus naturelle qu'une perte symétrique pour une décision de stock. Les deux premières pertes resteront nos exemples mathématiques.

1.4 Moyenne empirique : un premier optimum de référence

Pour des observations réelles $x_1, \dots, x_n$, cherchons la meilleure *constante* selon la perte quadratique.

Théorème 1.6 (Moyenne et moindres carrés)**.** *Le minimiseur est unique et correspond à la moyenne empirique :*

$$\boxed{z^\star = \arg\min_{z \in \mathbb{R}} \frac{1}{n} \sum_{i=1}^n (x_i - z)^2 = \frac{1}{n} \sum_{i=1}^n x_i.}$$

Preuve. Pour $J(z) = n^{-1} \sum_i (x_i - z)^2$, $J'(z) = 2(z - n^{-1} \sum_i x_i)$ et $J''(z) = 2 > 0$. L'unique point critique est donc l'unique minimum global. □

Par exemple, les valeurs $(2, 3, 10)$ conduisent à $z^\star = 5$. Ce résultat servira à comprendre l'algorithme FTL.

1.5 Le protocole en ligne et le regret

En Online Learning, l'apprenant choisit successivement des décisions $\theta_t \in \mathcal{K}$; la perte ℓ_t n'est révélée qu'après la décision du temps t. L'évaluation porte sur la somme des pertes subies, non sur la qualité d'un estimateur calculé une fois à partir d'un échantillon.

Définition 1.7 (Comparateur en hindsight et regret)**.** La meilleure décision *fixe* choisie après coup est $\theta^\star \in \arg\min_{\theta\in\mathcal{K}} \sum_{t=1}^T \ell_t(\theta)$. Le regret contre un comparateur $u \in \mathcal{K}$ et le regret standard sont

$$\mathrm{Reg}_T(u) = \sum_{t=1}^T [\ell_t(\theta_t) - \ell_t(u)], \quad \mathrm{Reg}_T = \sum_{t=1}^T \ell_t(\theta_t) - \min_{u\in\mathcal{K}} \sum_{t=1}^T \ell_t(u).$$

On appelle Reg_T/T le *regret moyen*.

Avec la perte $\ell_t(\theta) = (Y_t - \theta)^2$, le comparateur fixe optimal est $\theta^\star = T^{-1}\sum_{t=1}^T Y_t$: il connaît tout le passé *et* le futur, contrairement à l'apprenant. Le regret peut être négatif, même face au meilleur comparateur fixe : une suite de décisions adaptatives peut parfois faire mieux que toute constante. Pour FTL avec minimiseurs exacts, nous démontrerons toutefois une propriété particulière de non-négativité.

Remarque 1.8 (Décision et information : chronologie)*.* L'ordre des événements est déterminant :

$$\underbrace{\theta_t \text{ choisie}}_{\text{avant observation}} \longrightarrow \underbrace{\ell_t \text{ révélée}}_{\text{perte } \ell_t(\theta_t)} \longrightarrow \underbrace{\theta_{t+1} \text{ mise à jour}}_{\text{pour le prochain tour}}.$$

Cette contrainte d'information est précisément ce qui distingue une politique en ligne d'une optimisation effectuée en hindsight.

2 Convexité, sous-gradients et optimisation en ligne

2.1 De la dérivée au sous-différentiel

Certaines pertes convexes (notamment la valeur absolue) ne sont pas différentiables partout. Le sous-gradient généralise le gradient à ce cadre.

Définition 2.1 (Sous-gradient)**.** Pour $f : \mathbb{R}^d \to \mathbb{R}$ convexe, un vecteur $g \in \mathbb{R}^d$ est un sous-gradient de f en u si

$$\boxed{f(v) \geq f(u) + \langle g, v - u\rangle \quad \text{pour tout } v \in \mathbb{R}^d.}$$

Le **sous-différentiel** est l'ensemble $\partial f(u) = \{g : \langle g, v - u\rangle \leq f(v) - f(u),\ \forall v\}$. Si f est différentiable en u, alors $\partial f(u) = \{\nabla f(u)\}$.

Géométriquement, $v \mapsto f(u) + \langle g, v - u\rangle$ est un *minorant affine global* de f touchant son graphe en u. L'inégalité peut se réécrire, sous une forme utile pour l'analyse du regret :

$$\langle g, u - v\rangle \geq f(u) - f(v).$$

2.2 Valeur absolue et droites d'appui

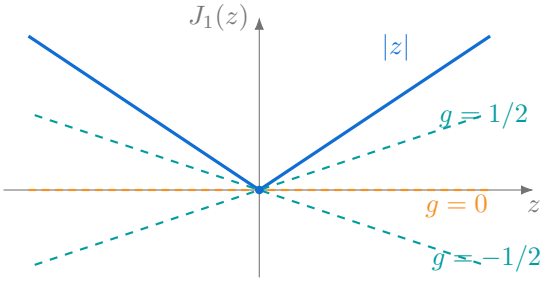
Pour $J_2(z) = z^2$, le minimum est en zéro : $J_2'(z) = 2z$. En revanche, $J_1(z) = |z|$ présente un point anguleux en zéro : $J_1'(z) = -1$ pour $z < 0$ et $J_1'(z) = 1$ pour $z > 0$. Cherchons son sous-différentiel

en ce point :

$$\partial J_1(0) = \{g \in \mathbb{R} : gv \le |v|,\ \forall v \in \mathbb{R}\}.$$

Pour $v > 0$, on obtient $g \le 1$; pour $v < 0$, la division inverse l'inégalité et impose $g \ge -1$; pour $v = 0$, aucune contrainte. Réciproquement, ces conditions suffisent. Par conséquent,

$$\boxed{\partial|z| = \begin{cases} \{-1\}, & z < 0, \\ [-1, 1], & z = 0, \\ \{1\}, & z > 0. \end{cases}}$$



Chaque droite en pointillés touche $|z|$ en zéro et reste au-dessous de son graphe : sa pente appartient à $[-1, 1]$. La droite d'appui horizontale correspond à $g = 0$.

Théorème 2.2 (Condition d'optimalité convexe)**.** *Pour une fonction convexe $f : \mathbb{R}^d \to \mathbb{R}$,*

$$\boxed{u^\star \in \arg\min_{u \in \mathbb{R}^d} f(u) \iff 0 \in \partial f(u^\star).}$$

Preuve. Si $0 \in \partial f(u^\star)$, alors, pour tout v, $f(v) \ge f(u^\star) + \langle 0, v - u^\star \rangle = f(u^\star)$. Réciproquement, si $u^\star$ minimise f, cette même inégalité est satisfaite avec $g = 0$. □

Remarque 2.3. Pour des observations scalaires, la perte quadratique $\sum_i (x_i - z)^2$ est minimisée par la **moyenne**, tandis que la perte absolue $\sum_i |x_i - z|$ l'est par une **médiane**. Sur $(2, 3, 10)$, ces deux réponses sont respectivement 5 et 3.

Exemple 2.4 (Un autre minimum : la médiane)**.** Pour $x_1 \le \cdots \le x_n$, considérons $A(z) = \sum_i |x_i - z|$. Entre deux observations successives, la pente de A est égale au nombre d'observations situées à gauche de z, moins le nombre situé à droite. Elle est négative avant la médiane et positive après. Ainsi, $0 \in \partial A(z)$ exactement pour les médianes empiriques ; si n est pair, tout l'intervalle $[x_{n/2}, x_{n/2+1}]$ minimise A.
Ce résultat met en évidence une règle générale : changer la perte modifie le paramètre optimal, donc la cible d'apprentissage.

2.3 Online Gradient Descent : un aperçu

L'algorithme OGD met à jour une décision *après* révélation de la perte courante, grâce à un sous-gradient de cette seule perte.

Définition 2.5 (Online Gradient Descent (OGD))**.** Si $\mathcal{K} \subset \mathbb{R}^d$ est fermé, convexe et non vide, si $g_t \in \partial \ell_t(\theta_t)$ et si $\eta_t > 0$, alors

$$\boxed{\theta_{t+1} = \Pi_{\mathcal{K}}(\theta_t - \eta_t g_t),}$$

où $\Pi_{\mathcal{K}}$ désigne la projection euclidienne.

La descente de gradient *hors ligne* utilise le gradient d'une fonction objectif fixée par l'échantillon ; OGD met à jour les décisions séquentiellement et vise une garantie sur les pertes cumulées.

Remarque 2.6 (Pourquoi travailler avec des sous-gradients ?). Dans de nombreux problèmes (régression robuste avec perte absolue, perte de quantile ou optimisation sous contraintes), la fonction objectif est convexe mais présente des points anguleux. L'inégalité de sous-gradient remplace alors le développement différentiel classique et permet d'analyser des algorithmes comme OGD.

3 Rappel asymptotique : le petit o

La notation o formalise le caractère *négligeable* d'une quantité relativement à une autre. Dans la formule de Taylor–Young,

$$f(x) = \sum_{k=0}^{n} \frac{f^{(k)}(a)}{k!}(x-a)^k + o((x-a)^n), \qquad x \to a,$$

le reste devient négligeable devant $(x-a)^n$.

Définition 3.1 (Petit o)**.** Lorsque $g(x) \neq 0$ au voisinage ponctué de a,

$$\boxed{f(x) = o(g(x)) \ (x \to a) \iff \lim_{x \to a} \frac{f(x)}{g(x)} = 0.}$$

Par exemple, $x^2 = o(x)$ lorsque $x \to 0$, $x^2 = o(\sqrt{x})$ lorsque $x \to 0^+$, mais $x = o(x^2)$ lorsque $x \to +\infty$. La limite doit donc être précisée. Pour les suites temporelles,

$$\frac{\sqrt{T}}{T} = \frac{1}{\sqrt{T}} \longrightarrow 0, \quad \frac{\log T}{T} \longrightarrow 0 \qquad (T \to \infty).$$

Exemple 3.2 (Reste de Taylor et échelles asymptotiques)**.** Au voisinage de zéro, le développement $e^x = 1 + x + \frac{1}{2}x^2 + o(x^2)$ signifie que l'erreur $e^x - (1 + x + \frac{1}{2}x^2)$ est petite devant x^2. Il ne faut pas confondre O et o : écrire $a_T = O(\sqrt{T})$ signifie qu'il existe $C > 0$ tel que $|a_T| \leq C\sqrt{T}$ pour T assez grand ; cette relation entraîne $a_T = o(T)$, mais n'impose pas $a_T = o(\sqrt{T})$.

Proposition 3.3 (Regret sous-linéaire)**.** *Si* $\mathrm{Reg}_T = o(T)$*, alors* $\mathrm{Reg}_T/T \to 0$ *: le regret moyen tend vers zéro. Une borne* $|\mathrm{Reg}_T| \leq C\sqrt{T}$ *l'assure. Une seule borne supérieure* $\mathrm{Reg}_T \leq C\sqrt{T}$ *garantit* $\limsup_T \mathrm{Reg}_T/T \leq 0$*, mais pas nécessairement la limite égale à zéro lorsqu'il s'agit d'un regret contre un comparateur arbitraire.*

Pour FTL avec minimiseurs exacts, une identité télescopique établira $\mathrm{Reg}_T \geq 0$. Dans ce cas, une borne supérieure $o(T)$ suffit pour obtenir la convergence du regret moyen. Cette conclusion ne vaut pas automatiquement pour un algorithme quelconque.

Croissance du regret	**Regret moyen**	**Sous-linéaire ?**
$C \log T$	$C \log(T)/T \to 0$	oui
$C\sqrt{T}$	$C/\sqrt{T} \to 0$	oui
CT	C	non

L'objectif asymptotique n'impose donc pas un regret cumulatif borné : un regret qui croît vers l'infini peut rester négligeable en moyenne.

4 Follow the Leader : méthode et exemple

4.1 Principe de la décision a posteriori

On cherche chaque jour à prévoir une demande y_t de pommes de terre. La décision θ_t est prise avant la révélation de y_t. Le modèle pédagogique emploie des quantités réelles sur $\mathcal{K} = [0, 20]$ et la perte quadratique

$$\ell_t(\theta) = \frac{1}{2}(\theta - y_t)^2.$$

Le facteur $1/2$ facilite les dérivées, sans modifier les minima. Dans un problème réel d'inventaire, le coût de rupture et celui du surstock sont généralement asymétriques : la perte quadratique est ici une simplification volontaire.

Définition 4.1 (Follow the Leader (FTL))**.** On initialise $\theta_1 \in \mathcal{K}$. Pour chaque $t \geq 2$,

$$\boxed{\theta_t \in \arg\min_{\theta \in \mathcal{K}} \sum_{s=1}^{t-1} \ell_s(\theta).}$$

La décision courante minimise les pertes *passées* : elle n'utilise pas la perte ℓ_t qui n'a pas encore été révélée.

Il faut distinguer $\sum_{s<t} \ell_s(\theta)$, qui évalue une *même* décision sur les dates passées, de $\sum_{s\leq t} \ell_s(\theta_s)$, la perte effectivement subie par l'apprenant qui a pu changer de décision chaque jour.

4.2 Exemple numérique sur trois jours

On choisit $\theta_1 = 10$, et la demande réelle est $y_1 = 15$. La perte vaut $\ell_1(10) = \frac{1}{2}(10 - 15)^2 = 12.5$. Au deuxième jour, FTL résout

$$\theta_2 = \arg\min_{\theta \in [0,20]} \frac{1}{2}(\theta - 15)^2 = 15.$$

Puis $y_2 = 12$: la perte est $\ell_2(15) = \frac{1}{2}(15 - 12)^2 = 4.5$. Au troisième jour, les deux observations donnent

$$\theta_3 = \arg\min_{\theta \in [0,20]} \left\{ \frac{1}{2}(\theta - 15)^2 + \frac{1}{2}(\theta - 12)^2 \right\}.$$

La dérivée $2\theta - 27$ s'annule en $\theta_3 = 13.5$. On observe ensuite $y_3 = 16$ et la perte est $\ell_3(13.5) = \frac{1}{2}(13.5 - 16)^2 = 3.125$.

t	θ_t	y_t	$\theta_t - y_t$	$\ell_t(\theta_t)$	$\sum_{s\leq t} \ell_s(\theta_s)$
1	10	15	-5	12.5	12.5
2	15	12	3	4.5	17
3	13.5	16	-2.5	3.125	20.125
4	43/3	?	?	?	?

La décision du jour 4 est déjà calculable : $\theta_4 = (15 + 12 + 16)/3 = 43/3 \simeq 14.33$.

4.3 Résultat général : FTL avec une perte quadratique

L'exemple précédent suggère un résultat général : avec une perte quadratique, FTL prédit la moyenne empirique du passé.

Théorème 4.2 (FTL et moyenne empirique)**.** *Supposons que les observations $y_1, \dots, y_T$ appartiennent à un intervalle convexe $\mathcal{K} \subseteq \mathbb{R}$.*
Pour la perte

$$\ell_t(\theta) = \frac{1}{2}(\theta - y_t)^2,$$

l'algorithme Follow the Leader choisit, pour tout $t \geq 2$,

$$\boxed{\theta_t = \frac{1}{t-1}\sum_{s=1}^{t-1} y_s}.$$

Autrement dit, la décision FTL au temps t est la moyenne empirique des $t-1$ demandes précédentes.

Preuve. Par définition,

$$\theta_t \in \arg\min_{\theta \in \mathcal{K}} \left\{ \frac{1}{2}\sum_{s=1}^{t-1}(\theta - y_s)^2 \right\}.$$

Définissons

$$J_{t-1}(\theta) = \frac{1}{2}\sum_{s=1}^{t-1}(\theta - y_s)^2.$$

Sa dérivée est

$$J'_{t-1}(\theta) = \sum_{s=1}^{t-1}(\theta - y_s) = (t-1)\theta - \sum_{s=1}^{t-1} y_s.$$

La condition du premier ordre donne

$$J'_{t-1}(\theta_t) = 0 \quad \Longleftrightarrow \quad (t-1)\theta_t - \sum_{s=1}^{t-1} y_s = 0.$$

Par conséquent,

$$\theta_t = \frac{1}{t-1}\sum_{s=1}^{t-1} y_s.$$

Enfin,

$$J''_{t-1}(\theta) = t - 1 > 0.$$

La fonction objectif est strictement convexe. Sa solution est donc l'unique minimiseur global. Puisque les observations appartiennent à l'intervalle convexe $\mathcal{K}$, leur moyenne appartient également à $\mathcal{K}$. □

On obtient une mise à jour récursive, valable pour $t \geq 2$:

$$\boxed{\theta_{t+1} = \theta_t + \frac{1}{t}(y_t - \theta_t).}$$

Le poids accordé à une nouvelle observation décroît comme $1/t$: la moyenne historique s'adapte lentement aux changements persistants.

Exemple 4.3 (Pourquoi le regret ne se confond pas avec la perte)**.** Une grande perte cumulée n'est pas nécessairement le signe d'un mauvais algorithme : la meilleure décision fixe peut elle-même subir une perte élevée si les demandes sont imprévisibles. À l'inverse, une faible perte peut correspondre à un regret important si un comparateur constant faisait beaucoup mieux. Le regret *retire* donc une référence commune à la suite observée.

4.4 Calcul du regret réalisé

Sur les trois premiers jours, l'apprenant a subi $12.5+4.5+3.125 = 20.125$. La meilleure constante choisie *a posteriori* est $\theta^\star = (15+12+16)/3 = 43/3$. Sa perte est

$$\min_{\theta\in[0,20]} \sum_{t=1}^{3} \ell_t(\theta) = \frac{1}{2}\left(\frac{4}{9}+\frac{49}{9}+\frac{25}{9}\right) = \frac{13}{3}.$$

Ainsi,

$$\boxed{\mathrm{Reg}_3 = 20.125 - \frac{13}{3} = \frac{379}{24} \simeq 15.79.}$$

Ce regret mesure le coût de l'information indisponible lors des premières décisions ; il n'implique pas que le regret croisse linéairement sur de longues périodes.

Remarque 4.4 (FTL et changement de régime). La récurrence $\theta_{t+1} = \theta_t + (y_t - \theta_t)/t$ signifie que la réponse d'une moyenne historique à une nouvelle observation diminue avec t. Si, après plusieurs mois stables, la demande augmente brutalement, la prévision continuera longtemps à refléter l'ancien régime. Ce phénomène motive les fenêtres glissantes, les pondérations adaptatives et, plus généralement, les algorithmes conçus pour la non-stationnarité.

4.5 Pourquoi une moyenne historique réagit lentement

La forme récursive de FTL se comprend aussi en présence d'un changement de régime. Supposons que les premières demandes soient toutes égales à a, puis que la demande passe brusquement à $b > a$ après le jour τ :

$$y_s = \begin{cases} a, & s \le \tau, \\ b, & s > \tau. \end{cases}$$

Pour $t > \tau + 1$, la décision FTL se calcule explicitement :

$$\theta_t = \frac{\tau a + (t-1-\tau)b}{t-1} = b - \frac{\tau}{t-1}(b-a).$$

Après le changement, l'écart $b - \theta_t$ décroît comme $\tau/(t-1)$: la moyenne historique demeure longtemps influencée par les τ anciennes observations. Il s'agit d'une illustration concrète de la différence entre *regret contre une constante* et *adaptation à un environnement changeant*. Le premier critère n'exige pas de suivre instantanément chaque variation de la demande.

5 FTL : inégalités et garanties de regret

5.1 Be-the-Leader : une comparaison fictive

Posons $F_t(\theta) = \sum_{s=1}^{t} \ell_s(\theta)$ et $F_0 \equiv 0$. Ainsi, $\theta_{t+1} \in \arg\min_{\theta\in\mathcal{K}} F_t(\theta)$. La décision θ_{t+1} repose déjà sur ℓ_t ; elle n'est donc pas disponible à l'apprenant *avant* la révélation de cette perte.

Théorème 5.1 (Inégalité Be-the-Leader). *Pour tout $u \in \mathcal{K}$, et pour des minimiseurs FTL exacts,*

$$\boxed{\sum_{t=1}^{T} \ell_t(\theta_{t+1}) \le \sum_{t=1}^{T} \ell_t(u).}$$

Preuve. Par définition, $\ell_t(\theta_{t+1}) = F_t(\theta_{t+1}) - F_{t-1}(\theta_{t+1})$. Comme θ_t minimise F_{t-1},

$$\ell_t(\theta_{t+1}) \le F_t(\theta_{t+1}) - F_{t-1}(\theta_t).$$

La somme télescope : $\sum_t \ell_t(\theta_{t+1}) \le F_T(\theta_{T+1}) - F_0(\theta_1) = F_T(\theta_{T+1}) \le F_T(u)$. □

5.2 Décomposition du regret et stabilité

En ajoutant et retranchant la perte du leader actualisé,

$$\mathrm{Reg}_T(u) = \underbrace{\sum_{t=1}^{T}\left[\ell_t(\theta_t) - \ell_t(\theta_{t+1})\right]}_{\text{coût du retard d'une période}} + \underbrace{\sum_{t=1}^{T}\left[\ell_t(\theta_{t+1}) - \ell_t(u)\right]}_{\leq 0 \text{ (Be-the-Leader)}}.$$

Proposition 5.2 (Borne de stabilité de FTL)**.** *Pour tout comparateur $u \in \mathcal{K}$,*

$$\boxed{\mathrm{Reg}_T(u) \leq \sum_{t=1}^{T}\left[\ell_t(\theta_t) - \ell_t(\theta_{t+1})\right].}$$

La différence $\theta_{t+1} - \theta_t$ mesure la réaction de l'algorithme à la nouvelle information. Si les minimisateurs changent peu, on peut espérer un faible regret.

Une intuition sur le coût du retard. Be-the-Leader peut minimiser la somme des pertes parce que la décision θ_{t+1} utilise déjà la perte du jour. FTL n'utilise que $\ell_1, \ldots, \ell_{t-1}$ et paie le prix de cette information manquante. La décomposition précédente montre qu'il suffit de borner le prix payé entre deux décisions successives. Une forte courbure du critère historique rend le minimiseur plus difficile à déplacer.

Exemple 5.3 (Vérification numérique du télescopage)**.** Sur l'exemple des trois jours, la meilleure décision après les premiers t jours est θ_{t+1}. On peut donc vérifier l'identité de regret directement à l'aide de $\Delta_t = F_t(\theta_t) - F_t(\theta_{t+1})$:

t	$F_t(\theta_t)$	$F_t(\theta_{t+1})$	Δ_t
1	25/2	0	25/2
2	9/2	9/4	9/4
3	43/8	13/3	25/24

Par sommation,

$$\sum_{t=1}^{3}\Delta_t = \frac{25}{2} + \frac{9}{4} + \frac{25}{24} = \frac{379}{24} = \mathrm{Reg}_3.$$

On retrouve exactement le regret calculé précédemment. Il est positif pour cette stratégie FTL avec minimiseurs exacts, puisque chaque Δ_t mesure le gain obtenu en réoptimisant F_t.

5.3 Forte convexité : la courbure stabilise le leader

Définition 5.4 (Forte convexité)**.** Une fonction convexe f est α-fortement convexe sur $\mathcal{K}$ ($\alpha > 0$) si, pour tous $u, v \in \mathcal{K}$ et $g \in \partial f(u)$,

$$\boxed{f(v) \geq f(u) + \langle g, v - u\rangle + \frac{\alpha}{2}\|v - u\|_2^2.}$$

Si f est deux fois différentiable, la condition $\nabla^2 f \succeq \alpha I_d$ est suffisante.

Chaque perte $\ell_t(\theta) = \frac{1}{2}(\theta - y_t)^2$ est 1-fortement convexe, car $\ell_t'' = 1$. Si toutes les pertes sont α-fortement convexes, leur somme F_t est $t\alpha$-fortement convexe. La courbure du critère cumulé augmente donc avec le nombre d'observations.

Théorème 5.5 (FTL : regret logarithmique)**.** *Supposons $\mathcal{K}$ convexe, les minimiseurs exacts existants, chaque ℓ_t α-fortement convexe ($\alpha > 0$), et des sous-gradients $g_t \in \partial \ell_t(\theta_t)$ tels que $\|g_t\|_2 \le G$ pour tout t. Alors, pour tout $u \in \mathcal{K}$,*

$$\boxed{\mathrm{Reg}_T(u) \le \frac{G^2}{2\alpha} \sum_{t=1}^{T} \frac{1}{t} \le \frac{G^2}{2\alpha}(1 + \log T).}$$

Exemple 5.6 (Effet de la courbure sur un minimiseur)**.** Considérons une famille de fonctions quadratiques $H_t(\theta) = \frac{t}{2}(\theta - m_t)^2$. Sa courbure est t et son minimum est en m_t. Pour un déplacement fixé δ, l'augmentation de l'objectif est $H_t(m_t + \delta) - H_t(m_t) = t\delta^2/2$. Un même déplacement devient donc de plus en plus coûteux lorsque le nombre d'observations augmente. La démonstration suivante formalise cette stabilité sans supposer de loi probabiliste.

5.4 Démonstration de la borne logarithmique

La preuve explique le rôle de la courbure et l'apparition de la série harmonique. Introduisons

$$\Delta_t := F_t(\theta_t) - F_t(\theta_{t+1}) \ge 0, \quad d_t := \|\theta_t - \theta_{t+1}\|_2.$$

1. Identité télescopique. Comme $\ell_t(\theta_t) = F_t(\theta_t) - F_{t-1}(\theta_t)$,

$$\sum_{t=1}^{T} \ell_t(\theta_t) = \sum_{t=1}^{T} \Delta_t + F_T(\theta_{T+1}).$$

Puisque $F_T(\theta_{T+1}) \le F_T(u)$, $\mathrm{Reg}_T(u) \le \sum_t \Delta_t$; pour $u = \theta_{T+1}$, l'inégalité devient une égalité.

2. Accumulation de la forte convexité. Le point θ_t minimise F_{t-1}, qui est $(t-1)\alpha$-fortement convexe, donc

$$F_{t-1}(\theta_{t+1}) - F_{t-1}(\theta_t) \ge \frac{(t-1)\alpha}{2} d_t^2.$$

En utilisant la forte convexité de la perte courante et $g_t \in \partial \ell_t(\theta_t)$, on obtient également

$$\ell_t(\theta_{t+1}) - \ell_t(\theta_t) \ge \langle g_t, \theta_{t+1} - \theta_t \rangle + \frac{\alpha}{2} d_t^2.$$

La somme des deux relations donne, via Cauchy–Schwarz,

$$\Delta_t \le \langle g_t, \theta_t - \theta_{t+1} \rangle - \frac{t\alpha}{2} d_t^2 \le G d_t - \frac{t\alpha}{2} d_t^2.$$

3. Optimisation de la majoration. La fonction concave $d \mapsto Gd - t\alpha d^2/2$ atteint son maximum pour $d = G/(t\alpha)$. Par conséquent,

$$\boxed{\Delta_t \le \frac{G^2}{2\alpha t}, \qquad \sum_{t=1}^{T} \Delta_t \le \frac{G^2}{2\alpha} \sum_{t=1}^{T} \frac{1}{t}.}$$

Enfin, $\sum_{t=1}^{T} 1/t \le 1 + \log T$. La forte convexité fait donc décroître la contribution au regret comme $1/t$, et son accumulation est logarithmique.

Corollaire 5.7 (Regret moyen sous les hypothèses du théorème)**.** *Pour le regret standard,* $0 \leq \mathrm{Reg}_T \leq \frac{G^2}{2\alpha}(1+\log T)$ *et donc*

$$\boxed{\frac{\mathrm{Reg}_T}{T} \longrightarrow 0.}$$

Remarque 5.8 (La borne de gradient est une hypothèse distincte). La perte quadratique est fortement convexe sur $\mathbb{R}$, mais $\nabla \ell_t(\theta) = \theta - y_t$ n'est pas borné sur tout $\mathbb{R}$ si les demandes et les décisions ne sont pas bornées. Il faut donc contrôler séparément la courbure α et l'amplitude G des sous-gradients. L'une ne remplace pas l'autre.

5.5 Application et limites des hypothèses

Dans l'exemple de la demande, $\mathcal{K} = [0, 20]$, $y_t \in [0, 20]$ et $\ell_t(\theta) = \frac{1}{2}(\theta - y_t)^2$. Alors $\alpha = 1$ et $|\ell_t'(\theta_t)| = |\theta_t - y_t| \leq 20$: $G = 20$. Le théorème garantit, pour *toute* suite de demandes bornées,

$$\boxed{\mathrm{Reg}_T \leq 200(1+\log T).}$$

Cette borne est volontairement prudente. Elle n'exige ni indépendance, ni stationnarité, ni modèle probabiliste de la demande.

Remarque 5.9 (Pourquoi FTL peut échouer). Sans forte convexité ou contrôle de l'amplitude des gradients, les décisions historiques peuvent osciller sous des pertes changeantes, et un regret sous-linéaire n'est pas garanti. La stabilité peut être renforcée par régularisation : c'est le principe de FTRL (*Follow the Regularized Leader*).

5.6 Un contre-exemple : regret linéaire sans stabilité

Le théorème précédent donne des *conditions suffisantes*, et non une propriété de toutes les pertes convexes. Montrons que FTL peut échouer de manière spectaculaire lorsque le critère historique est instable.

Exemple 5.10 (Pertes linéaires alternées)**.** Choisissons $\mathcal{K} = [-1, 1]$ et

$$\ell_t(\theta) = \begin{cases} \theta, & t \text{ impair}, \\ -\theta, & t \text{ pair}. \end{cases}$$

Initialisons $\theta_1 = 1$ et choisissons la valeur 1 lorsqu'il y a égalité entre plusieurs minimiseurs historiques. Au premier tour, la perte $\ell_1(\theta) = \theta$ pousse le leader vers $\theta_2 = -1$. Au deuxième tour, $\ell_1 + \ell_2 \equiv 0$: avec notre règle de départage, $\theta_3 = 1$. Le même mécanisme se répète :

$$\boxed{\theta_t = (-1)^{t+1}, \qquad \ell_t(\theta_t) = 1, \quad \forall t.}$$

Pour tout horizon T pair, la somme des pertes d'une décision fixe est $\sum_{t=1}^{T} \ell_t(u) = 0$ pour tout $u \in [-1, 1]$. Or FTL subit T unités de perte :

$$\boxed{\mathrm{Reg}_T = T, \qquad \frac{\mathrm{Reg}_T}{T} = 1 \quad (T \text{ pair}).}$$

FTL suit donc constamment le minimiseur du passé, mais celui-ci se retourne à chaque tour. Le regret est linéaire : il n'est pas sous-linéaire.

Cet exemple oppose deux géométries : les pertes linéaires ont une courbure nulle et admettent des minimiseurs qui peuvent basculer d'une extrémité de $\mathcal{K}$ à l'autre ; les pertes fortement convexes pénalisent de tels déplacements. **FTRL** ajoutera une régularisation pour stabiliser les décisions lorsque les pertes ne fournissent pas suffisamment de courbure.

À retenir

Chaîne logique : les pertes s'accumulent $\Rightarrow$ la courbure de F_t augmente comme $t\alpha \Rightarrow$ le coût du déplacement est majoré par $G^2/(2\alpha t) \Rightarrow \mathrm{Reg}_T = O(\log T)$, et le regret moyen devient négligeable.

5.7 Bilan des notions de la séance

Le document a suivi une même question, du modèle statistique jusqu'à la décision en ligne : *comment choisir un paramètre quand l'information apparaît progressivement ?*

Notion	**Résultat et rôle**
Risque empirique	Apprendre un paramètre en minimisant des pertes observées.
Sous-gradient	Étendre l'optimisation à des pertes convexes non différentiables.
Hindsight	Comparateur fixe qui connaît toute la suite des pertes.
FTL quadratique	Moyenne empirique du passé ; mise à jour de poids $1/t$.
Be-the-Leader	Contrôler le regret de FTL par son coût de stabilité.
Forte convexité	Courbure cumulée $t\alpha$ et contributions au regret en $1/t$.
Regret logarithmique	Sous les hypothèses : $O(\log T)$, donc regret moyen négligeable.

Remarque 5.11 (Lecture des garanties). Le résultat $O(\log T)$ est une garantie *conditionnelle* : il nécessite notamment la forte convexité et des sous-gradients bornés. Le contre-exemple linéaire montre que cette conclusion ne découle pas de la seule définition de FTL. La comparaison naturelle avec OGD et FTRL consiste désormais à déterminer quelles garanties persistent lorsque la courbure des pertes est insuffisante.