Online Learning — Notes de la séance du 6 novembre 2026

Rappels, apprentissage avec covariables et introduction à FTRL

1 Rappels : apprentissage séquentiel et regret

1.1 Séries temporelles et fréquence d'échantillonnage

Une série temporelle est une réalisation d'un processus stochastique $(Y_t)_{t\in\mathcal{T}}$. L'indice t représente l'instant ou la période d'observation. Sa **fréquence d'échantillonnage** précise à quel rythme la variable est mesurée : température horaire, cours de bourse quotidien, effectif étudiant annuel ou volume mensuel d'appels.

Le caractère temporel n'implique pas nécessairement une dépendance, mais il permet de décrire des mécanismes où le présent dépend du passé. En Online Learning, les décisions sont prises successivement, sans devoir supposer que les observations sont indépendantes et identiquement distribuées.

Définition 1.1 (Ensemble convexe de décisions)**.** Un ensemble $\mathcal{K} \subseteq \mathbb{R}^d$ est **convexe** si

$$\forall u, v \in \mathcal{K},\ \forall \tau \in [0,1], \qquad \tau u + (1-\tau)v \in \mathcal{K}.$$

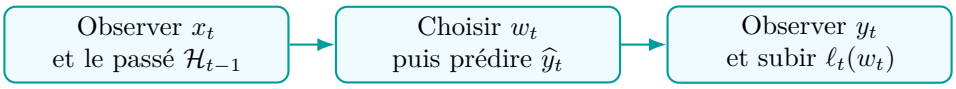
La moyenne de deux décisions admissibles appartient donc encore à $\mathcal{K}$. Un intervalle de $\mathbb{R}$ et une boule euclidienne de $\mathbb{R}^d$ sont convexes.

1.2 Protocole en ligne : une chronologie stricte

Soit $\mathcal{K}$ l'ensemble des paramètres admissibles. À l'instant t, l'apprenant choisit $w_t \in \mathcal{K}$ à partir des informations disponibles *avant* la révélation de la cible y_t. Il subit ensuite une perte $\ell_t(w_t)$ puis actualise sa décision. Formellement, si $\mathcal{H}_t$ désigne l'historique révélé jusqu'à t, on écrit

$$w_{t+1} = \mathcal{A}_t(\mathcal{H}_t), \qquad \mathcal{H}_t = \{(x_s, y_s) : 1 \le s \le t\}.$$

La variable x_t peut être une covariable disponible avant la décision, comme l'annonce préalable d'une promotion. On autorise donc le choix de w_t à dépendre de x_t *si le protocole le prévoit*, mais **jamais** de y_t.



Définition 1.2 (Comparateur fixe et regret)**.** Le meilleur paramètre *fixe en hindsight* est

$$w^\star \in \arg\min_{u\in\mathcal{K}} \sum_{t=1}^{T} \ell_t(u).$$

Le regret envers une décision fixe u et le regret standard sont

$$\mathrm{Reg}_T(u) = \sum_{t=1}^{T} [\ell_t(w_t) - \ell_t(u)],$$

$$\mathrm{Reg}_T = \sum_{t=1}^{T} \ell_t(w_t) - \min_{u\in\mathcal{K}} \sum_{t=1}^{T} \ell_t(u).$$

Le regret moyen est Reg_T/T. Un algorithme est dit **sans regret** si $\mathrm{Reg}_T/T \to 0$ lorsque $T \to \infty$.

Le regret mesure la différence de perte cumulée avec une décision constante qui connaît toute la suite. Il ne mesure pas directement l'erreur de prévision absolue. Dans le cadre général, le regret réalisé peut être négatif ; une borne supérieure sous-linéaire garantit donc d'abord $\limsup_T \mathrm{Reg}_T/T \le 0$. Pour FTL avec minimiseurs exacts, le regret standard est non négatif, et une telle borne donne bien $\mathrm{Reg}_T/T \to 0$.

1.3 Sous-gradients et condition d'optimalité

Définition 1.3 (Sous-gradient)**.** Pour une fonction convexe $f : \mathbb{R}^d \to \mathbb{R}$, un vecteur $g \in \mathbb{R}^d$ est un sous-gradient en u si

$$f(v) \ge f(u) + \langle g, v - u\rangle, \qquad \forall v \in \mathbb{R}^d.$$

L'ensemble de ces vecteurs est le **sous-différentiel** $\partial f(u)$. Si f est différentiable en u, $\partial f(u) = \{\nabla f(u)\}$.

Géométriquement, $v \mapsto f(u) + \langle g, v - u\rangle$ est un minorant affine global de f. En particulier,

$$u^\star \in \arg\min_{u\in\mathbb{R}^d} f(u) \quad \Longleftrightarrow \quad 0 \in \partial f(u^\star).$$

Cette condition est une caractérisation complète de l'optimalité *sans contrainte* pour une fonction convexe. Sur un ensemble contraint $\mathcal{K}$, on remplace f par $f + \iota_{\mathcal{K}}$ ou on utilise une condition d'optimalité adaptée aux contraintes.

Exemple 1.4 (Perte absolue)**.** Pour $f(u) = |u|$, les dérivées à gauche et à droite en zéro valent respectivement -1 et 1 : la fonction n'y est pas dérivable. Cependant,

$$\partial|u| = \begin{cases} \{-1\}, & u < 0, \\ [-1, 1], & u = 0, \\ \{1\}, & u > 0. \end{cases}$$

Comme $0 \in \partial|0|$, la valeur $u^\star = 0$ est bien un minimum.

1.4 Follow the Leader et hypothèses de regret

Définition 1.5 (Follow the Leader (FTL))**.** À partir d'un choix initial $w_1 \in \mathcal{K}$, FTL définit

$$w_{t+1} \in \arg\min_{u\in\mathcal{K}} \sum_{s=1}^{t} \ell_s(u).$$

La mise à jour w_{t+1} utilise la perte du temps t ; la décision w_t, prise au début du tour, ne l'utilise pas encore.

Théorème 1.6 (FTL : borne logarithmique)**.** *Si $\mathcal{K}$ est convexe, si les minimiseurs FTL existent et sont exacts, si chaque ℓ_t est α-fortement convexe ($\alpha > 0$), et s'il existe $g_t \in \partial\ell_t(w_t)$ avec $\|g_t\|_2 \le G$, alors pour tout $u \in \mathcal{K}$,*

$$\mathrm{Reg}_T(u) \le \frac{G^2}{2\alpha} \sum_{t=1}^{T} \frac{1}{t} \le \frac{G^2}{2\alpha}(1 + \log T).$$

Comme $\log T/T \to 0$, le regret standard de FTL est alors asymptotiquement négligeable en moyenne. **Ces hypothèses ne sont pas automatiques.** La perte scalaire $\ell_t(\theta) = \frac{1}{2}(y_t - \theta)^2$ est 1-fortement convexe ; son gradient $\theta - y_t$ est borné seulement si les décisions et les observations le sont.

Point de vigilance. Dès que l'on enrichit la prévision par plusieurs paramètres, la perte quadratique d'une observation n'est généralement *pas* fortement convexe dans tout l'espace des paramètres. Le théorème ci-dessus ne pourra donc pas être appliqué mécaniquement au modèle avec covariable introduit ci-dessous.

1.5 Précision sur les hypothèses : courbure et gradient borné

Le théorème de regret logarithmique exige **deux propriétés distinctes** : une courbure strictement positive de chaque perte et un contrôle de ses sous-gradients aux décisions effectivement jouées.

Propriété 1.7 (Perte quadratique scalaire). *Pour la perte $\ell_t(\theta) = \frac{1}{2}(\theta - y_t)^2$, on a*

$$\ell_t'(\theta) = \theta - y_t, \qquad \ell_t''(\theta) = 1.$$

Ainsi ℓ_t est α-fortement convexe avec $\alpha = 1$, quel que soit y_t. En revanche, la forte convexité ne donne pas de borne sur $|\ell_t'(\theta)|$.

Sur $\mathcal{K} = \mathbb{R}$. Le gradient n'est pas uniformément borné : pour un y_t fixé, $|\theta - y_t| \to \infty$ lorsque $|\theta| \to \infty$. Il en va de même si $\mathcal{K}$ est borné mais que les y_t peuvent prendre des valeurs arbitrairement grandes.

Sur $\mathcal{K} = [0, K]$. Si l'on suppose *également* que $y_t \in [0, K]$ pour tout t, alors, pour tout $\theta \in \mathcal{K}$,

$$|\ell_t'(\theta)| = |\theta - y_t| \leq K.$$

On peut donc choisir $G = K$ et $\alpha = 1$. Si la perte était définie par $(\theta - y_t)^2$ sans le facteur $\frac{1}{2}$, on obtiendrait plutôt $\alpha = 2$ et $G = 2K$.

Remarque 1.8 (La perte absolue). Pour $\ell_t(\theta) = |\theta - y_t|$, tous les sous-gradients appartiennent à $[-1, 1]$, donc $G = 1$ même sur $\mathbb{R}$. Mais la perte est seulement convexe, *pas fortement convexe* : le théorème logarithmique précédent n'est pas applicable.

2 Notebook illustratif : intégrer une covariable

2.1 Du prévisionnel constant à la prévision conditionnelle

Dans le notebook initial, on prévoit une demande quotidienne y_t par une constante θ_t. La perte est

$$\ell_t^{\text{base}}(\theta) = \frac{1}{2}(y_t - \theta)^2, \qquad \theta_t \in \arg\min_{\theta \in \mathbb{R}} \sum_{s=1}^{t-1} \ell_s^{\text{base}}(\theta).$$

Pour $t \geq 2$, FTL correspond donc à la moyenne historique $\theta_t = (t-1)^{-1} \sum_{s<t} y_s$.

Nous souhaitons maintenant exploiter une information disponible **avant la vente** : le magasin organise-t-il une promotion ?

$$x_t = \begin{cases} 1, & \text{promotion annoncée au jour } t, \\ 0, & \text{aucune promotion au jour } t. \end{cases}$$

Le nouveau prévisionnel est

$$\widetilde{\theta}_t = \underbrace{\theta_t}_{\text{demande de référence}} + \underbrace{\beta_t x_t}_{\text{correction liée à la promotion}}.$$

Ici θ_t représente l'ordonnée à l'origine, tandis que β_t représente l'effet *prédictif* associé à la promotion. Il ne faut pas le confondre avec un effet causal : en pratique, les promotions peuvent être choisies en fonction de la demande attendue.

Définition 2.1 (Perte linéaire avec covariable)**.** Posons le vecteur de paramètres et le vecteur de caractéristiques

$$w = \begin{pmatrix} \theta \\ \beta \end{pmatrix} \in \mathbb{R}^2, \qquad z_t = \begin{pmatrix} 1 \\ x_t \end{pmatrix} \in \mathbb{R}^2.$$

La prédiction du modèle est $\widehat{y}_t(w) = z_t^\top w = \theta + \beta x_t$. Sa perte quadratique au jour t vaut

$$\widetilde{\ell}_t(w) = \frac{1}{2}\left(y_t - z_t^\top w\right)^2 = \frac{1}{2}(y_t - \theta - \beta x_t)^2.$$

La stratégie FTL **estime conjointement** les deux coefficients :

$$w_t \in \arg\min_{w \in \mathcal{K}} \frac{1}{2} \sum_{s=1}^{t-1} (y_s - z_s^\top w)^2, \quad t \geq 2.$$

La différence est importante : on ne choisit pas d'abord une moyenne historique puis un coefficient arbitraire. **Les deux paramètres sont réestimés sur les données passées en résolvant le même problème d'optimisation.**

2.2 Cas binaire : une solution explicite pour FTL

Pour comprendre exactement ce que doit calculer le notebook, posons

$$I_j(t) = \{s < t : x_s = j\}, \qquad n_j(t) = |I_j(t)|, \quad j \in \{0, 1\}.$$

Lorsque $n_0(t), n_1(t) > 0$, définissons les moyennes historiques conditionnelles

$$\overline{y}_{j,t} = \frac{1}{n_j(t)} \sum_{s \in I_j(t)} y_s.$$

Le critère de FTL se sépare alors en deux groupes :

$$F_{t-1}(\theta, \beta) = \frac{1}{2} \sum_{s \in I_0(t)} (y_s - \theta)^2 + \frac{1}{2} \sum_{s \in I_1(t)} (y_s - \theta - \beta)^2.$$

Proposition 2.2 (FTL avec indicateur de promotion)**.** *Si les deux modalités ont été observées au moins une fois, le minimiseur est unique et vérifie*

$$\theta_t = \overline{y}_{0,t}, \qquad \beta_t = \overline{y}_{1,t} - \overline{y}_{0,t}.$$

Par conséquent,

$$\widetilde{\theta}_t = \begin{cases} \overline{y}_{0,t}, & x_t = 0, \\ \overline{y}_{1,t}, & x_t = 1. \end{cases}$$

Le modèle enrichi réalise donc une moyenne historique par groupe*, selon le statut de promotion.*

Exemple 2.3 (Calcul au jour 4)**.** Supposons avoir observé $y_1 = 10$, $y_2 = 18$, $y_3 = 12$, avec $x_1 = 0$, $x_2 = 1$, $x_3 = 0$. La moyenne hors promotion vaut $(10 + 12)/2 = 11$, tandis que celle des jours de promotion vaut 18. FTL fournit donc, avant le quatrième jour,

$$\theta_4 = 11, \qquad \beta_4 = 18 - 11 = 7.$$

Si $x_4 = 1$, la prévision enrichie est 18, contre $40/3 \simeq 13.33$ pour le modèle sans covariable. Si la demande réelle est $y_4 = 21$, leurs pertes quadratiques sont respectivement 4.5 et $529/18 \simeq 29.39$. Il s'agit d'un exemple illustratif, non d'une domination garantie.

Preuve. On obtient $\partial_\beta F_{t-1} = n_1(t)(\theta + \beta - \overline{y}_{1,t})$ et $\partial_\theta F_{t-1} = n_0(t)(\theta - \overline{y}_{0,t}) + n_1(t)(\theta + \beta - \overline{y}_{1,t})$. Leur annulation donne les deux expressions. Comme les deux groupes sont non vides, la matrice hessienne cumulée est définie positive : le minimiseur est unique. □

Point de vigilance. Démarrage à froid. Tant qu'une des modalités $x = 0$ ou $x = 1$ n'a pas été observée, les coefficients θ et β ne sont pas identifiables séparément par les moindres carrés. Pour définir une politique déterministe dans l'exercice, nous imposons alors $\beta_t = 0$ et $\theta_t = \frac{1}{t-1}\sum_{s<t} y_s$ pour $t \geq 2$. Ce choix reste un minimiseur FTL de la perte historique. Au premier tour, on prendra $\theta_1 = 10$ et $\beta_1 = 0$.

Remarque 2.4 (Pourquoi le théorème logarithmique ne s'applique pas directement). Pour une observation, la hessienne de la perte enrichie est

$$\nabla^2 \widetilde{\ell}_t(w) = z_t z_t^\top = \begin{pmatrix} 1 & x_t \\ x_t & x_t^2 \end{pmatrix}.$$

Cette matrice est de rang un et possède une valeur propre nulle : $\widetilde{\ell}_t$ n'est pas α-fortement convexe sur $\mathbb{R}^2$ pour $\alpha > 0$. En revanche, la hessienne *cumulée* devient définie positive lorsque les deux modalités apparaissent. Une telle propriété ne constitue pas, à elle seule, l'hypothèse uniforme de forte convexité de chaque perte du théorème précédent.

2.3 Travail demandé dans le notebook Python

Objectif. À partir du notebook illustratif fourni, implémenter une stratégie FTL utilisant une covariable binaire de promotion, puis comparer rigoureusement ses prédictions et ses pertes à celles du FTL initial sans covariable. **Aucune observation future ne doit entrer dans une décision au temps t.**

Exercice 2.1 (FTL contextuel : promotion et demande)**. Données.** Conservez l'axe temporel et la graine aléatoire existants dans le notebook. Si celui-ci dispose déjà d'un indicateur de promotion connu avant le jour t, utilisez-le. Sinon, créez une suite $x_t \in \{0, 1\}$, par exemple avec $\mathbb{P}(x_t = 1) = 0.2$ et une graine fixée. Pour rendre l'effet mesurable, construisez à partir de la demande initiale y_t^{base} la demande d'étude

$$y_t = y_t^{\text{base}} + \delta x_t, \qquad \delta > 0$$

avec une amplitude δ adaptée à l'échelle du notebook (par exemple $\delta = 8$ pour des ventes en unités). N'appliquez *pas* cette correction si la promotion agit déjà sur la variable cible d'origine.

À programmer et analyser :

1. **Modèle de référence.** Reprendre FTL sans covariable : $\widehat{y}_t^{\text{base}} = \theta_t^{\text{base}}$, où θ_t^{base} minimise la perte quadratique sur les dates $s < t$. Fixer la prévision initiale à 10.
2. **Modèle enrichi.** Calculer, pour chaque t, les nombres $n_0(t)$ et $n_1(t)$, puis θ_t et β_t *uniquement avec les jours $s < t$*. Appliquer la convention de démarrage à froid donnée précédemment. Produire $\widehat{y}_t^{\text{promo}} = \theta_t + \beta_t x_t$.

3. **Pertes.** Pour les *mêmes* observations y_t, calculer les deux pertes réalisées

$$L_T^{\text{base}} = \frac{1}{2}\sum_{t=1}^{T}(y_t - \widehat{y}_t^{\text{base}})^2, \qquad L_T^{\text{promo}} = \frac{1}{2}\sum_{t=1}^{T}(y_t - \widehat{y}_t^{\text{promo}})^2.$$

   Tracer l'évolution des deux pertes cumulées.

4. **Comparateur commun.** Calculer *après coup* $w^\star = (\theta^\star, \beta^\star)$ qui minimise $\sum_{t=1}^{T}\widetilde{\ell}_t(w)$ sur toute la période. Comparer les deux stratégies à ce **même** comparateur :

$$\text{Reg}_T^{\text{base|promo}} = L_T^{\text{base}} - \sum_{t=1}^{T}\widetilde{\ell}_t(w^\star),$$

$$\text{Reg}_T^{\text{promo}} = L_T^{\text{promo}} - \sum_{t=1}^{T}\widetilde{\ell}_t(w^\star).$$

   Pour tracer le **regret standard à chaque horizon** t, recalculer le comparateur $w_t^\star$ sur les seules dates $s \le t$: $\text{Reg}_t = L_t - F_t(w_t^\star)$. La courbe finale à T utilise donc $w_T^\star$; tracer aussi Reg_t/t. Pour la stratégie de référence, employer le même comparateur contextualisé, afin de comparer les deux modèles sur une base commune.

5. **Interprétation.** Tracer y_t, les deux prévisions, les indicateurs de promotion et l'évolution de β_t. Comparer aussi les erreurs les jours de promotion ($x_t = 1$) et hors promotion ($x_t = 0$). Discuter l'avantage éventuel de la covariable, et ce qui se produit lorsque les promotions sont rares.

Remarque 2.5 (Indications d'implémentation). Les premières lignes de la boucle doivent utiliser x_t et l'historique $\{(x_s, y_s) : s < t\}$. La variable y_t n'est consultée **qu'après** l'enregistrement de la prévision. Les étudiants peuvent calculer les moyennes conditionnelles explicitement ou vérifier le résultat par `numpy.linalg.lstsq` après que les deux groupes ont été observés. Dans le cas général, un ajustement `fit` sur toutes les lignes avant la boucle constituerait une fuite d'information.

Chronologie d'implémentation (pseudo-code)

Entrées : demandes $y_{1:T}$, indicateurs $x_{1:T}$, valeurs initiales $(\theta_1, \beta_1) = (10, 0)$.
Pour $t = 1, \dots, T$ **:**

1. Estimer θ_t, β_t à partir des seules dates $s < t$.
2. Lire x_t et enregistrer $\widehat{y}_t = \theta_t + \beta_t x_t$.
3. Révéler y_t, calculer $\frac{1}{2}(y_t - \widehat{y}_t)^2$.
4. Ajouter (x_t, y_t) à l'historique pour le tour $t + 1$.

Sorties : prévisions, trajectoires des paramètres, pertes cumulées et regrets.

Point de vigilance. Les deux regrets construits avec le comparateur enrichi ne répondent pas au même théorème que le regret du FTL scalaire. Le modèle constant appartient néanmoins à la classe enrichie ($\beta = 0$), ce qui rend la comparaison opérationnelle pertinente. Une amélioration de la perte empirique réalisée doit être constatée numériquement : elle n'est pas garantie à chaque horizon.

3 Follow the Regularized Leader (FTRL)

3.1 Pourquoi régulariser ? Le rappel de Ridge

Dans le cadre statistique supervisé, les observations $(X_i, Y_i)_{i=1}^n$ permettent d'ajuster un modèle $\mu_\beta(X_i)$. Pour une régression linéaire avec $\beta = (\beta_1, \dots, \beta_p)^\top$, la régression Ridge minimise la perte

quadratique augmentée d'une pénalisation :

$$\widehat{\beta}^{\text{ridge}} \in \arg\min_{\beta_0\in\mathbb{R},\,\beta\in\mathbb{R}^p} \left\{ \underbrace{\frac{1}{2}\sum_{i=1}^{n}(Y_i-\beta_0-\beta^\top X_i)^2}_{\text{adéquation aux données}} + \underbrace{\frac{\lambda}{2}\|\beta\|_2^2}_{\text{pénalisation}} \right\}, \quad \lambda>0.$$

L'ordonnée à l'origine β_0 n'est habituellement pas pénalisée. Lorsque λ augmente, les coefficients explicatifs sont ramenés vers zéro ; lorsque $\lambda \to 0^+$, on retrouve les moindres carrés ordinaires lorsque la solution limite est bien définie. La pénalisation ℓ_2 *ne crée pas en général de coefficients exactement nuls*, contrairement à une pénalisation ℓ_1 de type Lasso.

3.2 Un terme constant ne change pas un minimiseur

Exemple 3.1 (Ajouter une constante à l'objectif)**.** Considérons le problème élémentaire

$$u^\star = \arg\min_{u\in\mathbb{R}}(u-1)^2 = 1.$$

Si nous ajoutons une constante indépendante de u, par exemple 170, alors

$$u^\star = \arg\min_{u\in\mathbb{R}}\{(u-1)^2+170\} = 1.$$

En effet, la dérivée ne change pas et, plus généralement,

$$\arg\min_{u\in\mathcal{K}}\{f(u)+C\} = \arg\min_{u\in\mathcal{K}} f(u, \qquad C\in\mathbb{R}.$$

Le minimum *en valeur* augmente de C, mais *le point minimisant* reste identique. C'est ce principe qui permettra de supprimer les termes indépendants de u dans le FTRL linéarisé.

3.3 FTRL : stabiliser les décisions en ligne

FTL minimise exclusivement l'historique des pertes. FTRL lui ajoute une fonction de régularisation R destinée à contrôler l'amplitude ou les variations des décisions.

Définition 3.2 (Follow the Regularized Leader)**.** Étant donnés $R:\mathcal{K}\to\mathbb{R}$ et $\eta>0$, FTRL choisit

$$w_{t+1} \in \arg\min_{u\in\mathcal{K}}\left\{\sum_{s=1}^{t}\ell_s(u)+\frac{1}{\eta}R(u)\right\}.$$

La régularisation peut, par exemple, être quadratique : $R(u)=\frac{1}{2}\|u\|_2^2$, soit un terme $\frac{1}{2\eta}\|u\|_2^2$.

Le paramètre η contrôle ici le poids *inverse* de la régularisation. La régularisation rend le critère cumulatif plus fortement courbé et peut éviter qu'une petite variation des observations fasse basculer brutalement le minimiseur.

3.4 Que signifie « linéariser » une fonction ?

Souvenez-vous du développement de Taylor au premier ordre. Si $f:\mathbb{R}^d\to\mathbb{R}$ est différentiable en w, alors, pour $u\to w$,

$$f(u) = f(w) + \langle \nabla f(w), u-w\rangle + o(\|u-w\|_2).$$

La fonction affine

$$u \longmapsto f(w) + \langle \nabla f(w), u-w\rangle$$

est la **linéarisation affine** de f au voisinage de w. En dimension un, il s'agit de l'équation de la tangente au graphe.

Exemple 3.3 (Linéariser une fonction quadratique)**.** Pour $f(u) = (u-1)^2$ et un point $w \in \mathbb{R}$,

$$f(u) = \underbrace{(w-1)^2 + 2(w-1)(u-w)}_{\text{partie affine}} + \underbrace{(u-w)^2}_{o(|u-w|) \text{ quand } u \to w}.$$

Le terme quadratique est négligeable devant $|u-w|$ à proximité de w. L'approximation affine est donc précise *localement*.

Remarque 3.4 (Différentiabilité et convexité). Pour une fonction convexe non différentiable, on ne peut pas invoquer le développement de Taylor ordinaire. En revanche, si $g \in \partial f(w)$, l'affine $f(w) + \langle g, u - w\rangle$ est un **minorant global** de f, exact en $u = w$. C'est cette propriété qui justifie le FTRL linéarisé utilisant les sous-gradients.

3.5 FTRL linéarisé : la connexion avec les sous-gradients

Choisissons au temps s un sous-gradient $g_s \in \partial \ell_s(w_s)$. L'inégalité du premier ordre donne

$$\ell_s(u) \geq \ell_s(w_s) + \langle g_s, u - w_s\rangle.$$

Le membre de droite est un **minorant affine exact au point** w_s, mais il n'est pas nécessairement une approximation de Taylor au sens usuel lorsque la fonction n'est pas différentiable. Nous pouvons le choisir comme *perte de substitution linéarisée* :

$$\widehat{\ell}_s(u) = \ell_s(w_s) + \langle g_s, u - w_s\rangle.$$

En substituant ces pertes dans l'objectif régularisé, les termes indépendants de u disparaissent de l'argmin :

$$\begin{aligned} w_{t+1} &\in \arg\min_{u \in \mathcal{K}} \left\{ \sum_{s=1}^{t} \widehat{\ell}_s(u) + \frac{1}{2\eta}\|u\|_2^2 \right\} \\ &= \arg\min_{u \in \mathcal{K}} \left\{ \left\langle \sum_{s=1}^{t} g_s, u \right\rangle + \frac{1}{2\eta}\|u\|_2^2 \right\}. \end{aligned}$$

Proposition 3.5 (Mise à jour explicite du FTRL linéarisé)**.** *Avec $\mathcal{K} = \mathbb{R}^d$ et $R(u) = \frac{1}{2}\|u\|_2^2$,*

$$w_{t+1} = -\eta \sum_{s=1}^{t} g_s.$$

Pour un ensemble convexe fermé non vide $\mathcal{K}$, la solution est la projection euclidienne

$$w_{t+1} = \Pi_{\mathcal{K}} \left(-\eta \sum_{s=1}^{t} g_s \right).$$

Preuve. En complétant le carré,

$$\left\langle \sum_{s \leq t} g_s, u \right\rangle + \frac{1}{2\eta}\|u\|_2^2 = \frac{1}{2\eta} \left\| u + \eta \sum_{s \leq t} g_s \right\|_2^2 - \frac{\eta}{2} \left\| \sum_{s \leq t} g_s \right\|_2^2.$$

Le dernier terme est constant en u. Le minimiseur sans contrainte est l'opposé de la somme des gradients multipliée par η ; avec contraintes convexes fermées, on le projette sur $\mathcal{K}$. □

Remarque 3.6 (FTL, FTRL et FTRL linéarisé). FTL minimise les *vraies* pertes passées. FTRL minimise ces pertes avec une régularisation. Le FTRL *linéarisé* remplace chaque perte par son minorant affine construit au point effectivement joué. Ces objectifs sont différents, même lorsqu'ils partagent le principe de décision séquentielle.

3.6 Prolongement facultatif du notebook : Ridge en ligne

Pour le modèle promotionnel $w = (\theta, \beta)$, on peut stabiliser l'estimation en pénalisant seulement l'effet de promotion :

$$(\theta_t, \beta_t) \in \arg\min_{\theta,\beta\in\mathbb{R}} \left\{ \frac{1}{2}\sum_{s=1}^{t-1}(y_s - \theta - \beta x_s)^2 + \frac{\lambda}{2}\beta^2 \right\}, \quad \lambda > 0.$$

Il s'agit d'une variante de FTRL (Ridge sur le coefficient de promotion). Pour $t \geq 2$, elle possède un minimiseur unique dès qu'une observation passée est disponible ; en particulier, $\beta_t = 0$ lorsqu'une seule modalité de x a été rencontrée. Demander en complément de comparer les courbes de β_t avec et sans pénalisation, pour plusieurs valeurs de λ, et de commenter le compromis entre stabilité et adaptation.

4 Ouverture : prévision contextuelle et mémoire temporelle

Dans nos premiers exemples, l'apprenant choisissait directement un nombre θ_t comme prévision :

$$\widehat{y}_t = \theta_t, \qquad \ell_t(\theta_t) = \frac{1}{2}(\theta_t - y_t)^2.$$

Mais une prévision peut aussi dépendre de **caractéristiques connues au moment de décider**. La décision en ligne ne porte alors plus sur une quantité prédite, mais sur les *paramètres d'un prédicteur*.

4.1 Des covariables exogènes et des retards observés

Supposons que $x_t \in \{0, 1\}$ indique si une promotion est prévue au jour t. Il est également naturel d'utiliser les ventes récentes $y_{t-1}, y_{t-2}, \ldots$ déjà observées. On pourrait être tenté de poser le vecteur $\boldsymbol{z}_t = (x_t, y_1, \ldots, y_{t-1})$. **L'idée temporelle est correcte, mais ce vecteur grandit avec** t : sa dimension varie, ce qui empêche d'utiliser directement un paramètre $w \in \mathbb{R}^d$ de dimension fixe dans les formules usuelles de FTL, FTRL et OGD.

Pour le notebook, choisissons donc un nombre de retards **fixé** $p \geq 1$ (par exemple $p = 2$) et le vecteur

$$\boldsymbol{z}_t = (1,\, x_t,\, y_{t-1}, \ldots, y_{t-p})^\top \in \mathbb{R}^{p+2}, \qquad t \geq p + 1.$$

Le premier coefficient est une constante d'interception et $\boldsymbol{z}_t$ est disponible avant de révéler y_t. Les p premières observations servent à initialiser les retards.

Définition 4.1 (Prédiction linéaire contextuelle)**.** Le paramètre en ligne est $w_t \in \mathcal{K} \subset \mathbb{R}^{p+2}$; la prévision et sa perte sont

$$\widehat{y}_t = w_t^\top \boldsymbol{z}_t, \qquad \ell_t(w_t) = \frac{1}{2}\big(w_t^\top \boldsymbol{z}_t - y_t\big)^2.$$

Le protocole est : observer $\boldsymbol{z}_t$, choisir w_t avec le seul passé, émettre $\widehat{y}_t$, révéler y_t, enregistrer la perte, puis actualiser w_{t+1}.

4.2 Trois stratégies pour un même modèle

On notera $t_0 = p + 1$ le premier jour évalué et $R(w) = \frac{1}{2}\|w\|_2^2$ une régularisation possible. Pour $t \geq t_0$, les trois stratégies utilisent les **mêmes** observations et la **même** fonction de perte :

$$\textbf{FTL :} \quad w_t \in \arg\min_{w \in \mathcal{K}} \sum_{s=t_0}^{t-1} \ell_s(w),$$

$$\textbf{FTRL :} \quad w_t \in \arg\min_{w \in \mathcal{K}} \left\{ \sum_{s=t_0}^{t-1} \ell_s(w) + \lambda R(w) \right\},$$

$$\textbf{OGD :} \quad w_{t+1} = \Pi_{\mathcal{K}}(w_t - \eta_t \nabla \ell_t(w_t)).$$

Pour OGD, le gradient vectoriel s'écrit explicitement

$$\nabla \ell_t(w_t) = (w_t^\top \boldsymbol{z}_t - y_t)\boldsymbol{z}_t.$$

À la date t_0, la somme historique de FTL est vide : il faut spécifier un choix initial commun w_{t_0} et une règle de départage des minimiseurs non uniques (par exemple la solution de norme minimale). Pour FTRL, $\lambda > 0$ pénalise le vecteur des coefficients (éventuellement sans pénaliser l'interception, à préciser explicitement).

Remarque 4.2 (La dimension modifie la géométrie de la perte). La hessienne de la perte d'un jour est

$$\nabla^2 \ell_t(w) = \boldsymbol{z}_t \boldsymbol{z}_t^\top.$$

Cette matrice est de rang au plus un. Dès que $d = p + 2 > 1$, la perte individuelle n'est pas fortement convexe sur $\mathbb{R}^d$. Une forte convexité de la *somme* des pertes peut apparaître si les caractéristiques sont suffisamment variées, mais les hypothèses du théorème logarithmique précédent ne sont pas automatiquement vérifiées.

Point de vigilance. Il est interdit d'utiliser y_t, y_{t+1} ou des retards calculés à partir de la série complète avant d'avoir émis la prévision du jour t. On ne doit pas non plus ajuster les normalisations avec les observations futures. Les mêmes dates $t_0, \ldots, T$ doivent servir à comparer les trois stratégies.

À retenir. Le modèle initial apprend une prévision constante ; le modèle contextualisé apprend $\widehat{y}_t = \theta_t + \beta_t x_t$. FTRL vise à stabiliser cette estimation. Dans les deux cas, *la prévision précède toujours l'observation de* y_t.

Travail à rendre — 15 novembre 2026, 23 h 59

Objectif. Reprendre le notebook illustratif `Illustration_FTL_FTRL_OGD.ipynb` et y appliquer **FTL, FTRL et OGD** au *même modèle contextuel* avec promotion et mémoire temporelle. La fiche interactive `circular_block_bootstrap_interactive.html` sert de référence pour le bootstrap circulaire par blocs.

1. Formaliser le nouveau jeu de caractéristiques. L'indicateur $x_t \in \{0,1\}$ correspond à la promotion du jour t, connue avant la décision. Utiliser un nombre fixe de retards, par exemple $p = 2$, et poser pour $t \geq p+1$:

$$\boldsymbol{z}_t = (1, x_t, y_{t-1}, \ldots, y_{t-p})^\top, \quad \widehat{y}_t = w_t^\top \boldsymbol{z}_t.$$

Pour ce devoir, il faut donc retenir p retards (ou justifier une représentation fixe équivalente) et faire glisser la fenêtre d'une unité au fur et à mesure.

2. Implémenter et comparer les trois algorithmes. Conserver le protocole **prévision → observation → perte → mise à jour**. Initialiser les modèles de façon documentée et préciser les coefficients de régularisation et les pas d'apprentissage. À chaque jour t, calculer

$$\ell_t(w_t) = \frac{1}{2}(\widehat{y}_t - y_t)^2, \qquad L_t^A = \sum_{s=t_0}^{t} \ell_s(w_s^A), \quad A \in \{\mathrm{FTL}, \mathrm{FTRL}, \mathrm{OGD}\}.$$

Pour la comparaison, employer **un même comparateur fixe en hindsight** de la classe linéaire enrichie :

$$w_t^\star \in \arg\min_{w \in \mathcal{K}} \sum_{s=t_0}^{t} \ell_s(w), \qquad \mathrm{Reg}_t^A = L_t^A - \sum_{s=t_0}^{t} \ell_s(w_t^\star).$$

Le dénominateur de la courbe de regret moyen sera le nombre de *tours évalués*, $n_t = t - t_0 + 1$. Tracer Reg_t^A / n_t. Si l'on choisit plutôt Reg_t^A / t, il faut expliquer le traitement des p premiers jours.

3. Représenter les prévisions et l'incertitude.

- **Visualisation :** tracer sur un même graphique les observations réelles y_t, les trois prévisions $\widehat{y}_t^A$ et leurs intervalles prédictifs empiriques à 95 %.
- **Bootstrap circulaire par blocs (CBB) :** rééchantillonner des blocs consécutifs de longueur ℓ afin de préserver la dépendance temporelle locale. Fixer une graine, préciser le nombre de répétitions B et justifier le choix de ℓ.
- **Construction séquentielle :** au jour t, utiliser uniquement les données antérieures à t. Rééchantillonner l'historique, réajuster le modèle, puis simuler une innovation à partir des résidus passés, en explicitant les hypothèses retenues.
- **Intervalles prédictifs :** calculer les quantiles empiriques à 2.5 % et 97.5 % des prédictions simulées pour construire les intervalles à 95 %.
- **Limites :** ces intervalles sont approximatifs et ne bénéficient d'aucune garantie universelle de couverture.

4. Incertitude sur le regret moyen. Tracer aussi, pour chaque algorithme, la suite $\left(\mathrm{Reg}_t^A / n_t\right)_{t=t_0}^{T}$, accompagnée d'un **intervalle bootstrap empirique à 95 %**. Pour chaque réplication $b = 1, \ldots, B$, rééchantillonner les observations alignées (x_s, y_s) *par blocs circulaires*, reconstruire les retards $y_{s-j}^{*(b)}$ sur la série rééchantillonnée, **relancer entièrement** FTL, FTRL et OGD, puis recalculer le comparateur $w_t^{\star,(b)}$ et le regret $\mathrm{Reg}_t^{A,(b)}$. Pour chaque horizon t, poser

$$\mathrm{IC}_{95\%}^{\mathrm{boot}}\left(\frac{\mathrm{Reg}_t^A}{n_t}\right) = \left[Q_{0.025}\left(r_t^{A,*(1:B)}\right), Q_{0.975}\left(r_t^{A,*(1:B)}\right)\right],$$

avec $r_t^{A,*(b)} = \mathrm{Reg}_t^{A,(b)} / n_t$. Ces bornes représentent une *variabilité empirique sous rééchantillonnage* et ne doivent pas être présentées comme des garanties de regret valables pour toute suite adversariale.

5. Analyse attendue. Discuter les performances les jours avec et sans promotion, l'effet des p retards, le choix du pas OGD, la régularisation FTRL, la taille des blocs ℓ et l'écart entre *regret réalisé*, *intervalle prédictif* et *intervalle bootstrap pour le regret moyen*. Indiquer les limites de validité du bootstrap (dépendance temporelle, stationnarité locale, effets de bord entre blocs, petit échantillon).

Livrable. Un notebook `.ipynb` exécutable, avec les cellules de code complétées, figures légendées, graine aléatoire fixée, paramètres documentés et réponses rédigées en Markdown. **Date limite : dimanche 15 novembre 2026, 23 h 59.**