Online Learning — Notes de la séance du 9 novembre 2026

Descente de gradient en ligne, régularisation quadratique et décisions d'inventaire

1 Rappel : la descente de gradient en ligne

1.1 Prédire une série temporelle sans connaître le futur

Considérons une série temporelle $(Y_t)_{t\geq 1}$, dont les observations sont notées $y_1, y_2, \ldots$. Au temps t, nous souhaitons produire une prévision $\widehat{y}_t$ à partir des seules informations disponibles *avant* de connaître y_t. Après révélation de cette observation, nous pourrons actualiser la prévision destinée au tour suivant.

Dans le modèle le plus simple, l'apprenant choisit un nombre $\theta_t \in \mathcal{K} \subseteq \mathbb{R}$ et annonce $\widehat{y}_t = \theta_t$. L'ensemble $\mathcal{K}$ est supposé non vide, fermé et convexe ; il représente les décisions admissibles.

Définition 1.1 (Perte instantanée quadratique)**.** Pour une observation y_t, la perte associée à une décision $\theta \in \mathcal{K}$ est

$$\ell_t(\theta) = \frac{1}{2}(\theta - y_t)^2.$$

Sa dérivée, calculée *par rapport à la décision*, est

$$\ell_t'(\theta) = \theta - y_t.$$

La perte réalisée est $\ell_t(\theta_t)$; elle n'est connue qu'après la révélation de y_t.

Point de vigilance. La perte *instantanée* ℓ_t ne contient pas de somme sur toutes les dates $1, \ldots, T$. Cette somme définit une perte *cumulée*. Le signe du gradient est également important : $\ell_t'(\theta_t) = \theta_t - y_t$, et non $y_t - \theta_t$.

1.2 Le protocole OGD : décision, perte, mise à jour

La **descente de gradient en ligne** (*Online Gradient Descent*, OGD) modifie sa décision après chaque observation. Pour des pertes convexes non différentiables, on peut remplacer le gradient par un sous-gradient.

Définition 1.2 (Online Gradient Descent)**.** Soit $\mathcal{K} \subseteq \mathbb{R}^d$ un ensemble convexe fermé non vide. On initialise $\theta_1 \in \mathcal{K}$ et l'on choisit des pas $\eta_t > 0$. Pour chaque tour $t = 1, \ldots, T$:

1. **Décision :** choisir θ_t à partir du passé disponible.
2. **Observation :** révéler y_t, puis calculer la perte $\ell_t(\theta_t)$ et un sous-gradient $g_t \in \partial \ell_t(\theta_t)$.
3. **Mise à jour :** définir la décision du tour suivant par

$$\theta_{t+1} = \Pi_{\mathcal{K}}(\theta_t - \eta_t g_t),$$

où $\Pi_{\mathcal{K}}$ désigne la projection euclidienne sur $\mathcal{K}$.

On peut formaliser l'information historique par $\mathcal{H}_{t-1} = \{(\theta_s, y_s, \ell_s(\theta_s), g_s) : s < t\}$. La décision θ_t dépend de $\mathcal{H}_{t-1}$; en revanche, y_t n'appartient pas encore à cet historique.

Pour la perte quadratique scalaire, OGD devient

$$\begin{aligned}\theta_{t+1} &= \Pi_{\mathcal{K}}(\theta_t - \eta_t(\theta_t - y_t)) \\ &= \Pi_{\mathcal{K}}((1-\eta_t)\theta_t + \eta_t y_t).\end{aligned}$$

Lorsque $\mathcal{K} = \mathbb{R}$ et $0 < \eta_t \leq 1$, la nouvelle décision est une moyenne pondérée de l'ancienne prévision et de la dernière observation. Elle pourra servir à prédire y_{t+1}, mais n'a pas été utilisée pour prédire y_t.

2 OGD pour une régression avec covariables

2.1 Un prédicteur linéaire mis à jour séquentiellement

Prenons l'exemple d'une boulangerie. Pour prévoir les ventes de baguettes au jour t, nous pouvons exploiter les ventes passées et une promotion annoncée à l'avance. Une telle covariable est disponible lors de la prévision, même si la demande y_t reste inconnue.

Notons $z_t \in \mathbb{R}^d$ le vecteur des caractéristiques disponibles au début du jour t, et $w_t \in \mathcal{K} \subseteq \mathbb{R}^d$ les coefficients du prédicteur. Nous posons

$$\widehat{y}_t = w_t^\top z_t, \qquad \ell_t(w) = \frac{1}{2}(w^\top z_t - y_t)^2.$$

Le choix du modèle et celui de la fonction de perte déterminent entièrement le gradient utilisé par OGD.

Proposition 2.1 (Gradient de la perte de régression). *Pour $\ell_t(w) = \frac{1}{2}(w^\top z_t - y_t)^2$, le gradient au paramètre courant est*

$$g_t = \nabla \ell_t(w_t) = \underbrace{(w_t^\top z_t - y_t)}_{e_t} z_t,$$

où $e_t = \widehat{y}_t - y_t$ désigne le résidu signé. La mise à jour est

$$w_{t+1} = \Pi_{\mathcal{K}}\left(w_t - \eta_t e_t z_t\right).$$

Preuve. En appliquant la règle de dérivation en chaîne à $\ell_t(w) = \frac{1}{2}(w^\top z_t - y_t)^2$, et en utilisant $\nabla_w(w^\top z_t) = z_t$, on obtient le résultat. □

Remarque 2.2 (Chronologie de la prévision à un pas). À la fin du jour t, nous connaissons $y_1, \ldots, y_t$. Pour prévoir y_{t+1}, nous utilisons w_{t+1}, appris grâce aux observations jusqu'à t, et un vecteur z_{t+1} connu avant la vente :

$$\widehat{y}_{t+1|t} = w_{t+1}^\top z_{t+1}.$$

Il faut distinguer le *paramètre* w_{t+1}, actualisé après le jour t, du *vecteur de caractéristiques* z_{t+1}, constitué sans utiliser la cible future y_{t+1}.

2.2 Retards temporels et composantes harmoniques

Une première construction consiste à retenir les p dernières ventes, ainsi qu'un indicateur de promotion $x_t \in \{0, 1\}$:

$$z_t^{\text{retards}} = (1, x_t, y_{t-1}, y_{t-2}, \ldots, y_{t-p})^\top, \qquad t \geq p + 1.$$

Le premier coefficient correspond à l'ordonnée à l'origine ; la **dimension du vecteur reste fixe**, contrairement au choix $(y_1, \ldots, y_{t-1})$ dont la taille augmente avec t.

Pour représenter les oscillations présentes dans les dernières ventes, on peut également calculer les premières composantes de Fourier sur la fenêtre historique $(y_{t-p}, \ldots, y_{t-1})$. Avec $p \geq 7$ et $k \in \{1, 2, 3\}$, une convention possible est

$$a_{k,t} = \frac{2}{p}\sum_{j=1}^{p} y_{t-j} \cos\left(\frac{2\pi k(j-1)}{p}\right),$$

$$b_{k,t} = \frac{2}{p}\sum_{j=1}^{p} y_{t-j} \sin\left(\frac{2\pi k(j-1)}{p}\right).$$

Ces coefficients sont disponibles avant la révélation de y_t. On pourrait donc proposer le vecteur enrichi

$$z_t = (1, x_t, y_{t-1}, \ldots, y_{t-p}, a_{1,t}, b_{1,t}, a_{2,t}, b_{2,t}, a_{3,t}, b_{3,t})^\top.$$

Point de vigilance. Les coefficients $a_{k,t}$ et $b_{k,t}$ ci-dessus sont des **combinaisons linéaires des mêmes p retards**. Les ajouter à *tous* ces retards ne fournit donc aucune information supplémentaire à un prédicteur linéaire : cela introduit des colonnes dépendantes dans la matrice de régression. Pour une expérimentation, on peut *remplacer* les retards par les composantes harmoniques, ou utiliser une base de saisonnalité calendaire distincte.

Par exemple, si une périodicité P est connue, les variables

$$c_{k,t} = \cos\left(\frac{2\pi kt}{P}\right), \qquad s_{k,t} = \sin\left(\frac{2\pi kt}{P}\right)$$

sont connues à l'avance et peuvent compléter les retards. Leur présence permet au modèle de représenter une saisonnalité explicite sans consulter les demandes futures. Une normalisation éventuelle doit elle aussi être estimée avec les seules observations passées.

2.3 Rappel : matrices positives et convexité

Définition 2.3 (Matrices semi-définies et définies positives)**.** Soit $A \in \mathbb{R}^{d\times d}$ une matrice **symétrique**. On dit que A est

- **semi-définie positive**, et l'on note $A \succeq 0$, si $v^\top A v \geq 0$ pour tout $v \in \mathbb{R}^d$;
- **définie positive**, et l'on note $A \succ 0$, si $v^\top A v > 0$ pour tout $v \in \mathbb{R}^d \setminus \{0\}$.

Le théorème spectral assure l'existence d'une matrice orthogonale Q et d'une matrice diagonale Λ telles que

$$A = Q\Lambda Q^\top, \qquad \Lambda = \mathrm{diag}(\lambda_1, \dots, \lambda_d).$$

Dans ce cadre symétrique,

$$A \succeq 0 \iff \lambda_i \geq 0 \quad \text{pour tout } i,$$
$$A \succ 0 \iff \lambda_i > 0 \quad \text{pour tout } i.$$

Propriété 2.4 (Critères hessiens)**.** *Soit $f : \Omega \to \mathbb{R}$ une fonction de classe $\mathcal{C}^2$ sur un* ouvert convexe $\Omega \subseteq \mathbb{R}^d$. *Alors*

$$f \text{ convexe} \iff \forall w \in \Omega \quad \nabla^2 f(w) \succeq 0.$$

Si $\nabla^2 f(w) \succ 0$ partout, f est strictement convexe ; cette condition est suffisante, mais non nécessaire. Enfin, $\nabla^2 f(w) \succeq \alpha I_d$ partout caractérise la α-forte convexité pour $\alpha > 0$.

Exemple 2.5 (Une Hessienne de rang un)**.** Pour la perte quadratique du modèle linéaire,

$$\nabla^2 \ell_t(w) = z_t z_t^\top \succeq 0.$$

Cette matrice est de rang au plus un. Si $d > 1$ et $z_t \neq 0$, elle possède des valeurs propres nulles : la perte est convexe, mais elle n'est pas fortement convexe sur $\mathbb{R}^d$. La forte convexité de chaque perte ne peut donc pas être déduite de sa seule forme quadratique.

3 Regret de la régression par OGD

3.1 Hypothèses de bornitude et borne en $\sqrt{T}$

Nous étudions une suite de pertes convexes de régression avec les hypothèses uniformes suivantes :

$$\mathcal{K} = \{w \in \mathbb{R}^d : \|w\|_2 \leq B\}, \quad \|z_t\|_2 \leq R, \quad |y_t| \leq Y,$$

où $B, R > 0$, $Y \geq 0$, et $\mathcal{K}$ possède un diamètre $D = 2B$. Pour tout $w \in \mathcal{K}$, Cauchy–Schwarz donne

$$|w^\top z_t - y_t| \leq BR + Y.$$

Il en résulte

$$\|\nabla \ell_t(w)\|_2 \leq \underbrace{(BR+Y)R}_{G_{\text{quad}}}.$$

La borne des gradients provient donc *conjointement* de celle des paramètres, des covariables et des observations.

Théorème 3.1 (Regret en racine de T pour OGD projeté). *Supposons $G_{\text{quad}} > 0$ et l'horizon T connu. On initialise $w_1 \in \mathcal{K}$ et on choisit le pas constant*

$$\eta_t = \eta = \frac{2B}{G_{\text{quad}}\sqrt{T}}.$$

Alors, pour tout comparateur fixe $u \in \mathcal{K}$,

$$\text{Reg}_T(u) \leq 2BG_{\text{quad}}\sqrt{T} = 2B(BR+Y)R\sqrt{T}.$$

En particulier, le regret standard vérifie la même borne supérieure.

Preuve. Par convexité et par non-expansivité de la projection euclidienne,

$$\ell_t(w_t) - \ell_t(u) \leq \langle g_t, w_t - u\rangle \leq \frac{\|w_t - u\|_2^2 - \|w_{t+1} - u\|_2^2}{2\eta} + \frac{\eta}{2}\|g_t\|_2^2.$$

En sommant, puis en utilisant $\|w_1 - u\|_2 \leq D = 2B$ et $\|g_t\|_2 \leq G_{\text{quad}}$,

$$\text{Reg}_T(u) \leq \frac{D^2}{2\eta} + \frac{\eta G_{\text{quad}}^2 T}{2}.$$

Le choix $\eta = D/(G_{\text{quad}}\sqrt{T})$ conduit à $\text{Reg}_T(u) \leq DG_{\text{quad}}\sqrt{T}$. □

Après division par T,

$$\frac{\text{Reg}_T}{T} \leq \frac{2B(BR+Y)R}{\sqrt{T}} \xrightarrow[T\to\infty]{} 0.$$

Cette majoration garantit $\limsup_{T\to\infty} \text{Reg}_T/T \leq 0$, c'est-à-dire l'absence de *surcoût moyen asymptotiquement positif* par rapport au meilleur comparateur fixe. Le regret réalisé pouvant être négatif pour un algorithme adaptatif, la borne supérieure seule n'impose pas une convergence bilatérale vers zéro sur chaque trajectoire.

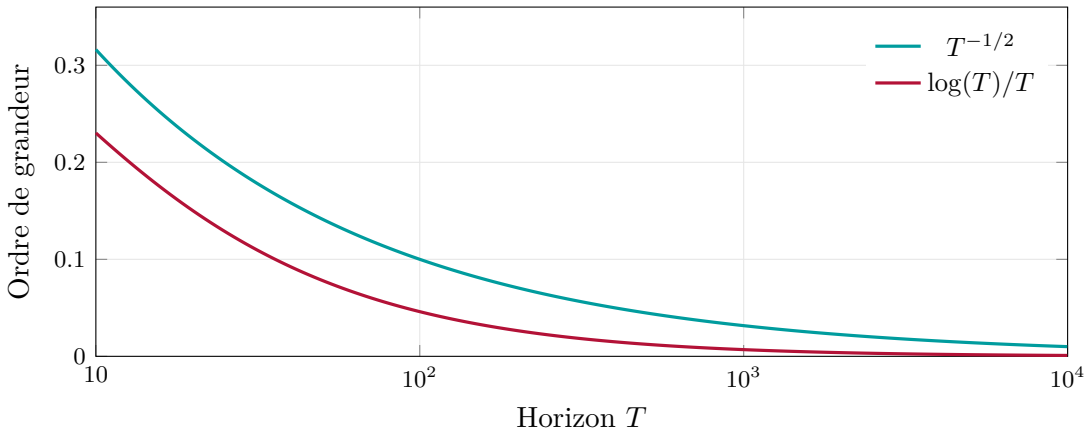
3.2 Comparer les vitesses de décroissance du regret moyen

Nous comparerons deux échelles asymptotiques, en omettant les constantes multiplicatives :

$$\frac{1}{\sqrt{T}} \quad \text{et} \quad \frac{\log T}{T}.$$

La seconde décroît plus vite, puisque

$$\frac{(\log T)/T}{T^{-1/2}} = \frac{\log T}{\sqrt{T}} \xrightarrow[T\to\infty]{} 0.$$



Abscisse logarithmique ; log désigne le logarithme népérien.

T	$T^{-1/2}$	$(\log T)/T$
10^2	0.1000	0.04605
10^3	0.0316	0.00691
10^4	0.0100	0.00092

Remarque 3.2 (Interprétation). Une borne $O(\log T)$ implique une borne moyenne $O((\log T)/T)$, plus rapide que $O(T^{-1/2})$. Cependant, elle nécessite généralement des hypothèses géométriques supplémentaires sur les pertes, notamment une forme de forte convexité. Nous allons voir comment une régularisation quadratique permet de l'obtenir.

4 OGD avec régularisation quadratique

4.1 Ajouter une pénalité à chaque perte

La perte de régression $\ell_t(w) = \frac{1}{2}(w^\top z_t - y_t)^2$ est convexe, mais elle n'est pas, en dimension $d > 1$, fortement convexe à chaque tour. L'idée consiste à ajouter une **pénalité quadratique** sur les coefficients du modèle.

Définition 4.1 (Perte quadratique régularisée)**.** Pour $\lambda > 0$, nous définissons

$$\widetilde{\ell}_t(w) = \underbrace{\frac{1}{2}(w^\top z_t - y_t)^2}_{\text{erreur de prévision}} + \underbrace{\frac{\lambda}{2}\|w\|_2^2}_{\text{pénalisation quadratique}}.$$

Cette pénalité est ajoutée *à chaque tour*.

Le gradient et la Hessienne se calculent directement :

$$\nabla\widetilde{\ell}_t(w) = (w^\top z_t - y_t)z_t + \lambda w,$$
$$\nabla^2\widetilde{\ell}_t(w) = z_t z_t^\top + \lambda I_d \succeq \lambda I_d.$$

Proposition 4.2 (Forte convexité et mise à jour régularisée)**.** *Chaque perte $\widetilde{\ell}_t$ est λ-fortement convexe. En notant $e_t = w_t^\top z_t - y_t$, l'OGD projeté devient*

$$w_{t+1} = \Pi_{\mathcal{K}}\Big(\underbrace{(1-\eta_t\lambda)w_t}_{\text{contraction des coefficients}} - \underbrace{\eta_t e_t z_t}_{\text{correction liée aux données}}\Big).$$

Le terme $-\eta_t\lambda w_t$ tend à rapprocher les coefficients de zéro, tandis que le terme $-\eta_t e_t z_t$ corrige la prévision à partir du résidu observé. La projection maintient les paramètres dans l'ensemble admissible $\mathcal{K}$.

Point de vigilance. Dans ce modèle, la pénalisation porte sur *tous* les coefficients, y compris l'interception éventuelle. Cela assure $\nabla^2 \widetilde{\ell}_t \succeq \lambda I_d$ dans toutes les directions. Exclure l'interception de la pénalisation, comme on le fait souvent en régression Ridge, demande une analyse distincte de la forte convexité.

4.2 Une garantie logarithmique pour OGD pénalisé

Conservons les hypothèses de bornitude

$$\mathcal{K} = \{w : \|w\|_2 \le B\}, \quad \|z_t\|_2 \le R, \quad |y_t| \le Y, \quad \lambda > 0.$$

Alors, pour tout $w \in \mathcal{K}$,

$$\|\nabla \widetilde{\ell}_t(w)\|_2 \le \underbrace{(BR + Y)R + \lambda B}_{G_\lambda}.$$

Théorème 4.3 (Regret logarithmique de l'OGD régularisé)**.** *On initialise $w_1 \in \mathcal{K}$ et on choisit $\eta_t = 1/(\lambda t)$. Pour tout comparateur fixe $u \in \mathcal{K}$,*

$$\sum_{t=1}^{T} \left[\widetilde{\ell}_t(w_t) - \widetilde{\ell}_t(u)\right] \le \frac{G_\lambda^2}{2\lambda}(1 + \log T).$$

Ainsi, le regret standard pour les pertes régularisées *satisfait*

$$\widetilde{\mathrm{Reg}}_T \le \frac{G_\lambda^2}{2\lambda}(1 + \log T).$$

Preuve. La forte convexité et la propriété de projection donnent, pour $u \in \mathcal{K}$ et $g_t = \nabla \widetilde{\ell}_t(w_t)$,

$$\begin{aligned}\widetilde{\ell}_t(w_t) - \widetilde{\ell}_t(u) &\le \langle g_t, w_t - u\rangle - \frac{\lambda}{2}\|w_t - u\|_2^2 \\ &\le \frac{\|w_t - u\|_2^2 - \|w_{t+1} - u\|_2^2}{2\eta_t} + \frac{\eta_t G_\lambda^2}{2} - \frac{\lambda}{2}\|w_t - u\|_2^2.\end{aligned}$$

Avec $\eta_t^{-1} = \lambda t$, les termes en distances au comparateur se compensent lors de la sommation (à un terme final non positif près). On obtient

$$\sum_{t=1}^{T}[\widetilde{\ell}_t(w_t) - \widetilde{\ell}_t(u)] \le \frac{G_\lambda^2}{2\lambda}\sum_{t=1}^{T}\frac{1}{t} \le \frac{G_\lambda^2}{2\lambda}(1 + \log T).$$

□

Remarque 4.4 (Quelle notion de regret est bornée ?). Le théorème compare les pertes *régularisées* $\widetilde{\ell}_t = \ell_t + \lambda\|w\|_2^2/2$. Il ne constitue pas, sans argument supplémentaire, une garantie logarithmique pour le regret calculé uniquement avec les erreurs quadratiques ℓ_t. En outre, ajouter la pénalité à chaque tour est différent d'un FTRL qui ajoute une seule régularisation à la *somme* des pertes historiques.

5 Gestion d'inventaire

5.1 Motivation : surstock et rupture

La gestion d'inventaire (*inventory management*) consiste à déterminer une quantité à commander ou à produire avant de connaître la demande réelle. À chaque instant t, on choisit une quantité $q_t \in \mathcal{K} = [0, Q_{\max}]$, puis on observe la demande $y_t \geq 0$.

Deux coûts économiques interviennent :

- ▷ **Surstock :** $c_h > 0$ désigne le coût unitaire d'un excédent (*holding cost*) : stockage, invendus, péremption ou démarque.
- ▷ **Rupture :** $c_b > 0$ désigne le coût unitaire d'une demande non satisfaite (*shortage cost*) : marge perdue, pénalité de service ou coût de commande différée.

On note l'écart entre la décision et la demande :

$$\delta_t = q_t - y_t.$$

Avec la notation $(a)_+ = \max\{a, 0\}$, les deux composantes du coût s'écrivent

$$\underbrace{c_h(q_t - y_t)_+}_{\text{surstock}}, \qquad \underbrace{c_b(y_t - q_t)_+}_{\text{rupture}}.$$

Définition 5.1 (Perte d'inventaire : newsvendor)**.** La perte d'inventaire au temps t est

$$\ell_t^{\text{inv}}(q) = c_h(q - y_t)_+ + c_b(y_t - q)_+. \tag{1}$$

Cette fonction est **convexe**, mais généralement non différentiable en $q = y_t$.

Remarque 5.2. Le modèle *newsvendor* est historiquement associé à la vente de journaux : une quantité doit être commandée avant que la demande soit connue, tandis que les invendus perdent rapidement leur valeur.
Nous considérons ici un modèle à une période, sans report de stock ni délai d'approvisionnement.

5.2 De la perte absolue à la pinball loss

Rappelons la perte absolue, également appelée perte L^1 :

$$\ell_1(\widehat{y}, y) = |\widehat{y} - y|.$$

Pour un modèle paramétrique μ_β, la minimisation du risque empirique absolu s'écrit

$$\widehat{\beta} \in \arg\min_{\beta \in \mathbb{R}^p} \sum_{i=1}^{n} |y_i - \mu_\beta(x_i)|.$$

Dans le cas particulier d'un prédicteur constant, on retrouve les médianes empiriques :

$$\arg\min_{c \in \mathbb{R}} \sum_{i=1}^{n} |y_i - c| = \text{Med}(y_1, \ldots, y_n).$$

Remarque 5.3. Lorsque n est pair, le minimiseur n'est pas nécessairement unique : tout point entre les deux observations centrales convient.
Pour un modèle de régression général, le prédicteur optimal sous perte absolue vise une **médiane conditionnelle**, et non la médiane globale de toutes les observations.

Définition 5.4 (Pinball loss)**.** Pour $\tau \in (0,1)$, on définit la perte pinball :

$$\rho_\tau(q,y) = (1-\tau)(q-y)_+ + \tau(y-q)_+. \tag{2}$$

Le paramètre τ contrôle l'asymétrie des coûts de surestimation et de sous-estimation.

Pour $\tau = \frac{1}{2}$, on retrouve la perte absolue, à un facteur multiplicatif près :

$$\rho_{1/2}(q,y) = \frac{1}{2}|q-y|.$$

La perte pinball généralise donc la perte absolue en introduisant une pénalisation asymétrique.

5.3 Identité entre perte d'inventaire et pinball

Reprenons la perte d'inventaire :

$$\begin{aligned}\ell_t^{\text{inv}}(q) &= c_h(q-y_t)_+ + c_b(y_t-q)_+ \\ &= (c_h+c_b)\left[\frac{c_h}{c_h+c_b}(q-y_t)_+ + \frac{c_b}{c_h+c_b}(y_t-q)_+\right].\end{aligned}$$

Posons

$$\tau = \frac{c_b}{c_h+c_b}, \qquad 1-\tau = \frac{c_h}{c_h+c_b}.$$

Nous obtenons l'identité fondamentale :

Proposition 5.5 (Identité newsvendor–pinball)**.** *Pour tout q et toute demande y_t,*

$$\ell_t^{\text{inv}}(q) = (c_h+c_b)\rho_\tau(q,y_t), \qquad \tau = \frac{c_b}{c_h+c_b}. \tag{3}$$

Exemple 5.6 (Une rupture trois fois plus coûteuse)**.** Supposons que

$$c_b = 3c_h.$$

Alors

$$\tau = \frac{3c_h}{3c_h+c_h} = \frac{3}{4} = 0.75.$$

Une unité de surstock coûte c_h, tandis qu'une unité de rupture coûte $3c_h$.
La décision optimale devra donc privilégier une quantité suffisamment élevée pour limiter les ruptures : elle correspondra au **quantile d'ordre** 75 % de la demande, sous les hypothèses du modèle probabiliste présenté ci-dessous.

5.4 Décision optimale : le quantile critique

Supposons maintenant que la demande Y soit une variable aléatoire intégrable, de fonction de répartition F_Y, définie par

$$F_Y(q) = \mathbb{P}(Y \le q),$$

sa limite à gauche s'exprimant comme :

$$F_Y(q^-) = \mathbb{P}(Y < q).$$

On cherche à minimiser le **coût espéré** :

$$\mathcal{C}(q) = \mathbb{E}\left[c_h(q-Y)_+ + c_b(Y-q)_+\right].$$

Proposition 5.7 (Quantile optimal du newsvendor). *Soient $c_h, c_b > 0$ et*

$$\tau = \frac{c_b}{c_h + c_b}.$$

Une quantité $q^\star$ minimise le coût espéré sur $\mathbb{R}$ si et seulement si

$$F_Y(q^{\star-}) \leq \tau \leq F_Y(q^\star). \tag{4}$$

En particulier, un choix optimal est le quantile généralisé d'ordre τ :

$$q^\star = F_Y^{-1}(\tau) := \inf\{q \in \mathbb{R} : F_Y(q) \geq \tau\}.$$

Si F_Y est continue et strictement croissante au voisinage de ce quantile, l'optimum est unique.

Preuve. La fonction $\mathcal{C}$ est convexe. Ses dérivées à gauche et à droite vérifient

$$\mathcal{C}'_-(q) = (c_h + c_b)F_Y(q^-) - c_b,$$
$$\mathcal{C}'_+(q) = (c_h + c_b)F_Y(q) - c_b.$$

La condition d'optimalité convexe est

$$\mathcal{C}'_-(q^\star) \leq 0 \leq \mathcal{C}'_+(q^\star).$$

En divisant par $c_h + c_b > 0$, on obtient

$$F_Y(q^{\star-}) \leq \frac{c_b}{c_h + c_b} \leq F_Y(q^\star).$$

□

Remarque 5.8 (Contrainte de capacité). Si $Y \geq 0$ et que les décisions sont limitées à $\mathcal{K} = [0, Q_{\max}]$, on peut choisir

$$q^\star_{\mathcal{K}} = \min\{Q_{\max}, F_Y^{-1}(\tau)\}.$$

La capacité peut donc empêcher de commander la quantité correspondant au quantile critique.

5.5 Application au Online Learning

En Online Learning, la loi de Y n'est pas nécessairement connue, et les demandes $y_1, \ldots, y_T$ sont révélées séquentiellement.

Au temps t, l'apprenant choisit q_t **avant** d'observer y_t, puis subit la perte $\ell_t^{\text{inv}}(q_t)$.

Le regret par rapport à la meilleure quantité fixe en hindsight est

$$\text{Reg}_T^{\text{inv}} = \sum_{t=1}^{T} \ell_t^{\text{inv}}(q_t) - \min_{q \in \mathcal{K}} \sum_{t=1}^{T} \ell_t^{\text{inv}}(q).$$

Propriété 5.9 (Sous-gradient de la perte d'inventaire). *Le sous-différentiel de la perte d'inventaire est*

$$\partial \ell_t^{\text{inv}}(q) = \begin{cases} \{-c_b\}, & q < y_t, \\ [-c_b, c_h], & q = y_t, \\ \{c_h\}, & q > y_t. \end{cases}$$

Tous les sous-gradients sont bornés :

$$|g_t| \leq G := \max\{c_h, c_b\}.$$

Preuve. On utilise l'identité $(a)_+ = (a + |a|)/2$ pour écrire

$$\ell_t^{\mathrm{inv}}(q) = \frac{c_h + c_b}{2}|q - y_t| + \frac{c_h - c_b}{2}(q - y_t).$$

Par les règles de calcul du sous-différentiel,

$$\partial\ell_t^{\mathrm{inv}}(q) = \frac{c_h + c_b}{2}\partial|q - y_t| + \frac{c_h - c_b}{2}.$$

En utilisant $\partial|z| = \{-1\}$ si $z < 0$, $[-1, 1]$ si $z = 0$ et $\{1\}$ si $z > 0$, on retrouve les trois cas annoncés.
Enfin, $\partial\ell_t^{\mathrm{inv}}(q) \subseteq [-c_b, c_h]$, d'où $|g_t| \leq \max\{c_h, c_b\}$. □

On peut ainsi appliquer la descente de sous-gradient projetée :

$$q_{t+1} = \Pi_{\mathcal{K}}\left(q_t - \eta_t g_t\right), \qquad g_t \in \partial\ell_t^{\mathrm{inv}}(q_t).$$

En particulier, lorsque $q_t < y_t$, le sous-gradient vaut $-c_b$: la mise à jour augmente la quantité commandée.

Lorsque $q_t > y_t$, il vaut c_h : la mise à jour réduit la quantité commandée.

Remarque 5.10 (FTL et quantile empirique). Pour la perte d'inventaire, FTL minimise la somme des pertes passées :

$$q_t \in \arg\min_{q \in \mathcal{K}} \sum_{s=1}^{t-1} \ell_s^{\mathrm{inv}}(q).$$

En l'absence de contrainte de capacité active, on peut choisir le **quantile empirique d'ordre** τ des demandes $y_1, \ldots, y_{t-1}$.
Ainsi, FTL avec perte quadratique produit une moyenne historique, tandis que FTL avec perte pinball produit un quantile historique.

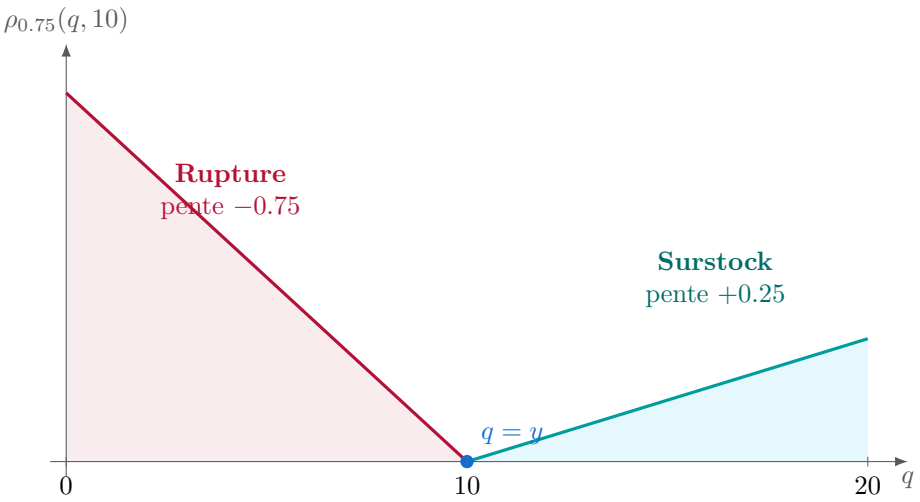
5.6 Représentation géométrique de la perte pinball

Considérons la perte pinball avec $\tau = 0.75$:

$$\rho_{0.75}(q, y) = 0.25(q - y)_+ + 0.75(y - q)_+.$$

Pour illustrer son asymétrie, fixons une demande $y = 10$. La fonction est affine par morceaux :

$$\rho_{0.75}(q, 10) = \begin{cases} 0.75(10 - q), & q < 10, \\ 0, & q = 10, \\ 0.25(q - 10), & q > 10. \end{cases}$$



Perte pinball pour $\tau = 0.75$ et $y = 10$. La sous-estimation est trois fois plus pénalisée que la surestimation.

Remarque 5.11 (Interprétation économique). Pour une unité de demande non satisfaite, le coût normalisé vaut 0.75, contre 0.25 pour une unité excédentaire. Le rapport des coûts est donc

$$\frac{c_b}{c_h} = \frac{0.75}{0.25} = 3.$$

Le paramètre τ contrôle directement l'asymétrie de la perte.

5.7 OGD : une correction opérationnelle des commandes

On initialise une quantité $q_1 \in [0, Q_{\max}]$. Après chaque observation y_t, on choisit un sous-gradient

$$g_t \in \partial \ell_t^{\text{inv}}(q_t).$$

La correction dépend du résultat observé :

Situation	$\partial \ell_t(q_t)$	g_t	**Commande suivante avant projection**
Rupture : $q_t < y_t$	$\{-c_b\}$	$-c_b$	$q_t + \eta_t c_b$
Commande exacte : $q_t = y_t$	$[-c_b, c_h]$	0	q_t
Surstock : $q_t > y_t$	$\{c_h\}$	c_h	$q_t - \eta_t c_h$

Définition 5.12 (Mise à jour OGD projetée)**.** La mise à jour de la commande est

$$q_{t+1} = \Pi_{[0,Q_{\max}]}\left(q_t - \eta_t g_t\right), \tag{5}$$

où $\eta_t > 0$ est le pas d'apprentissage et

$$\Pi_{[0,Q_{\max}]}(z) = \min\{Q_{\max}, \max\{0, z\}\}.$$

Remarque 5.13 (Lecture opérationnelle). Une **rupture** entraîne une augmentation de la prochaine commande ; un **surstock** entraîne sa diminution.
Les coûts relatifs c_b et c_h déterminent l'amplitude de ces corrections, tandis que la projection impose les contraintes de capacité.
À l'égalité $q_t = y_t$, nous choisissons $g_t = 0$, ce qui est un sous-gradient admissible.
Avant projection, l'amplitude de la correction dépend du coût unitaire et du pas η_t, **pas de la magnitude de l'erreur** $|q_t - y_t|$.

5.8 Regret d'OGD pour les décisions d'inventaire

Considérons l'ensemble convexe et borné

$$\mathcal{K} = [0, Q_{\max}], \qquad Q_{\max} > 0.$$

Son diamètre euclidien est

$$D = Q_{\max}.$$

D'après le sous-différentiel de la perte d'inventaire, tous les sous-gradients vérifient

$$|g_t| \le G, \qquad G := \max\{c_b, c_h\}.$$

Le regret par rapport à la meilleure quantité **fixe en hindsight** est

$$\text{Reg}_T^{\text{inv}} = \sum_{t=1}^{T} \ell_t^{\text{inv}}(q_t) - \min_{q \in \mathcal{K}} \sum_{t=1}^{T} \ell_t^{\text{inv}}(q).$$

Théorème 5.14 (Regret d'OGD pour l'inventaire)**.** *Supposons que les pertes soient convexes, que $\mathcal{K} = [0, Q_{\max}]$ et que $|g_t| \leq G$ pour tout t.*
Pour un pas d'apprentissage constant $\eta > 0$, l'algorithme OGD projeté satisfait

$$\mathrm{Reg}_T^{\mathrm{inv}} \leq \frac{Q_{\max}^2}{2\eta} + \frac{\eta G^2 T}{2}. \tag{6}$$

Lorsque l'horizon T est connu, le choix

$$\eta = \frac{Q_{\max}}{G\sqrt{T}}$$

donne

$$\mathrm{Reg}_T^{\mathrm{inv}} \leq Q_{\max} G \sqrt{T}.$$

En particulier,

$$\frac{\mathrm{Reg}_T^{\mathrm{inv}}}{T} \leq \frac{Q_{\max} G}{\sqrt{T}} \xrightarrow[T\to\infty]{} 0.$$

On en déduit

$$\limsup_{T\to\infty} \frac{\mathrm{Reg}_T^{\mathrm{inv}}}{T} \leq 0.$$

Preuve. La non-expansivité de la projection euclidienne donne, pour tout $u \in \mathcal{K}$,

$$|q_{t+1} - u|^2 \leq |q_t - \eta g_t - u|^2 = |q_t - u|^2 - 2\eta g_t (q_t - u) + \eta^2 g_t^2.$$

Par convexité,

$$\ell_t^{\mathrm{inv}}(q_t) - \ell_t^{\mathrm{inv}}(u) \leq g_t (q_t - u).$$

Par conséquent,

$$\ell_t^{\mathrm{inv}}(q_t) - \ell_t^{\mathrm{inv}}(u) \leq \frac{|q_t - u|^2 - |q_{t+1} - u|^2}{2\eta} + \frac{\eta}{2} g_t^2.$$

En sommant sur $t = 1, \ldots, T$, les différences de carrés télescopent :

$$\mathrm{Reg}_T^{\mathrm{inv}}(u) \leq \frac{|q_1 - u|^2}{2\eta} + \frac{\eta}{2} \sum_{t=1}^{T} g_t^2 \leq \frac{Q_{\max}^2}{2\eta} + \frac{\eta G^2 T}{2}.$$

Cette borne étant valable pour tout comparateur fixe $u \in \mathcal{K}$, elle l'est notamment pour le meilleur comparateur en hindsight. □

Remarque 5.15 (Interprétation de la garantie). La comparaison porte sur deux stratégies :

- **En ligne :** les quantités $q_1, \ldots, q_T$ sont choisies avant l'observation des demandes.
- **En hindsight :** une unique quantité constante $q^\star$ est choisie après observation de toute la série.

Le comparateur est un quantile empirique d'ordre

$$\tau = \frac{c_b}{c_h + c_b},$$

éventuellement ramené à l'intervalle $[0, Q_{\max}]$ par projection.
La borne ne nécessite aucune hypothèse de stationnarité, d'indépendance ou de distribution connue des demandes.
Elle garantit l'absence d'excès moyen de coût asymptotiquement positif, mais ne compare pas l'algorithme à une suite de quantiles conditionnels variables.

À retenir

Gestion d'inventaire et Online Learning.
La perte pinball permet d'intégrer les coûts économiques asymétriques dans la décision.
OGD ajuste les commandes à partir des ruptures et des excédents observés, tout en respectant les contraintes opérationnelles.
Sur un ensemble borné, la convexité et les sous-gradients bornés donnent

$$\mathrm{Reg}_T^{\mathrm{inv}} = O(\sqrt{T}) \quad \text{au sens d'une borne supérieure.}$$

La performance cumulée est ainsi contrôlée par rapport à la meilleure quantité fixe, sans supposer que les demandes suivent un modèle probabiliste particulier.

6 Conclusion générale

L'apprentissage en ligne consiste à prendre une décision avant de connaître l'observation courante, puis à actualiser cette décision à partir de la perte révélée.

Les algorithmes étudiés diffèrent principalement par leur mécanisme de mise à jour :

- **FTL :** minimise les pertes historiques.
- **FTRL :** ajoute une régularisation pour stabiliser les décisions.
- **OGD :** effectue une correction à partir d'un (sous-)gradient courant.

La fonction de perte traduit l'objectif recherché :

$$\begin{aligned} \text{Quadratique} &\longrightarrow \text{moyenne}, \\ \text{Absolue} &\longrightarrow \text{médiane}, \\ \text{Pinball} &\longrightarrow \text{quantile}. \end{aligned}$$

Ces correspondances concernent l'optimisation d'une prévision constante, ou leurs analogues conditionnels sous des hypothèses appropriées.

En gestion d'inventaire, le choix de la perte n'est pas seulement statistique : **il traduit directement les coûts économiques de surstock et de rupture**.

$$\tau = \frac{c_b}{c_h + c_b} \quad \Longrightarrow \quad q^\star = F_Y^{-1}(\tau)$$

Enfin, il faut distinguer deux cadres : le **modèle probabiliste**, où l'on cherche à minimiser un coût espéré, et le **cadre online**, où l'on cherche à contrôler le regret cumulatif sans nécessairement supposer une loi connue des demandes.