Online Learning — Notes de la séance du 12 novembre 2026

OGD régressive, régularisation Ridge et décisions d'inventaire

1 Retour sur la dernière séance : prévoir, puis corriger

Reprenons notre exemple de boulangerie. Au début du jour t, on choisit une quantité q_t pour anticiper la demande y_t, encore inconnue. Une fois les ventes observées, on mesure l'erreur et on actualise la décision pour le jour suivant. C'est exactement la chronologie de l'*Online Learning* : **décider, observer, subir une perte, puis apprendre**.

Pour commencer, on peut mesurer l'erreur de prévision par une perte quadratique instantanée :

$$\ell_t^{\text{quad}}(q) = \frac{1}{2}(q - y_t)^2.$$

Le facteur $1/2$ simplifie le calcul du gradient, sans changer les minimiseurs. Nous allons d'abord utiliser cette perte pour apprendre un modèle de régression, puis la pénaliser avec Ridge. Enfin, nous changerons de perte pour traduire directement les coûts de surstock et de rupture.

1.1 Descente de gradient en ligne avec covariables

L'idée est de proposer un modèle entre les **covariables** $z_t \in \mathbb{R}^d$ disponibles avant la vente et la **cible** y_t. On considère un prédicteur linéaire :

$$\widehat{y}_t = \beta_t^\top z_t, \qquad \beta_t \in \mathcal{K} \subseteq \mathbb{R}^d.$$

Le vecteur β_t contient les coefficients du modèle au jour t ; $\mathcal{K}$ est l'ensemble des paramètres admissibles, supposé fermé et convexe.

Un exemple typique de vecteur de covariables est

$$z_t = (1, x_t^1, \dots, x_t^p, y_{t-1}, y_{t-2}, \dots, y_{t-w})^\top.$$

La constante 1 permet d'ajouter une *interception* (ordonnée à l'origine). Les variables x_t^j peuvent représenter une promotion, le jour de la semaine ou une information météorologique connue au moment de prévoir. Les w dernières ventes introduisent une mémoire temporelle de dimension fixe.

On peut enrichir ce vecteur avec une moyenne mobile calculée sur le passé, une valeur saisonnière y_{t-s} (*seasonal naive*), ou des composantes de Fourier décrivant une périodicité. La seule règle à respecter est la suivante : **aucune caractéristique utilisée pour prévoir y_t ne doit dépendre de y_t ou d'une observation future**. Les coefficients de Fourier calculés à partir des mêmes retards peuvent être redondants avec ces retards dans un modèle linéaire ; les composantes calendaires, elles, peuvent apporter une information saisonnière distincte.

La perte devient une fonction du *paramètre* β :

$$\ell_t^{\text{quad}}(\beta) = \frac{1}{2}(\beta^\top z_t - y_t)^2. \tag{1}$$

Rappel de dérivation en dimension 1.

Si $f(u) = \frac{1}{2}(au - 1)^2$, avec a fixé, la dérivation en chaîne donne

$$f'(u) = a(au - 1), \qquad f''(u) = a^2 \geq 0.$$

On retrouve exactement la même mécanique en dimension multiple, en remplaçant le coefficient a par le vecteur z_t.

Proposition 1.1 (Gradient et Hessienne de la perte quadratique)**.** *Pour la perte* (1)*,*

$$\nabla_\beta \ell_t^{\text{quad}}(\beta) = (\beta^\top z_t - y_t) z_t, \qquad \nabla_\beta^2 \ell_t^{\text{quad}}(\beta) = z_t z_t^\top \succeq 0.$$

En notant $e_t = \widehat{y}_t - y_t$*, l'OGD projeté s'écrit*

$$\beta_{t+1} = \Pi_{\mathcal{K}}(\beta_t - \eta_t e_t z_t), \qquad \eta_t > 0. \tag{2}$$

Preuve. On applique la règle de dérivation en chaîne à $\frac{1}{2}(\beta^\top z_t - y_t)^2$, en utilisant $\nabla_\beta(\beta^\top z_t) = z_t$. La Hessienne vaut $z_t z_t^\top$, qui est semi-définie positive car $v^\top z_t z_t^\top v = (z_t^\top v)^2 \geq 0$. □

Remarque 1.2 (Que met-on à jour ?). Le gradient est calculé **par rapport à** β, pas par rapport à la prévision scalaire $\widehat{y}_t$. C'est donc β_t que l'on actualise. La prévision du lendemain sera ensuite $\widehat{y}_{t+1|t} = \beta_{t+1}^\top z_{t+1}$, à condition que z_{t+1} soit connu avant la demande du lendemain.

1.2 Ridge : pénaliser les coefficients du modèle

On peut évidemment pénaliser la perte. L'intérêt de Ridge est de limiter l'amplitude des coefficients, notamment lorsque les variables sont corrélées ou que certaines directions sont mal observées. Il s'agit d'une **contraction des coefficients**, et non des covariables elles-mêmes. Contrairement à LASSO, Ridge ne produit pas en général de coefficients exactement nuls : ce n'est donc pas, à proprement parler, une méthode de sélection de variables.

Définition 1.3 (Perte instantanée Ridge)**.** Pour $\lambda > 0$, on considère

$$\widetilde{\ell}_t(\beta) = \frac{1}{2}(\beta^\top z_t - y_t)^2 + \frac{\lambda}{2}\|\beta\|_2^2. \tag{3}$$

La pénalité quadratique est ici ajoutée *à chaque tour*.

Puisque nous voulons appliquer OGD, calculons le gradient et la Hessienne :

$$\nabla \widetilde{\ell}_t(\beta) = (\beta^\top z_t - y_t) z_t + \lambda \beta,$$
$$\nabla^2 \widetilde{\ell}_t(\beta) = z_t z_t^\top + \lambda I_d \succeq \lambda I_d.$$

On obtient donc la mise à jour

$$\beta_{t+1} = \Pi_{\mathcal{K}}\left((1 - \eta_t \lambda)\beta_t - \eta_t(\beta_t^\top z_t - y_t) z_t\right). \tag{4}$$

Le premier terme tend à ramener les coefficients vers zéro ; le second corrige l'erreur de prévision observée.

Propriété 1.4 (Forte convexité et regret logarithmique)**.** *Chaque perte* $\widetilde{\ell}_t$ *est* λ*-fortement convexe. Supposons*

$$\mathcal{K} = \{\beta : \|\beta\|_2 \leq B\}, \qquad \|z_t\|_2 \leq R, \qquad |y_t| \leq Y.$$

Alors

$$\|\nabla \widetilde{\ell}_t(\beta)\|_2 \leq G_\lambda := (BR + Y)R + \lambda B.$$

Avec $\eta_t = 1/(\lambda t)$*, OGD projeté vérifie, pour tout comparateur fixe* $u \in \mathcal{K}$*,*

$$\sum_{t=1}^{T} [\widetilde{\ell}_t(\beta_t) - \widetilde{\ell}_t(u)] \leq \frac{G_\lambda^2}{2\lambda}(1 + \log T). \tag{5}$$

Autrement dit, la borne de regret est d'ordre $O(\log T)$ et la borne sur le regret moyen est d'ordre $O((\log T)/T)$, plus rapide que $O(T^{-1/2})$.

Point de vigilance. Cette garantie porte sur les **pertes régularisées** $\widetilde{\ell}_t$, et pas automatiquement sur les seules erreurs quadratiques. Pour obtenir la forte convexité dans toutes les directions, nous pénalisons ici tous les coefficients, y compris l'interception. Dans la pratique, on peut choisir de ne pas pénaliser l'interception, mais la justification théorique doit alors être adaptée.

2 Perte d'inventaire : traduire les coûts métier

Cette fois, on change de **fonction de perte instantanée** : on change donc le comportement recherché. L'objectif n'est plus seulement de prévoir une valeur proche de y_t, mais de choisir une quantité $q_t \in \mathcal{K} = [0, Q_{\max}]$ qui tienne compte du coût économique d'une erreur.

Deux coûts unitaires interviennent : $c_h > 0$ pour une unité produite en trop (*holding cost* : stockage, invendu ou perte), et $c_b > 0$ pour une unité de demande non satisfaite (*shortage cost*, parfois appelé *backorder cost* selon le modèle métier).

En notant $(a)_+ = \max\{0, a\}$, la perte *newsvendor* est

$$\ell_t^{\text{inv}}(q) = c_h(q - y_t)_+ + c_b(y_t - q)_+. \tag{6}$$

Nous supposons ici qu'il n'y a ni report de stock ni délai d'approvisionnement : chaque jour constitue une décision à une période.

2.1 On retrouve la pinball loss

Posons le **ratio critique**

$$\tau = \frac{c_b}{c_h + c_b} \in (0, 1).$$

Alors $1 - \tau = c_h/(c_h + c_b)$ et

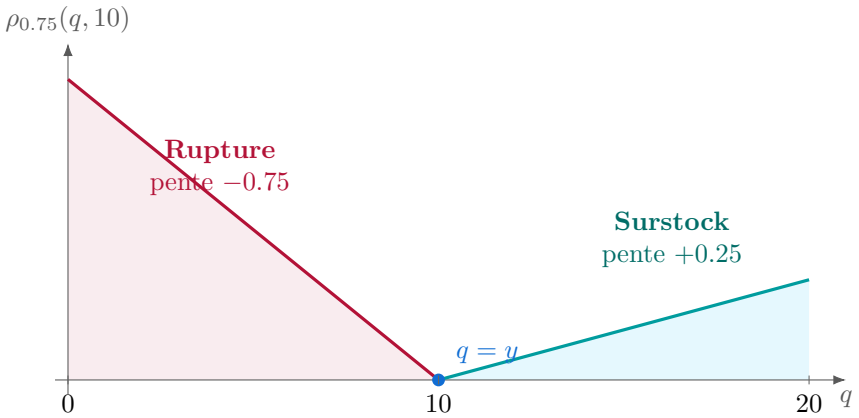
$$\begin{aligned} \ell_t^{\text{inv}}(q) &= (c_h + c_b)\underbrace{\left[(1-\tau)(q - y_t)_+ + \tau(y_t - q)_+\right]}_{\rho_\tau(q, y_t)} \\ &= (c_h + c_b)\rho_\tau(q, y_t). \end{aligned}$$

On lit directement la **pinball loss** dans la perte d'inventaire. Pour $\tau = 1/2$, elle est proportionnelle à la valeur absolue ; pour $\tau \neq 1/2$, elle pénalise différemment la surestimation et la sous-estimation.

2.2 Représentation de la pinball loss pour $\tau = 0.75$

Fixons $y = 10$. La perte normalisée est affine par morceaux :

$$\rho_{0.75}(q, 10) = \begin{cases} 0.75(10 - q), & q < 10, \\ 0, & q = 10, \\ 0.25(q - 10), & q > 10. \end{cases}$$



La sous-production (à gauche de y) est trois fois plus pénalisée que la surproduction.

Exemple 2.1 (Une rupture trois fois plus coûteuse)**.** Si $c_b = 3c_h$, alors $\tau = 3/4 = 0.75$. Une unité manquante coûte trois fois plus qu'une unité excédentaire. On cherchera donc à commander *davantage* que si les deux coûts étaient identiques : la décision optimale probabiliste visera le quantile d'ordre 75 % de la demande.

C'est bien le sens de l'asymétrie : si $\tau > 0.5$, alors $c_b > c_h$ et la pente à gauche est plus forte en valeur absolue. Si $\tau < 0.5$, c'est le surstock qui coûte davantage. Pour $\tau = 0.5$, les deux pentes ont la même amplitude : on retrouve le cas médian.

3 Quel est le q optimal ? Du risque au quantile

Question : quelle quantité faut-il choisir *avant* de connaître la demande ? Dans un cadre probabiliste, on minimise le **risque**, c'est-à-dire la perte moyenne espérée. Cela diffère de la minimisation de $\ell_t^{\text{inv}}(q)$ après observation de y_t, dont le minimiseur serait simplement $q = y_t$: cette information n'est pas disponible au moment de commander.

3.1 Rappel : risque statistique et indicatrice

Définition 3.1 (Risque espéré)**.** Pour un prédicteur $\mu_\theta(X)$ et une perte ℓ, on définit

$$\mathcal{R}(\mu_\theta) = \mathbb{E}_{(X,Y)}\big[\ell(\mu_\theta(X), Y)\big].$$

Un paramètre optimal est un élément de $\arg\min_\theta \mathcal{R}(\mu_\theta)$, lorsque cet ensemble est non vide.

Rappelons l'indicatrice d'un événement A :

$$\mathbb{1}_A = \begin{cases} 1, & A \text{ se réalise,} \\ 0, & \text{sinon.} \end{cases} \qquad \text{et} \qquad \mathbb{P}(A) = \mathbb{E}[\mathbb{1}_A].$$

Par exemple, $\mathbb{E}[\mathbb{1}_{\{Y \le q\}}] = \mathbb{P}(Y \le q)$. Nous allons utiliser cette identité pour *dériver* le risque d'inventaire.

3.2 Risque d'inventaire et dérivée

Supposons $Y \ge 0$ intégrable, de fonction de répartition

$$F_Y(q) = \mathbb{P}(Y \le q), \qquad F_Y(q^-) = \mathbb{P}(Y < q).$$

Le risque d'inventaire associé à une quantité constante q est

$$\mathcal{R}(q) = \mathbb{E}\big[c_h(q - Y)_+ + c_b(Y - q)_+\big]. \tag{7}$$

Point de vigilance. Il ne faut pas remplacer les parties positives $(q - Y)_+$ et $(Y - q)_+$ par de simples indicatrices dans (7) : les indicatrices ne mesurent pas **l'amplitude** du surplus ou de la rupture. Elles apparaissent lorsqu'on **dérive** la perte par rapport à q.

En effet, pour $q \neq Y$,

$$\frac{\partial}{\partial q}(q - Y)_+ = \mathbb{1}_{\{Y<q\}}, \qquad \frac{\partial}{\partial q}(Y - q)_+ = -\mathbb{1}_{\{Y>q\}}.$$

Si la loi de Y est continue, on peut dériver sous l'espérance et obtenir

$$\begin{aligned} \mathcal{R}'(q) &= c_h\mathbb{E}[\mathbb{1}_{\{Y<q\}}] - c_b\mathbb{E}[\mathbb{1}_{\{Y>q\}}] \\ &= c_h\mathbb{P}(Y < q) - c_b\mathbb{P}(Y > q) \\ &= c_h F_Y(q) - c_b(1 - F_Y(q)) \\ &= (c_h + c_b)\,(F_Y(q) - \tau)\,. \end{aligned}$$

On retrouve ici une expression très simple : le signe de la dérivée est déterminé par la position de $F_Y(q)$ par rapport au ratio critique τ.

Proposition 3.2 (La quantité optimale est un quantile). *Soient $c_h, c_b > 0$ et $\tau = c_b/(c_h + c_b)$. Une quantité $q^\star$ minimise le risque (7) sur $\mathbb{R}$ si et seulement si*

$$F_Y(q^{\star -}) \leq \tau \leq F_Y(q^\star). \tag{8}$$

Un choix optimal est donc le quantile généralisé

$$q^\star = F_Y^{-1}(\tau) := \inf\{q \in \mathbb{R} : F_Y(q) \geq \tau\}.$$

Lorsque F_Y est continue et strictement croissante au voisinage de ce quantile, on retrouve l'équation

$$F_Y(q^\star) = \tau, \qquad q^\star = F_Y^{-1}(\tau).$$

Preuve. La fonction $\mathcal{R}$ est convexe, car elle est l'espérance de fonctions convexes. Sans supposer Y continue, ses dérivées latérales sont

$$\mathcal{R}'_-(q) = (c_h + c_b)F_Y(q^-) - c_b,$$
$$\mathcal{R}'_+(q) = (c_h + c_b)F_Y(q) - c_b.$$

La condition du premier ordre pour une fonction convexe est $\mathcal{R}'_-(q^\star) \leq 0 \leq \mathcal{R}'_+(q^\star)$, ce qui est équivalent à (8). □

Remarque 3.3 (Contrainte de capacité et information contextuelle). Si $Y \geq 0$ et $q \in [0, Q_{\max}]$, on peut retenir

$$q^\star_{\mathcal{K}} = \min\{Q_{\max}, F_Y^{-1}(\tau)\}.$$

Si l'on dispose de covariables X, la décision optimale conditionnelle vise plutôt un quantile de $Y \mid \{X = x\}$: $q^\star(x) = F^{-1}_{Y|\{X=x\}}(\tau)$, sous les hypothèses usuelles.

À retenir

Le modèle *newsvendor* ne demande pas nécessairement de prévoir la **moyenne** de la demande. Il demande de choisir un **quantile**, dont le niveau $\tau = c_b/(c_h + c_b)$ est fixé par les coûts métier. Plus la rupture est chère relativement au surstock, plus le quantile visé est élevé.

4 Retour au Online Learning : apprendre sans connaître la loi

Dans un cadre online, on ne connaît pas nécessairement F_Y et on ne suppose pas que les demandes sont indépendantes ou stationnaires. On choisit $q_t \in [0, Q_{\max}]$ avant d'observer y_t, puis on met à jour la quantité à partir de la perte révélée.

Propriété 4.1 (Sous-gradient de la perte d'inventaire). *Pour* $\ell_t^{\text{inv}}(q) = c_h(q-y_t)_+ + c_b(y_t-q)_+$,

$$\partial \ell_t^{\text{inv}}(q) = \begin{cases} \{-c_b\}, & q < y_t, \\ [-c_b, c_h], & q = y_t, \\ \{c_h\}, & q > y_t. \end{cases}$$

Tout sous-gradient g_t *satisfait* $|g_t| \le G := \max\{c_h, c_b\}$.

Preuve. L'identité $(a)_+ = (a + |a|)/2$ donne

$$\ell_t^{\text{inv}}(q) = \frac{c_h + c_b}{2}|q - y_t| + \frac{c_h - c_b}{2}(q - y_t).$$

On applique le sous-différentiel connu de la valeur absolue, puis on ajoute la dérivée du terme affine. □

On initialise $q_1 \in [0, Q_{\max}]$ et, après observation de y_t, on sélectionne $g_t \in \partial \ell_t^{\text{inv}}(q_t)$.

Observation	$\partial \ell_t(q_t)$	g_t	Correction avant projection
Rupture : $q_t < y_t$	$\{-c_b\}$	$-c_b$	$q_t + \eta_t c_b$
Égalité : $q_t = y_t$	$[-c_b, c_h]$	0	q_t
Surstock : $q_t > y_t$	$\{c_h\}$	c_h	$q_t - \eta_t c_h$

Définition 4.2 (Mise à jour OGD projetée).

$$q_{t+1} = \Pi_{[0,Q_{\max}]}(q_t - \eta_t g_t), \qquad \Pi_{[0,Q_{\max}]}(u) = \min\{Q_{\max}, \max\{0, u\}\}.$$

Une rupture augmente donc la prochaine commande ; un surstock la réduit. À l'égalité, le choix $g_t = 0$ est admissible. Remarquons que l'amplitude de la correction *avant projection* dépend du pas et du coût unitaire, **pas de la taille de l'écart** $|q_t - y_t|$.

Théorème 4.3 (Regret d'OGD pour l'inventaire). *Soit* $\mathcal{K} = [0, Q_{\max}]$, *de diamètre* $D = Q_{\max}$, *et* $G = \max\{c_h, c_b\}$. *Pour un pas constant* $\eta > 0$,

$$\text{Reg}_T^{\text{inv}} := \sum_{t=1}^{T} \ell_t^{\text{inv}}(q_t) - \min_{q \in \mathcal{K}} \sum_{t=1}^{T} \ell_t^{\text{inv}}(q) \le \frac{D^2}{2\eta} + \frac{\eta G^2 T}{2}.$$

Si T *est connu et* $\eta = D/(G\sqrt{T})$, *alors*

$$\text{Reg}_T^{\text{inv}} \le DG\sqrt{T}, \qquad \limsup_{T \to \infty} \frac{\text{Reg}_T^{\text{inv}}}{T} \le 0.$$

Le comparateur est la meilleure **quantité fixe**, choisie après observation des T demandes : un quantile empirique d'ordre τ, éventuellement projeté sur $[0, Q_{\max}]$. Ce n'est pas une suite de quantiles conditionnels qui varierait chaque jour. La borne est valable sans hypothèse probabiliste sur les demandes ; elle est *une borne supérieure* et n'impose pas, à elle seule, la convergence bilatérale du regret moyen réalisé vers zéro.

5 Récapitulatif pour le TP

Nous avons désormais trois modèles à comparer : **OGD régressive**, **OGD régressive avec Ridge** et **OGD pour l'inventaire**. Les trois suivent le même protocole séquentiel, mais n'optimisent pas la même fonction de perte.

Modèle	Hypothèses et borne sur le gradient	Pas d'OGD	Borne de regret
Quadratique	$\|\beta\| \leq B$, $\|z_t\| \leq R$, $\|y_t\| \leq Y$; $G_{\text{quad}} = (BR+Y)R$	$\eta = 2B/(G_{\text{quad}}\sqrt{T})$	$\leq 2BG_{\text{quad}}\sqrt{T}$
Ridge	Mêmes bornes, $\lambda > 0$; $G_\lambda = (BR+Y)R + \lambda B$	$\eta_t = 1/(\lambda t)$	$\leq \frac{G_\lambda^2}{2\lambda}(1+\log T)$
Inventaire	$q \in [0, Q_{\max}]$; $G = \max\{c_h, c_b\}$	$\eta = Q_{\max}/(G\sqrt{T})$	$\leq Q_{\max}G\sqrt{T}$

Remarque 5.1 (Comment lire ce tableau ?). Les deux premières lignes concernent les *coefficients* d'un prédicteur linéaire ; la troisième concerne directement la *quantité commandée*. Pour Ridge, le regret logarithmique porte sur les pertes **régularisées**. Pour les deux bornes en $\sqrt{T}$, l'horizon T est supposé connu lors du choix du pas. Toutes ces bornes sont sublinéaires en T : leur majoration, divisée par T, tend vers zéro.

À retenir

Une **fonction de perte** formalise l'objectif : son **(sous-)gradient** fournit la correction online ; les **hypothèses de convexité et de bornitude** permettent de contrôler le regret. La perte quadratique vise une moyenne, la perte absolue une médiane et la perte pinball un quantile. En inventaire, le quantile visé dépend directement du rapport entre coûts de rupture et de surstock.