

Correction TP Statistiques – ACP

Paul Minchella

Avril 2026

Partie I : Analyse exploratoire du jeu de données

Avant de réaliser une analyse en composantes principales (ACP), il est indispensable de procéder à une **analyse descriptive complète du jeu de données**. Cette étape permet de comprendre la nature des variables disponibles, leur rôle potentiel dans l'analyse, et la pertinence d'une réduction de dimension. L'objectif de l'ACP est ici de résumer l'information contenue dans les variables quantitatives en un nombre réduit d'axes principaux, afin de mieux comprendre la structure géométrique du jeu de données.

1) Lecture des données

a) *Importation du fichier*

On commence par importer le fichier contenant les observations.

```
setwd("~/Ton/Folder/approprié")

df <- read.csv("vins.csv",
               sep = ";",
               dec = ",",
               header = TRUE,
               row.names = 1,
               stringsAsFactors = FALSE)
```

La commande `row.names = 1` indique que la première colonne du fichier correspond au nom des vins et ne doit pas être considérée comme une variable statistique.

b) *Nombre d'observations et nombre de variables*

On peut déterminer ces informations avec :

```
nrow(df)
ncol(df)
dim(df)
```

On obtient 21 observations pour 31 variables.

c) *Structure générale du tableau*

On examine ensuite la structure globale du jeu de données :

```
str(df)
summary(df)
head(df)
```

La commande `str(df)` permet d'identifier immédiatement la nature des variables présentes dans le jeu de données.

On observe que certaines variables sont **qualitatives** (origine du vin), tandis que les autres variables correspondent à des **notes numériques** attribuées par des experts.

Ces variables quantitatives seront utilisées pour construire l'ACP.

2) Identification des variables qualitatives et quantitatives

a) *Identification des types de variables*

Une ACP s'effectue uniquement sur des variables quantitatives. Il est donc nécessaire d'identifier clairement quelles variables participent à la construction des axes principaux.

Les variables qualitatives décrivent l'origine des vins. Elles ne participent pas directement à la construction des axes, mais elles seront utiles pour **interpréter les résultats de l'ACP**.

b) *Isolation des variables quantitatives et résumé descriptif*

On peut effectuer cette séparation explicitement :

```
vars_quali <- df[, 1:2]
vars_quanti <- df[, -c(1,2)]
```

On examine ensuite leurs statistiques descriptives :

```
summary(vars_quanti)
sapply(vars_quanti, sd)
```

Ces statistiques permettent d'évaluer les ordres de grandeur des variables, leur dispersion et leur homogénéité éventuelle.

c) *Discussion sur la nécessité d'une standardisation*

Dans le cadre d'une ACP, cette étape est importante car elle permet de vérifier si une **standardisation** des variables sera nécessaire.

Lorsque les variables présentent des dispersions différentes ou sont exprimées dans des unités différentes, il est indispensable de travailler sur la matrice de corrélation plutôt que sur la matrice de covariance.

Dans le contexte présent, une standardisation est pertinente.

3) Première exploration du jeu de données

a) *Recherche de valeurs manquantes ou atypiques*

On peut vérifier la présence éventuelle de valeurs manquantes avec :

```
sum(is.na(df))
```

Une inspection descriptive via `summary(df)` permet également d'identifier d'éventuelles observations atypiques.

Dans ce jeu de données, aucune valeur manquante notable n'est observée.

b) *Pertinence d'une analyse multivariée*

Le jeu de données contient un nombre important de variables quantitatives décrivant différentes dimensions sensorielles des vins. Il semble donc adapté à une analyse multivariée, et en particulier à une ACP visant à résumer l'information contenue dans ces variables.

4) Description des variables disponibles

Le jeu de données comprend deux variables qualitatives décrivant le contexte de production des vins, ainsi qu'un ensemble de variables quantitatives correspondant à des notes sensorielles attribuées par des experts en œnologie. Ces variables décrivent différentes dimensions sensorielles du vin :

- les caractéristiques visuelles (robe, nuance),
- les caractéristiques olfactives (intensité, qualité, arômes),
- les caractéristiques gustatives (attaque, acidité, astringence),
- l'évaluation globale (équilibre, harmonie, qualité).

Ces variables sont susceptibles d'être corrélées car elles décrivent différentes facettes d'un même objet sensoriel complexe. L'objectif de l'ACP sera précisément d'identifier les directions principales structurant ces dimensions sensorielles et de résumer l'information contenue dans ces nombreuses variables corrélées.

5) Matrice de corrélation des variables quantitatives

a) Calcul de la matrice de corrélation

Avant de réaliser une analyse en composantes principales, il est indispensable d'examiner les relations linéaires existant entre les variables quantitatives :

```
corrplot(
  cor(vars_quant),
  method = "circle", type = "upper",
  tl.col = "black", tl.cex = 0.8
)
```

b) Identification des corrélations faibles ou négatives

Le rendu exposé en Figure 1 représente la matrice des corrélations entre toutes les variables quantitatives du jeu de données.




FIGURE 1 – Matrice de corrélation des variables quantitatives

On observe clairement l'existence de groupes de variables fortement corrélées, notamment entre : **Harmony**, **Overall.quality**, **Typical**, **Balance**, **Intensity**.

Inversement, certaines variables comme **Plante** présentent des corrélations plus faibles, voire négatives avec ces mêmes variables.

c) *Justification du recours à l'ACP*

La présence de nombreuses corrélations fortes entre variables indique que l'information contenue dans le jeu de données est en partie redondante.

Cette redondance justifie précisément l'utilisation d'une analyse en composantes principales : celle-ci permet de résumer l'information contenue dans ces variables corrélées par un nombre réduit de nouvelles variables non corrélées appelées **composantes principales**.

Partie II : Analyse en composantes principales

1) Mise en œuvre de l'ACP

On réalise l'ACP sur les variables quantitatives avec la commande suivante :

```
Vins.PCA <- PCA(  
  vins,  
  scale.unit = TRUE, quali.sup = 1:2, graph = TRUE  
)
```

Les deux premières variables (**Label** et **Soil**) sont qualitatives. Elles ne doivent pas intervenir dans la construction des axes principaux, mais elles pourront être utilisées pour **interpréter** les résultats.

L'argument **scale.unit = TRUE** est essentiel : il permet de **standardiser les variables**. Cette étape est indispensable car les variables ne présentent pas toutes la même dispersion. Deux graphiques principaux sont alors obtenus :

- le **cercle des corrélations** (variables),
- le **plan principal des individus**.

Ces deux représentations constituent le cœur de l'interprétation d'une ACP.

2) Cercle des corrélations

a) *Affichage et interprétation du cercle des corrélations*




FIGURE 2 – Cercle des corrélations (plan principal)

Ce graphique représente les **corrélations entre les variables initiales et les deux premiers axes principaux**. Chaque flèche correspond à une variable quantitative. Sa position est donnée, pour tout $j = 1, \dots, 31$, par :

$$(\text{corr}(X^j, Z^1), \text{corr}(X^j, Z^2))$$

où Z^1 et Z^2 sont les deux premières composantes principales. Ainsi :

- (★) plus une flèche est proche du cercle unité, mieux la variable est représentée sur le plan principal ;
- (★) deux variables proches indiquent une **corrélacion positive forte** ;
- (★) deux variables opposées indiquent une **corrélacion négative forte** ;
- (★) deux variables orthogonales indiquent une **absence de corrélacion**.

On observe ici que plusieurs variables liées à la **qualité globale du vin** (Harmony, Balance, Overall.quality, Typical) sont fortement corrélées entre elles et contribuent fortement au premier axe. Le premier axe semble donc représenter un **axe global de qualité sensorielle**. Le second axe oppose principalement certaines caractéristiques aromatiques spécifiques (par exemple Spice.before.shaking) à d'autres dimensions sensorielles plus générales.

b) *Origine des coordonnées des variables*

Les coordonnées sont obtenues par :

```
Vins.PCA$var$coord
```

Ces coordonnées correspondent aux corrélations entre les variables initiales et les axes principaux :

$$\text{coord}(j, k) = \text{corr}(X^j, Z^k).$$

Ainsi :

- une valeur proche de 1 ou -1 indique une forte corrélacion avec l'axe ;
- une valeur proche de 0 indique une faible relation avec cet axe.

Ces coefficients permettent donc d'interpréter la signification statistique des axes principaux en identifiant les variables qui structurent chaque direction principale.

c) *Interprétation géométrique des positions relatives des flèches*

- (★) deux variables proches indiquent une **corrélacion positive forte** ;
- (★) deux variables opposées indiquent une **corrélacion négative forte** ;
- (★) deux variables orthogonales indiquent une **absence de corrélacion**.

d) *Variables structurant les deux premiers axes*

On observe que plusieurs variables liées à la **qualité globale du vin** (Harmony, Balance, Overall.quality, Typical) sont fortement corrélées entre elles et contribuent fortement au premier axe. Je laisse les œnologues interpréter les axes principaux avec soin...

e) *Interprétation qualitative des axes 1 et 2*

Le premier axe semble représenter un **axe global de qualité sensorielle**.

Le second axe oppose principalement certaines caractéristiques aromatiques spécifiques (par exemple Spice.before.shaking) à d'autres dimensions sensorielles plus générales.

3) Coordonnées factorielles des variables

a) *Extraction et interprétation des coordonnées*

Les coordonnées des variables sont obtenues avec :

```
Vins.PCA$var$coord
```

Une valeur proche de 1 ou -1 indique une forte corrélacion avec l'axe ; une valeur proche de 0 indique une faible relation avec cet axe.

b) *Lien avec les corrélations variables-axes*

Ces coordonnées correspondent exactement aux corrélations entre les variables initiales et les composantes principales :

$$\text{coord}(j, k) = \text{corr}(X^j, Z^k).$$

Elles permettent donc d'interpréter la signification statistique des axes principaux en identifiant les variables qui structurent chaque direction principale.

4) Plan principal des individus

a) *Projection des individus sur le plan principal*




FIGURE 3 – Projection des vins sur le premier plan principal

b) *Justification mathématique des coordonnées principales*

Si l'on note $\widetilde{\mathbf{X}}_i$ le vecteur centré associé à l'observation i , et $P = [P_1 | \dots | P_p]$ la matrice des vecteurs propres, alors

$$\mathbf{Z}_i = P^\top \widetilde{\mathbf{X}}_i.$$

Les coordonnées représentées correspondent donc aux projections sur les directions principales.

c) *Interprétation de la proximité entre individus*

Deux individus proches dans le plan principal possèdent des profils sensoriels similaires relativement aux variables initiales.

d) *Structure globale du nuage d'individus*

Les individus situés aux extrémités du plan principal contribuent fortement à la structuration des axes.

Ils peuvent correspondre à des profils sensoriels atypiques ou particulièrement marqués.

5) Coordonnées factorielles des individus

a) *Extraction des coordonnées*

```
Vins.PCA$ind$coord
```

b) *Interprétation mathématique*

Ces coordonnées correspondent aux projections des observations centrées-réduites sur les axes principaux :

$$Z_i^k = P_k^\top \widetilde{\mathbf{X}}_i.$$

c) *Rôle dans l'étude géométrique*

Elles permettent :

- de représenter graphiquement les individus ;
- d'identifier les individus extrêmes ;
- d'interpréter la structure du nuage de points.

d) *Extraction sur les cinq premiers axes*

Les cinq premières coordonnées sont directement accessibles dans :

```
Vins.PCA$ind$coord[,1:5]
```

6) Valeurs propres et variance expliquée

a) *Extraction des valeurs propres*

```
Vins.PCA$eig
```

b) *Interprétation statistique*

Les valeurs propres mesurent la quantité de variance expliquée par chaque axe principal.

c) *Variance expliquée par les deux premiers axes*

Le premier axe explique environ 51.9% de la variance, le second environ 18.9%.

d) *Variance expliquée cumulée du plan principal*

Le plan principal explique donc : $51.9 + 18.9 = 70.8\%$.

e) *Qualité de la représentation*

Le plan principal fournit déjà une **représentation satisfaisante** du jeu de données.

7) Scree plot

a) Construction du scree plot




FIGURE 4 – Scree plot normalisé de l'ACP des vins

Le code R approprié :

```
eig_values <- Vins.PCA$eig[, 2]      # % variance expliquée
eig_cum <- Vins.PCA$eig[, 3]         # % variance cumulée

plot(eig_values, type = "b", col = "blue", xlab = "Composantes principales",
     ylab = "Pourcentage de variance expliquée",
     ylim=c(0,100), main = "Scree plot normalisé de l'ACP")
lines(eig_cum, type = "b", col = "red")

legend("right", legend = c("Variance expliquée", "Variance expliquée cumulée"),
      col = c("blue", "red"), lty = 1, pch = 19); grid()
```

b) *Interprétation du graphique*

Le scree plot représente :

- la variance expliquée par chaque composante principale (2 ou 3 selon les préférences ici...), en **bleu**;
- la variance expliquée cumulée en **rouge**.

Un éventuel *coude* indique le nombre pertinent d'axes à conserver.

c) *Choix du nombre de composantes principales*

Ce graphique aide à déterminer combien de composantes principales doivent être conservées pour résumer efficacement l'information du jeu de données.

8) Lecture détaillée de la commande `summary(Vins.PCA)`

a) *Rôle central de la commande*

```
summary(Vins.PCA)
```

Elle fournit :

- les valeurs propres;
- les coordonnées;
- les contributions;
- les qualités de représentation (`cos2`).

b) *Signification des colonnes dans la partie **Individuals***

Distance à l'origine : Dist

$$\text{Dist}(i) = \|\widetilde{\mathbf{X}}_i\|$$

Elle mesure l'éloignement global d'un individu au centre du nuage.

Qualité de représentation : cos2 La quantité

$$\text{cos2}(i, k) = \frac{(Z_i^k)^2}{\|\widetilde{\mathbf{X}}_i\|^2}$$

correspond au **cosinus carré de l'angle** entre le vecteur centré $\widetilde{\mathbf{X}}_i$ et l'axe principal P_k . En effet, comme la base des vecteurs propres est orthonormée, on a

$$Z_i^k = P_k^\top \widetilde{\mathbf{X}}_i = \|\widetilde{\mathbf{X}}_i\| \cos(\theta_{ik}),$$

où θ_{ik} est l'angle entre l'individu i et l'axe principal k . En élevant au carré puis en divisant par $\|\widetilde{\mathbf{X}}_i\|^2$, on obtient exactement la formule du `cos2`.

- D'un point de vue statistique, cette quantité mesure la **qualité de représentation** de l'individu sur l'axe principal considéré : elle correspond à la proportion de la position de l'individu expliquée par sa projection sur cet axe.
- D'un autre point de vue, on peut également en donner une interprétation énergétique. Comme

$$\|\widetilde{\mathbf{X}}_i\|^2 = \sum_{k=1}^p (Z_i^k)^2,$$

le terme $(Z_i^k)^2$ représente la part de la “dispersion” de l'individu portée par la direction principale P_k . Ainsi, le **cos2** mesure la **part d'énergie** (ou d’“information” si vous préférez ce paradigme) du vecteur $\widetilde{\mathbf{X}}_i$ expliquée par l'axe principal k .

Utilisation pratique :

- si $\cos 2 \approx 1$, l'individu est très bien représenté sur cet axe ;
- si $\cos 2 \approx 0$, l'individu est mal représenté sur cet axe.

Bref, reprenez que le **cos2** indique quelle proportion de la position de l'individu est expliquée par la projection sur l'axe considéré.

Contribution : ctr La quantité

$$\text{ctr}(i, k) = \frac{(Z_i^k)^2}{n\lambda_k} \quad (\text{Ctr})$$

mesure la **contribution de l'individu** i à la construction de l'axe principal k .

Pour comprendre cette formule, rappelons que la variance expliquée par l'axe principal k est donnée par la valeur propre λ_k , et que celle-ci s'écrit :

$$\lambda_k = \widehat{\text{Var}}(Z^k) = \frac{1}{n} \sum_{i=1}^n (Z_i^k)^2.$$

La quantité $(Z_i^k)^2$ représente la part de variance portée par l'individu i dans la direction principale P_k . En divisant par la variance totale associée à cet axe, on obtient la contribution relative de cet individu à la construction de l'axe considéré.

Utilisation pratique :

- si $\text{ctr}(i, k)$ est grande, l'individu joue un rôle important dans la construction de l'axe principal k ;
- si $\text{ctr}(i, k)$ est faible, l'individu intervient peu dans la définition de cet axe.

Ainsi, les individus ayant les plus fortes contributions sont généralement situés aux extrémités de l'axe considéré : ce sont eux qui structurent la direction principale correspondante.

Lien entre contribution et coordonnée au carré. L'expression (Ctr) montre bien que la contribution d'un individu à la construction d'un axe principal est directement proportionnelle au carré de sa coordonnée sur cet axe. Ainsi, plus un individu est éloigné de l'origine dans la direction principale P_k , plus il participe à la construction de cet axe. Autrement dit, ce sont les individus situés aux extrémités du nuage projeté qui structurent principalement les directions principales de l'ACP.

```
plot(
  Vins.PCA$ind$coord[,1]^2,
  Vins.PCA$ind$contrib[,1],
  xlab = expression((Z[i]^1)^2),
  ylab = "Contribution à Dim 1 (%)"
)

n <- nrow(vars_quant); lambda1 <- Vins.PCA$eig[1, 1]
coef_theorique <- 100 / (n * lambda1)
abline(a = 0, b = coef_theorique, col = "red", lty = 2, lwd = 2)
```

La Figure 5 illustre cette relation linéaire entre le carré de la coordonnée factorielle et la contribution à l'axe principal 1.




FIGURE 5 – Relation entre la coordonnée factorielle au carré et la contribution des individus à l'axe principal 1

c) *Partie Variables*

Pour les variables, le tableau fourni par la commande `summary(Vins.PCA)` contient trois quantités essentielles permettant d'interpréter le rôle de chaque variable dans la construction des axes principaux :

- **coord** : coordonnée de la variable X^j sur l'axe principal P_k . Elle correspond à la corrélation entre la variable initiale et la composante principale :

$$\text{coord}(j, k) = \text{corr}(X^j, Z^k).$$

Ainsi, une valeur proche de 1 ou -1 indique que la variable est fortement liée à l'axe considéré.

- **cos2** : qualité de représentation de la variable sur l'axe principal k . Idem qu'avec les observations, une valeur proche de 1 signifie que la variable est bien représentée dans le plan factoriel considéré.
- **ctr** : contribution de la variable à la construction de l'axe principal k . Elle mesure dans quelle proportion la variable participe à la définition de la direction principale. Les variables ayant les contributions les plus élevées sont celles qui structurent réellement l'axe étudié.

Ainsi, l'analyse conjointe des **coord**, des **cos2** et des **ctr** permet d'identifier les variables les plus importantes pour interpréter le sens statistique des axes principaux.

9) Individus et variables structurant le premier axe principal

a) *Individus les plus contributifs*

```
top_ind <- sort(Vins.PCA$ind$contrib[,1], decreasing = TRUE)
head(top_ind, 5)
```

On obtient : 2ING, 1VAU, 1DAM, 2DAM, 1POY.

b) *Variables les plus contributives*

```
top_var <- sort(Vins.PCA$var$contrib[,1], decreasing = TRUE)
head(top_var, 5)
```

On obtient : Harmony, Intensity, Surface.feeling, Aroma.persistency, Smooth.

c) *Interprétation sensorielle de l'axe 1*

Ces variables participent fortement à la définition de la première direction principale.

On peut donc interpréter l'axe 1 comme une direction synthétisant principalement des caractéristiques liées à la **qualité sensorielle globale du vin**.

Partie III : Réduction de dimension

1) Choix d'un nombre de composantes principales

a) *Nombre minimal de composantes expliquant au moins 95% de la variance*

Une fois l'ACP réalisée, une question naturelle consiste à déterminer combien de composantes principales doivent être conservées pour résumer correctement les données.

On cherche le plus petit entier d tel que :

$$\frac{\lambda_1 + \dots + \lambda_d}{\lambda_1 + \dots + \lambda_p} \geq 0.95.$$

Cette information est directement accessible via la variance expliquée cumulée :

```
var_cum <- Vins.PCA$eig[, 3]
d_95 <- which(var_cum >= 95)[1]

cat(paste(
  "Nbr minimal de composantes pour 95% de variance:", d_95,
  "| Variance =", round(var_cum[d_95], 2), "%."
))
```

On obtient ici :

$$d_{0.95} = 9,$$

ce qui signifie qu'il faut conserver **9 composantes principales** pour préserver au moins 95% de la variabilité totale du jeu de données.

b) *Cohérence avec le scree plot*

Ce résultat est cohérent avec le scree plot observé précédemment : les deux premières composantes expliquent déjà une part importante de la variance totale, mais si l'on cherche à conserver presque toute l'information, il est nécessaire de retenir davantage d'axes.

c) *Compromis entre fidélité et compacité*

Conserver davantage de composantes principales améliore la fidélité de la représentation des données, mais diminue la compacité de la représentation.

À l'inverse, conserver peu de composantes permet une représentation plus simple et plus lisible, mais entraîne une perte d'information.

Le choix du nombre de composantes principales repose donc sur un compromis entre :


- **fidélité à l'information initiale ;**
- **réduction de dimension.**

Le seuil de 95% constitue en pratique un compromis souvent pertinent.

2) Intérêt pour un pipeline de machine learning

a) Rôle de l'ACP comme étape de prétraitement

Dans un pipeline classique de modélisation en *machine learning*, l'ACP est souvent utilisée comme étape de prétraitement :



Elle permet de transformer les variables initiales en un ensemble réduit de variables non corrélées conservant l'essentiel de l'information.

b) Avantages de la réduction de dimension par ACP

La réduction de dimension par ACP présente plusieurs avantages importants :

- ✓ **réduction du nombre de variables d'entrée** du modèle ;
- ✓ **suppression de la redondance** entre variables fortement corrélées ;
- ✓ **réduction de la multicollinéarité** entre covariables ;
- ✓ **accélération des calculs** lorsque la dimension initiale est élevée ;
- ✓ **réduction du bruit** en conservant les directions principales les plus informatives.

c) Intérêt de conserver 95% plutôt que 100% de la variance

Conserver 100% de la variance reviendrait à conserver toutes les composantes principales, donc toutes les variables initiales.

L'intérêt de l'ACP est précisément de réduire la dimension tout en conservant l'essentiel de l'information.

Choisir un seuil de 95% permet généralement :

- de conserver la structure informative principale du jeu de données ;
- d'obtenir une représentation plus compacte ;
- d'améliorer l'efficacité des méthodes d'apprentissage en aval.

Il s'agit donc d'un compromis classique entre compacité et fidélité de représentation.

Variables qualitatives supplémentaires : argument `quali.sup` Dans la commande `PCA()`, l'argument `quali.sup` permet d'indiquer que certaines variables qualitatives doivent être traitées comme des **variables supplémentaires**. Cela signifie qu'elles **n'interviennent pas dans la construction des axes principaux**, lesquels sont déterminés uniquement à partir des variables quantitatives actives.

Une fois les axes principaux construits, les modalités des variables qualitatives sont projetées *a posteriori* dans l'espace factoriel. Plus précisément, chaque modalité est représentée par le **barycentre des individus** qui possèdent cette modalité. Formellement, si l'on note Q une variable qualitative et ℓ l'une de ses modalités, la coordonnée de cette modalité sur l'axe principal k est donnée par

$$\text{coord}(\ell, k) = \frac{1}{n_\ell} \sum_{i: Q_i = \ell} Z_i^k,$$

où n_ℓ désigne le nombre d'individus appartenant à la modalité ℓ , et Z_i^k la coordonnée factorielle de l'individu i sur l'axe k . Ainsi, une modalité qualitative est placée au centre de gravité des individus qui la portent dans le plan principal. Cette représentation permet d'interpréter la relation entre les variables qualitatives et la structure géométrique du nuage d'individus, sans influencer la construction des axes principaux.

Synthèse : ce qu'il faut savoir faire pour un examen

À l'issue de ce TP, il est essentiel de maîtriser les points suivants concernant l'analyse en composantes principales réalisée avec le package `FactoMineR`.

- **Commande `PCA()`**

Savoir exécuter une ACP avec la commande :

```
PCA(data, scale.unit = TRUE, quali.sup = ..., graph = TRUE)
```

- **Lecture de la commande `summary()`**

Savoir lire les tableaux fournis par `summary(Vins.PCA)` : le `cos2` mesure la **qualité de représentation** d'un individu ou d'une variable sur un axe principal et

- la `ctr` (contribution) mesure le **poids d'un individu ou d'une variable dans la construction d'un axe principal**.

- **Lecture du cercle des corrélations**

Savoir interpréter le cercle des corrélations dans un plan principal (P^j, P^k) : deux variables "proches" sont positivement corrélées tandis que deux variables opposées le sont négativement. Deux variables **orthogonales** sont *non corrélées* selon les caractéristiques relevées par les axes P^j et P^k . Enfin, une variable proche du cercle est bien représentée sur le plan principal car de norme importante. Il faut savoir **identifier les variables structurant** principalement les **axes principaux**.

- **Lecture du plan principal des individus**

Savoir interpréter la projection des individus dans le plan principal (P^j, P^k) . Deux individus proches ont des profils similaires. Un individu éloigné de l'origine contribue fortement à la structuration des axes. Enfin, le plan principal correspond à la meilleure représentation bidimensionnelle du nuage de points (au sens de la variance expliquée).

- **Identifier les individus les plus contributifs à un axe**

Savoir repérer, à l'aide des contributions (`ctr`), les individus qui participent le plus à la construction d'un axe principal P^j .

- **Identifier les variables les plus contributives à un axe**

Savoir repérer les variables qui structurent principalement un axe principal P^j , à partir des contributions des variables.

- **Choisir le nombre de composantes principales**

Savoir déterminer le nombre de composantes principales nécessaires pour expliquer un certain pourcentage de variance (par exemple 95%), soit par lecture du tableau des valeurs propres (`Vins.PCA$eig`), soit par lecture du *scree plot*.

- **Variables qualitatives supplémentaires : `quali.sup`**

Comprendre que les variables indiquées dans l'argument `quali.sup` n'interviennent pas dans la construction des axes principaux, mais que leurs modalités sont projetées *a posteriori* comme barycentres des individus correspondants dans le plan factoriel.