

# *Correction* – Examen d’entraînement

## Statistiques et Machine Learning

Régression linéaire, ACP, LDA

Avril 2026

On considère le jeu de données de vins italien `UCI_wine.txt`. Ce jeu de données décrit différentes caractéristiques chimiques de vins issus de trois cépages distincts. Chaque observation correspond à un vin, caractérisé par des mesures physico-chimiques obtenues en laboratoire. On s’intéresse en particulier à la variable

$$Y = \text{Alcohol},$$

qui représente le **degré d’alcool du vin**. Cette variable constitue un indicateur important en œnologie, car elle renseigne sur le processus de fermentation et influence certaines propriétés organoleptiques du vin, comme l’intensité aromatique ou l’équilibre gustatif. L’objectif des premières parties est de modéliser la relation entre cette variable réponse et les autres variables quantitatives du jeu de données, notées  $X^{(1)}, \dots, X^{(p)}$ .

Par ailleurs, la variable

**Class**

correspond au cépage du vin. Il s’agit d’une variable qualitative décrivant l’origine botanique des observations. Elle sera mobilisée plus tard dans une perspective de classification via l’analyse discriminante linéaire.

## Partie I – Statistiques descriptives

### Q1. Importation du jeu de données

On commence par importer le fichier texte dans R. Dans ce cas précis de fichier de données, la première ligne du fichier contient les noms de colonnes, et que les champs sont séparés par des virgules.

```
df <- read.csv("UCI_wine.txt", sep = ",", header = TRUE)
```

Pour obtenir le nombre d’observations et le nombre de variables, on peut utiliser :

```
dim(df); nrow(df); ncol(df)
```

La commande `dim(df)` renvoie un couple  $(n, q)$ , où :

- $n = 178$  est le nombre d’observations ;
- $q = 14$  est le nombre de colonnes du tableau.

### Q2. Nature des variables

La structure générale du tableau s’obtient avec :

```
str(df)
```

On identifie **Class** comme variable qualitative et toutes les autres colonnes sont numériques. On peut isoler ces objets comme suit :

```
vars_quali <- df[, "Class"]  
vars_quant <- df[, -1]
```

Dans la suite :

- `Class` sera la variable qualitative ;
- `Alcohol` sera d'abord la variable réponse numérique ;
- les autres colonnes numériques seront des covariables explicatives.

### Q3. Moyenne et écart-type de Alcohol

Les statistiques descriptives usuelles s'obtiennent par :

```
mean(df$Alcohol)  
sd(df$Alcohol)
```

La moyenne empirique de `Alcohol` vaut environ 13 et son écart-type est 0.8.

### Q4. Corrélation entre Alcohol et Proline

Sous R, on calcule directement grâce à la commande suivante :

```
cor(df$Alcohol, df$Proline)
```

La valeur étant de 0.64, cela indique une forte liaison linéaire entre les deux variables, corrélées **positivement**.

### Q5. Valeurs manquantes et observations atypiques

Pour détecter d'éventuelles valeurs manquantes :

```
sum(is.na(df))
```

On lit rapidement qu'il n'y en a aucune.

Pour repérer d'éventuelles observations atypiques, on peut représenter les **boîtes à moustaches** (*boxplots*) des variables quantitatives. Pour comparer correctement les distributions des variables quantitatives, il est préférable de représenter leurs **boxplots après standardisation**, car ces variables sont exprimées dans des échelles très différentes. On standardise les variables avec la commande `scale()`, qui effectue la transformation suivante :

$$\tilde{X} = \frac{X - \bar{X}}{\sigma_X}.$$

Chaque variable est alors centrée (moyenne nulle) et réduite (variance égale à 1), ce qui permet une comparaison directe entre variables.

```
boxplot(  
  scale(vars_quant), las = 2,  
  main = "Boxplots des variables quantitatives standardisées"  
)
```

Chaque boxplot représente :

- la médiane (trait horizontal central) ;
- l'intervalle interquartile ;
- les moustaches ;
- les observations atypiques éventuelles (points isolés).

*Rappel : Les observations situées au-delà des moustaches correspondent à des valeurs potentiellement atypiques, au sens de la règle classique :*

$$Q_1 - 1.5 \times IQR \quad \text{ou} \quad Q_3 + 1.5 \times IQR.$$

Ces graphiques permettent donc d'identifier rapidement (entre-autre) des valeurs extrêmes/atypiques, ou encore des asymétries de distribution.




FIGURE 1 – Boxplots des variables quantitatives standardisées.

Comme on l'observe sur la Figure 1, certaines variables présentent plusieurs observations atypiques potentielles, notamment pour **Magnesium**, **Proanthocyanins** ou encore **Color\_Intensity**. Ces points extrêmes méritent une attention particulière lors des analyses multivariées ultérieures, car ils peuvent influencer la construction des axes principaux en ACP ou les frontières de décision en classification.

**Q6. Individus tels que  $Y_i > \text{median}(Y)$**

Une ligne de code suffisante est :

```
which(df$Alcohol > median(df$Alcohol))
```

Cette commande renvoie les indices des observations dont le degré d'alcool est strictement supérieur à la médiane empirique de **Alcohol**.

**Q7. Matrice de corrélation des variables quantitatives**

On calcule et affiche la matrice de corrélation des variables quantitatives avec :

```
library(corrplot)

corrplot(
  cor(vars_quant),
  method = "circle",
  type = "upper",
  tl.col = "black",
  tl.cex = 0.7
)
```

Cette représentation permet d'identifier visuellement, en un coup d'œil, les groupes de variables fortement corrélées positivement, les variables opposées par de fortes corrélations négatives et aussi les éventuelles redondances entre covariables.




FIGURE 2 – Matrice de corrélation des variables quantitatives.

On observe sur la Figure 2 l'existence de corrélations positives fortes entre **Flavanoids**, **Total\_Phenols** et **OD280\_OD315**, ainsi qu'une corrélation négative marquée entre **Color\_Intensity** et **Hue**. Ce type de représentation permet d'identifier rapidement des groupes de variables redondantes ou fortement liées, ce qui est particulièrement utile en amont d'une ACP ou d'une modélisation statistique.

### Q8. Couple de variables présentant la corrélation la plus forte en valeur absolue

Pour ce faire, une commande possible sous R est :

```
cor_mat <- cor(vars_quant)
cor_mat[upper.tri(cor_mat, diag = TRUE)] <- NA
idx <- which(abs(cor_mat) == max(abs(cor_mat), na.rm = TRUE), arr.ind = TRUE)
c(rownames(cor_mat)[idx[1]], colnames(cor_mat)[idx[2]])
```

- ✓ La commande `cor(vars_quant)` calcule la matrice de corrélation entre les variables quantitatives.
- ✓ La ligne suivante remplace par NA les coefficients situés au-dessus de la diagonale afin d'éviter de considérer deux fois la même corrélation (la matrice étant symétrique, quitte à choisir, on ne regarde que les termes inférieurs strict à la diagonale).
- ✓ La fonction `which(..., arr.ind = TRUE)` permet ensuite d'identifier la position du coefficient de corrélation maximal en valeur absolue dans la matrice, puis les noms des variables correspondantes sont extraits.

Ainsi, on relève que le couple de variables présentant la corrélation la plus forte (en valeur absolue) est :

(Flavanoids, Total\_Phenols)

## Partie II – Régression linéaire

On considère le modèle de régression linéaire multiple :

$$Y_i = \beta_0 + \sum_{j=1}^p \beta_j X_i^{(j)} + \varepsilon_i,$$

où :

- $Y_i$  désigne ici la variable `Alcohol` ;
- $X_i^{(1)}, \dots, X_i^{(p)}$  sont les covariables explicatives ;
- $\varepsilon_i$  désigne le bruit aléatoire.

### Q9. Instancier et ajuster le modèle

On ajuste le modèle avec la commande `lm()` :

```
model <- lm(Alcohol ~ ., data = vars_quant)
```

Ici, le symbole `.` signifie : “toutes les autres variables du tableau `vars_quant`<sup>1</sup> servent à expliquer `Alcohol`”.

### Q10. Variables significatives, coefficients estimés et erreurs standards

La commande centrale est :

```
summary(model)
```

Dans le tableau des coefficients :

- ✓ la colonne **Estimate** contient les estimateurs  $\hat{\beta}_j$  ;
- ✓ la colonne **Std. Error** contient les écarts-types estimés de ces estimateurs ;
- ✓ la colonne **Pr(>|t|)** contient les *p-values* associées aux tests de significativité.

---

1. On en prend en compte que les variables quantitatives pour ce modèle linéaire !

Au seuil de significativité 5%, les variables explicatives significatives sont :

**Malic, Alcalinity\_of\_Ash, Color\_Intensity, Proline.**

Leurs estimations, erreurs standards et *p-values* associées sont :

| Variable          | $\hat{\beta}_j$ | Std. Error | p-value                     |
|-------------------|-----------------|------------|-----------------------------|
| Malic             | 0.1316          | 0.0453     | 0.00415 (**)                |
| Alcalinity_of_Ash | -0.0378         | 0.0178     | 0.03537 (*)                 |
| Color_Intensity   | 0.1630          | 0.0274     | $1.63 \times 10^{-8}$ (***) |
| Proline           | 0.001016        | 0.0001999  | $1.01 \times 10^{-6}$ (***) |

On peut également extraire directement le tableau :

```
summary(model)$coefficients
```

#### Q11. Variable la moins significative

La variable la “moins” significative est celle dont la *p-value* est la plus grande parmi les variables explicatives.<sup>2</sup> Ici, il s’agit de **Magnesium** avec une *p-value* égale à 0.99901. Elle n’apporte donc aucune information statistiquement significative pour expliquer la variable **Alcohol** dans ce modèle.

#### Q12. Coefficient de détermination $R^2$

Le coefficient de détermination  $R^2$  mesure la proportion de variabilité totale de la variable réponse  $Y$  expliquée par le modèle de régression. De fait, il s’écrit comme le rapport entre la variabilité expliquée par le modèle et la variabilité totale des observations :

$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}.$$

Sous R, on le lit sur le `summary` et on peut aussi explicitement le relever via :

```
summary(model)$r.squared
summary(model)$adj.r.squared
```

On obtient :

$$R^2 = 0.5936, \quad R^2_{\text{ajusté}} = 0.564.$$

Ainsi, environ 59.36% de la variabilité de la variable **Alcohol** est expliquée par le modèle, ce qui correspond à une qualité d’ajustement correcte mais non excellente.

#### Q13. Écart-type des résidus

L’estimation de l’écart-type des résidus est donnée par :

```
summary(model)$sigma
```

On obtient :

$$\hat{\sigma} = 0.5361.$$

Cette quantité mesure la dispersion typique des résidus autour de 0. Plus elle est faible, plus les prédictions sont proches des valeurs observées.

2. En toute rigueur, une *p-value* n’a pas vocation à être interprétée comme une mesure graduelle de l’importance d’une variable. Elle sert uniquement à tester la compatibilité des données avec l’hypothèse nulle associée au coefficient considéré. Comparer les *p-values* entre variables pour établir un classement de significativité constitue donc une approximation pédagogique courante, mais doit être interprété avec prudence.

#### Q14. Inférence pour une nouvelle observation

On construit d'abord la nouvelle observation sous forme de `data.frame` :

```
new_obs <- data.frame(  
  Malic = 2.34,  
  Ash = 2.37,  
  Alcalinity_of_Ash = 19.49,  
  Magnesium = 99.74,  
  Total_Phenols = 2.30,  
  Flavanoids = 2.03,  
  Nonflavanoid_Phenols = 0.36,  
  Proanthocyanins = 1.59,  
  Color_Intensity = 5.06,  
  Hue = 0.96,  
  OD280_OD315 = 2.61,  
  Proline = 746.89  
)
```

La prédiction s'obtient par :

```
Y_new <- predict(model, newdata = new_obs)  
round(Y_new, 2)
```

Mathématiquement, la valeur prédite (*on dit aussi "ajusté"*) s'écrit :

$$\hat{Y}_{\text{new}} = \hat{\beta}_0 + \sum_{j=1}^p \hat{\beta}_j x_{\text{new}}^{(j)}.$$

On relève, arrondi à 2 chiffres significatifs après la virgule : `round(Y_new, 2) = 13.00`.

### Partie III – Analyse en composantes principales

On réalise maintenant une ACP sur les **variables explicatives uniquement**. La variable réponse `Alcohol` ne doit donc pas intervenir dans la construction des axes principaux. On pose :

```
X <- df[, -which(names(df) == "Alcohol")]
```

Dans cette matrice : `Class` est une variable qualitative supplémentaire et les autres variables sont quantitatives actives.

#### Q15. Réalisation de l'ACP

On utilise la commande :

```
library(FactoMineR)  
  
Wine.PCA <- PCA(X, scale.unit = TRUE, quali.sup = 1, graph = TRUE)
```

- ✓ Le paramètre `scale.unit = TRUE` impose une standardisation des variables, ce qui revient à réaliser l'ACP sur la matrice des corrélations.
- ✓ Le paramètre `quali.sup = 1` signifie que la première colonne de `X`, ici `Class`, est une variable qualitative supplémentaire. Elle n'intervient donc pas dans la construction des axes principaux.

Sur le plan mathématique, si  $\tilde{\mathbf{X}}_i$  désigne le vecteur centré-réduit de l'individu  $i$ , et si  $P_1, \dots, P_p$  désignent les vecteurs propres de la matrice de corrélation, alors les coordonnées factorielles sont données, pour  $k = 1, \dots, p$  l'index de la composante, par :

$$Z_i^k = P_k^\top \widetilde{\mathbf{X}}_i.$$

Ce sont les projections des observations sur les directions principales.

#### Q16. Variance expliquée par les deux premiers axes

Les valeurs propres et pourcentages de variance expliquée sont contenus dans :

```
Wine.PCA$eig[1:2, ]
```

On obtient :

$$\lambda_1 = 4.633 \quad \text{et} \quad \lambda_2 = 2.026.$$

Les pourcentages de variance expliquée associés sont :

$$38.61\% \quad \text{pour l'axe 1,} \quad 16.88\% \quad \text{pour l'axe 2.}$$

Ainsi, les deux premiers axes expliquent ensemble :

$$55.49\%$$

de la variance totale du nuage des observations.

On rappelle que la valeur propre  $\lambda_k$  mesure la variance portée par la composante principale  $k$ .

#### Q17. Variables contribuant le plus aux axes 1 et 2




FIGURE 3 – Cercle des corrélations associé aux deux premières composantes principales.

L'interprétation conjointe de la Figure 3 avec les contributions numériques confirme que l'axe 1 correspond essentiellement à un gradient de richesse phénolique, tandis que l'axe 2 est lié principalement à l'intensité colorante et à certaines caractéristiques minérales du vin.

On observe en effet que les variables **Flavanoids**, **Total\_Phenols** et **OD280\_OD315** sont fortement corrélées positivement à l'axe 1, tandis que **Malic**, **Alkalinity\_of\_Ash** et **Nonflavanoid\_Phenols** y sont corrélées négativement. L'axe 2 est principalement structuré par **Color\_Intensity**, **Ash**, **Magnesium** et **Proline**.



Pour examiner plus en détail les contributions des variables, on encode sur R :

```
sort(Wine.PCA$var$contrib[, 1], decreasing = TRUE)[1:5]
sort(Wine.PCA$var$contrib[, 2], decreasing = TRUE)[1:5]
```

Les variables contribuant le plus à l'axe 1 sont :

Flavanoids (18.17%), Total.Phenols (15.52%), OD280-OD315 (15.01%),  
Proanthocyanins (9.99%), Hue (9.81%).

Les variables contribuant le plus à l'axe 2 sont :

Color.Intensity (28.77%), Ash (20.65%), Magnesium (16.81%),  
Proline (14.99%), Hue (7.40%).

***Rappel :** La contribution d'une variable à un axe mesure dans quelle proportion elle participe à la définition de cet axe. Les variables les plus contributives sont donc celles qui structurent réellement la direction principale. Les coordonnées des variables sont accessibles via :*

```
Wine.PCA$var$coord[, 1:2]
```

*et correspondent aux corrélations entre les variables initiales et les composantes principales :*

$$\text{coord}(j, k) = \text{corr}(X^{(j)}, Z^{(k)}).$$

#### Q18. Individus contribuant le plus aux axes 1 et 2

Les individus les plus contributifs à chaque axe sont obtenus par :

```
sort(Wine.PCA$ind$contrib[, 1], decreasing = TRUE)[1:5]
sort(Wine.PCA$ind$contrib[, 2], decreasing = TRUE)[1:5]
```

Les individus contribuant le plus à l'axe 1 sont : 147, 15, 138, 137, 156.

Les individus contribuant le plus à l'axe 2 sont : 60, 159, 81, 77, 116.

La contribution d'un individu  $i$  à l'axe  $k$  est proportionnelle au carré de sa coordonnée factorielle sur cet axe :

$$\text{ctr}(i, k) = \frac{(Z_i^k)^2}{n\lambda_k}.$$

Ainsi, les individus les plus éloignés (*par rapport à l'origine*) le long d'un axe sont généralement ceux qui participent le plus à sa construction.

#### Q19. Interprétation statistique des axes 1 et 2

Pour interpréter un axe principal, on croise :

- les variables les plus contributives ;
- les coordonnées des variables ;
- éventuellement le cercle des corrélations.

Les commandes utiles sont :

```
Wine.PCA$var$coord[, 1:2]
Wine.PCA$var$contrib[, 1:2]
```

On observe que l'axe 1 est fortement corrélé positivement avec :

Flavanoids (0.917), Total\_Phenols (0.848), OD280\_OD315 (0.834),

ainsi qu'avec :

Proanthocyanins (0.680), Hue (0.674), Proline (0.571).

Cet axe oppose principalement ces variables aux variables :

Malic (-0.558), Alcalinity\_of\_Ash (-0.505), Nonflavanoid\_Phenols (-0.649).

L'axe 1 peut ainsi être interprété comme un axe décrivant globalement l'opposition entre des variables associées à une richesse phénolique élevée et certaines variables liées à la composition minérale ou acide.

L'axe 2 est fortement corrélé positivement avec :

Color\_Intensity (0.763), Ash (0.647), Magnesium (0.584), Proline (0.551),

et négativement avec :

Hue (-0.387).

Cet axe traduit donc principalement un gradient associé à l'intensité colorante et à certaines caractéristiques minérales du vin.

## Partie IV – Réduction de dimension

On décide maintenant de ne conserver que les trois premières composantes principales des covariables.

### Q20. Variance expliquée cumulée par trois composantes

La variance expliquée cumulée par les trois premiers axes se lit dans :

```
Wine.PCA$eig[3, 3]
```

On obtient et lit : 66.87%. Ainsi, les trois premières composantes principales résument environ les deux tiers de la variabilité totale des variables explicatives. Il s'agit donc d'une réduction de dimension substantielle tout en conservant une part importante de l'information initiale.

### Q21. Régression sur les trois premières composantes principales

On extrait les coordonnées factorielles des individus sur les trois premiers axes :

```
PC <- Wine.PCA$ind$coord[, 1:3]
```

Puis on construit un nouveau tableau pour la régression :

```
df_PCA <- data.frame(Alcohol = df$Alcohol, PC)
model_PCA <- lm(Alcohol ~ ., data = df_PCA)
```

Mathématiquement, on remplace ici les covariables initiales  $X^{(1)}, \dots, X^{(p)}$  par les composantes principales  $Z^1, Z^2, Z^3$ , qui sont non corrélées entre elles.

Le modèle estimé s'écrit alors :

$$\widehat{\text{Alcohol}} = 13.0006 + 0.0866 Z^1 + 0.3315 Z^2 - 0.2148 Z^3.$$

Les trois composantes principales sont statistiquement significatives (p-values < 0.001).

## Q22. Comparaison des coefficients de détermination

On compare les coefficients de détermination du modèle complet et du modèle réduit :

```
summary(model)$r.squared  
summary(model_PCA)$r.squared  
summary(model_PCA)$adj.r.squared
```

On obtient :

$$R^2_{\text{modèle complet}} = 0.5936,$$

$$R^2_{\text{modèle ACP}} = 0.4888, \quad R^2_{\text{ajusté}} = 0.4800.$$

Ainsi, le modèle basé sur les trois premières composantes principales explique environ 48.9% de la variabilité de la variable `Alcohol`, contre 59.36% pour le modèle initial.

La réduction de dimension entraîne donc une perte d'environ 10% de variance expliquée<sup>3</sup>.

## Q23. Conclusion : avantage et inconvénient

L'avantage principal de la réduction de dimension est de remplacer un grand nombre de variables potentiellement corrélées par un petit nombre de composantes principales non corrélées.

Cela permet entre-autre :

- de simplifier le modèle ;
- de réduire la redondance entre variables ;
- de stabiliser certaines méthodes d'apprentissage ;
- de limiter les effets de multicollinéarité entre covariables.

L'inconvénient principal est la perte d'interprétabilité directe : les composantes principales sont des combinaisons linéaires des variables initiales, et non des variables observées naturellement.

On observe ici que la réduction de dimension permet de conserver une part importante de la variabilité initiale (66.87%), mais au prix d'une diminution du pouvoir explicatif du modèle de régression.

## Partie V – Analyse discriminante linéaire (LDA)

On souhaite désormais prédire la variable catégorielle

$$Y = \text{Class}$$

à partir des variables explicatives quantitatives. L'analyse discriminante linéaire (LDA) cherche à construire des directions permettant de séparer au mieux les classes, sous l'hypothèse que les distributions conditionnelles sont gaussiennes avec une même matrice de covariance dans chaque classe :

$$X \mid \{Y = k\} \sim \mathcal{N}(\mu_k, \Sigma).$$

### Apprentissage sur seulement trois covariables

On conserve :

`Flavanoids`, `Color_Intensity`, `Proline`.

---

3. Dans de nombreux projets en pratique, l'ACP aide justement à augmenter les performances d'un modèle, surtout lorsque celui-ci est d'une architecture plus complexe comme un `RandomForest` ou un `NeuralNetwork`... Donc, toujours insérer une ACP dans votre pipeline et voir les performances rétrospectives qui en résultent !

#### Q24. Table de contingence de Class

```
table(df$Class)
```

On obtient :

| Classe   | 1  | 2  | 3  |
|----------|----|----|----|
| Effectif | 59 | 71 | 48 |

Les trois classes sont donc représentées de manière relativement équilibrée.

#### Q25. Construction du modèle LDA à trois variables

```
lda_model_3var <- lda(  
  Class ~ Flavanoids + Color_Intensity + Proline,  
  data = df  
)
```

Les probabilités *a priori* estimées sont :

(0.331, 0.399, 0.270).

Les directions discriminantes obtenues sont :

$$LD1 = -1.727 \text{Flavanoids} + 0.470 \text{Color\_Intensity} - 0.00323 \text{Proline},$$

$$LD2 = -0.372 \text{Flavanoids} + 0.405 \text{Color\_Intensity} + 0.00396 \text{Proline}.$$

La première direction discriminante explique :

74.78%

du pouvoir discriminant total.

#### Q26. Matrice de confusion

```
conf_mat_3var
```

On obtient :

| Classe réelle | Classe prédite |    |    |
|---------------|----------------|----|----|
|               | 1              | 2  | 3  |
| 1             | 56             | 3  | 0  |
| 2             | 4              | 66 | 1  |
| 3             | 0              | 1  | 47 |

TABLE 1 – Matrice de confusion du modèle LDA basé sur trois variables explicatives

Nombre d'observations correctement classées : 169

Nombre d'observations mal classées : 9

Le taux de bonne classification est donc :  $\frac{169}{178} \approx 94.9\%$ .

#### Q27. Observations mal classées

```
which(pred_3var$class != df$Class)
```

On obtient :

5, 22, 44, 62, 74, 96, 99, 122, 131.

### Q28. Observation la plus éloignée de sa classe réelle (au sens probabiliste)

```
worst_obs  
min(true_class_prob)
```

On obtient :

Observation 74

avec une probabilité *a posteriori* d'appartenir à sa vraie classe égale à : 0.0181. Cette observation est donc particulièrement atypique relativement à sa classe réelle selon le modèle.

### Q29. Prédiction pour un nouveau vin

```
pred_new$class  
pred_new$posterior
```

La classe estimée pour cette nouvelle observation est : `Class = 1`, avec probabilités *a posteriori* : (0.8078, 0.1922, 0.000015). Le modèle affecte donc ce vin à la classe 1 avec une probabilité élevée.

## Apprentissage avec toutes les covariables

On utilise maintenant l'ensemble des variables explicatives quantitatives.

### Q30. Construction du modèle complet

```
lda_model_full <- lda(  
  Class ~ .,  
  data = df  
)
```

Deux directions discriminantes sont obtenues, expliquant respectivement :

68.75% et 31.25%

du pouvoir discriminant total.

### Q31. Matrice de confusion et comparaison des performances

```
conf_mat_full
```

On obtient :

| Classe réelle | Classe prédite |    |    |
|---------------|----------------|----|----|
|               | 1              | 2  | 3  |
| 1             | 59             | 0  | 0  |
| 2             | 0              | 71 | 0  |
| 3             | 0              | 0  | 48 |

TABLE 2 – Matrice de confusion du modèle LDA utilisant toutes les variables explicatives

Nombre d'observations correctement classées : 178.

Nombre d'observations mal classées : 0.

Le modèle utilisant toutes les variables explicatives réalise donc ici une **classification parfaite**<sup>4</sup> sur l'échantillon d'apprentissage. Cela illustre qu'un modèle plus riche en variables peut améliorer fortement la capacité de discrimination, même si cette performance doit toujours être interprétée avec prudence en l'absence de validation croisée.

4. Attention, ça peut aussi être risqué d'*overfitting*... Il faut procéder à un *train-test split* avant d'apprendre un modèle pour vérifier sa capacité à réagir à de nouvelles observations.