

Examen d'entraînement – Statistiques et Machine Learning

Régression linéaire et ACP

Avril 2026

On considère le jeu de données de vins italien `UCI_wine.txt`. Ce jeu de données décrit différentes caractéristiques chimiques de vins issus de trois cépages distincts. Chaque observation correspond à un vin, caractérisé par des mesures physico-chimiques obtenues en laboratoire. On s'intéresse en particulier à la variable

$$Y = \text{Alcohol},$$

qui représente le **degré d'alcool du vin**. Cette variable joue un rôle important en œnologie, car elle constitue un indicateur global du processus de fermentation et influence directement certaines propriétés organoleptiques du vin, comme l'intensité aromatique ou l'équilibre gustatif.

L'objectif est de déterminer dans quelle mesure cette variable peut être expliquée à partir des autres caractéristiques chimiques disponibles dans le jeu de données. On cherche donc à modéliser la relation entre la variable réponse $Y = \text{Alcohol}$ et les autres variables quantitatives du jeu de données, notées $X^{(1)}, \dots, X^{(p)}$.

Par ailleurs, la variable `Class` correspond au cépage du vin. Il s'agit d'une variable qualitative décrivant l'origine botanique des observations. Elle ne sera pas utilisée dans la modélisation de la variable réponse dans un premier temps, mais pourra être exploitée ultérieurement pour interpréter la structure du jeu de données dans une perspective d'analyse multivariée. Dans toute la suite :

- les variables explicatives quantitatives seront notées $X^{(1)}, \dots, X^{(p)}$;
- la variable réponse est $Y = \text{Alcohol}$.

Partie I – Statistiques descriptives

- Q1.** Importer le jeu de données `wine` sous R. Préciser le nombre d'observations et le nombre de variables (colonnes).
- Q2.** Identifier les variables quantitatives et la variable qualitative.
- Q3.** Calculer la moyenne de `Alcohol` et l'écart-type de `Alcohol`.
- Q4.** Calculer le coefficient de corrélation entre `Alcohol` et `Malic`. Interpréter le résultat.
- Q5.** Déterminer :
 - s'il existe des valeurs manquantes ;
 - s'il existe des observations potentiellement atypiques.
- Q6.** Donner une ligne de code R permettant de relever les individus tels que

$$Y_i > \text{médiane}(Y).$$

- Q7.** Afficher la matrice de corrélation des variables quantitatives.
- Q8.** Déterminer le couple de variables quantitatives présentant la corrélation la plus forte (en valeur absolue).

Partie II – Régression linéaire

On considère le modèle :

$$Y_i = \beta_0 + \sum_{j=1}^p \beta_j X_i^{(j)} + \varepsilon_i.$$

Q9. Instancier et ajuster ce modèle.

Q10. À l'aide de la commande convenue :

- identifier les variables significatives
- relever leurs coefficients estimés
- relever l'écart-type associé à ces estimations

Q11. Identifier la variable la moins significative.

Q12. Donner le coefficient de détermination R^2 . Conclure sur la qualité du modèle.

Q13. Donner l'estimation de l'écart-type des résidus.

Q14. On considère une nouvelle observation décrite par :

```
Malic = 2.34,  Ash = 2.37,  Alcalinity_of_Ash = 19.49,  
Magnesium = 99.74,  Total_Phenols = 2.30,  Flavanoids = 2.03,  
Nonflavanoid_Phenols = 0.36,  Proanthocyanins = 1.59,  
Color_Intensity = 5.06,  Hue = 0.96,  OD280_OD315 = 2.61,  Proline = 746.89
```

a) Donner la commande R permettant d'estimer

$$Y_{\text{new}} = \widehat{\text{Alcohol}}.$$

b) Donner la valeur estimée, arrondie à deux décimales, de

$$Y_{\text{new}}.$$

Partie III – Analyse en composantes principales

On réalise une ACP sur les variables explicatives uniquement. Dans cette partie, la variable réponse Y **ne doit pas intervenir** dans l'ACP.¹

Q15. Réaliser l'ACP avec la commande `PCA()` du package `FactoMineR`. Préciser l'index de la variable qualitative supplémentaire.

Q16. Donner :

- la variance expliquée par la première composante principale;
- la variance expliquée par la deuxième composante principale.

Q17. Identifier :

- les variables contribuant le plus à l'axe principal 1
- les variables contribuant le plus à l'axe principal 2

Q18. Identifier :

- les individus contribuant le plus à l'axe principal 1
- les individus contribuant le plus à l'axe principal 2

Q19. Enfin, proposer une interprétation statistique de :

- l'axe principal 1
- l'axe principal 2

1. Ce ne sera pas forcément le cas à l'examen final, tout dépend du contexte. Ici, on souhaite réaliser une ACP sur les covariables pour prédire Y , d'où la pertinence (et même l'obligation) de la retirer en amont.

Partie IV – Réduction de dimension

On conserve uniquement les trois premières composantes principales des covariables (*Y n'est normalement pas intervenu dans l'ACP*).

- Q20.** Donner le pourcentage de variance expliquée cumulée par ces trois composantes principales.
- Q21.** Construire un nouveau modèle de régression linéaire en utilisant uniquement ces trois nouvelles variables.
- Q22.** Comparer le nouveau coefficient de détermination R^2 à celui du modèle complet précédent.
- Q23.** Conclure en donnant un avantage de la réduction de dimension et un inconvénient potentiel.

Partie V – Analyse discriminante linéaire (LDA)

On revient maintenant au jeu de données initial complet. On souhaite cette fois prédire la variable catégorielle

$$Y = \text{Class}$$

à partir des variables explicatives quantitatives à disposition. On met en œuvre une **analyse discriminante linéaire (LDA)** afin de construire un modèle de classification.

Apprentissage sur seulement trois covariables

Dans un premier temps, on restreint l'analyse aux trois variables explicatives suivantes :

$$\text{Flavanoids}, \quad \text{Color_Intensity}, \quad \text{Proline}.$$

- Q24.** Afficher la table de contingence de la variable **Class**. Combien d'observations appartiennent à chaque classe ?
- Q25.** Construire un modèle d'analyse discriminante linéaire permettant de prédire **Class** à partir des trois variables explicatives précédentes.
- Q26.** Construire la matrice de confusion associée à ce modèle. Donner le nombre d'observations correctement classées et le nombre d'observations mal classées.
- Q27.** Identifier, en une ligne de commande **R**, les observations pour lesquelles la prédiction du modèle est incorrecte.
- Q28.** Parmi les observations mal classées, identifier celle dont la probabilité *a posteriori* d'appartenir à sa classe réelle est la plus faible. Donner la valeur de cette probabilité.
- Q29.** On considère maintenant un vin caractérisé par :

$$\text{Flavanoids} = 2.50, \quad \text{Color_Intensity} = 5.20, \quad \text{Proline} = 900.$$

À quelle classe ce vin est-il affecté par le modèle précédent ? Donner également la probabilité *a posteriori* associée à cette prédiction.

Apprentissage avec toutes les covariables

On considère maintenant un modèle LDA utilisant l'ensemble des variables explicatives quantitatives.

- Q30.** Construire ce nouveau modèle.
- Q31.** Construire la matrice de confusion associée à ce modèle. Comparer ses performances à celles du modèle précédent.