

Correction TP Statistiques – LDA

Paul Minchella

Avril 2026

Objectif du TD

On étudie ici l'analyse discriminante linéaire (LDA) sur le célèbre jeu de données `iris`. Le but est de comprendre comment la LDA permet de classer une fleur d'iris à partir de ses quatre variables quantitatives :

`Sepal.Length`, `Sepal.Width`, `Petal.Length`, `Petal.Width`,
afin de prédire son espèce parmi

`setosa`, `versicolor`, `virginica`.

Question 1 – Chargement du package

Le package utilisé pour la LDA est `MASS`. La commande est :

```
library(MASS)
```

Question 2 – Chargement et première exploration des données

On charge le jeu de données `iris`, puis on sépare les variables explicatives quantitatives de la variable réponse :

```
data(iris)
df <- iris; X <- df[, 1:4]; y <- df$Species
```

Aperçu rapide du jeu de données

Les premières lignes montrent que chaque observation correspond à une fleur décrite par quatre mesures morphologiques et une espèce. Le jeu de données contient : $n = 150$ observations et les trois classes sont équilibrées :

50 `setosa`, 50 `versicolor`, 50 `virginica`.

Les statistiques descriptives indiquent notamment :

- `Sepal.Length` : moyenne 5.843,
- `Sepal.Width` : moyenne 3.057,
- `Petal.Length` : moyenne 3.758,
- `Petal.Width` : moyenne 1.199.

On peut obtenir un aperçu des écarts-type via :

```
apply(df[, 1:4], 2, sd)
```

Exploration graphique

Le pairplot des variables quantitatives permet de visualiser les relations entre variables. On constate déjà que les variables liées aux pétales, en particulier `Petal.Length` et `Petal.Width`, séparent très bien les espèces. Les histogrammes par classe confirment cette intuition :

- `Petal.Length` et `Petal.Width` sont très discriminantes ;
- `Sepal.Length` sépare partiellement les groupes ;
- `Sepal.Width` semble moins informative.

Le tout est présenté en Figure 1.

Question 3 – Ajustement du modèle LDA

On ajuste la LDA par :

```
lda_model <- lda(Species ~ ., data = df)
```

Le résumé du modèle est :

- probabilités *a priori* égales (et c'est normal car les classes sont équi-réparties dès le début) :

$$\hat{p}_{\text{setosa}} = \hat{p}_{\text{versicolor}} = \hat{p}_{\text{virginica}} = \frac{1}{3};$$

- centres de classes :

$$\begin{aligned}\mu_{\text{setosa}} &= (5.006, 3.428, 1.462, 0.246), \\ \mu_{\text{versicolor}} &= (5.936, 2.770, 4.260, 1.326), \\ \mu_{\text{virginica}} &= (6.588, 2.974, 5.552, 2.026).\end{aligned}$$

Coefficients des axes discriminants

R renvoie les coefficients suivants :

Covariable	<i>LD1</i>	<i>LD2</i>
<code>Sepal.Length</code>	0.8294	0.0241
<code>Sepal.Width</code>	1.5345	2.1645
<code>Petal.Length</code>	-2.2012	-0.9319
<code>Petal.Width</code>	-2.8105	2.8392

Ces coefficients définissent les deux axes discriminants *LD1* et *LD2*.

Interprétation. Comme il y a $K = 3$ classes, la LDA produit au plus $K - 1 = 2$ axes discriminants. Le premier axe *LD1* porte l'essentiel de la discrimination, ce qui est confirmé par :

$$\text{Proportion of trace} = \begin{cases} 0.9912 & \text{pour } LD1, \\ 0.0088 & \text{pour } LD2. \end{cases}$$

Le premier axe *LD1* explique à lui seul plus de 99% de la séparation discriminante entre classes.




FIGURE 1 – Exploration graphique des variables explicatives du jeu de données *iris*. Le pairplot met en évidence une bonne séparation entre les espèces, en particulier selon les variables **Petal.Length** et **Petal.Width**, qui apparaissent fortement discriminantes. Les histogrammes par classe confirment cette observation : l'espèce **setosa** est clairement séparée des deux autres, tandis que la distinction entre **versicolor** et **virginica** est plus subtile. Ces observations suggèrent que les variables liées aux pétales jouent un rôle central dans la classification et motivent l'utilisation d'une analyse discriminante linéaire.

Question 4 – Explorer le modèle appris

Probabilités *a priori*

R retrouve :

$$\hat{p}_{\text{setosa}} = \hat{p}_{\text{versicolor}} = \hat{p}_{\text{virginica}} = \frac{1}{3}.$$

Cela est cohérent avec le fait que les trois espèces sont présentes en effectifs égaux.

Effectifs

Espèce	Effectif
setosa	50
versicolor	50
virginica	50

Centres de gravité des classes

Les centres de gravité sont exactement ceux donnés par `lda_model$means`. Ils montrent que les trois classes sont bien séparées, en particulier sur les variables de pétale.

Coefficients discriminants

Les coefficients affichés dans `lda_model$scaling` correspondent aux coefficients des combinaisons linéaires utilisées pour construire *LD1* et *LD2*. Ce sont eux qui permettent de projeter les individus dans l'espace discriminant.

Valeurs singulières

R affiche :

$$\text{lda_model}\$svd = (48.64, 4.58).$$

Le carré de ces quantités est lié aux valeurs propres discriminantes. Leur forte dissymétrie confirme que le premier axe suffit presque à lui seul à séparer les espèces.

Question 5 – Utilisation de predict

La commande

```
lda_pred <- predict(lda_model, newdata = X)
```

renvoie un objet contenant trois composantes :

- `class` : la classe prédite ;
- `posterior` : les probabilités *a posteriori* ;
- `x` : les coordonnées sur les axes discriminants.

Par exemple, pour les premières observations, R prédit bien **setosa**. Les coordonnées sur les axes discriminants sont de la forme :

Classe	<i>LD1</i>	<i>LD2</i>
1	8.0618	0.3004
2	7.1287	-0.7867
3	7.4898	-0.2654

Ces valeurs indiquent la position des individus dans l'espace discriminant.

Question 6 – Matrice de confusion

Il est essentiel d'évaluer les performances d'un modèle de classification après son apprentissage. Une première manière simple et très informative consiste à comparer les classes prédites par le modèle aux classes réellement observées. Cette comparaison est synthétisée dans un tableau appelé **matrice de confusion**. La matrice de confusion permet de visualiser, pour chaque classe réelle, la répartition des observations dans les différentes classes prédites par le modèle. Une bonne classification se traduit par des valeurs élevées sur la diagonale du tableau (observations correctement classées) et faibles en dehors de la diagonale (erreurs de classification). Sous R, cette matrice peut être obtenue à l'aide de la commande suivante :

```
conf_mat_lda <- table(
  Classe_reelle = y,
  Classe_predite = lda_pred$class
)
conf_mat_lda
```

La matrice de confusion obtenue est :

Classe réelle	Classe prédite		
	setosa	versicolor	virginica
setosa	50	0	0
versicolor	0	48	2
virginica	0	1	49

TABLE 1 – Matrice de confusion obtenue avec la LDA sur le jeu d'apprentissage `iris`.

Interprétation

- Les `setosa` sont parfaitement reconnues.
- Les erreurs se concentrent entre `versicolor` et `virginica`, ce qui est classique sur ce jeu de données.

Le taux de bonne classification est :

$$\frac{50 + 48 + 49}{150} = \frac{147}{150} = 0.98.$$

Donc :

$$\text{accuracy} = 98\%, \quad \text{erreur} = 2\%.$$

La LDA est donc ici bien performante (*le jeu de données iris s'y prête bien...*).

Question 7 – Probabilités *a posteriori*

La sortie `lda_pred$posterior` renvoie les probabilités *a posteriori* : $\hat{\mathbb{P}}(Y = j \mid X = x)$. Par exemple, pour les premières observations :

Obs.	setosa	versicolor	virginica
1	1	3.9×10^{-22}	2.6×10^{-42}
2	1	7.2×10^{-18}	5.0×10^{-37}

Les probabilités sont donc extrêmement concentrées sur la bonne classe pour les `setosa`. Pour les dernières observations, on trouve par exemple :

Obs.	setosa	versicolor	virginica
150	2.9×10^{-33}	1.75×10^{-2}	0.9824577

ce qui traduit une forte probabilité d'appartenance à `virginica`.

Question 8 – Lien entre prédiction et probabilités *a posteriori*

On vérifie que la classe prédite est exactement celle qui maximise la probabilité *a posteriori* :

$$\hat{y}(x) = \arg \max_j \mathbb{P}(Y = j \mid X = x).$$

La commande

```
all(class_from_posterior == as.character(lda_pred$class))
```

renvoie TRUE, ce qui confirme que la règle de décision utilisée par la LDA consiste bien à attribuer chaque individu à la classe de probabilité *a posteriori* maximale.

Question 9 – Inférence sur de nouvelles observations

On considère quatre nouvelles fleurs caractérisées par leurs variables explicatives (Sepal.Length, Sepal.Width, Petal.Length, Petal.Width) :

Observation	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
1	5.0	3.4	1.5	0.2
2	6.2	2.8	4.8	1.8
3	6.9	3.1	5.4	2.1
4	5.8	2.7	5.1	1.9

TABLE 2 – Nouvelles observations à classifier.

Après application du modèle d'analyse discriminante linéaire appris précédemment, les classes prédites sont les suivantes :

Observation	Classe prédite
1	setosa
2	virginica
3	virginica
4	virginica

TABLE 3 – Classes prédites par la LDA pour les nouvelles observations.

On observe que la première fleur est classée sans ambiguïté dans la classe **setosa**, tandis que les trois autres observations sont associées à la classe **virginica**, ce qui est cohérent avec leurs caractéristiques morphologiques, notamment des dimensions de pétales relativement élevées.

Probabilités *a posteriori* associées

Pour la première fleur $\mathbf{x}_1 = (5.1, 3.5, 1.4, 0.2)$:

$$\hat{\mathbb{P}}(\text{setosa} \mid \mathbf{x}_1) = 1$$

à la précision numérique près, ce qui est parfaitement cohérent avec ses petites dimensions de pétale.

Pour la deuxième fleur $\mathbf{x}_2 = (6.2, 2.8, 4.8, 1.8)$:

$$\hat{\mathbb{P}}(\text{versicolor} \mid \mathbf{x}_2) = 0.19, \quad \hat{\mathbb{P}}(\text{virginica} \mid \mathbf{x}_2) = 0.81.$$

La fleur est donc prédite **virginica**, mais avec une hésitation modérée avec **versicolor**. Les troisième et quatrième fleurs sont classées **virginica** avec une probabilité très élevée. *Etc etc...*

Conclusion générale du TD

Ce TD met en évidence plusieurs faits importants sur la LDA :

- la méthode est simple à ajuster sous R via `lda()` ;
- elle fournit à la fois des classes prédites, des probabilités *a posteriori* et des axes discriminants ;
- sur le jeu `iris`, elle obtient une excellente performance (*à prendre avec des pincettes...*) ;
- la séparation entre classes repose principalement sur le premier axe discriminant ;
- les variables de pétale sont les plus discriminantes.

En bref, la LDA constitue ici un excellent outil de classification supervisée, à la fois efficace, interprétable et géométriquement lisible.

Ce qu'il faut savoir faire

À l'issue de ce TP, il est important de maîtriser les points suivants :

- (★) Comprendre le principe de l'analyse discriminante linéaire (LDA) : le modèle appris permet, à partir d'un vecteur de covariables $\mathbf{z} = (z^{(1)}, \dots, z^{(p)})$, d'attribuer une observation à une classe $y \in \{1, \dots, K\}$ en comparant les probabilités *a posteriori* d'appartenance aux différentes classes.
- (★) Savoir construire et afficher une **matrice de confusion** afin de comparer les classes prédites aux classes réelles.
- (★) Savoir calculer le **nombre** et la **proportion d'observations bien classées** (taux de bonne classification), ainsi que le **taux d'erreur** associé.
- (★) Savoir identifier les observations **mal classées** par le modèle.
- (★) Savoir relever les probabilités *a priori* d'appartenance aux classes (proportions des classes dans l'échantillon d'apprentissage).
- (★) Savoir relever les probabilités *a posteriori* d'appartenance à chaque classe pour une observation donnée, et comprendre que la classe prédite correspond à celle dont la probabilité *a posteriori* est maximale.
- (★) Savoir utiliser la fonction `predict` pour :
 - obtenir les classes prédites,
 - accéder aux probabilités *a posteriori*,
 - projeter les observations sur les axes discriminants,
 - réaliser des prédictions pour de nouvelles observations.