

Notes de cours sur la LDA

Paul Minchella

Avril 2026




Table des matières

1	Motivation générale	2
1.1	Motivation géométrique	2
1.2	Résultat fondamental en analyse discriminante	3
2	Matrices de variance en analyse discriminante	3
2.1	Florilège de matrices de variance	4
2.2	Décomposition fondamentale de la variance	6
2.3	Estimation de la matrice de covariance commune	8
3	Apprentissage bayésien de l'analyse discriminante linéaire	8
3.1	Modélisation probabiliste des classes	8
3.2	Probabilités <i>a posteriori</i> et règle de Bayes	9
3.3	Apprentissage bayésienne	9
4	Critère de Fisher	11
4.1	Lien avec le critère de Fisher	11
4.2	Lecture géométrique de la LDA et interprétation	12
4.2.1	La forme quadratique comme mesure de la variance	12
4.2.2	Interprétation des axes discriminants	12
4.2.3	Proportion de la trace	12
4.3	Coïncidence entre approche bayésienne et critère de Fisher	13
	Une brève conclusion	13
	Synthèse : Analyse Discriminante Linéaire (LDA)	14

1 Motivation générale

L'analyse discriminante linéaire (**LDA** pour *Linear Discriminant Analysis*) est une méthode de **classification supervisée** dont l'objectif est d'attribuer à une observation $\mathbf{x} = (x^1, \dots, x^p) \in \mathbb{R}^p$ une classe $y \in \{1, \dots, K\}$. On souhaite donc construire une règle de décision

$$\mathbf{x} \mapsto \hat{y}(\mathbf{x})$$

qui approxime au mieux la vraie classe associée à l'observation.

1.1 Motivation géométrique

L'idée centrale de la LDA consiste à **séparer les classes dans l'espace des variables explicatives** à l'aide de frontières de décision simples. Supposons que l'on observe deux variables explicatives $(X^{(1)}, X^{(2)})$ et trois classes possibles $Y \in \{1, 2, 3\}$. On suppose que conditionnellement à la classe, les observations suivent des lois normales :

Exemple 1.1. On suppose que

$$(X^{(1)}, X^{(2)}) \mid \{Y = j\} \sim \mathcal{N}(\mu_j, \Sigma), \quad j = 1, 2, 3,$$

où chaque moyenne (barycentre) $\mu_1, \mu_2, \mu_3 \in \mathbb{R}^2$ est différente mais la matrice de covariance Σ est commune aux trois groupes.




FIGURE 1 – Illustration d'un jeu de données adapté à la LDA. Chaque patient est décrit par deux biomarqueurs : $X^{(1)}$ (niveau de CRP normalisé, biomarqueur inflammatoire) et $X^{(2)}$ (score radiologique de masse tumorale). On distingue les 3 classes (diagnostics cliniques : inflammation, tumeur suspecte et tumeur). Les ellipses pointillées représentent des courbes d'iso-densité gaussienne associées à chaque classe et possèdent la même forme (homoscédasticité). Les étoiles indiquent les centres empiriques des classes.

Cette hypothèse signifie d'une part que chaque classe possède un **centre différent** ; et d'autre part que la **forme de dispersion autour du centre est identique** puisque la matrice de covariance est la même pour chaque groupe. Dans ce cas, les régions les plus probables d'appartenance aux classes sont séparées par des **frontières linéaires**.

1.2 Résultat fondamental en analyse discriminante

Proposition 1.1. Si

$$X \mid \{Y = j\} \sim \mathcal{N}(\mu_j, \Sigma)$$

avec une matrice de covariance commune à toutes les classes, alors la règle de classification bayésienne optimale sépare les classes par des frontières linéaires.

Cette propriété constitue la justification principale de la LDA : elle permet de construire une règle simple, interprétable et efficace.




FIGURE 2 — Les droites violettes représentent les frontières de décision linéaires estimées par la LDA entre les trois diagnostics cliniques (inflammation, tumeur suspecte et tumeur certaine). Sous l'hypothèse d'une matrice de covariance commune entre classes, la règle de classification bayésienne conduit à des séparateurs affines dans l'espace des variables explicatives. Ces frontières sont déterminées à partir des centres empiriques des groupes et de leur structure de dispersion intra-classes commune, et partitionnent l'espace des biomarqueurs en régions associées à chaque diagnostic.

Interprétation intuitive. L'objectif de la LDA consiste à :

- rapprocher les observations appartenant à une même classe,
- éloigner les centres des classes entre eux.

Ce que l'on peut formuler par :

minimiser la variance intra-classe et maximiser la variance inter-classe.

C'est justement ce compromis qu'on va formaliser dans ce qui suit.

2 Matrices de variance en analyse discriminante

Les figures précédentes l'illustrent : il existe plusieurs objets pour décrire la variabilité au sein d'un jeu de données qui se distingue par une variable à modalité. Pour comprendre la construction de la LDA, il est donc nécessaire d'introduire plusieurs matrices décrivant la dispersion des observations.

2.1 Florilège de matrices de variance

Soit $\mathbf{X}_i = (X_i^1, \dots, X_i^p)^\top$ les variables explicatives observées pour un individu i . On définit la version centrée de la variable par :

$$\widetilde{\mathbf{X}}_i = \begin{pmatrix} \widetilde{X}_i^1 \\ \vdots \\ \widetilde{X}_i^p \end{pmatrix} = \begin{pmatrix} X_i^1 - \bar{X}^1 \\ \vdots \\ X_i^p - \bar{X}^p \end{pmatrix}$$

où

$$\bar{X}^j = \frac{1}{n} \sum_{i=1}^n X_i^j.$$

Matrice de covariance empirique totale. Un premier objet à traiter est celui *a priori* sur le jeu de donnée global.

Définition 2.1. La matrice de covariance empirique est définie par

$$V = \frac{1}{n} \sum_{i=1}^n \widetilde{\mathbf{X}}_i \widetilde{\mathbf{X}}_i^\top.$$

Cette matrice mesure la dispersion globale du nuage de points autour de son centre de gravité.¹

Centre de gravité des classes. On introduit ici des notations très utiles pour la suite.

Définition 2.2 (Classe et centre de gravité). On note

$$C_j = \{i \mid Y_i = j\}$$

l'ensemble des observations appartenant à la classe j . Le centre de gravité de la classe j est défini par

$$\mu_j = \bar{\mathbf{X}}_j = \begin{pmatrix} \frac{1}{n_j} \sum_{i \in C_j} X_i^1 \\ \vdots \\ \frac{1}{n_j} \sum_{i \in C_j} X_i^p \end{pmatrix}.$$

Ce vecteur représente la position moyenne de la classe dans l'espace des variables explicatives.

Matrice de covariance intra-classe. La dispersion interne à une classe est mesurée par sa matrice de covariance empirique :

Définition 2.3. La matrice de covariance intra-classe associée à la classe j est

$$V_j = \frac{1}{n_j} \sum_{i \in C_j} (X_i - \bar{\mathbf{X}}_j)(X_i - \bar{\mathbf{X}}_j)^\top.$$

Elle mesure la dispersion des observations autour du centre de gravité de la classe.

1. Lorsque l'on a introduit l'ACP, on a vu comme correspondance géométrique que le nuage de points peut-être dessiné par une ellipse multidimensionnelle dont les axes principaux correspondent aux composantes principales de la matrice de variance-covariance.

Matrice de covariance intra-classe globale. On définit ensuite la matrice de covariance intra-classe globale comme moyenne pondérée (barycentre) des matrice de covariance intra-classe :

Définition 2.4. La matrice de covariance intra-classe globale est

$$W = \sum_{j=1}^K \frac{n_j}{n} V_j.$$

W mesure la dispersion moyenne des observations autour des centres des classes et quantifie donc la variabilité *interne* aux groupes, indépendamment de leur position relative dans l'espace des variables explicatives.

Cette matrice joue un rôle fondamental en analyse discriminante : contrairement à la matrice de covariance totale V de la Définition 2.1, qui mesure la dispersion globale du nuage de points autour du centre moyen total $\bar{\mathbf{X}}$, la matrice W mesure uniquement la dispersion des observations autour de leur *centre de classe* respectif. Ainsi :

→ la matrice V mélange deux sources de variabilité : la variabilité interne aux classes et la variabilité due à la séparation entre les classes ;

→ la matrice W isole uniquement la variabilité interne aux classes.

L'objectif de l'analyse discriminante linéaire consiste précisément à construire des directions de projection qui minimisent la dispersion intra-classe (décrite par W) tout en maximisant la séparation entre classes (décrite par la matrice de covariance inter-classes B que l'on présente juste après).

Matrice de covariance inter-classes. La dispersion entre les classes est mesurée par la matrice suivante.

Définition 2.5. La matrice de covariance inter-classes est définie par

$$B = \sum_{j=1}^K \frac{n_j}{n} (\mu_j - \bar{\mathbf{X}})(\mu_j - \bar{\mathbf{X}})^\top.$$

Elle mesure la dispersion des centres de classes autour du centre global $\bar{\mathbf{X}}$, et quantifie ainsi la séparation entre les classes.

La matrice B est construite de manière analogue à une matrice de covariance classique : elle mesure ici la dispersion non plus des observations individuelles, mais des *centres de classes* autour du centre moyen global du nuage de points. En effet, chaque vecteur $\mu_j - \bar{\mathbf{X}}$ décrit l'écart entre le centre de la classe j et le centre global des données. La matrice

$$(\mu_j - \bar{\mathbf{X}})(\mu_j - \bar{\mathbf{X}})^\top$$

mesure alors la contribution directionnelle de cette classe à la séparation globale entre groupes, et la pondération par n_j/n tient compte de la taille relative de chaque classe dans l'échantillon.

Ainsi, la matrice B fournit une mesure de la dispersion *entre* les classes, complémentaire de la matrice W , qui mesure la dispersion *à l'intérieur* des classes.

Conséquence

L'introduction de cet objet est naturelle dans le contexte de la classification : si les centres de classes sont très éloignés les uns des autres, la discrimination entre groupes est facile ; au contraire, si ces centres sont proches, la séparation des classes devient plus difficile. La matrice B quantifie précisément ce phénomène et permettra, dans la suite, de construire des directions de projection maximisant la séparation entre classes.

2.2 Décomposition fondamentale de la variance

On peut maintenant relier ces différentes matrices.

Théorème 2.1. *La variance totale se décompose en somme de la variance intra-classe et de la variance inter-classe :*

$$V = W + B.$$

Preuve.

On souhaite démontrer la décomposition suivante :

$$\frac{1}{n} \sum_{i=1}^n (X_i - \bar{\mathbf{X}})(X_i - \bar{\mathbf{X}})^\top = \sum_{j=1}^K \frac{n_j}{n} V_j + \sum_{j=1}^K \frac{n_j}{n} (\mu_j - \bar{\mathbf{X}})(\mu_j - \bar{\mathbf{X}})^\top.$$

Soit $i \in \{1, \dots, n\}$, et notons Y_i la classe de l'observation X_i . On peut alors écrire

$$X_i - \bar{\mathbf{X}} = (X_i - \mu_{Y_i}) + (\mu_{Y_i} - \bar{\mathbf{X}}).$$

Cette identité est simple mais essentielle : on a simplement ajouté puis retranché le centre de la classe à laquelle appartient X_i . En reportant cette décomposition dans l'expression de V , on obtient

$$V = \frac{1}{n} \sum_{i=1}^n \left[(X_i - \mu_{Y_i}) + (\mu_{Y_i} - \bar{\mathbf{X}}) \right] \left[(X_i - \mu_{Y_i}) + (\mu_{Y_i} - \bar{\mathbf{X}}) \right]^\top.$$

On exploite distributivité et la linéarité de la transposée,

$$V = \frac{1}{n} \sum_{i=1}^n \left[(X_i - \mu_{Y_i})(X_i - \mu_{Y_i})^\top + (X_i - \mu_{Y_i})(\mu_{Y_i} - \bar{\mathbf{X}})^\top + (\mu_{Y_i} - \bar{\mathbf{X}})(X_i - \mu_{Y_i})^\top + (\mu_{Y_i} - \bar{\mathbf{X}})(\mu_{Y_i} - \bar{\mathbf{X}})^\top \right].$$

On sépare alors cette somme en quatre morceaux :

$$\begin{aligned} V &= \frac{1}{n} \sum_{i=1}^n (X_i - \mu_{Y_i})(X_i - \mu_{Y_i})^\top \\ &\quad + \frac{1}{n} \sum_{i=1}^n (X_i - \mu_{Y_i})(\mu_{Y_i} - \bar{\mathbf{X}})^\top \\ &\quad + \frac{1}{n} \sum_{i=1}^n (\mu_{Y_i} - \bar{\mathbf{X}})(X_i - \mu_{Y_i})^\top \\ &\quad + \frac{1}{n} \sum_{i=1}^n (\mu_{Y_i} - \bar{\mathbf{X}})(\mu_{Y_i} - \bar{\mathbf{X}})^\top. \end{aligned}$$

Puis on étudie chacun de ces termes.

Étude du premier terme. Regroupons les observations par classe. Comme $Y_i = j$ signifie $i \in C_j$, on peut écrire

$$\frac{1}{n} \sum_{i=1}^n (X_i - \mu_{Y_i})(X_i - \mu_{Y_i})^\top = \frac{1}{n} \sum_{j=1}^K \underbrace{\sum_{i \in C_j} (X_i - \mu_j)(X_i - \mu_j)^\top}_{= n_j V_j}.$$

On reconnaît ici la définition V_j au nombre n_j prêt, donc

$$\frac{1}{n} \sum_{i=1}^n (X_i - \mu_{Y_i})(X_i - \mu_{Y_i})^\top = \frac{1}{n} \sum_{j=1}^K n_j V_j = \sum_{j=1}^K \frac{n_j}{n} V_j = W.$$

Étude des deux termes croisés. Considérons le deuxième terme, que l'on regroupe par classe :

$$\frac{1}{n} \sum_{i=1}^n (X_i - \mu_{Y_i})(\mu_{Y_i} - \bar{\mathbf{X}})^\top = \frac{1}{n} \sum_{j=1}^K \sum_{i \in C_j} (X_i - \mu_j)(\mu_j - \bar{\mathbf{X}})^\top.$$

Comme $(\mu_j - \bar{\mathbf{X}})^\top$ ne dépend pas de i , on peut le sortir de la somme intérieure :

$$\frac{1}{n} \sum_{j=1}^K (\mu_j - \bar{\mathbf{X}})^\top \left(\sum_{i \in C_j} (X_i - \mu_j) \right).$$

Or, par définition du centre de gravité μ_j ,

$$\sum_{i \in C_j} (X_i - \mu_j) = 0.$$

Donc ce deuxième terme est nul :

$$\frac{1}{n} \sum_{i=1}^n (X_i - \mu_{Y_i})(\mu_{Y_i} - \bar{\mathbf{X}})^\top = 0.$$

De la même manière, le troisième terme vaut aussi 0 :

$$\frac{1}{n} \sum_{i=1}^n (\mu_{Y_i} - \bar{\mathbf{X}})(X_i - \mu_{Y_i})^\top = 0.$$

Étude du dernier terme. Il reste

$$\frac{1}{n} \sum_{i=1}^n (\mu_{Y_i} - \bar{\mathbf{X}})(\mu_{Y_i} - \bar{\mathbf{X}})^\top.$$

Comme toutes les observations d'une même classe j ont le même centre μ_j , ce terme prend la même valeur pour chacun des n_j individus de la classe j . On peut donc regrouper par classe :

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n (\mu_{Y_i} - \bar{\mathbf{X}})(\mu_{Y_i} - \bar{\mathbf{X}})^\top &= \frac{1}{n} \sum_{j=1}^K n_j (\mu_j - \bar{\mathbf{X}})(\mu_j - \bar{\mathbf{X}})^\top \\ &= \sum_{j=1}^K \frac{n_j}{n} (\mu_j - \bar{\mathbf{X}})(\mu_j - \bar{\mathbf{X}})^\top = B. \end{aligned}$$

Conclusion. En réunissant les quatre calculs précédents, on obtient $V = W + 0 + 0 + B$. Donc

$$\boxed{V = W + B.}$$

□

Conséquence

Cette décomposition signifie que la dispersion totale du nuage de points se partage en deux parties quadratique (analogue à Pythagore) :

- une part due à la dispersion à l'intérieur des classes [Matrice W];
- une part due à la dispersion entre les classes [Matrice B].

C'est ce qui est exploité pour apprendre un modèle d'analyse discriminante linéaire, son objectif étant :

maximisent B et minimisent W .

2.3 Estimation de la matrice de covariance commune

Dans le modèle d'analyse discriminante linéaire, on suppose que les variables explicatives suivent, conditionnellement à la classe, une loi gaussienne de la forme

$$X \mid \{Y = j\} \sim \mathcal{N}(\mu_j, \Sigma)$$

où la matrice de covariance Σ est supposée identique pour toutes les classes (hypothèse d'homoscédasticité). Cette matrice n'est pas connue en pratique et doit être estimée à partir des données. Pour chaque classe j , on peut estimer la matrice de covariance empirique intra-classe comme en Définition 2.3. Sous l'hypothèse que toutes les classes partagent la même matrice de covariance, il est naturel de combiner ces estimateurs en une matrice **moyenne pondérée** :

$$\hat{\Sigma} = \frac{1}{n-K} \sum_{j=1}^K (n_j - 1) V_j = \frac{1}{n-K} \sum_{j=1}^K \sum_{i \in C_j} (X_i - \mu_j)(X_i - \mu_j)^\top.$$

Cette matrice est appelée *estimateur pooled* de la covariance commune.² Elle correspond à une estimation globale de la dispersion intra-classe moyenne et constitue la version normalisée de la matrice de variance intra-classe W introduite précédemment.

Elle joue un rôle central dans la LDA : son inverse intervient directement dans la construction des fonctions discriminantes et donc dans la détermination des frontières de décision linéaires entre classes.

3 Apprentissage bayésien de l'analyse discriminante linéaire

On s'attaque désormais à la construction de la règle de classification optimale reposant sur un modèle probabiliste des données. On considère une observation

$$\mathbf{z} = (z^1, \dots, z^p) \in \mathbb{R}^p$$

et l'on souhaite déterminer la classe

$$Y \in \{1, \dots, K\}$$

à laquelle elle appartient.

3.1 Modélisation probabiliste des classes

On note

$$E_j = \{Y = j\}$$

l'évènement : "l'observation appartient à la classe j ". On suppose que, conditionnellement à la classe j , la variable explicative Z possède une densité $f_j(\mathbf{z})$ appelée densité conditionnelle de Z sachant $\{Y = j\}$. On note également

$$p_j = \mathbb{P}(E_j)$$

la probabilité *a priori* d'appartenance à la classe j . En pratique, on estime généralement

$$p_j \approx \frac{n_j}{n},$$

traduisant la proportion d'individus de la classe j . C'est une inférence naïve *a priori*.

La densité marginale de Z , indépendamment de la classe, est obtenue par la formule des probabilités totales. En effet, la variable aléatoire Z peut être vue comme issue de l'une des distributions conditionnelles

$$f_j(\mathbf{z}) = f(\mathbf{z} \mid Y = j),$$

avec probabilité

$$p_j = \mathbb{P}(Y = j).$$

2. C'est une version **non biaisée** de V définie plus tôt dans ce cours.

Ainsi, pour tout $\mathbf{z} \in \mathbb{R}^p$, la densité marginale de Z s'écrit comme une moyenne pondérée des densités conditionnelles :

$$f(\mathbf{z}) = \sum_{j=1}^K \mathbb{P}(Y = j) f(\mathbf{z} | Y = j) = \sum_{j=1}^K p_j f_j(\mathbf{z}).$$

La distribution de Z est un **mélange** des distributions conditionnelles associées aux différentes classes, naturellement pondéré par la proportion d'individus par classe.

3.2 Probabilités *a posteriori* et règle de Bayes

L'objectif est maintenant d'apprendre un modèle pour calculer la probabilité d'appartenance à la classe j sachant l'observation $\mathbf{z}$:

$$\mathbb{P}(E_j | Z = \mathbf{z}).$$

Proposition 3.1 (Formule de Bayes). On a

$$\mathbb{P}(E_j | \{Z = \mathbf{z}\}) = \frac{p_j f_j(\mathbf{z})}{\sum_{\ell=1}^K p_\ell f_\ell(\mathbf{z})}. \quad (\text{FB})$$

Preuve. D'après le théorème de Bayes,

$$\mathbb{P}(E_j | \{Z = \mathbf{z}\}) = \frac{\mathbb{P}(\{Z = \mathbf{z}\} | E_j) \mathbb{P}(E_j)}{\mathbb{P}(Z = \mathbf{z})}.$$

Or

$$\mathbb{P}(\{Z = \mathbf{z}\} | E_j) = f_j(\mathbf{z})$$

et

$$\mathbb{P}(Z = \mathbf{z}) = f(\mathbf{z}) = \sum_{\ell=1}^K p_\ell f_\ell(\mathbf{z}).$$

D'où

$$\mathbb{P}(E_j | \{Z = \mathbf{z}\}) = \frac{p_j f_j(\mathbf{z})}{\sum_{\ell=1}^K p_\ell f_\ell(\mathbf{z})}.$$

□

Remarque 1 (Abus de notation classique). Dans les expressions précédentes, l'écriture $\mathbb{P}(Z = \mathbf{z})$ constitue un abus de notation. En effet, lorsque la variable aléatoire Z est continue, on a $\mathbb{P}(Z = \mathbf{z}) = 0$. La quantité utilisée dans la formule de Bayes n'est donc pas une probabilité ponctuelle, mais une *densité de probabilité* évaluée en $\mathbf{z}$, notée $f(\mathbf{z})$. De manière rigoureuse, la formule de Bayes doit s'écrire sous forme de densités :

$$\mathbb{P}(Y = j | Z = \mathbf{z}) = \frac{f(\mathbf{z} | Y = j) \mathbb{P}(Y = j)}{f(\mathbf{z})}.$$

L'écriture $\mathbb{P}(Z = \mathbf{z})$ est néanmoins très courante dans les présentations introductives car elle permet de conserver une analogie formelle avec la version discrète du théorème de Bayes.

3.3 Apprentissage bayésienne

Règle de décision bayésienne optimale. La règle de classification bayésienne consiste à attribuer $\mathbf{z}$ à la classe ayant la probabilité *a posteriori* maximale :

$$\hat{y}(\mathbf{z}) = \operatorname{argmax}_{j \in \{1, \dots, K\}} \mathbb{P}(E_j | Z = \mathbf{z}).$$

En remplaçant par l'expression de l'Équation (FB), comme le dénominateur est indépendant de j , cela revient à maximiser $p_j f_j(\mathbf{z})$. Ainsi,

$$\hat{y}(\mathbf{z}) = \operatorname{argmax}_j p_j f_j(\mathbf{z}).$$

Hypothèse gaussienne du modèle LDA. Rappelons que dans le cadre de la LDA, on suppose que pour tout $j \in \{1, \dots, K\}$,

$$Z \mid \{Y = j\} \sim \mathcal{N}(\mu_j, \Sigma)$$

avec une matrice de covariance **commune** Σ . Donc chaque classe possède un centre propre μ_j et toutes les classes possèdent la même dispersion. Cette hypothèse est appelée hypothèse d'*homoscédasticité* (variance-covariance identique par groupe).

Expression explicite des fonctions discriminantes. La densité gaussienne multivariée s'écrit

$$f_j(\mathbf{z}) = \frac{1}{(2\pi)^{p/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{z} - \mu_j)^\top \Sigma^{-1} (\mathbf{z} - \mu_j) \right).$$

On cherche à maximiser $p_j f_j(\mathbf{z})$. Par croissance du logarithme, on peut ramener le problème à la formulation :

$$\hat{y}(\mathbf{z}) = \operatorname{argmax}_{j=1, \dots, K} \log(p_j f_j(\mathbf{z})).$$

Donc

$$\hat{y}(\mathbf{z}) = \operatorname{argmax}_{j=1, \dots, K} \left(\log p_j - \frac{1}{2} (\mathbf{z} - \mu_j)^\top \Sigma^{-1} (\mathbf{z} - \mu_j) \right).$$

Développons le **terme quadratique** :

$$(\mathbf{z} - \mu_j)^\top \Sigma^{-1} (\mathbf{z} - \mu_j) = \mathbf{z}^\top \Sigma^{-1} \mathbf{z} - 2\mu_j^\top \Sigma^{-1} \mathbf{z} + \mu_j^\top \Sigma^{-1} \mu_j.$$

Le terme $\mathbf{z}^\top \Sigma^{-1} \mathbf{z}$ étant indépendant de j , il ne change rien à l'argmax et peut donc être ignoré dans la règle de décision. On définit alors la fonction discriminante :

$$\mathcal{S}_j(\mathbf{z}) = \mu_j^\top \Sigma^{-1} \mathbf{z} - \frac{1}{2} \mu_j^\top \Sigma^{-1} \mu_j + \log p_j.$$

La règle de classification devient

$$\hat{y}(\mathbf{z}) = \operatorname{argmax}_{j=1, \dots, K} \mathcal{S}_j(\mathbf{z}).$$

Proposition 3.2. Chaque fonction discriminante est affine :

$$\mathcal{S}_j(\mathbf{z}) = a_j^\top \mathbf{z} + b_j$$

avec

$$a_j = \Sigma^{-1} \mu_j \quad \text{et} \quad b_j = -\frac{1}{2} \mu_j^\top \Sigma^{-1} \mu_j + \log p_j.$$

Les frontières de décision sont donc bien linéaires, ce qui justifie rigoureusement la structure observée empiriquement dans la section précédente.

Remarque 2 (Pourquoi les frontières de décision sont affines). La règle de classification consiste à attribuer l'observation $\mathbf{z}$ à la classe ayant le score discriminant maximal :

$$\hat{y}(\mathbf{z}) = \operatorname{argmax}_{j=1, \dots, K} \mathcal{S}_j(\mathbf{z}).$$

C'est-à-dire qu'une observation appartient à la classe j ssi $\mathcal{S}_j(\mathbf{z}) \geq \mathcal{S}_k(\mathbf{z})$ pour tout k . La frontière entre deux classes j et k correspond donc aux points pour lesquels les deux scores sont égaux :

$$\mathcal{S}_j(\mathbf{z}) = \mathcal{S}_k(\mathbf{z})$$

$$\iff a_j^\top \mathbf{z} + b_j = a_k^\top \mathbf{z} + b_k$$

$$\iff (a_j - a_k)^\top \mathbf{z} + (b_j - b_k) = 0.$$

Cette équation est bien celle d'un hyperplan affine de $\mathbb{R}^p$. Les frontières de décision entre classes sont bien affines/linéaires. La LDA partitionne l'espace des variables explicatives à l'aide de séparateurs affines.

4 Critère de Fisher

4.1 Lien avec le critère de Fisher

La construction précédente repose sur une approche probabiliste. Cependant, il existe une seconde interprétation fondamentale de la LDA : une interprétation géométrique basée sur la projection optimale des données. L'idée est de rechercher une direction $\mathbf{a}$ telle que la projection

$$\mathbf{z} \mapsto \mathbf{a}^\top \mathbf{z}$$

sépare au mieux les classes. On cherche donc à maximiser la séparation entre classes projetées tout en minimisant leur dispersion interne. Cela conduit naturellement au critère de Fisher :

Théorème 4.1 (Critère de Fisher). *La direction discriminante optimale maximise*

$$\mathbf{a}^* = \operatorname{argmax}_{\mathbf{a} \in \mathbb{R}^p} \left\{ J(\mathbf{a}) = \frac{\mathbf{a}^\top B \mathbf{a}}{\mathbf{a}^\top W \mathbf{a}} \right\}. \quad (\text{Fisher})$$

Remarque 3 (Intuition géométrique). Le numérateur mesure la dispersion inter-classes projetée, tandis que le dénominateur mesure la dispersion intra-classe projetée. Ainsi, maximiser $J(\mathbf{a})$ signifie bien maximiser la séparation des classes tout en minimisant leur dispersion interne.

Proposition 4.1. La solution du problème d'optimisation (Fisher) conduit à résoudre

$$B\mathbf{a} = \lambda W\mathbf{a},$$

c'est-à-dire un problème aux valeurs propres généralisé. Les directions discriminantes sont donc les vecteurs propres associés aux plus grandes valeurs propres de $W^{-1}B$. Ces directions définissent les axes de projection optimaux de la LDA.

Preuve. On cherche à déterminer la direction de projection optimale $\mathbf{a} \in \mathbb{R}^p$ maximisant le critère de Fisher

$$J(\mathbf{a}) = \frac{\mathbf{a}^\top B \mathbf{a}}{\mathbf{a}^\top W \mathbf{a}}.$$

Comme ce quotient est invariant par changement d'échelle de $\mathbf{a}$, on peut imposer la contrainte de normalisation $\mathbf{a}^\top W \mathbf{a} = 1$. Le problème d'optimisation devient alors

$$\max_{\mathbf{a}} \quad \mathbf{a}^\top B \mathbf{a} \quad \text{sous la contrainte} \quad \mathbf{a}^\top W \mathbf{a} = 1.$$

On introduit un multiplicateur de Lagrange λ et on considère la fonction

$$\mathcal{L}(\mathbf{a}, \lambda) = \mathbf{a}^\top B \mathbf{a} - \lambda(\mathbf{a}^\top W \mathbf{a} - 1).$$

On dérive par rapport à $\mathbf{a}$ et on impose la condition d'optimalité :

$$\nabla_{\mathbf{a}} \mathcal{L}(\mathbf{a}, \lambda) = 0$$

$$\iff 2B^\top \mathbf{a} - 2\lambda W^\top \mathbf{a} = 0$$

$$\iff 2B\mathbf{a} - 2\lambda W\mathbf{a} = 0 \quad \text{par symétrie des matrices } B \text{ et } W$$

$$\iff B\mathbf{a} = \lambda W\mathbf{a}$$

$$\iff W^{-1}B\mathbf{a} = \lambda \mathbf{a} \quad \text{en supposant que } W \text{ soit inversible (variables explicatives non colinéaires)}$$

Ainsi, la direction optimale $\mathbf{a}$ est un vecteur propre de la matrice $W^{-1}B$. Par ailleurs, la valeur du critère de Fisher dans cette direction vaut exactement $J(\mathbf{a}) = \lambda$. Maximiser le critère de Fisher revient donc à choisir le vecteur propre associé à la plus grande valeur propre de $W^{-1}B$. $\square$

Plus généralement, en dimension $K > 2$, les directions discriminantes optimales sont données par les vecteurs propres associés aux plus grandes valeurs propres de $W^{-1}B$. Elles définissent les axes de projection permettant de séparer au mieux les classes après projection.

4.2 Lecture géométrique de la LDA et interprétation

On a vu que les axes discriminants de la LDA sont donnés par les vecteurs propres associés aux plus grandes valeurs propres de la matrice $W^{-1}B$. Cette section propose une lecture géométrique complète permettant de comprendre pourquoi cette construction est naturelle.

4.2.1 La forme quadratique comme mesure de la variance

Soit un vecteur aléatoire $X \in \mathbb{R}^p$ de matrice de covariance $\Sigma = \text{Cov}(X)$. On projette X sur une direction $\mathbf{a}$ via l'opération suivante (produit scalaire) : $Y = \mathbf{a}^\top X$. Alors on a

$$\text{Var}(Y) = \mathbf{a}^\top \Sigma \mathbf{a}.$$

À retenir. Une forme quadratique $\mathbf{a} \mapsto \mathbf{a}^\top M \mathbf{a}$ mesure toujours la variance du vecteur projeté dans la direction $\mathbf{a}$ lorsque M est une matrice de covariance. Dans la LDA, les matrices B et W jouent exactement ces rôles :

$\mathbf{a}^\top B \mathbf{a}$ mesure la variance inter-classes projetée,

$\mathbf{a}^\top W \mathbf{a}$ mesure la variance intra-classes projetée.

4.2.2 Interprétation des axes discriminants

On cherche une direction $\mathbf{a}$ telle que

- (★) les centres des classes soient le plus éloignés possible ;
- (★) les nuages de points soient les plus compacts possibles,

c'est-à-dire une direction où les groupes des classes sont les plus éloignées et compactes possibles. Formellement, cela conduit à maximiser le critère de Fisher

$$\frac{\text{variance inter-classes projetée}}{\text{variance intra-classes projetée}} = \frac{\mathbf{a}^\top B \mathbf{a}}{\mathbf{a}^\top W \mathbf{a}}.$$

Ainsi, la LDA cherche une direction vérifiant

$$\text{séparation maximale} \quad / \quad \text{dispersion minimale},$$

ce que l'on peut traduire comme “on cherche l'angle de vue depuis lequel les classes apparaissent le plus séparées possible”. Les directions optimales obtenues sont nommés **axes discriminants**.

4.2.3 Proportion de la trace

Notons $\lambda_1, \dots, \lambda_{K-1}$ les valeurs auxquelles sont associés les axes discriminants de la matrice $W^{-1}B$. On rappelle que la trace, étant égale à la somme des valeurs propres, on a :

$$\text{tr}(W^{-1}B) = \sum_{k=1}^{K-1} \lambda_k.$$

Elle représente la séparation discriminante totale disponible dans les données. Le logiciel R affiche alors la quantité

$$\frac{\lambda_k}{\sum_{j=1}^{K-1} \lambda_j},$$

appelée *Proportion of trace*, qui indique la proportion de séparation inter-classes expliquée par l'axe discriminant LD_k .

4.3 Coïncidence entre approche bayésienne et critère de Fisher

Sous l'hypothèse du modèle LDA, $Z \mid \{Y = j\} \sim \mathcal{N}(\mu_j, \Sigma)$, la règle bayésienne conduit aux scores discriminants

$$\mathcal{S}_j(z) = \mu_j^\top \Sigma^{-1} z - \frac{1}{2} \mu_j^\top \Sigma^{-1} \mu_j + \log p_j.$$

La décision dépend donc uniquement des vecteurs $\Sigma^{-1} \mu_j$. Ainsi, la classification vit dans l'espace vectoriel

$$\text{Vect}\{\Sigma^{-1} \mu_1, \dots, \Sigma^{-1} \mu_K\}.$$

Par ailleurs, si on multiplie B par W^{-1} à gauche, on obtient :

$$W^{-1} B = \sum_{j=1}^K \frac{n_j}{n} W^{-1} (\mu_j - \bar{X}) (\mu_j - \bar{X})^\top.$$

Ainsi, l'image de $W^{-1} B$ est contenue dans

$$\text{Vect}\{W^{-1}(\mu_1 - \bar{X}), \dots, W^{-1}(\mu_K - \bar{X})\} = \text{Vect}\{W^{-1} \mu_1, \dots, W^{-1} \mu_K\}.$$

Or la matrice Σ est une estimation empirique non biaisée de la matrice intra-classe globale W , on a $\Sigma \propto W$. Nécessairement,

$$\text{Vect}\{\Sigma^{-1} \mu_1, \dots, \Sigma^{-1} \mu_K\} = \text{Vect}\{W^{-1} \mu_1, \dots, W^{-1} \mu_K\}.$$

D'où la coïncidence entre l'approche bayésienne et le critère de Fisher. Bien que ces deux méthodes reposent sur des points de vue *a priori* très différents (*l'une probabiliste et l'autre algébrique*), elles décrivent en réalité le même problème de séparation optimale entre classes et conduisent aux mêmes directions discriminantes, donc à la même règle de classification linéaire. Ces deux points de vue sont donc très complémentaires.

Une brève conclusion

Deux interprétations complémentaires de la LDA émergent naturellement :

- (*) une interprétation probabiliste : la LDA correspond à la règle de classification bayésienne optimale sous l'hypothèse que les variables explicatives suivent, dans chaque classe, une loi normale multivariée de moyenne μ_j et de matrice de covariance commune Σ ;
- (*) une interprétation géométrique : la LDA consiste à projeter les observations sur des directions optimales maximisant la séparation entre les centres de classes (variance inter-classes B) tout en minimisant la dispersion interne des classes (variance intra-classe W), ce qui conduit au critère de [Fisher](#).

Ces deux approches conduisent exactement à la même règle de classification linéaire : l'espace des variables explicatives est partitionné par des hyperplans affines séparant les classes.

Du point de vue du machine learning, la LDA occupe une place importante parmi les méthodes de classification supervisée : elle constitue un modèle simple, interprétable et efficace lorsque les hypothèses gaussiennes sont raisonnablement vérifiées. Elle est également utilisée comme méthode de réduction de dimension supervisée, permettant de construire des variables synthétiques particulièrement discriminantes avant l'application d'autres algorithmes de classification.

Enfin, la LDA sert souvent de modèle de référence (baseline) en pratique, car elle permet d'obtenir rapidement une règle de décision stable, peu coûteuse en calcul et directement interprétable, ce qui en fait un outil privilégié pour l'analyse exploratoire et la compréhension de la structure discriminante des données. *Attention néanmoins au caractère linéaire qui la limite dans une géométrie complexe des données...*

Synthèse : Analyse Discriminante Linéaire (LDA)

Cadre. On observe un jeu de données supervisé : (X, Y) , $X \in \mathbb{R}^p$, $Y \in \{1, \dots, K\}$ où

- $X = (X^{(1)}, \dots, X^{(p)})$: covariables numériques,
- Y : variable qualitative à prédire (classe).

Objectif : prédire la classe Y d'une nouvelle observation z .

Hypothèses du modèle. On suppose que

$$X \mid \{Y = j\} \sim \mathcal{N}(\mu_j, \Sigma)$$

avec une moyenne spécifique à chaque classe : μ_j , et une matrice de covariance commune : Σ (homoscédasticité). On note $p_j = \mathbb{P}(Y = j)$ la probabilité *a priori* (souvent estimée par n_j/n).

Principe bayésien. La probabilité d'appartenance à la classe j sachant z vaut

$$\mathbb{P}(Y = j \mid Z = z) = \frac{p_j f_j(z)}{\sum_{\ell=1}^K p_\ell f_\ell(z)}$$

où f_j est la densité gaussienne de la classe j . Règle de décision :

$$\hat{y}(z) = \operatorname{argmax}_{j \in \{1, \dots, K\}} p_j f_j(z)$$

Sous hypothèse gaussienne homoscédastique, on obtient un score affine à arg-maximiser :

$$\hat{y}(z) = \operatorname{argmax}_{j \in \{1, \dots, K\}} \left\{ \mathcal{S}_j(z) = \mu_j^\top \Sigma^{-1} z - \frac{1}{2} \mu_j^\top \Sigma^{-1} \mu_j + \log p_j \right\}.$$

Donc les frontières de décision sont linéaires.

Vision géométrique. La dispersion totale des données se décompose en $V = W + B$ où W désigne la variance intra-classe, tandis que B décrit variance inter-classes. La LDA cherche des directions $\mathbf{a}$ maximisant le critère de Fisher :

$$J(\mathbf{a}) = \frac{\mathbf{a}^\top B \mathbf{a}}{\mathbf{a}^\top W \mathbf{a}}.$$

Cela conduit à résoudre $B\mathbf{a} = \lambda W\mathbf{a}$: les axes discriminants sont les vecteurs propres principaux de $W^{-1}B$. On obtient au plus $K - 1$ axes discriminants $LD_1, \dots, LD_{K-1}$.

Interprétation. La LDA en une phrase : maximise la séparation entre classes, tout en minimisant la dispersion interne. Cela revient à construire des frontières affines.

Prédiction d'une nouvelle observation. Pour une nouvelle observation z :

1. calculer les scores discriminants $\mathcal{S}_j(z)$,
2. choisir la classe maximisant ce score :

$$\hat{y}(z) = \operatorname{argmax}_j \mathcal{S}_j(z).$$