

Notes de cours sur la régression linéaire

Paul Minchella

Avril 2026

Table des matières

1	Contexte et motivation	1
2	Régression linéaire simple	2
3	Estimation par la méthode des moindres carrés	3
4	Régression linéaire multiple	3
4.1	Le modèle	3
4.2	Hypothèses essentielles	3
4.3	Écriture matricielle	4
4.4	Estimation par la méthode des moindres carrés	4
5	Qualité du modèle	4
5.1	Sommes des carrés et décomposition de la variabilité	4
5.2	Coefficient de détermination R^2	6
5.3	Le R^2 ajusté	7
6	Application avec R	8
6.1	Construire un modèle linéaire avec <code>lm</code>	8
6.2	Les tests statistiques : principe général	8
6.3	Lire la sortie d'un <code>summary(lm(...))</code>	8
6.4	Interpréter un intervalle de confiance à 95%	10
6.5	Interpréter R^2 et R^2_{adj}	10
7	Comparer deux modèles linéaires	10

1 Contexte et motivation

La régression linéaire est l'un des modèles fondamentaux de la statistique. Elle formalise une idée simple : expliquer une variable d'intérêt Y à partir d'une variable explicative X .

Dans de nombreuses situations concrètes, on cherche à comprendre comment une grandeur évolue en fonction d'une autre : salaire et niveau d'études, consommation et température, rendement et quantité d'engrais. La régression linéaire propose un cadre mathématique pour analyser ce type de relation.


Données. On observe un échantillon indépendant

$$\{(X_1, Y_1), \dots, (X_n, Y_n)\},$$

où $X_i \in \mathbb{R}$ est la variable explicative **numérique** et $Y_i \in \mathbb{R}$ la variable réponse **numérique**.

Une première étape consiste à représenter les couples (X_i, Y_i) sous forme de nuage de points. Très souvent, on observe une tendance approximativement linéaire : les points semblent se répartir autour d'une droite.

Exemple 1.1. En biologie, la taille d'un organe peut croître approximativement de façon linéaire avec l'âge sur une période donnée.



Face à une telle configuration, la question devient : peut-on résumer cette relation par une droite choisie de manière optimale ?

Deux objectifs. La régression linéaire poursuit deux objectifs :

- (★₁) D'abord un objectif descriptif : résumer la relation moyenne entre X et Y par une formule simple et interprétable.
- (★₂) Ensuite un objectif inférentiel et prédictif : mesurer l'effet de X sur Y et prédire la valeur de Y pour une nouvelle valeur de X .

2 Régression linéaire simple

On considère le cas d'une seule variable explicative.

Définition 2.1 (Modèle de régression linéaire simple). Pour toute observation i , on modélise la réponse Y_i comme telle :

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i,$$

où β_0 est l'intercept, β_1 la pente, et chaque ε_i un terme d'erreur aléatoire.

Interprétation géométrique. La droite

$$y = \beta_0 + \beta_1 x$$

représente la relation moyenne entre X et Y . Pour une observation X_i , la valeur prédite est

$$\hat{Y}_i = \beta_0 + \beta_1 X_i.$$

La différence $Y_i - \hat{Y}_i$ est appelée *résidu*. Les points ne sont jamais parfaitement alignés : ils se répartissent autour de la droite avec une certaine dispersion σ^2 .

Rôle du terme d'erreur. Le terme ε modélise la variabilité non expliquée par X : facteurs non observés, fluctuations naturelles, erreurs de mesure. On suppose classiquement, pour chaque observation $i = 1, \dots, n$:

$$\varepsilon_i \stackrel{\text{i.i.d}}{\sim} \mathcal{N}(0, \sigma^2).$$

L'espérance nulle signifie que la droite décrit correctement la tendance moyenne, tandis que σ^2 mesure la dispersion autour de cette tendance. Les paramètres inconnus du modèle sont donc β_0 , β_1 et σ^2 , qui devront être estimés à partir des données.

3 Estimation par la méthode des moindres carrés

Principe. L'idée est de choisir la droite qui minimise l'énergie des erreurs, c'est-à-dire la somme des carrés des résidus.

Définition 3.1. Les estimateurs des moindres carrés $(\hat{\beta}_0, \hat{\beta}_1)$ sont définis par :

$$(\hat{\beta}_0, \hat{\beta}_1) = \underset{(\beta_0, \beta_1) \in \mathbb{R}^2}{\operatorname{argmin}} \left\{ \sum_{i=1}^n (Y_i - (\beta_0 + \beta_1 X_i))^2 \right\}.$$

Cette approche pénalise fortement les grandes erreurs et conduit à un problème mathématique bien posé. On note J la fonction objective à (arg-)minimiser :

$$J(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - (\beta_0 + \beta_1 X_i))^2$$

Proposition 3.1. Supposons que $\sum_{i=1}^n (X_i - \bar{X})^2 > 0$ (c'est-à-dire que les X_i ne sont pas tous égaux). Alors la fonction J admet un unique minimiseur $(\hat{\beta}_0, \hat{\beta}_1)$, donné explicitement par

$$\begin{aligned} \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{X}, \\ \hat{\beta}_1 &= \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}. \end{aligned}$$

4 Régression linéaire multiple

Dans la pratique, une variable réponse dépend rarement d'un seul facteur. La régression linéaire multiple généralise le cas simple en permettant à Y de dépendre simultanément de plusieurs variables explicatives, via un simple ajout linéaire.

4.1 Le modèle

On observe

$$\{(X_i^1, \dots, X_i^p, Y_i)\}_{i=1}^n,$$

où X_i^j est la j -ième variable explicative. Le modèle s'écrit

$$Y = \beta_0 + \beta_1 X^1 + \dots + \beta_p X^p + \varepsilon.$$

Chaque coefficient β_j mesure l'effet de X^j sur Y , *toutes choses égales par ailleurs*. Le terme ε regroupe les facteurs non observés et la variabilité résiduelle. Géométriquement, la droite du cas simple devient un *hyperplan* dans $\mathbb{R}^{p+1}$.

4.2 Hypothèses essentielles

Le modèle classique repose sur les hypothèses suivantes :

- (H1) Linéarité du modèle en les paramètres β_j ;
- (H2) Indépendance des observations ;
- (H3) Espérance conditionnelle nulle : $\mathbb{E}[\varepsilon \mid X] = 0$;
- (H4) Homoscédasticité : $\operatorname{Var}(\varepsilon \mid X) = \sigma^2$;
- (H5) Absence de colinéarité parfaite (inversibilité de $\mathbb{X}^\top \mathbb{X}$, notation présentée plus bas).

Si on suppose de surcroît la normalité des erreurs, alors on peut condenser toutes les hypothèses des résidus en une écriture. Pour toute observation $i = 1, \dots, n$:

$$\varepsilon_i \stackrel{\text{i.i.d}}{\sim} \mathcal{N}(0, \sigma^2),$$

n'est pas nécessaire pour estimer les coefficients, mais elle intervient dans l'inférence.

4.3 Écriture matricielle

On introduit la matrice de design

$$\mathbb{X} = \begin{pmatrix} 1 & X_1^1 & \dots & X_1^p \\ \vdots & \vdots & & \vdots \\ 1 & X_n^1 & \dots & X_n^p \end{pmatrix} \in \mathbb{R}^{n \times (p+1)},$$

le vecteur des paramètres

$$\boldsymbol{\beta} = (\beta_0, \dots, \beta_p)^\top \in \mathbb{R}^{p+1},$$

et le vecteur des observations $\mathbf{Y}$. La première colonne constituée uniquement de 1 est indispensable pour permettre l'ajustement de l'intercept β_0 . Le modèle s'écrit alors

$$\mathbf{Y} = \mathbb{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \in \mathbb{R}^n.$$

4.4 Estimation par la méthode des moindres carrés

Comme dans le cas univarié, les coefficients du modèle sont estimés par la méthode des moindres carrés. L'idée consiste à choisir le vecteur $\boldsymbol{\beta}$ qui minimise la somme des carrés des résidus, c'est-à-dire la norme euclidienne du vecteur des erreurs (*on cherche toujours à minimiser sa variance*). On cherche donc à résoudre le problème d'optimisation :

$$\hat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta} \in \mathbb{R}^{p+1}}{\operatorname{argmin}} \left\{ \frac{1}{n} \sum_{i=1}^n \left(Y_i - (\mathbb{X}\boldsymbol{\beta})_i \right)^2 = \|\mathbf{Y} - \mathbb{X}\boldsymbol{\beta}\|_2^2 \right\}.$$

Ce critère généralise naturellement celui introduit dans le cas de la régression linéaire simple. Il s'agit toujours de minimiser une fonction quadratique strictement convexe, sous réserve que la matrice $\mathbb{X}$ contienne suffisamment d'information.

Théorème 4.1. *Si la matrice $\mathbb{X}^\top \mathbb{X}$ est inversible, alors le problème des moindres carrés admet une solution unique, donnée par*

$$\hat{\boldsymbol{\beta}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbf{Y}.$$

5 Qualité du modèle

Ajuster une régression linéaire (simple ou multiple) revient à construire une fonction de prédiction

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i^1 + \dots + \hat{\beta}_p X_i^p$$

qui approxime au mieux les valeurs observées Y_i . Une question essentielle est alors la suivante : *dans quelle mesure le modèle explique-t-il réellement les données ?* Pour répondre à cette question, on introduit des grandeurs qui mesurent la variabilité de Y et la part de cette variabilité capturée (ou non) par le modèle.

5.1 Sommes des carrés et décomposition de la variabilité

On note

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

la moyenne empirique de la variable réponse. Comme on l'a déjà souligné, $\bar{Y}$ représente une valeur centrale : si l'on devait prédire Y sans utiliser aucune covariable, la prédiction la plus naturelle (au sens des moindres carrés) serait précisément la constante $\bar{Y}$.

Somme totale des carrés.

Définition 5.1 (Somme totale des carrés). On appelle *somme totale des carrés* (en anglais *Total Sum of Squares*) la quantité

$$\text{SST} = \sum_{i=1}^n (Y_i - \bar{Y})^2,$$

où

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

désigne la moyenne empirique des observations.

La somme totale des carrés mesure la variabilité globale de la variable réponse autour de sa moyenne. Elle constitue une référence absolue : elle correspond à l'erreur que l'on commettrait si l'on cherchait à prédire toutes les observations par une constante unique, égale à $\bar{Y}$. Une valeur élevée de SST traduit une forte dispersion des données, tandis qu'une valeur faible indique que les observations sont proches de leur moyenne. Notons enfin que la variance empirique (*biaisée*) est donnée par $\frac{1}{n} \text{SST}$.

Somme des carrés résiduels.

Définition 5.2 (Somme des carrés résiduels). Après ajustement du modèle, on définit les résidus par

$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i,$$

où $\hat{Y}_i$ désigne la valeur prédite par le modèle pour l'observation i . La *somme des carrés résiduels* (en anglais *Residual Sum of Squares*) est alors définie par

$$\text{SSR} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n \hat{\varepsilon}_i^2.$$

La quantité SSR mesure l'erreur globale commise par le modèle sur les données observées. Elle évalue la part de la variabilité des données qui n'est pas expliquée par le modèle. Plus SSR est petite, plus l'ajustement est précis. Dans le cadre de la méthode des moindres carrés, l'estimation des paramètres vise précisément à minimiser cette somme.

Somme des carrés expliqués.

Définition 5.3 (Somme des carrés expliqués). On appelle *somme des carrés expliqués* (en anglais *Explained Sum of Squares*) la quantité

$$\text{SSR} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2,$$

où $\hat{Y}_i$ sont les valeurs prédites par le modèle et $\bar{Y}$ la moyenne empirique des observations.

La somme des carrés expliqués mesure la variabilité des prédictions produites par le modèle autour de la moyenne. Elle représente la part de la variabilité totale des données que le modèle parvient à capturer à l'aide des variables explicatives. Plus SSE est grande, plus le modèle explique une part importante de la structure présente dans les données.

Proposition 5.1 (Décomposition de la variabilité). Dans le cadre des moindres carrés (avec intercept), on a la décomposition fondamentale

$$\text{SST} = \text{SSE} + \text{SSR}.$$

Cela s'écrit explicitement :

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Preuve. On écrit

$$Y_i - \bar{Y} = (Y_i - \hat{Y}_i) + (\hat{Y}_i - \bar{Y}).$$

En élevant au carré puis en sommant, on obtient

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + 2 \sum_{i=1}^n (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y}).$$

Il reste à montrer que le dernier terme est nul. Or, dans la régression aux moindres carrés avec intercept, le vecteur des résidus est orthogonal à l'espace engendré par les colonnes de $\mathbb{X}$, donc en particulier orthogonal au vecteur $(\hat{Y}_1 - \bar{Y}, \dots, \hat{Y}_n - \bar{Y})$ qui appartient à cet espace. Ainsi

$$\sum_{i=1}^n (Y_i - \hat{Y}_i)(\hat{Y}_i - \bar{Y}) = 0,$$

ce qui donne bien $\text{SST} = \text{SSR} + \text{SSE}$. □

Remarque 1. Cette décomposition est l'analogue, en statistiques, d'un théorème de Pythagore : SST mesure l'énergie totale, SSR l'énergie résiduelle (non expliquée), et SSE l'énergie expliquée par le modèle.

5.2 Coefficient de détermination R^2

Définition.

Définition 5.4 (Coefficient de détermination). On appelle *coefficient de détermination* le nombre

$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}.$$

Cette formule s'interprète immédiatement : R^2 mesure la **proportion de la variance expliquée** de Y par le modèle linéaire. R^2 compare l'erreur du modèle (SSR) à l'erreur du modèle le plus naïf possible (prédire $\bar{Y}$ pour tout le monde), qui correspond à SST. Ainsi :

- si SSR est très petite devant SST, alors le modèle explique bien les données et R^2 est proche de 1 ;
- si SSR est proche de SST, alors le modèle n'apporte presque rien par rapport à la simple moyenne et R^2 est proche de 0.

Propriété 5.1. Dans une régression linéaire estimée par moindres carrés avec intercept, on a toujours

$$0 \leq R^2 \leq 1.$$

Preuve. Immédiate. Positivité par définition. Inférieure à 1 par Proposition 5.1. □

Exemples d'interprétation.

Exemple 5.1. Deux exemples un peu extrêmes.

1. Supposons que $R^2 = 0.05$. Cela signifie que le modèle n'explique qu'environ 5% de la variabilité de Y . Autrement dit, même en connaissant les covariables, l'incertitude sur Y reste très grande : le modèle est probablement trop simple, les covariables sont peu pertinentes, ou bien la relation n'est pas linéaire.
2. Si $R^2 = 0.90$, alors le modèle explique environ 90% de la variabilité de Y . Cela indique une forte capacité descriptive : la prédiction $\hat{Y}$ suit étroitement les données, et les résidus sont globalement faibles.

Remarque 2. Un R^2 élevé ne garantit pas à lui seul que le modèle est “bon” au sens scientifique : il peut résulter d'un sur-ajustement (trop de variables), d'une relation accidentelle sur l'échantillon, ou encore d'un phénomène déterministe dans les données. L'analyse des résidus et des hypothèses du modèle reste indispensable.

5.3 Le R^2 ajusté

Un point important mérite d'être compris : lorsque l'on ajoute des variables explicatives, la somme des carrés résiduels SSR ne peut qu'*diminuer* (ou rester constante), car on augmente la flexibilité du modèle. Par conséquent, R^2 ne peut qu'augmenter (ou rester constant). Cela rend R^2 peu fiable pour comparer des modèles de tailles différentes, car il favorise mécaniquement les modèles plus complexes.

Pour corriger cet effet, on introduit une version pénalisée : le R^2 ajusté.

Définition 5.5 (R^2 ajusté). Dans un modèle de régression linéaire multiple comportant p variables explicatives (et donc $p + 1$ paramètres en comptant l'intercept), on définit

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}.$$

Interprétation. Le facteur $\frac{n-1}{n-p-1}$ est supérieur à 1 et augmente avec p . Ainsi, à R^2 fixé, plus le modèle contient de variables, plus la pénalisation est forte. Le R_{adj}^2 ne récompense donc l'ajout d'une variable que si cette variable améliore suffisamment l'ajustement pour compenser l'augmentation de complexité.

Exemple 5.2 (Comparaison de deux modèles). Supposons que l'on compare deux modèles sur les mêmes données (même n) :

- Modèle A : $p = 2$ variables explicatives, $R^2 = 0.72$.
- Modèle B : $p = 6$ variables explicatives, $R^2 = 0.74$.

Même si R^2 augmente légèrement, le R_{adj}^2 du modèle B peut être inférieur à celui du modèle A si les variables supplémentaires n'apportent qu'un gain marginal. Dans ce cas, le modèle A est à préférer : il est plus simple et presque aussi explicatif.

Remarque 3. Le R_{adj}^2 constitue un premier outil de comparaison de modèles, mais il ne remplace pas une analyse plus complète (validation croisée, critères AIC/BIC, diagnostic des résidus, etc.). Il a néanmoins l'avantage d'être simple et directement interprétable dans le cadre des régressions linéaires.

6 Application avec R

Dans la pratique, les modèles de régression linéaire sont estimés à l'aide du logiciel R. Deux fonctions sont essentielles :

- la fonction `lm()`, qui permet d'ajuster un modèle linéaire ;
- la fonction `summary()`, qui permet d'en analyser les résultats.

6.1 Construire un modèle linéaire avec `lm`

Supposons que l'on souhaite ajuster le modèle

$$Y_i = \beta_0 + \beta_1 X_i^1 + \beta_2 X_i^2 + \varepsilon_i.$$

Si les variables sont contenues dans un tableau de données nommé `df`, on écrit simplement :

```
model = lm(Y ~ X1 + X2, data = df)
```

La formule `Y ~ X1 + X2` signifie que la variable réponse est `Y` et que les variables explicatives sont `X1` et `X2`. L'intercept est inclus automatiquement par défaut.

Une fois le modèle estimé, la commande

```
summary(model)
```

permet d'obtenir les principales informations statistiques associées à l'ajustement.

6.2 Les tests statistiques : principe général

Avant d'interpréter la sortie d'un `summary()`, rappelons brièvement le principe d'un test statistique.

On commence par formuler une **hypothèse nulle** H_0 , qui correspond en général à l'absence d'effet ou de relation. Par exemple :

$$H_0 : \beta_j = 0.$$

L'objectif est de déterminer si les données observées apportent suffisamment d'évidence pour rejeter cette hypothèse. Pour cela, on calcule une **statistique de test**, dont on déduit une **p-value**. La p-value correspond à la probabilité d'observer un résultat au moins aussi extrême que celui obtenu si l'hypothèse H_0 était vraie. *Grossièrement, on peut dire que la p-value est la probabilité de commettre une erreur en rejetant l'hypothèse nulle.*

On compare ensuite cette p-value à un seuil appelé **niveau de significativité**, généralement

$$\alpha = 0.05.$$

- Si la p-value est inférieure à α , on rejette H_0 .
- Sinon, on ne rejette pas H_0 .

Ainsi, plus la p-value est petite, plus les données sont incompatibles avec l'hypothèse nulle.

6.3 Lire la sortie d'un `summary(lm(...))`

La commande `summary(model)` fournit notamment le tableau suivant pour chaque coefficient estimé :

- **Estimate** : estimation du coefficient $\hat{\beta}_j$;
- **Std. Error** : écart-type estimé de $\hat{\beta}_j$;
- **t value** : statistique de test de Student associée au test $H_0 : \beta_j = 0$;
- **Pr(> |t|)** : p-value du test $H_0 : \beta_j = 0$.

Significativité d'un coefficient Un coefficient est dit *statistiquement significatif au seuil 5%* si sa p-value est inférieure à 0.05. Cela signifie que les données fournissent suffisamment d'évidence pour rejeter l'hypothèse

$$H_0 : \beta_j = 0.$$

Autrement dit, la variable explicative associée contribue de manière significative à expliquer la variable réponse dans le modèle. La commande `summary(model)` fournit plusieurs informations importantes permettant d'évaluer la qualité du modèle ajusté.

Estimation de l'écart-type des erreurs : Residual standard error Dans la sortie de `summary(model)`, on lit une ligne de la forme :

Residual standard error: 2.31 on 97 degrees of freedom

Cette quantité correspond à une estimation de l'écart-type du bruit du modèle, noté

$$\hat{\sigma}.$$

Plus précisément,

$$\hat{\sigma} = \sqrt{\frac{1}{n-p-1} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}.$$

Autrement dit, $\hat{\sigma}$ mesure la dispersion moyenne des observations autour de la droite (ou de l'hyperplan) de régression. Plus $\hat{\sigma}$ est petit, plus les prédictions du modèle sont proches des observations. Le terme

degrees of freedom

désigne le nombre de degrés de liberté utilisés pour estimer cette quantité, égal à

$$n - p - 1,$$

où

- n est le nombre d'observations ;
- p est le nombre de variables explicatives.

On retire donc un degré de liberté pour chaque coefficient estimé (y compris l'intercept).

Test global de significativité du modèle : test de Fisher La sortie de `summary(model)` contient également une ligne de la forme :

F-statistic: 24.6 on 3 and 96 DF, p-value: 1.2e-10

Il s'agit du **test global de Fisher**. Ce test répond à la question :

Le modèle est-il globalement significatif ?

Plus précisément, on teste

$$H_0 : \beta_1 = \dots = \beta_p = 0$$

contre

H_1 : au moins un coefficient est non nul.

Bref, l'hypothèse nulle présente un scénario selon lequel aucune variable explicative n'a d'effet sur la variable réponse.

- Si la p-value du test de Fisher est petite (par exemple < 0.05), on rejette H_0 .
- On conclut alors que le modèle est globalement significatif.
- Cela signifie qu'au moins une des variables explicatives contribue à expliquer la variable réponse.

À l'inverse, si la p-value est grande, on ne peut pas conclure que le modèle apporte une amélioration significative par rapport au modèle trivial qui consiste à prédire uniquement la moyenne $\bar{Y}$.

6.4 Interpréter un intervalle de confiance à 95%

Un intervalle de confiance à 95% pour un coefficient β_j est de la forme

$$\text{IC}_{95\%}(\hat{\beta}_j) = [a, b].$$

On peut l'interpréter ainsi :

- si $0 \notin [a, b]$, alors β_j est significativement différent de 0 au seuil 5% ;
- si $0 \in [a, b]$, alors on ne peut pas conclure que β_j est différent de 0.

L'interprétation par intervalle de confiance est équivalente à celle basée sur la p-value. Dans R, on obtient ces intervalles avec :

```
confint(model)
```

6.5 Interpréter R^2 et R^2_{adj}

On note $\hat{Y}_i$ la valeur prédite pour l'observation i . Le coefficient de détermination R^2 mesure la proportion de la variabilité totale de Y expliquée par le modèle.

- Plus R^2 est proche de 1, plus le modèle explique bien les données ;
- un R^2 faible indique que le modèle explique peu la variabilité observée.

Cependant, lorsque l'on ajoute des variables explicatives, R^2 augmente toujours (ou reste constant), même si ces variables sont peu pertinentes. Pour corriger cet effet, on utilise le coefficient ajusté R^2_{adj} , qui pénalise l'ajout de variables inutiles. Il est généralement plus pertinent pour comparer deux modèles de complexité différente.

7 Comparer deux modèles linéaires

Pour déterminer si un modèle est préférable à un autre, plusieurs critères peuvent être utilisés :

- (★) les nouvelles variables introduites sont-elles significatives ?
- (★) certaines variables non significatives peuvent-elles être supprimées ?
- (★) R^2 s'améliore-t-il sensiblement ?
- (★) R^2_{adj} s'améliore-t-il ?
- (★) le modèle reste-t-il interprétable ?
- (★) les hypothèses sur les résidus restent-elles raisonnables (normalité, homoscedasticité, indépendance) ?

Idée importante

Un modèle plus complexe n'est pas automatiquement meilleur. Ajouter une variable non significative peut compliquer l'interprétation sans améliorer réellement le pouvoir explicatif.