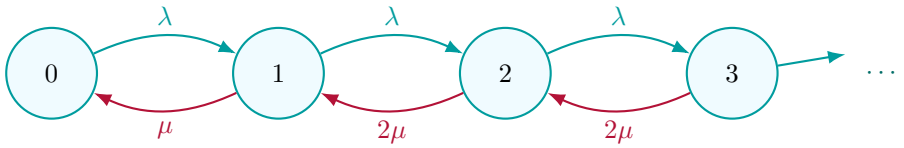
ERO2
Recherche opérationnelle
Édition 2026

Files d'attente

et processus stochastiques

Des modèles probabilistes au dimensionnement des systèmes



Un état décrit le système.
Les taux décrivent son évolution.

$$\pi Q = 0 \qquad \Longrightarrow \qquad L = \lambda_{\text{eff}}\, \mathbb{E}[T]$$

Modéliser les flux $\longrightarrow$ **Quantifier l'attente** $\longrightarrow$ **Choisir la capacité**

Paul Minchella

Octobre 2026

Table des matières

Introduction générale **1**

1 Rappels de probabilités **2**
1.1 Variables aléatoires et description d'une loi . . . 2
1.2 Espérance, dispersion et moyennes empiriques . . . 3
1.3 Indépendance des variables aléatoires . . . 4
1.4 Les lois utilisées dans le cours . . . 5
1.5 Absence de mémoire et loi exponentielle . . . 6
1.6 Transformées : calculer les moments et les sommes . . . 6
1.7 Processus stochastiques et évolution temporelle . . . 8
1.8 Rappels : notations asymptotiques et développements limités . . . 8

2 Chaînes de Markov en temps discret **10**
2.1 État présent, transitions et évolution de la loi . . . 10
2.2 Communication, retours et périodicité . . . 11
2.3 Stationnarité, convergence et moyennes temporelles . . . 13
2.4 Calcul de l'équilibre et réversibilité . . . 16

3 Chaînes de Markov à temps continu **18**
3.1 De la probabilité de transition au générateur . . . 18
3.2 Temps de séjour dans un état et chaîne des sauts . . . 20
3.3 Chapman–Kolmogorov et équations différentielles . . . 22
3.4 Équilibre global et processus de naissance–mort . . . 25
3.5 Temps d'arrêt et observation à long terme . . . 26

4 Processus de comptage et processus de Poisson **28**
4.1 Compter les événements et dater les arrivées . . . 28
4.2 Loi de Poisson, temps exponentiels et équations locales . . . 29
4.3 Superposition et amincissement . . . 30

5 Modéliser une file et définir ses performances **32**
5.1 Composantes du système et notation de Kendall . . . 32
5.2 Comptages, occupation et grandeurs de performance . . . 33
5.3 Stabilité et loi de Little . . . 34
5.4 PASTA : ce que voient les arrivées . . . 35

6 Le modèle $M/M/1$ **37**
6.1 Construction du modèle et état markovien . . . 37
6.2 Équations transitoires : un bilan de flux . . . 38
6.3 Distribution stationnaire et performances moyennes . . . 39
6.4 Délais, probabilités de dépassement et saturation . . . 40

7 Plusieurs serveurs et capacité finie **42**
7.1 Le modèle $M/M/c$ . . . 42
7.2 Erlang C et performances avec attente . . . 43
7.3 Le modèle $M/M/c/K$ . . . 44
7.4 Pertes, admission et délais à capacité finie . . . 44
7.5 Deux cas particuliers : capacité limitée et pertes pures . . . 45

8 Exercices de synthèse **47**
8.1 Construire un générateur : le club sportif . . . 47
8.2 Exercice de synthèse : une file $M/M/2/3$ . . . 48

A Outils de calcul et fiche de révision **59**
A.1 Rappels : petit o, grand O et équivalents . . . 59
A.2 Sommes géométriques et espérance de $M/M/1/K$ . . . 60
A.3 Fiche de révision et méthode de résolution . . . 61

Introduction générale

Une file d'attente apparaît lorsqu'une ressource ne peut pas traiter immédiatement toutes les demandes qui lui sont adressées. Les clients peuvent être des personnes, des appels, des paquets réseau ou des tâches informatiques. Le service peut être assuré par un guichet, un opérateur, un processeur ou une machine.

Le problème ne se résume pas à comparer deux moyennes. Même lorsque la capacité moyenne de service dépasse le flux moyen d'arrivées, les fluctuations créent des périodes de congestion. La théorie des files d'attente quantifie les conséquences de cette variabilité.

Objectif. Construire un modèle probabiliste, déterminer son régime stationnaire lorsqu'il existe, puis calculer les délais, les niveaux d'occupation et les pertes utiles au dimensionnement.

Les trois questions directrices

- **Décrire :** quel état contient l'information nécessaire pour prévoir l'évolution du système ?
- **Calculer :** comment relier les arrivées et les services aux probabilités d'occupation et aux temps d'attente ?
- **Décider :** combien de serveurs et quelle capacité permettent d'atteindre un objectif de coût ou de qualité de service ?

Le parcours du cours

Les rappels probabilistes introduisent les lois exponentielle, géométrique, Gamma et de Poisson. Les chaînes de Markov fournissent ensuite le langage de la dynamique et de l'équilibre. Les processus de renouvellement et de Poisson décrivent les arrivées. Ces outils sont réunis dans les modèles $M/M/1$, $M/M/c$ et $M/M/c/K$.

Les exercices apprennent à construire un générateur à partir d'un énoncé. Le projet final relie calcul stationnaire, simulation et choix économique du nombre de serveurs.

Point de vigilance. Les hypothèses de Poisson et d'exponentialité sont des choix de modèle. Leur intérêt analytique ne suffit pas à établir leur adéquation aux données. Une variation horaire des arrivées, des services très réguliers ou des arrivées groupées peuvent nécessiter un autre modèle.

Conventions utilisées

Dans tout le cours, $\mathbb{N} = \{0, 1, 2, \ldots\}$. Les lois exponentielles sont paramétrées par leur *taux* : si $S \sim \mathrm{Exp}(\mu)$, alors $\mathbb{E}[S] = 1/\mu$. Les distributions d'état sont des *vecteurs lignes*.

La lettre T désigne un temps de séjour, W un temps d'attente avant service. On écrit explicitement $\mathbb{E}[T]$ et $\mathbb{E}[W]$ pour leurs moyennes.

À retenir

Le raisonnement central est :

$$\text{hypothèses} \longrightarrow \text{état et transitions} \longrightarrow \text{loi stationnaire} \longrightarrow \text{performances} \longrightarrow \text{décision}.$$

Rappels de probabilités

1.1 Variables aléatoires et description d'une loi

Objectif. Distinguer l'expérience aléatoire, la variable qui la décrit et la loi utilisée pour les calculs.

Définition 1.1.1 (Tribu et mesure)**.** Soit Ω un ensemble représentant les issues possibles d'une expérience aléatoire.
Une **tribu** $\mathcal{F}$ est une collection de sous-ensembles de Ω, appelés *événements*, vérifiant :

1. $\Omega \in \mathcal{F}$;
2. si $A \in \mathcal{F}$, alors $A^c \in \mathcal{F}$;
3. si $(A_n)_{n\geq 1} \subseteq \mathcal{F}$, alors $\bigcup_{n\geq 1} A_n \in \mathcal{F}$.

Une **mesure** μ est une application $\mu : \mathcal{F} \to [0, +\infty]$ qui associe une taille à chaque événement, telle que :

$$\mu(\varnothing) = 0, \qquad \mu\left(\bigsqcup_{n\geq 1} A_n\right) = \sum_{n\geq 1} \mu(A_n),$$

pour toute suite $(A_n)_{n\geq 1}$ d'événements deux à deux disjoints.
Lorsque $\mu(\Omega) = 1$, cette mesure est appelée **mesure de probabilité**, généralement notée $\mathbb{P}$.

Définition 1.1.2 (Espace de probabilité)**.** Un espace de probabilité est un triplet $(\Omega, \mathcal{F}, \mathbb{P})$, où Ω est l'ensemble des issues, $\mathcal{F}$ une tribu d'événements et $\mathbb{P}$ une mesure vérifiant

$$\mathbb{P}(\Omega) = 1, \qquad \mathbb{P}\left(\bigsqcup_{n\geq 1} A_n\right) = \sum_{n\geq 1} \mathbb{P}(A_n)$$

pour toute suite d'événements deux à deux disjoints. Une tribu contient Ω et est stable par complémentaire et union dénombrable.

Définition 1.1.3 (Variable aléatoire et loi)**.** Une variable aléatoire réelle est une application mesurable $X : (\Omega, \mathcal{F}) \to (\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Sa loi est la probabilité

$$\mathbb{P}_X(B) = \mathbb{P}(X \in B), \qquad B \in \mathcal{B}(\mathbb{R}).$$

La mesurabilité garantit que les événements tels que $\{X \leq t\}$ possèdent une probabilité. Dans les calculs, on utilise généralement la loi de X, sans expliciter Ω.

Définition 1.1.4 (Répartition, survie et densité)**.** La fonction de répartition et la fonction de survie sont

$$F_X(t) = \mathbb{P}(X \leq t), \qquad \overline{F}_X(t) = \mathbb{P}(X > t) = 1 - F_X(t).$$

Si X admet une densité f_X, alors

$$\mathbb{P}(X \in B) = \int_B f_X(x)\,\mathrm{d}x, \qquad F_X(t) = \int_{-\infty}^{t} f_X(x)\,\mathrm{d}x.$$

La densité est non négative et son intégrale vaut 1.

La fonction F_X est croissante, continue à droite et vérifie $F_X(-\infty) = 0$, $F_X(+\infty) = 1$. Elle caractérise entièrement la loi. Lorsque F_X est absolument continue, $F_X' = f_X$ presque partout au sens de Lebesgue.

Exemple 1.1.5 (Une durée d'attente)**.** Pour $X \sim \mathrm{Exp}(\lambda)$,

$$F_X(t) = \begin{cases} 0, & t < 0, \\ 1 - e^{-\lambda t}, & t \geq 0, \end{cases} \qquad \mathbb{P}(X > t) = e^{-\lambda t} \quad (t \geq 0).$$

La survie donne directement la probabilité de dépasser un délai.

1.2 Espérance, dispersion et moyennes empiriques

Définition 1.2.1 (Espérance et variance)**.** Si $\mathbb{E}[|X|] < \infty$, l'espérance de X est

$$\mathbb{E}[X] = \int_\Omega X \, \mathrm{d}\mathbb{P}.$$

Si $\mathbb{E}[X^2] < \infty$, sa variance vaut

$$\mathrm{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

Théorème 1.2.2 (Transfert)**.** *Pour une fonction mesurable g, si $g(X)$ est intégrable,*

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \, \mathbb{P}_X(\mathrm{d}x).$$

Ainsi,

$$\mathbb{E}[g(X)] = \begin{cases} \displaystyle\sum_x g(x)\mathbb{P}(X = x), & X \text{ discrète}, \\ \displaystyle\int_{\mathbb{R}} g(x) f_X(x) \, \mathrm{d}x, & X \text{ à densité}. \end{cases}$$

Le transfert permet de calculer une espérance à partir de la loi, sans revenir à l'espace des issues. Le moment d'ordre k est $\mathbb{E}[X^k]$, lorsqu'il est défini et fini.

On rappelle ce qu'est l'indépendance en Définition 1.3.1.

Théorème 1.2.3 (Lois des grands nombres)**.** *Soient $X_1, X_2, \ldots$ i.i.d., avec $\mathbb{E}[|X_1|] < \infty$. En posant $m = \mathbb{E}[X_1]$ et $\overline{X}_n = \frac{1}{n} \sum_{k=1}^{n} X_k$, on a*

$$\overline{X}_n \xrightarrow{p.s.} m, \qquad \overline{X}_n \xrightarrow{\mathbb{P}} m.$$

La première convergence est la loi forte ; la seconde est la loi faible.

Théorème 1.2.4 (Théorème central limite)**.** *Si, de plus, $0 < \sigma^2 = \mathrm{Var}(X_1) < \infty$, alors*

$$\frac{\sqrt{n}}{\sigma}(\overline{X}_n - m) \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1).$$

Pour n grand, la dispersion de la moyenne est donc de l'ordre de $\sigma/\sqrt{n}$.

Interprétation pour les files d'attente

La moyenne observée de durées de service indépendantes estime leur espérance. En revanche, les nombres de clients relevés successivement dans une même file sont généralement dépendants : le théorème i.i.d. ne s'applique pas directement à cette série.

Exemple 1.2.5. Si $S \sim \mathrm{Exp}(\mu)$, alors $\mathbb{E}[S] = 1/\mu$ et $\mathrm{Var}(S) = 1/\mu^2$. Une moyenne de n services indépendants possède une variance $1/(n\mu^2)$.

À retenir

La loi des grands nombres justifie la stabilisation d'une moyenne. Le TCL décrit ses fluctuations. Leur application exige de vérifier les hypothèses, notamment l'indépendance et les moments disponibles.

1.3 Indépendance des variables aléatoires

Définition 1.3.1 (Indépendance de variables aléatoires)**.** Deux variables aléatoires réelles X et Y sont dites **indépendantes** si, pour tous boréliens $A, B \in \mathcal{B}(\mathbb{R})$,

$$\mathbb{P}(X \in A,\ Y \in B) = \mathbb{P}(X \in A)\mathbb{P}(Y \in B).$$

Autrement dit, connaître la réalisation de l'une n'apporte aucune information probabiliste sur l'autre.
Plus généralement, les variables $X_1, \dots, X_n$ sont **mutuellement indépendantes** si

$$\mathbb{P}\left(\bigcap_{i=1}^{n} \{X_i \in A_i\}\right) = \prod_{i=1}^{n} \mathbb{P}(X_i \in A_i)$$

pour tous boréliens $A_1, \dots, A_n$.

Proposition 1.3.2 (Conséquences de l'indépendance)**.** *Si X et Y sont indépendantes et intégrables, alors*

$$\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y], \qquad \mathrm{Cov}(X, Y) = 0,$$

dès lors que la covariance est définie.
Si X et Y sont de carré intégrable, on obtient

$$\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y).$$

Plus généralement, pour $X_1, \dots, X_n$ indépendantes et de carré intégrable,

$$\mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{Var}(X_i).$$

Remarque 1.3.3. L'indépendance implique une covariance nulle, mais la réciproque est généralement fausse : deux variables peuvent être non corrélées tout en restant dépendantes. De même, l'indépendance deux à deux n'implique pas nécessairement l'indépendance mutuelle.

Exemple 1.3.4 (Durées de service indépendantes)**.** Soient $S_1, \dots, S_n$ des durées de service i.i.d., d'espérance m et de variance σ^2. Le temps total de service $T_n = \sum_{i=1}^{n} S_i$ vérifie

$$\mathbb{E}[T_n] = nm, \qquad \mathrm{Var}(T_n) = n\sigma^2.$$

L'indépendance permet ainsi d'additionner les variances, et non les écarts-types.

1.4 Les lois utilisées dans le cours

Les paramètres de taux ont l'unité inverse du temps. Un paramètre de comptage, comme celui d'une loi de Poisson, est sans dimension.

Loi	Masse ou densité	Espérance	Variance
$\mathrm{Exp}(\lambda)$	$\lambda e^{-\lambda x}\mathbb{1}_{\{x\geq 0\}}$	$1/\lambda$	$1/\lambda^2$
$\mathrm{Gamma}(k,\lambda)$	$\dfrac{\lambda^k}{\Gamma(k)}x^{k-1}e^{-\lambda x}\mathbb{1}_{\{x>0\}}$	k/λ	k/λ^2
$\mathrm{Poisson}(\theta)$	$\mathbb{P}(N=n)=e^{-\theta}\theta^n/n!$	θ	θ
$\mathrm{Geom}(p)$ sur $\mathbb{N}$	$\mathbb{P}(G=n)=p(1-p)^n$	$(1-p)/p$	$(1-p)/p^2$

Ici $\lambda>0$, $k>0$, $\theta\geq 0$, et $0<p<1$. Pour la loi de Poisson, $n\in\mathbb{N}$.

Définition 1.4.1 (Fonction Gamma)**.** Pour $a>0$,

$$\Gamma(a)=\int_0^\infty x^{a-1}e^{-x}\,\mathrm{d}x.$$

Une intégration par parties donne $\Gamma(a+1)=a\Gamma(a)$, donc $\Gamma(k)=(k-1)!$ pour $k\geq 1$ entier.

Proposition 1.4.2 (Somme de durées exponentielles)**.** *Si $S_1,\dots,S_k$ sont indépendantes de loi* $\mathrm{Exp}(\lambda)$*, alors*

$$S_1+\cdots+S_k\sim\mathrm{Gamma}(k,\lambda).$$

Lorsque k est entier, on parle aussi de loi d'Erlang.

Cette loi décrit une durée composée de plusieurs phases successives. Dans un processus de Poisson, elle donnera le temps nécessaire pour observer k arrivées.

Exemple 1.4.3 (Une unité de temps commune)**.** Un serveur traite en moyenne 12 clients par heure :

$$\mu=12\ \mathrm{h}^{-1},\qquad \mathbb{E}[S]=\frac{1}{12}\ \mathrm{h}=5\ \mathrm{min}.$$

Avec un flux de 8 clients par heure, le temps moyen entre deux arrivées vaut 1/8 heure, soit 7.5 minutes.

Remarque 1.4.4 (Deux conventions géométriques). Ici G compte le nombre d'échecs avant un premier succès et prend ses valeurs dans $\mathbb{N}$. La variable $G+1$, à valeurs dans $\{1,2,\dots\}$, compte le nombre total d'essais. Les formules de survie dépendent de cette convention.

À retenir

- ▷ La loi de Poisson décrit un *nombre d'événements*.
- ▷ Les lois exponentielle et Gamma décrivent des *durées*.
- ▷ La loi géométrique apparaîtra comme loi stationnaire de la file $M/M/1$.

1.5 Absence de mémoire et loi exponentielle

Proposition 1.5.1 (Absence de mémoire). *Pour $X \sim \mathrm{Exp}(\lambda)$ et $s, t \geq 0$,*

$$\mathbb{P}(X > s + t \mid X > s) = e^{-\lambda t} = \mathbb{P}(X > t).$$

Pour $G \sim \mathrm{Geom}(p)$ sur $\mathbb{N}$,

$$\mathbb{P}(G \geq m + n \mid G \geq m) = \mathbb{P}(G \geq n), \qquad m, n \in \mathbb{N}.$$

Dans le cas exponentiel, une durée résiduelle a la même loi que la durée initiale. Il s'agit d'une propriété conditionnelle : elle ne signifie pas qu'un événement doit survenir prochainement parce que l'on a déjà beaucoup attendu.

Théorème 1.5.2 (Caractérisation de l'exponentielle). *Soit X une variable aléatoire finie presque sûrement, avec $\mathbb{P}(X > 0) = 1$ et $\mathbb{P}(X > t) > 0$ pour tout $t \geq 0$. Si X vérifie l'absence de mémoire, alors $X \sim \mathrm{Exp}(\lambda)$ pour un $\lambda > 0$.*

Preuve. Posons $g(t) = \mathbb{P}(X > t)$. L'hypothèse donne $g(s + t) = g(s)g(t)$ avec $g(0) = 1$. La fonction g est positive et décroissante. Par conséquent $a(t) = -\log g(t)$ est croissante et additive : $a(s + t) = a(s) + a(t)$.
Pour tout rationnel $r \geq 0$, l'additivité entraîne $a(r) = r\, a(1)$. En encadrant un réel $t \geq 0$ par des suites rationnelles et en utilisant la monotonie, on obtient $a(t) = \lambda t$, avec $\lambda = a(1) \geq 0$.
Enfin, X étant finie presque sûrement, $g(t) \to 0$. On ne peut donc pas avoir $\lambda = 0$. Ainsi $g(t) = e^{-\lambda t}$, avec $\lambda > 0$. □

Cette démonstration ne suppose pas à l'avance la dérivabilité de la fonction de survie.

Proposition 1.5.3 (Discrétisation). *Si $X \sim \mathrm{Exp}(\lambda)$ et $\Delta > 0$, alors*

$$G = \lfloor X/\Delta \rfloor \sim \mathrm{Geom}\left(1 - e^{-\lambda\Delta}\right).$$

Preuve. Pour $n \in \mathbb{N}$, $\mathbb{P}(G = n) = \mathbb{P}(n\Delta \leq X < (n + 1)\Delta) = e^{-\lambda n\Delta}(1 - e^{-\lambda\Delta})$. □

Le lien avec un taux instantané

Pour $h \downarrow 0$,

$$\mathbb{P}(X \leq t + h \mid X > t) = 1 - e^{-\lambda h} = \lambda h + o(h).$$

Le taux conditionnel de réalisation reste constant. Cette propriété rend possible une description de nombreuses files par le seul nombre de clients présents.

1.6 Transformées : calculer les moments et les sommes

Définition 1.6.1 (Trois transformées). Pour $N \in \mathbb{N}$ et $X \geq 0$, on définit

$$G_N(z) = \mathbb{E}[z^N], \qquad |z| \leq 1,$$

$$\phi_X(s) = \mathbb{E}[e^{-sX}], \qquad s \geq 0.$$

Il s'agit respectivement de la *fonction génératrice* de probabilités et de la *transformée de Laplace–Stieltjes*. Pour une variable réelle, la *fonction caractéristique* est

$$\varphi_X(t) = \mathbb{E}[e^{itX}], \qquad t \in \mathbb{R}, \quad i^2 = -1.$$

Cette dernière existe toujours et caractérise la loi.

Si les moments concernés sont finis, les dérivées à l'origine ou en 1 donnent

$$\mathbb{E}[X] = -\phi'_X(0^+), \qquad \mathbb{E}[X^2] = \phi''_X(0^+),$$

$$\mathbb{E}[N] = G'_N(1^-), \qquad \mathbb{E}[N(N-1)] = G''_N(1^-).$$

La fonction génératrice des moments $M_X(t) = \mathbb{E}[e^{tX}]$ n'est pas nécessairement finie pour $t > 0$. Lorsqu'elle est finie dans un voisinage de 0, $M_X^{(k)}(0) = \mathbb{E}[X^k]$.

Preuve. Par définition de la transformée de Laplace,

$$\phi_{X+Y}(s) = \mathbb{E}\left[e^{-s(X+Y)}\right] = \mathbb{E}\left[e^{-sX}e^{-sY}\right].$$

L'indépendance de X et Y permet de factoriser l'espérance, d'où

$$\phi_{X+Y}(s) = \phi_X(s)\phi_Y(s).$$

Pour la seconde identité, posons $S_N = \sum_{i=1}^{N} X_i$, avec $S_0 = 0$. Par définition, puis par la formule de l'espérance totale en conditionnant par N,

$$\begin{aligned}
\phi_{S_N}(s) &= \mathbb{E}\left[e^{-sS_N}\right] \\
&= \sum_{n\geq 0} \mathbb{P}(N=n)\mathbb{E}\left[e^{-sS_N} \mid N=n\right] \\
&= \sum_{n\geq 0} \mathbb{P}(N=n)\mathbb{E}\left[e^{-s\sum_{i=1}^{n} X_i}\right] \\
&= \sum_{n\geq 0} \mathbb{P}(N=n)\prod_{i=1}^{n}\mathbb{E}[e^{-sX_i}] \\
&= \sum_{n\geq 0} \mathbb{P}(N=n)\phi_{X_1}(s)^n \\
&= G_N(\phi_{X_1}(s)).
\end{aligned}$$

La troisième égalité utilise l'indépendance entre N et la suite (X_i), tandis que la quatrième utilise l'indépendance mutuelle des X_i. Enfin, $G_N(z) = \mathbb{E}[z^N]$ désigne la fonction génératrice des probabilités de N. □

Loi	Transformée
$X \sim \text{Exp}(\lambda)$	$\phi_X(s) = \lambda/(\lambda+s)$
$X \sim \text{Gamma}(k,\lambda)$	$\phi_X(s) = (\lambda/(\lambda+s))^k$
$N \sim \text{Poisson}(\theta)$	$G_N(z) = e^{\theta(z-1)}$
$G \sim \text{Geom}(p)$	$G_G(z) = p/[1-(1-p)z]$

À retenir

L'indépendance transforme les sommes de variables en produits de transformées. Ces identités serviront aux renouvellements et aux temps de séjour dans les files.

1.7 Processus stochastiques et évolution temporelle

Définition 1.7.1 (Processus stochastique)**.** Un **processus stochastique** est une famille de variables aléatoires $(X_t)_{t\in T}$ définies sur un même espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$ et à valeurs dans un espace d'états $\mathcal{S}$:

$$X_t : \Omega \longrightarrow \mathcal{S}, \qquad t \in T.$$

Lorsque l'ensemble des indices T représente le temps, le processus décrit l'évolution aléatoire d'un système.
On distingue les processus à **temps discret** ($T = \mathbb{N}$) et à **temps continu** ($T = \mathbb{R}_+$).
Pour chaque instant t, X_t est une variable aléatoire possédant sa propre loi. En revanche, pour une issue $\omega \in \Omega$ fixée, l'application $t \mapsto X_t(\omega)$ constitue une **trajectoire** (ou réalisation) du processus.

Exemple 1.7.2 (Nombre de clients dans une file d'attente)**.** Considérons une file d'attente et notons N_t le nombre de clients présents à l'instant $t \geq 0$.
Le processus $(N_t)_{t\geq 0}$ est à temps continu et à espace d'états discret $\mathcal{S} = \mathbb{N}$. Son évolution dépend des arrivées et des départs :

$$N_t = N_0 + A_t - D_t,$$

où A_t et D_t désignent respectivement les nombres cumulés d'arrivées et de départs avant l'instant t.
À un instant fixé, $\mathbb{P}(N_t = n)$ représente la probabilité d'observer n clients. Une trajectoire particulière décrit, quant à elle, l'évolution effective du nombre de clients au cours du temps. Ainsi, **la loi décrit les comportements possibles**, tandis qu'une trajectoire décrit une réalisation particulière du système.

Dépendance temporelle. Contrairement à une simple collection de variables indépendantes, les variables X_s et X_t peuvent être dépendantes : l'état présent contient généralement de l'information sur l'état futur.

Cette dépendance constitue l'un des objets centraux de l'étude des processus stochastiques. Les chaînes de Markov en fournissent un exemple particulier : conditionnellement à l'état présent, leur évolution future ne dépend pas du passé.

1.8 Rappels : notations asymptotiques et développements limités

Les notations asymptotiques permettent de comparer des fonctions au voisinage d'un point, généralement lorsque $h \to 0$ ou $n \to +\infty$. Elles servent à identifier les termes dominants d'une approximation et à contrôler son erreur.

Définition 1.8.1 (Petit o, grand O et équivalence)**.** Soient f et g deux fonctions définies au voisinage de a, avec $g(x) \neq 0$ pour $x \neq a$ suffisamment proche de a.

- ▷ **Petit o :** $f(x) = o(g(x))$ lorsque $x \to a$ si

$$\lim_{x\to a} \frac{f(x)}{g(x)} = 0.$$

  Le terme f est alors négligeable devant g.
- ▷ **Grand O :** $f(x) = O(g(x))$ lorsque $x \to a$ s'il existe $C > 0$ tel que, au voisinage de a,

$$|f(x)| \leq C|g(x)|.$$

  Le terme f est donc au plus du même ordre de grandeur que g.

▷ **Équivalence :** $f(x) \sim g(x)$ lorsque $x \to a$ si

$$\lim_{x \to a} \frac{f(x)}{g(x)} = 1.$$

Les deux fonctions possèdent alors le même comportement asymptotique dominant.

Ces définitions s'appliquent également lorsque $a = +\infty$ ou $a = -\infty$.

Exemple 1.8.2 (Développement limité de l'exponentielle)**.** Au voisinage de $h = 0$, le développement de Taylor donne

$$e^h = 1 + h + \frac{h^2}{2} + O(h^3).$$

On en déduit notamment

$$e^h - 1 = h + o(h), \qquad e^h - 1 \sim h.$$

Ainsi, h^2 est négligeable devant h lorsque $h \to 0$, tandis que le reste $O(h^3)$ est borné en valeur absolue par une constante fois $|h|^3$.
Plus généralement, un développement limité à l'ordre k s'écrit

$$f(h) = \sum_{j=0}^{k} a_j h^j + o(h^k),$$

lorsque les hypothèses de régularité nécessaires sont vérifiées.

Application aux processus stochastiques. Dans un processus de Poisson d'intensité $\lambda > 0$, le nombre N_h d'arrivées pendant un petit intervalle de durée $h > 0$ suit une loi Poisson(λh). Par développement limité,

$$\begin{aligned}
\mathbb{P}(N_h = 0) &= e^{-\lambda h} = 1 - \lambda h + o(h), \\
\mathbb{P}(N_h = 1) &= \lambda h e^{-\lambda h} = \lambda h + o(h), \\
\mathbb{P}(N_h \geq 2) &= 1 - e^{-\lambda h}(1 + \lambda h) = O(h^2) = o(h).
\end{aligned}$$

Ces relations montrent que, sur un intervalle très court, la probabilité d'une seule arrivée est approximativement λh, tandis que celle de plusieurs arrivées est négligeable devant h.

À retenir

Le petit o caractérise un terme négligeable, le grand O fournit une borne sur son ordre de grandeur, et l'équivalence identifie un comportement dominant. Ces notations sont essentielles pour décrire les transitions infinitésimales des processus de Poisson et des chaînes de Markov à temps continu.

Chapitre 2

Chaînes de Markov en temps discret

2.1 État présent, transitions et évolution de la loi

Objectif. Distinguer la dynamique d'une trajectoire et l'évolution de sa distribution.

Définition 2.1.1 (Chaîne de Markov homogène)**.** Une suite $(X_n)_{n\geq 0}$, à valeurs dans un ensemble fini ou dénombrable $\mathcal{S}$, est une **chaîne de Markov** s'il existe une matrice de transition $P = (p_{ij})$ telle que

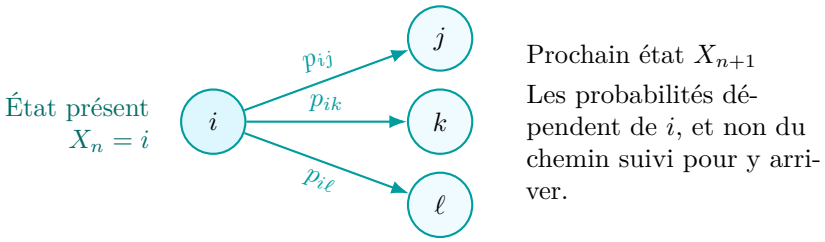
$$\mathbb{P}(X_{n+1} = j \mid X_0, \dots, X_n) = \mathbb{P}(X_{n+1} = j \mid X_n) \quad \text{p.s.}$$

La chaîne est dite **homogène en temps** lorsque les probabilités de transition ne dépendent pas de l'instant n :

$$\mathbb{P}(X_{n+1} = j \mid X_n = i) = p_{ij}, \qquad \forall n \geq 0,$$

pour tout état i tel que $\mathbb{P}(X_n = i) > 0$. Les coefficients vérifient $p_{ij} \geq 0$ et $\sum_{j\in\mathcal{S}} p_{ij} = 1$.

Intuition. La propriété de Markov signifie que, **connaissant l'état présent**, le passé n'apporte aucune information supplémentaire pour prédire l'état suivant ; l'homogénéité signifie que les règles probabilistes d'évolution restent identiques au cours du temps.



Vue locale des transitions issues de i : seuls trois destinataires sont représentés. La même règle s'applique à chaque pas.

Proposition 2.1.2 (Évolution des distributions)**.** *Si $\nu^{(0)}$ est la loi initiale, écrite en ligne, alors*

$$\nu^{(n)} = \nu^{(0)} P^n, \qquad (P^n)_{ij} = \mathbb{P}(X_n = j \mid X_0 = i).$$

Preuve. La formule des probabilités totales donne

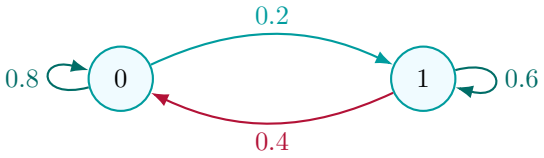
$$\nu_j^{(n+1)} = \sum_{i\in\mathcal{S}} \mathbb{P}(X_n = i)\mathbb{P}(X_{n+1} = j \mid X_n = i) = \sum_{i\in\mathcal{S}} \nu_i^{(n)} p_{ij}.$$

Ainsi $\nu^{(n+1)} = \nu^{(n)} P$, puis on raisonne par récurrence. □

Exemple 2.1.3 (Une ressource disponible ou occupée)**.** Notons 0 l'état disponible et 1 l'état occupé. Une dynamique possible est

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}.$$

Si $X_0 = 0$, alors $\nu^{(1)} = (0.8, 0.2)$, puis $\nu^{(2)} = (0.8, 0.2) \cdot P = (0.72, 0.28)$.



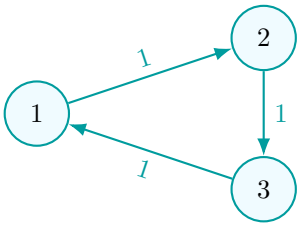
Point de vigilance. Les nombres inscrits sur ce graphe sont des *probabilités*. Dans un graphe de chaîne à temps continu, ils seront des *taux*, avec une unité inverse du temps.

2.2 Communication, retours et périodicité

Définition 2.2.1 (Irréductibilité)**.** Une chaîne est irréductible lorsque tous les états communiquent :

$$\forall i, j \in \mathcal{S}, \quad \exists n \geq 0 : \ (P^n)_{ij} > 0.$$

Son graphe orienté est alors fortement connexe.



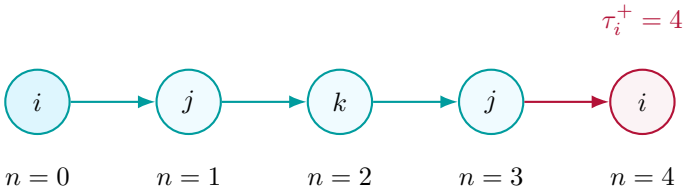
Tout état est accessible depuis tout autre en suivant les flèches. Une transition directe entre chaque paire n'est pas nécessaire.

Ce cycle orienté forme une seule classe de communication.

Définition 2.2.2 (Premier retour)**.** En partant de i, le premier temps de retour en i est

$$\tau_i^+ = \inf\{n \geq 1 : X_n = i\},$$

avec $\inf \varnothing = +\infty$. L'état i est récurrent si $\mathbb{P}_i(\tau_i^+ < \infty) = 1$, et récurrent positif si $\mathbb{E}_i[\tau_i^+] < \infty$.



Une trajectoire possible, déroulée dans le temps, avec $j, k \neq i$: le premier retour en i a lieu au quatrième pas. Ce retour observé ne suffit pas à établir la récurrence.

Un état récurrent dont le temps moyen de retour est infini est dit *récurrent nul*. Un état non récurrent est *transient*. Dans une chaîne irréductible, ces propriétés sont communes à tous les états.

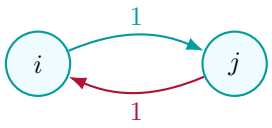
Définition 2.2.3 (Période)**.** La période d'un état récurrent i est

$$d(i) = \operatorname{pgcd}\{n \geq 1 : (P^n)_{ii} > 0\}.$$

Une chaîne irréductible est *apériodique* lorsque cette période vaut 1.

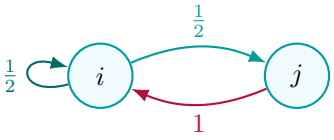
Une boucle $p_{ii} > 0$ suffit à assurer l'apériodicité d'une chaîne irréductible. Elle n'est pas nécessaire : des retours de longueurs 2 et 3, par exemple, donnent déjà un plus grand commun diviseur égal à 1.

Période 2



Retours en i : $2, 4, 6, \ldots$
$\text{pgcd}(2, 4, 6, \ldots) = 2$.

Période 1



Retours en i : $1, 2, 3, \ldots$
La boucle permet
un retour en un pas.

Les deux chaînes sont irréductibles ; seule celle de droite est apériodique.

Exemple 2.2.4 (Une chaîne périodique)**.** Pour

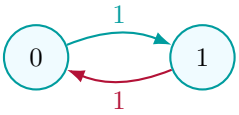
$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix},$$

la chaîne alterne entre les deux états. Les retours ont lieu uniquement après un nombre pair de pas : la période vaut 2.

Interprétation : communication, retours et périodicité. L'**irréductibilité** signifie que tout état est accessible depuis n'importe quel autre en un nombre fini d'étapes, avec une probabilité positive. Elle ne garantit toutefois pas que cet état sera effectivement atteint.

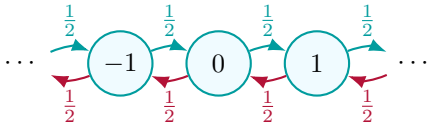
La **récurrence** signifie qu'en partant d'un état, la chaîne y reviendra presque sûrement. On distingue :

- **Récurrence positive :** le retour est presque sûr et son temps moyen est fini. Toute chaîne irréductible à espace d'états fini possède cette propriété.



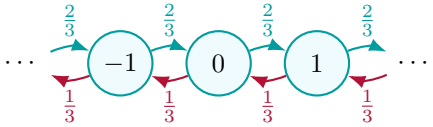
$\mathbb{P}_0(\tau_0^+ < \infty) = 1, \quad \mathbb{E}_0[\tau_0^+] = 2.$
Le retour a lieu exactement après deux pas.

- **Récurrence nulle :** le retour est presque sûr, mais son espérance est infinie. C'est le cas de la marche aléatoire symétrique sur $\mathbb{Z}$.



$\mathbb{P}_0(\tau_0^+ < \infty) = 1, \quad \mathbb{E}_0[\tau_0^+] = \infty.$
Le retour est certain, mais peut être arbitrairement long.

- **Transience :** il existe une probabilité strictement positive de ne jamais revenir à l'état initial. C'est le cas d'une marche aléatoire biaisée sur $\mathbb{Z}$.



$\mathbb{P}_0(\tau_0^+ < \infty) = \frac{2}{3} < 1.$
La dérive vers la droite rend possible une absence définitive de retour.

Dans les deux marches sur $\mathbb{Z}$, les probabilités de transition indiquées se répètent en chaque entier.

La **période** décrit, quant à elle, la régularité des instants auxquels un retour est possible. Une période $d(i) > 1$ traduit une contrainte cyclique : les retours ne peuvent avoir lieu qu'à des instants multiples de $d(i)$. Par exemple, une chaîne alternant entre deux états possède une période 2. Lorsque $d(i) = 1$, l'état est dit **apériodique** : les retours ne sont pas contraints à un cycle strict. Cela ne signifie pas qu'un retour est possible à chaque instant.

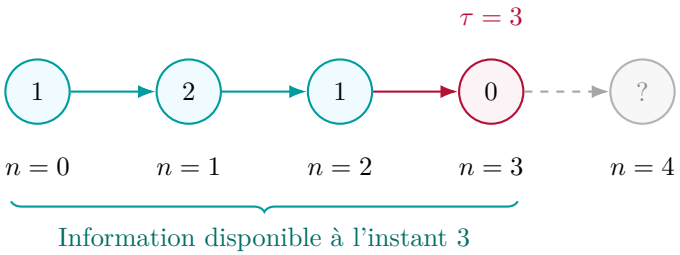
Application aux files d'attente. Dans une file M/M/1 observée aux instants de transition, la chaîne des nombres de clients est irréductible. Si $\lambda < \mu$, elle est récurrente positive (file stable) ; si $\lambda = \mu$, récurrente nulle ; et si $\lambda > \mu$, transiente (file instable). La chaîne des sauts est toutefois périodique de période 2, car chaque transition modifie le nombre de clients de ± 1.

Temps d'arrêt

Avec $\mathcal{F}_n = \sigma(X_0, \dots, X_n)$, une variable $\tau : \Omega \to \mathbb{N} \cup \{\infty\}$ est un temps d'arrêt si

$$\{\tau \leq n\} \in \mathcal{F}_n, \qquad n \geq 0.$$

Au temps n, l'information disponible permet de décider si l'arrêt a déjà eu lieu. Un premier temps d'atteinte est un exemple fondamental.



Pour $\tau = \inf\{n \geq 0 : X_n = 0\}$, cette trajectoire permet de constater l'arrêt à l'instant 3, sans connaître le futur.

À retenir

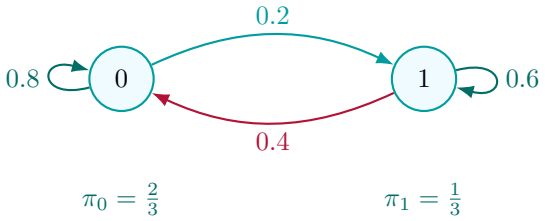
L'irréductibilité décrit l'accessibilité des états. La récurrence positive contrôle les temps moyens de retour. L'apériodicité exclut des oscillations imposées par le calendrier des transitions.

2.3 Stationnarité, convergence et moyennes temporelles

Définition 2.3.1 (Probabilité stationnaire)**.** Une probabilité $\pi = (\pi_i)$ est stationnaire si

$$\pi P = \pi, \qquad \pi_i \geq 0, \qquad \sum_{i \in \mathcal{S}} \pi_i = 1.$$

Si $X_0 \sim \pi$, alors $X_n \sim \pi$ pour tout n.



$$\frac{2}{3} \times 0.8 + \frac{1}{3} \times 0.4 = \frac{2}{3}$$
$$\frac{2}{3} \times 0.2 + \frac{1}{3} \times 0.6 = \frac{1}{3}$$

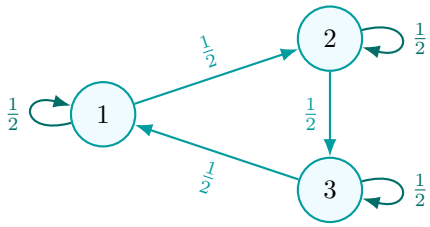
Les masses de probabilité se redistribuent suivant les flèches et se reconstituent après chaque pas : $\pi P = \pi$. La trajectoire, elle, continue à changer d'état.

Théorème 2.3.2 (Existence et convergence)**.** *Pour une chaîne irréductible sur un espace dénombrable :*

- ▷ *une probabilité stationnaire existe si et seulement si la chaîne est récurrente positive ; elle est alors unique ;*
- ▷ *si la chaîne est également apériodique, alors*

$$(P^n)_{ij} \longrightarrow \pi_j \qquad \text{pour tous } i, j.$$

Sur un espace fini, toute chaîne irréductible *est* récurrente positive.



Cycle : irréductibilité.
Espace fini : récurrence positive.
Boucles : apériodicité.

$$\nu P^n \longrightarrow \pi = \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right)$$

pour toute loi initiale ν.

Ici, les trois propriétés assurent la convergence de la loi vers l'unique probabilité stationnaire.

Remarque 2.3.3 (L'existence ne suffit pas à la convergence). La chaîne alternante de la section précédente possède la probabilité stationnaire $(1/2, 1/2)$. Cependant, en partant de 0, sa loi alterne entre $(1, 0)$ et $(0, 1)$. Elle ne converge pas.

Le cas d'un espace d'états fini

Corollaire 2.3.4 (Existence, unicité et convergence)**.** *Soit P la matrice de transition d'une chaîne de Markov homogène sur un espace fini $\mathcal{S}$.*

(i) ***Existence.*** *Il existe au moins une probabilité stationnaire π, vérifiant $\pi P = \pi$.*

(ii) ***Unicité.*** *Si P est irréductible, cette probabilité est unique.*

(iii) ***Convergence.*** *Si P est irréductible et apériodique, alors, pour toute loi initiale π_0,*

$$\pi_0 P^n \xrightarrow[n\to\infty]{} \pi.$$

Preuve. Toute chaîne finie possède une classe de communication fermée $\mathcal{C}$. La chaîne restreinte à cette classe est finie et irréductible, donc récurrente positive : elle admet une probabilité stationnaire. Son prolongement par zéro hors de $\mathcal{C}$ établit l'existence sur $\mathcal{S}$.
Si P est irréductible, le théorème précédent garantit l'unicité. Si elle est aussi apériodique, $(P^n)_{ij} \to \pi_j$; la finitude de $\mathcal{S}$ permet alors d'écrire

$$(\pi_0 P^n)_j = \sum_{i\in\mathcal{S}} \pi_0(i)(P^n)_{ij} \longrightarrow \sum_{i\in\mathcal{S}} \pi_0(i)\pi_j = \pi_j.$$

□

Exemple 2.3.5 (Existence sans unicité)**.** Deux états absorbants forment deux classes fermées distinctes.

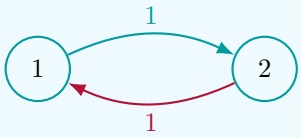
$$P = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$



Toute loi $\pi = (\alpha, 1-\alpha)$, avec $\alpha \in [0, 1]$, vérifie $\pi P = \pi$: il existe une infinité de probabilités stationnaires.

Exemple 2.3.6 (Unicité sans convergence générale)**.** La chaîne alternante est irréductible, mais de période 2.

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}.$$



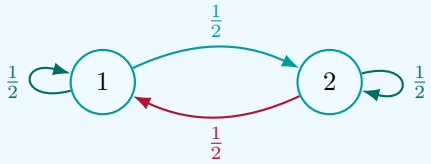
Son unique probabilité stationnaire est $\pi = (1/2, 1/2)$. Pour $\pi_0 = (1, 0)$, cependant,

$$\pi_0 P^{2n} = (1, 0), \qquad \pi_0 P^{2n+1} = (0, 1).$$

La loi oscille : l'unicité de π ne suffit pas à garantir la convergence depuis toute loi initiale.

Exemple 2.3.7 (Unicité et convergence)**.** Les deux états communiquent et possèdent une boucle : la chaîne est irréductible et apériodique.

$$P = \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}.$$



Ici, $P^n = P$ pour tout $n \geq 1$. Pour toute loi initiale $\pi_0 = (\alpha, 1 - \alpha)$,

$$\pi_0 P^n = \left(\frac{1}{2}, \frac{1}{2}\right) = \pi, \qquad n \geq 1.$$

L'équilibre est atteint dès le premier pas.

Remarque 2.3.8 (Des conditions suffisantes). L'irréductibilité n'est nécessaire ni à l'unicité de la loi stationnaire ni à la convergence vers celle-ci depuis toute loi initiale. Par exemple, pour $P = \left(\begin{smallmatrix} 0 & 1 \\ 0 & 1 \end{smallmatrix}\right)$, l'état 2 est absorbant et toute loi initiale devient l'unique loi stationnaire $(0, 1)$ après un pas.

Théorème 2.3.9 (Loi forte pour les moyennes temporelles)**.** *Si la chaîne est* irréductible *et* récurrente positive*, alors, pour toute fonction f telle que $\sum_{i \in \mathcal{S}} \pi_i |f(i)| < \infty$,*

$$\frac{1}{n} \sum_{k=0}^{n-1} f(X_k) \xrightarrow{p.s.} \sum_{i \in \mathcal{S}} \pi_i f(i).$$

L'apériodicité n'est pas nécessaire à ce résultat.

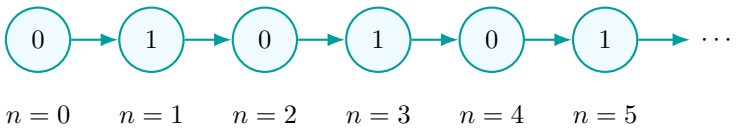
En prenant $f(x) = \mathbb{1}_{\{x=j\}}$, on obtient

$$\frac{1}{n} \sum_{k=0}^{n-1} \mathbb{1}_{\{X_k=j\}} \xrightarrow{\text{p.s.}} \pi_j.$$

Ainsi π_j décrit aussi une fréquence de visite à long terme.

Pourquoi des moyennes peuvent converger malgré les oscillations

Dans la chaîne alternante, les probabilités à un instant fixé oscillent. En revanche, chaque état est visité environ une fois sur deux : les fréquences convergent vers $1/2$. Il faut donc distinguer la convergence de la loi de X_n et celle d'une moyenne calculée le long d'une trajectoire.



Trajectoire de la chaîne alternante : parmi les $2m$ observations $X_0, \dots, X_{2m-1}$, chaque état apparaît m fois. Les fréquences valent $1/2$, malgré l'oscillation de la loi.

Point de vigilance. Sur un espace infini, une matrice stochastique n'admet pas nécessairement de probabilité stationnaire. Une mesure invariante de masse infinie ne peut pas être utilisée comme distribution d'équilibre.

2.4 Calcul de l'équilibre et réversibilité

La recherche de π est un problème linéaire :

$$\pi(P - I) = 0, \qquad \sum_{i \in \mathcal{S}} \pi_i = 1.$$

L'équation de normalisation remplace une équation redondante. Le vecteur π est un vecteur propre gauche de P pour la valeur propre 1.

Exemple 2.4.1 (Calcul à deux états)**.** Pour

$$P = \begin{pmatrix} 1-a & a \\ b & 1-b \end{pmatrix}, \qquad 0 < a, b < 1,$$

l'équation stationnaire se réduit à

$$\pi_0 a = \pi_1 b, \qquad \pi_0 + \pi_1 = 1.$$

D'où

$$\pi_0 = \frac{b}{a+b}, \qquad \pi_1 = \frac{a}{a+b}.$$

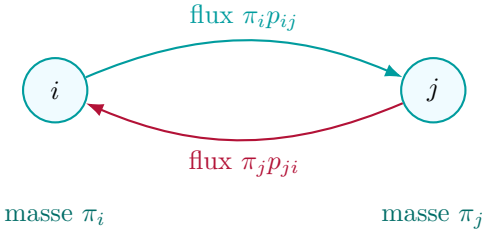
Avec $a = 0.2$, $b = 0.4$, on obtient $\pi = (2/3, 1/3)$.

Définition 2.4.2 (Équilibre détaillé [a])**.** Une probabilité π vérifie l'équilibre détaillé si

$$\pi_i p_{ij} = \pi_j p_{ji} \qquad \text{pour tous } i, j.$$

La chaîne stationnaire correspondante est dite réversible.

a. ou encore, "réversibilité"



$\pi_i p_{ij} = \pi_j p_{ji}$

À l'équilibre, les flux opposés se compensent pour chaque paire d'états.

Vue d'une paire d'états : les flèches portent ici des flux stationnaires, et non les seules probabilités de transition.

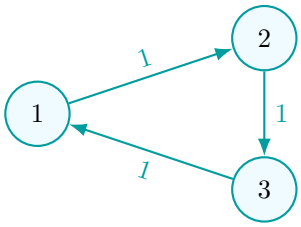
Proposition 2.4.3. *Toute probabilité vérifiant* l'équilibre détaillé *est* stationnaire.

Preuve. Pour chaque j,

$$(\pi P)_j = \sum_{i \in \mathcal{S}} \pi_i p_{ij} = \pi_j \sum_{i \in \mathcal{S}} p_{ji} = \pi_j.$$

Dans la dernière somme, j est l'indice de ligne : $\sum_{i \in \mathcal{S}} p_{ji} = 1$. □

L'équilibre détaillé impose une compensation entre chaque paire d'états. L'équilibre global exige seulement que le flux total entrant dans un état égale son flux total sortant. Une chaîne stationnaire peut donc ne pas être réversible.



$\pi = \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right)$ est stationnaire.

En chaque état : flux entrant = flux sortant = $\frac{1}{3}$.

Mais $\pi_1 p_{12} = \frac{1}{3} \neq 0 = \pi_2 p_{21}$.

Les probabilités de transition valent 1 *sur le cycle. Un flux stationnaire circule dans un seul sens : l'équilibre global n'impose pas l'équilibre détaillé.*

Existence dans le cas fini : idée de preuve

Pour une loi initiale ν, considérons

$$\overline{\nu}_n = \frac{1}{n} \sum_{k=0}^{n-1} \nu P^k.$$

Le simplexe des probabilités étant compact, une sous-suite converge vers une probabilité π. Or

$$\overline{\nu}_n P - \overline{\nu}_n = \frac{\nu P^n - \nu}{n} \longrightarrow 0.$$

Toute limite ainsi obtenue vérifie donc $\pi P = \pi$. L'irréductibilité assure ensuite l'unicité.

À retenir

Pour calculer l'équilibre, commencer par les équations stationnaires. Si la structure du graphe permet l'équilibre détaillé, le calcul devient souvent une simple récurrence.

Chapitre 3

Chaînes de Markov à temps continu

Objectif. Comprendre comment des taux instantanés déterminent une dynamique probabiliste en temps continu.

3.1 De la probabilité de transition au générateur

Définition 3.1.1 (Chaîne de Markov à temps continu)**.** Un processus stochastique $(X_t)_{t\geq 0}$, à valeurs dans un espace d'états fini ou dénombrable $\mathcal{S}$, est une *chaîne de Markov à temps continu* si

$$\mathbb{P}(X_{t+s} = j \mid \mathcal{F}_t) = \mathbb{P}(X_{t+s} = j \mid X_t), \qquad s, t \geq 0, \quad j \in \mathcal{S},$$

où $\mathcal{F}_t = \sigma(X_u : 0 \leq u \leq t)$ représente l'information disponible jusqu'au temps t.

Autrement dit, une fois l'état présent connu, la connaissance du passé n'apporte aucune information supplémentaire pour prévoir le futur.

Nous considérons des trajectoires constantes entre les sauts, continues à droite, et des chaînes *non explosives* : elles effectuent un nombre fini de changements d'état sur tout intervalle de temps borné.

Définition 3.1.2 (Probabilités de transition)**.** Pour $0 \leq s \leq t$, la probabilité de transition de l'état i à l'état j entre les instants s et t est

$$p_{ij}(s, t) = \mathbb{P}(X_t = j \mid X_s = i).$$

La matrice $P(s, t) = (p_{ij}(s, t))_{i,j\in\mathcal{S}}$ est une matrice stochastique :

$$p_{ij}(s, t) \geq 0, \qquad \sum_{j\in\mathcal{S}} p_{ij}(s, t) = 1.$$

Définition 3.1.3 (Homogénéité)**.** La chaîne est *homogène dans le temps* si ses probabilités de transition dépendent uniquement de la durée écoulée :

$$p_{ij}(s, t) = p_{ij}(0, t - s).$$

On utilise alors la notation à un seul paramètre

$$p_{ij}(t) = \mathbb{P}_i(X_t = j), \qquad P(t) = (p_{ij}(t))_{i,j\in\mathcal{S}},$$

où $\mathbb{P}_i$ désigne la probabilité lorsque $X_0 = i$.

L'homogénéité signifie que les règles d'évolution restent les mêmes au cours du temps. Dans la suite, toutes les chaînes considérées sont homogènes.

La propriété de Markov et la formule des probabilités totales donnent

$$p_{ij}(t + s) = \sum_{k\in\mathcal{S}} p_{ik}(t)p_{kj}(s).$$

En notation matricielle, ce sont les relations de *Chapman–Kolmogorov* :

$$P(0) = I, \qquad P(t + s) = P(t)P(s).$$

L'évolution pendant $t+s$ se décompose ainsi en une évolution pendant t, puis pendant s, en sommant sur les états intermédiaires possibles.

Définition 3.1.4 (Générateur infinitésimal)**.** Le *générateur infinitésimal* $Q = (q_{ij})_{i,j\in\mathcal{S}}$ est défini, lorsque ces limites existent et sont finies, par

$$q_{ij} = \lim_{h\downarrow 0} \frac{p_{ij}(h) - \mathbb{1}_{\{i=j\}}}{h}.$$

On note $q_i = -q_{ii}$.

Le générateur décrit la dynamique à l'échelle infinitésimale : il indique à quelle vitesse la probabilité quitte chaque état et se répartit vers les autres.

Propriété 3.1.5 (Structure du générateur)**.** *Pour les chaînes conservatives étudiées ici,*

$$q_{ij} \geq 0 \quad (i \neq j), \qquad q_{ii} = -\sum_{j\neq i} q_{ij}.$$

Chaque ligne de Q somme donc à zéro, et

$$q_i = \sum_{j\neq i} q_{ij}$$

est le taux total de sortie de l'état i.

Démonstration sur un espace fini. Pour $i \neq j$ et $h > 0$, on a $p_{ij}(h)/h \geq 0$. Par passage à la limite,

$$q_{ij} = \lim_{h\downarrow 0} \frac{p_{ij}(h)}{h} \geq 0.$$

Aucune hypothèse de croissance de p_{ij} n'est nécessaire.
D'autre part, la conservation de la masse donne

$$\sum_{j\in\mathcal{S}} p_{ij}(h) = 1 \quad \Longrightarrow \quad \sum_{j\in\mathcal{S}} \frac{p_{ij}(h) - \mathbb{1}_{\{i=j\}}}{h} = 0.$$

La somme étant finie, on peut passer à la limite terme à terme :

$$\sum_{j\in\mathcal{S}} q_{ij} = 0, \qquad \text{soit} \qquad q_{ii} = -\sum_{j\neq i} q_{ij}.$$

□

La définition du générateur s'écrit aussi

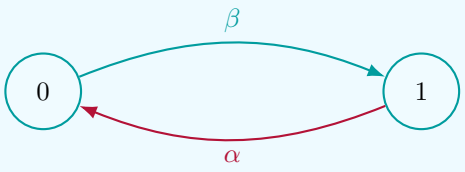
$$p_{ij}(h) = \begin{cases} q_{ij}h + o(h), & j \neq i, \\ 1 - q_i h + o(h), & j = i. \end{cases}$$

Sur un espace fini, on résume ces développements par

$$P(h) = I + hQ + o(h).$$

Les coefficients q_{ij} sont des **taux**, exprimés en inverse d'une unité de temps. Ce sont les produits $q_{ij}h$ qui approchent des probabilités lorsque h est petit.

Exemple 3.1.6 (Disponibilité d'une machine)**.** Une machine fonctionne dans l'état 1 et est en réparation dans l'état 0. Les taux de panne et de réparation sont respectivement $\alpha > 0$ et $\beta > 0$.



En réparation En fonctionnement

Dans l'ordre des états $(0, 1)$, le générateur est

$$Q = \begin{pmatrix} -\beta & \beta \\ \alpha & -\alpha \end{pmatrix}.$$

Depuis l'état 1, une panne dans les h prochaines unités de temps a une probabilité $\alpha h + o(h)$. Depuis l'état 0, la réparation se termine dans ce même intervalle avec une probabilité $\beta h + o(h)$.

Remarque 3.1.7 (Cadre des résultats matriciels). Les calculs matriciels sont présentés sur un espace fini. Ils s'étendent aux chaînes conservatives sur un espace dénombrable dont les taux sont uniformément bornés :

$$\sup_{i \in \mathcal{S}} q_i < \infty.$$

Ce cadre contient les files $M/M/c$ à c fixé, puisque $q_i \leq \lambda + c\mu$. Pour une infinité d'états, le passage d'une limite sous une somme demande toutefois une justification ; des générateurs non bornés nécessitent des précautions supplémentaires.

3.2 Temps de séjour dans un état et chaîne des sauts

La matrice $P(t)$ décrit l'état observé après une durée donnée. Le générateur permet également de décrire directement les sauts successifs : combien de temps attendre, puis vers quel état se déplacer.

Proposition 3.2.1 (Construction par les sauts)**.** *Lorsque la chaîne entre dans un état i avec $q_i > 0$, le temps H_i avant le prochain changement d'état suit*

$$H_i \sim \mathrm{Exp}(q_i), \qquad \mathbb{E}[H_i] = \frac{1}{q_i}.$$

La destination J_i du saut est indépendante de H_i et vérifie

$$\mathbb{P}(J_i = j) = \frac{q_{ij}}{q_i}, \qquad j \neq i.$$

Si $q_i = 0$, l'état est absorbant : la chaîne n'en sort pas.

Preuve. La propriété de Markov s'applique également aux instants de saut : on peut le justifier en approchant ces instants par la droite sur des grilles de plus en plus fines et en utilisant la continuité à droite des trajectoires. Il suffit donc d'étudier la chaîne partant de i à l'instant 0.

Loi du temps de séjour. Posons

$$H_i = \inf\{t > 0 : X_t \neq i\}, \qquad G_i(t) = \mathbb{P}_i(H_i > t).$$

Sur l'événement $\{H_i > s\}$, la chaîne est toujours dans l'état i au temps s. La propriété de Markov et l'homogénéité donnent

$$G_i(s + t) = G_i(s) G_i(t).$$

Comme $G_i(0) = 1$ et G_i est continue à droite en 0, il existe un paramètre $\theta_i \geq 0$ tel que

$$G_i(t) = e^{-\theta_i t}.$$

Si $\theta_i = 0$, la chaîne ne quitte jamais i : l'état est absorbant et $q_i = 0$.

Indépendance de la destination. Supposons $\theta_i > 0$, et posons $r_{ij} = \mathbb{P}_i(J_i = j)$, pour $j \neq i$. Conditionnellement à l'absence de saut avant t, la chaîne repart de i avec les mêmes règles. Ainsi,

$$\mathbb{P}_i(H_i > t,\ J_i = j) = G_i(t)\, r_{ij}.$$

Cette factorisation établit l'indépendance de H_i et J_i.

Identification des paramètres. Le premier saut survient avant h avec une probabilité $1-e^{-\theta_i h} = \theta_i h + o(h)$. Conditionnellement à sa destination, la probabilité d'un second saut dans le temps restant tend vers zéro. En moyennant sur les destinations, la probabilité d'au moins deux sauts avant h est donc $o(h)$.
Par conséquent,

$$p_{ij}(h) = \begin{cases} \theta_i r_{ij} h + o(h), & j \neq i, \\ 1 - \theta_i h + o(h), & j = i. \end{cases}$$

En comparant avec la définition du générateur, on obtient

$$q_i = \theta_i, \qquad q_{ij} = \theta_i r_{ij}.$$

Ainsi, $H_i \sim \mathrm{Exp}(q_i)$ et $r_{ij} = q_{ij}/q_i$, comme annoncé. □

Interprétation par des horloges concurrentes

Pour un nombre fini de destinations possibles, on peut associer à chaque transition $i \to j$ de taux strictement positif une horloge indépendante

$$E_{ij} \sim \mathrm{Exp}(q_{ij}).$$

Le premier déclenchement détermine le prochain saut. Le temps d'attente est donc $H_i = \min_{j \neq i} E_{ij}$, et

$$\mathbb{P}(H_i > t) = \prod_{j \neq i} \mathbb{P}(E_{ij} > t) = \prod_{j \neq i} e^{-q_{ij} t} = e^{-q_i t}.$$

Le minimum de durées exponentielles indépendantes est ainsi exponentiel, avec un taux égal à la somme des taux.

Exemple 3.2.2 (Une arrivée en concurrence avec un service)**.** Dans une file $M/M/1$ non vide, notons U le temps jusqu'à la prochaine arrivée et V le temps restant jusqu'à la fin du service en cours. Par les hypothèses du modèle et l'absence de mémoire de la loi exponentielle,

$$U \sim \mathrm{Exp}(\lambda), \qquad V \sim \mathrm{Exp}(\mu), \qquad U \text{ et } V \text{ sont indépendantes.}$$

Le prochain changement d'état survient après $H = \min(U, V)$. Pour $t \geq 0$,

$$\mathbb{P}(H > t) = \mathbb{P}(U > t)\mathbb{P}(V > t) = e^{-\lambda t} e^{-\mu t},$$

donc $H \sim \mathrm{Exp}(\lambda + \mu)$.
Le prochain saut est une arrivée si $U < V$. En conditionnant sur la durée $U = u$, on obtient

$$\mathbb{P}(U < V) = \int_0^\infty \mathbb{P}(V > u)\, \lambda e^{-\lambda u}\, \mathrm{d}u = \int_0^\infty \lambda e^{-(\lambda+\mu)u}\, \mathrm{d}u = \frac{\lambda}{\lambda + \mu}.$$

De même,

$$\mathbb{P}(V < U) = \int_0^\infty \mu e^{-(\lambda+\mu)v}\, \mathrm{d}v = \frac{\mu}{\lambda + \mu}.$$

Les deux durées étant continues, $\mathbb{P}(U = V) = 0$: ces deux probabilités somment bien à 1. Lorsque la file est vide, seule l'horloge d'arrivée est active : le prochain saut survient après une durée $\mathrm{Exp}(\lambda)$ et conduit nécessairement à l'état 1.

Définition 3.2.3 (Chaîne incluse)**.** On pose $\tau_0 = 0$, puis on note $\tau_1, \tau_2, \ldots$ les instants successifs de changement d'état. La suite

$$Y_n = X_{\tau_n}$$

est la *chaîne incluse*, ou *chaîne des sauts*. Pour $q_i > 0$, sa matrice de transition vérifie

$$\widetilde{p}_{ij} = \begin{cases} q_{ij}/q_i, & j \neq i, \\ 0, & j = i. \end{cases}$$

Si un état absorbant est atteint, il n'y a plus de saut. On peut prolonger la suite en répétant cet état, avec la convention $\widetilde{p}_{ii} = 1$.

Point de vigilance. Le temps avant de *quitter* i est exponentiel. Le temps nécessaire pour *atteindre un état donné* j ne l'est pas en général : plusieurs étapes peuvent être nécessaires. Par exemple, sur le chemin imposé $0 \to 1 \to 2$, avec un taux λ à chaque transition, le temps pour atteindre 2 depuis 0 est la somme de deux durées exponentielles indépendantes : il suit une loi $\mathrm{Gamma}(2, \lambda)$, où λ est le paramètre de taux.

De même, il faut distinguer

$$\mathbb{P}_i(H_i > t) = e^{-q_i t} \qquad \text{et} \qquad p_{ii}(t) = \mathbb{P}_i(X_t = i).$$

La première probabilité décrit l'absence de saut. La seconde inclut aussi les trajectoires qui quittent i puis y reviennent avant t ; elle est donc généralement supérieure à la première.

À retenir

Pour simuler une chaîne à temps continu depuis un état i, on tire une durée exponentielle de taux q_i, puis, indépendamment, une destination $j \neq i$ avec probabilité q_{ij}/q_i. On recommence depuis le nouvel état. Si $q_i = 0$, la chaîne reste définitivement en i.

3.3 Chapman–Kolmogorov et équations différentielles

La propriété de Markov permet de décomposer une évolution en étapes successives. En combinant cette décomposition avec le générateur, on obtient les équations différentielles qui gouvernent les probabilités de transition.

Théorème 3.3.1 (Relation de Chapman–Kolmogorov)**.** *Soit $(X_t)_{t\geq 0}$ une chaîne de Markov homogène, non explosive, sur un espace d'états fini ou dénombrable $\mathcal{S}$. On note*

$$p_{ij}(t) = \mathbb{P}_i(X_t = j), \qquad P(t) = (p_{ij}(t))_{i,j\in\mathcal{S}}.$$

Alors, pour tous $t, h \geq 0$,

$$p_{ij}(t+h) = \sum_{k\in\mathcal{S}} p_{ik}(t)\, p_{kj}(h).$$

En notation matricielle,

$$P(t+h) = P(t)P(h), \qquad P(0) = I.$$

L'évolution sur $[0, t+h]$ se décompose en une évolution sur $[0, t]$, puis sur $[t, t+h]$. On somme sur tous les états intermédiaires possibles au temps t.

Preuve. Fixons les états i, j et les durées $t, h \geq 0$. La formule des probabilités totales, appliquée à l'état intermédiaire X_t, donne

$$\begin{aligned} p_{ij}(t+h) &= \mathbb{P}_i(X_{t+h} = j) \\ &= \sum_{k \in \mathcal{S}} \mathbb{P}_i(X_t = k,\ X_{t+h} = j) \\ &= \sum_{k \in \mathcal{S}} \mathbb{P}_i(X_t = k)\, \mathbb{P}_i(X_{t+h} = j \mid X_t = k). \end{aligned}$$

Par la propriété de Markov, une fois $X_t = k$ connu, la condition initiale $X_0 = i$ n'apporte plus d'information sur le futur. Puis, par homogénéité,

$$\mathbb{P}_i(X_{t+h} = j \mid X_t = k) = \mathbb{P}(X_{t+h} = j \mid X_t = k) = \mathbb{P}(X_h = j \mid X_0 = k) = p_{kj}(h).$$

Ainsi,

$$p_{ij}(t+h) = \sum_{k \in \mathcal{S}} p_{ik}(t) p_{kj}(h) = \big(P(t)P(h)\big)_{ij}.$$

Cette égalité étant vraie pour tous i, j, on obtient $P(t+h) = P(t)P(h)$. Enfin, $p_{ij}(0) = \mathbb{1}_{\{i=j\}}$, donc $P(0) = I$. □

Remarque 3.3.2 (Rôle des hypothèses). Deux propriétés distinctes interviennent dans la preuve.

(i) **La propriété de Markov** permet d'oublier le passé lorsque l'état présent est connu :

$$\mathbb{P}(X_{t+h} = j \mid X_t = k, X_0 = i) = \mathbb{P}(X_{t+h} = j \mid X_t = k).$$

(ii) **L'homogénéité temporelle** permet de remplacer les instants absolus par la durée écoulée :

$$\mathbb{P}(X_{t+h} = j \mid X_t = k) = \mathbb{P}(X_h = j \mid X_0 = k) = p_{kj}(h).$$

Sans homogénéité, la composition reste valable, mais avec des matrices dépendant de deux instants :

$$P(s,u) = P(s,t)P(t,u), \qquad s \leq t \leq u.$$

Du comportement local à l'évolution des probabilités

Le générateur décrit l'évolution pendant une durée très courte :

$$P(h) = I + hQ + o(h).$$

La relation de Chapman–Kolmogorov permet d'insérer ce petit intervalle au début ou à la fin d'une évolution de durée t. On obtient ainsi deux écritures de la même dérivée.

Théorème 3.3.3 (Équations différentielles de Kolmogorov). *Supposons que l'espace d'états soit fini ou, plus généralement, que le générateur soit conservatif et ses taux uniformément bornés :*

$$\sup_{i \in \mathcal{S}} q_i < \infty, \qquad q_i = -q_{ii}.$$

La matrice de transition $P(t)$ est dérivable pour $t > 0$, et dérivable à droite en 0. Elle vérifie

$$\begin{aligned} P'(t) &= P(t)Q \quad \textit{(équation de Kolmogorov avant)}, \\ P'(t) &= QP(t) \quad \textit{(équation de Kolmogorov arrière)}, \\ P(0) &= I. \end{aligned}$$

Coefficient par coefficient,

$$p'_{ij}(t) = \sum_{k \in \mathcal{S}} p_{ik}(t) q_{kj} = \sum_{k \in \mathcal{S}} q_{ik} p_{kj}(t).$$

Preuve. Sur un espace fini, la définition du générateur donne le développement matriciel

$$P(h) \underset{h\to 0^+}{=} I + hQ + o(h).$$

Dans le cadre dénombrable à taux uniformément bornés, ce développement reste valable dans la norme $\|A\| = \sup_i \sum_j |a_{ij}|$, ce qui justifie également les opérations suivantes.

Équation avant. En plaçant le petit intervalle de durée h à la fin de l'évolution, Chapman–Kolmogorov donne

$$\begin{aligned} P(t+h) &= P(t)P(h) \\ &\underset{h\to 0^+}{=} P(t)\big(I + hQ + o(h)\big) \\ &\underset{h\to 0^+}{=} P(t) + hP(t)Q + o(h). \end{aligned}$$

Ainsi,

$$\frac{P(t+h) - P(t)}{h} = P(t)Q + \frac{o(h)}{h} \xrightarrow[h\to 0^+]{} P(t)Q.$$

On obtient d'abord la dérivée à droite.
Pour $t > 0$ et $0 < h < t$, on a également

$$\frac{P(t) - P(t-h)}{h} = P(t-h)\frac{P(h) - I}{h} \xrightarrow[h\to 0^+]{} P(t)Q.$$

Les dérivées à gauche et à droite coïncident :

$$P'(t) = P(t)Q.$$

Équation arrière. On place maintenant le petit intervalle au début de l'évolution. Comme $t + h = h + t$,

$$P(t+h) = P(h)P(t).$$

Par conséquent,

$$\frac{P(t+h) - P(t)}{h} = \frac{P(h) - I}{h} P(t) \xrightarrow[h\to 0^+]{} QP(t).$$

On obtient donc aussi

$$P'(t) = QP(t).$$

Enfin, $P(0) = I$ entraîne $P'(0) = Q$, la dérivée étant prise à droite en 0. □

Remarque 3.3.4 (Sens des termes « avant » et « arrière »). L'équation **avant**

$$p'_{ij}(t) = \sum_{k\in\mathcal{S}} p_{ik}(t)q_{kj}$$

décrit l'effet d'un petit intervalle ajouté *à la fin* : la chaîne évolue d'abord de i vers k pendant t, puis les taux q_{kj} décrivent son évolution immédiate.
L'équation **arrière**

$$p'_{ij}(t) = \sum_{k\in\mathcal{S}} q_{ik}p_{kj}(t)$$

décrit l'effet d'un petit intervalle ajouté *au début* : les taux q_{ik} décrivent l'évolution immédiate depuis i, suivie d'une évolution de durée t.
Les deux équations décrivent une évolution vers le futur. Le terme « arrière » renvoie au rôle de l'état initial ; il ne signifie pas que le temps est parcouru à l'envers.

Remarque 3.3.5 (Pourquoi la dérivée n'est-elle pas simplement Q ?). Le générateur est la dérivée de la matrice de transition au temps initial :

$$P'(0) = Q.$$

À un instant $t > 0$, la chaîne a déjà évolué. Pour calculer la variation de $p_{ij}(t)$, il faut donc pondérer les taux q_{kj} par les probabilités $p_{ik}(t)$ d'occuper les états intermédiaires :

$$p'_{ij}(t) = p_{ij}(t)q_{jj} + \sum_{k \neq j} p_{ik}(t)q_{kj}.$$

Le premier terme représente la perte de probabilité due aux sorties de j, et la somme représente les apports depuis les autres états.
C'est ce bilan qui s'écrit sous la forme du **produit matriciel** $P(t)Q$. En général, $P'(t) \neq Q$ pour $t > 0$.

Propriété 3.3.6 (Expression fermée)**.** *Sur un espace fini, ou dans le cadre à taux uniformément bornés, on a donc établi que $P'(t) = P(t)Q$ et $P'(t) = QP(t)$. La solution est explicitement donnée par*

$$P(t) = e^{tQ}.$$

Pour une loi initiale $p(0)$, écrite en ligne,

$$p(t) = p(0)P(t) = p(0)e^{tQ}, \qquad p'(t) = p(t)Q.$$

Interprétation d'une équation d'état

Pour chaque état j,

$$p'_j(t) = \sum_{i \neq j} p_i(t)q_{ij} - p_j(t)q_j.$$

La dérivée est un bilan :

$$\text{variation de probabilité} = \text{flux entrants} - \text{flux sortants}.$$

Les termes *avant* et *arrière* désignent les deux écritures matricielles de Kolmogorov. Ils ne signifient pas qu'une équation ferait évoluer physiquement le processus vers le passé.

Exemple 3.3.7 (Retour à la machine)**.** Si $u(t) = \mathbb{P}(X_t = 1)$,

$$u'(t) = \beta(1 - u(t)) - \alpha u(t),$$

d'où

$$u(t) = \frac{\beta}{\alpha + \beta} + \left(u(0) - \frac{\beta}{\alpha + \beta}\right) e^{-(\alpha+\beta)t}.$$

3.4 Équilibre global et processus de naissance–mort

Définition 3.4.1 (Distribution stationnaire)**.** Une probabilité π est stationnaire lorsque

$$\pi P(t) = \pi \qquad \text{pour tout } t \geq 0.$$

Dans le cadre considéré, cela équivaut à

$$\pi Q = 0, \qquad \sum_{i \in \mathcal{S}} \pi_i = 1.$$

En dérivant $\pi P(t) = \pi$ en 0, on obtient $\pi Q = 0$. Réciproquement, $\pi Q = 0$ implique $\frac{\mathrm{d}}{\mathrm{d}t}(\pi P(t)) = 0$.

Proposition 3.4.2 (Équilibre détaillé)**.** *Si une probabilité π vérifie*

$$\pi_i q_{ij} = \pi_j q_{ji} \qquad (i \neq j),$$

alors elle est stationnaire.

Preuve. Pour chaque j,

$$(\pi Q)_j = \sum_{i \neq j} \pi_i q_{ij} - \pi_j q_j = \pi_j \sum_{i \neq j} q_{ji} - \pi_j q_j = 0.$$

□

Définition 3.4.3 (Processus de naissance–mort)**.** Sur $\mathbb{N}$, un processus de naissance–mort autorise uniquement

$$n \longrightarrow n+1 \text{ au taux } \lambda_n, \qquad n \longrightarrow n-1 \text{ au taux } \mu_n,$$

avec $\mu_0 = 0$. Son générateur est tridiagonal.

Proposition 3.4.4 (Forme produit)**.** *Supposons les taux entre états voisins strictement positifs et la chaîne non explosive. Posons*

$$w_0 = 1, \qquad w_n = \prod_{k=0}^{n-1} \frac{\lambda_k}{\mu_{k+1}}.$$

Si $Z = \sum_{n \geq 0} w_n < \infty$, alors

$$\pi_n = \frac{w_n}{Z} \tag{3.1}$$

est la probabilité stationnaire. Pour une chaîne finie, la somme est arrêtée au dernier état.

Preuve. La construction donne $\pi_n \lambda_n = \pi_{n+1} \mu_{n+1}$. L'équilibre détaillé assure l'invariance et la normalisation assure que π est une probabilité.
Réciproquement, l'équilibre global en 0 impose $\pi_0 \lambda_0 = \pi_1 \mu_1$. Les équations suivantes propagent cette relation par récurrence. □

Point de vigilance. L'équilibre détaillé n'est pas une propriété automatique de toute chaîne de Markov. Il découle ici de la structure linéaire du processus de naissance–mort et de la condition au bord.

3.5 Temps d'arrêt et observation à long terme

Définition 3.5.1 (Temps d'arrêt en temps continu)**.** Une variable $\tau : \Omega \to [0, \infty]$ est un temps d'arrêt si

$$\{\tau \leq t\} \in \mathcal{F}_t \qquad \text{pour tout } t \geq 0.$$

Un premier instant où la file devient vide est un exemple :

$$\tau = \inf\{t \geq 0 : N_t = 0\}.$$

Théorème 3.5.2 (Propriété forte de Markov). *Pour une chaîne à temps continu non explosive, munie de sa filtration usuelle, et un temps d'arrêt $\tau < \infty$ presque sûrement,*

$$\mathbb{P}(X_{\tau+t} = j \mid \mathcal{F}_\tau) = p_{X_\tau, j}(t).$$

Conditionnellement à X_τ, l'évolution après τ suit donc la dynamique d'une chaîne redémarrant dans cet état.

Cette propriété justifie l'étude par cycles : lorsqu'un système retrouve un état de régénération, son évolution future peut être analysée comme un nouveau cycle.

Théorème 3.5.3 (Convergence et moyennes temporelles). *Pour une chaîne irréductible, non explosive et récurrente positive, de probabilité stationnaire π,*

$$p_{ij}(t) \longrightarrow \pi_j.$$

Pour toute f intégrable sous π,

$$\frac{1}{t}\int_0^t f(X_s)\,\mathrm{d}s \xrightarrow{p.s.} \sum_{i\in\mathcal{S}} \pi_i f(i).$$

Dans ce cadre à temps continu, il n'est pas nécessaire d'ajouter la condition d'apériodicité des chaînes discrètes.

Pourquoi il faut pondérer les états par les durées

Une simulation fournit des états successifs Y_k et des durées H_k. La proportion de temps passée dans l'état i s'estime par

$$\widehat{\pi}_i = \frac{\sum_{k\in\mathcal{S}} H_k \mathbb{1}_{\{Y_k=i\}}}{\sum_{k\in\mathcal{S}} H_k},$$

avec une correction du dernier intervalle si l'observation s'arrête entre deux sauts.

Compter seulement le nombre de visites donnerait la distribution de la chaîne des sauts. Lorsque $0 < \sum_{i\in\mathcal{S}} \pi_i q_i < \infty$, sa loi stationnaire est

$$\widetilde{\pi}_i = \frac{\pi_i q_i}{\sum_{j\in\mathcal{S}} \pi_j q_j}.$$

Les états où les transitions sont rapides sont donc surreprésentés dans un échantillon pris aux sauts.

À retenir

Pour les performances d'une file, l'équilibre pertinent est généralement celui observé dans le temps. Une moyenne non pondérée des états enregistrés à chaque saut peut être biaisée.

Chapitre 4

Processus de comptage et processus de Poisson

4.1 Compter les événements et dater les arrivées

Définition 4.1.1 (Processus de comptage simple)**.** Soit $(A_t)_{t\geq 0}$ un processus stochastique. On le qualifie de **processus de comptage** simple si :

- ▷ $(A_t)_{t\geq 0}$ part de 0 ;
- ▷ prend ses valeurs dans $\mathbb{N}$, ;
- ▷ possède des trajectoires non décroissantes, continues à droite ;
- ▷ des sauts de taille 1.

On suppose un nombre fini de sauts sur tout intervalle borné.

En notant T_n l'instant de la n-ième arrivée,

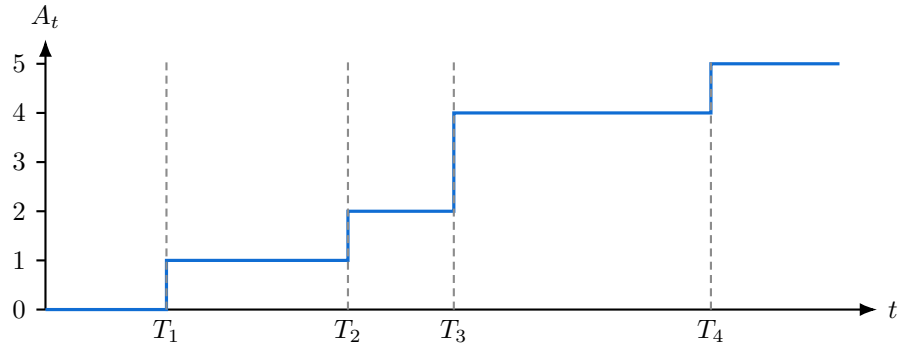
$$T_n = \inf\{t \geq 0 : A_t \geq n\}, \qquad A_t = \sum_{n\geq 1} \mathbb{1}_{\{T_n \leq t\}}.$$

Avec $T_0 = 0$ et $V_n = T_n - T_{n-1}$,

$$T_n = \sum_{k=1}^{n} V_k.$$

Proposition 4.1.2 (Passage entre comptage et instants)**.** *Pour $n \geq 1$ et $0 \leq s < t$,*

- ▷ $\{A_t \geq n\} = \{T_n \leq t\}$,
- ▷ $\{A_t \geq n > A_s\} = \{s < T_n \leq t\}$
- ▷ $\{A_t = n\} = \{T_n \leq t < T_{n+1}\}$ (*valable pour $n = 0$*).



Définition 4.1.3 (Processus de Poisson homogène)**.** Un processus de Poisson homogène de taux $\lambda > 0$ est un processus de comptage simple tel que :

- ▷ les accroissements sur des intervalles disjoints sont indépendants ;
- ▷ pour $s, t \geq 0$,

$$A_{s+t} - A_s \sim \text{Poisson}(\lambda t).$$

La loi d'un accroissement dépend seulement de la longueur de l'intervalle : les accroissements sont stationnaires. Le processus A_t lui-même n'est pas stationnaire, puisque son espérance λt augmente avec t.

4.2 Loi de Poisson, temps exponentiels et équations locales

Théorème 4.2.1 (Caractérisations du processus de Poisson). *Pour un processus de Poisson homogène de taux λ, les durées interarrivées vérifient*

$$V_n \overset{\text{i.i.d.}}{\sim} \text{Exp}(\lambda).$$

Réciproquement, des durées i.i.d. exponentielles engendrent un processus de Poisson homogène. En particulier,

$$A_t \sim \text{Poisson}(\lambda t), \qquad T_n \sim \text{Gamma}(n, \lambda).$$

La première arrivée

L'événement $\{T_1 > t\}$ signifie qu'aucune arrivée n'a eu lieu avant t. Ainsi,

$$\mathbb{P}(T_1 > t) = \mathbb{P}(A_t = 0) = e^{-\lambda t}.$$

La propriété de Markov forte aux instants d'arrivée permet de recommencer le raisonnement et d'obtenir des durées successives indépendantes de même loi.

La description sur un petit intervalle

Trois développements limités caractérisent le processus $(A_t)_t$:

$$\begin{cases} \mathbb{P}(A_h = 0) \underset{h\to 0^-}{=} 1 - \lambda h + o(h), \\ \mathbb{P}(A_h = 1) \underset{h\to 0^-}{=} \lambda h + o(h), \\ \mathbb{P}(A_h \geq 2) \underset{h\to 0^-}{=} O(h^2) = o(h). \end{cases}$$

Il peut y avoir plusieurs arrivées dans un petit intervalle, mais leur probabilité est négligeable au premier ordre.

Proposition 4.2.2 (Équations du comptage). *En posant $p_n(t) = \mathbb{P}(A_t = n)$,*

$$\begin{cases} p_0'(t) = -\lambda p_0(t), \\ p_n'(t) = \lambda p_{n-1}(t) - \lambda p_n(t), \qquad n \geq 1. \end{cases}$$

Avec $A_0 = 0$, leur solution est

$$p_n(t) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}.$$

Preuve. Pour atteindre le niveau n au temps $t + h$, il faut être en n sans arrivée, ou en $n - 1$ avec une arrivée, à une erreur $o(h)$ près :

$$p_n(t + h) = p_n(t)(1 - \lambda h) + p_{n-1}(t)\lambda h + o(h).$$

On soustrait $p_n(t)$, on divise par h, puis on passe à la limite. La forme annoncée vérifie les équations et la condition initiale. □

Exemple 4.2.3 (Taux de 6 arrivées par heure). Sur une demi-heure,

$$\mathbb{P}(A_{1/2} = 0) = e^{-3}, \qquad \mathbb{E}[A_{1/2}] = 3.$$

Le temps moyen avant la quatrième arrivée vaut $\mathbb{E}[T_4] = 4/6$ heure, soit 40 minutes.

4.3 Superposition et amincissement

Proposition 4.3.1 (Superposition). *La somme de processus de Poisson* indépendants *de taux* $\lambda_1, \dots, \lambda_r$ *est un processus de Poisson de taux* $\lambda_1 + \cdots + \lambda_r$.

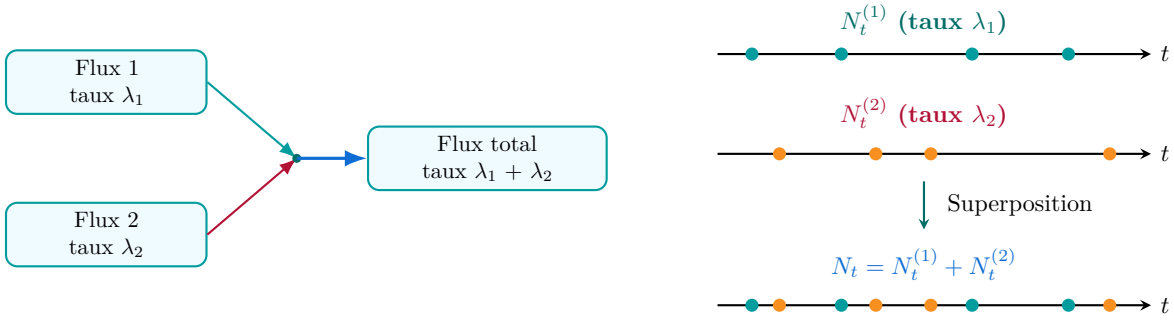
Preuve. Notons $N_t = \sum_{j=1}^{r} N_t^{(j)}$, où les $N^{(j)}$ sont des processus de Poisson indépendants de taux λ_j.
Par définition, pour chaque j et $t \geq 0$, $N_t^{(j)} \sim \text{Poisson}(\lambda_j t)$. Or, si $X \sim \text{Poisson}(\theta)$, sa fonction génératrice des probabilités est

$$G_X(z) = \mathbb{E}[z^X] = \sum_{k=0}^{\infty} z^k e^{-\theta} \frac{\theta^k}{k!} = e^{\theta(z-1)}.$$

L'indépendance des comptages permet alors de factoriser la fonction génératrice de leur somme :

$$G_{N_t}(z) = \mathbb{E}\left[z^{\sum_{j=1}^{r} N_t^{(j)}}\right] = \prod_{j=1}^{r} \mathbb{E}\left[z^{N_t^{(j)}}\right] = \prod_{j=1}^{r} e^{\lambda_j t(z-1)} = e^{(\lambda_1+\cdots+\lambda_r)t(z-1)}.$$

On reconnaît la fonction génératrice d'une loi Poisson$((\lambda_1 + \cdots + \lambda_r)t)$.
Le même raisonnement s'applique aux accroissements $N_{t+h} - N_t$. Leur loi ne dépend que de h, et les accroissements sur des intervalles disjoints restent indépendants, par indépendance des processus initiaux. Ainsi, N est un processus de Poisson de taux $\sum_{j=1}^{r} \lambda_j$. □



Deux processus de Poisson indépendants, de taux λ_1 et λ_2, se superposent pour former un processus de Poisson de taux $\lambda_1 + \lambda_2$. Les couleurs permettent d'identifier l'origine des événements.

Exemple 4.3.2 (Réunir les appels de deux lignes)**.** Deux lignes téléphoniques reçoivent des appels suivant des processus de Poisson indépendants, de taux respectifs 20 et 10 appels par heure. Tous les appels sont dirigés vers un même standard.
En notant $A_t^{(1)}$ et $A_t^{(2)}$ les nombres d'appels reçus sur chaque ligne depuis l'instant 0, le comptage total est

$$A_t = A_t^{(1)} + A_t^{(2)}.$$

C'est un processus de Poisson de taux

$$\lambda = 20 + 10 = 30 \text{ appels par heure.}$$

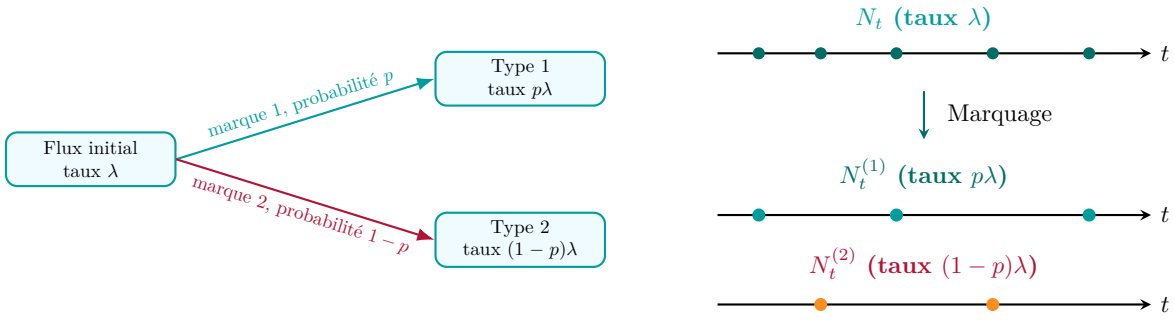
Pour t exprimé en heures, $A_t \sim \text{Poisson}(30t)$. Ainsi, sur une demi-heure, le nombre total d'appels suit une loi de Poisson de paramètre 15.

Proposition 4.3.3 (Amincissement indépendant). *Chaque événement d'un processus de Poisson de taux λ est marqué 1 avec probabilité p, et 2 avec probabilité $1-p$, indépendamment des autres marques et du processus. Les deux comptages obtenus sont des processus de Poisson indépendants de taux $p\lambda$ et $(1-p)\lambda$.*

Preuve. Notons $A_t^{(1)}, A_t^{(2)}$ les deux comptages. Conditionnellement à $A_t = n$, leur fonction génératrice jointe est $(pz + (1-p)w)^n$. Par conséquent,

$$\mathbb{E}\left[z^{A_t^{(1)}} w^{A_t^{(2)}}\right] = \exp\{\lambda t[pz + (1-p)w - 1]\} = \exp\{p\lambda t(z-1)\}\exp\{(1-p)\lambda t(w-1)\}.$$

Cette factorisation donne les deux lois de Poisson et leur indépendance à temps fixé. Le même raisonnement sur des intervalles disjoints établit l'indépendance des processus. □



Chaque événement du processus initial est affecté indépendamment au type 1 avec probabilité p, ou au type 2 avec probabilité $1-p$. L'amincissement produit deux processus de Poisson indépendants, de taux respectifs $p\lambda$ et $(1-p)\lambda$. Les instants d'arrivée sont conservés.

Exemple 4.3.4 (Répartir les appels selon leur motif)**.** Les appels reçus par un standard forment un processus de Poisson de taux 30 par heure. Chaque appel concerne le support technique avec probabilité 0.4, et le service commercial avec probabilité 0.6. On suppose les motifs indépendants entre eux et indépendants des instants d'arrivée.
Les deux services reçoivent alors des flux de Poisson indépendants, de taux respectifs

$$\lambda_{\text{support}} = 0.4 \times 30 = 12, \qquad \lambda_{\text{commercial}} = 0.6 \times 30 = 18 \quad \text{appels par heure.}$$

Sur une demi-heure, les nombres d'appels au support et au service commercial suivent donc des lois de Poisson indépendantes de paramètres 6 et 9.
Conditionnellement au nombre total d'appels, ces deux nombres ne sont toutefois plus indépendants : leur somme est alors fixée.

Point de vigilance. L'admission dans une file à capacité finie dépend de son état. Ce filtrage n'est pas un amincissement indépendant : le flux des clients admis n'est généralement pas un processus de Poisson.

Chapitre 5

Modéliser une file et définir ses performances

5.1 Composantes du système et notation de Kendall

Objectif. Traduire une situation concrète en hypothèses précises sur les arrivées, les services, les ressources et l'attente.

Une file est décrite par un flux d'arrivées, des durées de service, un nombre de serveurs et une règle d'organisation. Une capacité limitée peut provoquer des refus.

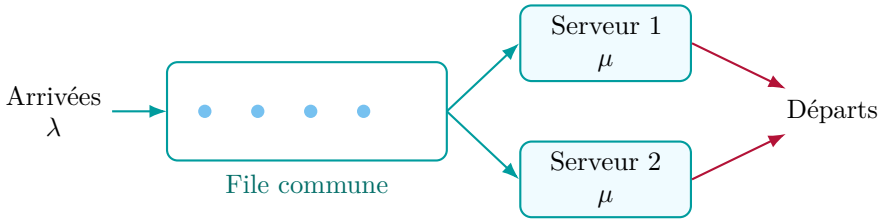
Définition 5.1.1 (Convention de Kendall)**.** Nous utilisons la notation

$$A/B/c/K/M_{\text{pop}}/\mathcal{D},$$

où A décrit les durées interarrivées, B les durées de service, c le nombre de serveurs, K la capacité totale, M_{pop} la population potentielle et $\mathcal{D}$ la discipline. Les derniers paramètres sont souvent omis.

Les conventions d'ordre des paramètres supplémentaires peuvent varier selon les références ; il faut donc les préciser. Dans ce cours, $M/M/c/K$ signifie toujours une capacité totale K, comprenant les clients en service et en attente.

Symbole	Signification
M[1]	Durées exponentielles ; pour les interarrivées i.i.d., flux de Poisson homogène.
D	Durées déterministes.
G	Distribution générale ; les hypothèses d'indépendance doivent être précisées.
FIFO	Service dans l'ordre d'arrivée.
LIFO	Le dernier arrivé est servi en premier.
SIRO	Choix aléatoire du prochain client à servir.



Hypothèses communes aux modèles étudiés

Les services sont indépendants entre clients et indépendants du flux d'arrivées. Le service commence dès qu'un serveur est libre et qu'un client attend : la discipline est *sans inactivité volontaire*. Sauf mention contraire, elle est FIFO, sans abandon et sans interruption de service.

1. La lettre M sert à désigner les processus **m**arkoviens

Exemple 5.1.2 (Lire une notation de Kendall dans des situations concrètes)**.** Sauf précision contraire, la population potentielle et la capacité sont supposées infinies, et la discipline est FIFO. Les lois indiquées sont des *hypothèses de modélisation*.

1. $M/M/1$ **: un guichet.** Les clients arrivent selon un processus de Poisson de taux $\lambda = 12$ par heure. Un seul agent les sert, avec des durées exponentielles de moyenne 3 minutes, soit $\mu = 20$ par heure. La capacité d'attente est supposée illimitée.

2. $M/M/3$ **: un centre d'appels.** Les appels arrivent selon un processus de Poisson de taux $\lambda = 18$ par heure. Trois opérateurs partagent une file commune. Chaque conversation dure en moyenne 7.5 minutes, selon une loi exponentielle : $\mu = 8$ par heure *et par opérateur*. Les trois opérateurs occupés offrent donc un taux total de service $3\mu = 24$ par heure.

3. $M/M/2/6$ **: un petit restaurant.** L'unité comptée est ici un *groupe de clients*. Les groupes arrivent selon un processus de Poisson de taux $\lambda = 3$ par heure. Deux tables accueillent chacune un groupe ; leur durée d'occupation est exponentielle de moyenne 30 minutes, soit $\mu = 2$ par heure et par table. La capacité totale $K = 6$ comprend **deux groupes à table et quatre en attente**. Un groupe arrivant lorsque les six places sont occupées est refusé et repart immédiatement.

4. $D/D/2/5$ **: un atelier automatisé.** Une pièce arrive exactement toutes les 4 minutes. Deux machines travaillent en parallèle, et chaque traitement dure exactement 6 minutes. La capacité $K = 5$ comprend **deux pièces en traitement et trois en attente**. Une pièce présentée lorsque l'atelier est plein est rejetée ou redirigée hors du système étudié.

5. $M/M/1/8/8/\mathrm{SIRO}$ **: maintenance de huit machines.** Chaque machine en fonctionnement tombe en panne après une durée exponentielle de moyenne 100 heures. Un réparateur unique effectue des réparations exponentielles de moyenne 2 heures. Il choisit uniformément la prochaine machine parmi celles en attente (*SIRO*). Ici, $K = M_{\mathrm{pop}} = 8$. Si n machines sont en panne, seules les $8 - n$ autres peuvent tomber en panne : le taux d'arrivée vaut $\lambda_n = (8 - n)/100$ par heure. La population finie rend donc ce taux dépendant de l'état.

Convention de refus. Dans les exemples à capacité limitée, une arrivée trouvant le système plein n'entre pas : elle repart sans rejoindre une file extérieure. La capacité K compte toujours les clients *en service et en attente*. Pour le parc de huit machines, lorsque $n = 8$, aucune nouvelle panne ne peut survenir puisque toutes les machines sont déjà dans le système.

Point de vigilance. La seule notation $M/M/c/K$ ne suffit pas à décrire des priorités, des abandons ou des politiques d'admission particulières. Ces mécanismes doivent être annoncés séparément.

5.2 Comptages, occupation et grandeurs de performance

Notons A_t le nombre d'arrivées proposées, R_t le nombre de refus, $A_t^{\mathrm{adm}} = A_t - R_t$ le nombre d'admissions, et D_t le nombre de départs.

Proposition 5.2.1 (Conservation des clients)**.** *Sans abandon,*

$$N_t = N_0 + A_t^{\mathrm{adm}} - D_t = N_0 + A_t - R_t - D_t.$$

Le processus N_t compte les clients *présents*. Il peut augmenter ou diminuer : ce n'est pas un processus de comptage non décroissant.

Définition 5.2.2 (Occupation et attente)**.** Avec c serveurs et une discipline sans inactivité volontaire,

$$B_t = \min(N_t, c), \qquad N_{q,t} = (N_t - c)_+.$$

Ici B_t est le nombre de serveurs occupés et $N_{q,t}$ le nombre de clients en attente.

En régime stationnaire de loi π, on définit

$$L = \mathbb{E}_\pi[N] = \sum_{n\geq 0} n\pi_n, \qquad L_q = \mathbb{E}_\pi[(N-c)_+].$$

Pour un client admis, son temps de séjour est

$$T = W + S,$$

où W est l'attente avant service et S la durée du service.

Définition 5.2.3 (Débits et utilisation)**.** Le débit admis est noté λ_{eff}. L'utilisation moyenne des serveurs est

$$U = \frac{\mathbb{E}_\pi[\min(N,c)]}{c}.$$

Dans les modèles à services exponentiels de taux μ, le débit stationnaire de départ est

$$\mu\,\mathbb{E}_\pi[\min(N,c)].$$

L'équilibre des entrées et des sorties donne alors

$$\lambda_{\text{eff}} = \mu\,\mathbb{E}_\pi[\min(N,c)], \qquad U = \frac{\lambda_{\text{eff}}}{c\mu}.$$

Remarque 5.2.4 (Charge offerte et occupation effective). On distingue

$$a = \frac{\lambda}{\mu}, \qquad \rho = \frac{\lambda}{c\mu}.$$

Le premier est la charge offerte en unités de service, le second la charge offerte rapportée à la capacité. Avec des refus, ρ peut dépasser 1, tandis que l'utilisation effective U reste dans $[0,1]$.

À retenir

Toujours préciser le périmètre d'un indicateur : arrivées proposées ou admises, clients en attente ou dans tout le système, durée d'attente ou durée de séjour.

5.3 Stabilité et loi de Little

Définition 5.3.1 (Stabilité dans le cadre markovien)**.** Pour une file irréductible décrite par une chaîne de Markov, la stabilité stationnaire correspond à la récurrence positive : il existe une probabilité stationnaire. La finitude des performances moyennes doit ensuite être vérifiée.

Proposition 5.3.2 (Capacité infinie ou finie)**.** *Deux cas sont à distinguer :*

- ▷ *Pour la file $M/M/c$ à capacité infinie,*

$$\text{stabilité} \iff \rho = \frac{\lambda}{c\mu} < 1.$$

- ▷ *Pour $M/M/c/K$, avec $K < \infty$ et $\lambda, \mu > 0$, la chaîne est finie et irréductible : elle possède une probabilité stationnaire pour toute charge offerte.*

Une capacité finie évite une croissance illimitée du nombre de clients en provoquant des refus. Elle ne garantit pas une qualité de service satisfaisante.

Point de vigilance. L'égalité des débits moyens d'entrée et de sortie ne suffit pas à caractériser la récurrence positive. Un système critique peut équilibrer ses débits sans posséder de probabilité stationnaire.

Théorème 5.3.3 (Loi de Little). *Dans un régime stationnaire approprié, avec débit admis* $0 < \lambda_{\text{eff}} < \infty$ *et moyennes finies,*

$$L = \lambda_{\text{eff}}\,\mathbb{E}[T], \qquad L_q = \lambda_{\text{eff}}\,\mathbb{E}[W].$$

Les durées concernent les clients admis et le même périmètre que celui utilisé pour compter les clients.

Interprétation par les aires. L'intégrale $\int_0^t N_s\,\mathrm{d}s$ est l'aire sous la courbe d'occupation. Elle est aussi la somme des durées de présence des clients sur la fenêtre $[0, t]$.
En divisant par t, puis en négligeant les contributions de bord sous les hypothèses de stabilité et d'intégrabilité appropriées, on obtient

$$[\text{Occupation moyenne}] = [\text{Nombre d'admissions par unité de temps} \times \text{séjour moyen}].$$

Le même raisonnement appliqué à l'attente donne la seconde identité. □

Exemple 5.3.4. Un système admet 20 clients par heure. Chaque client y passe en moyenne 6 minutes, soit 0.1 heure. Alors

$$L = 20 \times 0.1 = 2.$$

Si seuls 15 clients par heure sont admis, c'est ce débit de 15, et non le flux proposé, qui doit être utilisé.

5.4 PASTA : ce que voient les arrivées

Une distribution stationnaire décrit l'état observé dans le temps ("suffisamment à long terme"). Un client observe le système à un instant d'arrivée. Ces deux modes d'observation ne sont pas automatiquement équivalents.

Théorème 5.4.1 (Principe PASTA). *Supposons que les arrivées proposées forment un processus de Poisson exogène de taux* λ*, sans anticipation du futur par le système. En régime stationnaire, la distribution de l'état* juste avant une arrivée *est la distribution stationnaire :*

$$\mathbb{P}_{\text{arr}}(N_{T^-} = n) = \pi_n.$$

PASTA signifie Poisson Arrivals See Time Averages.

Qu'est-ce qui rend ce résultat plausible ?

Sur un petit intervalle, une arrivée proposée survient avec probabilité $\lambda h + o(h)$, indépendamment de l'information passée. Les périodes où le système occupe un état particulier ne sont donc pas privilégiées par le mécanisme d'arrivée.

Plus formellement, le nombre d'arrivées voyant l'état n est

$$A_n(t) = \int_{(0,t]} \mathbb{1}_{\{N_{s^-}=n\}}\,\mathrm{d}A_s.$$

Dans les modèles markoviens à taux bornés étudiés ici, on peut raisonner sur un petit intervalle $(t, t+h]$. Conditionnellement à l'information disponible au temps t, une arrivée survient avec

probabilité $\lambda h + o(h)$. Les contributions nécessitant plusieurs événements dans cet intervalle sont d'ordre $O(h^2)$. Ainsi,

$$\mathbb{E}[A_n(t+h) - A_n(t)] = \lambda h\, \mathbb{P}(N_t = n) + o(h).$$

En divisant par h, puis en passant à la limite et en intégrant, avec $A_n(0) = 0$, on obtient

$$\mathbb{E}[A_n(t)] = \lambda \int_0^t \mathbb{P}(N_s = n)\, \mathrm{d}s = \lambda \int_0^t \mathbb{P}(N_{s^-} = n)\, \mathrm{d}s.$$

La dernière égalité utilise le fait qu'un saut à un instant déterministe fixé a une probabilité nulle.

En régime stationnaire, $\mathbb{P}(N_s = n) = \pi_n$, donc

$$\mathbb{E}[A_n(t)] = \lambda t \pi_n.$$

Cette égalité porte sur une *espérance*. Pour conclure sur les fréquences observées le long d'une trajectoire, on utilise en outre une loi forte pour ces comptages, admise ici : sous les hypothèses d'ergodicité du modèle,

$$\frac{A_n(t)}{t} \xrightarrow{\text{p.s.}} \lambda \pi_n, \qquad \frac{A_t}{t} \xrightarrow{\text{p.s.}} \lambda, \qquad \frac{A_n(t)}{A_t} \xrightarrow{\text{p.s.}} \pi_n.$$

La proportion d'arrivées voyant l'état n rejoint donc la proportion de temps passée dans cet état : c'est le principe PASTA.

Proposition 5.4.2 (Refus dans une file à capacité K)**.** *Pour $M/M/c/K$,*

$$p_{\text{bloc}} = \pi_K, \qquad \lambda_{\text{eff}} = \lambda(1 - \pi_K).$$

La fréquence des refus parmi les arrivées proposées tend vers π_K, tandis que leur nombre moyen par unité de temps vaut $\lambda \pi_K$.

Remarque 5.4.3 (Interprétation par les processus de comptage). Notons le nombre d'arrivées admises par $A_t^{\text{adm}} = A_t - R_t$ où R_t désigne le nombre de refus à t. En régime stationnaire, à long terme, on a presque sûrement :

$$\frac{A_t}{t} \xrightarrow{\text{p.s}} \lambda, \qquad \frac{R_t}{t} \xrightarrow{\text{p.s}} \lambda \pi_K.$$

Ainsi, le taux moyen d'admission vérifie

$$\frac{A_t^{\text{adm}}}{t} \longrightarrow \lambda - \lambda \pi_K = \lambda_{\text{eff}}.$$

Autrement dit, λ_{eff} représente le **débit moyen de clients effectivement admis**, et non nécessairement l'intensité d'un processus de Poisson.

Remarque 5.4.4 (Conditionner par l'admission). Une arrivée admise ne voit pas la loi π entière :

$$\mathbb{P}_{\text{arr}}(N_{T^-} = n \mid \text{admission}) = \frac{\pi_n}{1 - \pi_K}, \qquad 0 \le n < K.$$

Cette distinction sera nécessaire pour calculer une probabilité d'attente parmi les clients effectivement admis.

À retenir

Une probabilité de refus est sans dimension. Un débit de refus, $\lambda \pi_K$, s'exprime en clients par unité de temps.

Chapitre 6

Le modèle $M/M/1$

Objectif. Établir complètement le modèle de référence à un serveur, puis comprendre l'effet de la charge sur les délais.

6.1 Construction du modèle et état markovien

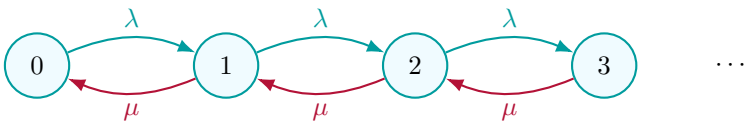
Définition 6.1.1 (File $M/M/1$)**.** Le système possède :

- un flux de Poisson de taux $\lambda > 0$;
- des services i.i.d. de loi $\mathrm{Exp}(\mu)$, indépendants des arrivées ;
- un serveur, une capacité infinie et une discipline FIFO sans inactivité volontaire.

Grâce à la propriété sans mémoire de la loi exponentielle, la durée de service restante d'un client suit toujours une loi $\mathrm{Exp}(\mu)$, indépendamment du temps déjà passé en service. Ainsi, connaître le nombre total de clients N_t suffit à déterminer les probabilités de transition futures : $(N_t)_{t\geq 0}$ est un processus de Markov.

Proposition 6.1.2 (Taux de naissance et de mort)**.** *Le processus N_t est une chaîne de naissance–mort avec*

$$\lambda_n = \lambda \quad (n \geq 0), \qquad \mu_n = \mu \mathbb{1}_{\{n\geq 1\}}.$$



Construction client par client

Pour un système initialement vide, notons T_n les arrivées, S_n les services, B_n les débuts de service et D_n les départs. Alors

$$B_n = \max(T_n, D_{n-1}), \qquad D_n = B_n + S_n, \qquad D_0 = 0.$$

L'attente et le séjour du client n sont

$$W_n = B_n - T_n, \qquad T_n^{\text{séjour}} = D_n - T_n = W_n + S_n.$$

Cette construction conserve l'identité des clients. La description par N_t est plus compacte pour calculer les probabilités d'occupation.

Remarque 6.1.3 (Les départs ne constituent pas une horloge active à vide). Le paramètre μ est le taux de service d'un serveur occupé. Lorsque la file est vide, le taux instantané de départ est nul. Cela ne signifie pas qu'un départ soit impossible sur un intervalle de longueur $h > 0$: une arrivée suivie d'un service très court peut se produire, avec une probabilité d'ordre h^2.

6.2 Équations transitoires : un bilan de flux

Notons $p_n(t) = \mathbb{P}(N_t = n)$. Lorsque $n \geq 1$, les deux horloges actives ont pour taux λ et μ et le processus $(N_t)_t$ vérifie :

$$\begin{cases} \mathbb{P}(N_{t+h} = n+1 \mid N_t = n) \underset{h\to 0^-}{=} \lambda h + o(h), \\ \mathbb{P}(N_{t+h} = n-1 \mid N_t = n) \underset{h\to 0^-}{=} \mu h + o(h), \\ \mathbb{P}(N_{t+h} = n \mid N_t = n) \underset{h\to 0^-}{=} 1 - (\lambda+\mu)h + o(h). \end{cases}$$

Les transitions nécessitant au moins deux événements contribuent seulement à l'ordre $o(h)$.

Proposition 6.2.1 (Équations de Kolmogorov avant). *La distribution de N_t satisfait*

$$\begin{cases} p_0'(t) = \mu p_1(t) - \lambda p_0(t), \\ p_n'(t) = \lambda p_{n-1}(t) + \mu p_{n+1}(t) - (\lambda+\mu)p_n(t), \quad n \geq 1. \end{cases} \tag{6.1}$$

Preuve. Fixons $t \geq 0$ et $h > 0$. Par la formule des probabilités totales et la propriété de Markov,

$$p_n(t+h) = \sum_{k\geq 0} \mathbb{P}(N_{t+h} = n \mid N_t = k)\, p_k(t).$$

Cas $n \geq 1$. Au premier ordre en h, trois situations permettent de se trouver dans l'état n à l'instant $t+h$:

- ▷ **Une arrivée depuis $n-1$:** le système passe de $n-1$ à n, avec une probabilité $\lambda h + o(h)$.
- ▷ **Un départ depuis $n+1$:** le système passe de $n+1$ à n, avec une probabilité $\mu h + o(h)$.
- ▷ **Aucun changement depuis n :** aucune arrivée ni aucun départ ne se produit, avec une probabilité $1 - (\lambda+\mu)h + o(h)$.

Les autres transitions nécessitent au moins deux événements et leur contribution est d'ordre $o(h)$. Ainsi,

$$p_n(t+h) = \lambda h\, p_{n-1}(t) + \mu h\, p_{n+1}(t) + \big[1 - (\lambda+\mu)h\big]p_n(t) + o(h).$$

En soustrayant $p_n(t)$ puis en divisant par h,

$$\frac{p_n(t+h) - p_n(t)}{h} = \lambda p_{n-1}(t) + \mu p_{n+1}(t) - (\lambda+\mu)p_n(t) + \frac{o(h)}{h}.$$

Puisque $o(h)/h \to 0$ lorsque $h \to 0^+$, on obtient

$$p_n'(t) = \lambda p_{n-1}(t) + \mu p_{n+1}(t) - (\lambda+\mu)p_n(t), \quad n \geq 1.$$

Cas $n = 0$. Lorsque le système est vide, aucun départ n'est possible. Seules deux situations contribuent au premier ordre :

- ▷ le système était vide et aucune arrivée ne survient, avec une probabilité $1 - \lambda h + o(h)$;
- ▷ le système contenait un client et celui-ci termine son service, avec une probabilité $\mu h + o(h)$.

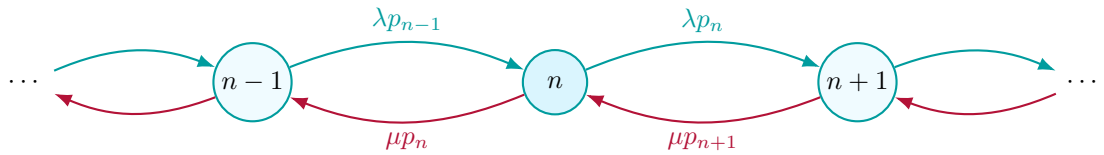
Par conséquent,

$$p_0(t+h) = p_0(t)(1-\lambda h) + \mu h\, p_1(t) + o(h).$$

En soustrayant $p_0(t)$, en divisant par h puis en faisant tendre h vers 0^+, on obtient

$$p_0'(t) = \mu p_1(t) - \lambda p_0(t).$$

Les deux équations constituent les **équations de Kolmogorov avant** du modèle $M/M/1$. □



Une vérification de cohérence

En sommant les équations sur tous les états, les flux internes se compensent. On retrouve

$$\frac{\mathrm{d}}{\mathrm{d}t}\sum_{n\geq 0} p_n(t) = 0,$$

ce qui traduit la conservation de la masse de probabilité.

À retenir

Les équations transitoires décrivent l'évolution depuis une condition initiale. Le régime stationnaire s'obtient ensuite en annulant les dérivées et en imposant une normalisation.

6.3 Distribution stationnaire et performances moyennes

Posons $\rho = \lambda/\mu$. L'équilibre au bord 0 donne $\pi_0\lambda = \pi_1\mu$. Les équations suivantes propagent cette relation.

Théorème 6.3.1 (Équilibre de $M/M/1$)**.** *Une probabilité stationnaire existe si et seulement si $\rho < 1$. Elle est alors donnée par*

$$\pi_n = (1-\rho)\rho^n, \qquad n \geq 0.$$

Preuve. L'équilibre détaillé donne $\pi_{n+1} = \rho\pi_n$, donc $\pi_n = \pi_0\rho^n$. La série $\sum_{n\geq 0}\rho^n$ est finie exactement lorsque $\rho < 1$. La normalisation impose alors $\pi_0 = 1-\rho$. □

Proposition 6.3.2 (Performances moyennes du modèle $M/M/1$)**.** *Supposons $\rho = \lambda/\mu < 1$, de sorte que le système admette une distribution stationnaire.*

- ***Nombre moyen de clients :*** *dans le système (L) et en attente (L_q),*

$$L = \mathbb{E}[N] = \frac{\rho}{1-\rho}, \qquad L_q = \frac{\rho^2}{1-\rho}.$$

- ***Temps moyen par client :*** *temps de séjour total (T) et temps d'attente avant service (W),*

$$\mathbb{E}[T] = \frac{1}{\mu-\lambda}, \qquad \mathbb{E}[W] = \frac{\rho}{\mu-\lambda}.$$

- ***Taux d'occupation du serveur :*** *proportion du temps pendant laquelle le serveur est occupé,*

$$U = \mathbb{P}(N \geq 1) = \rho.$$

Preuve. **1. Nombre moyen de clients.** Puisque N suit la distribution stationnaire $\pi_n = (1-\rho)\rho^n$, on obtient

$$L = \mathbb{E}[N] = \sum_{n\geq 0} n\pi_n = (1-\rho)\sum_{n\geq 1} n\rho^n = (1-\rho)\frac{\rho}{(1-\rho)^2} = \frac{\rho}{1-\rho},$$

où l'on utilise la dérivée de la série géométrique, valable pour $\rho < 1$.

2. Occupation et longueur de la file. Le serveur est occupé si et seulement si $N \geq 1$. Ainsi,

$$U = \mathbb{P}(N \geq 1) = 1 - \pi_0 = 1 - (1 - \rho) = \rho.$$

Comme un seul client peut être en service, le nombre de clients en attente est $N_q = (N-1)_+ = N - \mathbb{1}\{N \geq 1\}$. Par linéarité de l'espérance,

$$L_q = \mathbb{E}[N_q] = L - U = \frac{\rho}{1-\rho} - \rho = \frac{\rho^2}{1-\rho}.$$

3. Temps moyens. La file possède une capacité infinie et aucun client n'est refusé : le débit effectif vaut donc $\lambda_{\text{eff}} = \lambda$.
La loi de Little donne

$$L = \lambda \mathbb{E}[T], \qquad L_q = \lambda \mathbb{E}[W].$$

Par conséquent,

$$\mathbb{E}[T] = \frac{L}{\lambda} = \frac{\rho}{\lambda(1-\rho)} = \frac{1}{\mu - \lambda}.$$

Enfin, le temps de séjour est la somme du temps d'attente et du temps de service : $T = W + S$, avec $\mathbb{E}[S] = 1/\mu$. D'où

$$\mathbb{E}[W] = \mathbb{E}[T] - \mathbb{E}[S] = \frac{1}{\mu - \lambda} - \frac{1}{\mu} = \frac{\rho}{\mu - \lambda}.$$

□

Exemple 6.3.3. Pour $\lambda = 2$ et $\mu = 4$ clients par minute,

$$\rho = \frac{1}{2}, \quad L = 1, \quad L_q = \frac{1}{2},$$

$$\mathbb{E}[T] = 30 \text{ s}, \qquad \mathbb{E}[W] = 15 \text{ s}, \qquad \mathbb{E}[S] = 15 \text{ s}.$$

Point de vigilance. À $\lambda = \mu$, la chaîne est récurrente nulle : elle n'admet pas de probabilité stationnaire. Dire simplement que la file « diverge » serait imprécis, car elle peut encore revenir à zéro. Pour $\lambda > \mu$, la dynamique est transiente.

6.4 Délais, probabilités de dépassement et saturation

Les moyennes résument les performances, mais ne décrivent pas à elles seules le risque de dépasser un délai contractuel.

Proposition 6.4.1 (Loi du séjour et queue de l'attente)**.** *En régime stationnaire FIFO, avec $\lambda < \mu$,*

$$T \sim \text{Exp}(\mu - \lambda), \qquad \mathbb{P}(W = 0) = 1 - \rho, \qquad \mathbb{P}(W > t) = \rho e^{-(\mu-\lambda)t}, \quad t \geq 0.$$

Preuve. Par PASTA, le client arrivant voit n clients avec probabilité $(1-\rho)\rho^n$. Son séjour comprend $n+1$ durées exponentielles de taux μ, en comptant le service résiduel éventuel. Sa transformée est

$$\mathbb{E}[e^{-sT}] = \sum_{n \geq 0} (1-\rho)\rho^n \left(\frac{\mu}{\mu + s}\right)^{n+1} = \frac{\mu - \lambda}{\mu - \lambda + s}.$$

C'est celle d'une exponentielle de taux $\mu - \lambda$.
L'attente est nulle si $n = 0$. Conditionnellement à $n \geq 1$, le même calcul appliqué aux n phases avant le service donne $W \mid \{W > 0\} \sim \text{Exp}(\mu - \lambda)$. □

Dimensionner à partir d'un seuil

Pour un délai maximal acceptable $d > 0$, on souhaite contrôler la probabilité qu'un client attende plus de d unités de temps. Dans une file $M/M/1$ stationnaire, la contrainte $\mathbb{P}(W > d) \leq \varepsilon$ s'écrit

$$\rho e^{-(\mu-\lambda)d} \leq \varepsilon,$$

d'après PASTA. En effet, cette propriété donne $\mathbb{P}(W > 0) = \rho$ et le temps d'attente conditionnellement à $W > 0$ suit une loi $\text{Exp}(\mu - \lambda)$.

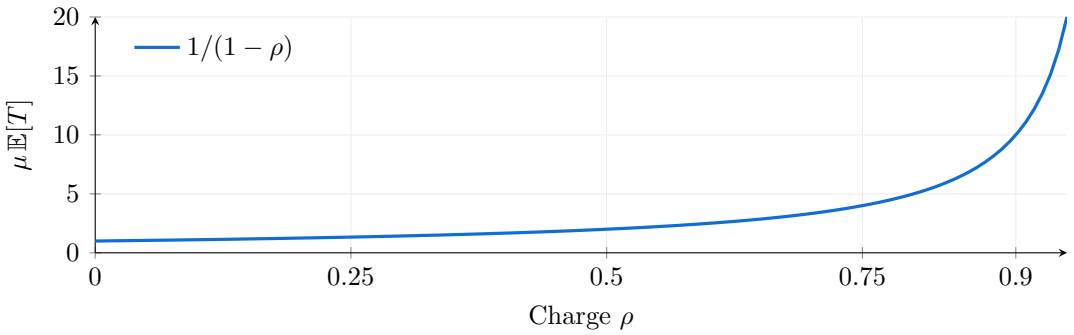
Elle porte sur une **probabilité de dépassement**, et non uniquement sur le temps d'attente moyen.

Attention, les délais explosent à l'approche de la saturation. Rappelons que $\rho = \lambda/\mu$ représente la fraction moyenne du temps pendant laquelle le serveur est occupé. Le temps moyen de séjour vérifie

$$\mathbb{E}[T] = \frac{1}{\mu - \lambda} = \frac{1}{\mu}\frac{1}{1-\rho} \quad \Longleftrightarrow \quad \mu\mathbb{E}[T] = \frac{1}{1-\rho}.$$

Cette dernière quantité mesure le temps de séjour moyen **en unités de durée moyenne de service** $1/\mu$. Elle vaut 1 lorsque $\rho = 0$ (absence de congestion), puis croît de manière non linéaire avec la charge.

La courbe est donc **croissante et convexe** : chaque augmentation supplémentaire de charge entraîne une dégradation des délais plus importante que la précédente.



Par exemple, à $\rho = 0.5$, le séjour moyen représente 2 durées moyennes de service ; à $\rho = 0.9$, il en représente 10. Lorsque $\rho \to 1^-$, la capacité résiduelle $\mu - \lambda$ tend vers zéro et $\mathbb{E}[T] \to +\infty$.

Conséquence pour le dimensionnement. Il ne suffit donc pas d'assurer la stabilité $\lambda < \mu$: un système peut être stable tout en présentant des délais très élevés. La contrainte $\mathbb{P}(W > d) \leq \varepsilon$ permet de fixer un objectif de qualité de service plus exigeant, en limitant explicitement le risque d'attente excessive.

À retenir

Les délais augmentent de façon non linéaire lorsque la charge approche 1. Une utilisation très élevée peut s'accompagner d'une forte dégradation de la qualité de service.

Plusieurs serveurs et capacité finie

7.1 Le modèle $M/M/c$

Objectif. Comprendre l'effet de plusieurs serveurs, puis celui d'une limitation du nombre total de clients.

La file $M/M/c$ possède une file commune, c serveurs identiques, des arrivées de Poisson de taux λ, des services exponentiels de taux μ par serveur et une capacité infinie.

Proposition 7.1.1 (Taux et stabilité). *Le processus d'occupation est un naissance–mort de taux*

$$\lambda_n = \lambda, \qquad \mu_n = \min(n, c)\mu.$$

En posant

$$a = \frac{\lambda}{\mu}, \qquad \rho = \frac{\lambda}{c\mu} = \frac{a}{c},$$

le système est stable si et seulement si $\rho < 1$.

Si $n < c$, seuls n serveurs sont occupés. Si $n \geq c$, tous les serveurs travaillent et le taux total de départ atteint $c\mu$.

Théorème 7.1.2 (Distribution stationnaire). *Pour $\rho < 1$,*

$$\pi_n = \begin{cases} \pi_0 \dfrac{a^n}{n!}, & 0 \leq n < c, \\ \pi_0 \dfrac{a^c}{c!}\rho^{n-c}, & n \geq c, \end{cases}$$

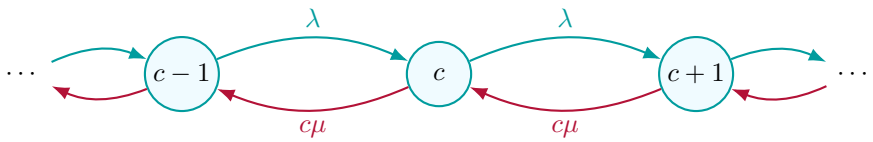
avec

$$\pi_0 = \left[\sum_{n=0}^{c-1} \frac{a^n}{n!} + \frac{a^c}{c!}\frac{1}{1-\rho} \right]^{-1}.$$

Preuve. L'équilibre détaillé impose

$$\pi_{n+1} = \frac{\lambda}{\min(n+1, c)\mu}\pi_n.$$

Avant c, les dénominateurs produisent une factorielle. Après c, le rapport est constant et égal à ρ. La normalisation utilise donc une somme finie et une série géométrique. □



Remarque 7.1.3. Le taux $c\mu$ décrit le prochain départ parmi c services simultanés. Il ne signifie pas que chaque client reçoit un service de durée moyenne $1/(c\mu)$.

7.2 Erlang C et performances avec attente

Définition 7.2.1 (Probabilité d'attente : Erlang C)**.** En régime stationnaire, une arrivée attend si elle trouve au moins c clients. Par PASTA,

$$C(c,a) = \mathbb{P}_{\text{arr}}(W > 0) = \sum_{n=c}^{\infty} \pi_n = \pi_0 \frac{a^c}{c!} \frac{1}{1-\rho}.$$

Proposition 7.2.2 (Moyennes dans $M/M/c$)**.** *Pour $\rho < 1$,*

$$L_q = C(c,a)\frac{\rho}{1-\rho}, \qquad L = L_q + a,$$

$$\mathbb{E}[W] = \frac{C(c,a)}{c\mu - \lambda}, \qquad \mathbb{E}[T] = \mathbb{E}[W] + \frac{1}{\mu}, \qquad U = \rho.$$

Preuve. Pour $n = c + k$, le nombre de clients en attente est k. En notant $b = \pi_0 a^c / c!$,

$$L_q = b \sum_{k \geq 0} k\rho^k = b\frac{\rho}{(1-\rho)^2} = C(c,a)\frac{\rho}{1-\rho}.$$

Le débit servi est λ, donc le nombre moyen de serveurs occupés vaut $\lambda/\mu = a$. Les formules temporelles suivent de Little. □

Proposition 7.2.3 (Dépassement d'un délai)**.** *Sous FIFO,*

$$\mathbb{P}(W > t) = C(c,a)e^{-(c\mu-\lambda)t}, \qquad t \geq 0.$$

Conditionnellement à l'attente, le nombre de phases de départ à franchir est géométrique sur $\{1, 2, \ldots\}$. Chaque phase a pour taux $c\mu$, puisque les serveurs restent tous occupés jusqu'au début du service du client considéré. Le mélange donne une exponentielle de taux $c\mu - \lambda$.

Exemple 7.2.4 (Deux serveurs)**.** Pour $\lambda = 8$ clients par heure, $\mu = 5$ par heure et $c = 2$,

$$a = 1.6, \quad \rho = 0.8, \quad \pi_0 = \frac{1}{9}, \quad C(2, 1.6) = \frac{32}{45}.$$

On obtient

$$L_q = \frac{128}{45} \simeq 2.844, \qquad L = \frac{40}{9} \simeq 4.444,$$

$$\mathbb{E}[W] = \frac{16}{45}\,\text{h} \simeq 21.33\,\text{min}, \qquad \mathbb{E}[T] = \frac{5}{9}\,\text{h} \simeq 33.33\,\text{min}.$$

À retenir

Erlang C est une probabilité d'attente dans une file stable à capacité infinie. Elle ne représente pas une probabilité de refus.

7.3 Le modèle $M/M/c/K$

Supposons désormais une capacité totale finie $K \geq c$. Une arrivée trouvant K clients est refusée. Il y a au maximum $K - c$ clients en attente.

Proposition 7.3.1 (Générateur et existence de l'équilibre). *L'espace d'états est* $\{0, \dots, K\}$, *avec*

$$\lambda_n = \lambda \mathbb{1}_{\{n<K\}}, \qquad \mu_n = \min(n, c)\mu.$$

Pour $\lambda, \mu > 0$, *la chaîne est finie et irréductible : elle admet une unique probabilité stationnaire, sans condition* $\rho < 1$.

Le taux de naissance est nul en K, car une arrivée refusée ne modifie pas N_t. Le flux extérieur d'arrivées proposées continue pourtant à exister au taux λ.

Théorème 7.3.2 (Distribution stationnaire à capacité finie). *Avec* $a = \lambda/\mu$, $\rho = a/c$,

$$\pi_n = \begin{cases} \pi_0 \dfrac{a^n}{n!}, & 0 \leq n < c, \\ \pi_0 \dfrac{a^c}{c!} \rho^{n-c}, & c \leq n \leq K. \end{cases}$$

La constante de normalisation vaut

$$\pi_0^{-1} = \sum_{n=0}^{c-1} \frac{a^n}{n!} + \frac{a^c}{c!} \begin{cases} \dfrac{1 - \rho^{K-c+1}}{1-\rho}, & \rho \neq 1, \\ K - c + 1, & \rho = 1. \end{cases}$$

Preuve. On applique la forme produit (3.1). La partie au-delà de c est maintenant une somme géométrique *finie*, donc elle se normalise même si $\rho \geq 1$. Pour $\rho = 1$, chacun de ses $K - c + 1$ termes vaut 1. □

Équation au bord supérieur

La dernière équation de Kolmogorov est

$$p'_K(t) = \lambda p_{K-1}(t) - c\mu p_K(t).$$

Il n'y a pas de terme $-\lambda p_K(t)$: les arrivées refusées ne retirent aucune probabilité à l'état K.

Point de vigilance. La formule d'Erlang B correspond au cas particulier $K = c$, sans place d'attente. Pour $K > c$, on parle ici de file $M/M/c/K$, afin d'éviter de confondre les deux situations.

7.4 Pertes, admission et délais à capacité finie

Proposition 7.4.1 (Indicateurs stationnaires). *Pour* $M/M/c/K$,

$$p_{\text{bloc}} = \pi_K, \qquad \lambda_{\text{eff}} = \lambda(1 - \pi_K),$$

$$L = \sum_{n=0}^{K} n\pi_n, \qquad L_q = \sum_{n=0}^{K} (n-c)_+ \pi_n,$$

$$\mathbb{E}[T] = \frac{L}{\lambda_{\text{eff}}}, \qquad \mathbb{E}[W] = \frac{L_q}{\lambda_{\text{eff}}}, \qquad U = \frac{\lambda_{\text{eff}}}{c\mu}.$$

Les temps moyens portent sur les clients admis.

Deux contrôles de cohérence

L'équilibre des flux de service donne

$$\lambda_{\text{eff}} = \mu \sum_{n=0}^{K} \min(n, c)\pi_n.$$

Comme $n = (n-c)_+ + \min(n, c)$,

$$L = L_q + \frac{\lambda_{\text{eff}}}{\mu}, \qquad \mathbb{E}[T] = \mathbb{E}[W] + \frac{1}{\mu}.$$

Ces identités permettent de vérifier une implémentation.

Proposition 7.4.2 (Attente parmi les clients admis). *La probabilité d'attendre conditionnellement à l'admission est*

$$\mathbb{P}(W > 0 \mid \textit{admission}) = \frac{\sum_{n=c}^{K-1} \pi_n}{1 - \pi_K}.$$

Une arrivée voyant K clients est refusée : elle ne doit pas être comptée parmi les clients admis qui attendent.

Si une arrivée admise voit $n \geq c$ clients, elle doit attendre $n - c + 1$ fins de service avant de commencer son propre service. Sous FIFO,

$$W \mid \{N_{T^-} = n, \text{admission}\} \sim \text{Gamma}(n - c + 1, c\mu).$$

On peut donc calculer une probabilité de dépassement par mélange :

$$\mathbb{P}(W > t \mid \text{admission}) = \frac{1}{1 - \pi_K} \sum_{n=c}^{K-1} \pi_n e^{-c\mu t} \sum_{j=0}^{n-c} \frac{(c\mu t)^j}{j!}.$$

Remarque 7.4.3 (Limite de forte demande). À c, K, μ fixés, lorsque $\lambda \to \infty$,

$$\pi_K \to 1, \qquad \lambda_{\text{eff}} \to c\mu, \qquad U \to 1.$$

Le débit servi ne tend pas vers zéro : les serveurs restent presque toujours occupés. La fraction admise tend vers zéro parce que le flux proposé augmente sans borne.

7.5 Deux cas particuliers : capacité limitée et pertes pures

Proposition 7.5.1 (File $M/M/1/K$). *Avec $\rho = \lambda/\mu$,*

$$\pi_n = \begin{cases} \dfrac{1-\rho}{1-\rho^{K+1}}\rho^n, & \rho \neq 1, \\ \dfrac{1}{K+1}, & \rho = 1, \end{cases} \qquad 0 \leq n \leq K.$$

Le nombre moyen de clients vaut

$$L = \begin{cases} \dfrac{\rho[1 - (K+1)\rho^K + K\rho^{K+1}]}{(1-\rho)(1-\rho^{K+1})}, & \rho \neq 1, \\ K/2, & \rho = 1. \end{cases}$$

La démonstration de la somme pondérée utilisée ici est donnée en annexe. Le cas $\rho = 1$ doit être traité séparément dans une formule fermée pour éviter une division $0/0$.

Proposition 7.5.2 (File $M/M/c/c$ et Erlang B)**.** *Lorsque $K = c$, aucune attente n'est possible :*

$$\pi_n = \frac{a^n/n!}{\sum_{k=0}^{c} a^k/k!}, \qquad 0 \le n \le c.$$

La probabilité de refus est la formule d'Erlang B :

$$B(c,a) = \frac{a^c/c!}{\sum_{k=0}^{c} a^k/k!}.$$

Pour les clients admis,

$$\mathbb{E}[W] = 0, \qquad \mathbb{E}[T] = \frac{1}{\mu}.$$

Exemple 7.5.3 (Deux serveurs, aucune place d'attente)**.** Pour $a = 2$ et $c = 2$,

$$B(2,2) = \frac{2^2/2!}{1 + 2 + 2^2/2!} = \frac{2}{5}.$$

Quarante pour cent des arrivées sont refusées, mais les clients admis commencent immédiatement leur service.

Modèle	Attente	Refus	Condition stationnaire
$M/M/1$	Oui	Non	$\lambda < \mu$
$M/M/c$	Oui	Non	$\lambda < c\mu$
$M/M/c/K$	Si $K > c$	Oui	Toujours si $\lambda, \mu > 0$
$M/M/c/c$	Non	Oui	Toujours si $\lambda, \mu > 0$

À retenir

Augmenter la capacité d'attente réduit généralement les refus, mais ne crée pas de capacité de service. Ajouter des serveurs modifie directement le débit potentiel.

Exercices de synthèse

8.1 Construire un générateur : le club sportif

Exercice 8.1 (Deux terrains de tennis)**.** Les joueurs arrivent selon un processus de Poisson de taux λ. Le club possède deux terrains. Dès que deux joueurs sont disponibles et qu'un terrain est libre, une partie commence. Les parties ont des durées indépendantes de loi $\mathrm{Exp}(\mu)$.
À la fin d'une partie, le perdant quitte le club. Le gagnant part avec probabilité p, indépendamment du reste, et rejoint sinon les joueurs disponibles.
Définir un état markovien et donner les transitions ainsi que le générateur.

Corrigé. Notons N_t le nombre total de joueurs présents. Avec un démarrage immédiat des parties, le nombre de matchs en cours lorsque $N_t = n$ est

$$m(n) = \min\left(2, \left\lfloor \frac{n}{2} \right\rfloor\right).$$

Les durées exponentielles permettent d'ignorer les âges des parties en cours.

Les seuls coefficients hors diagonale non nuls sont

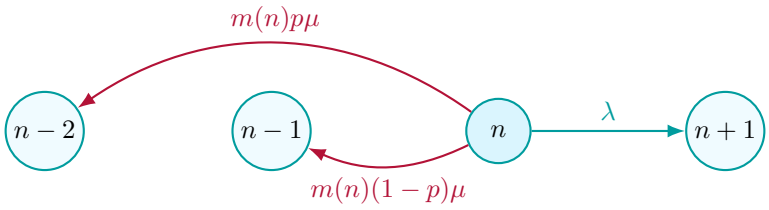
$$q_{n,n+1} = \lambda,$$

$$q_{n,n-1} = m(n)(1-p)\mu, \qquad n \geq 2,$$

$$q_{n,n-2} = m(n)p\mu, \qquad n \geq 2.$$

Enfin,

$$q_{nn} = -(\lambda + m(n)\mu).$$



Lecture des frontières

Pour $n = 0, 1$, aucun match n'est possible : seule une arrivée peut modifier l'état. Pour $n = 2, 3$, un match est actif. À partir de $n = 4$, deux matchs sont actifs.

Point de vigilance. Ce modèle est markovien, mais ce n'est pas un processus de naissance–mort : une fin de partie peut produire un saut de -2. La récurrence stationnaire des files $M/M/c$ ne s'applique donc pas directement.

Indication de stabilité

Pour $n \geq 4$, la dérive du nombre de joueurs vaut

$$\lambda - 2\mu(1+p).$$

Une dérive strictement négative à grande occupation suggère la condition $\lambda < 2\mu(1+p)$. Un critère de Foster–Lyapunov permet de formaliser la suffisance de cette condition sur la classe récurrente pertinente.

8.2 Exercice de synthèse : une file $M/M/2/3$

8.2.1 Énoncé

Exercice 8.2 (File d'attente $M/M/2/3$ — Exercice de synthèse)**.** On considère une file d'attente de type $M/M/2/3$, modélisée comme un processus de naissance et mort $(N_t)_{t\geq 0}$ représentant le nombre total de clients dans le système (en service ou en attente) à l'instant t.
Les arrivées proposées forment un processus de Poisson de taux $\lambda > 0$. Les durées de service sont indépendantes, de loi $\mathrm{Exp}(\mu)$ avec $\mu > 0$, et indépendantes du processus d'arrivées. On suppose une discipline FIFO, sans abandon ni interruption de service. Un client en attente entre en service dès qu'un serveur se libère. Une arrivée trouvant le système plein est refusée.

(1) Signification du modèle. Expliquer le sens de la notation $M/M/2/3$. Que signifient les lettres et les chiffres ? Quelle est la politique (ou discipline) de service retenue ici ? Est-elle précisée par les quatre symboles de cette notation ?

(2) Processus de comptage et dynamique. On note le taux d'arrivées proposées λ et le taux de service *par serveur occupé* μ. On rappelle la représentation du comptage des arrivées :

$$A_t = \sum_{n\geq 0} \mathbb{1}_{\{S_n \leq t\}},$$

où $(S_n)_{n\geq 0}$ désignent les instants d'arrivée successifs, numérotés à partir de 0 : $S_0 > 0$ est le premier instant d'arrivée. Ce comptage doit être distingué du nombre de clients présents N_t. Dans le modèle $M/M/2/3$:

(i) Quelle loi suivent les interarrivées I_n ? Quel est leur lien avec (S_n) ?

(ii) Quelle loi suivent les durées de service B_n ? Pourquoi N_t suffit-il à décrire un état markovien ?

(iii) Définir les comptages de refus R_t et de départs D_t, puis écrire la conservation des clients. Donner les approximations au premier ordre, avec un reste $o(h)$, des probabilités de transition de (N_t) lorsque $h \downarrow 0$, y compris aux frontières.

(3) Espace des états. Déterminer l'espace d'états $\mathcal{S}$ de $(N_t)_{t\geq 0}$ et interpréter chaque état.

(4) Équations de Kolmogorov avant. En notant $p_n(t) = \mathbb{P}(N_t = n)$, établir les équations de Kolmogorov avant :

$$p_n'(t) = \lambda_{n-1} p_{n-1}(t) + \mu_{n+1} p_{n+1}(t) - (\lambda_n + \mu_n) p_n(t),$$

avec les conditions aux bords appropriées et en omettant les termes correspondant à des états inexistants.

(5) Relation entre les lois temporelles et la matrice de transition. On note

$$p(t) = (p_0(t), p_1(t), p_2(t), p_3(t))$$

le vecteur ligne décrivant la loi de N_t à l'instant t, et $p(0)$ la loi initiale. On note également $P(t)$ la *matrice de transition* du processus, telle que

$$P(t) = (p_{ij}(t))_{0\leq i,j\leq 3}, \qquad p_{ij}(t) = \mathbb{P}(N_t = j \mid N_0 = i).$$

(i) Exprimer la relation entre $p(t)$, $p(0)$ et $P(t)$.

(ii) Rappeler les équations différentielles reliant $P(t)$ à la matrice infinitésimale Q.

(iii) Donner l'expression de $p(t)$ en fonction de Q.

(iv) Justifier que la matrice infinitésimale Q est la dérivée à droite en $t = 0$ de la matrice des transitions $P(t)$ et interpréter cette relation.

(6) Matrice infinitésimale. Écrire la matrice infinitésimale Q explicitement, puis interpréter :

- le signe de ses coefficients diagonaux ;
- la signification physique des coefficients hors diagonale ;
- pourquoi chaque ligne de Q somme à 0.

(7) Loi stationnaire et stabilité. Définir la loi stationnaire π du processus (N_t). Énoncer les équations qu'elle satisfait. Discuter la notion de **stabilité** : que signifie $\rho = \lambda/(c\mu) < 1$ dans le cas $M/M/c$ à capacité infinie (ρ désigne le facteur de charge) ? Cette condition est-elle nécessaire ici, avec une capacité finie $K = 3$?

(8) Résolution de la loi stationnaire. Déterminer $\pi = (\pi_0, \pi_1, \pi_2, \pi_3)$ explicitement, en justifiant les récurrences

$$\pi_n \mu_n = \pi_{n-1} \lambda_{n-1}, \qquad n \in \{1, 2, 3\}.$$

Donner la valeur normalisée de π_0, puis exprimer toutes les autres composantes.

(9) Refus et métriques de performance. Calculer :

- la **probabilité de refus** P_{refus}, et la distinguer du nombre moyen de refus par unité de temps ;
- le **taux effectif d'entrée** λ_{eff} ;
- l'**utilisation moyenne des serveurs** $U = \lambda_{\text{eff}}/(2\mu)$.

Interpréter ces résultats : que se passe-t-il si $\lambda \gg \mu$? Étudier les limites lorsque $\lambda \to \infty$, à μ fixé.

(10) Loi de Little et temps moyens. Rappeler la *loi de Little*, en notant $\mathbb{E}[N]$ le nombre moyen de clients dans le système stationnaire. En déduire le temps moyen de séjour $\mathbb{E}[T]$ dans le système $M/M/2/3$, puis préciser les valeurs de $L = \mathbb{E}[N]$, L_q et $\mathbb{E}[W]$, où W désigne le temps d'attente avant service. Les temps T et W concernent les *clients admis*. Donner la relation entre ces quantités et expliquer leur signification pratique. Effectuer les calculs pour $\lambda = 2$ et $\mu = 1$, exprimés dans une unité de temps commune.

(11) Interprétation globale. Discuter l'intérêt du modèle $M/M/2/3$ dans un contexte réel (centre d'appel, guichet, service hospitalier). Quelles grandeurs peuvent être ajustées pour optimiser les performances ?

8.2.2 Solution

(1) Signification du modèle

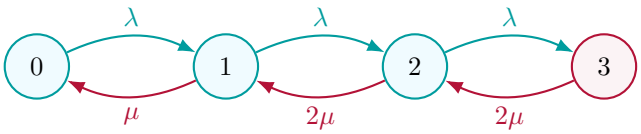
Le modèle $M/M/2/3$ se lit selon la **notation de Kendall** :

$$A/B/C/K,$$

où :

- $A = M$ signifie que les arrivées suivent un **processus de Poisson** de taux λ, c'est-à-dire que les temps interarrivées sont **i.i.d. exponentiels de moyenne** $1/\lambda$;
- $B = M$ indique que les temps de service sont également **i.i.d. exponentiels**, de paramètre μ ;
- $C = 2$ correspond au nombre de **serveurs en parallèle** ;
- $K = 3$ est la **capacité totale du système**, incluant les clients en service et en attente.

Ainsi, le système peut contenir au maximum trois clients : deux en service et un en attente. La **discipline de service** retenue est **FIFO** (*First In, First Out*), c'est-à-dire que les clients entrent en service dans l'ordre d'arrivée. Cette discipline est une hypothèse de l'énoncé ; elle n'est pas précisée par les quatre symboles $M/M/2/3$.



Système vide | Un client en service | Deux clients en service | Deux en service, un en attente

(2) Processus de comptage et dynamique

On rappelle qu'un processus de comptage des arrivées $(A_t)_{t\geq 0}$ peut se représenter comme

$$A_t = \sum_{n\geq 0} \mathbb{1}_{\{S_n \leq t\}},$$

où $(S_n)_{n\geq 0}$ sont les instants d'arrivée successifs. Avec l'indexation retenue, S_0 est le premier instant d'arrivée, et non l'origine des temps. En posant $S_{-1} = 0$, on définit

$$I_n = S_n - S_{n-1}, \qquad S_n = \sum_{k=0}^{n} I_k, \qquad n \geq 0.$$

Ce lien exprime que les instants d'arrivée sont les cumuls des temps interarrivées.

Point de vigilance. Le processus A_t compte les arrivées proposées depuis l'instant 0 et ne peut qu'augmenter. Le processus N_t décrit le nombre de clients *présents* : il augmente lors d'une admission et diminue lors d'un départ. Il ne s'agit donc pas du même processus.

(i) **Interarrivées.** Dans un système $M/M/2/3$, les arrivées proposées suivent un *processus de Poisson homogène* de taux λ. Les interarrivées $I_n = S_n - S_{n-1}$ sont alors des variables aléatoires **exponentielles de paramètre** λ, i.i.d. On a donc

$$I_n \sim \text{Exp}(\lambda), \qquad S_n = \sum_{k=0}^{n} I_k \sim \text{Gamma}(n+1, \lambda),$$

où le second paramètre de la loi Gamma est un *taux*. L'indice $n+1$ vient du fait que les arrivées sont numérotées à partir de 0.

(ii) **Durées de service.** Les durées de service (B_n) sont supposées **i.i.d. exponentielles de paramètre** μ, où μ représente le taux de fin de service d'un serveur occupé. Chaque serveur fournit des durées $B_n \sim \text{Exp}(\mu)$. Dans un modèle $M/M/2/3$, jusqu'à deux services peuvent être exécutés simultanément.
La propriété d'absence de mémoire implique que les durées résiduelles des services en cours sont encore exponentielles de taux μ. Il n'est donc pas nécessaire de mémoriser les temps déjà passés en service : le nombre N_t de clients présents suffit à décrire l'état markovien. Lorsque deux serveurs sont occupés, le prochain départ survient au taux 2μ.

(iii) **Conservation et approximation infinitésimale des transitions.** On note R_t le nombre d'arrivées refusées et D_t le nombre de clients ayant terminé leur service sur $(0, t]$. Le nombre d'arrivées admises est $A_t - R_t$; la conservation des clients s'écrit

$$N_t = N_0 + A_t - R_t - D_t.$$

Pour un petit intervalle $(t, t+h]$, avec $h \downarrow 0$, les probabilités élémentaires, *conditionnellement à* $N_t = n$, s'écrivent au premier ordre :

$$\begin{aligned}
\mathbb{P}(N_{t+h} = n+1 \mid N_t = n) &= \lambda_n h + o(h), & n &\in \{0,1,2\},\\
\mathbb{P}(N_{t+h} = n-1 \mid N_t = n) &= \mu_n h + o(h), & n &\in \{1,2,3\},\\
\mathbb{P}(N_{t+h} = n \mid N_t = n) &= 1 - (\lambda_n + \mu_n)h + o(h), & n &\in \{0,1,2,3\},
\end{aligned}$$

avec

$$(\lambda_0, \lambda_1, \lambda_2, \lambda_3) = (\lambda, \lambda, \lambda, 0), \qquad (\mu_0, \mu_1, \mu_2, \mu_3) = (0, \mu, 2\mu, 2\mu).$$

Les transitions vers -1 ou 4 sont impossibles. Pour deux états n, m tels que $|m - n| \geq 2$, la probabilité de transition est $o(h)$: elle nécessite plusieurs événements. La probabilité d'au moins deux événements sur $(t, t + h]$ est ici $O(h^2)$, donc $o(h)$, puisque les taux sont bornés. Ces relations traduisent la *dynamique de naissance et mort* caractéristique du processus $M/M/2/3$, où les arrivées admises se produisent au taux λ lorsque le système n'est pas plein, et les départs au taux μ par serveur actif.

Point de vigilance. Rester dans le même état ne signifie pas nécessairement qu'aucun événement ne s'est produit. Dans l'état 3, une arrivée refusée laisse N_t inchangé. Ainsi, $\mathbb{P}(N_{t+h} = 3 \mid N_t = 3) = 1 - 2\mu h + o(h)$, même si les arrivées proposées continuent au taux λ.

(3) Espace des états

L'espace des états du processus (N_t) est

$$\mathcal{S} = \{0, 1, 2, 3\}.$$

- $N_t = 0$: aucun client dans le système ;
- $N_t = 1$: un client en service, un serveur occupé ;
- $N_t = 2$: deux clients en service, les deux serveurs occupés ;
- $N_t = 3$: système plein, un client en attente et deux en service.

(4) Équations de Kolmogorov avant

Notons $p_n(t) = \mathbb{P}(N_t = n)$ la probabilité que le système contienne n clients à l'instant t.

Idée générale. On établit les équations d'évolution en effectuant un *bilan probabiliste* sur un petit intervalle $(t, t + h]$, avec $h \downarrow 0$. Durant cet intervalle court, conditionnellement à l'état n au temps t :

- une **arrivée admise** survient avec probabilité $\lambda_n h + o(h)$;
- un **départ** (fin de service) survient avec probabilité $\mu_n h + o(h)$;
- l'état reste inchangé à l'instant $t + h$ avec probabilité $1 - (\lambda_n + \mu_n)h + o(h)$.

Ici, les taux dépendent de l'état :

$$\lambda_n = \begin{cases} \lambda, & n < 3, \\ 0, & n = 3, \end{cases} \qquad \mu_n = \min(n, 2)\mu, \qquad n \in \mathcal{S}.$$

On regroupe les contributions nécessitant plusieurs événements dans un reste $o(h)$. En appliquant la **formule des probabilités totales**, pour $n = 1, 2$, on obtient

$$\begin{aligned} p_n(t + h) = {} & p_{n-1}(t)\lambda_{n-1}h + p_{n+1}(t)\mu_{n+1}h \\ & + p_n(t)\big[1 - (\lambda_n + \mu_n)h\big] + o(h). \end{aligned}$$

En soustrayant $p_n(t)$, en divisant par h et en passant à la limite $h \downarrow 0$, on obtient l'équation de Kolmogorov avant :

$$p_n'(t) = \lambda_{n-1}p_{n-1}(t) + \mu_{n+1}p_{n+1}(t) - (\lambda_n + \mu_n)p_n(t).$$

Aux frontières, on omet les contributions des états inexistants. Les quatre équations s'écrivent donc explicitement

$$\begin{cases} p_0'(t) = -\lambda p_0(t) + \mu p_1(t), \\ p_1'(t) = \lambda p_0(t) - (\lambda + \mu)p_1(t) + 2\mu p_2(t), \\ p_2'(t) = \lambda p_1(t) - (\lambda + 2\mu)p_2(t) + 2\mu p_3(t), \\ p_3'(t) = \lambda p_2(t) - 2\mu p_3(t). \end{cases}$$

(5) Relation entre lois temporelles et matrice de transition

On note

$$p(t) = (p_0(t), p_1(t), p_2(t), p_3(t)).$$

(i) La relation entre la loi à l'instant t et la loi initiale est

$$p(t) = p(0)P(t),$$

où $P(t) = (p_{ij}(t))_{i,j}$ est la matrice de transition. Le vecteur $p(t)$ est une seule loi de probabilité ; la ligne i de $P(t)$ est la loi au temps t lorsque l'état initial est i.

(ii) L'évolution de $P(t)$ est régie par les équations de Kolmogorov avant et arrière :

$$P'(t) = P(t)Q = QP(t), \qquad P(0) = I_4.$$

(iii) La solution est

$$P(t) = e^{tQ} \qquad \text{et donc} \qquad p(t) = p(0)e^{tQ}.$$

En particulier, $p'(t) = p(t)Q$.

(iv) **Relation entre Q et $P(t)$.** La matrice des transitions $P(t) = (p_{ij}(t))_{i,j}$ décrit la dynamique du processus :

$$p_{ij}(t) = \mathbb{P}(N_t = j \mid N_0 = i).$$

Pour cette chaîne de Markov à temps continu, elle satisfait les **équations de Chapman–Kolmogorov** :

$$P(t+h) = P(t)P(h), \qquad t, h \geq 0,$$

avec la condition initiale $P(0) = I_4$.
La dérivée à droite en 0 définit le **générateur infinitésimal** :

$$Q = P'(0) = \lim_{h \downarrow 0} \frac{P(h) - I_4}{h}.$$

Chaque coefficient de Q possède alors une interprétation probabiliste :

$$Q_{ij} = \lim_{h \downarrow 0} \frac{p_{ij}(h) - \mathbb{1}_{\{i=j\}}}{h} = \begin{cases} \lim\limits_{h \downarrow 0} \dfrac{p_{ij}(h)}{h}, & i \neq j, \\ -\sum\limits_{k \neq i} Q_{ik}, & i = j. \end{cases}$$

Ainsi :

- ▷ pour $i \neq j$, Q_{ij} est le **taux instantané de transition** de l'état i vers l'état j ;
- ▷ pour $i = j$, la valeur Q_{ii} est l'**opposé du taux total de sortie** de l'état i : ce taux positif vaut $-Q_{ii}$.

En utilisant Chapman–Kolmogorov, on retrouve l'équation avant :

$$\frac{P(t+h) - P(t)}{h} = P(t)\frac{P(h) - I_4}{h} \longrightarrow P(t)Q.$$

Réciproquement, connaissant Q, la matrice des transitions s'obtient par la **résolution du système matriciel différentiel**

$$P'(t) = P(t)Q, \qquad P(0) = I_4.$$

Sa solution s'écrit

$$P(t) = e^{tQ} = I_4 + tQ + \frac{t^2}{2!}Q^2 + \cdots.$$

Cette expression montre que la matrice infinitésimale Q gouverne entièrement la dynamique du processus : elle joue le rôle de **générateur du semi-groupe** $(P(t))_{t \geq 0}$.

Vérification. À partir de $P(t)$, on retrouve bien Q en dérivant à droite en $t = 0$:

$$Q = P'(0) = \frac{\mathrm{d}}{\mathrm{d}t} P(t)\Big|_{t=0^+}.$$

En pratique, pour une file $M/M/2/3$, les premières dérivées des coefficients $p_{ij}(t)$ en $t = 0$ donnent exactement les taux de transition. Par exemple,

$$p'_{01}(0) = \lambda, \qquad p'_{10}(0) = \mu, \qquad p'_{22}(0) = -(\lambda + 2\mu),$$

ce qui confirme la cohérence entre les définitions de $P(t)$ et Q.
Ainsi, Q et $P(t)$ sont intimement liées :

$$Q = P'(0) \qquad \text{et} \qquad P(t) = e^{tQ}.$$

La première décrit la **dynamique instantanée**, la seconde son **évolution temporelle globale**.

(6) Matrice infinitésimale

Rappelons que l'expression de la matrice infinitésimale Q est la suivante :

$$Q = P'(0), \qquad Q_{ij} = \begin{cases} p'_{ij}(0), & i \neq j, \\ -\displaystyle\sum_{k \in \mathcal{S} \setminus \{i\}} p'_{ik}(0), & i = j. \end{cases}$$

Pour interpréter les termes Q_{ij}, partons de la définition différentielle de $p'_{ij}(0)$:

$$p'_{ij}(0) = \lim_{h \downarrow 0} \frac{p_{ij}(h) - \mathbb{1}_{\{i=j\}}}{h}.$$

Pour une file d'attente de type $M/M/2/3$, les probabilités élémentaires sur un petit intervalle vérifient, pour $i, j \in \mathcal{S}$,

$$p_{ij}(h) = \begin{cases} \lambda_i h + o(h), & j = i + 1, \\ \mu_i h + o(h), & j = i - 1, \\ 1 - (\lambda_i + \mu_i)h + o(h), & j = i, \\ o(h), & \text{sinon}, \end{cases}$$

où les taux dépendent de l'état i selon

$$\lambda_i = \begin{cases} \lambda, & i < 3, \\ 0, & i = 3, \end{cases} \qquad \mu_i = \begin{cases} 0, & i = 0, \\ \mu, & i = 1, \\ 2\mu, & i = 2, 3. \end{cases}$$

En soustrayant $p_{ij}(0) = \mathbb{1}_{\{i=j\}}$, en divisant par h et en faisant tendre h vers 0 par valeurs positives, on obtient

$$p'_{ij}(0) = \begin{cases} \lambda_i, & j = i + 1, \\ \mu_i, & j = i - 1, \\ -(\lambda_i + \mu_i), & j = i, \\ 0, & \text{sinon}. \end{cases}$$

Vue comme la matrice des taux instantanés, la matrice infinitésimale est donc donnée par

$$Q = \begin{pmatrix} -\lambda & \lambda & 0 & 0 \\ \mu & -(\lambda + \mu) & \lambda & 0 \\ 0 & 2\mu & -(\lambda + 2\mu) & \lambda \\ 0 & 0 & 2\mu & -2\mu \end{pmatrix}.$$

Interprétation.

- Les coefficients diagonaux $Q_{ii} < 0$ sont les **opposés des taux de sortie** de l'état i.
- Les coefficients hors diagonale positifs indiquent les **taux de transition** entre états :

$$Q_{i,i+1} = \lambda_i \quad (i < 3), \qquad Q_{i,i-1} = \mu_i \quad (i \geq 1).$$

- Chaque ligne somme à zéro :

$$\sum_{j=0}^{3} Q_{ij} = 0,$$

traduisant la **conservation des probabilités**.

Point de vigilance. Une arrivée refusée dans l'état 3 n'est pas une transition vers un nouvel état. Le taux de sortie de cet état vaut 2μ, et le coefficient diagonal est donc $Q_{33} = -2\mu$. Le taux λ des refus n'est pas ajouté à cette diagonale.

(7) Loi stationnaire et stabilité

Une **loi stationnaire** $\pi = (\pi_0, \pi_1, \pi_2, \pi_3)$ vérifie $\pi P(t) = \pi$ pour tout $t \geq 0$. Ici, cela équivaut à

$$\pi Q = 0, \qquad \pi_n \geq 0, \qquad \sum_{n=0}^{3} \pi_n = 1.$$

Si N_0 suit cette loi, alors N_t suit la même loi pour tout $t \geq 0$.

La **stabilité** d'une file $M/M/c$ à capacité infinie, au sens de l'existence d'une probabilité stationnaire, s'exprime par la condition sur le facteur de charge

$$\rho = \frac{\lambda}{c\mu} < 1.$$

Elle signifie que le flux d'arrivées est inférieur à la capacité totale de service lorsque tous les serveurs sont occupés.

Ici, la capacité est finie ($K = 3$) : pour $\lambda, \mu > 0$, la chaîne est **finie et irréductible**. Elle est donc récurrente positive et possède une **unique probabilité stationnaire**, même si $\rho = \lambda/(2\mu) \geq 1$. Les arrivées excédentaires sont simplement refusées. Cette stabilité ne garantit toutefois pas une faible probabilité de refus.

(8) Résolution de la loi stationnaire

En régime stationnaire, le **principe de conservation des flux de probabilité** impose, pour chaque état n, l'égalité entre flux entrants et sortants. Ainsi,

$$\text{Flux entrant en } n = \text{Flux sortant de } n.$$

On démarre par le bilan dans l'état 0, obtenant

$$\lambda_0 \pi_0 = \mu_1 \pi_1.$$

Le bilan dans l'état 1 donne ensuite

$$(\lambda_1 + \mu_1)\pi_1 = \lambda_0 \pi_0 + \mu_2 \pi_2 \quad \Longrightarrow \quad \mu_2 \pi_2 = \lambda_1 \pi_1.$$

De même, le bilan dans l'état 2 donne

$$(\lambda_2 + \mu_2)\pi_2 = \lambda_1 \pi_1 + \mu_3 \pi_3 \quad \Longrightarrow \quad \mu_3 \pi_3 = \lambda_2 \pi_2.$$

On obtient ainsi les relations d'équilibre détaillé :

$$\pi_n \mu_n = \pi_{n-1} \lambda_{n-1}, \qquad n \in \{1, 2, 3\}.$$

D'où les expressions

$$\pi_1 = \frac{\lambda}{\mu}\pi_0, \qquad \pi_2 = \frac{\lambda^2}{2\mu^2}\pi_0, \qquad \pi_3 = \frac{\lambda^3}{4\mu^3}\pi_0.$$

En imposant la normalisation $\sum_{n=0}^{3}\pi_n = 1$, on obtient

$$\pi_0 = \left(1 + \frac{\lambda}{\mu} + \frac{\lambda^2}{2\mu^2} + \frac{\lambda^3}{4\mu^3}\right)^{-1}.$$

Les autres composantes s'en déduisent directement. En posant $\tilde{\rho} = \lambda/\mu$, une écriture générale correcte est

$$\pi_n = \pi_0 \frac{\tilde{\rho}^n}{\prod_{k=1}^{n}\min(k,2)}, \qquad n \in \{0,1,2,3\},$$

avec la convention qu'un produit vide vaut 1. Ainsi, en notant $Z = 1 + \tilde{\rho} + \tilde{\rho}^2/2 + \tilde{\rho}^3/4$,

$$\pi = \frac{1}{Z}\left(1,\ \tilde{\rho},\ \frac{\tilde{\rho}^2}{2},\ \frac{\tilde{\rho}^3}{4}\right).$$

Point de vigilance. Le dénominateur fait intervenir le *produit* des taux de service successifs. Pour l'état 3, ce produit vaut $\mu \times 2\mu \times 2\mu = 4\mu^3$. La formule $\pi_n = \pi_0\tilde{\rho}^n/\min(n,2)!$ serait donc incorrecte dès $n = 3$.

(9) Refus et métriques de performance

$$P_{\text{refus}} = \pi_3, \qquad \lambda_{\text{eff}} = \lambda(1-\pi_3), \qquad U = \frac{\lambda_{\text{eff}}}{2\mu}.$$

Interprétation.

- π_3 est la probabilité stationnaire que le système soit plein : une arrivée le trouvant dans cet état est immédiatement refusée.
- Par le **principe PASTA** (*Poisson Arrivals See Time Averages*), les arrivées proposées de Poisson voient l'état du système *juste avant leur arrivée* selon ses proportions stationnaires. Ainsi, la probabilité qu'une arrivée soit bloquée est exactement égale à la probabilité stationnaire de saturation :

  $$P_{\text{perte}} = P_{\text{refus}} = \pi_3.$$

  Cette probabilité est sans unité. Le **nombre moyen de refus par unité de temps** vaut, lui,

  $$r_{\text{refus}} = \lambda\pi_3.$$

- $\lambda_{\text{eff}} = \lambda(1-\pi_3)$ est le **taux d'entrée effectif** : il correspond au flux d'arrivées réellement acceptées et servies. En régime stationnaire, il coïncide avec le débit de sortie :

  $$\lambda_{\text{eff}} = \mu\pi_1 + 2\mu(\pi_2 + \pi_3).$$

- Enfin, $U = \lambda_{\text{eff}}/(2\mu)$ mesure la **proportion moyenne de serveurs occupés** :

  $$U = \frac{\mathbb{E}[\min(N,2)]}{2} = \frac{\pi_1 + 2\pi_2 + 2\pi_3}{2}.$$

  Cette utilisation reste comprise entre 0 et 1, contrairement au facteur de charge proposé $\rho = \lambda/(2\mu)$, qui peut dépasser 1.

Si $\lambda \gg \mu$, la file est presque toujours saturée. Plus précisément, lorsque $\lambda \to \infty$ à μ fixé,

$$1 - \pi_3 = \frac{1 + \tilde{\rho} + \tilde{\rho}^2/2}{1 + \tilde{\rho} + \tilde{\rho}^2/2 + \tilde{\rho}^3/4} \underset{\lambda\to\infty}{\sim} \frac{2}{\tilde{\rho}} = \frac{2\mu}{\lambda}.$$

Par conséquent,

$$\pi_3 \xrightarrow[\lambda\to\infty]{} 1, \qquad \lambda_{\text{eff}} \xrightarrow[\lambda\to\infty]{} 2\mu, \qquad U \xrightarrow[\lambda\to\infty]{} 1.$$

Le système refuse une proportion de clients qui tend vers 1, mais les serveurs restent presque toujours occupés : le débit admis tend vers la capacité maximale de service 2μ.

(10) Loi de Little et temps moyens

La **loi de Little** relie les quantités stationnaires :

$$\mathbb{E}[N] = \lambda_{\text{eff}}\mathbb{E}[T] \quad \Longleftrightarrow \quad \mathbb{E}[T] = \frac{\mathbb{E}[N]}{\lambda_{\text{eff}}}.$$

Les temps de séjour T et d'attente avant service W sont ceux des *clients admis* dans le système.

Définitions des grandeurs.

- En régime stationnaire, la variable aléatoire N représente **le nombre total de clients présents dans le système (en service ou en attente)**. Sa loi est π :

  $$\mathbb{P}(N = n) = \pi_n, \qquad n \in \{0, 1, 2, 3\}.$$

  Comme cette chaîne finie et irréductible converge vers son équilibre, on a également, quelle que soit la loi initiale,

  $$\mathbb{E}[N] = \lim_{t\to\infty} \mathbb{E}[N_t].$$

- $L = \mathbb{E}[N] = \sum_{n=0}^{3} n\pi_n$: nombre moyen de clients dans le système ;
- $L_q = L - \lambda_{\text{eff}}/\mu$: nombre moyen de clients dans la file d'attente, puisque λ_{eff}/μ représente le **nombre moyen de clients en service** ;
- $\mathbb{E}[T]$: temps moyen passé dans le système par un client admis ;
- $\mathbb{E}[W] = \mathbb{E}[T] - 1/\mu$: temps moyen d'attente avant service d'un client admis.

Définitions et justification des grandeurs moyennes. En régime stationnaire, la distribution de probabilité du nombre de clients dans le système est donnée par la loi $(\pi_n)_{n=0,\dots,3}$, vérifiant

$$\pi_n = \mathbb{P}(N = n), \qquad \sum_{n=0}^{3} \pi_n = 1.$$

Cette loi représente la proportion de temps que le système passe dans chaque état à long terme. Par le **théorème ergodique**, les moyennes temporelles des fonctions de l'état coïncident avec leurs espérances sous la loi stationnaire. Ainsi, les nombres moyens de clients s'obtiennent par espérance sur (π_n). Les temps moyens vus par les clients admis s'en déduisent ensuite par la loi de Little.

On note

$$L = \mathbb{E}[N] = \sum_{n=0}^{3} n\pi_n.$$

C'est le **nombre moyen de clients présents dans le système** (en service ou en attente).

- D'après les expressions de $\pi_0, \pi_1, \pi_2, \pi_3$, on a

  $$\begin{aligned} L &= \pi_0 \left(0 \times 1 + \frac{\lambda}{\mu} + 2\frac{\lambda^2}{2\mu^2} + 3\frac{\lambda^3}{4\mu^3} \right) \\ &= \pi_0 \left(\frac{\lambda}{\mu} + \frac{\lambda^2}{\mu^2} + \frac{3\lambda^3}{4\mu^3} \right) = \frac{\tilde{\rho} + \tilde{\rho}^2 + 3\tilde{\rho}^3/4}{Z}, \end{aligned}$$

  avec $\tilde{\rho} = \lambda/\mu$ et $Z = 1 + \tilde{\rho} + \tilde{\rho}^2/2 + \tilde{\rho}^3/4$.

- **Nombre moyen de clients dans la file d'attente :**

$$L_q = L - \frac{\lambda_{\text{eff}}}{\mu}.$$

Le terme λ_{eff}/μ correspond au nombre moyen de clients en service, par l'équilibre des flux stationnaires. En remplaçant $\lambda_{\text{eff}} = \lambda(1-\pi_3)$, on obtient

$$L_q = L - \frac{\lambda(1-\pi_3)}{\mu}.$$

Ici, une seule personne peut attendre, et uniquement dans l'état 3. On obtient donc aussi directement

$$L_q = \mathbb{E}[(N-2)_+] = \pi_3 = \frac{\tilde{\rho}^3}{4Z}.$$

- **Temps moyen dans le système (loi de Little) :**

$$\mathbb{E}[T] = \frac{L}{\lambda_{\text{eff}}} = \frac{L}{\lambda(1-\pi_3)} = \frac{1+\tilde{\rho}+3\tilde{\rho}^2/4}{\mu(1+\tilde{\rho}+\tilde{\rho}^2/2)}.$$

C'est le **temps moyen de séjour** d'un client admis (attente et service).

- **Temps moyen d'attente avant service :**

$$\begin{aligned}\mathbb{E}[W] &= \mathbb{E}[T] - \frac{1}{\mu} = \frac{L}{\lambda(1-\pi_3)} - \frac{1}{\mu} \\ &= \frac{L_q}{\lambda_{\text{eff}}} = \frac{\tilde{\rho}^2}{4\mu(1+\tilde{\rho}+\tilde{\rho}^2/2)}.\end{aligned}$$

Le terme $1/\mu$ est la durée moyenne de service pour une loi exponentielle de paramètre μ.

Interprétation.

- L mesure l'**occupation globale du système** : nombre moyen de clients présents, toutes positions confondues.
- L_q quantifie la **congestion de la file** : un indicateur direct de la qualité de service.
- $\mathbb{E}[T]$ est le **temps moyen passé par un client admis** depuis son arrivée jusqu'à sa sortie.
- $\mathbb{E}[W]$ est le **temps d'attente uniquement dans la file**, excluant la durée de service.

Ces relations constituent les **formules fondamentales de la file d'attente** $M/M/2/3$: elles relient les performances temporelles (temps d'attente, congestion) aux caractéristiques structurelles du système (taux d'arrivée, taux de service et capacité). Elles permettent d'évaluer le confort de service et le dimensionnement du système.

Exemple 8.2.1 (Application numérique : $\lambda = 2$ et $\mu = 1$)**.** Les deux taux sont exprimés dans une même unité de temps. On a $\tilde{\rho} = 2$ et $Z = 7$, donc

$$\pi = \frac{1}{7}(1,2,2,2).$$

Les métriques de performance sont

$$P_{\text{refus}} = \frac{2}{7}, \qquad r_{\text{refus}} = \frac{4}{7}, \qquad \lambda_{\text{eff}} = \frac{10}{7}, \qquad U = \frac{5}{7},$$

et

$$L = \frac{12}{7}, \qquad L_q = \frac{2}{7}, \qquad \mathbb{E}[T] = \frac{6}{5}, \qquad \mathbb{E}[W] = \frac{1}{5}.$$

Les débits s'expriment en clients par unité de temps, et les durées dans l'unité de temps choisie. On vérifie bien

$$\lambda_{\text{eff}}\mathbb{E}[T] = L, \qquad \lambda_{\text{eff}}\mathbb{E}[W] = L_q, \qquad \mathbb{E}[T] - \mathbb{E}[W] = \frac{1}{\mu} = 1.$$

(11) Interprétation globale

Le modèle $M/M/2/3$ illustre une situation concrète où deux serveurs travaillent en parallèle avec une capacité d'attente limitée (par exemple un centre d'appel ou un service hospitalier).

- Si λ augmente, les refus deviennent plus fréquents (π_3 augmente) et la proportion de clients admis diminue.
- Si μ augmente (meilleure efficacité des serveurs), les files se résorbent et la probabilité de refus décroît.
- Augmenter K ajoute des places d'attente et réduit les refus, mais peut augmenter les temps d'attente : cela n'accroît pas la capacité de service.
- Augmenter le nombre de serveurs c, à capacité totale compatible, accroît la capacité de service et réduit la congestion, au prix d'un coût supplémentaire.

Ainsi, l'étude de la file $M/M/2/3$ permet de **trouver un équilibre entre coût et performance**, en quantifiant rigoureusement l'occupation, les temps d'attente et les refus.

À retenir

Commencer par les états et les taux de transition, puis calculer la loi stationnaire. Les performances s'en déduisent en distinguant le flux proposé du flux admis. La loi de Little utilise λ_{eff}, et les durées T et W concernent les clients admis.

Outils de calcul et fiche de révision

A.1 Rappels : petit o, grand O et équivalents

Les notations asymptotiques décrivent le comportement d'une fonction lorsque $h \to 0$. Dans les files d'attente, elles permettent de distinguer les événements **d'ordre** h des événements négligeables devant h, notamment sur un intervalle $[t, t+h]$.

Définition A.1.1 (Grand O : ordre de grandeur)**.** On écrit $f(h) = O(g(h))$ lorsque $h \to 0$ si

$$\exists C > 0,\ \exists \delta > 0, \quad |f(h)| \le C|g(h)|, \quad 0 < |h| < \delta.$$

Autrement dit, f est **bornée en ordre** par g. Par exemple, $3h + 2h^2 = O(h)$.

Définition A.1.2 (Petit o : négligeabilité)**.** On écrit $f(h) = o(g(h))$ lorsque $h \to 0$ si

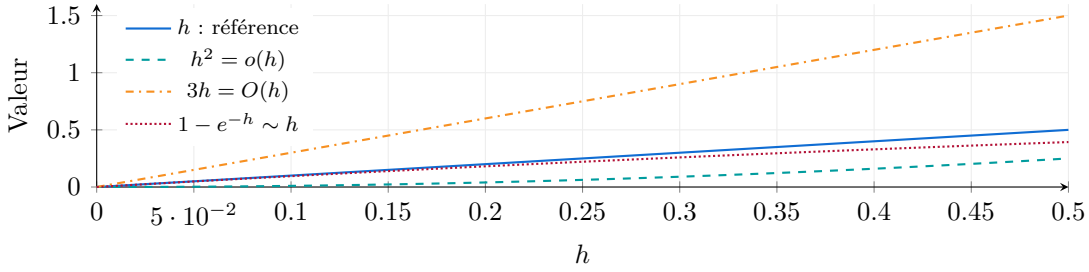
$$\lim_{h \to 0} \frac{f(h)}{g(h)} = 0,$$

pour $g(h) \neq 0$ au voisinage de 0. Ainsi, $h^2 = o(h)$: h^2 devient **négligeable devant** h.

Définition A.1.3 (Équivalence asymptotique)**.** On écrit $f(h) \sim g(h)$ lorsque $h \to 0$ si

$$\lim_{h \to 0} \frac{f(h)}{g(h)} = 1.$$

Les fonctions ont alors le même comportement dominant : $1 - e^{-\lambda h} \sim \lambda h$.



Proposition A.1.4 (Développement limité au premier ordre)**.** *Si f est dérivable en 0, alors*

$$f(h) = f(0) + hf'(0) + o(h), \qquad h \to 0.$$

En particulier, pour $a > 0$,

$$e^{-ah} = 1 - ah + O(h^2) = 1 - ah + o(h).$$

Preuve. Par définition de la dérivée,

$$\frac{f(h) - f(0)}{h} \longrightarrow f'(0),$$

donc $f(h) - f(0) - hf'(0) = o(h)$. Pour l'exponentielle, la formule de Taylor donne le reste $O(h^2)$. □

Application : construire le générateur

Pour une chaîne de Markov en temps continu de générateur $Q = (q_{ij})$,

$$\mathbb{P}(N_{t+h} = j \mid N_t = i) = \begin{cases} q_{ij}h + o(h), & j \neq i, \\ 1 + q_{ii}h + o(h), & j = i. \end{cases}$$

Les coefficients q_{ij} sont donc les **taux de transition instantanés** : ils correspondent aux termes du premier ordre en h dans les probabilités de transition.

A.2 Sommes géométriques et espérance de $M/M/1/K$

Pour $K \in \mathbb{N}$ et $r \neq 1$,

$$G_K(r) = \sum_{n=0}^{K} r^n = \frac{1 - r^{K+1}}{1 - r}.$$

La somme étant finie, on peut la dériver terme à terme :

$$\sum_{n=1}^{K} n r^n = r G_K'(r).$$

Proposition A.2.1 (Somme géométrique pondérée)**.**

$$\sum_{n=1}^{K} n r^n = \begin{cases} \dfrac{r[1 - (K+1)r^K + Kr^{K+1}]}{(1-r)^2}, & r \neq 1, \\ \dfrac{K(K+1)}{2}, & r = 1. \end{cases}$$

Première preuve : dérivation. La règle du quotient donne

$$G_K'(r) = \frac{-(K+1)r^K(1-r) + (1 - r^{K+1})}{(1-r)^2}.$$

Après regroupement et multiplication par r, on obtient la formule annoncée. □

Seconde preuve : télescopage. Posons $S_K(r) = \sum_{n=1}^{K} n r^n$. En décalant les indices,

$$r S_K(r) = \sum_{n=2}^{K+1} (n-1) r^n.$$

La différence se simplifie :

$$(1-r) S_K(r) = \sum_{n=1}^{K} r^n - K r^{K+1}.$$

On remplace la somme géométrique par sa forme fermée, puis on divise par $1 - r$. Le cas $r = 1$ est la somme des K premiers entiers. □

Application à $M/M/1/K$

La loi stationnaire est

$$\pi_n = \frac{\rho^n}{\sum_{j=0}^{K} \rho^j} \qquad \text{donc} \quad L = \frac{\sum_{n=1}^{K} n\rho^n}{\sum_{n=0}^{K} \rho^n}.$$

Pour $\rho \neq 1$, on retrouve

$$L = \frac{\rho[1 - (K+1)\rho^K + K\rho^{K+1}]}{(1-\rho)(1-\rho^{K+1})}.$$

Pour $\rho = 1$, la loi est uniforme :

$$L = \frac{1}{K+1}\sum_{n=0}^{K} n = \frac{K}{2}.$$

Remarque A.2.2 (Calcul numérique près de $\rho = 1$). La formule fermée peut perdre en précision à cause de soustractions entre nombres proches. Le calcul par poids normalisés, utilisé dans le projet Python, évite de traiter explicitement ces quotients presque indéterminés.

A.3 Fiche de révision et méthode de résolution

Objet	Relation à connaître	Notations
Chaîne discrète	$\nu^{(n)} = \nu^{(0)}P^n, \quad \pi P = \pi$	$\nu^{(n)}$: loi à l'instant n ; π : loi stationnaire.
Chaîne continue	$P(t) = e^{tQ}, \quad p'(t) = p(t)Q, \quad \pi Q = 0$	$P(t)$: transition ; Q : générateur.
Taux de sortie	$q_i = -q_{ii} = \sum_{j \neq i} q_{ij}$	q_i : taux de sortie ; q_{ij} : taux de transition.
Temps inter-saut	$H_i \sim \mathrm{Exp}(q_i)$, pour $q_i > 0$	H_i : temps de séjour dans l'état i.
Destination d'un saut	$\widetilde{p}_{ij} = q_{ij}/q_i$, $j \neq i$	$\widetilde{p}_{ij}$: probabilité du prochain état j.
Naissance–mort	$\pi_{n+1}\mu_{n+1} = \pi_n\lambda_n$	λ_n : naissance ; μ_n : mort.
Poisson	$A_t \sim \mathrm{Poisson}(\lambda t), \quad V_n \overset{\text{i.i.d.}}{\sim} \mathrm{Exp}(\lambda)$	A_t : arrivées cumulées ; V_n : interarrivée ; λ : intensité.
Renouvellement	$R(t)/t \to 1/\mathbb{E}[V_1]$	$R(t)$: comptage ; V_1 : interrenouvellement.
Débit admis	$\lambda_{\text{eff}} = \lambda(1 - p_{\text{bloc}})$	λ_{eff} : débit effectif ; p_{bloc} : probabilité de refus.
PASTA et refus	$p_{\text{bloc}} = \pi_K$	π_K : probabilité de saturation ; K : capacité totale.
Loi de Little	$L = \lambda_{\text{eff}}\mathbb{E}[T], \quad L_q = \lambda_{\text{eff}}\mathbb{E}[W]$	L, L_q : effectifs moyens ; T : séjour ; W : attente.
Services exponentiels	$\lambda_{\text{eff}} = \mu\mathbb{E}[\min(N, c)], \quad \mathbb{E}[T] = \mathbb{E}[W] + 1/\mu$	μ : taux de service ; N : occupation ; c : serveurs.

Une méthode en six étapes

1. **Définir l'état.** Vérifier qu'il contient assez d'information pour rendre la dynamique markovienne.
2. **Lister les événements.** Associer à chaque changement d'état un taux et une unité. Traiter séparément les frontières.
3. **Construire le générateur.** Renseigner les coefficients hors diagonale, puis imposer une somme nulle sur chaque ligne.
4. **Établir l'équilibre.** Résoudre $\pi Q = 0$ et normaliser. Exploiter l'équilibre détaillé lorsqu'il est justifié.
5. **Définir les performances.** Distinguer flux proposé et admis, attente et séjour, charge offerte et utilisation effective.
6. **Vérifier et interpréter.** Contrôler les unités, les cas limites, les flux et la loi de Little avant de conclure sur une décision.

Point de vigilance. Les confusions les plus fréquentes portent sur : un taux pris pour une probabilité ; l'occupation N_t prise pour un comptage croissant ; une arrivée refusée traitée comme un changement d'état ; le débit proposé utilisé dans Little malgré les pertes ; et une moyenne prise aux sauts utilisée comme moyenne temporelle.