

Introduction au Clustering Spectral

Paul MINCHELLA

11 juin 2026




Table des matières

1	Introduction au clustering	3
1.1	La motivation du clustering	4
1.2	Deux grandes visions du clustering	5
1.3	Limites des approches naïves	5
1.4	Benchmarks classiques	6
1.5	Évaluer la qualité d'un clustering	8
1.5.1	Quelques métriques élémentaires	8
1.5.2	Limites des métriques	10
1.6	Vers le clustering spectral	11
2	Le clustering par k-means	12
2.1	Principe et algorithme	12
2.2	Limites du k -means	14
3	Graphes et structures de connectivité	15
3.1	Un exemple motivant	15
3.2	Définition d'un graphe	16
3.3	Graphes pondérés	16
3.4	Connectivité et composantes connexes	18
3.5	Construire un graphe à partir des données	20
3.6	Du clustering au graphe	20
3.7	Vers le Laplacien	21
4	Rappels en algèbre	23
4.1	Préambule algébrique : produit scalaire et formes quadratiques	23
4.1.1	Produit scalaire dans un espace préhilbertien	23
4.1.2	Produit scalaire euclidien	27
4.1.3	Rôle de la transposée	27
4.1.4	Compatibilité matricielle fondamentale	29
4.1.5	Importance de la quantité $\langle Mx, x \rangle$	29
4.1.6	La forme quadratique comme quantification d'énergie	32
4.2	Matrices orthonormées	32
4.3	Le théorème spectral	34
5	Analyse spectrale et quotient de Rayleigh	38
5.1	Définition	39
5.2	Lien avec les valeurs propres	40
5.3	Encadrement spectral	41
5.4	Exemples	44
5.5	Lien avec les matrices de covariance	46
5.6	Lien avec le Laplacien	46
5.7	Minimisation d'énergie et émergence des clusters	47
5.8	Gradient et variations locales	49
5.9	Le Laplacien continu	50
5.10	L'espace L^2	50

5.11	Énergie continue	51
5.12	Lien entre énergie et Laplacien	51
5.13	Analyse spectrale du Laplacien	53
5.14	Principe variationnel	56
5.15	Du continu au discret	57
6	Le Laplacien de graphe	59
6.1	Fonctions définies sur un graphe	59
6.2	Le Laplacien de graphe	60
6.3	Énergie discrète	60
6.4	Positivité du Laplacien	63
6.5	Le noyau du Laplacien	63
6.6	Composantes connexes et multiplicité de zéro	63
7	Le clustering spectral	69
	Étape 1 : construction du graphe	69
	Étape 2 : construction du Laplacien	70
	Étape 3 : diagonalisation du Laplacien	71
	Étape 4 : application du k -means	71
	Algorithme complet	71
8	Exercices de clustering spectral	72
8.1	Énoncés	72
8.2	Corrigés	74
	Conclusion et ouvertures	80
	Résumé	80
	Limites et aspects pratiques	80
	Ouvertures	81
	Ressources complémentaires	82

Chapitre 1

Introduction au clustering

Dans de nombreux problèmes appliqués, les données disponibles ne possèdent aucune étiquette ou variable réponse explicitement observée. Un exemple simple consiste en l'étude par une entreprise du comportement des clients¹. Doit-on les regrouper par âge, par lieu, par préférence culturelle ou encore selon d'autres caractéristiques "cachées" (en un sens que l'expert métier ne peut pas relever par lui-même) ? C'est justement sur ce dernier point que l'on porte toute notre attention. La motivation même du clustering émerge de l'envie de regrouper par paquet ou par-justement- *clusters* les individus aux comportements d'achats similaires. Du point de vu du machine learning, on débarque dans le domaine de l'**apprentissage non supervisé**.

Cadre statistique. Supposons que l'on dispose simplement d'un ensemble d'observations :

$$X_1, \dots, X_n \in \mathbb{R}^p,$$

et l'objectif devient alors de comprendre la structure interne des données elles-mêmes.

Définition 1.0.1 (Apprentissage non supervisé). On parle d'apprentissage non supervisé lorsque les observations disponibles sont uniquement des variables explicatives

$$X_1, \dots, X_n \in \mathbb{R}^d,$$

sans variable réponse associée.

Contrairement à l'apprentissage supervisé, où l'on cherche à prédire une variable cible connue à partir de données annotées, l'apprentissage non supervisé vise à découvrir "automatiquement" des régularités, des structures géométriques ou des organisations cachées dans les données.

Idée générale de l'apprentissage non supervisé

En apprentissage non supervisé, les données ne possèdent pas de "bonne réponse" explicitement fournie. L'objectif est donc d'extraire automatiquement :

- des groupes cohérents ;
- des structures géométriques ;
- des relations de similarité ;
- ou des régularités statistiques cachées.

1. On laissera bon au lecteur de juger l'éthique derrière une telle application des mathématiques.

1.1 La motivation du clustering

Lorsqu'un grand ensemble de données est observé, il est fréquent que certaines observations présentent des comportements similaires. Intuitivement, en une courte liste d'exemples :

- certains individus se ressemblent ;
- certains documents abordent des thématiques proches ;
- certains signaux possèdent des caractéristiques communes ;
- certaines régions d'un espace de données présentent une forte densité.

L'idée fondamentale du clustering réside dans le fait que des observations similaires doivent appartenir à un même groupe. Le but devient donc de partitionner automatiquement les données en plusieurs sous-ensembles homogènes appelés *clusters*.

Intérêts. Le clustering va présenter bon nombre d'intérêts : d'un point de vue descriptif, il permet de mieux comprendre l'organisation interne d'un jeu de données en révélant des structures, des comportements ou des populations naturellement présentes. Dans certains contextes, il constitue également une forme de classification non supervisée : on cherche à attribuer automatiquement des observations à différents groupes sans connaître au préalable les étiquettes réelles.

Les clusters obtenus peuvent ensuite être exploités dans des tâches plus complexes. Par exemple, l'indice de cluster d'une observation peut être réintroduit comme variable explicative dans un modèle de régression ou de classification supervisée afin d'enrichir l'information disponible. De manière plus générale, le clustering sert souvent à simplifier, résumer ou structurer des données complexes avant une analyse statistique ou géométrique plus approfondie.

Proche au sens d'une similarité. Toute la difficulté réside alors dans la définition mathématique du mot "similaire". En effet, selon la nature des données étudiées, plusieurs notions de proximité peuvent être pertinentes. Dans certains contextes, la distance euclidienne classique suffit à capturer correctement la géométrie des observations. Dans d'autres situations, il peut être plus pertinent de comparer des directions via une similarité cosinus, d'étudier une structure de graphe, d'analyser des relations de connectivité locale ou encore de raisonner en termes de densité probabiliste.

Le choix de cette notion de similarité constitue généralement le cœur même d'un problème de clustering. Deux méthodes différentes appliquées aux mêmes données peuvent produire des regroupements très différents simplement parce qu'elles ne reposent pas sur la même géométrie sous-jacente.

Il paraît donc obligatoire d'insister sur ce fait : un algorithme de clustering ne découvre pas une "vérité absolue" cachée dans les données, mais une structure cohérente relativement à une certaine notion de proximité ou de connectivité.

Exemples d'application. Le clustering se révèle utile dans de nombreux domaines, dont on cite quelques exemples.

Exemple 1.1.1 (Segmentation de clients). En marketing, on cherche à regrouper automatiquement des clients possédant des habitudes d'achat similaires et plus généralement des profils de consommation proches. Cela permettra ensuite d'adapter des stratégies spécifiques à chaque groupe.

Exemple 1.1.2 (Regroupement de documents). En traitement automatique du langage, le clustering permet de regrouper automatiquement :

- des articles traitant d'un même sujet ;
- des publications scientifiques proches ;
- des documents possédant une structure sémantique similaire.

Exemple 1.1.3 (Biologie et génomique). En biologie, certaines méthodes de clustering permettent d’identifier :

- des sous-types de cellules ;
- des profils génétiques similaires ;
- des structures fonctionnelles cachées.

Les clusters obtenus ne constituent certes pas automatiquement une vérité biologique absolue. Toutefois, lorsque plusieurs études indépendantes retrouvent systématiquement les mêmes regroupements génomiques, cela fournit un argument fort en faveur de l’existence de nouveaux sous-groupes biologiques ou fonctionnels.

Exemple 1.1.4 (Détection de communautés). Dans un réseau social, le clustering peut révéler des groupes d’utilisateurs fortement connectés, des communautés d’intérêts ou encore des structures sociales implicites.

1.2 Deux grandes visions du clustering

Il existe plusieurs manières d’interpréter mathématiquement un problème de clustering. Derrière un même objectif – regrouper des observations similaires – se cachent en réalité des philosophies très différentes selon la manière dont on modélise la notion de groupe.

Vision géométrique. Une première approche, possiblement la plus illustrative, consiste à considérer que les données se répartissent naturellement en différentes régions dans l’espace des covariables. Dans cette perspective, un cluster est vu comme un ensemble d’observations “proches” (à définir selon la métrique de l’espace topologique considéré), souvent organisées autour d’un barycentre. On visera à construire des groupes compacts et bien séparés entre-eux, relativement à une certaine distance (généralement euclidienne). Cette vision est celle du célèbre algorithme du k -means, mais également de nombreuses méthodes métriques classiques.

L’idée sous-jacente est donc profondément géométrique : les clusters correspondent à des régions distinctes de l’espace des données et cette approche fonctionne particulièrement bien lorsque les groupes sont compacts, relativement convexes et correctement séparés. Cependant, ces hypothèses deviennent rapidement limitantes lorsque les données possèdent une géométrie plus complexe.

Vision probabiliste. Une autre manière d’aborder le clustering consiste à supposer que les données sont générées par plusieurs mécanismes probabilistes différents. Dans cette perspective, chaque cluster correspond à une distribution sous-jacente particulière. Les données observées proviennent alors d’un mélange de lois probabilistes que l’on cherche à reconstruire.

L’objectif n’est plus uniquement géométrique puisqu’il devient statistique. On cherche à identifier des régions de forte densité, des composantes cachées ou des structures probabilistes latentes expliquant les observations. Parmi les exemples les plus célèbres, on peut citer celui des modèles de mélanges gaussiens, les approches bayésiennes ou certaines méthodes génératives modernes. Le clustering devient dans ce contexte même un problème d’inférence statistique. On tentera d’estimer quels mécanismes probabilistes ont vraisemblablement généré les données.

1.3 Limites des approches naïves

Une difficulté fondamentale du clustering provient du fait que les données réelles possèdent souvent une géométrie beaucoup plus complexe que celle supposée par les méthodes classiques. En pratique, les groupes observés ne sont pas nécessairement convexes, ni linéairement séparables. Ils peuvent posséder des courbures complexes, des structures en spirales, des anneaux concentriques ou encore des géométries de faible dimension plongées dans un espace ambiant de grande dimension ! Dans ce contexte, raisonner uniquement avec des distances euclidiennes devient souvent insuffisant.

Problème fondamental

Deux points peuvent être éloignés euclidiennement tout en appartenant à une même structure géométrique connectée.
Inversement, deux points proches euclidiennement peuvent appartenir à des groupes totalement différents.

La géométrie pertinente d'un jeu de données n'est pas toujours capturée par les distances classiques dans l'espace ambiant, et peut dépendre davantage des relations de voisinage et de connectivité que des distances globales (cf Figure 1.1).

C'est cette difficulté qui motive des approches plus profondes fondées sur la géométrie locale, sur les graphes de similarité et phénomènes de diffusion et l'analyse spectrale.

Cette dernière notion est justement le cœur de notre cours. L'idée du clustering spectral sera précisément de transformer les données en un graphe afin d'étudier non plus seulement les distances entre points, mais la structure globale de connectivité portée par les données elles-mêmes.

1.4 Benchmarks classiques

À but illustratif, on pourra générer des jeu de données à la géométrie *plus ou moins* complexes. Pour ce faire, il existe des packages adaptés, déjà encodés en Python.

Le benchmark `make_moons`.

Exemple 1.4.1 (Jeu de données `make_moons`). Le benchmark `make_moons`, disponible notamment dans `scikit-learn`, génère deux croissants entrelacés dans le plan.

Ces deux groupes sont clairement séparés visuellement mais ne sont pas convexes. Il ne peuvent pas être correctement séparés par une simple distance à des centroïdes. Ce type de géométrie met fortement en difficulté le k -means classique.




FIGURE 1.1 – Exemple de deux clusters non convexes dans $\mathbb{R}^2$.

Le benchmark `make_circles`.

Exemple 1.4.2 (Jeu de données `make_circles`). Le benchmark `make_circles` génère plusieurs anneaux concentriques.

Dans ce cas précis, les données possèdent une structure topologique claire mais les distances euclidiennes restent peu pertinentes. Deux points appartenant à un même anneau peuvent être éloignés euclidiennement, alors qu'ils appartiennent intuitivement au même groupe géométrique.





FIGURE 1.2 – Exemple de deux clusters concentriques dans $\mathbb{R}^2$.

Ces deux jeux de données fournissent une géométrie qui se décrit simplement, mais échappe à l'apprentissage euclidien et du k -means.



(a) Échec partiel sur des clusters non convexes.

(b) Échec sur des clusters concentriques.

FIGURE 1.3 – Le k -means repose sur une séparation géométrique par centroïdes et peine à capturer des structures de connectivité non convexes.

1.5 Évaluer la qualité d'un clustering

Une fois un algorithme de clustering appliqué, une question fondamentale apparaît immédiatement : comment savoir si les groupes obtenus sont pertinents ?

Contrairement à l'apprentissage supervisé, il n'existe généralement pas de vérité absolue en clustering. Les groupes recherchés sont souvent des structures cachées des données, et leur qualité dépend fortement de la géométrie des données, de la métrique utilisée, de l'objectif métier, ... Il devient donc nécessaire d'introduire des métriques permettant d'évaluer quantitativement la qualité d'une partition. Certaines métriques comparent les clusters obtenus à des labels réels connus (*external metrics*), tandis que d'autres évaluent directement la cohérence géométrique des groupes (*internal metrics*).

L'idée générale. Un "bon" clustering possède généralement deux propriétés :

- (i) les observations d'un même cluster doivent être proches entre elles ;
- (ii) les clusters différents doivent être bien séparés.

Ainsi, la similarité intra-cluster doit être forte tandis que la similarité inter-cluster doit être faible. Toutes les métriques de clustering cherchent, sous une forme ou une autre, à quantifier cet équilibre.

1.5.1 Quelques métriques élémentaires

Adjusted Rand Index (ARI). L'**Adjusted Rand Index** (ARI) est une métrique permettant de comparer deux partitions d'un même ensemble de données :

- une partition de référence (par exemple les vrais labels) ;
- et une partition prédite par l'algorithme de clustering.

L'idée consiste à examiner toutes les paires d'observations et à vérifier si les deux partitions prennent les mêmes décisions, soit les deux observations appartiennent au même cluster dans les deux partitions, soit elles appartiennent à des clusters différents dans les deux partitions. Plus les deux partitions sont cohérentes sur l'ensemble des paires, plus le score est élevé.

Définition 1.5.1 (ARI). On note :

- a le nombre de paires placées dans le même cluster dans les deux partitions ;
- b le nombre de paires placées dans des clusters différents dans les deux partitions.

Le *Rand Index* est alors défini par :

$$RI = \frac{a + b}{\binom{n}{2}},$$

où $\binom{n}{2}$ désigne le nombre total de paires d'observations. Le coefficient RI mesure simplement la proportion de décisions cohérentes prises simultanément par les deux partitions.

L'*Adjusted Rand Index* corrige ensuite ce score afin de tenir compte des accords obtenus par hasard, en centrant puis en normalisant :

$$ARI = \frac{RI - \mathbb{E}[RI]}{\max(RI) - \mathbb{E}[RI]}.$$

Utilisation de l'ARI

L'ajustement par l'espérance permet de corriger les accords purement aléatoires.
Le score ARI appartient à l'intervalle :

$$-1 \leq \text{ARI} \leq 1.$$

En pratique :

- $\text{ARI} \approx 1$: clustering excellent ;
- $\text{ARI} \approx 0$: résultat proche du hasard ;
- $\text{ARI} < 0$: partition incohérente.

L'ARI est très utilisé en pratique car il est invariant par permutation des labels : échanger les numéros des clusters ne modifie pas la valeur du score.

Normalized Mutual Information (NMI). Le **Normalized Mutual Information** (NMI) provient de la théorie de l'information et cherche à mesurer la quantité d'information commune entre deux partitions.

L'idée fondamentale est la suivante : si la connaissance du cluster prédit permet de fortement réduire l'incertitude sur le vrai cluster d'une observation, alors la partition obtenue est pertinente. Inversement, si les deux partitions sont essentiellement indépendantes, alors connaître l'une n'apporte presque aucune information sur l'autre. Le NMI quantifie ainsi le niveau d'information partagé entre une partition de référence et une partition produite par l'algorithme.

Définition 1.5.2 (Normalized Mutual Information). Soient Y les vrais labels et $\hat{Y}$ les labels prédits, à valeurs dans un ensemble fini de labels $\mathcal{Y}$. L'information mutuelle entre ces deux variables aléatoires est définie par :

$$I(Y, \hat{Y}) = \sum_{i,j \in \mathcal{Y}} \mathbb{P}(Y = i, \hat{Y} = j) \log \left(\frac{\mathbb{P}(Y = i, \hat{Y} = j)}{\mathbb{P}(Y = i)\mathbb{P}(\hat{Y} = j)} \right).$$

Elle mesure la dépendance statistique entre les deux partitions. Le NMI correspond alors à une version normalisée :

$$\text{NMI} = \frac{I(Y, \hat{Y})}{\sqrt{H(Y)H(\hat{Y})}},$$

où l'entropie se définit par :

$$H(Y) = - \sum_{i \in \mathcal{Y}} \mathbb{P}(Y = i) \log (\mathbb{P}(Y = i)).$$

Ces quantités mesurent le niveau global d'incertitude porté par chacune des partitions.

Utilisation du NMI

Après normalisation :

$$0 \leq \text{NMI} \leq 1.$$

Un score proche de 1 indique que les deux partitions contiennent pratiquement la même information, tandis qu'un score proche de 0 traduit une quasi-indépendance entre les regroupements.

Le NMI possède plusieurs avantages importants. Contrairement à certaines métriques purement géométriques, il est peu sensible à une permutation des labels et reste généralement robuste lorsque les tailles des clusters sont déséquilibrées. Cependant, comme toute métrique externe, il nécessite de disposer d'une partition de référence. De plus, un bon score NMI ne garantit pas nécessairement que les clusters soient géométriquement compacts ou interprétables dans l'espace des données.

Silhouette Score. Le **Silhouette Score** est une métrique interne de clustering : contrairement à l'ARI ou au NMI, il ne nécessite aucun label réel de référence. L'idée consiste à évaluer, pour chaque observation, si celle-ci est plus proche des éléments de son propre cluster que des éléments appartenant aux autres groupes. Une observation bien clusterisée doit naturellement être fortement similaire aux points de son cluster et relativement éloignée des autres clusters.

Définition 1.5.3 (Silhouette Score). Pour une observation X_i , on introduit :

- a_i , la distance moyenne entre X_i et les points de son propre cluster ;
- b_i , la plus petite distance moyenne entre X_i et les points d'un autre cluster.

Le coefficient de silhouette associé à X_i est alors défini par :

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}.$$

Cette quantité compare la séparation inter-cluster à la cohésion intra-cluster. La normalisation par $\max(a_i, b_i)$ garantit que :

$$-1 \leq s_i \leq 1.$$

Le *Silhouette Score* global correspond à la moyenne des coefficients individuels :

$$S = \frac{1}{n} \sum_{i=1}^n s_i \in [-1, 1].$$

Utilisation du Silhouette Score

- $S \approx 1$: clusters très bien séparés ;
- $S \approx 0$: clusters qui se chevauchent ;
- $S < 0$: nombreuses erreurs d'affectation.

Le Silhouette Score possède une interprétation géométrique bien intuitive et se révèle très pertinent lorsque les vrais labels sont inconnus, ce qui est précisément le cadre naturel du clustering non supervisé !

Attention néanmoins, puisque cette métrique dépend fortement de la distance utilisée et favorise souvent des clusters relativement convexes ou sphériques. Elle peut donc devenir moins pertinente pour des structures géométriques complexes ou fortement non convexes, précisément le type de situations motivant le clustering spectral.

1.5.2 Limites des métriques

Aucune métrique ne permet à elle seule de déterminer ce qu'est un "bon" clustering dans tous les contextes. Chaque score capture en réalité une certaine vision géométrique ou statistique de la notion de groupe.

Certaines métriques favorisent naturellement des clusters compacts et convexes, tandis que d'autres sont plus robustes aux déséquilibres de tailles entre groupes. De plus, les métriques externes comme l'ARI ou le NMI nécessitent des labels réels de référence, ce qui n'est généralement pas disponible en apprentissage non supervisé.

Ces métriques permettront notamment de comparer les performances du k -means et des méthodes de clustering spectral sur différentes structures de données.

1.6 Vers le clustering spectral

La paradigme essentiel du clustering spectral nous demande de changer de point de vue sur les données. En effet, plutôt que de raisonner directement dans l'espace euclidien ambiant à l'aide de distances globales et de centroïdes, on cherche à capturer la structure locale de connectivité des observations. Deux points seront alors considérés comme proches non pas uniquement parce qu'ils sont géométriquement voisins dans $\mathbb{R}^d$, **mais parce qu'ils appartiennent à une même structure connectée à travers une chaîne de voisinages locaux**.

Cette idée conduit naturellement à représenter les données sous la forme d'un graphe de similarité. Chaque observation devient un sommet du graphe, et des arêtes sont construites entre observations jugées suffisamment proches selon une certaine notion de voisinage ou de similarité.

Le problème du clustering devient alors un problème géométrique sur graphe : il s'agit d'identifier des régions fortement connectées entre elles mais faiblement reliées au reste du graphe. En étudiant certaines matrices associées au graphe – notamment le Laplacien – on va faire apparaître des structures géométriques profondes portées par les données. Les valeurs propres et vecteurs propres du Laplacien révéleront alors naturellement les grandes structures de connectivité, les communautés du graphe, les régions de diffusion lente et finalement les clusters eux-mêmes.

Toute la suite du cours consistera donc à comprendre :

- comment construire un graphe de similarité pertinent ;
- pourquoi le Laplacien joue un rôle central ;
- comment les valeurs propres captent la géométrie du graphe ;
- pourquoi les premiers vecteurs propres permettent de faire émerger naturellement les clusters ;
- *in fine*, comment s'en servir en machine learning.

Chapitre 2

Le clustering par k -means

Une première porte d'entrée au clustering est la méthode du k -means, grâce à son approche intuitive et une algorithmie facile à encoder. On présente son cadre avec un exemple illustratif, mais aussi succinctement ses limites.

2.1 Principe et algorithmie

Le clustering par k -means cherche à approximer les données par k centroïdes.

Définition 2.1.1 (k -means). Soient nos données observées $X_1, \dots, X_n \in \mathbb{R}^d$. L'algorithme du k -means consiste à résoudre :

$$\min_{C_1, \dots, C_k} \sum_{j=1}^k \sum_{X_i \in C_j} \|X_i - \mu_j\|^2, \quad (2.1)$$

en proposant un nombre de clusters k au préalable et où μ_j désigne le centroïde du cluster C_j .

On décortique l'expression (2.1). L'objectif du k -means est de partitionner les observations en k groupes homogènes. Pour chaque cluster C_j , on introduit un représentant central, μ_j , appelé *centroïde*, qui correspond intuitivement au "centre moyen" des observations du groupe. La quantité $\|X_i - \mu_j\|^2$ mesure alors à quel point l'observation X_i est éloignée du centre de son cluster. Plus cette distance est faible, plus l'observation est cohérente avec le groupe auquel elle est affectée. Ainsi, la fonction de coût :

$$\sum_{j=1}^k \sum_{X_i \in C_j} \|X_i - \mu_j\|^2$$

additionne toutes les dispersions intra-clusters (c'est-à-dire, à l'intérieur d'un même cluster). Minimiser cette quantité revient donc à rechercher des groupes les plus compacts possibles autour de leurs centroïdes.

On peut aussi raisonner dans le sens inverse. Une fois inféré, un bon clustering k -means est un partitionnement pour lequel les observations d'un même cluster sont proches entre elles, où chaque observation est affectée au centroïde le plus proche et pour lequel les groupes obtenus possèdent une géométrie relativement compacte.

L'algorithme du k -means procède donc de manière itérative :

Algorithme du k -means

1. Initialiser k centroïdes aléatoirement dans l'espace ;
2. Affecter chaque point au centroïde le plus proche ;
3. Recalculer les centroïdes ;
4. Répéter jusqu'à convergence ou jusqu'à un certain nombre d'itérations.

La Figure 2.1 illustre les différentes étapes conceptuelles de cet algorithme.




FIGURE 2.1 – Illustration des premières étapes de l'algorithme du k -means. L'algorithme alterne entre : (i) une phase d'affectation des observations au centroïde le plus proche, puis (ii) une phase de recalcul des centroïdes comme barycentres des groupes obtenus. Cette procédure itérative converge progressivement vers une partition stable des données.

Condition de convergence. L'algorithme du k -means est une procédure itérative, *comme toute une flopée de méthodes en machine learning et informatique*. À chaque étape, les centroïdes sont mis à jour comme barycentres des groupes courants, puis les observations sont réaffectées au centroïde le plus proche. Deux critères de convergence sont généralement employés :

- imposer un nombre maximal d'itérations, $N_{\max}$, afin d'éviter des temps de calcul excessifs ou des oscillations numériques ;
- constater que les centroïdes ne se déplacent presque plus dans l'espace, c'est-à-dire :

$$\left\| \mu_j^{(t+1)} - \mu_j^{(t)} \right\| \leq \varepsilon,$$

pour tout centroïde μ_j , où $\varepsilon > 0$ est un seuil fixé au préalable.

Dans ce second cas, l'algorithme est considéré comme stabilisé : les affectations des observations changent très peu d'une itération à l'autre.

Remarque 1. Le k -means converge toujours en un nombre fini d'itérations vers un minimum local de la fonction objectif (2.1). Cependant, le résultat dépend fortement de l'initialisation des centroïdes. On adoptera en pratique un comportement judicieux en testant l'algorithme pour plusieurs initialisations aléatoires.

Une fois le cycle itératif terminé, on peut observer le résultat final illustré en Figure 2.2.




FIGURE 2.2 – État final de l'algorithme du k -means après convergence. Les centroïdes se stabilisent progressivement au centre géométrique des groupes détectés, conduisant à une partition cohérente des observations.

2.2 Limites du k -means

Malgré sa simplicité algorithmique et sa grande popularité, l'algorithme du k -means possède plusieurs limitations théoriques et géométriques importantes. L'algorithme suppose implicitement que les groupes sont convexes, que les clusters possèdent une géométrie relativement isotrope et que les données sont séparables euclidiennement. Ces hypothèses deviennent rapidement restrictives dans des situations réelles.

Comme l'illustre la Figure 1.3, le k -means ne parvient pas à identifier les bons groupes. Le problème profond n'est pas algorithmique mais géométrique. Le k -means raisonne uniquement en termes de distances globales dans l'espace ambiant $\mathbb{R}^d$. Dans de nombreuses situations, la géométrie pertinente peut être en réalité locale, non linéaire, ou gouvernée par des notions de connectivité...

Pourquoi aller plus loin que le k -means ?

Le k -means repose sur une vision essentiellement euclidienne des données : les clusters sont recherchés comme des groupes compacts autour de centroïdes.

Cependant, deux observations peuvent être éloignées euclidiennement tout en appartenant à une même structure géométrique connectée. Inversement, des points proches peuvent appartenir à des régions très différentes des données.

Cette limitation motive une approche non seulement plus géométrique, mais aussi algébrique ! Représenter les données sous forme de graphe, étudier leur structure de connectivité, puis exploiter les propriétés spectrales du Laplacien du graphe afin de révéler les communautés naturelles présentes dans les données : c'est ce qu'on appelle le clustering spectral.

Chapitre 3

Graphes et structures de connectivité

Le clustering spectral repose entièrement sur une idée centrale : **transformer un nuage de points en un graphe afin d'étudier sa structure de connectivité**. Avant d'introduire les outils spectraux, il est donc nécessaire de définir rigoureusement ce qu'est un graphe et de comprendre pourquoi cet objet mathématique est particulièrement adapté à l'étude des clusters.

3.1 Un exemple motivant

On se place dans un contexte où l'on incarne une entreprise qui gère une plateforme *business to business* et l'on souhaite étudier le réseau entre les clients. On cherche à comprendre la relation entre eux pour adapter une stratégie qui conviendrait à tous les parties. Pour ce faire, on relève comme caractéristiques (covariables, standardisées dans ce schéma illustratif) le chiffre d'affaire $\mathbf{X}^1$ et le score d'interactions avec la plateforme client, noté $\mathbf{X}^2$. On peut donc placer dans un repère de $\mathbb{R}^2$ les points représentant chaque client.




FIGURE 3.1 – Exemple simple de graphe non orienté dans $\mathbb{R}^2$. Les sommets représentent des observations tandis que les arêtes modélisent des relations de proximité ou de similarité entre ces observations.

La Figure 3.1 illustre alors le réseau de clients représentés dans un espace de caractéristiques $(\mathbf{X}^1, \mathbf{X}^2)$. Chaque sommet correspond à un individu observé. Deux sommets sont reliés lorsqu'ils possèdent des profils jugés suffisamment similaires selon une métrique choisie. On peut imaginer que v_i et v_j sont connectés si les transactions ou accords d'achats signés entre-eux dépassent 10 unité par an.

Maintenant que l'on sait représenter les interactions entre clients sous forme de graphe, l'objectif devient d'identifier automatiquement des groupes d'entreprises possédant des comportements similaires ou fortement connectés entre eux. Comme dit plus haut, de tels regroupements peuvent avoir un intérêt stratégique majeur :

- proposer des offres commerciales adaptées à certains profils ;
- détecter des communautés de clients échangeant fortement entre elles ;
- ou encore recommander de nouveaux partenariats entre entreprises proches dans le graphe.

On aimerait donc disposer de méthodes d'apprentissage sur ces graphes capable de détecter automatiquement ces communautés à partir de la structure de connectivité du graphe.

3.2 Définition d'un graphe

Définition 3.2.1 (Graphe). Un graphe est un couple :

$$G = (V, E)$$

où :

- V est un ensemble de sommets ;
- $E \subseteq V \times V$ est un ensemble d'arêtes reliant certains sommets.

Les sommets représentent des objets ou observations, tandis que les arêtes représentent des relations entre ces objets.

Exemple 3.2.1. Les graphes interviennent naturellement dans tout contexte où l'on souhaite connecter les observations/individus (jouant le rôle de sommet ou *vertices*) et leur lien/connectivité (les arêtes ou *edges*).

Ex1 Dans un réseau social :

- les sommets représentent des utilisateurs ;
- les arêtes représentent des relations d'amitié ou d'interaction.

Ex2 Dans un problème de clustering : chaque sommet représente une observation et une arête relie deux observations jugées similaires.

3.3 Graphes pondérés

Dans de nombreuses situations réelles, toutes les connexions entre sommets ne possèdent pas la même importance. Certaines relations sont très fortes, d'autres beaucoup plus faibles. Il devient alors insuffisant de simplement indiquer si deux sommets sont connectés ou non : on souhaite également quantifier l'intensité de leur relation.

Cette pondération joue un rôle d'autant plus important dans un problème de clustering. Deux observations très similaires doivent être reliées par un poids élevé, tandis que deux observations peu proches doivent posséder une connexion faible, voire nulle. Cette approche permet de surcroît d'introduire une notion **progressive** de similarité plutôt qu'une séparation binaire rigide : les relations entre observations sont alors modélisées selon un continuum d'intensité, ce qui conduit généralement à des modèles géométriques et spectraux beaucoup plus riches.

Définition 3.3.1 (Graphe pondéré). Un graphe pondéré est un graphe muni d'une fonction :

$$w : V \times V \rightarrow \mathbb{R}_+,$$

où $w_{ij} = w(i, j)$ mesure l'intensité de la similarité entre les sommets i et j .

Remarque 2. Plus w_{ij} est grand, plus les sommets i et j sont considérés comme proches. Souvent $w_{ij} = 0$ signifie qu'aucune arête n'existe entre les sommets.

Exemple 3.3.1. Une façon très naturelle de construire une application de similarité consiste à transformer une distance en mesure de proximité. Supposons que :

$$\mathbf{X}_i, \mathbf{X}_j \in \mathbb{R}^p,$$

et que l'espace soit muni de la distance euclidienne :

$$d(\mathbf{x}^1, \mathbf{x}^2) = \sqrt{\sum_{k=1}^p (x_k^1 - x_k^2)^2}.$$

Une première idée consiste alors à définir une similarité inversement proportionnelle à la distance :

$$w_{ij} = \frac{1}{d(\mathbf{X}_i, \mathbf{X}_j)},$$

mais cette fonction présente plusieurs limitations, notamment lorsque la distance devient très petite. Une alternative extrêmement utilisée consiste à employer un noyau gaussien :

$$w_{ij} = \exp\left(-\frac{d(\mathbf{X}_i, \mathbf{X}_j)^2}{2\sigma^2}\right),$$

où $\sigma > 0$ est un paramètre contrôlant l'échelle locale des interactions. Ainsi :

- deux points très proches possèdent un poids proche de 1 ;
- deux points éloignés possèdent un poids proche de 0.

Le noyau gaussien joue un rôle fondamental en apprentissage statistique, en analyse spectrale et plus généralement dans les méthodes à noyau.

Représentation matricielle. Pour chaque pair (i, j) , on dispose d'un poids que l'on peut donc placer dans un tableau, mais pas n'importe lequel : une matrice. La représentation matricielle d'un graphe est fondamentale car elle permet de traduire un problème géométrique ou relationnel en un problème d'algèbre linéaire. Les outils spectraux (valeurs propres, vecteurs propres, Laplacien, diagonalisation, etc.) pourront alors être appliqués directement à ces matrices.

Définition 3.3.2 (Matrice d'adjacence). La matrice d'adjacence d'un graphe pondéré est :

$$W = (w_{ij})_{1 \leq i, j \leq n} \in \mathbb{R}^{n \times n}.$$

Lorsque le graphe est non orienté, c'est-à-dire que pour tout i, j , on a $w_{ij} = w_{ji}$, alors la matrice d'adjacence est symétrique et vérifie $W^\top = W$.

Remarque 3. Il est également possible de considérer des graphes orientés, pour lesquels la relation entre deux sommets n'est pas nécessairement symétrique. Par exemple, sur un réseau social, un utilisateur peut suivre un autre compte sans réciprocité (*follow* sans *followback*). Dans ce cas, la matrice d'adjacence n'est généralement plus symétrique.

Exemple 3.3.2. Considérons le graphe :

$$1 \longleftrightarrow 2 \longleftrightarrow 3.$$

Sa matrice d'adjacence est :

$$W = \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}.$$




FIGURE 3.2 – Illustration du graphe $1 \longleftrightarrow 2 \longleftrightarrow 3$. Les sommets 1 et 3 ne sont pas directement connectés, ce qui se traduit dans la matrice d'adjacence par $w_{13} = w_{31} = 0$.

3.4 Connectivité et composantes connexes

La notion de connectivité est fondamentale en clustering spectral.

Définition 3.4.1 (Chemin). Un chemin entre deux sommets i et j est une suite de sommets :

$$(i = v_0, v_1, \dots, v_k = j)$$

telle que chaque paire successive soit reliée par une arête.


Définition 3.4.2 (Composante connexe). Une composante connexe d'un graphe est un sous-ensemble maximal de sommets reliés entre eux par des chemins.

Concrètement, cela signifie qu'à l'intérieur d'une même composante connexe, tous les sommets communiquent, et qu'entre deux composantes distinctes, aucun chemin n'existe.

Exemple 3.4.1. Considérons le graphe :

$$1 \longleftrightarrow 2 \longleftrightarrow 3 \qquad 4 \longleftrightarrow 5.$$

Ce graphe possède deux composantes connexes : $\{1, 2, 3\}$ et $\{4, 5\}$.



On peut imaginer que ce graphe illustre deux scénarios précis :

1. Cinq individus sont décrits par deux covariables :

$$x^1 = \text{distance domicile-travail}, \qquad x^2 = \text{nombre d'enfants},$$

et est alors représenté par un point de $\mathbb{R}^2$ via $X_i = (x_i^1, x_i^2)$. On construit ensuite un graphe social :

- chaque sommet représente un individu ;
- une arête relie deux sommets lorsque les individus sont déjà amis.

Le graphe encode donc une structure sociale réelle au-dessus des variables observées.

Dans un problème de recommandation d'amis, l'objectif peut être de prédire quelles nouvelles arêtes devraient apparaître naturellement dans le graphe. Les individus fortement connectés indirectement ou proches dans l'espace des covariables peuvent alors être considérés comme candidats à une future relation sociale.

2. Considérons maintenant un ensemble de patients décrits par des données complexes : données biologiques, comptes-rendus médicaux, variables cliniques, embeddings issus d'un modèle de Deep Learning, ... Supposons qu'après réduction de dimension ou apprentissage de représentations, chaque patient soit représenté dans un espace latent de dimension 2 : $\mathbf{X}_i \in \mathbb{R}^2$. On souhaite construire un graphe de similarité entre patients. Pour cela, on définit :

$$w_{ij} = \exp \left(-\frac{\|\mathbf{X}_i - \mathbf{X}_j\|^2}{2\sigma^2} \right),$$

et l'on juge que deux patients sont alors reliés si $w_{ij} \geq \tau$ où : $\tau > 0$ désigne un seuil fixé. Ainsi :

- des patients très similaires dans l'espace latent deviennent fortement connectés ;
- des patients éloignés possèdent peu ou pas de connexion.

Le graphe obtenu peut alors révéler naturellement :

- des sous-types de patients ;
- des profils cliniques proches ;
- des communautés biologiques ;
- ou des groupes de risque similaires.

Le clustering spectral permettra ensuite d'exploiter cette structure de connectivité pour faire émerger automatiquement ces groupes latents.

3.5 Construire un graphe à partir des données

À partir d'un nuage de points, plusieurs méthodes permettent de construire un graphe. Certaines sont arbitraires, où une expertise extérieure aux données peut conclure au lien ou non. D'autres sont réglementaires via des métriques bien spécifiées, comme celles présentées ci-dessous.

Graphe ε -voisin. Deux sommets sont reliés si :

$$\|X_i - X_j\| \leq \varepsilon.$$

On connecte donc les observations suffisamment proches.

Graphe des k plus proches voisins. Pour chaque sommet X_i , on relie X_i à ses k plus proches voisins. Cette méthode peut être employée en clustering spectral.

Remarque 4. Le graphe obtenu encode alors la géométrie locale des données.

Poids gaussiens. Les arêtes peuvent également être pondérées par :

$$w_{ij} = \exp\left(-\frac{\|X_i - X_j\|^2}{2\sigma^2}\right).$$

Ainsi, les points proches possèdent un poids fort tandis que les points éloignés possèdent un poids faible.

3.6 Du clustering au graphe

L'objectif de ce cours étant de se concentrer sur le clustering spectral, on se doit d'en comprendre le paradigme essentiel : Un **cluster** peut être interprété comme une **région fortement connectée d'un graphe**.

Cette reformulation change profondément la manière d'aborder le problème du clustering. Dans les approches classiques, on cherche généralement à partitionner directement l'espace euclidien en régions géométriques compactes, souvent autour de centroïdes. Une telle vision devient cependant limitée dès que les données possèdent une géométrie complexe, non convexe ou fortement locale.

L'approche spectrale adopte un tout autre point de vue. Plutôt que de raisonner directement sur les coordonnées des observations, on cherche à comprendre comment les observations se connectent entre elles.

Dans notre représentation de graphe de similarité, un cluster correspond intuitivement à une région du graphe où les sommets possèdent de nombreuses connexions entre eux, les poids des arêtes internes sont importants et les chemins reliant les sommets sont nombreux et courts.

Inversement, deux clusters distincts sont généralement reliés par peu d'arêtes, souvent faibles. Les interactions entre ces régions deviennent alors rares, ce qui crée naturellement des zones de faible connectivité dans le graphe.

Idée géométrique profonde

Le clustering spectral ne cherche pas directement des groupes compacts dans l'espace ambiant. Il cherche plutôt des régions du graphe à l'intérieur desquelles la connectivité est forte, et entre lesquelles la connectivité devient faible.

Le problème du clustering devient alors un problème de géométrie sur graphe (*en particulier, algébrique*) où l'on cherche comment détecter automatiquement les grandes régions de connectivité du graphe.

3.7 Vers le Laplacien

Une fois le graphe construit, il devient nécessaire d'introduire des objets mathématiques capables de résumer sa structure de connectivité. Pour ce faire, on se munira d'un opérateur discret mesurant les variations d'une fonction sur le graphe, exactement comme le Laplacien continu mesure les variations secondes (courbure) locales d'une fonction dans le cadre différentiel. Pour cela, plusieurs matrices fondamentales interviennent naturellement.

La première est la **matrice d'adjacence**

$$W = (w_{ij})_{1 \leq i, j \leq n},$$

définie en 3.3.2. C'est elle qui encode les similarités entre sommets puisque chaque coefficient w_{ij} mesure l'intensité de la connexion entre les sommets i et j .

Cependant, cette matrice décrit uniquement les interactions *paire à paire*. Il est également naturel de vouloir mesurer le niveau global de connectivité d'un sommet avec l'ensemble du graphe. Pour cela, on introduit la **matrice de degré**. Pour un sommet donné i , on somme tous les poids des arêtes incidentes :

$$d_i = \sum_{j=1}^n w_{ij}.$$

Cette quantité mesure donc le poids total des connexions du **sommet i avec le reste du graphe**. Un sommet fortement relié à de nombreux voisins possèdera ainsi un degré important.

Définition 3.7.1 (Matrice de degré). Étant donné un graphe de matrice d'adjacence $W = (w_{ij})$, on définit la matrice de degré par :

$$D = \text{diag}(d_1, \dots, d_n), \quad d_i = \sum_{j=1}^n w_{ij}.$$

Enfin, une idée toute naturelle consiste alors à comparer ce qu'un sommet "reçoit" du graphe via son degré **contre** ce qu'il partage effectivement avec ses voisins via les poids de similarité. Cette différence conduit à l'objet central de toute l'analyse spectrale sur graphe : le **Laplacien**.

Définition 3.7.2 (Laplacien du graphe). Étant donné un graphe pondéré de matrice d'adjacence W et de matrice de degré D , on définit le Laplacien du graphe par :

$$L = D - W.$$

Cette définition peut sembler artificielle au premier abord, mais elle possède une interprétation géométrique et énergétique extrêmement profonde. En effet, le Laplacien compare la valeur d'une fonction en un sommet avec les valeurs prises sur ses voisins. Il mesure donc une forme de variation locale sur le graphe, exactement comme le Laplacien continu mesure les variations locales d'une fonction dans l'espace. Plus précisément, nous verrons que pour une fonction $f : V \rightarrow \mathbb{R}$, la quantité $f^\top L f$ s'écrit :

$$f^\top L f = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2.$$

Cette formule possède une interprétation fondamentale :

- si deux sommets fortement connectés prennent des valeurs très différentes, alors l'énergie devient grande ;
- inversement, une fonction de faible énergie varie peu sur les régions fortement connectées du graphe.

On étudiera en détail l'intérêt conceptuel de cette quantité et pourquoi les valeurs propres et vecteurs propres du Laplacien révèlent naturellement les structures cachées des données.

Exemple 3.7.1 (Exemple concret de fonction sur le graphe). Reprenons le graphe représentant les interactions entre cinq entreprises clientes, exposé en Figure 3.1. On dispose de $n = 5$ clients, avec $V = (v_1, v_2, v_3, v_4, v_5)$. On définit une fonction :

$$f : V \rightarrow \mathbb{R}$$

en associant à chaque sommet une quantité mesurant le niveau d’activité mensuel de l’entreprise sur la plateforme. Supposons :

$$f = \begin{pmatrix} 10 \\ 12 \\ 11 \\ 35 \\ 36 \end{pmatrix}.$$

Les entreprises v_1, v_2, v_3 possèdent alors des comportements proches, tandis que v_4, v_5 forment un second groupe d’activité beaucoup plus élevé. Le terme :

$$f^\top L f = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2$$

va mesurer alors l’énergie de variation de cette fonction sur le graphe. Intuitivement :

- si deux entreprises fortement connectées possèdent des niveaux d’activité très différents, alors l’énergie augmente fortement ;
- inversement, si les entreprises reliées possèdent des comportements proches, alors l’énergie reste faible.

Cet exemple nous donne bien des valeurs pour f relativement homogènes à l’intérieur de chaque groupe connecté :

$$10, 12, 11 \quad \text{et} \quad 35, 36.$$

La fonction possède donc une énergie relativement faible relativement à la structure du graphe. Elle respecte la géométrie de connectivité des données : les sommets fortement reliés prennent des valeurs proches. C’est d’ailleurs ce type de fonctions “lisses” sur le graphe que le clustering spectral cherche à construire et privilégiera via les premiers vecteurs propres du Laplacien.

Chapitre 4

Rappels en algèbre

Afin d’appréhender pleinement la puissance du clustering spectral, il est nécessaire de (ré)introduire en amont les outils fondamentaux d’algèbre et d’analyse spectrale, en particulier ceux qui étudient en profondeur les matrices **symétriques**.

4.1 Préambule algébrique : produit scalaire et formes quadratiques

Pour faire un tant soit peu d’analyse spectrale, il est indispensable d’évoquer et rappeler les notions liées au produit scalaire, à la transposée d’une matrice et aux formes quadratiques. Ces objets joueront un rôle central dans toute l’analyse spectrale via la diagonalisation, les valeurs propres, le quotient de Rayleigh qu’on aura la joie de rappeler plus tard, le Laplacien de graphe, et j’en passe.

4.1.1 Produit scalaire dans un espace préhilbertien

Avant de définir le produit scalaire euclidien usuel, on motive la notion plus générale sur $\mathbb{R}^p$. Cette approche permettra notamment de comprendre pourquoi certaines matrices symétriques définissent naturellement des géométries adaptées à un problème donné.

Matrices symétriques. On note :

$$\mathcal{S}_p = \{M \in \mathbb{R}^{p \times p} ; M^\top = M\}$$

l’ensemble des matrices symétriques réelles. Ces matrices joueront un rôle central en analyse spectrale et en machine learning en général. *Les rappels consacrés à la transposée se trouvent en Section 4.1.3.*

Produit scalaire d’un espace préhilbertien. Le produit scalaire est possiblement l’application bilinéaire la plus importante en algèbre et analyse fonctionnelle. Il induit naturellement une géométrie précise de l’espace, permet de définir la notion d’orthogonalité, construire des bases orthonormées, donne une intuition sur bon nombre de notions, quantifie l’énergie d’un objet (ou “vecteur”), etc. Pour correctement le définir, il suffit de lui demander de vérifier cinq propriétés bien précise.

Définition 4.1.1 (Produit scalaire). Soient les vecteurs quelconques $u, u_1, u_2, v, v_1, v_2 \in \mathbb{R}^p$ et un scalaire $\lambda \in \mathbb{R}$. On appelle produit scalaire sur $\mathbb{R}^p$ toute application

$$s : \mathbb{R}^p \times \mathbb{R}^p \rightarrow \mathbb{R}$$

vérifiant les propriétés suivantes :

1. s est une “forme” : $s(u, v) \in \mathbb{R}$;

2. s est “bilinéaire” :

$$s(\lambda u_1 + u_2, v) = \lambda s(u_1, v) + s(u_2, v);$$

$$s(u, \lambda v_1 + v_2) = \lambda s(u, v_1) + s(u, v_2)$$

3. s est “symétrique” :

$$s(u, v) = s(v, u);$$

4. s est “positive” :

$$s(u, u) \geq 0;$$

5. s est “séparable” (on dit aussi que s est “définie”) :

$$s(u, u) = 0 \iff u = \mathbf{0}.$$

Un espace vectoriel muni d’un produit scalaire est appelé espace **préhilbertien**.

Remarque 5. Le produit scalaire permet de généraliser les notions géométriques élémentaires comme la longueur, la distance, la mesure d’angle, l’orthogonalité et la projection, ... Toute la géométrie euclidienne découle de cette structure.

Norme induite. À tout produit scalaire est naturellement associée une norme :

$$\|\cdot\| : u \mapsto \|u\| = \sqrt{s(u, u)}.$$

Cette quantité mesure la longueur géométrique du vecteur u relativement au produit scalaire considéré. On peut vérifier que $\|\cdot\|$ vérifie naturellement :

(i) **Positivité et séparation**

$$\|u\| \geq 0, \quad \text{et} \quad \|u\| = 0 \iff u = \mathbf{0}.$$

(ii) **Multiplication par un scalaire**

$$\|\lambda u\| = |\lambda| \|u\|.$$

(iii) **Inégalité triangulaire**

$$\|u + v\| \leq \|u\| + \|v\|.$$

Produits scalaires induits par des matrices symétriques définies positives. Un exemple fondamental de produit scalaire est obtenu à partir d’une matrice symétrique définie positive.

Définition 4.1.2 (Matrice symétrique définie positive). Une matrice symétrique $A \in \mathcal{S}_p$ est dite définie positive si pour tout vecteur **non nul** $u \in \mathbb{R}^p$:

$$u^\top A u > 0$$

S’en suit une proposition importante, généralisant tout produit scalaire en dimension finie.

Proposition 4.1.1. Soit $A \in \mathbb{R}^{p \times p}$ une matrice symétrique définie positive. Alors l’application

$$(u, v) \mapsto u^\top A v$$

définit un produit scalaire sur $\mathbb{R}^p$.

Preuve. Vérifions les propriétés d'un produit scalaire.

(i) **Forme.** Pour tout $u, v \in \mathbb{R}^p$, l'image $u^\top Av$ est bien un scalaire de $\mathbb{R}$.

(ii) **Linéarité.**

Pour tout $\lambda \in \mathbb{R}$, on a :

$$(\lambda u_1 + u_2)^\top Av = \lambda u_1^\top Av + u_2^\top Av.$$

(iii) **Symétrie.**

Comme A est symétrique :

$$A^\top = A.$$

Ainsi :

$$u^\top Av = (u^\top Av)^\top = v^\top A^\top u = v^\top Au.$$

Donc :

$$u^\top Av = v^\top Au.$$

(iv) **Positivité.**

Comme A est définie-positve *par définition/hypothèse même* :

$$u^\top Au \geq 0$$

avec

$$u^\top Au = 0 \iff u = \mathbf{0}.$$

Toutes les propriétés sont donc satisfaites. (*La linéarité à gauche + la symétrie démontrées, on en conclut directement par induction la linéarité à droite !*) $\square$

Interprétation géométrique

La matrice A modifie la géométrie de l'espace, au sens où tout vecteur sur lequel elle va opérer va être naturellement modifié (on peut –en dimension finie– réduire cette étude à l'image de A sur la base canonique de $\mathbb{R}^p$). Le produit scalaire $u^\top Av$ ne mesure plus les angles et distances euclidiens usuels, mais une géométrie adaptée à la structure portée par A .

Remarque 6. Le produit scalaire euclidien classique correspond au cas particulier $A = I_p$. On retrouve alors :

$$u^\top I_p v = u^\top v.$$

L'inégalité de Cauchy–Schwarz. L'inégalité de Cauchy–Schwarz constitue l'un des résultats les plus fondamentaux de toute la géométrie euclidienne et hilbertienne. Elle exprime le fait que le produit scalaire entre deux vecteurs ne peut jamais être arbitrairement grand relativement à leurs normes.

Dans un espace muni d'un produit scalaire quelconque, cette inégalité permet notamment de contrôler les angles, de définir rigoureusement la notion de distance, d'établir l'inégalité triangulaire et plus généralement de développer toute la géométrie de l'espace.

Théorème 4.1.1 (Cauchy–Schwarz). *Soit $(E, \langle \cdot, \cdot \rangle)$ un espace préhilbertien réel.*

Alors, pour tous $x, y \in E$, on a :

$$|\langle x, y \rangle| \leq \|x\| \|y\|.$$

Preuve. Considérons, pour tout $t \in \mathbb{R}$, la quantité :

$$P(t) = \|tx + y\|^2.$$

Comme une norme au carré est toujours positive :

$$P(t) \geq 0.$$

Développons cette expression à l'aide du produit scalaire :

$$P(t) = \langle tx + y, tx + y \rangle.$$

Par bilinéarité :

$$P(t) = t^2 \langle x, x \rangle + 2t \langle x, y \rangle + \langle y, y \rangle.$$

Ainsi :

$$P(t) = t^2 \|x\|^2 + 2t \langle x, y \rangle + \|y\|^2.$$

On obtient donc un polynôme du second degré :

$$P(t) = at^2 + bt + c,$$

avec :

$$a = \|x\|^2, \quad b = 2\langle x, y \rangle, \quad c = \|y\|^2.$$

Comme $P(t) \geq 0$ pour tout t , son discriminant est nécessairement négatif ou nul :

$$\Delta_P = b^2 - 4ac \leq 0.$$

Donc :

$$4\langle x, y \rangle^2 - 4\|x\|^2\|y\|^2 \leq 0.$$

En divisant par 4 :

$$\langle x, y \rangle^2 \leq \|x\|^2\|y\|^2.$$

Finalement :

$$|\langle x, y \rangle| \leq \|x\| \|y\|.$$

□

Remarque 7. L'égalité dans Cauchy-Schwarz a lieu si et seulement si les vecteurs x et y sont colinéaires. Géométriquement, cela signifie que le produit scalaire atteint sa valeur maximale lorsque les deux vecteurs pointent exactement dans la même direction.

Importance fondamentale

L'inégalité de Cauchy-Schwarz intervient partout en mathématiques :

- en géométrie euclidienne ;
- en probabilités ;
- en analyse fonctionnelle ;
- en optimisation ;
- en apprentissage automatique ;
- et dans toute théorie énergétique fondée sur un produit scalaire.

Elle constitue le mécanisme fondamental permettant de contrôler les interactions entre deux objets via leur énergie propre.

4.1.2 Produit scalaire euclidien

Définition 4.1.3 (Produit scalaire euclidien). Pour tous vecteurs $x, y \in \mathbb{R}^p$, on définit le produit scalaire euclidien par :

$$\langle x, y \rangle = x^\top y = \sum_{i=1}^p x_i y_i.$$

Remarque 8. Le produit scalaire mesure :

- ✓ la proximité géométrique entre deux vecteurs ;
- ✓ leur alignement ;
- ✓ les notions d'orthogonalité et de projection.

En particulier :

$$\langle x, y \rangle = 0$$

signifie que les vecteurs sont **orthogonaux**.

Norme euclidienne associée. Puisque le produit scalaire induit naturellement la norme euclidienne

$$\|x\| = \sqrt{\langle x, x \rangle},$$

on retrouve alors :

$$\|x\|^2 = x^\top x.$$

Cette quantité représente l'énergie géométrique du vecteur.

4.1.3 Rôle de la transposée

Définition 4.1.4 (Transposée). Soit $M = (m_{ij}) \in \mathbb{R}^{n \times p}$. La transposée de M est la matrice :

$$M^\top = (m_{ji}) \in \mathbb{R}^{p \times n}.$$

Propriétés fondamentales. La transposée a pour caractéristique fondamentale d'être une **invololution linéaire** : en plus d'être une application linéaire avec toutes les vertus qu'on lui reconnaît, vue comme opérateur, si on l'applique deux fois, on obtient l'opérateur de l'identité et on retombe sur la matrice initiale. Plus profondément encore, la transposition exprime une **dualité**. Une matrice $A \in \mathbb{R}^{m \times n}$ représente une application linéaire

$$A : \mathbb{R}^n \rightarrow \mathbb{R}^m.$$

Sa transposée représente l'application linéaire

$$A^\top : \mathbb{R}^m \rightarrow \mathbb{R}^n,$$

qui agit sur l'espace dual via le produit scalaire. Appliquer deux fois la transposée revient donc à effectuer deux passages successifs entre l'espace primal et son dual. Comme cette correspondance est canonique et involutive, on retrouve nécessairement l'opérateur initial.

Proposition 4.1.2 (Propriétés de la transposée). Soient $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{n \times p}$ et un scalaire $\lambda \in \mathbb{R}$.

1. Linéarité : $(A + \lambda B)^\top = A^\top + \lambda B^\top$.
2. Involution : $(A^\top)^\top = A$.
3. Produit : $(AB)^\top = B^\top A^\top$.
4. Inverse (quand elle existe) : $(A^{-1})^\top = (A^\top)^{-1}$.

Preuve. On note $A = (a_{ij})_{\substack{1 \leq i \leq m \\ 1 \leq j \leq n}}$ et $B = (b_{ij})_{\substack{1 \leq i \leq n \\ 1 \leq j \leq p}}$. Soit $\lambda \in \mathbb{R}$. On part de la définition :

$$(A^\top)_{ij} = a_{ji}.$$

1. **Linéarité.** Pour tout i, j , on a

$$((A + \lambda B)^\top)_{ij} = (A + \lambda B)_{ji} = a_{ji} + \lambda b_{ji}.$$

D'autre part,

$$(A^\top + \lambda B^\top)_{ij} = (A^\top)_{ij} + \lambda (B^\top)_{ij} = a_{ji} + \lambda b_{ji}.$$

Les coefficients coïncident pour tout i, j , donc

$$(A + \lambda B)^\top = A^\top + \lambda B^\top.$$

2. **Involution.** Pour tout i, j ,

$$((A^\top)^\top)_{ij} = (A^\top)_{ji} = a_{ij}.$$

Ainsi $(A^\top)^\top$ et A ont les mêmes coefficients, donc

$$(A^\top)^\top = A.$$

3. **Produit.** Soit $A \in \mathbb{R}^{m \times n}$ et $B \in \mathbb{R}^{n \times p}$, alors $AB \in \mathbb{R}^{m \times p}$. Pour tout i, j ,

$$((AB)^\top)_{ij} = (AB)_{ji} = \sum_{k=1}^n a_{jk} b_{ki}.$$

D'autre part, $B^\top A^\top \in \mathbb{R}^{p \times m}$ et

$$(B^\top A^\top)_{ij} = \sum_{k=1}^n (B^\top)_{ik} (A^\top)_{kj} = \sum_{k=1}^n b_{ki} a_{jk}.$$

Les deux sommes sont égales terme à terme (commutativité dans $\mathbb{R}$), donc

$$(AB)^\top = B^\top A^\top.$$

4. **Inverse (quand elle existe).** Supposons $A \in \mathbb{R}^{n \times n}$ inversible. On part de l'identité

$$AA^{-1} = I_n.$$

En transposant et en utilisant la propriété (3) déjà établie, on obtient

$$(AA^{-1})^\top = I_n^\top \implies (A^{-1})^\top A^\top = I_n.$$

De même, en transposant $A^{-1}A = I_n$, on obtient

$$(A^{-1}A)^\top = I_n^\top \implies A^\top (A^{-1})^\top = I_n.$$

Ainsi $(A^{-1})^\top$ est à la fois inverse à droite et inverse à gauche de $A^\top$, donc c'est l'inverse de $A^\top$:

$$(A^{-1})^\top = (A^\top)^{-1}.$$

Les quatre propriétés essentielles de la transposée sont démontrées. $\square$

Remarque 9. La transposée permet de faire apparaître naturellement le produit scalaire dans les calculs matriciels. Par exemple, le terme $x^\top y$ est un scalaire obtenu en “combinant” un vecteur ligne avec un vecteur colonne. Toute la géométrie euclidienne peut ainsi être reformulée sous forme matricielle.

4.1.4 Compatibilité matricielle fondamentale

Propriété 4.1.1. Pour toute matrice $M \in \mathbb{R}^{p \times p}$ et tous vecteurs $x, y \in \mathbb{R}^p$, on a :

$$\langle Mx, y \rangle = \langle x, M^\top y \rangle.$$

Preuve. Par définition du produit scalaire $\langle Mx, y \rangle = (Mx)^\top y$.

Or $(Mx)^\top = x^\top M^\top$.

Donc :

$$(Mx)^\top y = x^\top M^\top y = \langle x, M^\top y \rangle.$$

□

Interprétation fondamentale

La relation

$$\langle Mx, y \rangle = \langle x, M^\top y \rangle$$

signifie que la transposée $M^\top$ est l'opérateur qui “transfère” l'action de M d'un vecteur vers l'autre à l'intérieur du produit scalaire. On dit alors que $M^\top$ est l'**adjoint** de M relativement au produit scalaire euclidien, et c'est une notion qui permet d'étudier en détail comment une transformation linéaire interagit avec la géométrie de l'espace (conservation des angles, projection, orthogonalité, diagonalisation, énergie...) En particulier, lorsque :

$$M^\top = M,$$

la matrice est dite **auto-adjointe** (ou symétrique réelle).

Cette symétrie géométrique explique pourquoi les matrices symétriques possèdent des valeurs propres réelles et des vecteurs propres orthogonaux. Toute l'analyse spectrale moderne repose profondément sur cette propriété.

4.1.5 Importance de la quantité $\langle Mx, x \rangle$

Supposons ici $M \in \mathcal{S}_p(\mathbb{R})$ **symétrique** (on peut généraliser dans $\mathbb{C}$ en supposant M “hermitienne”, dit encore “auto-adjointe”). Dans ce cas, on sait par théorème spectral que M est nécessairement diagonalisable dans $\mathbb{R}$:

$$\exists P \in \mathcal{O}_p(\mathbb{R}), \exists \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p), \quad M = P\Lambda P^\top,$$

où l'ensemble des matrices orthogonales de taille p à coefficients réels est noté $\mathcal{O}_p(\mathbb{R})$. La géométrie induite par la matrice symétrique M permet de définir clairement la quantité issue du produit scalaire

$$\langle Mx, x \rangle = x^\top M^\top x = x^\top Mx.$$

Elle porte un nom bien précis : c'est une **forme quadratique**. Une matrice symétrique définie positive agit naturellement comme un opérateur mesurant une énergie ou une géométrie sur l'espace vectoriel. La quantité $x^\top Mx$ associe alors un scalaire à chaque vecteur x , en tenant compte de la géométrie induite par M .

Définition 4.1.5 (Forme quadratique). Soit $M \in \mathcal{S}_p$ **symétrique réelle**. La fonction

$$q_M : x \mapsto q_M(x) = x^\top Mx$$

est appelée forme quadratique associée à la matrice M .

Cette quantité intervient partout en mathématiques appliquées : optimisation, mécanique, statistiques, énergie variationnelle, Laplacien, clustering spectral, ...

Exemple 4.1.1. Si $M = I_p$, alors :

$$x^\top Mx = x^\top x = \|x\|^2.$$

La forme quadratique généralise donc naturellement la notion de norme (ou “énergie”) euclidienne.

Quid de la positivité ? Supposons maintenant que $A \in \mathcal{S}_p(\mathbb{R})$ est **positive**, c’est-à-dire que pour tout vecteur $x \in \mathbb{R}^p$:

$$x^\top Ax \geq 0.$$

Alors, la forme bilinéaire associée

$$\langle Ax, y \rangle = \langle x, y \rangle_A$$

va induire une géométrie bien définie. En effet, la matrice A agit comme un opérateur géométrique qui mesure des longueurs, des angles ou des énergies relativement à une nouvelle géométrie de l’espace. Les directions associées aux grandes valeurs propres sont davantage “pondérées”, tandis que les directions associées aux petites valeurs propres sont comprimées. La matrice A déforme donc l’espace selon ses directions propres, tout en conservant une structure géométrique cohérente grâce à sa symétrie et à sa positivité.

Une propriété remarquable et naturellement induite par ce type de matrice est que ses valeurs propres sont nécessairement positives.

Proposition 4.1.3. Soit $M \in \mathcal{S}_p(\mathbb{R})$ symétrique positive. Alors toutes les valeurs propres de M sont positives :

$$\text{Sp}(M) \subset \mathbb{R}_+.$$

Preuve.

Soit $\lambda \in \text{Sp}(M)$ une valeur propre de M associé au vecteur propre $x \in \mathbb{R}^p \setminus \{0\}$ (nécessairement non nul) : $Mx = \lambda x$. Comme M est positive,

$$x^\top Mx \geq 0.$$

On est donc naturellement amené à travailler sur l’image numérique de M . Observons que :

$$x^\top Mx = x^\top (\lambda x) = \lambda x^\top x.$$

De plus,

$$x^\top x = \|x\|^2 > 0$$

puisque $x \neq 0$. Ainsi :

$$\lambda = \frac{x^\top Mx}{x^\top x} \geq 0.$$

Toutes les valeurs propres de M sont donc positives. □

Vers un produit scalaire induit par une matrice. La positivité d’une matrice symétrique ne garantit pas seulement la positivité de ses valeurs propres. Elle permet également de construire une nouvelle géométrie sur l’espace vectoriel. Une matrice symétrique définie positive permet en effet de définir une notion cohérente de longueur, d’angle et d’orthogonalité via une nouvelle forme bilinéaire.

Proposition 4.1.4. Soit $A \in \mathcal{S}_p(\mathbb{R})$ symétrique définie positive. Alors l'application

$$\begin{aligned} \langle \cdot, \star \rangle_A : \mathbb{R}^p \times \mathbb{R}^p &\rightarrow \mathbb{R} \\ (x, y) &\mapsto \langle x, y \rangle_A = x^\top A y \end{aligned}$$

définit un produit scalaire sur $\mathbb{R}^p$.

Preuve.

Montrons les trois propriétés caractéristiques d'un produit scalaire.

(i) Bilinéarité.

Comme le produit matriciel est linéaire,

$$\langle \alpha x + \beta z, y \rangle_A = (\alpha x + \beta z)^\top A y = \alpha x^\top A y + \beta z^\top A y.$$

Ainsi,

$$\langle \alpha x + \beta z, y \rangle_A = \alpha \langle x, y \rangle_A + \beta \langle z, y \rangle_A.$$

De même, la linéarité vaut par rapport à la seconde variable.

(ii) Symétrie.

Comme A est symétrique, $A^\top = A$, ce qui induit :

$$\langle x, y \rangle_A = x^\top A y = (x^\top A y)^\top = y^\top A^\top x = y^\top A x.$$

Ainsi,

$$\langle x, y \rangle_A = \langle y, x \rangle_A.$$

(iii) Positivité.

Comme A est définie positive,

$$\forall x \neq 0, \quad x^\top A x > 0.$$

Ainsi :

$$\forall x \neq 0, \quad \langle x, x \rangle_A = x^\top A x > 0.$$

La forme bilinéaire est donc définie positive.

Les trois propriétés étant vérifiées, l'application $\langle \cdot, \star \rangle_A$ définit bien un produit scalaire sur $\mathbb{R}^p$. $\square$

Interprétation. Cette construction montre qu'une matrice symétrique définie positive ne se contente pas d'agir algébriquement sur les vecteurs : elle modifie la géométrie même de l'espace tout en conservant une cohérence algébrique.

Les directions propres associées aux grandes valeurs propres deviennent plus "coûteuses" énergétiquement, tandis que les directions associées aux petites valeurs propres sont moins pénalisées. La matrice A agit donc comme un tenseur géométrique qui déforme l'espace selon ses directions propres.

La quantité $x^\top A x = \langle x, x \rangle_A$ joue alors naturellement le rôle d'une énergie, d'une norme quadratique ou d'un coût géométrique, interprétation bien centrale dans toute l'analyse spectrale moderne.

Remarque 10. Quelques remarques sur les hypothèses exigées sur A :

- La symétrie de A est nécessaire afin d'obtenir un produit scalaire symétrique : $\langle x, y \rangle_A = \langle y, x \rangle_A$.
- La définie-positivité est quant à elle nécessaire pour garantir : $\langle x, x \rangle_A > 0$.
- En revanche, pour définir simplement une forme bilinéaire $(x, y) \mapsto x^\top A y$, aucune hypothèse particulière sur A n'est requise.
- De même, pour définir une forme quadratique $x \mapsto x^\top A x$, il suffit de considérer la partie symétrique de A , car la partie antisymétrique n'intervient jamais dans cette expression.

4.1.6 La forme quadratique comme quantification d'énergie

Supposons $A \in \mathcal{S}_p(\mathbb{R})$ une matrice symétrique réelle. La quantité

$$q_A(x) = x^\top A x = \langle x, Ax \rangle$$

apparaît naturellement comme une mesure d'énergie associée à l'action de la transformation A sur le vecteur x .

Conceptuellement, le vecteur Ax représente la réponse, la résultante ou encore l'effet produit par l'opérateur A sur l'état initial x . Le produit scalaire $\langle x, Ax \rangle$ mesure alors le “travail” ou l'intensité de cette action relativement à la direction initiale x . Concrètement, la forme quadratique quantifie à quel point la transformation A agit énergétiquement sur le vecteur x . Cette interprétation apparaît dans de nombreux domaines :

→ En mécanique classique, l'énergie cinétique d'une particule s'écrit :

$$E_c = \frac{1}{2}mv^2,$$

ce qui constitue déjà une forme quadratique en la vitesse. L'énergie potentielle d'un ressort obéissant à la loi de Hooke est :

$$E_p = \frac{1}{2}kx^2,$$

autre exemple fondamental de quantité quadratique.

→ Dans les phénomènes ondulatoires, l'énergie d'une vibration ou d'un signal est souvent donnée par :

$$\int |f(t)|^2 dt \quad \text{ou} \quad \int \|\nabla f(x)\|^2 dx.$$

Ces expressions mesurent l'intensité globale des oscillations ou des variations spatiales du système.

→ En statistique et en apprentissage automatique, cette même structure apparaît encore. Par exemple, en régression linéaire, la quantité :

$$\|Y - X\beta\|^2$$

mesure l'énergie résiduelle du modèle, c'est-à-dire l'amplitude globale des erreurs de prédiction.

Les formes quadratiques jouent donc un rôle universel car elles permettent de mesurer une intensité indépendamment du signe, tout en restant compatibles avec la géométrie euclidienne et les propriétés du produit scalaire. Elles constituent ainsi les objets naturels pour modéliser des énergies, des variances, des phénomènes de diffusion ou encore des coûts d'optimisation. Cette omniprésence explique pourquoi les formes quadratiques sont au cœur de l'analyse spectrale, de la physique mathématique et du machine learning moderne.

4.2 Matrices orthonormées

Définition 4.2.1. Une matrice carrée $M \in \mathbb{R}^{p \times p}$ est dite orthonormée si

$$M^\top M = I_p \quad \Longleftrightarrow \quad M^{-1} = M^\top.$$

On a précédemment évoqué l'idée selon laquelle la transposée de M à l'intérieur du produit scalaire “transportait” l'action de M de x vers y via l'identité $\langle Mx, y \rangle = \langle x, M^\top y \rangle$. Dans le cas d'une matrice orthonormée, la transposée coïncide précisément avec l'inverse, signifiant donc que l'action de M ne déforme pas la géométrie de l'espace. Appliquer $M^\top$ revient exactement à “annuler” l'action de M . Les longueurs, les angles et le produit scalaire sont de fait conservés.

Une matrice orthonormée représente une transformation géométrique “rigide” de l'espace : rotation, symétrie ou combinaison de telles transformations, sans dilatation ni écrasement.

Propriété 4.2.1. Une matrice est orthonormée si et seulement si ses colonnes forment une base orthonormée de $\mathbb{R}^p$.

Preuve. Notons $C_1, \dots, C_p$ les colonnes de M . Alors

$$M^\top M = \begin{pmatrix} \langle C_1, C_1 \rangle & \cdots & \langle C_1, C_p \rangle \\ \vdots & \ddots & \vdots \\ \langle C_p, C_1 \rangle & \cdots & \langle C_p, C_p \rangle \end{pmatrix}.$$

Rappelons nous que M vérifie

$$M^\top M = I_p,$$

ce qui équivaut **terme à terme** à :

$$\langle C_i, C_j \rangle = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{sinon.} \end{cases}$$

Cela signifie exactement que les colonnes forment une base orthonormée. $\square$

Remarque 11. Les matrices orthonormées jouent un rôle fondamental en analyse spectrale car elles représentent des transformations géométriques qui préservent entièrement la structure euclidienne de l'espace. En particulier, si M est orthonormée, l'image par M de n'importe quel vecteur voit sa norme conservée.

Proposition 4.2.1 (Conservation du produit scalaire et de la norme). Soit $M \in \mathbb{R}^{p \times p}$ une matrice orthonormée, i.e., $M^\top M = I_p$. Alors, pour tous vecteurs $x, y \in \mathbb{R}^p$, on a :

$$\langle Mx, My \rangle = \langle x, y \rangle.$$

En particulier, $\|Mx\| = \|x\|$.

Preuve. Par définition du produit scalaire euclidien :

$$\langle Mx, My \rangle = (Mx)^\top (My).$$

Or $(Mx)^\top = x^\top M^\top$. Donc :

$$\langle Mx, My \rangle = x^\top M^\top My.$$

Comme M est orthonormée, $M^\top M = I_p$. Ainsi :

$$\langle Mx, My \rangle = x^\top I_p y = x^\top y = \langle x, y \rangle.$$

On en déduit la conservation de la norme en prenant $y = x$:

$$\|Mx\|^2 = \langle Mx, Mx \rangle = \langle x, x \rangle = \|x\|^2.$$

Comme les normes sont positives, on applique simplement l'application racine carrée pour finalement obtenir :

$$\|Mx\| = \|x\|.$$

$\square$

Une telle transformation ne déforme ni les longueurs, ni les angles, ni les distances. Les changements de base orthonormés permettent ainsi d'étudier une matrice dans un nouveau système de coordonnées sans altérer la géométrie intrinsèque du problème. Cette propriété sera essentielle dans le théorème spectral, où les matrices symétriques pourront être diagonalées dans une base orthonormée de vecteurs propres.

4.3 Le théorème spectral

C'est LE théorème absolu en algèbre linéaire à connaître. Il induit une pléthore de résultats tous essentiels en mathématiques (ACP, SVD, Spectral Clustering, ...). Pour cause, toute matrice symétrique est non seulement nécessairement diagonalisable, mais en plus ses valeurs propres sont réelles. On ajoute enfin comme propriété que la base propre peut être prise comme orthonormée ! La géométrie induite par une matrice symétrique est stable en bons nombres de points appréciable, tant pour ses propriétés algébriques que pour sa capacité computationnelle et algorithmique appliquée.

Théorème 4.3.1 (Théorème spectral). *Soit $A \in \mathcal{S}_p(\mathbb{R})$ une matrice symétrique réelle. Alors :*

- toutes les valeurs propres de A sont réelles ;
- A est diagonalisable ;
- il existe une base orthonormée de vecteurs propres de A .

Formellement, on peut l'écrire comme :

$$A = PDP^T,$$

avec P orthogonal et $D = \text{diag}(\lambda_1, \dots, \lambda_p)$ avec chaque $\lambda_i \in \mathbb{R}$.

Preuve. La démonstration repose sur deux idées fondamentales :

1. Une matrice symétrique possède des valeurs propres réelles ;
2. Deux vecteurs propres associés à des valeurs propres distinctes sont orthogonaux.

1) Les valeurs propres sont réelles.

Soit $\lambda \in \mathbb{C}$ une valeur propre de A et soit $z \in \mathbb{C}^p$ un vecteur propre non nul associé :

$$Az = \lambda z.$$

Comme A est réelle symétrique, on a : $A^T = A$. En particulier, son adjoint est elle-même : $A^* = A$. On note $\bar{z}$ le conjugué complexe de z et son adjoint par $z^* = \bar{z}^T$. Alors :

$$z^*Az = z^*(\lambda z) = \lambda z^*z. \quad (4.1)$$

Or :

$$z^*z = \|z\|^2 > 0.$$

D'autre part, puisque A est symétrique réelle :

$$(z^*Az)^* = z^*A^Tz = z^*Az.$$

Donc z^*Az est réel puisqu'il est égal à son adjoint. Ainsi, la valeur propre λ est réelle. En effet, en réarrangeant l'expression (4.1) :

$$\lambda = \frac{z^*Az}{z^*z} \in \mathbb{R}.$$

Toutes les valeurs propres de A sont donc réelles.

2) Orthogonalité des espaces propres associés à des valeurs propres distinctes.

Soient $u, v \in \mathbb{R}^p$ deux vecteurs propres de A associés à deux valeurs propres distinctes $\lambda \neq \mu$:

$$Au = \lambda u, \quad Av = \mu v.$$

On calcule de deux manières le produit scalaire $\langle Au, v \rangle$.

D'une part :

$$\langle Au, v \rangle = \langle \lambda u, v \rangle = \lambda \langle u, v \rangle.$$

D'autre part, comme A est symétrique :

$$\langle Au, v \rangle = \langle u, A^\top v \rangle = \langle u, Av \rangle = \langle u, \mu v \rangle = \mu \langle u, v \rangle.$$

Donc :

$$\lambda \langle u, v \rangle = \mu \langle u, v \rangle.$$

Ainsi :

$$(\lambda - \mu) \langle u, v \rangle = 0.$$

Comme $\lambda \neq \mu$, on obtient :

$$\langle u, v \rangle = 0.$$

Les vecteurs propres associés à des valeurs propres distinctes sont donc orthogonaux.

3) Existence d'une base orthonormée de vecteurs propres.

Comme A est une matrice réelle symétrique, son polynôme caractéristique est de degré p . Il admet donc au moins une racine complexe (théorème de d'Alembert, $\mathbb{C}$ est "algébriquement clos"). D'après la première partie, toute valeur propre complexe éventuelle est en réalité réelle. Il existe donc une valeur propre réelle λ_1 et un vecteur propre réel non nul u_1 tel que :

$$Au_1 = \lambda_1 u_1.$$

On normalise ce vecteur :

$$e_1 = \frac{u_1}{\|u_1\|}.$$

Considérons maintenant l'orthogonal de $\text{Vect}(e_1)$:

$$E_1^\perp = \{x \in \mathbb{R}^p ; \langle x, e_1 \rangle = 0\}.$$

Montrons que cet espace est stable par A .

Montrer que $E_1^\perp$ est **stable par A** signifie que :

$$x \in E_1^\perp \implies Ax \in E_1^\perp,$$

c'est-à-dire que l'action de la matrice A ne fait pas "sortir" les vecteurs de cet espace orthogonal. Si on montre cela, alors on peut restreindre l'étude de A à un sous-espace de dimension plus petite, tout en conservant la symétrie de l'opérateur. Sachant que l'axe propre E_1 est naturellement stable par définition, alors par l'action de A , on sépare en somme direct l'espace $\mathbb{R}^p$ distinctement.

Soit $x \in E_1^\perp$. Alors :

$$\langle Ax, e_1 \rangle = \langle x, Ae_1 \rangle$$

car A est symétrique.

Or :

$$Ae_1 = \lambda_1 e_1.$$

car e_1 est simplement le vecteur propre u_1 normalisé.

Donc :

$$\langle Ax, e_1 \rangle = \langle x, Ae_1 \rangle = \langle x, \lambda_1 e_1 \rangle = \lambda_1 \langle x, e_1 \rangle = 0,$$

car x est dans l'orthogonal de E_1 . L'espace $E_1^\perp$ est donc stable par A .

Cette propriété est fondamentale : elle signifie que l'action de A ne fait pas sortir les vecteurs de $E_1^\perp$ hors de cet espace. On peut donc restreindre l'application linéaire associée à A à :

$$A|_{E_1^\perp} : E_1^\perp \rightarrow E_1^\perp.$$

Après avoir extrait une première direction propre e_1 , la matrice A continue d'agir naturellement sur tout l'espace orthogonal restant, ce que l'on peut puissamment formaliser par la décomposition orthogonale :

$$\mathbb{R}^p = \text{Vect}(e_1) \oplus E_1^\perp.$$

De plus :

$$\dim(E_1^\perp) = p - 1.$$

La restriction $A|_{E_1^\perp}$ reste bien entendu symétrique, car pour tous $x, y \in E_1^\perp$, on conserve :

$$\langle Ax, y \rangle = \langle x, Ay \rangle.$$

Le polynôme caractéristique de $A|_{E_1^\perp}$ est alors de degré $p - 1$. Comme $\mathbb{C}$ est algébriquement clos, ce polynôme est scindé sur $\mathbb{C}$ et possède au moins une racine complexe.

En reprenant exactement le même raisonnement que précédemment, on montre que cette valeur propre est nécessairement réelle. Il existe donc un vecteur propre non nul $u_2 \in E_1^\perp$ tel que

$$A|_{E_1^\perp}(u_2) = \lambda_2 u_2.$$

Après normalisation :

$$e_2 = \frac{u_2}{\|u_2\|},$$

on obtient un second vecteur propre unitaire. Comme $e_2 \in E_1^\perp$ on a automatiquement :

$$\langle e_1, e_2 \rangle = 0.$$

On peut alors répéter exactement le même raisonnement sur :

$$\text{Vect}(e_1, e_2)^\perp,$$

puis récursivement sur les orthogonaux successifs. En poursuivant cette construction, on obtient finalement une famille :

$$(e_1, \dots, e_p)$$

de vecteurs propres unitaires deux à deux orthogonaux. Cette famille contient p vecteurs orthonormés dans un espace de dimension p ; elle forme donc une base orthonormée de $\mathbb{R}^p$.

4) Diagonalisation orthogonale.

Soit P la matrice dont les colonnes sont les vecteurs propres :

$$P = \begin{pmatrix} | & | & & | \\ e_1 & e_2 & \cdots & e_p \\ | & | & & | \end{pmatrix}.$$

Comme $(e_1, \dots, e_p)$ est une base orthonormée :

$$P^\top P = I_p.$$

Donc P est orthogonale. De plus, par définition et construction, pour chaque $j \in \{1, \dots, p\}$:

$$Ae_j = \lambda_j e_j.$$

Cela signifie matriciellement :

$$AP = P\Lambda,$$

où :

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p).$$

En multipliant à gauche par $P^\top$, on obtient $P^\top AP = \Lambda$, donc *in fine* :

$$A = P\Lambda P^\top.$$

Ainsi, A est diagonalisable dans une base orthonormée de vecteurs propres.

□

Anecdote terminologique. La terminologie *spectrale* provient du mot *spectre*, introduit dans la théorie des opérateurs au début du XX^e siècle par analogie avec la décomposition spectrale de la lumière. De la même manière qu'un prisme décompose une lumière blanche en différentes fréquences colorées, le théorème spectral affirme qu'un opérateur symétrique (ou auto-adjoint) peut être décomposé selon ses valeurs propres. Le *spectre* d'une matrice A désigne précisément l'ensemble de ses valeurs propres :

$$\text{Sp}(A) = \{\lambda \in \mathbb{C} \mid \det(A - \lambda I) = 0\}.$$

Ainsi, le théorème spectral décrit la structure d'un opérateur à partir de son spectre. Cette analogie entre décomposition fréquentielle et décomposition en modes propres deviendra fondamentale en analyse de Fourier, en mécanique quantique et en théorie des équations aux dérivées partielles.

Transition vers l'analyse spectrale. L'idée fondamentale de l'analyse spectrale est la suivante :

comprendre une matrice en étudiant les directions où son action devient purement multiplicative, sans perturbation en dehors de son axe "propre" d'application.

Ces directions privilégiées seront précisément les vecteurs propres. L'étude des quantités :

$$x^\top Mx \quad \text{et} \quad \frac{x^\top Mx}{x^\top x}$$

permettra alors de révéler les directions géométriquement dominantes d'un opérateur linéaire.

Chapitre 5

Analyse spectrale et quotient de Rayleigh

L'expression 4.1 nous met quand même aux aguets... Elle est la résultante de l'action de A comme produit scalaire sur un vecteur z . Pour λ valeur propre, dont $z \neq \mathbf{0}$ est vecteur propre associé, on construit d'ailleurs naturellement

$$\lambda = \frac{z^* A z}{z^* z}. \quad (\text{QR})$$

Mais pour des raisons conceptuelles profondes, ce quotient ne mesure pas seulement une énergie : il compare l'énergie produite par l'action de A sur z à l'énergie intrinsèque du vecteur z lui-même. Il quantifie donc une sorte de *facteur d'amplification énergétique* induit par l'opérateur A dans la direction z .

Or les directions propres sont précisément les directions les plus stables sous l'action de A : l'opérateur n'y déforme pas le vecteur, il se contente de le dilater ou de le contracter par un facteur scalaire λ . Dans une telle direction, toute l'énergie de l'action de A reste parfaitement alignée avec le vecteur initial. Le quotient de Rayleigh devient alors exactement égal à cette valeur propre. Le quotient considéré révèle naturellement les directions privilégiées de la transformation linéaire, c'est-à-dire les directions propres, ainsi que les intensités énergétiques associées à ces directions.

Le terme étudié (QR) porte justement le nom de “quotient de Rayleigh” et constitue l'un des objets les plus fondamentaux de toute l'analyse spectrale moderne et apparaît un peu partout (optimisation, mécanique, analyse variationnelle, ...).

Hypothèse

Dans tout ce chapitre, pour que l'action de A fasse sens, on supposera toujours (sauf si exception indiquée) que A est **auto-adjointe**. Si on restreint à l'application en machine learning, où A est à coefficients réels uniquement, alors on dit simplement que A est **symétrique réelle**.

Anecdote historique. Historiquement, le quotient de Rayleigh apparaît dans l'étude des vibrations mécaniques. Lorsqu'on étudie une corde vibrante, une membrane, un système mécanique, ou un opérateur différentiel, ... les fréquences naturelles du système correspondent aux valeurs propres d'un opérateur d'énergie. Le quotient de Rayleigh permet précisément d'identifier ces fréquences caractéristiques comme solutions d'un problème d'optimisation.

Idée fondamentale

Le quotient de Rayleigh mesure l'énergie moyenne d'une transformation linéaire dans une direction donnée, et va pouvoir s'exprimer comme moyenne pondérée des valeurs propres de cette application linéaire.

5.1 Définition

Définition 5.1.1 (Quotient de Rayleigh). Soit $A \in \mathcal{S}_p(\mathbb{R})$ une matrice **symétrique réelle**. Pour tout vecteur non nul $x \in \mathbb{R}^p \setminus \{0\}$, on définit

$$R_A(x) = \frac{x^\top Ax}{x^\top x}.$$

Interprétation géométrique du quotient de Rayleigh

Le quotient de Rayleigh :

$$R_A(x) = \frac{x^\top Ax}{x^\top x}$$

mesure l'action moyenne de la transformation A dans la direction x , indépendamment de la norme du vecteur. Il quantifie donc une réponse énergétique ou un étirement moyen produit par A relativement à l'énergie euclidienne portée par x .

Les directions propres jouent alors un rôle particulier : ce sont les seules directions pour lesquelles l'action de A reste parfaitement alignée avec le vecteur initial. Dans ces directions, la transformation agit uniquement par dilatation ou contraction, et le quotient de Rayleigh devient exactement égal à la valeur propre associée.

Remarque 12. Le quotient de Rayleigh est invariant par changement d'échelle. Pour tout $\alpha \in \mathbb{R}$ (non nul) :

$$R_A(\alpha x) = R_A(x).$$

Ainsi, il ne dépend pas de la norme du vecteur mais uniquement de sa direction. On peut donc restreindre l'étude aux vecteurs unitaires :

$$\|x\| = 1.$$

Ce principe apparaît très fréquemment en mathématiques : lorsqu'une quantité est homogène, il est naturel de normaliser les objets étudiés afin de ne conserver que leur information géométrique essentielle.

On peut d'ores-et-déjà préciser que les vecteurs propres sont précisément les directions où l'action de la matrice devient purement multiplicative. En effet, si $Ax = \lambda x$ ($x \neq \mathbf{0}$), alors :

$$R_A(x) = \frac{x^\top (\lambda x)}{x^\top x} = \lambda.$$

Le quotient de Rayleigh prend donc exactement la valeur propre associée lorsque l'on se place sur une direction propre. Les valeurs propres apparaissent ainsi comme les énergies extrêmes accessibles par l'opérateur, et les vecteurs propres comme les directions optimales réalisant ces extrema.

Invariance par changement de base. Une propriété importante et intuitive :

Proposition 5.1.1 (Invariance du quotient de Rayleigh par changement de base orthonormé). Soient $A \in \mathcal{S}_p(\mathbb{R})$ et $P \in \mathbb{R}^{p \times p}$ une matrice orthogonale vérifiant donc $P^\top P = I_p$. On pose :

$$B = P^\top A P.$$

Alors, pour tout vecteur non nul $y \in \mathbb{R}^p$, en posant $x = Py$, on a :

$$R_A(x) = R_B(y).$$

Preuve. Par définition :

$$R_A(x) = \frac{x^\top A x}{x^\top x}.$$

Comme $x = Py$, on obtient :

$$R_A(Py) = \frac{(Py)^\top A (Py)}{(Py)^\top (Py)}.$$

Or, par propriété sur la transposée, $(Py)^\top = y^\top P^\top$ et sachant $P^\top P = I_p$, il vient que :

$$R_A(Py) = \frac{y^\top P^\top A P y}{y^\top P^\top P y} = \frac{y^\top B y}{y^\top y} = R_B(y)$$

Le quotient de Rayleigh est donc invariant par changement de base orthonormé. $\square$

Remarque 13 (Intérêt conceptuel). Cette propriété signifie que le quotient de Rayleigh ne dépend pas du système de coordonnées choisi, dès lors que le changement de base préserve la géométrie euclidienne. On peut ainsi étudier :

$$R_A(x) = \frac{x^\top A x}{x^\top x}$$

dans n'importe quelle base orthonormée, sans modifier son contenu géométrique. C'est précisément ce qui rend le théorème spectral si puissant. En choisissant une base orthonormée de vecteurs propres de A , la matrice devient diagonale :

$$A = P D P^\top,$$

ou encore :

$$D = P^\top A P.$$

Le quotient de Rayleigh s'écrit alors dans cette base :

$$R_A(x) = R_D(y) = \frac{\sum_{i=1}^p \lambda_i y_i^2}{\sum_{i=1}^p y_i^2}.$$

On voit alors immédiatement que le quotient de Rayleigh est une **moyenne pondérée des valeurs propres**. Cette invariance permet donc de passer d'une matrice éventuellement complexe dans la base canonique à une écriture diagonale simple dans la base propre, sans changer la quantité étudiée.

5.2 Lien avec les valeurs propres

Le quotient de Rayleigh entretient un lien extrêmement profond avec les valeurs propres d'une matrice symétrique et cherche à capter l'idée suivante : les directions qui maximisent ou minimisent l'énergie spectrale d'une matrice sont précisément ses directions propres. Les vecteurs propres apparaissent naturellement comme les **directions à privilégier** de l'opérateur linéaire.

Théorème 5.2.1. *Les extrema du quotient de Rayleigh sont atteints sur les vecteurs propres de A . Plus précisément, si :*

$$\lambda_{\min} \quad \text{et} \quad \lambda_{\max}$$

désignent respectivement la plus petite et la plus grande valeur propre de A , alors :

$$\lambda_{\min} = \min_{x \neq 0} R_A(x),$$

et :

$$\lambda_{\max} = \max_{x \neq 0} R_A(x).$$

Ces extrema sont atteints exactement lorsque x est un vecteur propre associé aux valeurs propres extrêmes.

Preuve. Comme A est symétrique réelle, le théorème spectral garantit l'existence d'une base **orthonormée** de vecteurs propres :

$$(u_1, \dots, u_p),$$

associés aux valeurs propres :

$$(\lambda_1, \dots, \lambda_p).$$

Pour tout vecteur x quelconque, on peut l'écrire dans la base propre prédéfinie :

$$x = \sum_{i=1}^p \alpha_i u_i.$$

Alors :

$$Ax = \sum_{i=1}^p \alpha_i \lambda_i u_i.$$

Comme la base est orthonormée :

$$x^\top Ax = \sum_{i=1}^p \lambda_i \alpha_i^2 \quad \text{et} \quad x^\top x = \sum_{i=1}^p \alpha_i^2.$$

Ainsi :

$$R_A(x) = \frac{\sum_i \lambda_i \alpha_i^2}{\sum_i \alpha_i^2}.$$

Le quotient de Rayleigh est donc une moyenne pondérée des valeurs propres. Les extrema sont atteints lorsque tout le poids est concentré sur une unique direction propre. $\square$

Remarque 14. Les directions où cette énergie est maximale ou minimale sont naturellement les directions propres dominantes de l'opérateur. Cette propriété est fondamentale en mathématiques appliquées puisqu'elle explique pourquoi les valeurs propres apparaissent naturellement en Analyse en Composantes Principales (ACP), dans les problèmes vibrationnels, dans les équations différentielles, dans les méthodes variationnelles et dans le clustering spectral (et même pour quantifier les états quantiques d'une particule élémentaire). Dans tous ces contextes, les vecteurs propres représentent des directions géométriquement ou énergétiquement optimales.

5.3 Encadrement spectral

Il en résulte un théorème immédiat, par combinaison convexe de valeurs propres :

Proposition 5.3.1. Soient

$$\lambda_{\min} \quad \text{et} \quad \lambda_{\max}$$

les plus petite et plus grande valeurs propres de A . Alors

$$\lambda_{\min} \leq R_A(x) \leq \lambda_{\max}.$$

Preuve. Comme :

$$R_A(x) = \frac{\sum_i \lambda_i \alpha_i^2}{\sum_i \alpha_i^2},$$

il s'agit d'une moyenne pondérée des valeurs propres. Une moyenne pondérée est toujours comprise entre le minimum et le maximum des valeurs considérées. Comme $\lambda_i \geq \lambda_{\min}$ pour tout i , on a :

$$\sum_i \lambda_i \alpha_i^2 \geq \sum_i \lambda_{\min} \alpha_i^2 = \lambda_{\min} \sum_i \alpha_i^2.$$

Donc

$$R_A(x) = \frac{\sum_i \lambda_i \alpha_i^2}{\sum_i \alpha_i^2} \geq \lambda_{\min}.$$

De même, comme $\lambda_i \leq \lambda_{\max}$ pour tout i , on a :

$$\sum_i \lambda_i \alpha_i^2 \leq \sum_i \lambda_{\max} \alpha_i^2 = \lambda_{\max} \sum_i \alpha_i^2.$$

Donc

$$R_A(x) = \frac{\sum_i \lambda_i \alpha_i^2}{\sum_i \alpha_i^2} \leq \lambda_{\max}.$$

Finalement :

$$\lambda_{\min} \leq R_A(x) \leq \lambda_{\max}.$$

□

Remarque 15. On pourra se servir du quotient de Rayleigh comme outil permettant de caractériser et repérer les valeurs propres extrêmes d'une matrice.

Cas particulier des vecteurs propres. Une propriété qui en découle directement :

Proposition 5.3.2. Si v est un vecteur propre de A associé à la valeur propre λ , alors :

$$R_A(v) = \lambda.$$

Preuve. Immédiate. Si $Av = \lambda v$, alors $v^\top Av = v^\top (\lambda v) = \lambda v^\top v$. Donc :

$$R_A(v) = \frac{\lambda v^\top v}{v^\top v} = \lambda.$$

□

Interprétation variationnelle. Le quotient de Rayleigh transforme le calcul des valeurs propres en problème d'optimisation.

Théorème 5.3.1 (Principe variationnel). *La plus grande valeur propre de A vérifie :*

$$\lambda_{\max} = \max_{\|x\|=1} x^\top Ax.$$

De même :

$$\lambda_{\min} = \min_{\|x\|=1} x^\top Ax.$$

Preuve. Comme $A \in \mathcal{S}_p(\mathbb{R})$, le théorème spectral assure qu'il existe une base orthonormée de vecteurs propres

$$(u_1, \dots, u_p),$$

associée aux valeurs propres *quitte à les ré-ordonner* :

$$\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_p.$$

Ainsi :

$$\lambda_{\min} = \lambda_1, \quad \lambda_{\max} = \lambda_p.$$

Soit maintenant un vecteur $x \in \mathbb{R}^p$, unitaire, i.e., $\|x\| = 1$. Comme $(u_1, \dots, u_p)$ est une base

orthonormée, on peut écrire :

$$x = \sum_{i=1}^p \alpha_i u_i.$$

Puisque $\|x\| = 1$, on a :

$$\sum_{i=1}^p \alpha_i^2 = 1.$$

Calculons alors :

$$x^\top Ax = \langle Ax, x \rangle.$$

Or :

$$Ax = A \left(\sum_{i=1}^p \alpha_i u_i \right) = \sum_{i=1}^p \alpha_i Au_i = \sum_{i=1}^p \alpha_i \lambda_i u_i.$$

Donc, par orthonormalité de la base propre :

$$x^\top Ax = \sum_{i=1}^p \lambda_i \alpha_i^2.$$

Cette quantité est une moyenne pondérée des valeurs propres, car :

$$\alpha_i^2 \geq 0 \quad \text{et} \quad \sum_{i=1}^p \alpha_i^2 = 1.$$

Ainsi :

$$\lambda_1 \leq \sum_{i=1}^p \lambda_i \alpha_i^2 \leq \lambda_p.$$

Donc :

$$\lambda_{\min} \leq x^\top Ax \leq \lambda_{\max}.$$

Il reste à vérifier que ces bornes sont atteintes pour parler précisément de min et de max. Si l'on choisit : $x = u_1$, alors :

$$x^\top Ax = u_1^\top Au_1 = u_1^\top (\lambda_1 u_1) = \lambda_1 \|u_1\|^2 = \lambda_1.$$

Donc :

$$\min_{\|x\|=1} x^\top Ax = \lambda_{\min}.$$

De même, si l'on choisit : $x = u_p$, alors :

$$x^\top Ax = u_p^\top Au_p = u_p^\top (\lambda_p u_p) = \lambda_p \|u_p\|^2 = \lambda_p.$$

D'où :

$$\max_{\|x\|=1} x^\top Ax = \lambda_{\max}.$$

On obtient finalement :

$$\lambda_{\max} = \max_{\|x\|=1} x^\top Ax, \quad \lambda_{\min} = \min_{\|x\|=1} x^\top Ax.$$

□

Remarque 16. Les valeurs propres apparaissent donc naturellement comme des extrema d'énergie, des directions à privilégier, et jouent le rôle de “modes”¹ dominants de la transformation.

5.4 Exemples

Exemple 5.4.1. Considérons :

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 5 \end{pmatrix}.$$

Pour :

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix},$$

on obtient :

$$R_A(x) = \frac{2x_1^2 + 5x_2^2}{x_1^2 + x_2^2}.$$

On peut réécrire :

$$R_A(x) = 2 \frac{x_1^2}{x_1^2 + x_2^2} + 5 \frac{x_2^2}{x_1^2 + x_2^2}.$$

Or :

$$\frac{x_1^2}{x_1^2 + x_2^2} \geq 0, \quad \frac{x_2^2}{x_1^2 + x_2^2} \geq 0,$$

et :

$$\frac{x_1^2}{x_1^2 + x_2^2} + \frac{x_2^2}{x_1^2 + x_2^2} = 1.$$

Ainsi, $R_A(x)$ est une moyenne pondérée de 2 et 5. On en déduit :

$$2 \leq R_A(x) \leq 5.$$

Le minimum est atteint lorsque :

$$x = \begin{pmatrix} 1 \\ 0 \end{pmatrix},$$

c'est-à-dire dans la direction propre associée à :

$$\lambda_{\min} = 2.$$

Le maximum est atteint lorsque :

$$x = \begin{pmatrix} 0 \\ 1 \end{pmatrix},$$

c'est-à-dire dans la direction propre associée à :

$$\lambda_{\max} = 5.$$

1. En analyse spectrale, un mode désigne une configuration élémentaire de comportement d'un système. En algèbre linéaire, les vecteurs propres représentent des modes fondamentaux d'une transformation : ce sont les directions où l'opérateur agit uniquement par dilatation ou contraction. En physique, cette notion apparaît naturellement dans les phénomènes vibratoires et diffusifs : modes de vibration d'une corde ou d'une membrane, modes de propagation d'une onde, modes de diffusion de la chaleur, etc. Les valeurs propres mesurent alors l'intensité, la fréquence ou la vitesse associée à chacun de ces comportements fondamentaux.

Exemple 5.4.2. Considérons maintenant une matrice symétrique non diagonale :

$$A = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}.$$

Cette matrice n'est pas diagonale dans la base canonique, mais elle est symétrique réelle. Par le théorème spectral, elle est donc diagonalisable dans une base orthonormée.

Pour :

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix},$$

on obtient :

$$x^\top Ax = 3x_1^2 + 2x_1x_2 + 3x_2^2.$$

Ainsi :

$$R_A(x) = \frac{3x_1^2 + 2x_1x_2 + 3x_2^2}{x_1^2 + x_2^2}.$$

Les valeurs propres de A sont données par :

$$\det(A - \lambda I_2) = \det \begin{pmatrix} 3 - \lambda & 1 \\ 1 & 3 - \lambda \end{pmatrix} = (3 - \lambda)^2 - 1.$$

Donc :

$$(3 - \lambda)^2 = 1,$$

ce qui donne :

$$\lambda_1 = 2, \quad \lambda_2 = 4.$$

Les vecteurs propres associés sont :

$$u_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \quad u_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Ainsi, même si la matrice n'est pas diagonale dans la base canonique, elle devient diagonale dans la base orthonormée :

$$(u_1, u_2).$$

Dans cette base propre, si :

$$x = \alpha_1 u_1 + \alpha_2 u_2,$$

alors :

$$R_A(x) = \frac{2\alpha_1^2 + 4\alpha_2^2}{\alpha_1^2 + \alpha_2^2}.$$

On retrouve donc que :

$$2 \leq R_A(x) \leq 4.$$

Le minimum est atteint dans la direction propre :

$$u_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix},$$

et le maximum dans la direction propre :

$$u_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Cet exemple illustre que le quotient de Rayleigh ne dépend pas du fait que la matrice soit déjà diagonale dans la base canonique : ce qui importe est l'existence d'une base propre orthonormée dans laquelle l'action de la matrice devient lisible.

5.5 Lien avec les matrices de covariance

En statistiques, si Σ désigne une matrice de covariance, alors $x^\top \Sigma x$ mesure la variance des données projetées selon la direction x . Maximiser le quotient de Rayleigh revient alors à rechercher **la direction de variance maximale**. C'est d'ailleurs exactement le principe de l'Analyse en Composantes Principales (ACP).

5.6 Lien avec le Laplacien

Le quotient de Rayleigh devient particulièrement important lorsqu'on l'applique au Laplacien d'un graphe. Supposons que les données soient représentées par un graphe pondéré. Chaque sommet représente une observation, et chaque poids constituant la matrice W , noté

$$w_{ij} \geq 0,$$

mesure la similarité entre les sommets i et j . Plus w_{ij} est grand, plus les deux sommets sont considérés comme fortement liés. On définit alors la matrice de degré :

$$D = \text{diag}(d_1, \dots, d_n), \quad d_i = \sum_{j=1}^n w_{ij},$$

puis le Laplacien (*non normalisé*) :

$$L = D - W.$$

Pour une fonction définie sur les sommets du graphe,

$$f : V \rightarrow \mathbb{R}, \quad f = (f_1, \dots, f_n),$$

la quantité fondamentale est $f^\top L f$, **car elle mesure l'énergie de variation de la fonction sur le graphe** (on en donne une première intuition en Section 3.7).

Le terme $f^\top L f$ mesure à quel point la fonction f respecte la structure de connectivité du graphe. De fait, une fonction de faible énergie reste relativement constante sur les régions fortement connectées du graphe, et ne varie significativement que lorsqu'on traverse des zones faiblement connectées. Cette idée est l'analogue discret du rôle joué par l'énergie

$$\int \|\nabla f(x)\|^2 dx$$

dans le cadre continu. Dans les deux cas, on "pénalise" les variations locales importantes de la fonction en cherchant les valeurs

On montrera plus loin dans ce cours que

$$f^\top L f = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2,$$

illustrant le fait que l'énergie associée au Laplacien est :

- grande lorsque deux sommets fortement connectés portent des valeurs très différentes ;
- faible lorsque w_{ij} , signifiant ainsi que les valeurs f_i et f_j sont "*assez*" proches.

. Le quotient de Rayleigh associé au Laplacien s'exprimera par :

$$R_L(f) = \frac{f^\top L f}{f^\top f} = \frac{\frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2}{\|f\|^2},$$

mesurant la variation moyenne de la fonction f sur le graphe, relativement à sa taille globale.

Interprétation

Minimiser $R_L(f)$ revient à chercher une fonction f qui varie le moins possible entre sommets fortement connectés : les fonctions associées aux petites valeurs propres du Laplacien sont les fonctions les plus lisses sur le graphe.

5.7 Minimisation d'énergie et émergence des clusters

Ainsi, on comprend pourquoi le point de départ du clustering spectral consiste à considérer l'énergie :

$$\mathcal{E}(f) = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2.$$

Chercher à minimiser cette énergie revient donc à rechercher des fonctions qui restent presque constantes sur les régions fortement connectées du graphe, tout en autorisant des variations principalement entre régions faiblement connectées. Or, cette propriété correspond précisément à l'idée intuitive d'un cluster : à l'intérieur d'un même groupe, les sommets doivent être fortement liés et donc recevoir des valeurs similaires ; entre groupes différents, les valeurs peuvent changer davantage.

Cependant, minimiser directement $\mathcal{E}(f)$ pose immédiatement un problème trivial. En effet, la fonction constante

$$f = (1, \dots, 1) =: \mathbb{1}$$

vérifie

$$\forall i, j, \quad f_i - f_j = 0,$$

menant directement à $\mathcal{E}(f) = 0$.

Cette fonction minimise parfaitement l'énergie, mais elle ne contient aucune information géométrique : tous les sommets reçoivent exactement la même valeur, donc aucun cluster ne peut être distingué. Pour éviter cette solution triviale, on étudie justement le quotient de Rayleigh :

$$R_L(f) = \frac{f^\top L f}{f^\top f}.$$

Le dénominateur $f^\top f = \|f\|^2$ normalise la fonction et rend la quantité indépendante de l'échelle :

$$R_L(\alpha f) = R_L(f).$$

Ainsi, le problème ne dépend plus de l'amplitude de f mais uniquement de sa direction dans l'espace des fonctions. Conceptuellement, on cherche ici les directions les plus significatives du problème variationnel, ce qui revient à raisonner sur la sphère unité (*puisque seules les directions nous intéressent, autant réduire l'étude à la sphère unité*). Le théorème variationnel du quotient de Rayleigh 5.2.1 affirme alors que les minima "successifs" de cette quantité sont atteints sur les vecteurs propres du Laplacien.

Néanmoins, pour un graphe connexe on a d'office :

$$L\mathbb{1} = 0.$$

signifiant donc que le premier vecteur propre est précisément la fonction constante $\mathbb{1} = (1, \dots, 1)$, associée à la valeur propre $\lambda_1 = 0$. Cette fonction minimise parfaitement l'énergie mais ne **contient aucune information géométrique utile** : tous les sommets reçoivent la même valeur, donc aucun cluster ne peut être distingué.

On cherche alors les minimisations non triviales, **obtenues en imposant des contraintes d'orthogonalité** aux solutions précédentes. En particulier, le premier vecteur propre informatif est obtenu via :

$$\min_{f \neq 0, f \perp \mathbb{1}} R_L(f).$$

Par le principe variationnel, cette solution correspond au vecteur propre associé à la deuxième plus petite valeur propre du Laplacien. Ces nouveaux vecteurs propres représentent alors les plus petites variations non triviales possibles sur le graphe. Leur propriété fondamentale est qu'ils varient très peu à l'intérieur des régions fortement connectées mais changent principalement lorsqu'on traverse des zones faiblement connectées.

Interprétation profonde

Le clustering spectral consiste à rechercher les fonctions "les plus lisses" (*au sens qu'elles minimisent une perte énergétique quadratique*) possibles sur le graphe, après avoir éliminé les solutions triviales constantes.

Les premiers vecteurs propres non triviaux du Laplacien deviennent alors presque constants sur les communautés du graphe et révèlent ainsi directement les clusters.

Le clustering spectral peut bien s'interpréter comme un problème variationnel d'énergie :

clusters $\iff$ régions où les fonctions de faible énergie restent presque constantes.

Exemple 5.7.1 (Cas idéal de deux composantes connexes). Supposons que le graphe possède deux composantes connexes totalement séparées :

C_1 et C_2 .

Il n'existe aucune arête entre C_1 et C_2 . Considérons la fonction :

$$f(i) = \begin{cases} 1 & \text{si } i \in C_1, \\ 0 & \text{si } i \in C_2. \end{cases}$$

Alors, pour toute arête interne à C_1 , on a :

$$f_i - f_j = 1 - 1 = 0.$$

Pour toute arête interne à C_2 , on a :

$$f_i - f_j = 0 - 0 = 0.$$

Et comme il n'existe aucune arête entre C_1 et C_2 , il n'y a pas de terme reliant une valeur 1 à une valeur 0.

Donc :

$$f^\top Lf = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2 = 0.$$

Ainsi, f est une fonction d'énergie nulle. Elle est constante sur chaque composante connexe et permet de distinguer les deux composantes.

Cet exemple explique pourquoi les vecteurs propres associés aux plus petites valeurs propres sont si importants. Lorsque le graphe est parfaitement séparé en plusieurs composantes connexes, les fonctions indicatrices de ces composantes **appartiennent au noyau du Laplacien**. Plus généralement, si le graphe possède k composantes connexes, alors il existe k fonctions indépendantes

$$f_1, \dots, f_k \quad \text{telles que} \quad \forall \ell \in \{1, \dots, k\}, \quad Lf_\ell = 0.$$

Ces fonctions sont précisément constantes sur une composante et nulles ailleurs.

Cas idéal

Dans un graphe parfaitement séparé en k composantes connexes, les vecteurs propres associés à la valeur propre 0 codent directement les clusters.

Les lignes de la matrice :

$$U = [f_1, \dots, f_k]$$

indiquent alors l'appartenance communautaire des sommets.

Remarque 17. Dans les données réelles, les clusters ne sont généralement pas totalement déconnectés. Il existe souvent quelques arêtes faibles entre les groupes. Dans ce cas, les valeurs propres ne sont plus exactement nulles, mais les plus petites valeurs propres restent proches de zéro. Les vecteurs propres associés, quant à eux, ne sont alors plus exactement constants sur chaque cluster, mais ils le deviennent approximativement. Ils varient peu à l'intérieur des régions fortement connectées, et changent principalement lorsqu'on traverse une zone de faible connectivité.

C'est le sens précis de l'affirmation selon laquelle les premiers vecteurs propres du Laplacien sont presque constants sur les régions fortement connectées du graphe. Cette phrase signifie que les petits

vecteurs propres minimisent une énergie de variation. Ils n'ont donc pas intérêt à prendre des valeurs très différentes sur deux sommets fortement reliés, car cela coûterait beaucoup dans la quantité :

$$\sum_{i,j} w_{ij} (f_i - f_j)^2.$$

En revanche, ils peuvent changer de valeur entre deux régions faiblement connectées, car les poids w_{ij} entre ces régions sont faibles.

Idée fondamentale du clustering spectral

Le clustering spectral ne cherche pas directement des centroïdes dans l'espace initial. Il construit d'abord un espace spectral dans lequel la connectivité du graphe devient visible géométriquement (et algébriquement). Dans cet espace, les régions fortement connectées du graphe deviennent des nuages de points séparables.

5.8 Gradient et variations locales

Lorsqu'on étudie une fonction $f : \mathbb{R}^d \rightarrow \mathbb{R}$, une première question naturelle consiste à comprendre comment cette fonction varie localement. Dans le cas d'une fonction d'une seule variable $f : \mathbb{R} \rightarrow \mathbb{R}$, c'est la dérivée $f'(x)$ qui endosse ce rôle en mesurant cette variation locale. En dimension supérieure, cette notion est généralisée par le gradient.

Définition 5.8.1 (Gradient). Soit :

$$f : \mathbb{R}^d \rightarrow \mathbb{R}$$

une fonction différentiable. Le gradient de f est le champ de vecteurs :

$$\nabla f = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_d} \end{pmatrix}.$$

Le gradient contient toutes les dérivées partielles de la fonction en chacune de ses composantes. Il décrit **la direction dans laquelle la fonction croît le plus rapidement**.

Remarque 18. La norme $\|\nabla f(x)\|$ mesure localement l'intensité de variation de la fonction autour du point x . Plus cette quantité est grande, plus la fonction varie rapidement localement.

Exemple 5.8.1. Considérons :

$$f(x, y) = x^2 + y^2.$$

Alors :

$$\nabla f(x, y) = \begin{pmatrix} 2x \\ 2y \end{pmatrix}.$$

Le gradient pointe radialement vers l'extérieur : la fonction augmente lorsqu'on s'éloigne de l'origine.

5.9 Le Laplacien continu

Le gradient mesure les variations de premier ordre d'une fonction. Le Laplacien mesure quant à lui les variations de second ordre, c'est-à-dire la courbure locale de la fonction.

Définition 5.9.1 (Laplacien continu). Soit $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Le Laplacien de f est défini par :

$$\Delta f = \sum_{i=1}^d \frac{\partial^2 f}{\partial x_i^2}.$$

Le Laplacien additionne les dérivées **secondes** selon toutes les directions de l'espace.

Remarque 19. Il en résulte que le Laplacien mesure localement la manière dont une fonction se **courbe** au vu de l'intervention des dérivées secondes. Lorsque $\Delta f(x)$ est grand, cela signifie que la fonction présente de fortes variations locales autour du point x . Inversement, lorsque $\Delta f(x) \approx 0$, la fonction est localement régulière et relativement lisse.

Exemple 5.9.1. Considérons de nouveau

$$f(x, y) = x^2 + y^2.$$

f étant de classe $\mathcal{C}^2(\mathbb{R}^2)$, on obtient

$$\frac{\partial^2 f}{\partial x^2} = 2, \quad \frac{\partial^2 f}{\partial y^2} = 2.$$

Donc, pour tout $(x, y) \in \mathbb{R}^2$,

$$\Delta f(x, y) = 4.$$

Le Laplacien constant positif traduit ici une courbure uniforme de la fonction.

5.10 L'espace L^2

Pour étudier analytiquement les fonctions et leurs énergies, on introduit un cadre fonctionnel adapté. On notera $\Omega \subset \mathbb{R}^d$ un ouvert borné, de bords suffisamment réguliers (c'est-à-dire que le bord $\partial\Omega$ est localement suffisamment lisse pour être décrit par des paramétrisations de classe $\mathcal{C}^1$).

Définition 5.10.1 (Fonctions de carré intégrable). On note :

$$L^2(\Omega) = \left\{ f : \Omega \rightarrow \mathbb{R} \mid \int_{\Omega} |f(x)|^2 dx < \infty \right\}.$$

Les fonctions qui vivent dans l'espace L^2 possèdent une énergie totale finie et on comprend donc pourquoi cet espace joue un rôle fondamental en analyse spectrale, en physique mathématique et dans les équations aux dérivées partielles.

Proposition 5.10.1. L'espace $L^2(\Omega)$ est un espace de Hilbert lorsqu'il est muni du produit scalaire :

$$\langle f, g \rangle = \int_{\Omega} f(x)g(x) dx,$$

c'est-à-dire qu'il est complet et dont le produit scalaire est bien défini comme en 4.1.1.

Remarque 20. Le caractère hilbertien de L^2 est fondamental puisqu'il permet de généraliser les notions géométriques usuelles aux espaces de fonctions. On retrouve alors les notions d'orthogonalité, de projection, de décomposition spectrale et de diagonalisation d'opérateurs. Toute l'analyse spectrale moderne repose profondément sur cette structure.

5.11 Énergie continue

Une idée fondamentale de l'analyse variationnelle consiste à associer une énergie à une fonction. Cette énergie mesure l'intensité globale des variations spatiales de la fonction.

Définition 5.11.1 (Énergie de Dirichlet). L'énergie associée à une fonction $f : \Omega \rightarrow \mathbb{R}$ s'exprime comme

$$\mathcal{E}(f) = \int_{\Omega} \|\nabla f(x)\|^2 dx.$$

Interprétation physique

- ✓ Le gradient ∇f mesure localement les variations spatiales de la fonction.
- ✓ On quantifie l'énergie d'une particule par "le travail" (ou l'effet énergétique physique) résultante de sa variation de quantité de mouvement sur elle-même. De fait, le travail étant issu du produit scalaire, il vient que la quantité

$$\langle \nabla f(x), \nabla f(x) \rangle = \|\nabla f(x)\|^2$$

représente une énergie infinitésimale locale et quantifie l'intensité des variations autour du point x .

- ✓ Enfin, pour considérer l'énergie globale, il suffit d'intégrer cette dernière quantité sur tout le domaine Ω comme suit :

$$\int_{\Omega} \|\nabla f(x)\|^2 dx.$$

Remarque 21. Cette énergie pénalise les fortes variations locales. Une fonction très oscillante possède une énergie élevée, tandis qu'une fonction régulière possède une énergie faible. *On voit de suite qu'une fréquence d'oscillation élevée conduit à une énergie forte, ce que l'on retrouve dans l'expression de l'énergie cinétique d'un oscillateur ou encore dans l'équation de Plank-Einstein $E = h\nu$.*

5.12 Lien entre énergie et Laplacien

Le Laplacien apparaît naturellement comme l'opérateur associé à cette énergie.

Proposition 5.12.1. Soit $\Omega \subset \mathbb{R}^d$ un ouvert borné suffisamment régulier, et soit $f : \Omega \rightarrow \mathbb{R}$ une fonction de classe $\mathcal{C}^2$ sur Ω , telle que f s'annule sur le bord, *i.e.*, $f|_{\partial\Omega} = 0$. Alors :

$$\int_{\Omega} \|\nabla f(x)\|^2 dx = - \int_{\Omega} f(x) \cdot \Delta f(x) dx.$$

Preuve. Écrivons d'abord

$$\|\nabla f(x)\|^2 = \sum_{i=1}^d \left(\frac{\partial f}{\partial x_i} \right)^2.$$

On intègre sur le domaine Ω et on emploie la linéarité de l'intégrale pour le membre de droite, ce qui donne :

$$\int_{\Omega} \|\nabla f(x)\|^2 dx = \sum_{i=1}^d \int_{\Omega} \left(\frac{\partial f}{\partial x_i} \right)^2 dx.$$

On l'aura deviné en voyant la formule, l'idée principale consiste maintenant à effectuer une intégration par parties sur chaque direction de l'espace. Supposons pour simplifier que f s'an-

nule sur le bord $\partial\Omega$, i.e. :

$$f|_{\partial\Omega} = 0$$

de sorte que les termes de bord disparaissent^a. Pour chaque composante x_i , on obtient alors :

$$\int_{\Omega} \frac{\partial f}{\partial x_i} \frac{\partial f}{\partial x_i} dx = \underbrace{\int_{\partial\Omega} f \frac{\partial f}{\partial x_i} n_i dS}_{=0 \text{ car } f|_{\partial\Omega}=0} - \int_{\Omega} f \frac{\partial^2 f}{\partial x_i^2} dx,$$

avec n_i désigne la i -ème composante du vecteur normal sortant et dS représente la mesure de surface sur le bord $\partial\Omega$. En sommant sur chaque $i = 1, \dots, d$, il vient :

$$\begin{aligned} \int_{\Omega} \|\nabla f(x)\|^2 dx &= - \sum_{i=1}^d \int_{\Omega} f(x) \frac{\partial^2 f}{\partial x_i^2} dx \\ &= - \int_{\Omega} f(x) \underbrace{\left(\sum_{i=1}^d \frac{\partial^2 f}{\partial x_i^2} \right)}_{\Delta f} dx \\ &= - \int_{\Omega} f(x) \Delta f(x) dx, \end{aligned}$$

ce qui établit l'égalité énoncée. □

^a. Plus généralement, des conditions de bord adaptées permettent d'obtenir la même relation.

Remarque 22 (Interprétation physique). Cette identité ne constitue pas uniquement une conséquence technique de l'intégration par parties. Elle révèle une relation profonde entre la géométrie locale des variations d'une fonction et l'action du Laplacien comme opérateur de diffusion. Le terme $\|\nabla f(x)\|^2$ mesure localement l'intensité des variations spatiales de la fonction. L'intégrale issue du produit scalaire

$$\langle \nabla f(x), \nabla f(x) \rangle_{L^2} = \int_{\Omega} \|\nabla f(x)\|^2 dx$$

représente donc l'énergie totale contenue dans ces variations. L'identité

$$\int_{\Omega} \|\nabla f(x)\|^2 dx = -\langle f, \Delta f \rangle_{L^2}$$

montre alors que le Laplacien encode exactement cette énergie de variation et mesure comment une fonction tend localement à se diffuser, se lisser ou se rééquilibrer. En physique, les phénomènes de diffusion cherchent naturellement à diminuer les variations spatiales :

- la chaleur se répartit ;
- une membrane vise à se détendre ;
- une concentration chimique se diffuse ;
- une vibration dissipe son énergie dans l'espace qui lui est disponible.

Le Laplacien agit par ailleurs dans la direction opposée aux fortes oscillations. Les régions où la fonction présente une forte courbure produisent une contribution importante de $-\Delta f$. Ainsi $-\Delta$ apparaît comme un opérateur de dissipation d'énergie et de régularisation. Dans le cadre discret, le Laplacien de graphe jouera exactement le même rôle en pénalisant les fonctions qui varient fortement entre sommets (ou observations) fortement connectés.

5.13 Analyse spectrale du Laplacien

Une pleine justification de l'étude spectrale du Laplacien réside dans l'étude des phénomènes ondulatoires qui occupent une place centrale en physique et en ingénierie. Ils interviennent dans une immense variété de systèmes naturels : la propagation du son, des vibrations mécaniques, des ondes électromagnétiques, de la chaleur ou encore des phénomènes quantiques reposent tous sur des équations décrivant des mécanismes de diffusion ou d'oscillation dans l'espace et le temps.

Comprendre mathématiquement ces phénomènes revient alors à analyser comment une perturbation locale **se propage, se diffuse ou résonne** dans un milieu donné. Considérons par exemple une corde vibrante fixée à ses extrémités. Si $u(x, t)$ désigne la position verticale de la corde au point x et au temps t , alors la célèbre équation des ondes (cas unidimensionnel) s'écrit

$$\frac{\partial^2 u}{\partial t^2} = c^2 \frac{\partial^2 u}{\partial x^2}, \quad (5.1)$$

où $c > 0$ désigne la vitesse de propagation de l'onde ($c = 3 \times 10^8$ m.s⁻¹ pour la lumière ou $c = 340$ m.s⁻¹ pour le son dans l'air à température ambiante).

Une idée fondamentale de la physique mathématique consiste alors à rechercher des solutions **séparables** sous la forme :

$$u(x, t) = \phi(x)f(t),$$

où :

- $\phi(x)$ décrit la forme spatiale de vibration ;
- $f(t)$ décrit l'évolution temporelle.

(La séparation des variables vient du découplage imposé par l'égalité entre variables indépendantes.) En injectant cette forme dans l'équation des ondes (5.1), on obtient :

$$\phi(x)f''(t) = c^2 \phi''(x)f(t) \iff \frac{f''(t)}{f(t)} = c^2 \frac{\phi''(x)}{\phi(x)}.$$

En regardant la dernière égalité établie, on observe que le membre de gauche dépend uniquement du temps, tandis que le membre de droite dépend uniquement de l'espace. Puisque ces deux quantités sont égales en tout point de l'espace x et à tout instant t , alors elles sont nécessairement égale à une même constante, disons $-\lambda$ (*quitte à ré-injecter la constance de célérité c dedans...*). On obtient alors le problème spectral :

$$-\phi''(x) = \lambda \phi(x).$$

En dimension supérieure, cette équation devient :

$$-\Delta \phi = \lambda \phi.$$

Les solutions ϕ sont les **modes propres** de vibration du système, tandis que les valeurs propres λ codent les fréquences ou niveaux d'énergie associés.

L'analyse spectrale du Laplacien consiste ainsi à décomposer un système complexe en modes élémentaires indépendants.

Définition 5.13.1 (Fonction propre du Laplacien). Une fonction ϕ , supposée de classe $\mathcal{C}^2(\Omega, \mathbb{R})$, est appelée fonction propre du Laplacien si :

$$-\Delta \phi = \lambda \phi.$$

Remarque 23. Les fonctions propres représentent des modes fondamentaux de variation du système. Chaque valeur propre mesure l'énergie associée à un mode particulier. On peut par ailleurs relever qu'en dimension finie, la trace se conserve telle l'énergie : prenons une matrice quelconque M diagonalisable. Alors il existe P inversible et D diagonale constituée des valeurs propres de M telles que

$$M = PDP^{-1},$$

menant à $\text{tr}(M) = \text{tr}(D)$.

Exemple 5.13.1 (Vibration d'une corde). Considérons une corde de longueur L , fixée à ses deux extrémités. On reprend $u(x, t)$, solution de (5.1). On a établi :

$$-\phi''(x) = \lambda\phi(x),$$

et on suppose de surcroît des conditions de bord homogènes :

$$\phi(0) = \phi(L) = 0.$$

On cherche donc les solutions non nulles du problème :

$$\begin{cases} -\phi''(x) = \lambda\phi(x), \\ \phi(0) = 0, \\ \phi(L) = 0. \end{cases}$$

Supposons d'abord $\lambda > 0$ et posons $\alpha = \sqrt{\lambda}$. L'équation devient :

$$\phi''(x) + \alpha^2\phi(x) = 0.$$

La solution générale est alors, pour tout x :

$$\phi(x) = A \cos(\alpha x) + B \sin(\alpha x).$$

La première condition de bord donne :

$$\phi(0) = A \cos(0) + B \sin(0) = A = 0.$$

Donc :

$$\phi(x) = B \sin(\alpha x).$$

La seconde condition de bord impose :

$$\phi(L) = B \sin(\alpha L) = 0.$$

On cherche des solutions non nulles, donc $B \neq 0$. Il faut donc :

$$\sin(\alpha L) = 0.$$

Ainsi :

$$\alpha L = n\pi, \quad n \in \mathbb{N}^*.$$

Donc :

$$\alpha = \frac{n\pi}{L}.$$

Comme $\lambda = \alpha^2$, on obtient :

$$\lambda_n = \left(\frac{n\pi}{L}\right)^2.$$

Les fonctions propres associées sont donc :

$$\phi_n(x) = \sin\left(\frac{n\pi x}{L}\right), \quad n \geq 1.$$

Les fonctions ϕ_n représentent les modes fondamentaux de vibration de la corde. Par exemple, ϕ_1 correspond au mode fondamental, ϕ_2 à la première harmonique, ϕ_3 à la seconde harmonique, etc. Chaque mode décrit une forme de vibration stable de la corde, tandis que les valeurs propres déterminent les fréquences associées :

$$\omega_n = c\sqrt{\lambda_n}.$$

Un signal, aussi complexe soit-il, peut ainsi se décomposer comme superposition de modes propres élémentaires.

Exemple 5.13.2 (Diffusion de la chaleur). Considérons maintenant une barre métallique. Si $u(x, t)$ désigne la température au point x et au temps t , alors l'équation de la chaleur s'écrit :

$$\frac{\partial u}{\partial t} = \kappa \frac{\partial^2 u}{\partial x^2},$$

où $\kappa > 0$ désigne le coefficient de diffusion thermique. Comme précédemment, on cherche des solutions séparables :

$$u(x, t) = \phi(x)f(t).$$

On obtient alors :

$$-\phi''(x) = \lambda\phi(x).$$

Les fonctions propres spatiales sont exactement les mêmes :

$$\phi_n(x) = \sin\left(\frac{n\pi x}{L}\right).$$

Cependant, la partie temporelle n'aura pas la même forme. En effet, l'équation de la chaleur fait intervenir une dérivée première et non seconde sur le temps t . Si on injecte u_n séparable dans l'équation, on obtient :

$$\phi(x)f'(t) = \kappa\phi''(x)f(t).$$

En divisant par $\kappa\phi(x)f(t)$, lorsque ces quantités ne sont pas nulles, il vient :

$$\frac{f'(t)}{\kappa f(t)} = \frac{\phi''(x)}{\phi(x)},$$

alors on établit :

$$\frac{f'_n(t)}{\kappa f_n(t)} = -\lambda_n,$$

d'où la résolution pour tout $n \geq 1$:

$$f_n(t) = e^{-\kappa\lambda_n t},$$

puisque f_n est solution d'une EDO homogène d'ordre 1. Ainsi :

$$u_n(x, t) = \sin\left(\frac{n\pi x}{L}\right) e^{-\kappa\lambda_n t}.$$

Chaque mode thermique décroît exponentiellement avec le temps. Les grandes valeurs propres décroissent beaucoup plus rapidement de part l'intervention du terme $e^{-\kappa\lambda_n t}$. Autrement dit :

- les modes très oscillants disparaissent vite ;
- les modes lisses persistent plus longtemps.

Cette observation est extrêmement profonde : le Laplacien sélectionne naturellement les structures les plus régulières et pénalise les fortes oscillations. C'est exactement cette philosophie que l'on retrouvera dans le clustering spectral avec les petits vecteurs propres du Laplacien de graphe.

Remarque 24 (Anecdote historique). L'équation de la chaleur a été étudiée systématiquement au début du XIX^e siècle par Joseph Fourier. Son objectif était de comprendre mathématiquement comment la chaleur se diffuse dans un milieu matériel, notamment dans des plaques métalliques et des barres conductrices.

Pour résoudre ce problème, Fourier introduisit une idée révolutionnaire : décomposer une fonction compliquée comme somme de modes élémentaires sinusoidaux. Cette approche donna naissance aux séries de Fourier et constitua un tournant majeur dans l'histoire de l'analyse mathématique, de la physique mathématique et plus tard de l'analyse spectrale moderne.

Les travaux de Fourier influenceront profondément Gauss, Sturm, Liouville, Hilbert et toute la théorie moderne des opérateurs spectraux.

5.14 Principe variationnel

Comme dans le cadre matriciel, les valeurs propres du Laplacien apparaissent comme solutions d'un problème variationnel.

Théorème 5.14.1. *Les fonctions propres du Laplacien minimisent l'énergie*

$$\int_{\Omega} \|\nabla f(x)\|^2 dx$$

sous des contraintes de normalisation et d'orthogonalité.

Preuve. On raisonne dans un cadre régulier *sans perte de généralité*, par exemple avec des fonctions nulles sur le bord $\partial\Omega$, afin que les intégrations par parties ne produisent pas de terme de bord fastidieux à écrire. On considère le quotient de Rayleigh continu :

$$\mathcal{R}(f) = \frac{\int_{\Omega} \|\nabla f(x)\|^2 dx}{\int_{\Omega} |f(x)|^2 dx}.$$

Grâce à l'identité d'intégration par parties :

$$\int_{\Omega} \|\nabla f(x)\|^2 dx = - \int_{\Omega} f(x) \Delta f(x) dx,$$

on peut écrire :

$$\mathcal{R}(f) = \frac{\langle -\Delta f, f \rangle_{L^2}}{\langle f, f \rangle_{L^2}}.$$

Ainsi, $\mathcal{R}(f)$ est exactement l'analogue continu du quotient de Rayleigh matriciel :

$$\frac{x^{\top} A x}{x^{\top} x}.$$

Supposons maintenant que le Laplacien admette une base orthonormée de fonctions propres $(\phi_n)_{n \geq 1}$ dans $L^2(\Omega)$, associées aux valeurs propres :

$$-\Delta \phi_n = \lambda_n \phi_n, \quad 0 \leq \lambda_1 \leq \lambda_2 \leq \dots$$

Toute fonction admissible f peut alors se décomposer sous la forme :

$$f(\cdot) = \sum_{n \geq 1} a_n \phi_n(\cdot).$$

Par orthonormalité de la famille $(\phi_n)_n$:

$$\int_{\Omega} |f(x)|^2 dx = \sum_{n \geq 1} a_n^2.$$

De plus, puisque les éléments de $(\phi_n)_n$ sont des modes propres de $-\Delta$:

$$-\Delta f = \sum_{n \geq 1} a_n \lambda_n \phi_n,$$

on obtient :

$$\int_{\Omega} \|\nabla f(x)\|^2 dx = \langle -\Delta f, f \rangle_{L^2} = \sum_{n \geq 1} \lambda_n a_n^2.$$

Ainsi :

$$\mathcal{R}(f) = \frac{\sum_{n \geq 1} \lambda_n a_n^2}{\sum_{n \geq 1} a_n^2}.$$

Cette quantité est une moyenne pondérée des valeurs propres. Elle est donc minimale lorsque tout le poids est porté par la plus petite valeur propre admissible.

Sous la contrainte de normalisation $\|f\|_{L^2} = 1$, minimiser l'énergie revient donc à minimiser :

$$\int_{\Omega} \|\nabla f(x)\|^2 dx.$$

Le minimum est atteint pour $f = \phi_1$, et vaut λ_1 (on a ordonné les valeurs propres au préalable). Si l'on impose en plus l'orthogonalité à ϕ_1 , c'est-à-dire :

$$\langle f, \phi_1 \rangle_{L^2} = 0,$$

alors le coefficient a_1 est nul. Le minimum suivant est donc atteint pour $f = \phi_2$, et vaut λ_2 . Plus généralement, si l'on impose :

$$f \perp \phi_1, \dots, \phi_{k-1},$$

alors :

$$a_1 = \dots = a_{k-1} = 0,$$

et la minimisation de l'énergie sous la contrainte $\|f\|_{L^2} = 1$ est atteinte pour :

$$f = \phi_k.$$

Ainsi, les fonctions propres du Laplacien sont exactement les fonctions qui minimisent successivement l'énergie de variation, sous contraintes de normalisation et d'orthogonalité. $\square$

Remarque 25. Cette idée est profondément analogue au quotient de Rayleigh matriciel. En effet, la lecture de

$$\frac{\int_{\Omega} \|\nabla f(x)\|^2 dx}{\int_{\Omega} |f(x)|^2 dx},$$

montre un numérateur qui mesure l'énergie de variation spatiale de la fonction, tandis que le dénominateur normalise cette énergie relativement à la taille globale de f dans $L^2(\Omega)$.

Les fonctions propres sont celles qui minimisent précisément ce quotient variationnel, et représentent les modes spatiaux les plus stables (ou les moins énergétiques) compatibles avec les contraintes d'orthogonalité imposées. Les fonctions propres du Laplacien apparaissent naturellement comme les structures fondamentales minimisant l'énergie de diffusion ou de vibration du système.

5.15 Du continu au discret

On peut résumer le point conceptuel essentiel du clustering spectral en une phrase : le Laplacien de graphe est un analogue discret du Laplacien continu. Dans le cadre continu,

$$\int \|\nabla f(x)\|^2 dx$$

mesure l'énergie de variation d'une fonction, tandis que dans le cadre discret d'un graphe, cette énergie devient :

$$\mathcal{E}(f) = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2.$$

Les deux expressions jouent exactement le même rôle puisqu'elles pénalisent les fortes variations locales, favorisent les fonctions régulières et mesurent une énergie de diffusion.

Analogie fondamentale

Le Laplacien continu mesure les variations locales d'une fonction dans l'espace.

Le Laplacien de graphe mesure quant à lui les variations locales d'une fonction sur un réseau de sommets connectés.

Remarque 26. Dans le cadre du clustering spectral, les sommets du graphe représentent les observations, tandis que les poids w_{ij} mesurent les similarités locales. Chercher des fonctions de faible énergie revient alors à rechercher des fonctions qui varient peu entre sommets fortement connectés, mais peuvent changer entre régions faiblement connectées. Les vecteurs propres associés aux petites valeurs propres du Laplacien deviennent alors presque constants sur les régions fortement connectées du graphe. Ces régions correspondent précisément aux clusters. Ainsi, le clustering spectral peut être vu comme une version discrète de l'analyse harmonique classique :

les clusters apparaissent comme des régions où les fonctions de faible énergie restent presque constantes.

Chapitre 6

Le Laplacien de graphe

Nous avons vu dans le chapitre précédent que le Laplacien continu apparaît naturellement comme opérateur fondamental de variation spatiale. Il gouverne :

- les phénomènes de diffusion ;
- les équations de la chaleur ;
- les vibrations ;
- et plus généralement les énergies variationnelles.

L'idée centrale du clustering spectral consiste alors à transposer ces concepts dans un cadre discret. Les données n'étant plus décrites par un domaine continu : $\Omega \subset \mathbb{R}^d$, mais par un ensemble fini d'observations connectées sous forme de graphe, il devient nécessaire de construire un analogue discret du Laplacien continu : le Laplacien de graphe. Ce chapitre constitue le véritable pont entre :

l'analyse spectrale continue *et* *le machine learning spectral*.

6.1 Fonctions définies sur un graphe

Dans le cadre discret, une fonction n'est plus définie sur un domaine continu mais sur les sommets du graphe.

Définition 6.1.1 (Fonction sur un graphe). Soit $G = (V, E)$ un graphe possédant n sommets. Une fonction sur le graphe est une application :

$$f : V \rightarrow \mathbb{R}.$$

L'ensemble des sommets étant fini, on peut l'écrire comme $V = \{v_1, \dots, v_n\}$. Une telle fonction définie sur le graphe G peut être représentée par un vecteur :

$$f = (f_1, \dots, f_n)^\top \in \mathbb{R}^n,$$

où $f_i = f(v_i)$. Une fonction sur le graphe devient simplement un vecteur de $\mathbb{R}^n$. Ce constat permet de faire apparaître naturellement des matrices agissant sur ces fonctions, exactement comme les opérateurs différentiels agissent sur les fonctions continues.

Remarque 27 (Interprétation en clustering spectral). Dans le cadre du clustering spectral, la fonction : $f : V \rightarrow \mathbb{R}$ attribue une valeur réelle à chaque observation du jeu de données. L'objectif est alors de construire des fonctions qui varient peu entre sommets fortement connectés du graphe. Intuitivement, deux observations très similaires doivent recevoir des valeurs proches. On verra que les premiers vecteurs propres du Laplacien jouent précisément ce rôle.

6.2 Le Laplacien de graphe

Soit un graphe $G = (V, E)$. On note $W = (w_{ij})_{i,j}$ la matrice d'adjacence des paires d'observations $(i, j) \in V^2$ et D la matrice de degré comme définie pleinement en 3.7. On rappelle que le Laplacien du graphe est la matrice :

$$L = D - W.$$

À première vue, cette définition peut sembler artificielle. Pourtant, elle possède une interprétation extrêmement profonde. Considérons une fonction :

$$f : V \rightarrow \mathbb{R}.$$

Alors :

$$(Lf)_i = d_i f_i - \sum_{j=1}^n w_{ij} f_j.$$

Comme $d_i = \sum_j w_{ij}$, on peut réécrire :

$$(Lf)_i = \sum_{j=1}^n w_{ij} (f_i - f_j).$$

Interprétation du Laplacien

Le Laplacien de graphe mesure localement les variations d'une fonction entre un sommet et ses voisins. Il joue de fait exactement le même rôle que le Laplacien continu dans le cadre différentiel.

Ainsi :

- si f varie peu entre voisins fortement connectés, alors Lf reste petit ;
- si au contraire la fonction oscille fortement localement, alors le Laplacien devient grand.

6.3 Énergie discrète

Le lien profond avec le chapitre précédent apparaît maintenant naturellement.

Proposition 6.3.1 (Énergie discrète). Pour toute fonction $f \in \mathbb{R}^n$, on a :

$$f^\top Lf = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2.$$

Preuve. On développe :

$$f^\top Lf = f^\top (D - W)f.$$

Donc :

$$f^\top Lf = f^\top Df - f^\top Wf.$$

Or :

$$f^\top Df = \sum_{i=1}^n d_i f_i^2,$$

et :

$$f^\top Wf = \sum_{i,j} w_{ij} f_i f_j.$$

Ainsi :

$$f^\top Lf = \sum_i d_i f_i^2 - \sum_{i,j} w_{ij} f_i f_j.$$

Comme, par définition de la matrice de degré, $d_i = \sum_j w_{ij}$, on obtient :

$$\sum_i d_i f_i^2 = \sum_i \left(\sum_j w_{ij} \right) f_i^2 = \sum_{i,j} w_{ij} f_i^2.$$

Ainsi :

$$f^\top Lf = \sum_{i,j} w_{ij} f_i^2 - \sum_{i,j} w_{ij} f_i f_j.$$

À ce stade, on veut faire apparaître une différence au carré. Pour cela, on utilise la symétrie de la matrice d'adjacence $w_{ij} = w_{ji}$ comme tel :

$$\begin{aligned} \sum_{i,j} w_{ij} f_i^2 &= \sum_{i,j} w_{ji} f_i^2 \quad \text{par symétrie de } W \\ &= \sum_{i,j} w_{ij} f_j^2 \quad \text{en interchangeant les indices de sommation.} \end{aligned}$$

On peut donc écrire :

$$\sum_{i,j} w_{ij} f_i^2 = \frac{1}{2} \sum_{i,j} w_{ij} f_i^2 + \frac{1}{2} \sum_{i,j} w_{ij} f_j^2.$$

Par conséquent :

$$f^\top Lf = \frac{1}{2} \sum_{i,j} w_{ij} f_i^2 + \frac{1}{2} \sum_{i,j} w_{ij} f_j^2 - \sum_{i,j} w_{ij} f_i f_j.$$

On regroupe alors les trois termes dans une seule somme :

$$f^\top Lf = \frac{1}{2} \sum_{i,j} w_{ij} \underbrace{(f_i^2 + f_j^2 - 2f_i f_j)}_{=(f_i - f_j)^2}.$$

Finalement :

$$f^\top Lf = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2.$$

□

Remarque 28. Résumons en quelques mots en étudiant précisément $(Lf)_i$. Le Laplacien quantifie les variations locales entre le sommet i et tous ses voisins. L'énergie qui en résulte est le produit scalaire $\langle f, Lf \rangle = f^\top Lf$, c'est-à-dire l'effet physique qu'a le résultat Lf sur l'initiale f . Cette quantité agrège toutes ces variations locales autour de f_i sur l'ensemble du graphe et mesure alors le coût énergétique total des oscillations de f relativement à la structure de connectivité. Ainsi, le Laplacien joue dans le cadre discret exactement le même rôle que dans le cadre continu : il gouverne les phénomènes de diffusion, de lissage et de propagation des variations sur l'espace considéré.

Interprétation locale du Laplacien. Dans le cadre continu, le Laplacien :

$$\Delta f(x) = \sum_{i=1}^d \frac{\partial^2 f}{\partial x_i^2}(x)$$

mesure localement la courbure moyenne de la fonction autour du point x . Intuitivement :

- si $\Delta f(x) > 0$, alors la fonction est localement “creusée vers le haut” : les points voisins possèdent en moyenne des valeurs plus grandes que $f(x)$;
- si $\Delta f(x) < 0$, alors la fonction est localement “tournée vers le bas” : les voisins possèdent en moyenne des valeurs plus petites.

Le Laplacien compare donc la valeur locale $f(x)$ à une moyenne de ses voisins proches. Cette philosophie réapparaît naturellement dans le cadre discret, puisque :

$$(Lf)_i = d_i f_i - \sum_j w_{ij} f_j = \sum_j w_{ij} (f_i - f_j).$$

Cette quantité mesure l'écart entre la valeur prise au sommet i et les valeurs prises sur les sommets voisins. On a bien que :

- si $(Lf)_i > 0$, alors f_i est plus grand que la moyenne pondérée de ses voisins ;
- si $(Lf)_i < 0$, alors f_i est plus petit que cette moyenne locale.

Le Laplacien discret constitue donc un analogue naturel du Laplacien continu en mesurant localement les variations, la courbure et les phénomènes de diffusion sur le graphe.

Résumé du lien entre Laplacien continu et discret via le quotient de Rayleigh

Dans le cadre continu, le quotient de Rayleigh associé au Laplacien est :

$$R(f) = \frac{\int_{\Omega} \|\nabla f(x)\|^2 dx}{\int_{\Omega} f(x)^2 dx}.$$

Le terme $\|\nabla f(x)\|^2$ mesure localement les variations infinitésimales de la fonction f . Le quotient $R(f)$ mesure la variation spatiale de f normalisée par sa taille globale. Les fonctions propres du Laplacien satisfont

$$-\Delta f = \lambda f,$$

et sont exactement les minimiseurs successifs du quotient de Rayleigh. Ainsi, les petites valeurs propres correspondent aux fonctions qui varient peu, là où les grandes valeurs propres correspondent aux fonctions très oscillantes.

Dans le cadre discret, les dérivées n'existent plus. Les variations locales sont alors remplacées par les différences entre sommets voisins $f_i - f_j$.

L'énergie discrète associée au Laplacien $L = D - W$ devient :

$$f^\top L f = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2.$$

Le poids w_{ij} apparaît naturellement afin de tenir compte de l'intensité de la connexion entre les sommets i et j .

Ainsi :

- si w_{ij} est grand, alors les sommets sont fortement liés et les fortes variations entre f_i et f_j sont fortement pénalisées ;
- si w_{ij} est faible, alors les variations entre ces sommets sont moins coûteuses.

Le Laplacien discret mesure donc une énergie de variation pondérée par la structure de connectivité du graphe.

Le quotient de Rayleigh discret

$$R(f) = \frac{f^\top L f}{f^\top f},$$

joue exactement le même rôle variationnel que dans le cadre continu : les vecteurs propres du Laplacien minimisent successivement ce quotient, et les plus petites valeurs propres correspondent ainsi aux fonctions de plus faible énergie, c'est-à-dire aux fonctions variant peu sur les régions fortement connectées du graphe.

6.4 Positivité du Laplacien

Théorème 6.4.1. *Le Laplacien L est une matrice symétrique positive.*

Preuve. Par symétrie de W et D et par linéarité de la transposée, il vient directement :

$$L^\top = L.$$

De plus :

$$f^\top Lf = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2 \geq 0.$$

Donc L est de surcroît “positive”. □

Remarque 29. Toutes les valeurs propres du Laplacien sont donc réelles et positives.

6.5 Le noyau du Laplacien

Une propriété fondamentale apparaît immédiatement.

Proposition 6.5.1. Le vecteur constant :

$$\mathbb{1} = (1, \dots, 1)^\top$$

vérifie :

$$L\mathbb{1} = 0.$$

Preuve. Pour tout sommet i on a :

$$(L\mathbb{1})_i = d_i - \sum_j w_{ij}.$$

Or par définition même, $d_i = \sum_j w_{ij}$. Donc :

$$(L\mathbb{1})_i = 0.$$

□

On en conclut que 0 est **toujours** valeur propre du Laplacien. Cette propriété possède une interprétation géométrique profonde et pourtant bien intuitive : une fonction constante ne varie pas sur le graphe, donc son énergie est nulle.

6.6 Composantes connexes et multiplicité de zéro

Le résultat suivant est le plus fondamental et justifie à lui seul tout l'intérêt du clustering spectral, et comment s'en servir en pratique pour une tâche de machine learning.

Théorème 6.6.1. *La multiplicité de la valeur propre 0 du Laplacien est exactement égale au nombre de composantes connexes du graphe.*

Dans ce cas, un graphe connexe possède une unique valeur propre nulle, tandis que plusieurs composantes connexes produisent plusieurs directions constantes indépendantes.

Ce résultat possède une interprétation géométrique et physique très profonde. Le Laplacien mesure les variations locales ou les phénomènes de diffusion sur le graphe. Une valeur propre nulle correspond

donc à une direction pour laquelle aucune diffusion n'est observée : l'énergie associée est exactement nulle.

Or, sur une composante connexe, une fonction constante ne crée aucune variation entre sommets voisins. Chaque composante connexe engendre ainsi naturellement une direction indépendante de diffusion stationnaire. Les composantes connexes du graphe apparaissent exactement comme les régions où **la diffusion reste parfaitement stable** !

Même lorsque les clusters ne sont pas parfaitement déconnectés, les premiers vecteurs propres du Laplacien restent presque constants sur les communautés du graphe et révèlent ainsi les structures cachées des données.

Preuve. Commençons par supposer que le graphe possède exactement k composantes connexes, notées :

$$C_1, \dots, C_k.$$

Pour chaque composante C_ℓ , considérons la fonction indicatrice :

$$\begin{aligned} \mathbb{1}_{C_\ell} : V &\rightarrow \mathbb{R} \\ i &\mapsto \mathbb{1}_{C_\ell}(i) = \begin{cases} 1 & \text{si } i \in C_\ell, \\ 0 & \text{sinon.} \end{cases} \end{aligned}$$

Remarque 30. La fonction indicatrice $\mathbb{1}_{C_\ell} : V \rightarrow \mathbb{R}$ est volontairement confondue et identifiée au vecteur de $\mathbb{R}^n$:

$$(\mathbb{1}_{C_\ell}(1), \dots, \mathbb{1}_{C_\ell}(n))^\top.$$

Une fonction définie sur les sommets du graphe peut être **vue comme un vecteur** dont les composantes sont les valeurs prises sur chaque sommet. Cette identification permet alors de faire agir les matrices du graphe, et notamment le Laplacien $L\mathbb{1}_{C_\ell}$.

Montrons que $L\mathbb{1}_{C_\ell} = 0$. Pour ce faire, considérons un sommet $i \in C_\ell$. Comme aucune arête ne relie deux composantes connexes distinctes, tous les voisins de i appartiennent encore à C_ℓ , d'où :

$$(\mathbb{1}_{C_\ell})_i = 1,$$

et pour tout voisin j , on a :

$$(\mathbb{1}_{C_\ell})_j = 1.$$

On obtient donc :

$$(L\mathbb{1}_{C_\ell})_i = \sum_j w_{ij} \left((\mathbb{1}_{C_\ell})_i - (\mathbb{1}_{C_\ell})_j \right) = 0.$$

De même, si $i \notin C_\ell$, alors $(\mathbb{1}_{C_\ell})_i = 0$, et tous ses voisins appartiennent à la même composante connexe que i . Ainsi $(\mathbb{1}_{C_\ell})_j = 0$ pour tous ses voisins j , et donc $(L\mathbb{1}_{C_\ell})_i = 0$. Finalement :

$$L\mathbb{1}_{C_\ell} = 0.$$

Nous avons donc construit k vecteurs propres associés à la valeur propre 0. De plus, ces vecteurs sont linéairement indépendants car leurs supports sont disjoints. Ainsi :

$$\dim(\ker L) \geq k. \tag{6.1}$$

Montrons maintenant l'inégalité réciproque *de sorte à montrer qu'il y a exactement k composantes*. Soit $f \in \ker(L)$. Alors

$$Lf = 0.$$

En multipliant à gauche par $f^\top$, on obtient :

$$f^\top Lf = 0 \iff \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2 = 0.$$

par Proposition 6.3.1. Tous les termes étant positifs, cette somme est nulle si et seulement si

$$w_{ij} (f_i - f_j)^2 = 0$$

pour toute paire (i, j) . Ainsi, dès que $w_{ij} > 0$, on doit avoir $f_i = f_j$. Ainsi, la fonction f est constante sur chaque composante connexe du graphe. Par conséquent, toute fonction du noyau de L s'écrit comme combinaison linéaire des fonctions indicatrices $\mathbb{1}_{C_1}, \dots, \mathbb{1}_{C_k}$. Donc,

$$\dim(\ker L) \leq k. \quad (6.2)$$

Finalement, en combinant (6.1) et (6.2) :

$$\dim(\ker L) = k.$$

La multiplicité de la valeur propre 0 est donc exactement égale au nombre de composantes connexes du graphe. $\square$

Remarque 31 (Interprétation conceptuelle). Les vecteurs propres associés à la valeur propre nulle sont exactement les fonctions qui ne varient pas à l'intérieur des composantes connexes :

- le Laplacien annule les fonctions constantes sur chaque communauté ;
- les composantes connexes apparaissent comme des régions d'énergie nulle ;
- les vecteurs propres du noyau codent directement la structure de connectivité du graphe.

Dans un graphe parfaitement séparé en plusieurs groupes indépendants, les vecteurs propres associés à $\lambda = 0$ permettent donc de reconstruire exactement les clusters.

Lien avec le clustering spectral. En pratique, les graphes issus de données réelles ne possèdent presque jamais de composantes parfaitement déconnectées. Les clusters restent généralement reliés par quelques arêtes faibles. Dans ce cas, la valeur propre 0 reste simple mais plusieurs petites valeurs propres apparaissent. Les vecteurs propres associés deviennent presque constants sur les régions fortement connectées. Les premiers vecteurs propres du Laplacien fournissent tout de même naturellement des coordonnées révélant l'appartenance des sommets aux différents groupes du graphe.

Les vecteurs propres comme modes de variation. Comme dans le cadre continu, les vecteurs propres du Laplacien représentent des modes fondamentaux de variation. Les petites valeurs propres correspondent aux fonctions qui minimisent l'énergie $f^\top Lf$. Ces fonctions varient peu entre sommets fortement connectés mais peuvent changer entre régions faiblement connectées. Ainsi, les premiers vecteurs propres non triviaux deviennent presque constants sur les communautés du graphe : c'est précisément cette propriété qui permet de détecter les clusters ! Enfin, notons que le Laplacien de graphe constitue un analogue discret du Laplacien continu :

$$\Delta \iff L = D - W.$$


Dans les deux cas :

- les petites valeurs propres correspondent à des modes de faible énergie ;
- ces modes restent réguliers sur les régions fortement connectées ;
- les grandes structures géométriques émergent naturellement des fonctions propres.

Le clustering spectral consiste alors à exploiter ces vecteurs propres pour construire une représentation géométrique des données révélant automatiquement les communautés du graphe : le clustering spectral transforme un problème de partitionnement en un problème d'analyse harmonique discrète.

Un exemple de calcul explicite. Considérons le graphe :

$$1 \longleftrightarrow 2 \longleftrightarrow 3 \qquad 4 \longleftrightarrow 5.$$



Ce graphe possède deux composantes connexes : $\{1, 2, 3\}$ et $\{4, 5\}$.
Sa matrice d'adjacence est :

$$W = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 & 0 \end{pmatrix}.$$

Les degrés des sommets sont :

$$d_1 = 1, \quad d_2 = 2, \quad d_3 = 1, \quad d_4 = 1, \quad d_5 = 1.$$

Donc :

$$D = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}.$$

Le Laplacien non normalisé vaut alors :

$$L = D - W = \begin{pmatrix} 1 & -1 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 \\ 0 & -1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & -1 \\ 0 & 0 & 0 & -1 & 1 \end{pmatrix}.$$

On observe que cette matrice est par blocs :

$$L = \begin{bmatrix} L_1 & 0 \\ 0 & L_2 \end{bmatrix},$$

avec :

$$L_1 = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{pmatrix}, \quad L_2 = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}.$$

Le bloc L_1 correspond à la composante $1 \longleftrightarrow 2 \longleftrightarrow 3$, tandis que le bloc L_2 correspond à la composante $4 \longleftrightarrow 5$.

Commençons par étudier le **premier bloc** L_1 . Son polynôme caractéristique est :

$$\chi_{L_1}(\lambda) = \det(L_1 - \lambda I_3) = -\lambda(\lambda - 1)(\lambda - 3).$$

Ses valeurs propres sont donc 0, 1 et 3. Pour la valeur propre 0, un vecteur propre est :

$$u_1 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}.$$

Ce vecteur est constant sur la première composante connexe. Cela signifie qu'il n'y a aucune variation entre les sommets 1, 2 et 3.

Pour la valeur propre 1, on peut prendre :

$$u_2 = \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}.$$

Pour la valeur propre 3, on peut prendre :

$$u_3 = \begin{pmatrix} 1 \\ -2 \\ 1 \end{pmatrix}.$$

Étudions maintenant le second bloc :

$$L_2 = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}.$$

Son polynôme caractéristique est :

$$\chi_{L_2}(\lambda) = \det(L_2 - \lambda I_2) = \lambda(\lambda - 2).$$

Ses valeurs propres sont donc 0 et 2. Un vecteur propre associé à la valeur propre 0 est :

$$v_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix},$$

qui est constant sur la composante $\{4, 5\}$.

Un vecteur propre associé à la valeur propre 2 est :

$$v_2 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

En réunissant les deux blocs, les valeurs propres du Laplacien complet sont :

$$0, \quad 0, \quad 1, \quad 2, \quad 3.$$

On obtient donc bien deux valeurs propres nulles, ce qui correspond exactement aux deux composantes connexes du graphe.

Les deux vecteurs propres associés à la valeur propre 0 peuvent être écrits dans $\mathbb{R}^5$ sous la forme :

$$\mathbb{1}_{\{1,2,3\}} = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 0 \\ 0 \end{pmatrix}, \quad \mathbb{1}_{\{4,5\}} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 1 \\ 1 \end{pmatrix}.$$

Ces deux vecteurs codent directement les deux composantes connexes du graphe. Ils sont constants sur une composante et nuls sur l'autre.

Interprétation spectrale

Dans cet exemple, le spectre du Laplacien reconstruit exactement la structure de connectivité du graphe.

La multiplicité de la valeur propre 0 est égale à 2, ce qui indique qu'il existe deux composantes connexes.

Les vecteurs propres associés à $\lambda = 0$ sont précisément les fonctions indicatrices des deux composantes :

$$\mathbb{1}_{\{1,2,3\}} \quad \text{et} \quad \mathbb{1}_{\{4,5\}}.$$

Ainsi, dans un cas idéal parfaitement déconnecté, le clustering spectral permet de retrouver exactement les clusters.

Cet exemple illustre concrètement le théorème général : le nombre de valeurs propres nulles du Laplacien est égal au nombre de composantes connexes du graphe. Dans les problèmes réels, les clusters ne sont généralement pas totalement déconnectés. Les valeurs propres ne sont alors plus exactement nulles, mais les premières valeurs propres restent petites, et les vecteurs propres associés demeurent presque constants sur les régions fortement connectées.

Un court rappel de diagonalisation par blocs. Le Laplacien précédent possède une structure particulièrement simple : il est *diagonal par blocs*. Dans cette situation, chaque bloc agit indépendamment sur une partie des coordonnées, sans interaction avec les autres blocs. Il suffit alors de diagonaliser séparément chaque sous-matrice, puis de reconstruire la diagonalisation globale en concaténant les vecteurs propres obtenus, complétés par des zéros aux positions adéquates. Plus généralement, si une matrice s'écrit

$$M = \left[\begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right],$$

alors sa diagonalisation se déduit directement de celles de A et de B .

Proposition 6.6.1 (Diagonalisation d'une matrice diagonale par blocs). Soient $A \in \mathbb{R}^{p \times p}$ et $B \in \mathbb{R}^{q \times q}$. On considère la matrice

$$M = \left[\begin{array}{c|c} A & 0 \\ \hline 0 & B \end{array} \right] \in \mathbb{R}^{(p+q) \times (p+q)}.$$

Si A et B sont diagonalisables, alors M est diagonalisable. Plus précisément, si

$$A = P_A D_A P_A^{-1} \quad \text{et} \quad B = P_B D_B P_B^{-1},$$

alors

$$M = \left[\begin{array}{c|c} P_A & 0 \\ \hline 0 & P_B \end{array} \right] \left[\begin{array}{c|c} D_A & 0 \\ \hline 0 & D_B \end{array} \right] \left[\begin{array}{c|c} P_A^{-1} & 0 \\ \hline 0 & P_B^{-1} \end{array} \right].$$

Ainsi, les valeurs propres de M sont exactement les valeurs propres de A et celles de B , comptées avec multiplicités.

Chapitre 7

Le clustering spectral

On a présenté en profondeur les différents outils mathématiques qui servent à introduire le clustering spectral. Le point central des chapitres précédents était le suivant :

les premiers vecteurs propres du Laplacien révèlent naturellement les grandes structures de connectivité du graphe.

Ce chapitre consiste désormais à transformer et exploiter cette intuition spectrale en un véritable algorithme de clustering.

Les vecteurs propres révèlent les clusters. On l'a bien exposé dans les chapitres précédents, les vecteurs propres du Laplacien discret révèle des composantes s'apparentant à des clusters. Supposons d'abord un cas idéal où le graphe possède exactement k composantes connexes parfaitement séparées. Dans ce cas, nous avons démontré que L possède exactement k valeurs propres nulles, par Théorème 6.6.1. Les vecteurs propres associés sont les fonctions indicatrices des composantes connexes :

$$\mathbb{1}_{C_1}, \dots, \mathbb{1}_{C_k}.$$

Ainsi, tous les sommets d'un même cluster reçoivent exactement la même valeur et deux clusters distincts reçoivent des valeurs différentes. Les vecteurs propres encodent directement l'appartenance aux groupes.

Idée fondamentale

Dans un graphe parfaitement séparé, les vecteurs propres du Laplacien reconstruisent exactement les clusters.

Bien entendu, les données réelles ne produisent jamais des composantes totalement déconnectées. Cependant, lorsque les connexions entre groupes restent faibles, les premières valeurs propres restent petites et les vecteurs propres associés deviennent presque constants sur les communautés.

Étape 1 : construction du graphe

On dispose d'observations $(X_1, \dots, X_n) \in \mathbb{R}^p$. La première étape consiste à construire un graphe de similarité. Chaque observation devient un sommet du graphe et les arêtes sont ensuite construites :

- soit par voisinage ε ;
- soit par graphe des k plus proches voisins ;
- soit via un noyau gaussien.

Ce dernier cas de figure consitue d'ailleurs un choix assez fréquent, où les poids w_{ij} sont définis comme tels :

$$w_{ij} = \exp\left(-\frac{\|X_i - X_j\|^2}{2\sigma^2}\right).$$

Le graphe encode toute la géométrie locale des données.

Étape 2 : construction du Laplacien

On construit ensuite la matrice

$$W = (w_{ij})_{1 \leq i, j \leq n},$$

puis la matrice de degré :

$$D = \text{diag}(d_1, \dots, d_n), \quad d_i = \sum_j w_{ij}.$$

Le Laplacien à ce stade non normalisé est la différence de D avec W :

$$L = D - W.$$

En pratique, les variantes normalisées sont souvent préférées.

Définition 7.0.1 (Laplacien normalisé symétrique). On définit le Laplacien normalisé symétrique par :

$$L_{\text{sym}} = I - D^{-1/2} W D^{-1/2}.$$

Cette normalisation consiste à rééquilibrer les interactions du graphe en tenant compte du degré de chaque sommet. Intuitivement, plutôt que de considérer uniquement les poids bruts w_{ij} , on compare les connexions relativement à l'importance globale des sommets concernés. Le terme :

$$D^{-1/2} W D^{-1/2}$$

renormalise ainsi les similarités afin qu'un sommet de très grand degré ne domine pas artificiellement toute la structure spectrale¹. D'un point de vue géométrique, cette construction permet d'obtenir un opérateur mieux équilibré et plus stable lorsque les degrés varient fortement dans le graphe.

Remarque 32 (Intérêt algorithmique). Le Laplacien normalisé symétrique possède plusieurs avantages pratiques :

- ses valeurs propres restent contrôlées dans un intervalle borné ;
- les vecteurs propres obtenus sont souvent plus robustes numériquement ;
- les clusters deviennent mieux séparés lorsque les degrés sont hétérogènes.

C'est aujourd'hui l'une des variantes les plus utilisées en clustering spectral.

Définition 7.0.2 (Laplacien *random walk*). On définit également le Laplacien de marche aléatoire :

$$L_{\text{rw}} = I - D^{-1} W.$$

Cette définition possède une interprétation probabiliste très profonde. La matrice $D^{-1} W$ peut être vue comme une matrice de transition d'une marche aléatoire sur le graphe. En effet, le terme

$$(D^{-1} W)_{ij} = \frac{w_{ij}}{d_i}$$

représente la probabilité de passer du sommet i au sommet j . Le Laplacien $L_{\text{rw}} = I - D^{-1} W$ mesure alors l'écart entre une fonction et sa moyenne locale obtenue après diffusion sur le graphe, et encode ainsi les phénomènes de propagation et de diffusion d'information sur le réseau.

Remarque 33 (Intérêt algorithmique). Le Laplacien *random walk* est particulièrement pertinent lorsque l'on souhaite interpréter le clustering spectral en termes de diffusion ou de dynamique probabiliste et intervient naturellement dans les marches aléatoires sur graphes, les méthodes de diffusion, l'algorithme de PageRank, les diffusion maps, les modèles probabilistes de communautés, ... Les vecteurs propres associés décrivent alors des modes de diffusion pour lesquels l'information, l'énergie ou la chaleur se propage très rapidement à l'intérieur d'un même cluster grâce aux nombreuses connexions locales, mais beaucoup plus lentement entre clusters en raison du faible nombre de connexions reliant ces régions du graphe.

1. Comme $D = \text{diag}(d_1, \dots, d_n)$ est une matrice diagonale à coefficients strictement positifs, on définit : $D^{-1/2} = \text{diag}\left(\frac{1}{\sqrt{d_1}}, \dots, \frac{1}{\sqrt{d_n}}\right)$, qui existe nécessairement et vérifie $D^{-1/2} D^{-1/2} = D^{-1}$.

Étape 3 : diagonalisation du Laplacien

On calcule ensuite les premiers vecteurs propres du Laplacien. Supposons que l'on cherche k clusters. On extrait alors les vecteurs propres associés aux k plus petites valeurs propres, notés $u_1, \dots, u_k$. On construit ensuite la matrice :

$$U = \begin{pmatrix} | & & | \\ u_1 & \dots & u_k \\ | & & | \end{pmatrix} \in \mathbb{R}^{n \times k},$$

qui constitue le cœur de l'algorithme spectral.

Interprétation géométrique de la matrice U . Chaque ligne de U correspond à un sommet du graphe. Par conséquent, $U_i = (U_{i1}, \dots, U_{ik})$ fournit une nouvelle représentation géométrique du sommet i . Les données initiales sont désormais représentées dans un espace spectral.

Embedding spectral

Le clustering spectral projette les sommets dans un nouvel espace construit à partir des premiers vecteurs propres du Laplacien.

Dans cet espace, les sommets appartenant à une même communauté deviennent proches et les sommets de communautés différentes deviennent séparés. Les clusters deviennent alors beaucoup plus simples à identifier.

Les lignes de U révèlent-elles les clusters. Dans le cas idéal de k composantes connexes parfaitement séparées, les vecteurs $u_1, \dots, u_k$ sont exactement les fonctions indicatrices des composantes. Ainsi, U_i est identique pour tous les sommets appartenant au même cluster. Les lignes de U se regroupent donc automatiquement en k groupes distincts.

Certes, dans le cas réel les connexions entre groupes ne sont pas nulles mais les premiers vecteurs propres restent presque constants sur les communautés. Les lignes de U forment alors des nuages bien séparés dans l'espace spectral.

Étape 4 : application du k -means

Une fois les données projetées dans l'espace spectral $\mathbb{R}^k$, on applique généralement l'algorithme du k -means aux lignes de U .

Algorithme complet

Algorithme du clustering spectral

Entrée : observations $X_1, \dots, X_n$, et nombre de clusters k .

Étape 1 : Construire un graphe de similarité et sa matrice d'adjacence W .

Étape 2 : Construire le Laplacien L , L_{sym} ou L_{rw} .

Étape 3 : Calculer les k premiers vecteurs propres, stockés dans $U = [u_1 \mid \dots \mid u_k] \in \mathbb{R}^{n \times k}$.

Étape 4 : Appliquer le k -means aux lignes de U .

Sortie : partition des observations en k clusters.

Le succès du clustering spectral provient du fait qu'il ne repose pas directement sur la géométrie euclidienne brute des données. Au lieu de cela, il exploite la connectivité locale, reconstruit la géométrie intrinsèque du graphe et extrait les modes de faible énergie du Laplacien. Les vecteurs propres du Laplacien capturent alors les grandes structures de diffusion du graphe.

Chapitre 8

Exercices de clustering spectral

Le clustering spectral est particulièrement adapté aux situations où la géométrie des données ne peut pas être correctement séparée par des méthodes purement euclidiennes comme le k -means classique.

Dans les exercices suivants, on cherche à modéliser des situations concrètes sous forme de graphes de similarité, puis à interpréter les structures spectrales du Laplacien afin d'identifier des communautés, groupes ou comportements collectifs.

Les exercices sont volontairement rédigés dans des contextes appliqués afin de mettre en évidence la portée moderne du clustering spectral dans des domaines variés : réseaux sociaux, biologie, transport, recommandation ou encore cybersécurité.

8.1 Énoncés

Exercice 1 — Détection de communautés dans un réseau social

Une plateforme de réseau social souhaite analyser les interactions entre utilisateurs afin d'identifier automatiquement des communautés d'intérêts. On considère un ensemble de $n = 12$ utilisateurs. Deux utilisateurs sont reliés lorsqu'ils interagissent fréquemment entre eux (messages, mentions, commentaires, etc.). Le graphe observé est présenté en Figure 8.1.




FIGURE 8.1 – Graphe associé aux données de l'Exercice 1.

Questions.

1. Construire la matrice d'adjacence W du graphe.
2. Construire la matrice de degré D .
3. En déduire le Laplacien non normalisé $L = D - W$.
4. Expliquer intuitivement pourquoi le graphe semble contenir plusieurs communautés.
5. Sans calcul exact des valeurs propres, discuter qualitativement du nombre de petites valeurs propres attendues.
6. Expliquer pourquoi les premiers vecteurs propres du Laplacien devraient permettre de révéler les groupes d'utilisateurs.

Exercice 2 — Clustering spectral de clients d'un service de streaming

Une plateforme de streaming souhaite segmenter ses utilisateurs selon leurs habitudes de visionnage. Chaque utilisateur est représenté par un vecteur :

$$X_i = (x_{i1}, x_{i2}, x_{i3}, x_{i4}),$$

où :

- x_{i1} représente le temps moyen passé sur les films ;
- x_{i2} le temps moyen passé sur les séries ;
- x_{i3} le nombre de documentaires visionnés ;
- x_{i4} le nombre de contenus jeunesse visionnés.

On définit une similarité gaussienne :

$$w_{ij} = \exp\left(-\frac{\|X_i - X_j\|^2}{2\sigma^2}\right).$$

On suppose que certains utilisateurs ont des comportements très similaires mais que les groupes ne sont pas linéairement séparables dans l'espace original.

1. Expliquer pourquoi une matrice de similarité pondérée peut être plus pertinente qu'un graphe binaire.
2. Décrire la construction de la matrice d'adjacence pondérée W .
3. Définir la matrice de degré D associée.
4. Écrire les expressions des Laplaciens :

$$L = D - W,$$

$$L_{\text{sym}} = I - D^{-1/2} W D^{-1/2},$$

et

$$L_{\text{rw}} = I - D^{-1} W.$$

5. Expliquer qualitativement pourquoi les premiers vecteurs propres peuvent révéler les groupes d'utilisateurs.
6. Pourquoi l'application finale du k -means se fait-elle dans l'espace spectral plutôt que directement sur les données initiales ?

Exercice 3 — Analyse de connexions ferroviaires

Une compagnie ferroviaire souhaite identifier automatiquement des régions fortement interconnectées de son réseau, où chaque sommet représente une gare. Le poids w_{ij} correspond au nombre moyen de trains quotidiens entre les gares i et j . Le réseau est représenté par la matrice :

$$W = \begin{pmatrix} 0 & 8 & 7 & 0 & 0 & 0 \\ 8 & 0 & 6 & 0 & 0 & 0 \\ 7 & 6 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 7 & 8 \\ 0 & 0 & 0 & 7 & 0 & 6 \\ 0 & 0 & 0 & 8 & 6 & 0 \end{pmatrix}.$$

1. Faire une esquisse du graphe pondéré associé à la matrice W . On pourra adopter la convention graphique suivante : plus le poids w_{ij} est élevé, plus les gares i et j sont représentées proches l'une de l'autre.
2. Construire la matrice de degré D .
3. Calculer le Laplacien non normalisé $L = D - W$.
4. Identifier visuellement les zones fortement connectées du réseau.
5. Expliquer pourquoi l'arête reliant les sommets 3 et 4 joue un rôle particulier.
6. Décrire qualitativement la structure attendue des premiers vecteurs propres du Laplacien.
7. Interpréter le clustering spectral dans le contexte de l'organisation du trafic ferroviaire.

Exercice 4 — Détection de groupes de gènes en biologie

En biologie moléculaire, certains gènes présentent des comportements d'expression similaires au cours du temps. On mesure l'expression de n gènes sur m instants temporels :

$$X_i = (x_i(t_1), \dots, x_i(t_m)), \quad i = 1, \dots, n.$$

On construit une similarité entre deux gènes $i, j \in \{1, \dots, n\}$:

$$w_{ij} = \text{corr}(X_i, X_j)^2.$$

1. Expliquer pourquoi une corrélation forte peut traduire une proximité fonctionnelle entre deux gènes.
2. Pourquoi le clustering spectral est-il particulièrement adapté à ce type de données biologiques ?
3. Décrire la construction du graphe de similarité associé.
4. Expliquer pourquoi les groupes de gènes peuvent former des structures non convexes dans l'espace initial.
5. Interpréter les petites valeurs propres du Laplacien dans ce contexte.
6. Que représentent concrètement les clusters obtenus pour les biologistes ?

Exercice 5 — Détection d'activités suspectes sur un réseau informatique

Une entreprise souhaite détecter automatiquement des comportements anormaux dans son réseau informatique. Chaque machine est représentée par un sommet. Deux machines sont reliées lorsque des échanges réseau sont observés entre elles. On construit un poids :

$$w_{ij} = \frac{\text{nombre de communications entre } i \text{ et } j}{\text{temps total observé}}.$$

On observe :

- plusieurs groupes de machines communiquant fréquemment entre elles ;
 - quelques connexions rares entre groupes ;
 - un petit ensemble de machines présentant des comportements très atypiques.
1. Expliquer pourquoi ce problème peut être modélisé sous forme de graphe pondéré.
 2. Décrire qualitativement la structure attendue de la matrice d'adjacence W .
 3. Quel type de structure spectrale pourrait révéler l'existence de communautés fortement connectées ?
 4. Pourquoi les machines atypiques peuvent-elles perturber le clustering classique ?
 5. Expliquer pourquoi l'espace spectral peut rendre les comportements suspects plus visibles.
 6. Discuter les avantages du clustering spectral pour la cybersécurité.

8.2 Corrigés

Correction de l'exercice 1

Question 1. Le graphe contient trois communautés principales :

$$\{1, 2, 3, 4\}, \quad \{5, 6, 7, 8\}, \quad \{9, 10, 11, 12\},$$

reliées entre elles par deux arêtes :

$$4 \leftrightarrow 5, \quad 6 \leftrightarrow 9.$$

La matrice d'adjacence associée est :

$$W = \begin{pmatrix} 0 & 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 1 & 1 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 1 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 & 0 \end{pmatrix}.$$

Question 2. Les degrés des sommets sont :

$$d_1 = d_2 = d_3 = 3, \quad d_4 = 4,$$

$$d_5 = d_6 = 4, \quad d_7 = d_8 = 3,$$

$$d_9 = 4, \quad d_{10} = d_{11} = d_{12} = 3.$$

La matrice de degré vaut donc :

$$D = \text{diag}(3, 3, 3, 4, 4, 4, 3, 3, 4, 3, 3, 3).$$

Question 3. Le Laplacien non normalisé est défini par :

$$L = D - W.$$

On obtient :

$$L = \begin{pmatrix} 3 & -1 & -1 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ -1 & 3 & -1 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ -1 & -1 & 3 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ -1 & -1 & -1 & 4 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & -1 & 4 & -1 & -1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -1 & 4 & -1 & -1 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -1 & -1 & 3 & -1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -1 & -1 & -1 & 3 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & -1 & 0 & 0 & 4 & -1 & -1 & -1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & -1 & 3 & -1 & -1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & -1 & -1 & 3 & -1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & -1 & -1 & -1 & 3 \end{pmatrix}.$$

Question 4. Le graphe semble contenir plusieurs communautés car les connexions sont très nombreuses à l'intérieur de chacun des groupes :

$$\{1, 2, 3, 4\}, \quad \{5, 6, 7, 8\}, \quad \{9, 10, 11, 12\},$$

alors qu'il existe très peu de connexions entre ces groupes. Les arêtes $4 \leftrightarrow 5$ et $6 \leftrightarrow 9$ jouent le rôle de ponts faibles entre communautés.

Question 5. Si les trois communautés étaient totalement déconnectées, alors le Laplacien posséderait exactement trois valeurs propres nulles. Ici, le graphe reste connexe, donc la valeur propre 0 est simple. Cependant, comme les trois communautés sont faiblement reliées, on s'attend à observer plusieurs petites valeurs propres proches de 0.

Question 6. Les premiers vecteurs propres du Laplacien minimisent l'énergie :

$$f^\top Lf = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2.$$

Ils varient donc peu à l'intérieur des régions fortement connectées et changent principalement entre communautés. Ainsi, les coordonnées spectrales des sommets appartenant à une même communauté deviennent proches dans l'espace spectral.

Correction de l'exercice 2

Question 1. Une matrice de similarité pondérée est plus pertinente qu'un graphe binaire car elle conserve l'intensité des relations entre utilisateurs. Deux utilisateurs très similaires auront un poids proche de 1, tandis que deux utilisateurs très différents auront un poids proche de 0. Un graphe binaire perd cette information fine de proximité.

Question 2. La matrice d'adjacence pondérée est définie par :

$$W = (w_{ij})_{1 \leq i,j \leq n},$$

avec

$$w_{ij} = \exp\left(-\frac{\|X_i - X_j\|^2}{2\sigma^2}\right).$$

Deux utilisateurs proches dans l'espace des comportements auront donc une similarité élevée.

Question 3. La matrice de degré associée est :

$$D = \text{diag}(d_1, \dots, d_n), \quad \text{où} \quad d_i = \sum_{j=1}^n w_{ij}.$$

Le degré d_i mesure la similarité totale de l'utilisateur i avec le reste de la population.

Question 4. Les trois Laplaciens sont :

$$L = D - W,$$

$$L_{\text{sym}} = I - D^{-1/2} W D^{-1/2},$$

et

$$L_{\text{rw}} = I - D^{-1} W.$$

Les Laplaciens normalisés permettent généralement une meilleure stabilité géométrique lorsque les degrés sont très hétérogènes.

Question 5. Les premiers vecteurs propres minimisent l'énergie $f^\top Lf$, pour toute application f définie sur le graphe. Ils restent donc presque constants sur les groupes fortement connectés. Les utilisateurs similaires deviennent alors proches dans l'espace spectral.

Question 6. Dans l'espace original, les groupes peuvent être non convexes ou très imbriqués. Le clustering spectral transforme les données dans un nouvel espace où les communautés deviennent plus facilement séparables. Le k -means devient alors beaucoup plus efficace.

Correction de l'exercice 3

Question 1. Le graphe contient deux zones fortement connectées :

$$\{1, 2, 3\} \quad \text{et} \quad \{4, 5, 6\}.$$

Les poids internes sont élevés :

$$6, 7, 8,$$

alors que l'arête reliant les deux groupes possède un poids très faible :

$$w_{34} = 1.$$

Une représentation pertinente consiste donc à dessiner les sommets fortement reliés proches les uns des autres et à représenter l'arête entre 3 et 4 comme une liaison longue et faible.

Question 2. Les degrés sont :

$$d_1 = 15, \quad d_2 = 14, \quad d_3 = 14,$$

$$d_4 = 16, \quad d_5 = 13, \quad d_6 = 14.$$

Donc :

$$D = \begin{pmatrix} 15 & 0 & 0 & 0 & 0 & 0 \\ 0 & 14 & 0 & 0 & 0 & 0 \\ 0 & 0 & 14 & 0 & 0 & 0 \\ 0 & 0 & 0 & 16 & 0 & 0 \\ 0 & 0 & 0 & 0 & 13 & 0 \\ 0 & 0 & 0 & 0 & 0 & 14 \end{pmatrix}.$$

Question 3. Le Laplacien non normalisé vaut :

$$L = D - W.$$

Ainsi :

$$L = \begin{pmatrix} 15 & -8 & -7 & 0 & 0 & 0 \\ -8 & 14 & -6 & 0 & 0 & 0 \\ -7 & -6 & 14 & -1 & 0 & 0 \\ 0 & 0 & -1 & 16 & -7 & -8 \\ 0 & 0 & 0 & -7 & 13 & -6 \\ 0 & 0 & 0 & -8 & -6 & 14 \end{pmatrix}.$$

Question 4. Les groupes

$$\{1, 2, 3\} \quad \text{et} \quad \{4, 5, 6\}$$

sont fortement connectés en interne.

Les poids élevés traduisent un trafic ferroviaire important à l'intérieur de chaque région.

Question 5. L'arête reliant 3 et 4 joue un rôle de pont faible entre les deux sous-réseaux.

Sans cette arête, le graphe serait séparé en deux composantes connexes distinctes.

Cette liaison faible est donc cruciale pour la connectivité globale du réseau.

Question 6. On s'attend à ce que le premier vecteur propre soit constant sur l'ensemble du graphe. Le deuxième vecteur propre devrait prendre des valeurs proches sur $\{1, 2, 3\}$ et d'autres valeurs proches sur $\{4, 5, 6\}$. Il devrait donc révéler naturellement les deux régions ferroviaires.

Question 7. Le clustering spectral permettrait d'identifier automatiquement des bassins de circulation ferroviaire.

Ces groupes pourraient être utilisés pour :

- optimiser l'organisation du trafic ;
- identifier des zones fortement dépendantes ;
- détecter des liaisons critiques ;
- ou encore découper le réseau en régions opérationnelles.

Correction de l'exercice 4

Question 1. Deux gènes fortement corrélés présentent des profils d'expression similaires au cours du temps.

Cela peut indiquer qu'ils participent à un même mécanisme biologique ou qu'ils sont co-régulés.

Question 2. Le clustering spectral est particulièrement adapté car les structures biologiques peuvent être très complexes et non convexes.

La géométrie euclidienne classique ne suffit souvent pas à révéler ces relations.

Question 3. Chaque gène devient un sommet du graphe.

Deux gènes i et j sont reliés par un poids :

$$w_{ij} = \text{corr}(X_i, X_j)^2.$$

Plus la corrélation est forte, plus l'arête est importante.

Question 4. Les groupes de gènes peuvent former des structures non convexes car les relations biologiques sont souvent indirectes et organisées en réseaux complexes.

Deux gènes peuvent appartenir à une même voie biologique sans être proches au sens euclidien.

Question 5. Les petites valeurs propres du Laplacien traduisent l'existence de groupes de gènes fortement connectés entre eux mais faiblement connectés au reste du graphe. Les vecteurs propres associés deviennent alors presque constants sur ces groupes.

Question 6. Les clusters obtenus peuvent représenter :

- des voies biologiques ;
- des groupes de gènes co-régulés ;
- des signatures moléculaires ;
- ou des modules fonctionnels.

Ces regroupements fournissent des hypothèses biologiques interprétables.

Correction de l'exercice 5

Question 1. Chaque machine du réseau devient un sommet. Les échanges réseau définissent naturellement des arêtes pondérées entre machines. Le poids

$$w_{ij} = \frac{\text{nombre de communications}}{\text{temps observé}}$$

mesure l'intensité des interactions.

Question 2. La matrice W devrait présenter une structure par blocs :

- des coefficients élevés à l'intérieur des groupes ;
- des coefficients faibles entre groupes ;
- et quelques lignes atypiques correspondant à des machines suspectes.

Question 3. Plusieurs petites valeurs propres du Laplacien indiqueraient l'existence de communautés fortement connectées.

Les vecteurs propres associés permettraient de révéler ces groupes.

Question 4. Les machines atypiques peuvent perturber un clustering classique car elles ne suivent pas nécessairement une géométrie simple.

Elles peuvent être reliées à plusieurs groupes ou posséder des comportements très irréguliers.

Question 5. L'espace spectral représente les machines selon leur rôle dans la connectivité globale du réseau.

Les comportements suspects deviennent alors plus visibles géométriquement.

Question 6. Le clustering spectral permet :

- de détecter des communautés de machines ;
- d'identifier des connexions anormales ;
- de repérer des ponts suspects entre groupes ;
- et d'analyser la structure globale du réseau.

Il constitue donc un outil très pertinent pour l'analyse de cybersécurité.

Conclusion et ouvertures

Résumé

Le point de départ du clustering spectral est volontairement simple : lorsque la géométrie euclidienne devient insuffisante pour séparer correctement les données, il devient plus pertinent d'étudier les relations locales de connectivité entre observations. Cette idée conduit naturellement à transformer les données en un graphe de similarité :

$$G = (V, E),$$

où les sommets représentent les observations, les arêtes représentent des relations locales de proximité et les poids quantifient l'intensité de ces connexions. À partir de cette représentation, le problème du clustering change profondément de nature. Il ne s'agit plus simplement de rechercher des barycentres ou des régions convexes de l'espace ambiant, mais plutôt d'identifier des régions fortement connectées du graphe.

Cette reformulation fait apparaître un objet mathématique central :

$$L = D - W,$$

le Laplacien du graphe, qui mesure les variations locales d'une fonction sur le graphe, tout en constituant l'analogue discret du Laplacien différentiel. En effet, il encode la géométrie et la diffusion sur les données et ses valeurs propres révèlent les structures globales de connectivité. Le cœur théorique du clustering spectral repose alors sur une idée variationnelle fondamentale : les fonctions de faible énergie :

$$f^\top L f = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2$$

varient peu à l'intérieur des régions fortement connectées du graphe.

Les premiers vecteurs propres du Laplacien deviennent ainsi des fonctions presque constantes sur les clusters, ce qui permet de transformer un problème de géométrie complexe en un problème spectral beaucoup plus accessible.

Cette philosophie relie plusieurs domaines majeurs des mathématiques modernes : algèbre linéaire et théorie spectrale, analyse fonctionnelle, théorie des graphes, phénomène de diffusion et physique mathématique, le tout au service de l'apprentissage statistique.

Le clustering spectral constitue ainsi un exemple remarquable où des outils issus de l'analyse harmonique et des équations aux dérivées partielles deviennent directement exploitables en machine learning.

Limites et aspects pratiques

Malgré sa puissance géométrique, le clustering spectral possède plusieurs limitations importantes.

La première difficulté concerne la construction du graphe de similarité. Le choix du noyau, du paramètre σ ou du nombre de voisins, du seuil de connectivité, etc... influence fortement les résultats obtenus.

De plus, la diagonalisation spectrale devient coûteuse lorsque le nombre d'observations est très élevé. Dans les problèmes modernes à très grande échelle, des méthodes approchées ou distribuées deviennent alors nécessaires.

Enfin, comme beaucoup de méthodes non supervisées, le clustering spectral ne fournit pas une “vérité absolue” sur les données : il révèle une structure cohérente relativement à une notion de similarité choisie au préalable.

Interprétation conceptuelle du Laplacien de graphe

Le Laplacien de graphe

$$L = D - W$$

peut être interprété comme un opérateur mesurant les déséquilibres locaux de connectivité sur le graphe. En effet, la matrice d’adjacence W décrit comment cette connectivité est effectivement distribuée vers les voisins et la matrice de degré

$$D = \text{diag}(d_1, \dots, d_n), \quad d_i = \sum_j w_{ij},$$

encode l’intensité totale des connexions autour de chaque sommet. Ainsi, pour une fonction définie sur les sommets $f : V \rightarrow \mathbb{R}$, on obtient :

$$(Lf)_i = d_i f_i - \sum_j w_{ij} f_j = \sum_j w_{ij} (f_i - f_j).$$

Le Laplacien compare donc la valeur locale f_i à celles de ses voisins pondérés. Il mesure la variation locale de f sur le graphe, exactement comme le Laplacien différentiel mesure les variations locales d’une fonction dans le cadre continu.

Cette interprétation devient d’autant plus pertinente lorsque l’on exprime l’énergie (quadratique) :

$$f^\top L f = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2.$$

Cette quantité pénalise (*par principe des moindres actions*) les fortes variations entre sommets fortement connectés : plus deux sommets sont reliés, plus le modèle favorise des valeurs proches de f sur ces sommets. Les petites valeurs propres du Laplacien correspondent alors aux modes de plus faible énergie : des fonctions presque constantes sur les régions fortement connectées du graphe. C’est précisément cette propriété qui permet au clustering spectral de révéler automatiquement les communautés.

Enfin, dans le cas normalisé,

$$L_{\text{sym}} = I - D^{-1/2} W D^{-1/2} \quad \text{ou} \quad L_{\text{rw}} = I - D^{-1} W,$$

la matrice $D^{-1} W$ peut être interprétée comme un opérateur de diffusion locale ou de transition aléatoire. Les coefficients

$$\frac{w_{ij}}{d_i}$$

représentent alors des fréquences relatives de transition depuis le sommet i vers ses voisins j .

Le Laplacien normalisé compare donc chaque valeur locale à une moyenne pondérée de son voisinage : il mesure ce qui subsiste après diffusion de l’information sur le graphe.

Ouvertures

Le clustering spectral ouvre naturellement vers de nombreux sujets avancés. En machine learning moderne, les idées spectrales interviennent également dans les *diffusion maps*, le *manifold learning*, le *Laplacian Eigenmaps*, les *Graph Neural Networks*, les modèles de diffusion, l’apprentissage géométrique sur graphes, ... Plus généralement, ces domaines reposent aujourd’hui sur l’idée suivante :

la structure géométrique (ou latente via des représentations) des données est souvent plus importante que leur représentation euclidienne brute.

Ressources complémentaires

Pour approfondir les notions présentées dans ce cours, plusieurs ressources de très grande qualité peuvent être consultées. Certaines privilégient une approche intuitive et algorithmique, tandis que d'autres développent les fondements mathématiques et spectraux sous-jacents au partitionnement de graphes.

Article fondateur du clustering spectral moderne. L'article de Ng, Jordan et Weiss [NJW01] constitue l'une des références historiques majeures du clustering spectral moderne. Les auteurs y proposent une formulation algorithmique devenue classique, fondée sur le calcul des premiers vecteurs propres d'un Laplacien normalisé de graphe.

L'idée centrale consiste à transformer les données en un graphe de similarité pondéré, puis à utiliser les petites valeurs propres du Laplacien pour révéler les structures de connectivité cachées. Le papier montre notamment que les vecteurs propres associés aux plus petites valeurs propres permettent d'obtenir une représentation géométrique dans laquelle les clusters deviennent presque linéairement séparables.

L'une des contributions essentielles de l'article est l'introduction d'une étape de normalisation des vecteurs propres avant l'application finale de l'algorithme des k -means. Cette normalisation améliore fortement la stabilité géométrique et la séparation des groupes dans l'espace spectral.

Le papier propose également une analyse théorique du lien entre : la minimisation de certaines coupes de graphe (*normalized cuts*), les propriétés spectrales du Laplacien, et l'émergence des clusters comme composantes faiblement couplées. Cet article a profondément influencé : les méthodes de *manifold learning*, les *diffusion maps*, les *Laplacian Eigenmaps*, ainsi qu'une grande partie du *geometric machine learning*.

Introduction pratique et visuelle au clustering spectral. Le notebook interactif proposé par Michael Pyrcz [Pyr24] constitue une excellente introduction appliquée au clustering spectral. Le document présente :

- la construction des graphes de similarité ;
- les Laplaciens de graphe ;
- les embeddings spectraux ;
- ainsi que plusieurs visualisations Python particulièrement pédagogiques.

Cette ressource est particulièrement utile pour visualiser concrètement l'effet des premiers vecteurs propres du Laplacien sur des jeux de données classiques comme `make_moons` ou `make_circles`.

Partitionnement spectral et théorie des graphes. Les notes de cours de Luca Trevisan [Tre16] constituent une référence majeure pour comprendre les fondements théoriques du partitionnement spectral. Le document développe en profondeur les notions de graphes expanseurs, de coupes minimales, de propriétés spectrales du Laplacien, de liens entre connectivité et valeurs propres, etc... Ces notes montrent notamment pourquoi les petites valeurs propres du Laplacien contiennent une information géométrique profonde sur la structure globale du graphe.

Fondements théoriques du data science moderne. Le livre *Foundations of Data Science* de Avrim Blum, John Hopcroft et Ravi Kannan [BHK20] offre une excellente ressource générale sur les méthodes modernes de data science théorique. Le **Chapitre 7** se concentre sur le clustering et introduit les méthodes spectrales, traite des interprétations algorithmiques des valeurs propres et des graphes de similarité. L'ouvrage fait également le lien entre théorie spectrale, probabilités, algorithmes et apprentissage statistique moderne.

Le clustering spectral constitue aujourd'hui l'un des exemples les plus élégants d'interaction entre mathématiques profondes et intelligence artificielle moderne : des notions issues de la physique, de l'analyse harmonique et de la théorie spectrale deviennent des outils algorithmiques capables de révéler automatiquement la structure cachée des données.

Bibliographie

- [BHK20] Avrim Blum, John Hopcroft, and Ravi Kannan. *Foundations of Data Science*. Cambridge University Press, 2020. Particularly Chapter 7 on spectral methods and graph-based learning.
- [NJW01] Andrew Y. Ng, Michael I. Jordan, and Yair Weiss. On spectral clustering : Analysis and an algorithm. *Advances in Neural Information Processing Systems*, 14, 2001.
- [Pyr24] Michael Pyrcz. Machine learning demonstrations : Spectral clustering. https://geostatsguy.github.io/MachineLearningDemos_Book/MachineLearning_spectral_clustering.html, 2024. Accessed : 2026-05-17.
- [Tre16] Luca Trevisan. Lecture notes on graph partitioning. <https://lucatrevisan.github.io/books/expanders-2016.pdf>, 2016. Lecture notes, Accessed : 2026-05-17.